

**PENERAPAN *NONPOOLING* CNN-LSTM UNTUK PREDIKSI  
PEMAKAIAN OBAT RUMAH SAKIT**

**TUGAS AKHIR**

**Jason Nathaniel  
1117012**



**PROGRAM STUDI INFORMATIKA  
INSTITUT TEKNOLOGI HARAPAN BANGSA  
BANDUNG  
2022**

**PENERAPAN *NONPOOLING* CNN-LSTM UNTUK PREDIKSI  
PEMAKAIAN OBAT RUMAH SAKIT**

**TUGAS AKHIR**

**Diajukan sebagai salah satu syarat untuk memperoleh  
gelar sarjana dalam bidang Informatika**

**Jason Nathaniel  
1117012**



**PROGRAM STUDI INFORMATIKA  
INSTITUT TEKNOLOGI HARAPAN BANGSA  
BANDUNG  
2022**

## **HALAMAN PERNYATAAN ORISINALITAS**

**Saya menyatakan bahwa Tugas Akhir yang saya susun ini  
adalah hasil karya saya sendiri.**

**Semua sumber yang dikutip maupun dirujuk  
telah saya nyatakan dengan benar.**

**Saya bersedia menerima sanksi pencabutan gelar akademik  
apabila di kemudian hari Tugas Akhir ini terbukti plagiat.**

**Bandung, 25 Juni 2022**



**Jason Nathaniel**

**1117012**

## **HALAMAN PENGESAHAN TUGAS AKHIR**

Tugas Akhir dengan judul:

**PENERAPAN *NONPOOLING* CNN-LSTM UNTUK PREDIKSI PEMAKAIAN OBAT RUMAH SAKIT**

yang disusun oleh:

Jason Nathaniel

1117012

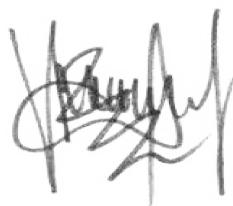
telah berhasil dipertahankan di hadapan Dewan Penguji Sidang Tugas Akhir yang dilaksanakan pada:

Hari / tanggal : Sabtu, 25 Juni 2022

Waktu : Jam 12.30 WIB

**Menyetujui,**

**Pembimbing Utama:**



**Ventje Jeremias Lewi Engel S.T., M.T., CEH**  
**116019**

## **HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI**

### **TUGAS AKHIR UNTUK KEPENTINGAN AKADEMIS**

Sebagai sivitas akademik Institut Teknologi Harapan Bangsa, saya yang bertanda tangan di bawah ini:

Nama : Jason Nathaniel

NIM : 1117012

Program Studi : Informatika

demi pengembangan ilmu pengetahuan, menyetujui untuk memberikan kepada Institut Teknologi Harapan Bangsa **Hak Bebas Royalti Noneksklusif (Non-exclusive Royalty Free Rights)** atas karya ilmiah saya yang berjudul:

**PENERAPAN NONPOOLING CNN-LSTM UNTUK PREDIKSI PEMAKAIAN OBAT RUMAH SAKIT**

beserta perangkat yang ada (jika diperlukan). Dengan Hak Bebas Royalti Noneksklusif ini Institut Teknologi Harapan Bangsa berhak menyimpan, mengalihmediakan, mengelola dalam pangkalan data, dan memublikasikan karya ilmiah saya selama tetap mencantumkan nama saya sebagai penulis/pencipta dan sebagai pemilik Hak Cipta.

Bandung, 25 Juni 2022

Yang menyatakan



Jason Nathaniel

## ABSTRAK

Nama : Jason Nathaniel  
Program Studi : Informatika  
Judul : Penerapan *Nonpooling* CNN-LSTM Untuk Prediksi Pemakaian Obat Rumah Sakit

Anggaran belanja obat di rumah sakit merupakan komponen terbesar dari pengeluaran rumah sakit (40-50%) dan pemerintah juga melalui JKN mewajibkan rumah sakit untuk memberikan pelayanan terbaik terutama sediaan farmasi yang baik. Maka dari itu, perlu adanya prediksi berapa keperluan pemakaian obat di rumah sakit sehingga dapat memenuhi sesuai dengan kebutuhan. Metode yang digunakan untuk melakukan prediksi adalah *Nonpooling* CNN-LSTM dan dibandingkan performanya dengan metode CNN-LSTM serta LSTM. Seluruh model akan dilatih menggunakan data pemakaian sebuah obat per hari di sebuah rumah sakit selama tahun 2021 dan akan dilakukan validasi hasil prediksinya menggunakan data pemakaian per hari selama tahun 2022. Model akan melakukan prediksi pemakaian obat untuk 30 hari dan 90 hari ke depan. Pengujian dilakukan dengan tiga rancangan arsitektur dengan mengombinasikan nilai jumlah *filter*, *units*, *epoch*, *learning rate* serta jumlah lapisan *Max Pooling* untuk menghasilkan nilai rata-rata *error* (RMSE) terendah. Berdasarkan hasil pengujian, model *Nonpooling* CNN-LSTM yang dibangun dapat menghasilkan nilai RMSE terendah sebesar 39.63529315 untuk prediksi 30 hari ke depan dan 54.68132489 untuk prediksi 90 hari ke depan.

**Kata kunci:** Farmasi, prediksi, pemakaian obat rumah sakit, *Convolutional Neural Network* (CNN), *Long-Short Term Memory* (LSTM), CNN-LSTM, *Nonpooling* CNN-LSTM.

## ***ABSTRACT***

*Name : Jason Nathaniel*  
*Department : Informatics*  
*Title : Application of Nonpooling CNN-LSTM for Hospital Medicine Usage*

*Hospital budget to stockpile medicine is the biggest expense (40-50%) and the government with JKN also mandate hospital to give the best service especially on pharmacy stock. Therefore, hospital needs to predict precisely how much it uses medicine to supply the needs. To make such prediction, Nonpooling CNN-LSTM will be used and the model performance will be compared with other models such as CNN-LSTM and LSTM. All models will be trained using medicine usage per day of particular medicine of the year 2021 and prediction result will be validated using medicine usage per day of particular medicine of the year 2022. Each model will predict medicine usage for the next 30 and 90 days respectively. Model testing includes three model architectures that combine parameter value such as filter, units, epoch, learning rate as well as Max Pooling layers to produce the lowest error average (RMSE) possible. Based on testing results, the Nonpooling CNN-LSTM has the lowest RMSE with 39.63529315 for prediction of the next 30 days and 54.68132489 for prediction of the next 90 days.*

***Keywords:****Pharmacy, prediction, hospital medicine usage, Convolutional Neural Network (CNN), Long-Short Term Memory (LSTM), CNN-LSTM, Nonpooling CNN-LSTM.*

## KATA PENGANTAR

Penulis mengucapkan terima kasih kepada Tuhan Yesus karena dengan karunia-Nya, penulis dapat menyelesaikan Tugas Akhir berjudul "Penerapan Nonpooling CNN-LSTM Untuk Prediksi Pemakaian Obat Rumah Sakit" dengan baik. Penelitian ini disusun sebagai salah satu syarat kelulusan Program Studi Informatika di Institut Teknologi Harapan Bangsa. Lebih dari itu, penulis ingin mencoba menghubungkan ilmu yang telah didapatkan selama masa perkuliahan ke dalam bidang pelayanan kesehatan terutama kefarmasian. Perkembangan teknologi sekarang, khususnya *deep learning*, telah memungkinkan pengolahan informasi terutama pemakaian obat farmasi di rumah sakit. Bidang pelayanan kesehatan juga merupakan hal yang cukup berperan besar dalam kehidupan penulis sehingga menjadi objek yang menarik untuk diteliti.

Selama penyusunan Tugas Akhir ini, banyak dinamika yang dialami oleh penulis yang tidak dapat dijalani sendirian. Oleh karena itu, penulis ingin menyampaikan terima kasih yang sebesar-besarnya kepada:

1. Tuhan Yang Maha Esa, karena bimbingan dan karunia-Nya, penulis selalu mendapat pengharapan dan kekuatan selama pembuatan Tugas Akhir ini.
2. Bapak Ventje Jeremias Lewi Engel S.T, M.T, selaku pembimbing utama Tugas Akhir yang senantiasa memberi dukungan, semangat, waktu dan bimbingan baik dalam penulisan dokumen Tugas Akhir maupun implementasi penelitian yang dilakukan.
3. Bapak Hans Christian Kurniawan S.T, M.T., selaku penguji I Tugas Akhir yang telah memberikan pengujian serta masukan-masukan kepada penulis selama pembuatan Tugas Akhir ini.
4. Bapak Dr. Hery Heryanto, M.Kom, selaku penguji II Tugas Akhir yang telah pengujian serta masukan-masukan kepada penulis selama pembuatan Tugas Akhir ini.
5. Dosen dan staff Program Studi Informatika serta DAAK ITHB yang telah membantu menyelesaikan proses administrasi sehingga Tugas Akhir ini dapat diselesaikan.
6. Periksa.id sebagai tempat penulis bekerja paruh waktu yang telah mengizinkan penulis menggunakan baik nama perusahaan maupun data perusahaan sehingga penulis dapat menyelesaikan Tugas Akhir ini.
7. Kedua orang tua dan adik yang selalu mendukung dalam doa, memberikan

semangat dan orang tua yang memberikan investasi finansial kepada penulis dalam menyelesaikan Tugas Akhir ini.

8. Kerabat, khususnya: Sherryl dan Keisyra serta Om Edgard, Ie Adel, Ema Tanti dan Oma Jean. Terima kasih untuk doa dan dukungan moril yang selalu diberikan kepada penulis untuk menyelesaikan Tugas Akhir ini.
9. Rumah Sakit Santo Borromeus, Klinik Kopo Sentral Medika, tim dokter khususnya: dr. Dian, dr. Mei, dr. Ana, dr. Robby, dr. Wulan dan dr. Lisa, serta staff kesehatan, kebersihan, keamanan dan perawat yang tidak dapat penulis tulis satu persatu. Terima kasih atas dukungan serta pengobatan yang diberikan sehingga penulis dapat menyelesaikan Tugas Akhir ini.
10. Teman seangkatan, khususnya: Dion, Evan, Jacob, Davin, Stendy, Wempy, Agape, Kevin, Adrian dan Nael. Terima kasih atas waktu, saran dan semangat yang diberikan kepada penulis untuk menyelesaikan Tugas Akhir ini.
11. Sahabat dekat, khususnya: Rendy, Reinald, Erai, Ferzy, Ivan dan Ferren. Terima kasih atas dukungan dan kekuatan yang diberikan kepada penulis sehingga dapat menyelesaikan Tugas Akhir ini.
12. Pimpinan Periksa.id, khususnya bapak Sutan dan ibu Indri atas waktu yang diberikan untuk pemulihan dan menyelesaikan Tugas Akhir sehingga Tugas Akhir ini dapat diselesaikan dengan baik.
13. Rekan kerja Periksa.id, khususnya: Julio, Evan, Raymond, Jeano, Majid dan rekan lain yang telah menggantikan posisi penulis selama penulis menyelesaikan Tugas Akhir.
14. Teman angkatan 2018, khususnya: Hanjaya, DC, Benedict, DA dan Nicholas. Terima kasih atas dukungan semangat, saran, waktu dan usaha kepada penulis sehingga dapat menyelesaikan Tugas Akhir.
15. Teman seangkatan yang tidak dapat penulis rincikan satu persatu, atas waktu, kebersamaan dan semangat yang selalu diberikan untuk menyelesaikan Tugas Akhir ini.

Penulis menyadari bahwa Tugas Akhir ini masih jauh dari sempurna, baik dari segi konten maupun penulisan, karena keterbatasan waktu, pengetahuan, dan pengalaman yang dimiliki oleh penulis. Penulis menyampaikan permohonan maaf atas hal tersebut. Oleh karena itu, kritik dan saran yang membangun sangat diharapkan demi penyempurnaan penelitian sejenis di masa mendatang.

Akhir kata, semoga Tugas Akhir ini dapat membantu para pembaca yang ingin mengetahui contoh penerapan bidang keilmuan Informatika yang diintegrasikan dengan bidang pelayanan kesehatan. Semoga kita semua selalu diberikan

kesehatan dan bidang pelayanan kesehatan di Indonesia dapat menjadi semakin baik.

Bandung, 25 Juni 2022

Hormat penulis,



JASON NATHANIEL

## DAFTAR ISI

<b>ABSTRAK</b>	<b>iv</b>
<b>ABSTRACT</b>	<b>v</b>
<b>KATA PENGANTAR</b>	<b>vi</b>
<b>DAFTAR ISI</b>	<b>ix</b>
<b>DAFTAR TABEL</b>	<b>xiii</b>
<b>DAFTAR GAMBAR</b>	<b>xv</b>
<b>DAFTAR ALGORITME</b>	<b>lxxvii</b>
<b>DAFTAR LAMPIRAN</b>	<b>lxxvii</b>
<b>BAB 1 PENDAHULUAN . . . . .</b>	<b>1-1</b>
1.1 Latar Belakang . . . . .	1-1
1.2 Rumusan Masalah . . . . .	1-3
1.3 Tujuan Penelitian . . . . .	1-3
1.4 Batasan Masalah . . . . .	1-4
1.5 Kontribusi Penelitian . . . . .	1-4
1.6 Metode Penelitian . . . . .	1-4
1.7 Sistematika Pembahasan . . . . .	1-5
<b>BAB 2 LANDASAN TEORI . . . . .</b>	<b>2-1</b>
2.1 Tinjauan Pustaka . . . . .	2-1
2.1.1 <i>Artificial Neural Network (ANN)</i> . . . . .	2-1
2.1.2 <i>Convolutional Neural Network (CNN)</i> . . . . .	2-3
2.1.2.1 <i>Convolutional Layer</i> . . . . .	2-4
2.1.2.2 <i>Max Pooling Layer</i> . . . . .	2-7
2.1.2.3 <i>Dense/Fully Connected Layer</i> . . . . .	2-8
2.1.3 Fungsi Aktivasi . . . . .	2-9
2.1.3.1 <i>Rectified Linear Unit (ReLU)</i> . . . . .	2-10
2.1.3.2 <i>Hyperbolic Tangent Activation</i> . . . . .	2-11
2.1.4 <i>Long-Short Term Memory (LSTM)</i> . . . . .	2-12
2.1.4.1 <i>Input Gate</i> . . . . .	2-13

2.1.4.2	<i>Forget Gate</i>	2-14
2.1.4.3	<i>Cell State</i>	2-14
2.1.4.4	<i>Output Gate</i>	2-15
2.1.5	CNN-LSTM	2-16
2.1.6	<i>Nonpooling CNN-LSTM</i>	2-19
2.1.7	Pustaka	2-19
2.1.7.1	NumPy	2-19
2.1.7.2	Pandas	2-19
2.1.7.3	Matplotlib	2-20
2.1.7.4	Keras	2-21
2.1.7.5	Tensorflow js	2-23
2.2	Tinjauan Studi	2-23
2.3	Tinjauan Objek	2-24
2.3.1	<i>Demand Forecasting</i>	2-25
2.3.1.1	Metode Konsumsi	2-25
2.3.1.2	Metode Morbiditas	2-26
2.3.2	<i>Forecasting Horizon</i>	2-28
2.3.3	<i>Dataset</i>	2-28

<b>BAB 3</b>	<b>ANALISIS DAN PERANCANGAN SISTEM</b>	<b>3-1</b>
3.1	Analisis Masalah	3-1
3.2	Kerangka Pemikiran	3-2
3.3	Analisis Urutan Proses Global	3-4
3.3.1	Proses Pelatihan	3-5
3.3.1.1	CNN-LSTM	3-6
3.3.2	Proses Pengujian	3-8
3.4	Analisis Manual	3-8
3.4.1	<i>Dataset</i>	3-8
3.4.2	<i>Nonpooling CNN-LSTM</i>	3-9
3.4.2.1	Perhitungan <i>Nonpooling CNN</i>	3-9
3.4.2.2	Perhitungan LSTM	3-11
3.4.2.3	Perhitungan <i>Dense</i>	3-25
3.4.3	CNN-LSTM	3-26
3.4.3.1	Perhitungan CNN	3-26
3.4.3.2	Perhitungan LSTM	3-28
3.4.3.3	Perhitungan <i>Dense</i>	3-39
3.4.4	<i>Root Mean Squared Error (RMSE)</i>	3-40

<b>BAB 4 IMPLEMENTASI DAN PENGUJIAN . . . . .</b>	<b>4-1</b>
4.1 Lingkungan Implementasi . . . . .	4-1
4.1.1 Spesifikasi Perangkat Keras . . . . .	4-1
4.1.2 Lingkungan Perangkat Lunak . . . . .	4-1
4.2 Implementasi Perangkat Lunak . . . . .	4-1
4.2.1 Daftar <i>Project</i> dan <i>Method</i> . . . . .	4-2
4.2.1.1 <i>ModelGenerator</i> . . . . .	4-2
4.2.1.2 <i>Backend</i> . . . . .	4-3
4.2.1.3 <i>Frontend</i> . . . . .	4-5
4.2.2 Penggunaan <i>Development Tools</i> . . . . .	4-6
4.2.3 Implementasi Penggunaan <i>Dataset</i> . . . . .	4-7
4.3 Implementasi Aplikasi . . . . .	4-7
4.4 Pengujian . . . . .	4-10
4.4.1 Pengujian Nilai <i>Epoch</i> . . . . .	4-10
4.4.2 Pengujian <i>Filter</i> . . . . .	4-11
4.4.3 Pengujian <i>Units</i> . . . . .	4-11
4.4.4 Pengujian <i>Learning Rate</i> . . . . .	4-11
4.4.5 Pengujian <i>Max Pooling</i> . . . . .	4-11
4.4.6 Pengujian <i>Forecasting Horizon</i> . . . . .	4-14
4.4.7 Skenario Pengujian . . . . .	4-14
4.5 Hasil Pengujian . . . . .	4-16
4.5.1 Pengujian pada Arsitektur 1 . . . . .	4-16
4.5.2 Pengujian pada Arsitektur 2 . . . . .	4-18
4.5.3 Pengujian pada Arsitektur 3 . . . . .	4-21
4.5.4 Pengujian pada model LSTM . . . . .	4-24
4.5.5 Pembahasan Umum Hasil Pengujian . . . . .	4-26
4.6 Analisis Kesalahan . . . . .	4-31
<b>BAB 5 KESIMPULAN DAN SARAN . . . . .</b>	<b>5-1</b>
5.1 Kesimpulan . . . . .	5-1
5.2 Saran . . . . .	5-2
<b>DAFTAR REFERENSI . . . . .</b>	<b>Ixxix</b>

## DAFTAR TABEL

2.1	Daftar <i>method</i> yang digunakan dari pustaka NumPy . . . . .	2-19
2.2	Daftar <i>method</i> yang digunakan dari pustaka Pandas . . . . .	2-20
2.3	Daftar <i>method</i> yang digunakan dari pustaka Matplotlib . . . . .	2-20
2.4	Daftar <i>method</i> yang digunakan dari pustaka Keras . . . . .	2-21
2.4	Daftar <i>method</i> yang digunakan dari pustaka Keras . . . . .	2-22
2.4	Daftar <i>method</i> yang digunakan dari pustaka Keras . . . . .	2-23
2.5	Daftar <i>method</i> yang digunakan dari pustaka Tensorflow js . . . . .	2-23
2.6	<i>State of the Art</i> . . . . .	2-24
2.7	Contoh Data . . . . .	2-29
3.1	Contoh larik . . . . .	3-9
3.2	Contoh nilai <i>kernel</i> $2 \times 1$ . . . . .	3-9
3.3	Contoh larik . . . . .	3-10
3.4	Contoh <i>feature map</i> hasil konvolusi . . . . .	3-10
3.5	Contoh <i>kernel</i> pada lapisan <i>dense</i> . . . . .	3-25
3.6	Contoh larik . . . . .	3-26
3.7	Contoh nilai <i>kernel</i> $2 \times 1$ . . . . .	3-27
3.8	Contoh larik . . . . .	3-27
3.9	Contoh <i>feature map</i> hasil konvolusi . . . . .	3-28
3.10	Contoh <i>feature map</i> hasil konvolusi . . . . .	3-28
3.11	Contoh <i>kernel</i> pada lapisan <i>dense</i> . . . . .	3-40
4.1	Daftar <i>method</i> pada project <i>ModelGenerator</i> . . . . .	4-3
4.2	Daftar <i>method</i> pada project <i>Backend</i> . . . . .	4-4
4.3	Daftar <i>method</i> pada project <i>Frontend</i> . . . . .	4-5
4.4	Perincian Penggunaan <i>Dataset</i> untuk Implementasi . . . . .	4-7
4.5	Rincian keseluruhan skenario pengujian yang akan diuji untuk model CNN-LSTM . . . . .	4-15
4.6	Rincian keseluruhan skenario pengujian yang akan diuji untuk model LSTM . . . . .	4-15
4.7	Ringkasan hasil pengujian arsitektur 1 untuk <i>forecasting horizon</i> 30 hari dan 90 hari . . . . .	4-16
4.8	Ringkasan hasil pengujian arsitektur 2 untuk <i>forecasting horizon</i> 30 hari dan 90 hari . . . . .	4-19

4.9	Ringkasan hasil pengujian arsitektur 3 untuk <i>forecasting horizon</i> 30 hari dan 90 hari . . . . .	4-22
4.10	Ringkasan hasil pengujian model LSTM untuk <i>forecasting horizon</i> 30 hari dan 90 hari . . . . .	4-24
4.10	Ringkasan hasil pengujian model LSTM untuk <i>forecasting horizon</i> 30 hari dan 90 hari . . . . .	4-25
4.11	Ringkasan keseluruhan hasil pengujian . . . . .	4-29

## DAFTAR GAMBAR

2.1	<i>Artificial Neural Network</i> [8] . . . . .	2-1
2.2	<i>Neuron</i> [8] . . . . .	2-2
2.3	Contoh operasi konvolusi . . . . .	2-6
2.4	Contoh operasi konvolusi pada matriks satu dimensi [12] . . . . .	2-7
2.5	Contoh susunan lapisan konvolusi dan <i>max pooling</i> pada data <i>time-series</i> . . . . .	2-8
2.6	Contoh operasi <i>max pooling</i> [11] . . . . .	2-8
2.7	Contoh arsitektur CNN lengkap beserta <i>dense</i> untuk data <i>time-series</i> .	2-9
2.8	Fungsi aktivasi ReLU . . . . .	2-10
2.9	Fungsi aktivasi tanh . . . . .	2-11
2.10	Contoh Gambaran arsitektur LSTM. . . . .	2-12
2.11	Contoh arsitektur CNN-LSTM [6] . . . . .	2-17
2.12	Contoh arsitektur CNN-LSTM untuk data <i>time-series</i> [7] . . . . .	2-18
2.13	Data pemakaian obat per hari selama setahun untuk tahun 2021 . . . . .	2-29
2.14	Data pemakaian obat per hari selama 90 hari untuk tahun 2022 . . . . .	2-29
3.1	Kerangka Pemikiran . . . . .	3-2
3.2	<i>Flowchart</i> urutan proses global . . . . .	3-5
3.3	<i>Flowchart</i> pelatihan sistem prediksi pemakaian obat . . . . .	3-6
3.4	Gambaran <i>dataset</i> dengan keterangan sumbu x dan y . . . . .	3-6
3.5	<i>Flowchart</i> pengujian sistem prediksi pemakaian obat . . . . .	3-8
4.1	Arsitektur Diagram Implementasi Perangkat Lunak . . . . .	4-2
4.2	Tampilan awal aplikasi . . . . .	4-8
4.3	Tampilan setelah memilih model CNN-LSTM . . . . .	4-8
4.4	Tampilan setelah memilih model LSTM . . . . .	4-9
4.5	Tampilan ketika pengguna telah menekan tombol <i>predict</i> . . . . .	4-10
4.6	Tampilan informasi mengenai data pada grafik . . . . .	4-10
4.7	Rancangan arsitektur CNN-LSTM dengan 2 lapisan Max Pooling .	4-12
4.8	Rancangan arsitektur CNN-LSTM dengan 1 lapisan Max Pooling .	4-13
4.9	Rancangan arsitektur CNN-LSTM tanpa lapisan Max Pooling <i>(Nonpooling CNN-LSTM)</i> . . . . .	4-14
4.10	Perbandingan RMSE berdasarkan parameter pengujian untuk arsitektur 1 . . . . .	4-17
4.11	Perbandingan RMSE berdasarkan parameter pengujian untuk arsitektur 1 . . . . .	4-20

4.12	Perbandingan RMSE berdasarkan parameter pengujian untuk arsitektur 1 . . . . .	4-23
4.13	Perbandingan RMSE berdasarkan parameter pengujian untuk arsitektur 1 . . . . .	4-25
4.14	Perbandingan RMSE berdasarkan parameter pengujian dari ketiga arsitektur arsitektur pada <i>forecasting horizon</i> 30 hari . . . . .	4-27
4.15	Perbandingan RMSE berdasarkan parameter pengujian dari ketiga arsitektur arsitektur pada <i>forecasting horizon</i> 90 hari . . . . .	4-28
1.1	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter</i> : 16 & 32, <i>Units</i> : 100, <i>Epoch</i> : 100, <i>Learning Rate</i> : 0.1 dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-1
1.2	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter</i> : 16 & 32, <i>Units</i> : 100, <i>Epoch</i> : 150, <i>Learning Rate</i> : 0.1 dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-1
1.3	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter</i> : 16 & 32, <i>Units</i> : 100, <i>Epoch</i> : 200, <i>Learning Rate</i> : 0.1 dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-1
1.4	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter</i> : 16 & 32, <i>Units</i> : 100, <i>Epoch</i> : 250, <i>Learning Rate</i> : 0.1 dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-2
1.5	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter</i> : 16 & 32, <i>Units</i> : 200, <i>Epoch</i> : 100, <i>Learning Rate</i> : 0.1 dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-2
1.6	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter</i> : 16 & 32, <i>Units</i> : 200, <i>Epoch</i> : 150, <i>Learning Rate</i> : 0.1 dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-2
1.7	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter</i> : 16 & 32, <i>Units</i> : 200, <i>Epoch</i> : 200, <i>Learning Rate</i> : 0.1 dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-3
1.8	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter</i> : 16 & 32, <i>Units</i> : 200, <i>Epoch</i> : 250, <i>Learning Rate</i> : 0.1 dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-3
1.9	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter</i> : 16 & 32, <i>Units</i> : 300, <i>Epoch</i> : 100, <i>Learning Rate</i> : 0.1 dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-3

1.10	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 16 &amp; 32, Units: 300, Epoch: 150, Learning Rate: 0.1</i> dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-4
1.11	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 16 &amp; 32, Units: 300, Epoch: 200, Learning Rate: 0.1</i> dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-4
1.12	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 16 &amp; 32, Units: 300, Epoch: 250, Learning Rate: 0.1</i> dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-4
1.13	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 32 &amp; 64, Units: 100, Epoch: 100, Learning Rate: 0.1</i> dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-5
1.14	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 32 &amp; 64, Units: 100, Epoch: 150, Learning Rate: 0.1</i> dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-5
1.15	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 32 &amp; 64, Units: 100, Epoch: 200, Learning Rate: 0.1</i> dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-5
1.16	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 32 &amp; 64, Units: 100, Epoch: 250, Learning Rate: 0.1</i> dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-6
1.17	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 32 &amp; 64, Units: 200, Epoch: 100, Learning Rate: 0.1</i> dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-6
1.18	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 32 &amp; 64, Units: 200, Epoch: 150, Learning Rate: 0.1</i> dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-6
1.19	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 32 &amp; 64, Units: 200, Epoch: 200, Learning Rate: 0.1</i> dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-7
1.20	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 32 &amp; 64, Units: 200, Epoch: 250, Learning Rate: 0.1</i> dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-7
1.21	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 32 &amp; 64, Units: 300, Epoch: 100, Learning Rate: 0.1</i> dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-7

1.22	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 32 &amp; 64, Units: 300, Epoch: 150, Learning Rate: 0.1</i> dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-8
1.23	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 32 &amp; 64, Units: 300, Epoch: 200, Learning Rate: 0.1</i> dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-8
1.24	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 32 &amp; 64, Units: 300, Epoch: 250, Learning Rate: 0.1</i> dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-8
1.25	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 64 &amp; 128, Units: 100, Epoch: 100, Learning Rate: 0.1</i> dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-9
1.26	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 64 &amp; 128, Units: 100, Epoch: 150, Learning Rate: 0.1</i> dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-9
1.27	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 64 &amp; 128, Units: 100, Epoch: 200, Learning Rate: 0.1</i> dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-9
1.28	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 64 &amp; 128, Units: 100, Epoch: 250, Learning Rate: 0.1</i> dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-10
1.29	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 64 &amp; 128, Units: 200, Epoch: 100, Learning Rate: 0.1</i> dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-10
1.30	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 64 &amp; 128, Units: 200, Epoch: 150, Learning Rate: 0.1</i> dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-10
1.31	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 64 &amp; 128, Units: 200, Epoch: 200, Learning Rate: 0.1</i> dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-11
1.32	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 64 &amp; 128, Units: 200, Epoch: 250, Learning Rate: 0.1</i> dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-11
1.33	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 64 &amp; 128, Units: 300, Epoch: 100, Learning Rate: 0.1</i> dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	A-11

- 1.34 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 150, Learning Rate: 0.1* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-12
- 1.35 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 200, Learning Rate: 0.1* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-12
- 1.36 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 250, Learning Rate: 0.1* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-12
- 1.37 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-13
- 1.38 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-13
- 1.39 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-13
- 1.40 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-14
- 1.41 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-14
- 1.42 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-14
- 1.43 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-15
- 1.44 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-15
- 1.45 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-15

- 1.46 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.01* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-16
- 1.47 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.01* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-16
- 1.48 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.01* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-16
- 1.49 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.01* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-17
- 1.50 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 150, Learning Rate: 0.01* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-17
- 1.51 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 200, Learning Rate: 0.01* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-17
- 1.52 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 250, Learning Rate: 0.01* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-18
- 1.53 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 100, Learning Rate: 0.01* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-18
- 1.54 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 150, Learning Rate: 0.01* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-18
- 1.55 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 200, Learning Rate: 0.01* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-19
- 1.56 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 250, Learning Rate: 0.01* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-19
- 1.57 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 100, Learning Rate: 0.01* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-19

- 1.58 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 150, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-20
- 1.59 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 200, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-20
- 1.60 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 250, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-20
- 1.61 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 100, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-21
- 1.62 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 150, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-21
- 1.63 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 200, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-21
- 1.64 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 250, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-22
- 1.65 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 100, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-22
- 1.66 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 150, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-22
- 1.67 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 200, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-23
- 1.68 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 250, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-23
- 1.69 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 100, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-23

- 1.70 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 150, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-24
- 1.71 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 200, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-24
- 1.72 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 250, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-24
- 1.73 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-25
- 1.74 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-25
- 1.75 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-25
- 1.76 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-26
- 1.77 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-26
- 1.78 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-26
- 1.79 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-27
- 1.80 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-27
- 1.81 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-27

- 1.82 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-28
- 1.83 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-28
- 1.84 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-28
- 1.85 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-29
- 1.86 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 150, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-29
- 1.87 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 200, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-29
- 1.88 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 250, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-30
- 1.89 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 100, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-30
- 1.90 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 150, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-30
- 1.91 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 200, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-31
- 1.92 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 250, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-31
- 1.93 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 100, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . A-31

- 1.94 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 150, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-32
- 1.95 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 200, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-32
- 1.96 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 250, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-32
- 1.97 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 100, Learning Rate: 0.001*  
dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-33
- 1.98 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 150, Learning Rate: 0.001*  
dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-33
- 1.99 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 200, Learning Rate: 0.001*  
dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-33
- 1.100 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 200, Learning Rate: 0.001*  
dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-34
- 1.101 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 100, Learning Rate: 0.001*  
dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-34
- 1.102 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 150, Learning Rate: 0.001*  
dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-34
- 1.103 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 200, Learning Rate: 0.001*  
dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-35
- 1.104 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 250, Learning Rate: 0.001*  
dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-35
- 1.105 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 100, Learning Rate: 0.001*  
dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . A-35

- 1.106 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 150, Learning Rate: 0.001*  
 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . A-36
- 1.107 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 200, Learning Rate: 0.001*  
 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . A-36
- 1.108 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 250, Learning Rate: 0.001*  
 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . A-36
- 1.109 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.1* dan 2  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-37
- 1.110 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.1* dan 2  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-37
- 1.111 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.1* dan 2  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-37
- 1.112 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.1* dan 2  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-38
- 1.113 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.1* dan 2  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-38
- 1.114 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.1* dan 2  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-38
- 1.115 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.1* dan 2  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-39
- 1.116 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.1* dan 2  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-39
- 1.117 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.1* dan 2  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-39

- 1.118 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.1* dan 2  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-40
- 1.119 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.1* dan 2  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-40
- 1.120 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.1* dan 2  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-40
- 1.121 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.1* dan 2  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-41
- 1.122 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 150, Learning Rate: 0.1* dan 2  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-41
- 1.123 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 200, Learning Rate: 0.1* dan 2  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-41
- 1.124 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 250, Learning Rate: 0.1* dan 2  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-42
- 1.125 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 100, Learning Rate: 0.1* dan 2  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-42
- 1.126 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 150, Learning Rate: 0.1* dan 2  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-42
- 1.127 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 200, Learning Rate: 0.1* dan 2  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-43
- 1.128 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 250, Learning Rate: 0.1* dan 2  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-43
- 1.129 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 100, Learning Rate: 0.1* dan 2  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-43

- 1.130 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 150, Learning Rate: 0.1* dan 2  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-44
- 1.131 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 200, Learning Rate: 0.1* dan 2  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-44
- 1.132 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 250, Learning Rate: 0.1* dan 2  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-44
- 1.133 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 100, Learning Rate: 0.1* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-45
- 1.134 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 150, Learning Rate: 0.1* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-45
- 1.135 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 200, Learning Rate: 0.1* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-45
- 1.136 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 250, Learning Rate: 0.1* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-46
- 1.137 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 100, Learning Rate: 0.1* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-46
- 1.138 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 150, Learning Rate: 0.1* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-46
- 1.139 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 200, Learning Rate: 0.1* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-47
- 1.140 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 250, Learning Rate: 0.1* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-47
- 1.141 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 100, Learning Rate: 0.1* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-47

- 1.142 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 150, Learning Rate: 0.1* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-48
- 1.143 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 200, Learning Rate: 0.1* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-48
- 1.144 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 250, Learning Rate: 0.1* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-48
- 1.145 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-49
- 1.146 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-49
- 1.147 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-49
- 1.148 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-50
- 1.149 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-50
- 1.150 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-50
- 1.151 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-51
- 1.152 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-51
- 1.153 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-51

- 1.154 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-52
- 1.155 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-52
- 1.156 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-52
- 1.157 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-53
- 1.158 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 150, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-53
- 1.159 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 200, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-53
- 1.160 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 250, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-54
- 1.161 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 100, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-54
- 1.162 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 150, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-54
- 1.163 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 200, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-55
- 1.164 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 250, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-55
- 1.165 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 100, Learning Rate: 0.01* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-55

- 1.166 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 150, Learning Rate: 0.01* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-56
- 1.167 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 200, Learning Rate: 0.01* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-56
- 1.168 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 250, Learning Rate: 0.01* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-56
- 1.169 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 100, Learning Rate: 0.01* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-57
- 1.170 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 150, Learning Rate: 0.01* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-57
- 1.171 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 200, Learning Rate: 0.01* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-57
- 1.172 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 250, Learning Rate: 0.01* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-58
- 1.173 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 100, Learning Rate: 0.01* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-58
- 1.174 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 150, Learning Rate: 0.01* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-58
- 1.175 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 200, Learning Rate: 0.01* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-59
- 1.176 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 250, Learning Rate: 0.01* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-59
- 1.177 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 100, Learning Rate: 0.01* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-59

- 1.178 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 150, Learning Rate: 0.01* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-60
- 1.179 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 200, Learning Rate: 0.01* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-60
- 1.180 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 250, Learning Rate: 0.01* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-60
- 1.181 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.001* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-61
- 1.182 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.001* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-61
- 1.183 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.001* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-61
- 1.184 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.001* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-62
- 1.185 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.001* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-62
- 1.186 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.001* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-62
- 1.187 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.001* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-63
- 1.188 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.001* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-63
- 1.189 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.001* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . . A-63

- 1.190 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-64
- 1.191 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-64
- 1.192 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-64
- 1.193 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-65
- 1.194 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 150, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-65
- 1.195 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 200, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-65
- 1.196 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 250, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-66
- 1.197 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 100, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-66
- 1.198 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 150, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-66
- 1.199 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 200, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-67
- 1.200 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 250, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-67
- 1.201 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 100, Learning Rate: 0.001* dan  
2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-67

- 1.202 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 150, Learning Rate: 0.001* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-68
- 1.203 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 200, Learning Rate: 0.001* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-68
- 1.204 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 250, Learning Rate: 0.001* dan  
 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-68
- 1.205 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 100, Learning Rate: 0.001*  
 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-69
- 1.206 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 150, Learning Rate: 0.001*  
 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-69
- 1.207 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 200, Learning Rate: 0.001*  
 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-69
- 1.208 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 200, Learning Rate: 0.001*  
 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-70
- 1.209 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 100, Learning Rate: 0.001*  
 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-70
- 1.210 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 150, Learning Rate: 0.001*  
 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-70
- 1.211 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 200, Learning Rate: 0.001*  
 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-71
- 1.212 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 250, Learning Rate: 0.001*  
 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-71
- 1.213 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 100, Learning Rate: 0.001*  
 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . A-71

1.214	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 64 &amp; 128, Units: 300, Epoch: 150, Learning Rate: 0.001</i> dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 90 hari . . .	A-72
1.215	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 64 &amp; 128, Units: 300, Epoch: 200, Learning Rate: 0.001</i> dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 90 hari . . .	A-72
1.216	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 64 &amp; 128, Units: 300, Epoch: 250, Learning Rate: 0.001</i> dan 2 lapisan <i>Max Pooling</i> untuk forecasting horizon 90 hari . . .	A-72
2.1	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 16 &amp; 32, Units: 100, Epoch: 100, Learning Rate: 0.1</i> dan 1 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	B-1
2.2	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 16 &amp; 32, Units: 100, Epoch: 150, Learning Rate: 0.1</i> dan 1 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	B-1
2.3	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 16 &amp; 32, Units: 100, Epoch: 200, Learning Rate: 0.1</i> dan 1 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	B-1
2.4	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 16 &amp; 32, Units: 100, Epoch: 250, Learning Rate: 0.1</i> dan 1 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	B-2
2.5	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 16 &amp; 32, Units: 200, Epoch: 100, Learning Rate: 0.1</i> dan 1 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	B-2
2.6	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 16 &amp; 32, Units: 200, Epoch: 150, Learning Rate: 0.1</i> dan 1 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	B-2
2.7	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 16 &amp; 32, Units: 200, Epoch: 200, Learning Rate: 0.1</i> dan 1 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	B-3
2.8	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 16 &amp; 32, Units: 200, Epoch: 250, Learning Rate: 0.1</i> dan 1 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	B-3
2.9	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 16 &amp; 32, Units: 300, Epoch: 100, Learning Rate: 0.1</i> dan 1 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	B-3

2.10	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 16 &amp; 32, Units: 300, Epoch: 150, Learning Rate: 0.1</i> dan 1 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	B-4
2.11	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 16 &amp; 32, Units: 300, Epoch: 200, Learning Rate: 0.1</i> dan 1 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	B-4
2.12	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 16 &amp; 32, Units: 300, Epoch: 250, Learning Rate: 0.1</i> dan 1 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	B-4
2.13	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 32 &amp; 64, Units: 100, Epoch: 100, Learning Rate: 0.1</i> dan 1 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	B-5
2.14	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 32 &amp; 64, Units: 100, Epoch: 150, Learning Rate: 0.1</i> dan 1 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	B-5
2.15	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 32 &amp; 64, Units: 100, Epoch: 200, Learning Rate: 0.1</i> dan 1 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	B-5
2.16	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 32 &amp; 64, Units: 100, Epoch: 250, Learning Rate: 0.1</i> dan 1 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	B-6
2.17	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 32 &amp; 64, Units: 200, Epoch: 100, Learning Rate: 0.1</i> dan 1 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	B-6
2.18	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 32 &amp; 64, Units: 200, Epoch: 150, Learning Rate: 0.1</i> dan 1 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	B-6
2.19	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 32 &amp; 64, Units: 200, Epoch: 200, Learning Rate: 0.1</i> dan 1 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	B-7
2.20	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 32 &amp; 64, Units: 200, Epoch: 250, Learning Rate: 0.1</i> dan 1 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	B-7
2.21	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 32 &amp; 64, Units: 300, Epoch: 100, Learning Rate: 0.1</i> dan 1 lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . . . .	B-7

- 2.22 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 150, Learning Rate: 0.1* dan 1  
lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . B-8
- 2.23 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 200, Learning Rate: 0.1* dan 1  
lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . B-8
- 2.24 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 250, Learning Rate: 0.1* dan 1  
lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . B-8
- 2.25 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 100, Learning Rate: 0.1* dan  
1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . B-9
- 2.26 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 150, Learning Rate: 0.1* dan  
1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . B-9
- 2.27 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 200, Learning Rate: 0.1* dan  
1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . B-9
- 2.28 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 250, Learning Rate: 0.1* dan  
1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . B-10
- 2.29 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 100, Learning Rate: 0.1* dan  
1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . B-10
- 2.30 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 150, Learning Rate: 0.1* dan  
1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . B-10
- 2.31 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 200, Learning Rate: 0.1* dan  
1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . B-11
- 2.32 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 250, Learning Rate: 0.1* dan  
1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . B-11
- 2.33 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 100, Learning Rate: 0.1* dan  
1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . . B-11

- 2.34 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 150, Learning Rate: 0.1* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-12
- 2.35 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 200, Learning Rate: 0.1* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-12
- 2.36 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 250, Learning Rate: 0.1* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-12
- 2.37 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-13
- 2.38 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-13
- 2.39 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-13
- 2.40 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-14
- 2.41 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-14
- 2.42 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-14
- 2.43 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-15
- 2.44 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-15
- 2.45 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-15

- 2.46 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-16
- 2.47 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-16
- 2.48 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-16
- 2.49 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-17
- 2.50 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 150, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-17
- 2.51 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 200, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-17
- 2.52 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 250, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-18
- 2.53 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 100, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-18
- 2.54 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 150, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-18
- 2.55 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 200, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-19
- 2.56 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 250, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-19
- 2.57 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 100, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-19

- 2.58 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 150, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-20
- 2.59 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 200, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-20
- 2.60 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 250, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-20
- 2.61 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 100, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-21
- 2.62 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 150, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-21
- 2.63 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 200, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-21
- 2.64 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 250, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-22
- 2.65 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 100, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-22
- 2.66 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 150, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-22
- 2.67 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 200, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-23
- 2.68 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 250, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-23
- 2.69 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 100, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-23

- 2.70 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 150, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-24
- 2.71 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 200, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-24
- 2.72 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 250, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-24
- 2.73 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-25
- 2.74 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-25
- 2.75 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-25
- 2.76 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-26
- 2.77 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-26
- 2.78 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-26
- 2.79 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-27
- 2.80 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-27
- 2.81 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-27

- 2.82 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-28
- 2.83 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-28
- 2.84 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-28
- 2.85 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-29
- 2.86 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 150, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-29
- 2.87 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 200, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-29
- 2.88 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 250, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-30
- 2.89 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 100, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-30
- 2.90 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 150, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-30
- 2.91 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 200, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-31
- 2.92 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 250, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-31
- 2.93 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 100, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-31

- 2.94 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 150, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-32
- 2.95 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 200, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-32
- 2.96 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 250, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-32
- 2.97 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 100, Learning Rate: 0.001*  
 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-33
- 2.98 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 150, Learning Rate: 0.001*  
 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-33
- 2.99 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 200, Learning Rate: 0.001*  
 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-33
- 2.100 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 200, Learning Rate: 0.001*  
 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-34
- 2.101 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 100, Learning Rate: 0.001*  
 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-34
- 2.102 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 150, Learning Rate: 0.001*  
 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-34
- 2.103 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 200, Learning Rate: 0.001*  
 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-35
- 2.104 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 250, Learning Rate: 0.001*  
 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-35
- 2.105 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 100, Learning Rate: 0.001*  
 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-35

- 2.106 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 150, Learning Rate: 0.001*  
 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-36
- 2.107 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 200, Learning Rate: 0.001*  
 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-36
- 2.108 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 250, Learning Rate: 0.001*  
 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . .B-36
- 2.109 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.1* dan 1  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-37
- 2.110 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.1* dan 1  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-37
- 2.111 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.1* dan 1  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-37
- 2.112 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.1* dan 1  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-38
- 2.113 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.1* dan 1  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-38
- 2.114 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.1* dan 1  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-38
- 2.115 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.1* dan 1  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-39
- 2.116 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.1* dan 1  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-39
- 2.117 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.1* dan 1  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-39

- 2.118 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.1* dan 1  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-40
- 2.119 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.1* dan 1  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-40
- 2.120 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.1* dan 1  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-40
- 2.121 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.1* dan 1  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-41
- 2.122 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 150, Learning Rate: 0.1* dan 1  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-41
- 2.123 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 200, Learning Rate: 0.1* dan 1  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-41
- 2.124 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 250, Learning Rate: 0.1* dan 1  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-42
- 2.125 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 100, Learning Rate: 0.1* dan 1  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-42
- 2.126 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 150, Learning Rate: 0.1* dan 1  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-42
- 2.127 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 200, Learning Rate: 0.1* dan 1  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-43
- 2.128 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 250, Learning Rate: 0.1* dan 1  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-43
- 2.129 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 100, Learning Rate: 0.1* dan 1  
 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-43

- 2.130 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 150, Learning Rate: 0.1* dan 1  
lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-44
- 2.131 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 200, Learning Rate: 0.1* dan 1  
lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-44
- 2.132 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 250, Learning Rate: 0.1* dan 1  
lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-44
- 2.133 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 100, Learning Rate: 0.1* dan  
1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-45
- 2.134 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 150, Learning Rate: 0.1* dan  
1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-45
- 2.135 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 200, Learning Rate: 0.1* dan  
1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-45
- 2.136 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 250, Learning Rate: 0.1* dan  
1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-46
- 2.137 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 100, Learning Rate: 0.1* dan  
1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-46
- 2.138 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 150, Learning Rate: 0.1* dan  
1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-46
- 2.139 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 200, Learning Rate: 0.1* dan  
1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-47
- 2.140 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 250, Learning Rate: 0.1* dan  
1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-47
- 2.141 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 100, Learning Rate: 0.1* dan  
1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-47

- 2.142 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 150, Learning Rate: 0.1* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-48
- 2.143 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 200, Learning Rate: 0.1* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-48
- 2.144 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 250, Learning Rate: 0.1* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-48
- 2.145 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-49
- 2.146 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-49
- 2.147 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-49
- 2.148 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-50
- 2.149 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-50
- 2.150 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-50
- 2.151 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-51
- 2.152 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-51
- 2.153 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-51

- 2.154 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-52
- 2.155 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-52
- 2.156 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-52
- 2.157 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-53
- 2.158 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 150, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-53
- 2.159 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 200, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-53
- 2.160 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 250, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-54
- 2.161 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 100, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-54
- 2.162 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 150, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-54
- 2.163 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 200, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-55
- 2.164 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 250, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-55
- 2.165 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 100, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-55

- 2.166 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 150, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-56
- 2.167 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 200, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-56
- 2.168 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 250, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-56
- 2.169 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 100, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-57
- 2.170 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 150, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-57
- 2.171 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 200, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-57
- 2.172 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 250, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-58
- 2.173 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 100, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-58
- 2.174 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 150, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-58
- 2.175 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 200, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-59
- 2.176 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 250, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-59
- 2.177 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 100, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-59

- 2.178 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 150, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-60
- 2.179 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 200, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-60
- 2.180 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 250, Learning Rate: 0.01* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-60
- 2.181 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-61
- 2.182 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-61
- 2.183 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-61
- 2.184 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-62
- 2.185 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-62
- 2.186 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-62
- 2.187 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-63
- 2.188 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-63
- 2.189 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-63

- 2.190 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-64
- 2.191 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-64
- 2.192 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-64
- 2.193 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-65
- 2.194 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 150, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-65
- 2.195 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 200, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-65
- 2.196 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 250, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-66
- 2.197 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 100, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-66
- 2.198 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 150, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-66
- 2.199 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 200, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-67
- 2.200 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 250, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-67
- 2.201 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 100, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-67

- 2.202 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 150, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-68
- 2.203 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 200, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-68
- 2.204 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 250, Learning Rate: 0.001* dan  
 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-68
- 2.205 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 100, Learning Rate: 0.001*  
 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-69
- 2.206 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 150, Learning Rate: 0.001*  
 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-69
- 2.207 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 200, Learning Rate: 0.001*  
 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-69
- 2.208 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 200, Learning Rate: 0.001*  
 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-70
- 2.209 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 100, Learning Rate: 0.001*  
 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-70
- 2.210 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 150, Learning Rate: 0.001*  
 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-70
- 2.211 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 200, Learning Rate: 0.001*  
 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-71
- 2.212 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 250, Learning Rate: 0.001*  
 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-71
- 2.213 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 100, Learning Rate: 0.001*  
 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . . .B-71

2.214	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 64 &amp; 128, Units: 300, Epoch: 150, Learning Rate: 0.001</i> dan 1 lapisan <i>Max Pooling</i> untuk forecasting horizon 90 hari . . .	.B-72
2.215	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 64 &amp; 128, Units: 300, Epoch: 200, Learning Rate: 0.001</i> dan 1 lapisan <i>Max Pooling</i> untuk forecasting horizon 90 hari . . .	.B-72
2.216	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 64 &amp; 128, Units: 300, Epoch: 250, Learning Rate: 0.001</i> dan 1 lapisan <i>Max Pooling</i> untuk forecasting horizon 90 hari . . .	.B-72
3.1	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 16 &amp; 32, Units: 100, Epoch: 100, Learning Rate: 0.1</i> dan tanpa lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . .	.C-1
3.2	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 16 &amp; 32, Units: 100, Epoch: 150, Learning Rate: 0.1</i> dan tanpa lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . .	.C-1
3.3	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 16 &amp; 32, Units: 100, Epoch: 200, Learning Rate: 0.1</i> dan tanpa lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . .	.C-1
3.4	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 16 &amp; 32, Units: 100, Epoch: 250, Learning Rate: 0.1</i> dan tanpa lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . .	.C-2
3.5	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 16 &amp; 32, Units: 200, Epoch: 100, Learning Rate: 0.1</i> dan tanpa lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . .	.C-2
3.6	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 16 &amp; 32, Units: 200, Epoch: 150, Learning Rate: 0.1</i> dan tanpa lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . .	.C-2
3.7	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 16 &amp; 32, Units: 200, Epoch: 200, Learning Rate: 0.1</i> dan tanpa lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . .	.C-3
3.8	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 16 &amp; 32, Units: 200, Epoch: 250, Learning Rate: 0.1</i> dan tanpa lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . .	.C-3
3.9	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 16 &amp; 32, Units: 300, Epoch: 100, Learning Rate: 0.1</i> dan tanpa lapisan <i>Max Pooling</i> untuk forecasting horizon 30 hari . . .	.C-3

- 3.10 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . C-4
- 3.11 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . C-4
- 3.12 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . C-4
- 3.13 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . C-5
- 3.14 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 150, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . C-5
- 3.15 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 200, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . C-5
- 3.16 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 250, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . C-6
- 3.17 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 100, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . C-6
- 3.18 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 150, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . C-6
- 3.19 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 200, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . C-7
- 3.20 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 250, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . C-7
- 3.21 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 100, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . C-7

- 3.22 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 150, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . C-8
- 3.23 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 200, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . C-8
- 3.24 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 250, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . C-8
- 3.25 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 100, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . C-9
- 3.26 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 150, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . C-9
- 3.27 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 200, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . C-9
- 3.28 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 250, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . C-10
- 3.29 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 100, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . C-10
- 3.30 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 150, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . C-10
- 3.31 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 200, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . C-11
- 3.32 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 250, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . C-11
- 3.33 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 100, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . . C-11

- 3.34 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 150, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-12
- 3.35 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 200, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-12
- 3.36 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 250, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-12
- 3.37 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-13
- 3.38 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-13
- 3.39 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-13
- 3.40 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-14
- 3.41 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-14
- 3.42 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-14
- 3.43 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-15
- 3.44 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-15
- 3.45 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-15

- 3.46 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-16
- 3.47 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-16
- 3.48 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-16
- 3.49 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-17
- 3.50 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 150, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-17
- 3.51 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 200, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-17
- 3.52 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 250, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-18
- 3.53 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 100, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-18
- 3.54 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 150, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-18
- 3.55 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 200, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-19
- 3.56 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 250, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-19
- 3.57 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 100, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-19

- 3.58 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 150, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-20
- 3.59 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 200, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-20
- 3.60 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 250, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-20
- 3.61 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 100, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-21
- 3.62 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 150, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-21
- 3.63 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 200, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-21
- 3.64 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 250, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-22
- 3.65 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 100, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-22
- 3.66 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 150, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-22
- 3.67 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 200, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-23
- 3.68 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 250, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-23
- 3.69 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 100, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-23

- 3.70 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 150, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-24
- 3.71 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 200, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-24
- 3.72 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 250, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-24
- 3.73 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-25
- 3.74 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-25
- 3.75 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-25
- 3.76 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-26
- 3.77 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-26
- 3.78 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-26
- 3.79 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-27
- 3.80 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-27
- 3.81 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-27

- 3.82 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-28
- 3.83 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-28
- 3.84 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-28
- 3.85 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-29
- 3.86 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 150, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-29
- 3.87 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 200, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-29
- 3.88 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 250, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-30
- 3.89 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 100, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-30
- 3.90 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 150, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-30
- 3.91 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 200, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-31
- 3.92 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 250, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-31
- 3.93 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 100, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-31

- 3.94 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 150, Learning Rate: 0.001* dan  
tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-32
- 3.95 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 200, Learning Rate: 0.001* dan  
tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-32
- 3.96 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 250, Learning Rate: 0.001* dan  
tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . . . .C-32
- 3.97 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 100, Learning Rate: 0.001*  
dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . .C-33
- 3.98 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 150, Learning Rate: 0.001*  
dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . .C-33
- 3.99 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 200, Learning Rate: 0.001*  
dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . .C-33
- 3.100 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 200, Learning Rate: 0.001*  
dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . .C-34
- 3.101 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 100, Learning Rate: 0.001*  
dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . .C-34
- 3.102 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 150, Learning Rate: 0.001*  
dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . .C-34
- 3.103 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 200, Learning Rate: 0.001*  
dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . .C-35
- 3.104 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 250, Learning Rate: 0.001*  
dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . .C-35
- 3.105 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 100, Learning Rate: 0.001*  
dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . .C-35

- 3.106 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 150, Learning Rate: 0.001*  
dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . .C-36
- 3.107 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 200, Learning Rate: 0.001*  
dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . .C-36
- 3.108 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 250, Learning Rate: 0.001*  
dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari . .C-36
- 3.109 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.1* dan  
tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-37
- 3.110 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.1* dan  
tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-37
- 3.111 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.1* dan  
tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-37
- 3.112 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.1* dan  
tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-38
- 3.113 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.1* dan  
tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-38
- 3.114 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.1* dan  
tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-38
- 3.115 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.1* dan  
tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-39
- 3.116 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.1* dan  
tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-39
- 3.117 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.1* dan  
tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-39

- 3.118 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-40
- 3.119 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-40
- 3.120 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-40
- 3.121 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-41
- 3.122 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 150, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-41
- 3.123 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 200, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-41
- 3.124 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 250, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-42
- 3.125 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 100, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-42
- 3.126 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 150, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-42
- 3.127 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 200, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-43
- 3.128 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 250, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-43
- 3.129 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 100, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-43

- 3.130 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 150, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-44
- 3.131 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 200, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-44
- 3.132 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 250, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-44
- 3.133 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 100, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-45
- 3.134 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 150, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-45
- 3.135 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 200, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-45
- 3.136 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 250, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-46
- 3.137 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 100, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-46
- 3.138 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 150, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-46
- 3.139 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 200, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-47
- 3.140 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 250, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-47
- 3.141 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 100, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-47

- 3.142 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 150, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-48
- 3.143 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 200, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-48
- 3.144 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 250, Learning Rate: 0.1* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-48
- 3.145 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-49
- 3.146 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-49
- 3.147 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-49
- 3.148 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-50
- 3.149 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-50
- 3.150 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-50
- 3.151 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-51
- 3.152 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-51
- 3.153 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-51

- 3.154 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-52
- 3.155 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-52
- 3.156 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-52
- 3.157 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-53
- 3.158 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 150, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-53
- 3.159 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 200, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-53
- 3.160 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 250, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-54
- 3.161 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 100, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-54
- 3.162 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 150, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-54
- 3.163 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 200, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-55
- 3.164 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 250, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-55
- 3.165 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 100, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-55

- 3.166 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 150, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-56
- 3.167 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 200, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-56
- 3.168 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 250, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-56
- 3.169 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 100, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-57
- 3.170 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 150, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-57
- 3.171 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 200, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-57
- 3.172 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 250, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-58
- 3.173 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 100, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-58
- 3.174 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 150, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-58
- 3.175 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 200, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-59
- 3.176 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 250, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-59
- 3.177 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 100, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-59

- 3.178 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 150, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-60
- 3.179 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 200, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-60
- 3.180 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 250, Learning Rate: 0.01* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-60
- 3.181 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-61
- 3.182 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-61
- 3.183 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-61
- 3.184 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-62
- 3.185 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-62
- 3.186 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-62
- 3.187 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-63
- 3.188 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-63
- 3.189 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-63

- 3.190 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.001* dan  
tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-64
- 3.191 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.001* dan  
tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-64
- 3.192 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.001* dan  
tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-64
- 3.193 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.001* dan  
tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-65
- 3.194 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 150, Learning Rate: 0.001* dan  
tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-65
- 3.195 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 200, Learning Rate: 0.001* dan  
tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-65
- 3.196 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 100, Epoch: 250, Learning Rate: 0.001* dan  
tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-66
- 3.197 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 100, Learning Rate: 0.001* dan  
tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-66
- 3.198 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 150, Learning Rate: 0.001* dan  
tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-66
- 3.199 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 200, Learning Rate: 0.001* dan  
tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-67
- 3.200 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 200, Epoch: 250, Learning Rate: 0.001* dan  
tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-67
- 3.201 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 100, Learning Rate: 0.001* dan  
tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-67

- 3.202 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 150, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-68
- 3.203 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 200, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-68
- 3.204 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 32 & 64, Units: 300, Epoch: 250, Learning Rate: 0.001* dan  
 tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . . . .C-68
- 3.205 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 100, Learning Rate: 0.001*  
 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . .C-69
- 3.206 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 150, Learning Rate: 0.001*  
 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . .C-69
- 3.207 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 200, Learning Rate: 0.001*  
 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . .C-69
- 3.208 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 100, Epoch: 200, Learning Rate: 0.001*  
 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . .C-70
- 3.209 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 100, Learning Rate: 0.001*  
 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . .C-70
- 3.210 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 150, Learning Rate: 0.001*  
 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . .C-70
- 3.211 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 200, Learning Rate: 0.001*  
 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . .C-71
- 3.212 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 200, Epoch: 250, Learning Rate: 0.001*  
 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . .C-71
- 3.213 Perbandingan hasil prediksi dengan data asli dengan konfigurasi  
*Filter: 64 & 128, Units: 300, Epoch: 100, Learning Rate: 0.001*  
 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari . .C-71

3.214	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 64 &amp; 128, Units: 300, Epoch: 150, Learning Rate: 0.001</i> dan tanpa lapisan <i>Max Pooling</i> untuk forecasting horizon 90 hari . .	C-72
3.215	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 64 &amp; 128, Units: 300, Epoch: 200, Learning Rate: 0.001</i> dan tanpa lapisan <i>Max Pooling</i> untuk forecasting horizon 90 hari . .	C-72
3.216	Perbandingan hasil prediksi dengan data asli dengan konfigurasi <i>Filter: 64 &amp; 128, Units: 300, Epoch: 250, Learning Rate: 0.001</i> dan tanpa lapisan <i>Max Pooling</i> untuk forecasting horizon 90 hari . .	C-72
4.1	Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units: 100, Epoch: 100, Learning Rate: 0.1</i> untuk forecasting horizon 30 hari . . . . .	D-1
4.2	Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units: 100, Epoch: 150, Learning Rate: 0.1</i> untuk forecasting horizon 30 hari . . . . .	D-1
4.3	Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units: 100, Epoch: 200, Learning Rate: 0.1</i> untuk forecasting horizon 30 hari . . . . .	D-1
4.4	Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units: 100, Epoch: 250, Learning Rate: 0.1</i> untuk forecasting horizon 30 hari . . . . .	D-2
4.5	Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units: 200, Epoch: 100, Learning Rate: 0.1</i> untuk forecasting horizon 30 hari . . . . .	D-2
4.6	Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units: 200, Epoch: 150, Learning Rate: 0.1</i> untuk forecasting horizon 30 hari . . . . .	D-2
4.7	Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units: 200, Epoch: 200, Learning Rate: 0.1</i> untuk forecasting horizon 30 hari . . . . .	D-3
4.8	Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units: 200, Epoch: 250, Learning Rate: 0.1</i> untuk forecasting horizon 30 hari . . . . .	D-3
4.9	Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units: 300, Epoch: 100, Learning Rate: 0.1</i> untuk forecasting horizon 30 hari . . . . .	D-3

4.10 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units</i> : 300, <i>Epoch</i> : 150, <i>Learning Rate</i> : 0.1 untuk forecasting horizon 30 hari . . . . .	D-4
4.11 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units</i> : 300, <i>Epoch</i> : 200, <i>Learning Rate</i> : 0.1 untuk forecasting horizon 30 hari . . . . .	D-4
4.12 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units</i> : 300, <i>Epoch</i> : 250, <i>Learning Rate</i> : 0.1 untuk forecasting horizon 30 hari . . . . .	D-4
4.13 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units</i> : 100, <i>Epoch</i> : 100, <i>Learning Rate</i> : 0.01 untuk forecasting horizon 30 hari . . . . .	D-5
4.14 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units</i> : 100, <i>Epoch</i> : 150, <i>Learning Rate</i> : 0.01 untuk forecasting horizon 30 hari . . . . .	D-5
4.15 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units</i> : 100, <i>Epoch</i> : 200, <i>Learning Rate</i> : 0.01 untuk forecasting horizon 30 hari . . . . .	D-5
4.16 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units</i> : 100, <i>Epoch</i> : 250, <i>Learning Rate</i> : 0.01 untuk forecasting horizon 30 hari . . . . .	D-6
4.17 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units</i> : 200, <i>Epoch</i> : 100, <i>Learning Rate</i> : 0.01 untuk forecasting horizon 30 hari . . . . .	D-6
4.18 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units</i> : 200, <i>Epoch</i> : 150, <i>Learning Rate</i> : 0.01 untuk forecasting horizon 30 hari . . . . .	D-6
4.19 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units</i> : 200, <i>Epoch</i> : 200, <i>Learning Rate</i> : 0.01 untuk forecasting horizon 30 hari . . . . .	D-7
4.20 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units</i> : 200, <i>Epoch</i> : 250, <i>Learning Rate</i> : 0.01 untuk forecasting horizon 30 hari . . . . .	D-7
4.21 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units</i> : 300, <i>Epoch</i> : 100, <i>Learning Rate</i> : 0.01 untuk forecasting horizon 30 hari . . . . .	D-7

4.22 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units</i> : 300, <i>Epoch</i> : 150, <i>Learning Rate</i> : 0.01 untuk forecasting horizon 30 hari . . . . .	D-8
4.23 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units</i> : 300, <i>Epoch</i> : 200, <i>Learning Rate</i> : 0.01 untuk forecasting horizon 30 hari . . . . .	D-8
4.24 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units</i> : 300, <i>Epoch</i> : 250, <i>Learning Rate</i> : 0.01 untuk forecasting horizon 30 hari . . . . .	D-8
4.25 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units</i> : 100, <i>Epoch</i> : 100, <i>Learning Rate</i> : 0.001 untuk forecasting horizon 30 hari . . . . .	D-9
4.26 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units</i> : 100, <i>Epoch</i> : 150, <i>Learning Rate</i> : 0.001 untuk forecasting horizon 30 hari . . . . .	D-9
4.27 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units</i> : 100, <i>Epoch</i> : 200, <i>Learning Rate</i> : 0.001 untuk forecasting horizon 30 hari . . . . .	D-9
4.28 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units</i> : 100, <i>Epoch</i> : 250, <i>Learning Rate</i> : 0.001 untuk forecasting horizon 30 hari . . . . .	D-10
4.29 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units</i> : 200, <i>Epoch</i> : 100, <i>Learning Rate</i> : 0.001 untuk forecasting horizon 30 hari . . . . .	D-10
4.30 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units</i> : 200, <i>Epoch</i> : 150, <i>Learning Rate</i> : 0.001 untuk forecasting horizon 30 hari . . . . .	D-10
4.31 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units</i> : 200, <i>Epoch</i> : 200, <i>Learning Rate</i> : 0.001 untuk forecasting horizon 30 hari . . . . .	D-11
4.32 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units</i> : 200, <i>Epoch</i> : 250, <i>Learning Rate</i> : 0.001 untuk forecasting horizon 30 hari . . . . .	D-11
4.33 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units</i> : 300, <i>Epoch</i> : 100, <i>Learning Rate</i> : 0.001 untuk forecasting horizon 30 hari . . . . .	D-11

- 4.34 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.001 untuk forecasting horizon 30 hari . . . . . D-12
- 4.35 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.001 untuk forecasting horizon 30 hari . . . . . D-12
- 4.36 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.001 untuk forecasting horizon 30 hari . . . . . D-12
- 4.37 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.1 untuk forecasting horizon 90 hari . . . . . D-13
- 4.38 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.1 untuk forecasting horizon 90 hari . . . . . D-13
- 4.39 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.1 untuk forecasting horizon 90 hari . . . . . D-13
- 4.40 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.1 untuk forecasting horizon 90 hari . . . . . D-14
- 4.41 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.1 untuk forecasting horizon 90 hari . . . . . D-14
- 4.42 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.1 untuk forecasting horizon 90 hari . . . . . D-14
- 4.43 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.1 untuk forecasting horizon 90 hari . . . . . D-15
- 4.44 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1 untuk forecasting horizon 90 hari . . . . . D-15
- 4.45 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1 untuk forecasting horizon 90 hari . . . . . D-15

- 4.46 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1 untuk forecasting horizon 90 hari . . . . . D-16
- 4.47 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.1 untuk forecasting horizon 90 hari . . . . . D-16
- 4.48 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.1 untuk forecasting horizon 90 hari . . . . . D-16
- 4.49 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.01 untuk forecasting horizon 90 hari . . . . . D-17
- 4.50 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01 untuk forecasting horizon 90 hari . . . . . D-17
- 4.51 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01 untuk forecasting horizon 90 hari . . . . . D-17
- 4.52 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01 untuk forecasting horizon 90 hari . . . . . D-18
- 4.53 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.01 untuk forecasting horizon 90 hari . . . . . D-18
- 4.54 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.01 untuk forecasting horizon 90 hari . . . . . D-18
- 4.55 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.01 untuk forecasting horizon 90 hari . . . . . D-19
- 4.56 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.01 untuk forecasting horizon 90 hari . . . . . D-19
- 4.57 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.01 untuk forecasting horizon 90 hari . . . . . D-19

- 4.58 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.01 untuk forecasting horizon 90 hari . . . . . D-20
- 4.59 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.01 untuk forecasting horizon 90 hari . . . . . D-20
- 4.60 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.01 untuk forecasting horizon 90 hari . . . . . D-20
- 4.61 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.001 untuk forecasting horizon 90 hari . . . . . D-21
- 4.62 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.001 untuk forecasting horizon 90 hari . . . . . D-21
- 4.63 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001 untuk forecasting horizon 90 hari . . . . . D-21
- 4.64 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.001 untuk forecasting horizon 90 hari . . . . . D-22
- 4.65 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001 untuk forecasting horizon 90 hari . . . . . D-22
- 4.66 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001 untuk forecasting horizon 90 hari . . . . . D-22
- 4.67 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001 untuk forecasting horizon 90 hari . . . . . D-23
- 4.68 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.001 untuk forecasting horizon 90 hari . . . . . D-23
- 4.69 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.001 untuk forecasting horizon 90 hari . . . . . D-23

4.70 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units</i> : 300, <i>Epoch</i> : 150, <i>Learning Rate</i> : 0.001 untuk forecasting horizon 90 hari . . . . .	D-24
4.71 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units</i> : 300, <i>Epoch</i> : 200, <i>Learning Rate</i> : 0.001 untuk forecasting horizon 90 hari . . . . .	D-24
4.72 Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi <i>Units</i> : 300, <i>Epoch</i> : 250, <i>Learning Rate</i> : 0.001 untuk forecasting horizon 90 hari . . . . .	D-24

## **DAFTAR ALGORITME**

Algoritme 3.1 CNN-LSTM . . . . .	3-7
----------------------------------	-----

## **DAFTAR LAMPIRAN**

<b>LAMPIRAN A</b> . . . . .	<b>A-1</b>
<b>LAMPIRAN B</b> . . . . .	<b>B-1</b>
<b>LAMPIRAN C</b> . . . . .	<b>C-1</b>
<b>LAMPIRAN D</b> . . . . .	<b>D-1</b>

# BAB 1 PENDAHULUAN

Bab ini menjelaskan landasan yang menjadi acuan bagi penulis dalam melakukan penelitian ini. Landasan tersebut didasarkan kepada fenomena masalah yang terjadi dan akan dibahas dalam penelitian setelah membaca sumber-sumber referensi.

## 1.1 Latar Belakang

Anggaran belanja obat di rumah sakit merupakan komponen terbesar dari pengeluaran rumah sakit dan dapat mencapai hingga 40-50% dari keseluruhan biaya rumah sakit [1]. Hal ini ditambah adanya perubahan Jaminan Kesehatan Nasional (JKN) yang mengacu kepada peraturan Menteri Kesehatan Nomor 72 tahun 2016 tentang Standar Pelayanan Kefarmasian di Rumah Sakit juga menyebutkan bahwa penyelenggara pelayanan kefarmasian di rumah sakit harus menjamin ketersediaan sediaan farmasi, alat kesehatan, dan bahan medis habis pakai yang aman, bermutu, bermanfaat, dan terjangkau membuat rumah sakit harus memastikan kesediaan dan mutu dari obat yang ada di farmasinya [1]. Selain itu, beberapa rumah sakit mengeluhkan bahwa rumus perhitungan pedoman Kementerian Kesehatan terlalu sederhana dan kurang akurat. Maka dari itu penting bagi rumah sakit untuk melakukan perkiraan akan pemakaian obat sehingga dapat selalu memastikan kesediaan, mutu dan lebih memperketat anggaran belanja dengan perhitungan yang lebih akurat.

Untuk melakukan prediksi pemakaian obat di rumah sakit biasanya dilakukan dengan menggunakan model statistika seperti *Exponential Smoothing* dan *Autoregressive Integrated Moving Average* (ARIMA) yang melihat berdasarkan data riwayat pemakaian obat dalam rentang waktu tertentu. Data yang digunakan merupakan data *time-series* riwayat pemakaian obat pada rumah sakit. Namun metode pembelajaran mesin juga sudah mulai banyak dilirik untuk menyelesaikan, terutama model *Artificial Neural Network* (ANN) [2]. Pada penelitian tersebut didapatkan bahwa model *Recurrent Neural Network* (RNN) *Long-Short Term Memory* (LSTM) memiliki performa yang baik, yaitu dengan nilai *Root Mean Squared Error* (RMSE) adalah 40,3 dengan *range data* 1500 sampai 2500.

ANN juga memiliki model lain yang lebih cocok untuk digunakan pada masalah data *time-series* yaitu *Convolutional Neural Network* (CNN). Pada penelitian [3], model CNN digunakan untuk melakukan prediksi penggunaan listrik berdasarkan

data *time-series* riwayat penggunaan listrik. CNN dipilih menggunakan *Support Vector Machine* (SVM) untuk mengatasi masalah tersebut karena dapat mengekstrak fitur non linear dengan baik, selain itu CNN juga dapat mengatasi masalah *short range forecast* atau prediksi untuk rentang waktu yang pendek. Pada penelitian ini [3], model yang digunakan mendapatkan nilai RMSE yaitu 0,698 dengan *range data* 0 sampai 30. Namun CNN memiliki lapisan *Max Pooling* yang dapat menyebabkan informasi yang mungkin dibutuhkan untuk prediksi hilang. Maka dari itu, penelitian [4] menggagas sebuah model CNN yang tidak menggunakan lapisan *Max Pooling* untuk melakukan prediksi berdasarkan data *time-series*. Penelitian [4] menggunakan data riwayat kunjungan sebuah halaman web dan mendapatkan kesimpulan bahwa terdapat pengaruh lapisan *Max Pooling* pada model CNN terhadap hasil prediksi. Pada penelitian [4] juga, disarankan untuk menggunakan *Nonpooling* CNN untuk mengolah data *time-series*. Pelitian ini mendapatkan hasil yang lebih baik jika menggunakan CNN tanpa *Max Pooling* yaitu dengan nilai RMSE 2,33453 jika dibandingkan dengan CNN biasa yaitu 2,704774 dengan *range data* untuk keduanya adalah 0 sampai 600. Dari penelitian [3] dan [4], CNN memiliki kelemahan yaitu lapisan *Max Pooling* cenderung menghilangkan informasi yang berguna untuk prediksi dan dependensi yang dapat dipelajari merupakan dependensi pendek sehingga kurang cocok untuk *Long-Term Load Forecasting* atau prediksi untuk rentang waktu yang panjang.

Selain menggunakan CNN, melakukan prediksi untuk data *time-series* juga dapat dilakukan dengan menggunakan model RNN. Pada kasus prediksi data *time-series*, biasanya menggunakan varian RNN, yaitu LSTM. Keunggulan LSTM adalah adanya penyaringan informasi yang akan diekstrak melalui *gate* untuk memperbarui *cell* yang bersifat sebagai tempat menyimpan informasi. Pada penelitian [5], LSTM digunakan dengan untuk melakukan prediksi harga saham. LSTM dipilih karena pada dasarnya RNN sangat baik untuk menangani masalah mengenai data *time-series* dimana adanya korelasi antara data sebelum dan sesudah. Penelitian ini mendapatkan hasil RMSE yaitu 4,8291 untuk LSTM memiliki *range data* 676,53 sampai 2664,11. Namun LSTM memiliki kelemahan yaitu *overfitting* dan sulit untuk menerapkan *drop out algorithm* untuk menghindari masalah tersebut.

Dapat dilihat bahwa penelitian [6] dan [7] menggunakan gabungan antara CNN dengan LSTM untuk mengatasi masalah di atas. Pada penelitian [6], data yang digunakan adalah data riwayat harga emas, sedangkan pada penelitian [7] digunakan untuk memprediksi konsentrasi partikel polusi *Particulate Matter*

(PM2.5) untuk 24 jam ke depan di kota Beijing. Dengan menggabungkan model CNN dan LSTM, kedua penelitian tersebut dapat memanfaatkan kelebihan CNN untuk melakukan ekstraksi fitur jarak pendek serta kelebihan LSTM yang dapat mempelajari keterkaitan antar titik pada data *time-series* dan melakukan penyaringan data yang lebih relevan terhadap prediksi. Pada penelitian [6], modelnya dapat mempelajari *seasonality* dan *trend* lebih baik jika dibandingkan dengan model CNN dan LSTM saja. Hal ini terlihat dari nilai rata-rata RMSE pada model CNN-LSTM yaitu 0,00767 jika dibandingkan dengan model LSTM yaitu 0,012273 dengan *range data* untuk keduanya adalah 100,50 sampai 113,10. Sedangkan pada penelitian [7], model CNN-LSTM memiliki rata-rata nilai RMSE yang lebih kecil jika dibandingkan dengan model LSTM saja (nilai RMSE 3,4954 lebih baik untuk model CNN-LSTM dengan *range data* 0 sampai 994).

Berdasarkan permasalahan dan potensi yang telah dibahas, penelitian ini akan melakukan pemodelan prediksi dengan menggunakan CNN-LSTM tanpa menggunakan lapisan *Max Pooling* atau dapat disebut sebagai model *Nonpooling*. CNN-LSTM sebagai alternatif dari kekurangan yang dimiliki oleh pemodelan CNN, serta membandingkan hasil prediksinya dengan model CNN-LSTM. Penelitian ini akan menggunakan data riwayat pemakaian obat dari sebuah rumah sakit di Jakarta, Indonesia untuk melakukan prediksi. Diharapkan pemodelan *Nonpooling* CNN-LSTM yang diajukan dapat menjadi solusi atas permasalahan yang telah dibahas.

### 1.2 Rumusan Masalah

Rumusan masalah yang akan dibahas pada penelitian ini antara lain:

1. Bagaimana konfigurasi parameter jumlah *filter*, *units*, *epoch* dan *learning rate* serta lapisan *Max Pooling* pada model CNN-LSTM untuk prediksi pemakaian obat rumah sakit agar meminimalisasi nilai RMSE?
2. Bagaimana hasil prediksi pemakaian obat rumah sakit yang menggunakan CNN-LSTM, *Nonpooling* CNN-LSTM dan LSTM untuk *forecasting horizon short range forecast* dan *long range forecast*?

### 1.3 Tujuan Penelitian

Berdasarkan rumusan masalah di atas, tujuan penelitian ini adalah sebagai berikut:

1. Menganalisis pengaruh konfigurasi parameter jumlah *filter*, *units*, *epoch* dan *learning rate* pada model CNN-LSTM dan *Nonpooling* CNN-LSTM.
2. Memprediksi jumlah pemakaian obat pada rumah sakit menggunakan model

CNN-LSTM dan *Nonpooling* CNN-LSTM untuk *forecasting horizon short range forecast* dan *long range forecast*.

3. Menganalisis pengaruh lapisan *Max Pooling* terhadap model CNN-LSTM dalam melakukan prediksi pemakaian obat rumah sakit.
4. Membandingkan performa model CNN-LSTM, *Nonpooling* CNN-LSTM serta LSTM dalam melakukan prediksi pemakaian obat rumah sakit.

### 1.4 Batasan Masalah

Dalam penelitian ini, ada beberapa batasan masalah, antara lain:

1. Perhitungan *error* yang dilakukan akan menggunakan *Root Mean Squared Error* (RMSE).
2. *Short* dan *long range forecast* akan memiliki masing-masing konfigurasi rentang waktu yaitu 1 bulan dan 3 bulan dengan dasar perhitungan metode konsumsi [1].
3. Model hanya dapat melakukan prediksi pemakaian hanya untuk satu jenis obat spesifik pada rumah sakit tersebut.

### 1.5 Kontribusi Penelitian

Kontribusi yang diberikan dalam penelitian ini, antara lain:

1. Memprediksi jumlah pemakaian obat pada sebuah rumah sakit dengan mengikuti pedoman Kementerian Kesehatan Republik Indonesia.
2. Mengetahui pengaruh konfigurasi parameter dan lapisan *Max Pooling* terhadap hasil prediksi berupa nilai RMSE.

### 1.6 Metode Penelitian

Metode penelitian yang dilakukan dalam penelitian ini adalah sebagai berikut:

#### 1. Studi Literatur

Penelitian ini dimulai dengan studi kepustakaan yaitu mengumpulkan referensi baik dari buku, artikel dan jurnal penelitian mengenai sistem prediksi yang menggunakan model CNN, LSTM serta CNN-LSTM.

#### 2. Pengumpulan dan Pengolahan Data

Pada tahap ini akan dilakukan pengumpulan data berupa riwayat inventori obat tertentu dari sebuah rumah sakit yang berada di Indonesia dan kemudian dilakukan pengolahan normalisasi terhadap data.

#### 3. Analisis Masalah

Pada tahap ini, dilakukan analisis permasalahan yang ada, batasan-batasan yang dimiliki, dan kebutuhan yang diperlukan untuk menyelesaikan permasalahan

## **BAB 1 PENDAHULUAN**

---

yang sudah dianalisis.

### **4. Perancangan dan Implementasi Algoritma**

Pada tahap ini, dilakukan analisis masalah, batasan, perancangan dan implementasi terhadap masalah.

### **5. Pengujian**

Pada tahap ini, dilakukan pengujian dengan menggunakan CNN-LSTM untuk melakukan prediksi pemakaian obat di rumah sakit.

### **6. Evaluasi Metode (Kesimpulan)**

Pada tahap ini, peneliti akan melakukan penghitungan RMSE terhadap hasil pengujian.

### **7. Dokumentasi**

Pada tahap ini, dilakukan pendokumentasian hasil analisis dan implementasi secara tertulis dalam bentuk laporan skripsi.

### **1.7 Sistematika Pembahasan**

Penelitian ini disusun berdasarkan sistematika penulisan sebagai berikut:

## **BAB 1 PENDAHULUAN**

Bab ini berisi latar belakang, rumusan masalah, tujuan penelitian, batasan masalah, kontribusi penelitian, serta metode penelitian yang akan digunakan untuk implementasi.

## **BAB 2 LANDASAN TEORI**

Bab ini berisi penjelasan dasar tentang teori yang mendukung penelitian ini, seperti tinjauan studi, tinjauan pustaka, landasan teori mengenai metode dan objek penelitian serta tahapan algoritema dan contoh penerapannya.

## **BAB 3 ANALISIS DAN PERANCANGAN SISTEM**

Bab ini berisi analisis tahapan penelitian yang terdiri dari pengumpulan data, pengolahan data, metode yang dipakai, pengujian metode, evaluasi dan validasi hasil pengujian.

## **BAB 4 IMPLEMENTASI DAN PENGUJIAN**

Bab ini berisi penjelasan mengenai implementasi dan pengujian metode. Pembahasan implementasi mulai dari pengolahan dataset, pengujian dataset, evaluasi dan validasi hasil pengujian dataset.

**BAB 5      KESIMPULAN DAN SARAN**

Bab ini berisi kesimpulan dari penelitian berdasarkan hasil pengujian yang telah dilakukan dan saran untuk penelitian lebih lanjut di masa mendatang.

## BAB 2 LANDASAN TEORI

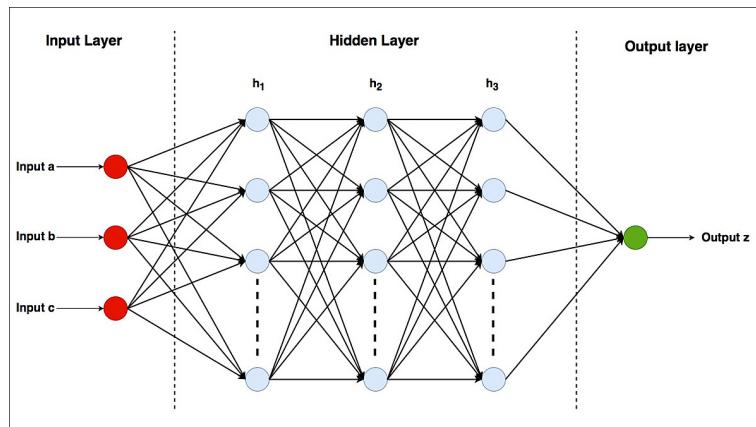
Bab ini menjelaskan dasar-dasar teori yang digunakan dalam penelitian ini. Teori tersebut merupakan teori penunjang yang diambil dari jurnal terkait dan buku-buku referensi.

### 2.1 Tinjauan Pustaka

Penelitian ini menggunakan teori-teori terkait yang diperlukan dalam penelitian. Pembahasan mengenai teori-teori tersebut akan dijelaskan sebagai berikut.

#### 2.1.1 Artificial Neural Network (ANN)

*Artificial neural network* (ANN), atau jaringan saraf tiruan merupakan model pembelajaran mesin yang mengadopsi cara kinerja otak manusia seperti memberi stimulus, melakukan proses dan memberikan hasil. ANN biasa juga dikenal dengan nama *Neural Network* (NN) memiliki struktur yang menyerupai dengan prinsip kinerja otak manusia yang dinamakan lapisan (*layer*). Lapisan-lapisan tersebut antara lain: *input*, *hidden* dan *output*. Lapisan *hidden* sendiri dapat terdiri dari satu sampai banyak lapisan, atau bahkan tidak memiliki lapisan ini sama sekali [8].



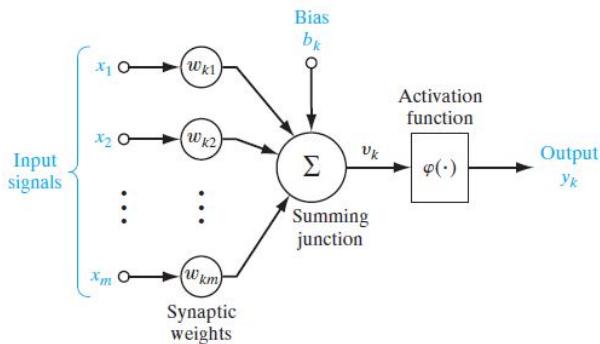
Gambar 2.1 Artificial Neural Network [8]

Pada setiap bagian dari NN, terdapat titik (*node*) yang disebut *neuron*. Jumlah *neuron* pada setiap lapisan mempengaruhi kemampuan generalisasi sistem, sementara jumlah *neuron* pada *hidden layer* berpengaruh terhadap efisiensi sistem. Jumlah *neuron* pada *hidden layer* berperan sebagai perhitungan *weighted sum* dari nilai yang diberikan dari lapisan sebelumnya untuk diterapkan ke dalam *activation function* (fungsi aktivasi). Hal ini berarti, semakin banyak *neuron* ada

kemungkinan terjadinya *overfitting* dimana kemampuan generalisasi model rendah hanya terbatas oleh data latih, ketika digunakan uji coba di luar data tersebut maka akan menghasilkan akurasi yang rendah.

*Neuron* merupakan unit untuk memroses informasi yang paling dasar dalam *neural network*. Secara umum, terdapat tiga buah elemen dasar dalam *neuron* [8]:

1. Sekumpulan sinapsis yang masing-masing memiliki bobot atau *weight*. Sinyal masukan  $x_j$  pada sinapsis  $j$  yang terhubung dengan *neuron*  $k$  akan dikalikan dengan bobot sinapsis  $w_{kj}$ .
2. Sebuah proses penjumlahan (*summing junction*) untuk menjumlahkan sinyal masukan yang telah diproses dengan bobotnya pada masing-masing sinapsis *neuron*. Operasi ini disebut *linear combiner*.
3. Fungsi aktivasi untuk membatasi jarak keluaran *neuron*. Biasanya, jarak keluaran dari *neuron* dibuat antara 0 hingga 1 atau -1 hingga 1.



Gambar 2.2 Neuron [8]

Gambar 2.2 menunjukkan contoh model dari sebuah *neuron*. Model tersebut dapat dilengkapi dengan beberapa Persamaan dasar berikut (Persamaan 2.1, 2.2, dan 2.3) [8]:

$$u_k = \sum_{j=1}^m w_{kj} x_j \quad (2.1)$$

$$v_k = u_k + b_k \quad (2.2)$$

$$y_k = \varphi(v_k) \quad (2.3)$$

Keterangan :

$u_k$	: hasil <i>linear combiner</i> dari sinyal masukan
$x$	: sinyal masukan
$w_k$	: bobot sinapsis pada <i>neuron k</i>
$m$	: jumlah masukan
$b_k$	: nilai <i>bias</i>
$v_k$	: <i>induced local field / activation potential</i> sebagai keluaran
$y_k$	: sinyal keluaran dari <i>neuron</i>
$\phi$	: fungsi aktivasi

Model *neuron* pada Gambar 2.2 juga mencakup *bias* yang diterapkan secara eksternal yang dilambangkan dengan  $b_k$ . *Bias*  $b_k$  memiliki efek [8]:

1. menaikkan atau menurunkan masukan fungsi aktivasi.
2. menerapkan *affine transformation* (transformasi linear kepada masukan) ke keluaran  $u_k$  dari *linear combiner* dalam model pada Gambar 2.2.

### 2.1.2 Convolutional Neural Network (CNN)

*Convolutional neural network* (CNN) merupakan ANN yang dapat memproses data yang memiliki topologi seperti *grid* seperti data time-domain yang dianggap seperti *grid* 1 dimensi atau data Gambar yang memiliki 2 sampai 3 dimensi (spektrum warna RGB). Data time-domain salah satu contohnya adalah data *time-series* merupakan data yang melakukan pengambilan sampel data pada dimensi waktu tertentu secara berurutan terhadap waktu. Nama *convolutional neural network* menunjukkan bahwa jaringan saraf melakukan operasi secara konvolusi, yang merupakan operasi linear khusus. Jaringan konvolusi adalah NN yang menggunakan operasi konvolusi sebagai ganti dari penerapan matriks umum pada lapisannya [9].

Pada umumnya, konvolusi adalah operasi dua fungsi yang bernilai *real*. Dua buah argumen yang diperlukan adalah nilai masukan serta *kernel*. Hasil dari konvolusi yang telah dilakukan disebut *feature map*. Pada umumnya, tipe pembelajaran mesin CNN biasanya digunakan untuk mempelajari data Gambar dengan data masukan multidimensi serta *kernel* merupakan larik multidimensi. Namun pada kasus data *time-series*, operasi konvolusi akan dilakukan terhadap data masukan 1 dimensi dan *kernel* merupakan larik 1 dimensi saja. Proses pelatihan CNN terdiri atas 2 proses besar, yaitu *forward propagation* dan *backward propagation*.

1. *Forward propagation* berfungsi untuk mencari nilai probabilitas dari data yang diproses dari *layer* pertama hingga *layer* terakhir dan menentukan ke kelas mana suatu data akan dimasukkan. Selain itu, ada juga perhitungan *loss function* yang berfungsi untuk mencari nilai *error*.
2. *Backward propagation* berfungsi untuk melakukan optimasi arsitektur CNN dengan melakukan pembaharuan bobot (*weight*) dari hasil perhitungan pada proses *forward propagation* sebagai masukan. Proses ini dilakukan dari *layer* terakhir sampai *layer* pertama.

Ada tiga jenis lapisan yang membentuk arsitektur CNN, yaitu: *convolutional layer*, *max pooling layer* dan *dense/fully connected layer* [10]. Pada arsitektur CNN, *fully connected layer* merupakan *output layer*, *convolutional layer* dan *max pooling layer* berperan sebagai *hidden layer* [9]. Dalam proses *forward propagation*, ada empat operasi utama, antara lain: konvolusi, aktivasi, *pooling* dan klasifikasi yang dilakukan dalam lapisan yang terdapat dalam CNN [10].

### 2.1.2.1 *Convolutional Layer*

*Convolutional layer* pada CNN memiliki fungsi untuk melakukan deteksi fitur. Deteksi fitur akan dilakukan oleh *kernel*. Hal ini berarti, semakin banyak *kernel* pada *convolutional layer*, maka semakin banyak fitur yang dapat dideteksi dari suatu masukan. Tinggi, lebar dan kedalaman *convolutional layer* dari matriks yang digunakan sebagai masukan sama dengan citra masukan. Keluaran dari *convolutional layer* bergantung kepada *hyperparameter* yang ada pada lapisan. Berbeda jika digunakan pada kasus data *time-series*, dimensi matriks masukan serta *kernel* berupa 1 dimensi dengan keluaran hanya nilai prediksinya saja. *Hyperparameter* merupakan parameter yang nilainya mengontrol proses pelatihan. Lima buah *hyperparameter* tersebut [10] yaitu:

1. Jumlah *filter* yang menentukan banyak *feature map* yang akan dihasilkan dalam satu kali konvolusi pada *convolutional layer* serta menentukan banyak *kernel* untuk memroses *feature map*.
2. Ukuran *kernel* yang menentukan ukuran matriks hasil konvolusi.
3. *Stride* yang merupakan besar perpindahan *kernel* pada proses konvolusi. Nilai *stride* tidak dapat bernilai nol karena konvolusi tidak dapat bergerak jika demikian.
4. *Padding* yang merupakan tambahan piksel pada *feature map*. Dengan adanya *padding*, *kernel* dapat melakukan konvolusi melewati dimensi *feature map*.
5. Fungsi aktivasi yang menentukan nilai keluaran dalam *feature map*.

Nilai awal dari setiap bobot dalam *kernel* merupakan nilai acak yang terdistribusi normal untuk mencegah hilangnya data ketika proses konvolusi dilakukan [10]. Bobot *kernel* akan diperbaharui dan atur ulang selama proses pelatihan CNN. Pendekatan umum untuk inisialisasi bobot adalah teknik (*Gaussian Random Initialization*) yang menghasilkan angka-angka acak yang terdistribusi normal. Pendekatan ini menginisialisasi *kernel* dari *convolutional layer* dan *fully connected layer* menggunakan matriks acak yang elemennya disampel dari distribusi Gaussian atau distribusi normal dengan rata-rata bernilai nol dan standar deviasi yang kecil (misalnya 0.1 dan 0.01) [11]. Persamaan 2.4 adalah Persamaan distribusi normal yang digunakan.

$$k = \frac{1}{\sigma\sqrt{2\pi}} e^{-(x-\mu)^2/2\sigma^2} \quad (2.4)$$

---

Keterangan :

- $k$  : nilai *kernel*
  - $x$  : variabel acak normal
  - $\sigma$  : standar deviasi
  - $\mu$  : rata-rata
  - $\pi$  : nilai pi (3.14159265359...)
  - $e$  : bilangan *Euler* (2.718281828...)
- 

Operasi konvolusi dapat dihubungkan dengan Persamaan 2.1 pada ANN. Jika pada ANN digunakan bobot *neuron* untuk menghitung *linear combiner* sesuai dengan Persamaan 2.1, pada CNN digunakan matriks masukan untuk menghitung *linear combiner*. Operasi konvolusi merupakan proses memindahkan *kernel* secara bergantian per piksel (*strides*) dalam suatu matriks serta menghitung hasil perkalian per elemen antara nilai pada matriks ( $x$ ) dan *kernel* ( $w$ ) untuk setiap elemennya. Operasi konvolusi antara matriks  $x$  dan *kernel*  $w$  dapat dilihat pada Persamaan 2.5.

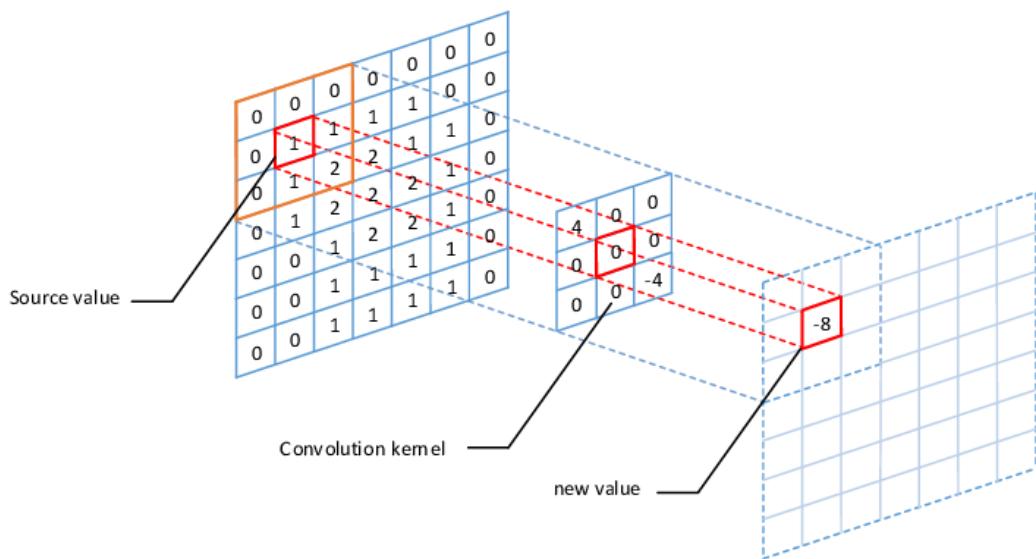
$$v(i, j) = \sum_n \sum_m w_{(n,m)} x_{(i-n, j-m)} \quad (2.5)$$

## BAB 2 LANDASAN TEORI

Keterangan :

- $x$  : matriks yang akan dikonvolusi  
 $w$  : nilai matriks *kernel*  
 $v(i, j)$  : nilai  $(x, y)$  pada matriks keluaran  
 $i$  : koordinat x pada matriks.  
 $j$  : koordinat y pada matriks.  
 $n$  : variabel iterasi untuk lebar matriks.  
 $m$  : variabel iterasi untuk tinggi matriks.

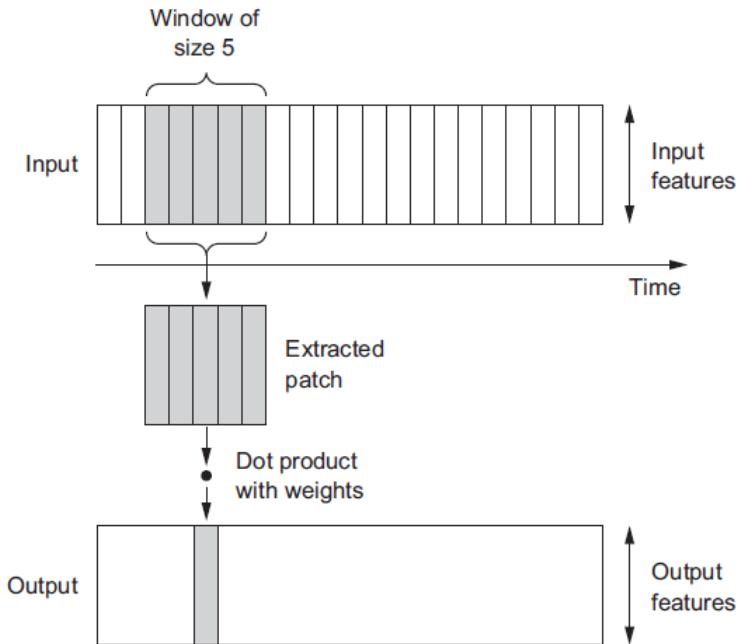
Gambar 2.3 merupakan ilustrasi perhitungan pada setiap langkah konvolusi. Saat *kernel* digeser ke masukan untuk menghitung nilai *feature map* keluaran. *Kernel*  $3 \times 3$  (*convolution kernel* pada Gambar) dikalikan dengan suatu wilayah yang ukurannya sama (*source value* pada Gambar) akan menghasilkan nilai (*new value* pada Gambar bernilai -8) di *feature map* keluaran pada setiap langkah konvolusi.



**Gambar 2.3** Contoh operasi konvolusi

Pada penelitian ini, karena data yang dimasukkan merupakan sebuah data *time-series* yang membentuk sebuah sekuens, digunakan operasi konvolusi yang bersifat satu dimensi. Perbedaan operasi konvolusi pada matriks 1 dimensi dan 2 dimensi ada di pergerakan *kernel*, dimana pada matriks 2 dimensi pergerakan *kernel* ke samping dan ke bawah, sedangkan pada matriks 1 dimensi pergerakan hanya ke samping mengikuti sekuens waktu dari data. Transformasi masukan yang sama dilakukan pada setiap *data patch*, pola yang dipelajari pada posisi tertentu dalam sebuah data nantinya dapat dikenali pada posisi yang berbeda. Gambar 2.4 menunjukkan Gambaran dari operasi konvolusi 1 dimensi, dimana pergerakan

*kernel* ke arah samping kanan berdasarkan dimensi waktu [12].

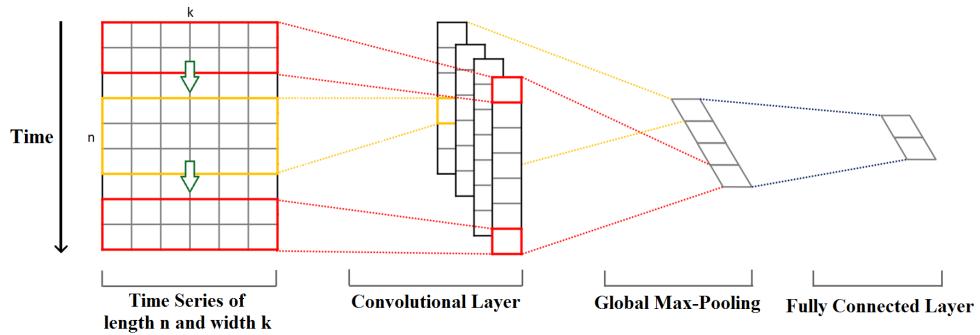


**Gambar 2.4** Contoh operasi konvolusi pada matriks satu dimensi [12]

### 2.1.2.2 Max Pooling Layer

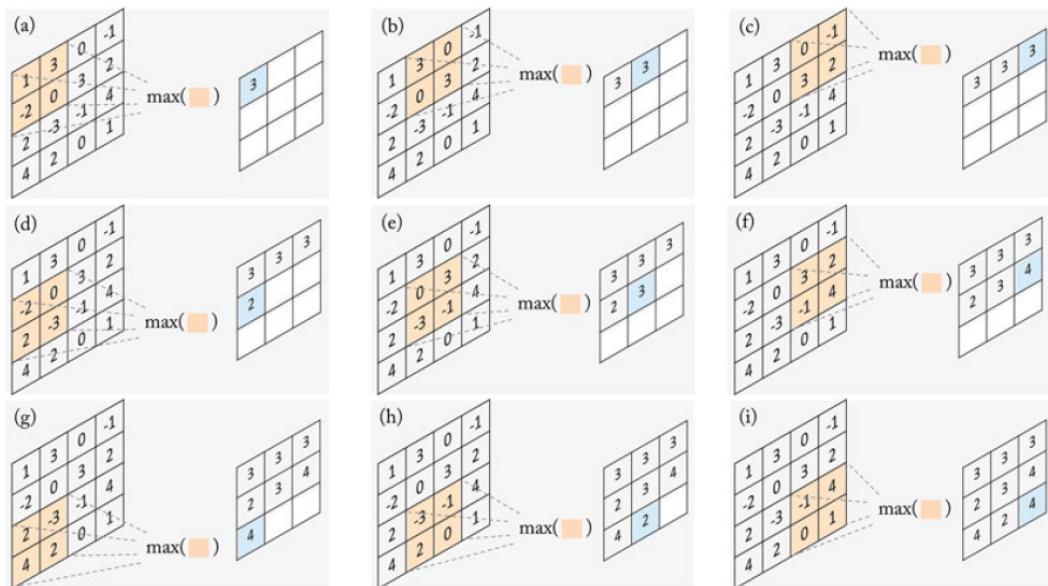
*Max pooling layer* adalah proses pengambilan nilai dari satu koordinat matriks hasil konvolusi dengan memilih nilai yang paling tinggi pada area tertentu. *Max pooling layer* berperan untuk mengurangi dimensi matriks (*down sampling*) dan membuat matriks baru dengan ukuran lebih kecil berisikan nilai maksimum dari operasi tersebut. Lapisan ini tidak memiliki *padding* seperti *convolutional layer*, tidak memiliki *weight* dan tidak terpengaruh oleh proses pelatihan [10]. Gambar 2.5 merupakan contoh susunan *convolution layer* beserta *max pooling layer* pada CNN untuk data *time-series*. *Max pooling layer* memiliki dua *hyperparameter* [10], yaitu:

1. *Spatial extent* untuk menentukan area yang akan dijadikan satu piksel pada proses *max pooling*.
2. *Stride*, besar perpindahan kotak *spatial extent*.



**Gambar 2.5** Contoh susunan lapisan konvolusi dan *max pooling* pada data *time-series*

Gambar 2.6 adalah contoh operasi *max pooling layer* dengan *spatial extent*  $2 \times 2$  dan *stride* 1 untuk matriks 2 dimensi. Pada setiap *spatial extent*, akan dipilih 1 nilai maksimal untuk kemudian disimpan menjadi matriks baru. Setiap langkahnya *spatial extent* akan bergerak 1 posisi ke kanan dikarenakan konfigurasi *strides* adalah 1.

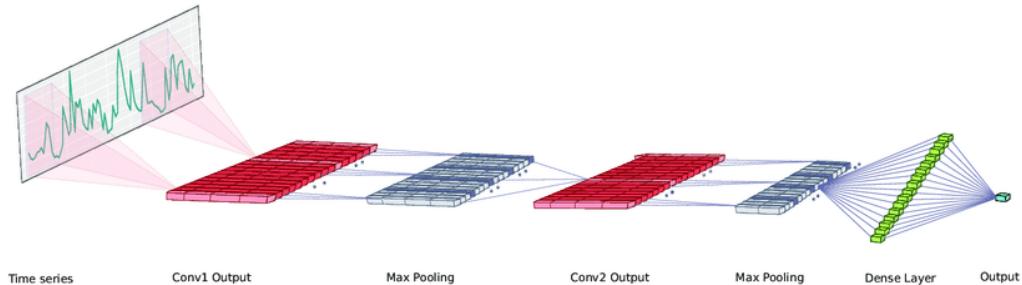


**Gambar 2.6** Contoh operasi *max pooling* [11]

### 2.1.2.3 Dense/Fully Connected Layer

*Dense* atau *fully connected layer* adalah lapisan terakhir dalam arsitektur CNN yang menghubungkan setiap *neuron* pada lapisan sebelumnya ke setiap *neuron* pada *fully connected layer*. Hasil dari *fully connected layer* diproses dengan fungsi aktivasi. *Hyperparameter* pada lapisan ini adalah jenis fungsi aktivasi yang digunakan. *Fully connected* terakhir pada sebuah *neural network* akan melakukan proses klasifikasi [10]. Pada kasus data *time-series*, hasil yang dikeluarkan oleh

*dense* biasanya memiliki 1 nilai atau sejumlah rentang waktu yang ingin diprediksi pada sekuens data. Gambar 2.7 merupakan contoh penggunaan CNN untuk data time-series dengan hasil keluaran *dense* 1 *neuron*.



**Gambar 2.7** Contoh arsitektur CNN lengkap beserta *dense* untuk data *time-series*

Pada Gambar 2.7, data yang berupa matriks 2 dimensi dengan sumbu xnya menggambarkan waktu akan dilakukan konvolusi 2 kali konvolusi serta 2 kali *Max Pooling* untuk memperkecil ukuran datanya. Kemudian hasil dari *Max Pooling* kedua akan diberikan kepada lapisan *dense* untuk nantinya akan menjadi nilai keluaran berupa 1 *neuron*. Persamaan 2.6 merupakan perhitungan untuk lapisan *dense* [9].

$$y = f(W^T x + b) \quad (2.6)$$

---

Keterangan :

- $W^T$  : matriks yang berisi bobot sambungan antar *layer*
  - $f$  : fungsi aktivasi
  - $x$  : vektor yang dihasilkan dari *feature map*
  - $b$  : vektor *bias*
- 

### 2.1.3 Fungsi Aktivasi

Dalam pemrograman *neural network*, fungsi aktivasi menetapkan batasan untuk keluaran *neuron* [10]. Fungsi aktivasi bertugas untuk memberikan transformasi penghitungan data berbobot. Keluarannya akan mengubah klasifikasi, prediksi, atau tujuan sebuah *neural network* dibangun [14]. Pada penelitian ini, akan digunakan fungsi aktivasi, yaitu *Rectified Linear Unit* (ReLU).

### 2.1.3.1 Rectified Linear Unit (ReLU)

ReLU digunakan untuk mengubah semua nilai negatif menjadi nol. Hal ini dilakukan untuk membantu CNN lebih mudah mencapai nilai optimumnya. Persamaan 2.7 merupakan persamaan fungsi aktivasi ReLU. Jika  $x$  adalah nol atau bilangan bulat negatif, fungsi mengembalikan nilai nol. Jika  $x$  adalah bilangan bulat positif, fungsi mengembalikan bilangan bulat positif tersebut [14]. Fungsi aktivasi ini digunakan di lapisan *dense*, seperti yang sudah dibahas pada bagian 2.1.2.3 dan diilustrasikan pada Gambar 2.7. Gambar 2.8 merupakan contoh penggambaran dari fungsi aktivasi ReLU.

$$f(x) = \max(0, x) \quad (2.7)$$

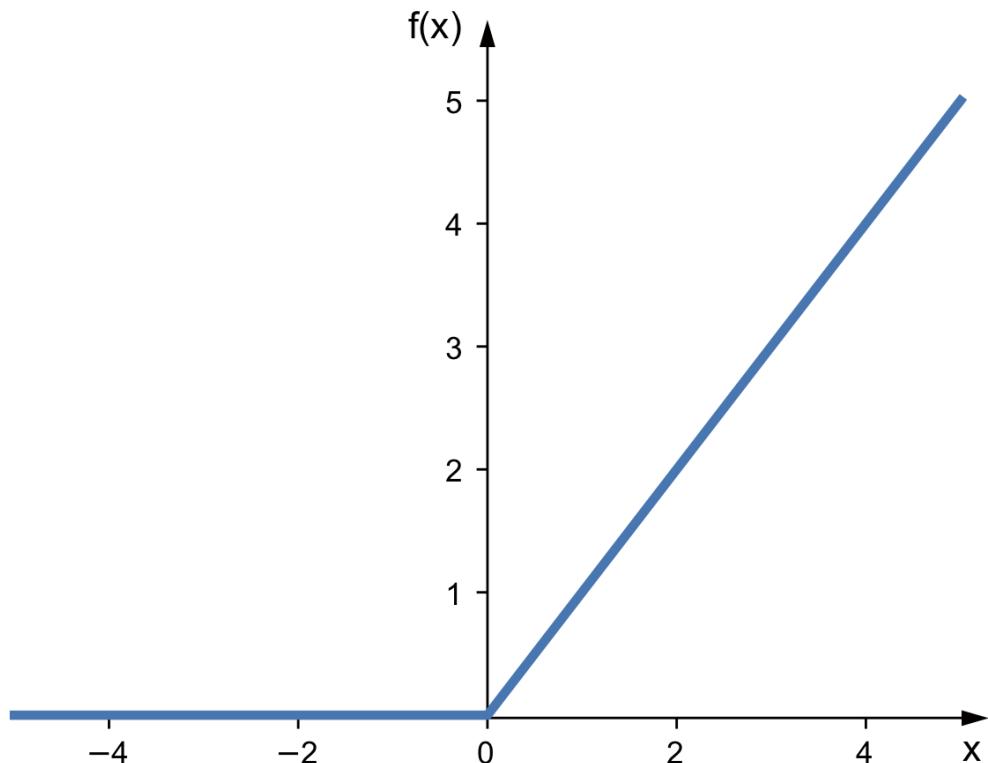
---

Keterangan :

$f(x)$  : Hasil fungsi aktivasi ReLU

$x$  : Nilai dari matriks

---



**Gambar 2.8** Fungsi aktivasi ReLU

### 2.1.3.2 Hyperbolic Tangent Activation

*Hyperbolic Tangent Activation Function* (*Tanh Activation Function* atau *tanh*) pada algoritma LSTM digunakan untuk komputasi pada *Candidate State* dan perhitungan keluaran. Fungsi aktivasi *tanh* sering digunakan sebagai fungsi aktivasi untuk *neural network* yang menghasilkan nilai keluaran diantara -1 dan 1 [15]. Fungsi ini berguna untuk meregulasi nilai keluaran agar tetap terjaga. Persamaan 2.8 merupakan persamaan untuk fungsi aktivasi *tanh*. Gambar 2.9 merupakan contoh penggambaran dari fungsi aktivasi *tanh*.

$$f(x) = \tanh(x) \quad (2.8)$$

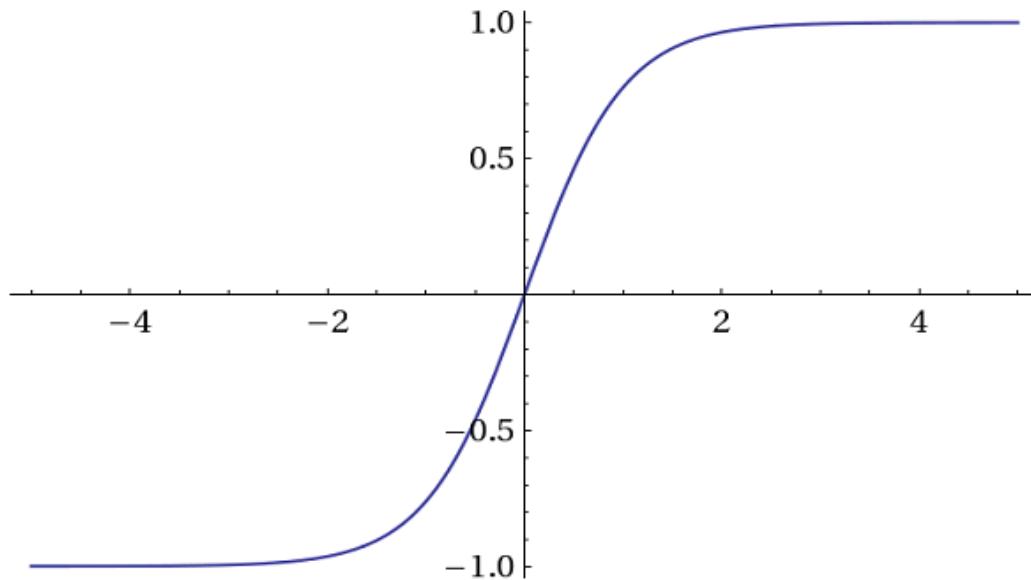
---

Keterangan :

$f(x)$  : Hasil fungsi aktivasi *tanh*

$x$  : Nilai dari matriks

---

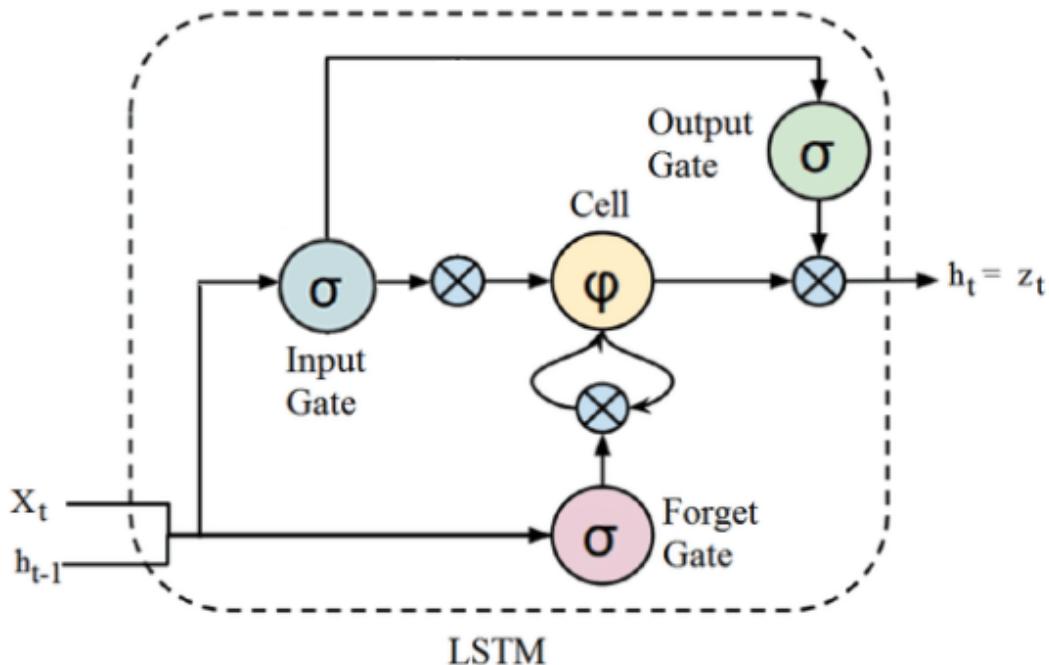


Gambar 2.9 Fungsi aktivasi tanh

#### 2.1.4 Long-Short Term Memory (LSTM)

*Long-Short Term Memory* (LSTM) adalah model versi perbaikan dari *Recurrent Neural Network* (RNN) yang lebih baik karena LSTM dapat menyelsaikan masalah RNN yaitu *Vanishing* dan *Exploding gradient* serta kekurangannya untuk mengingat serta melupakan informasi dari masukan sekuens [13]. LSTM memiliki lapisan *state* (keadaan) yang berperan untuk menyimpan informasi yang dapat digunakan pada lapisan berikutnya. Lapisan lain adalah *gates* (gerbang) yang berfungsi sebagai penentu mengenai informasi untuk diingat atau dilupakan. Kemudian fungsi aktivasi akan digunakan untuk membantu model jaringan saraf tiruan mempelajari pola kompleks pada data. Gambar 2.10 merupakan contoh Gambaran arsitektur LSTM yang menggunakan *tanh* sebagai fungsi aktivasinya. LSTM sendiri memiliki 3 mekanisme utama, antara lain:

1. *Output control* merupakan banyak *neuron* yang berpengaruh terhadap keluaran sebelumnya dan keadaan yang sekarang.
2. *Memory control* merupakan banyak dari keadaan sebelumnya yang akan dilupakan pada keadaan sekarang.
3. *Input control* merupakan banyak dari keluaran sebelumnya dan keadaan sekarang yang akan dipertimbangkan untuk keadaan berikutnya.



Gambar 2.10 Contoh Gambaran arsitektur LSTM.

Pada Gambar 2.10, nilai  $X_t$  beserta dengan nilai *cell* pada iterasi sebelumnya akan diproses menuju *input gate* dan *forget gate*. Rincian penjelasan mengenai *input*

*gate* akan dijelaskan lebih lanjut pada Bagian 2.1.4.1 dan rincian mengenai *forget gate* pada Bagian 2.1.4.2. Kemudian masing-masing akan memberikan hasil perhitungan yang nantinya akan dihitung menjadi nilai untuk *cell* pada iterasi  $t$  tersebut (seperti pada 2.12). Langkah terakhir adalah *output gate* yang berfungsi sebagai tempat perhitungan untuk nilai keluaran. Penjelasan lebih mendalam mengenai *output gate* ada pada Bagian 2.1.4.4.

#### 2.1.4.1 Input Gate

*Input Gate* adalah gerbang yang menentukan nilai masukan baru dimana nilai tersebut akan digunakan untuk membaharui *cell* [16]. Pada Gambar 2.10 dapat dilihat *input gate* akan melakukan kalkulasi yang nantinya akan diberikan kepada *cell* dan *output gate*. Seperti pada Persamaan 2.9,  $W_u$  akan dikalikan dengan nilai dari  $x[t]$  sebelumnya dan  $R_u$  dikalikan dengan nilai masukan  $y[t - 1]$  dan ditambah nilai  $b_u$  dimana  $t$  merupakan *state* saat ini. Kemudian hasil dari perhitungan tersebut akan dikalikan dengan fungsi aktivasi yang disebut *recurrent activation function*. Fungsi aktivasi dapat berupa seperti yang telah dijelaskan pada bagian 2.1.3.

$$f_u[t] = f(W_u X[t] + R_u y[t - 1] + b_u) \quad (2.9)$$

---

Keterangan :

- $f_u[t]$  : Hasil dari *input gate* untuk state  $t$
  - $f$  : *Recurrent activation function*
  - $W_u, R_u$  : Nilai bobot
  - $y[t - 1]$  : Nilai keluaran *state* sebelumnya
  - $b_u$  : Nilai *bias*
- 

Kemudian, tahap berikutnya adalah melakukan Persamaan 2.9 kembali namun menggunakan formula yang sedikit berbeda. Perbedaan terdapat pada perhitungan ini biasanya menggunakan fungsi aktivasi yang berbeda. Persamaan 2.10 merupakan Persamaan baru untuk menghitung *candidate state*, yang digunakan nantinya untuk melakukan pembaharuan nilai dari *cell*. Hasil dari *input gate* akan memiliki 2 hasil perhitungan, yaitu dari Persamaan 2.9 dan 2.10.

## BAB 2 LANDASAN TEORI

$$\tilde{h}[t] = g_1(W_h x[t] + R_h y[t-1] + b_h) \quad (2.10)$$

Keterangan :

- $\tilde{h}[t]$  : Hasil dari candidate state untuk *state t*  
 $g_1$  : Fungsi aktivasi (*activation function*)  
 $x[t]$  : Nilai masukan berupa vektor  
 $W_h, R_h$  : Nilai bobot  
 $y[t-1]$  : Nilai keluaran *state* sebelumnya  
 $b_h$  : Nilai *bias*

### 2.1.4.2 Forget Gate

*Forget gate* adalah gerbang yang bertujuan untuk menentukan informasi apa yang harus dilupakan pada *cell* [16]. Pada Gambar 2.10, dapat dilihat *forget gate* dengan *cell* memiliki panah 2 arah, dimana nantinya akan menentukan mengenai informasi pada *cell* akan disimpan atau dilupakan. Persamaan 2.11 merupakan perhitungan nilai dari *forget gate*.

$$f_f[t] = f(W_f x[t] + R_f y[t-1] + b_f) \quad (2.11)$$

Keterangan :

- $f_f[t]$  : Hasil dari forget gate untuk *state t*  
 $f$  : *Recurrent activation function*  
 $x[t]$  : Nilai masukan berupa vektor  
 $W_f, R_f$  : Nilai bobot  
 $y[t-1]$  : Nilai keluaran *state* sebelumnya  
 $b_f$  : Nilai *bias*

### 2.1.4.3 Cell State

*Cell state* adalah bagian tambahan pada LSTM yang tidak ada di RNN, yaitu untuk menyimpan informasi. *State* (keadaan) ini menentukan informasi dari langkah

sebelumnya apakah akan diingat atau dilupakan. Perhitungan untuk memperbarui nilai *cell state* adalah dengan mengalikan *forget gate* dengan nilai *cell state* sebelumnya. Seperti dapat dilihat pada Gambar 2.10, *cell* akan menerima masukan dari *input gate* serta berkomunikasi dengan *forget gate* yang nantinya akan ditentukan informasi apa yang disimpan pada *cell* di *state* tertentu. Persamaan 2.12 merupakan perhitungan dari *input gate* untuk membaharui nilai *cell* pada *state t*.

$$h[t] = f_u[t] \odot \bar{h}[t] + f_f[t] \odot \bar{h}[t - 1] \quad (2.12)$$

---

Keterangan :

- $h[t]$  : Hasil perhitungan untuk nilai *cell* di *state t*
  - $f_u[t]$  : Hasil dari *input gate* untuk *state t*
  - $\bar{h}[t]$  : Hasil dari *candidate state* untuk *state t*
  - $f_f[t]$  : Hasil dari *forget gate* untuk *state t*
  - $h[t - 1]$  : Hasil perhitungan untuk nilai *cell* di *state* sebelumnya
- 

#### 2.1.4.4 Output Gate

*Output gate* merupakan gerbang yang bertujuan untuk menentukan nilai yang akan digunakan untuk perhitungan *hidden state* baru berdasarkan hasil perhitungan masukan dan informasi pada *cell* [16]. Perhitungan di *output gate* mirip dengan Persamaan pada 2.9 dan Persamaan 2.11 yaitu menggunakan fungsi aktivasi *sigmoid*. Persamaan 2.13 merupakan Persamaan untuk mendapatkan nilai *output gate*.

$$f_o[t] = f(W_o x[t] + R_o y[t - 1] + b_o) \quad (2.13)$$

## BAB 2 LANDASAN TEORI

---

Keterangan :

- $f_o[t]$  : Hasil dari output gate untuk *state t*  
 $f$  : Recurrent activation function  
 $x[t]$  : Nilai masukan berupa vektor  
 $W_o, R_o$  : Nilai bobot  
 $y[t - 1]$  : Nilai keluaran *state* sebelumnya  
 $b_o$  : Nilai bias
- 

Setelah mendapatkan nilai *output gate*, akan dilakukan perhitungan untuk mendapatkan nilai keluaran yang nantinya akan digunakan lagi untuk melakukan perhitungan pada iterasi berikutnya. Persamaan 2.14 merupakan perhitungan untuk menetukan nilai keluarannya dengan mengalikan hasil dari *output gate* dengan *cell state* yang dikalikan dengan fungsi aktivasi *tanh*.

$$y[t] = f_o[t] \odot g_2(h[t]) \quad (2.14)$$

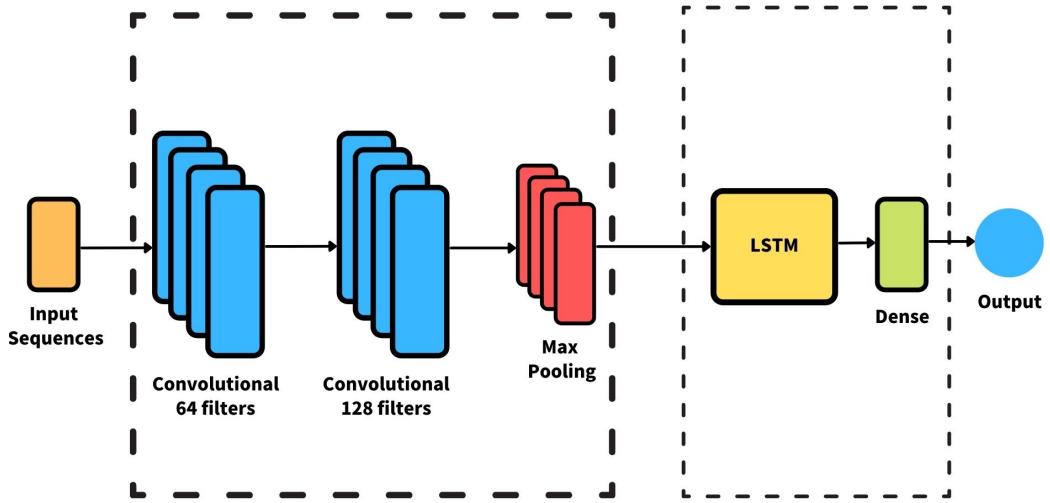
---

Keterangan :

- $y[t]$  : Hasil Nilai keluaran untuk *state t*  
 $f_o[t]$  : Hasil dari output gate untuk *state t*  
 $g_2$  : Fungsi aktivasi (*activation function*)  
 $h[t]$  : Hasil perhitungan untuk Nilai *cell* di *state t*
- 

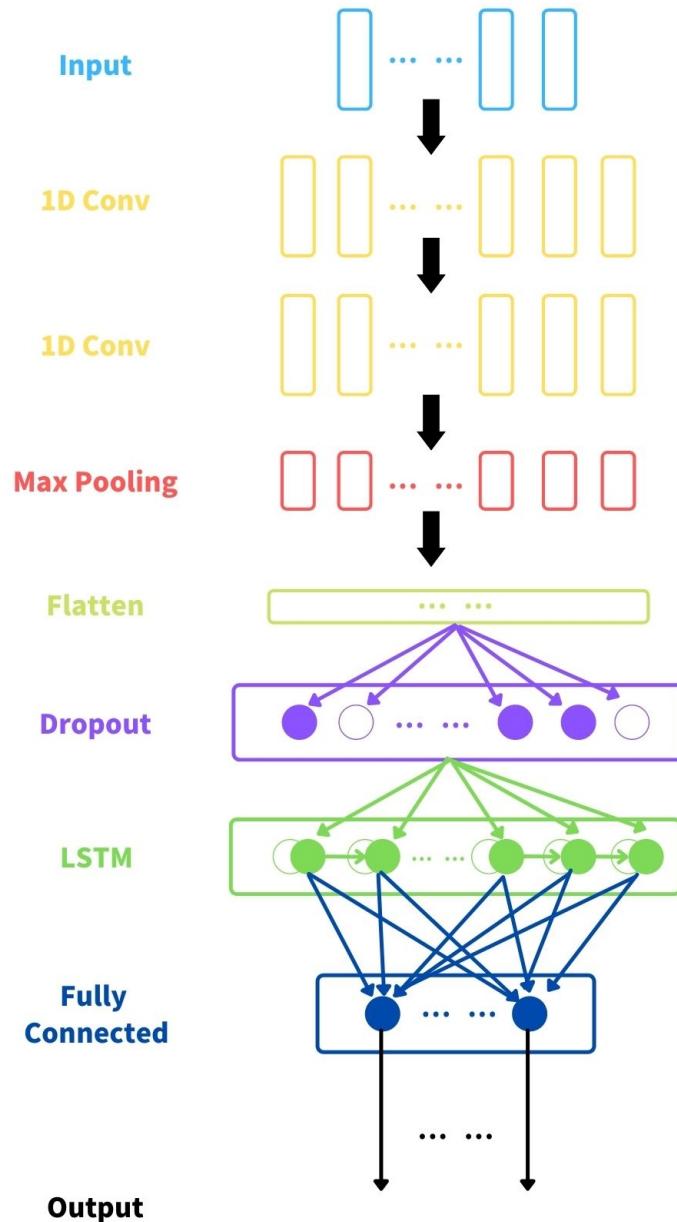
### 2.1.5 CNN-LSTM

CNN-LSTM merupakan metode yang menggabungkan lapisan konvolusi dari CNN serta jaringan LSTM untuk melakukan prediksi [6]. Penggabungan kedua model ini bertujuan untuk memanfaatkan kemampuan CNN untuk mengidentifikasi *short-term dependency* serta kemampuan memori dari sel LSTM. Gambar 2.11 merupakan contoh arsitektur dari CNN-LSTM.



**Gambar 2.11** Contoh arsitektur CNN-LSTM [6]

Pada Gambar 2.11, lapisan CNN yang digunakan adalah 2 lapisan konvolusi dengan masing-masing *filter* 64 dan 128 serta *Max Pooling layer*. Kemudian hasil dari CNN akan diberikan kepada LSTM untuk diproses dan terakhir menggunakan *fully connected layer (dense)* untuk menghasilkan nilai keluaran. Bentuk arsitektur CNN-LSTM lain yang digunakan oleh [7] terdapat pada Gambar 2.12.



**Gambar 2.12** Contoh arsitektur CNN-LSTM untuk data *time-series* [7]

Pada Gambar 2.12, lebih diperinci lagi mengenai arsitektur CNN-LSTM yang digunakan untuk data *time-series*. Secara garis besar, lapisan yang digunakan di model CNN serupa yaitu 2 lapisan konvolusi dan 1 *Max Pooling layer*. Perbedaannya ada di rincian penggunaan metode *flatten* dan *dropout* digunakan sebelum diberikan kepada LSTM. Hal ini dilakukan untuk menghindari terjadinya *overfitting*. Sama seperti arsitektur pada Gambar 2.11, arsitektur pada Gambar 2.12 juga menggunakan *fully connected layer (dense)* untuk menghasilkan nilai keluaran.

### 2.1.6 *Nonpooling CNN-LSTM*

Pada Bagian 2.1.2 sudah dijelaskan bahwa CNN memiliki 2 bagian utama yaitu lapisan konvolusi dan lapisan *Max Pooling*. *Nonpooling* CNN merupakan arsitektur CNN yang tidak memiliki lapisan *Max Pooling* sehingga arsitektur CNN tersebut hanya memiliki lapisan konvolusi saja [4]. Istilah *Nonpooling* sendiri berarti Non Max Pooling atau tanpa *Max Pooling* diambil dari istilah yang digunakan pada penelitian [4]. Sehingga *Nonpooling* CNN-LSTM adalah arsitektur CNN-LSTM seperti yang telah dijelaskan pada Bagian 2.1.5 hanya saja pada bagian CNN arsitektur tersebut tidak memiliki lapisan *Max Pooling* sama sekali.

### 2.1.7 Pustaka

Bagian ini menjelaskan pustaka (*library*) yang digunakan di dalam penelitian.

#### 2.1.7.1 NumPy

NumPy adalah pustaka untuk bahasa pemrograman Python yang memberikan dukungan untuk melakukan fungsi dan operasi matematika tingkat tinggi. NumPy membantu pemrosesan data berbentuk larik. Tabel berikut merupakan rincian fungsi yang akan digunakan dari pustaka ini.

**Tabel 2.1** Daftar *method* yang digunakan dari pustaka NumPy

No.	Method	Masukan	Keluaran	Keterangan
1	array	data[]	NumPy array	Mengubah data larik atau <i>list</i> menjadi sebuah objek NumPy <i>array</i> .

#### 2.1.7.2 Pandas

Pandas (*Python for Data Analysis*) adalah pustaka dari Python yang digunakan untuk proses analisis data yang mencakup analisis, persiapan dan pembersihan data. Pandas juga menyediakan struktud data serta fungsi tingkat tinggi untuk membuat pekerjaan menyangkut data terstruktur seperti data tabular lebih cepat dan mudah. Tabel berikut merupakan rincian fungsi yang akan digunakan dari pustaka ini.

**Tabel 2.2** Daftar *method* yang digunakan dari pustaka Pandas

No.	Method	Masukan	Keluaran	Keterangan
1	read_excel	berkas .xlsx	-	Membaca berkas berekstensi .xlsx

### 2.1.7.3 Matplotlib

Matplotlib adalah pustaka dari Python yang digunakan untuk melakukan visualisasi data seperti membuat grafik. Tabel berikut merupakan rincian fungsi yang akan digunakan dari pustaka ini.

**Tabel 2.3** Daftar *method* yang digunakan dari pustaka Matplotlib

No.	Method	Masukan	Keluaran	Keterangan
1	pyplot.figure	-	-	Melakukan inisialisasi grafik yang akan diatur parameternya
2	pyplot.figure.set figwidth	int	-	Mengatur ukuran lebar grafik yang akan ditampilkan
3	pyplot.figure.set figheight	int	-	Mengatur ukuran tinggi grafik yang akan ditampilkan
4	pyplot.title	string	-	Mengatur judul dari grafik yang akan ditampilkan
5	pyplot.xlabel	string	-	Mengatur nama sumbu x dari grafik yang akan ditampilkan
6	pyplot.ylabel	string	-	Mengatur nama sumbu y dari grafik yang akan ditampilkan
7	plot	-	-	Membuat plot grafik dari data
8	pyplot.show	-	grafik	Menampilkan hasil data yang telah diplot

#### 2.1.7.4 Keras

Keras merupakan pustaka untuk NN tingkat tinggi yang ditulis dengan bahasa Python. Pustaka ini menyediakan fitur seperti membuat model, membuat lapisan dan menambahkannya pada struktur NN. Pustaka ini digunakan dengan fokus mempermudah pengembangan lebih dalam mengenai *deep learning*. Tabel berikut merupakan rincian fungsi yang akan digunakan dari pustaka ini.

**Tabel 2.4** Daftar *method* yang digunakan dari pustaka Keras

No.	Method	Masukan	Keluaran	Keterangan
1	models.Sequential	-	-	Melakukan inisialisasi model kosong bertipe <i>sequence</i> atau deret
2	layers.Conv1D	filter: int, kernel: int, activation: string, padding: string, kernel_initializer: string, bias_initializer: string	-	Membuat lapisan konvolusi untuk struktur CNN dengan konfigurasi ukuran filter, ukuran kernel, fungsi aktivasi yang akan digunakan serta dimensi ukuran data yang akan diproses.
3	layers.MaxPool1D	pool_size: int, padding: string	-	Membuat lapisan Max Pooling untuk struktur CNN.
4	layers.lstm	unit: int, activation: string, recurrent_activation: string, kernel_initializer: string, bias_initializer: string	-	Membuat lapisan LSTM yang akan menerima hasil masukan dari hasil proses lapisan sebelumnya yaitu CNN.

## BAB 2 LANDASAN TEORI

---

**Tabel 2.4** Daftar *method* yang digunakan dari pustaka Keras

No.	Method	Masukan	Keluaran	Keterangan
5	layers.dense	unit: int, activation: string, kernel_initializer: string, bias_initializer: string	-	Membuat lapisan <i>dense</i> yang akan menerima hasil masukan dari hasil proses lapisan sebelumnya yaitu LSTM dan memberikan hasil keluaran.
6	models.add	layer: object	-	Menambahkan lapisan yang telah dibuat sebelumnya untuk disusun menjadi sebuah arsitektur CNN-LSTM.
7	models.compile	loss: string, learning rate: float	-	Melakukan kompilasi model yang telah disusun dan menambahkan atribut <i>learning rate</i> dan pengukuran error yang digunakan (RMSE).
8	models.fit	trainX: int[], trainY: int[], epochs: int	-	Menjalankan proses NN dengan konfigurasi model yang telah dibuat dan memberikan data latih kepada model untuk proses pelatihan serta jumlah iterasi ( <i>epochs</i> ) pelatihan model.

**Tabel 2.4** Daftar *method* yang digunakan dari pustaka Keras

No.	Method	Masukan	Keluaran	Keterangan
9	models.to_json	model	model.json	Mengubah model menjadi bentuk json untuk disimpan.
10	models .save_weights	model	weights.h5	Menyimpan beban pada model.

#### 2.1.7.5 Tensorflow js

Tensorflow js merupakan pustaka untuk NN tingkat tinggi yang ditulis dengan bahasa Javascript. Pustaka ini menyediakan fitur seperti membuat model, membuat lapisan dan menambahkannya pada struktur NN. Pustaka ini digunakan dengan fokus mempermudah pengembangan lebih dalam mengenai *deep learning*. Tabel berikut merupakan rincian fungsi yang akan digunakan dari pustaka ini.

**Tabel 2.5** Daftar *method* yang digunakan dari pustaka Tensorflow js

No.	Method	Masukan	Keluaran	Keterangan
1	models .loadLayersModel	model.json	-	Memuat model dari berkas .json ke dalam aplikasi.
2	models.predict	testX: int[], testY: int[]	prediction: float	Memberikan data uji coba kepada model untuk dilakukan prediksi sesuai dengan hasil pelatihan model.

## 2.2 Tinjauan Studi

Pada bagian ini, akan dijelaskan mengenai perbandingan dari berbagai penelitian terkait dengan metode NN serta kombinasinya.

Terdapat beberapa metode yang memiliki ruang lingkup yang mirip dengan penelitian mengenai *time-series data forecasting* menggunakan NN. Tabel 2.6 merupakan ringkasan dari jurnal mengenai topik bersangkutan. Walaupun bidangnya berbeda, secara konsep dan teori penelitiannya tidak berbeda jauh karena penelitian yang diacu juga menggunakan dasar masalah mengenai prediksi untuk data *time-series* menggunakan NN.

**Tabel 2.6 State of the Art**

No	Peneliti	Judul	Metode	Hasil
1	S. Liu, H. Ji, and M. C. Wang (2020)	Nonpooling Convolutional Neural Network Forecasting for Seasonal Time Series with Trends	<i>Nonpooling CNN.</i>	Metode CNN tanpa menggunakan lapisan <i>Max Pooling</i> menghasilkan RMSE sebesar 5,450051351 jika dibandingkan dengan CNN dengan <i>Max Pooling</i> yaitu sebesar 7,315805427.
2	J. Cao, Z. Li, and J. Li (2019)	Financial Time Series Forecasting Model Based on CEEMDAN and LSTM	LSTM dengan <i>complete ensemble empirical mode decomposition with adaptive noise.</i>	LSTM sendiri memiliki RMSE yang relatif kecil yaitu 18,2321. Namun dengan adisi penambahan <i>complete ensemble empirical mode decomposition with adaptive noise</i> meningkatkan performa hingga mendapatkan nilai RMSE 4,8291.
3	I. E. Livieris, E. Pintelas, and P. Pintelas (2020)	A CNN-LSTM Model For Gold Price Time-series Forecasting	CNN-LSTM	Model CNN-LSTM menghasilkan nilai RMSE lebih kecil yaitu 0,00767 jika dibandingkan dengan model LSTM biasa yaitu 0,012273.

### 2.3 Tinjauan Objek

Pada bagian ini, akan dijelaskan objek yang terkait dengan prediksi pemakaian obat di rumah sakit serta terkait *dataset* yang digunakan secara singkat.

### 2.3.1 *Demand Forecasting*

*Demand* atau dalam bahasa Indonesia memiliki arti permintaan atau tuntutan. Permintaan adalah prinsip ekonomi untuk memenuhi kebutuhan dengan membeli barang atau jasa dan bersedia membayar harga yang telah ditetapkan. Dalam lingkup pembahasan rumah sakit, *demand* merupakan kebutuhan atas inventori alat kesehatan maupun obat [1]. Sesuai dengan [1], rumah sakit diberikan arahan untuk melakukan manajemen inventornya dengan melakukan perencanaan yang melihat pemakaian obat selama rentang waktu tertentu. Terdapat 3 metode utama untuk menghitung perencanaan obat pada rumah sakit [1], yaitu metode konsumsi, metode morbiditas dan metode *proxy consumption*.

#### 2.3.1.1 Metode Konsumsi

Metode ini didasarkan pada data konsumsi kesediaan farmasi dan sering dijadikan perkiraan yang paling telat dalam perencanaan sediaan farmasi [1]. Perhitungan metode ini didasarkan atas analisa data konsumsi/penggunaan obat di rumah sakit di periode sebelumnya, ditambahkan dengan stok penyanga, stok waktu tunggu dan sisa stok yang ada. Stok penyanga merupakan stok yang sengaja dilebihkan untuk kejadian-kejadian khusus seperti perubahan pola penyakit yang menyebabkan naiknya jumlah kunjungan. Jumlah stok penyanga sendiri bervariasi, namun biasanya menggunakan antara 10% sampai 20% dari kebutuhan keseluruhan [1]. Ada beberapa hal yang perlu diperhatikan untuk melakukan perhitungan berdasarkan metode konsumsi ini [1], antara lain:

1. Pengumpulan dan pengolahan data. Data yang perlu dipersiapkan untuk perhitungan metode konsumsi adalah sebagai berikut:
  - (a) Daftar nama obat
  - (b) Stok awal
  - (c) Penerimaan
  - (d) Pengeluaran
  - (e) Sisa stok
  - (f) Daftar obat hilang, rusak, kedaluarsa
  - (g) Kekosongan obat
  - (h) Pemakaian rata-rata obat satu periode
  - (i) Waktu tunggu sejak obat dipesan sampai diterima
  - (j) Stok penyanga
  - (k) Pola kunjungan
2. Analisis data untuk informasi dan evaluasi.
3. Perhitungan perkiraan kebutuhan obat.

4. Penyesuaian jumlah kebutuhan sediaan farmasi dengan alokasi dana.

Berdasarkan kriteria pada paragraf sebelumnya, maka dari itu akan dihasilkan rumus perhitungan penyediaan obat berdasarkan metode konsumsi seperti pada Persamaan 2.15 [1].

$$A = (B + C + D) - E \quad (2.15)$$

---

Keterangan :

- A : Rencana kebutuhan  
B : Pemakaian rata-rata 12 bulan terakhir  
C : Stok penyangga  
D : Stok waktu tunggu  
E : Sisa stok
- 

### 2.3.1.2 Metode Morbiditas

Metode morbiditas adalah metode perhitungan kebutuhan obat yang didasarkan kepada pola penyakit [1]. Metode ini memperkirakan keperluan obat-obat tertentu berdasarkan dari jumlah obat dan kejadian penyakit umum serta mempertimbangkan pola standar pengobatan untuk penyakit tertentu. Metode ini merupakan metode yang paling rumit dan lama dikarenakan sulitnya data morbiditas yang *valid* terhadap rangkaian penyakit tertentu. Berikut adalah langkah-langkah melakukan perhitungan kebutuhan dengan metode ini [1]:

1. Pengumpulan dan pengolahan data. Data yang perlu dipersiapkan untuk perhitungan metode morbiditas adalah sebagai berikut:
  - (a) Perkiraan jumlah populasi meliputi komposisi demografi dari populasi yang akan diklasifikasikan berdasarkan jenis kelamin untuk umur antara:
    - i. 0 sampai 4 tahun
    - ii. 4 sampai 14 tahun
    - iii. 15 sampai 44 tahun
    - iv. Diatas 45 tahun
  - v. Atau ditetapkan berdasarkan kelompok dewasa (diatas 12 tahun) dan anak (1 sampai 12 tahun)

- (b) Pola morbiditas penyakit, mencakup 2 hal berikut:
- Jenis penyakit pertahun untuk seluruh populasi pada kelompok umur yang ada.
  - Frekuensi kejadian masing-masing penyakit pertahun untuk seluruh populasi pada kelompok umur yang ada.
- (c) Standar pengobatan, merupakan obat yang masuk dalam rencana kebutuhan sesuai dengan standar pengobatan untuk penyakit tertentu pada rumah sakit.
2. Menghitung kebutuhan jumlah obat dengan cara jumlah kasus dikali dengan jumlah obat sesuai pendoman pengobatan dasar. Jumlah kebutuhan obat yang akan datang dihitung dengan mempertimbangkan pola penyakit, stok penyanga dan stok waktu tunggu.

Berikut adalah contoh penggunaan metode morbiditas untuk obat Sefiksim yang digunakan untuk pengobatan penyakit bronkitis kronis pada anak dan dewasa.

- Penggunaan untuk anak menggunakan dosis 50 sampai 100 mg untuk berat badan diatas 30 kg secara oral sirup 2 kali sehari. Terdapat 100 kasus anak dengan berat badan diatas 30 kg. Maka perhitungan kebutuhan akan menjadi seperti berikut:
  - Jumlah kasus: 100 kasus
  - Kebutuhan 1 anak diatas 30 kg untuk standar pengobatan 2 kali sehari selama 5 hari =  $(100 \text{ mg} \times 2 \times 5) = 1000 \text{ mg}$
  - Dalam 1 botol Sefiksim sirup 100 mg/5 ml kemasan botol 60 ml, mengandung =  $100 \text{ mg} / 5 \text{ ml} \times 60 \text{ ml} = 1200 \text{ mg Sefiksim}$
  - Maka jumlah Sefiksim yang diperlukan =  $1000 \text{ mg} / 1200 \text{ mg} \times 1 \text{ botol} = 0,8 \text{ botol}$  untuk setiap kasus.
  - Maka jumlah Sefiksim sirup yang dibutuhkan untuk 100 kasus anak diatas 30 kg adalah 80 botol.
- Penggunaan untuk dewasa menggunakan dosis 50 sampai 100 mg, 2 kali sehari selama 5 hari menggunakan pengobatan oral tablet. Terdapat 1200 kasus untuk kategori pasien dewasa. Maka perhitungan kebutuhan akan menjadi seperti berikut:
  - Jumlah kasus: 1200 kasus
  - Kebutuhan 1 anak diatas 30 kg untuk standar pengobatan 2 kali sehari selama 5 hari =  $(100 \text{ mg} \times 2 \times 5) = 1000 \text{ mg}$  atau sama dengan 10 tablet @ 100 mg.
  - Maka jumlah Sefiksim yang diperlukan =  $1200 \times 10 \text{ tablet} @ 10 \text{ mg} = 12000 \text{ tablet}$  untuk setiap kasus.
  - Maka jumlah Sefiksim tablet yang dibutuhkan untuk 1200 kasus dewasa

- adalah 12000 tablet @ 10 mg.
3. Maka dari itu, kebutuhan obat Sefiksim pada rumah sakit akan menjadi seperti berikut:
- (a) 80 botol Sefiksim sirup 60 ml
  - (b) 12000 Sefiksim tablet @10 mg

### 2.3.2 *Forecasting Horizon*

*Forecasting* atau dalam bahasa Indonesia memiliki arti peramalan merupakan proses membuat pernyataan mengenai sebuah kejadian yang dimana hasilnya belum dilakukan observasi atau estimasi terhadap kejadian yang belum terjadi [17]. Estimasi biasanya dilakukan dengan melihat data riwayat kejadian sebelumnya yang disusun berdasarkan waktu data *time-series*. Peramalan atau prediksi dapat dilakukan untuk rentang waktu tertentu, hal ini dinamakan *forecasting horizon*. Terdapat 2 jenis dari *forecasting horizon*, yaitu *short-term* (biasanya berkisar di bawah 3 bulan) dan *long-term* (biasanya berkisar tahunan atau lebih) [18].

Pada kasus rumah sakit, biasanya prediksi jarak pendek (*short-term forecasting horizon*) adalah untuk 1 bulan, sedangkan prediksi jarak panjang (*long-term forecasting horizon*) adalah 3 sampai 6 bulan ke depan [1]. Kisaran waktu ini merupakan kebijakan rumah sakit masing-masing, tetapi secara umum rumah sakit menggunakan kedua jarak waktu tersebut untuk melakukan prediksi pemakaian obat pada jarak pendek atau jarak panjang.

### 2.3.3 *Dataset*

Data yang dipakai pada penelitian ini adalah data riwayat pemakaian obat dari sebuah rumah sakit di Indonesia selama 1 tahun. Data ini diberikan oleh sebuah perusahaan Sistem Informasi Manajemen Rumah Sakit yang bertempat di Jakarta Selatan, Indonesia bernama Periksa.id. Perusahaan mengizinkan penulis untuk menggunakan data pemakaian obat tersebut dengan syarat penulis tidak memberi tahu rincian data terutama nama obat dan nama rumah sakit yang dijadikan contoh datanya. Data terbagi menjadi 2 bagian yaitu data penggunaan obat setiap hari selama 1 tahun pada tahun 2021 serta data penggunaan obat setiap hari selama 90 hari pada tahun 2022. Data ini memiliki ekstensi *Microsoft Excel Open XML Spreadsheet (.xlsx)*. Berikut adalah contoh data yang mewakili data pemakaian obat. Tabel 2.7 merupakan contoh 10 data pertama pada *dataset* yang akan digunakan. Sedangkan Gambar 2.13 merupakan gambaran keseluruhan data pada *dataset* pemakaian obat per hari selama setahun untuk tahun 2021 dan Gambar

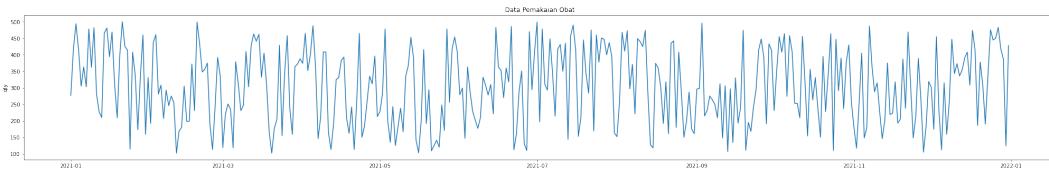
## BAB 2 LANDASAN TEORI

---

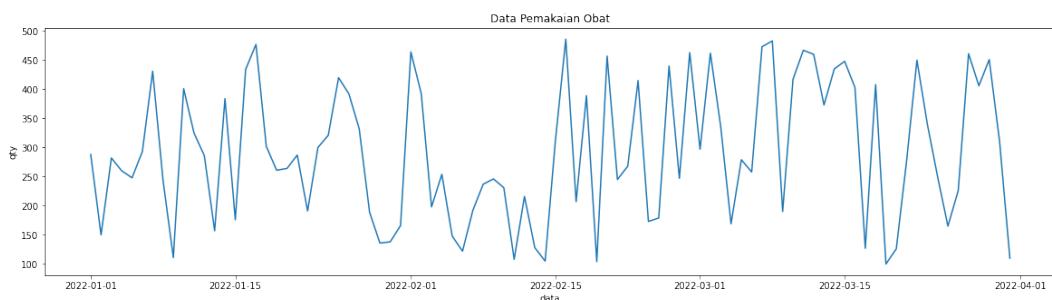
2.14 merupakan gambaran keseluruhan data pada *dataset* pemakaian obat per hari selama 90 hari untuk tahun 2022.

**Tabel 2.7** Contoh Data

No.	Tanggal	Qty
1	2021-01-01	277
2	2021-01-02	417
3	2021-01-03	494
4	2021-01-04	417
5	2021-01-05	305
6	2021-01-06	363
7	2021-01-07	303
8	2021-01-08	478
9	2021-01-09	362
10	2021-01-10	482



**Gambar 2.13** Data pemakaian obat per hari selama setahun untuk tahun 2021



**Gambar 2.14** Data pemakaian obat per hari selama 90 hari untuk tahun 2022

## BAB 3 ANALISIS DAN PERANCANGAN SISTEM

Bab ini memaparkan analisis masalah yang akan diatasi. Analisis masalah dilakukan dengan menjelaskan pendekatan dan alur kerja dari perangkat lunak yang dikembangkan, implementasi dari metode yang akan digunakan, dan hasil yang akan ditampilkan sistem.

### 3.1 Analisis Masalah

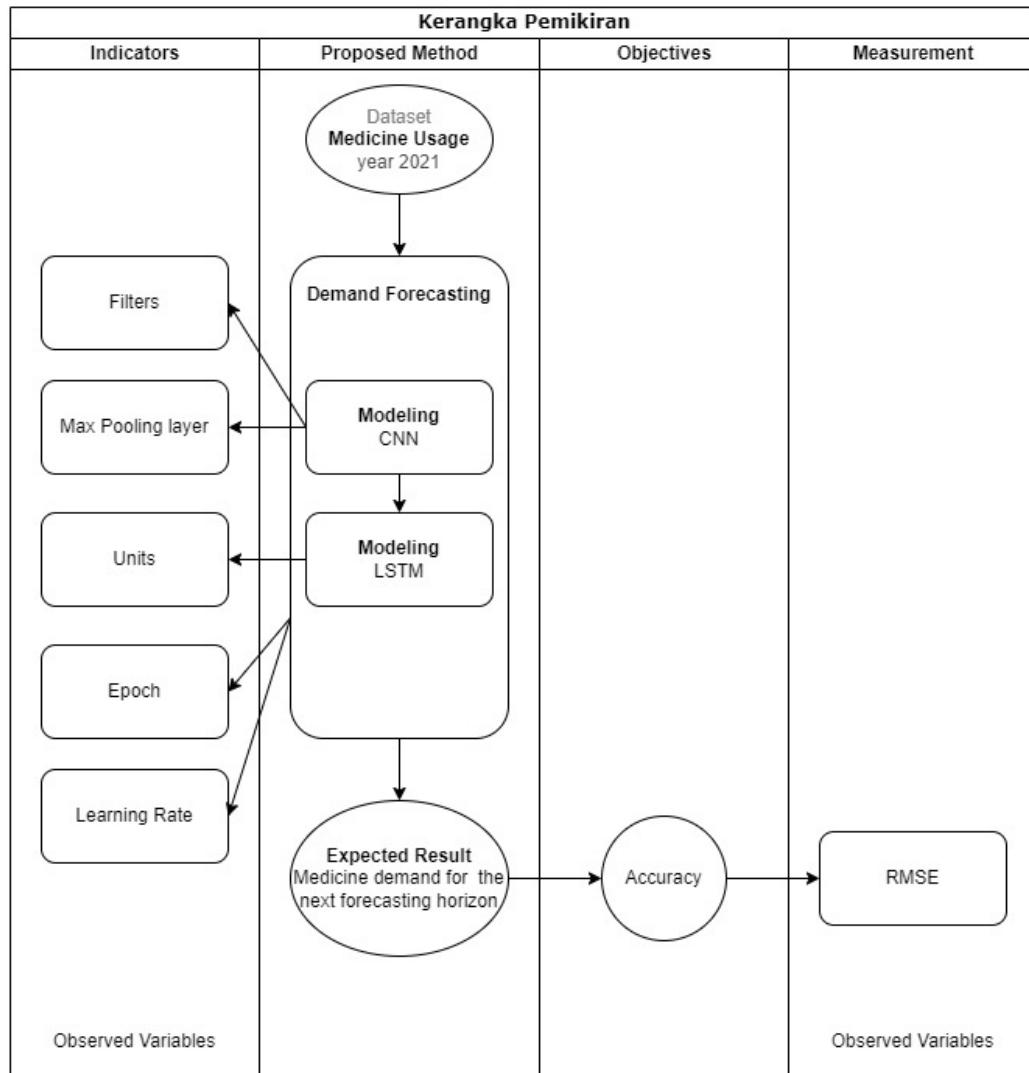
Pada bab 1 telah dijelaskan mengenai prediksi pemakaian obat pada rumah sakit merupakan hal yang penting dan sesuai dengan program JKN dari pemerintah. Pada penelitian ini, penulis menggunakan data pemakaian obat perhari di rumah sakit yang berada di Jakarta, Indonesia. Penerapan *Nonpooling CNN-LSTM* dilakukan untuk melakukan prediksi pemakaian obat di rumah sakit tersebut. Selain itu, penelitian ini juga akan membandingkan dengan model CNN-LSTM dengan lapisan *Max Pooling*.

Hasil perhitungan *Nonpooling CNN-LSTM* dan *CNN-LSTM* berupa prediksi titik data hari berikutnya selama  $n$  hari dari data masukan. Pertama data akan diproses melalui lapisan CNN terlebih dahulu untuk melakukan ekstraksi fitur-fitur penting dan mempelajari *short-term seasonality* sebelum diberikan kepada LSTM. Kemudian LSTM akan melakukan proses kembali untuk mempelajari *long-term seasonality* dari data yang nantinya akan diberikan ke *fully-connected layer* agar menghasilkan nilai keluaran sesuai  $n$  hari yang ingin diprediksi.

Masukan sistem prediksi merupakan data riwayat pemakaian obat di rumah sakit perhari selama 1 tahun kebelakang, sedangkan keluaran dari sistem akan menunjukkan berapa pemakaian di hari berikutnya selama  $n$  hari ke depan. Penelitian ini menentukan  $n$  hari ke depan adalah 30 hari (1 bulan) sebagai prediksi *short-term* dan 90 hari (3 bulan) sebagai prediksi *long-term*.

### 3.2 Kerangka Pemikiran

Gambar 3.1 adalah kerangka pemikiran dari metode yang diusulkan untuk melakukan prediksi pemakaian obat rumah sakit.



**Gambar 3.1** Kerangka Pemikiran

Berdasarkan Gambar 3.1, penelitian ini akan dimulai dengan membuat pemodelan CNN-LSTM dengan lapisan *Max Pooling* dan tanpa lapisan *Max Pooling* akan menggunakan data pemakaian obat selama 1 tahun pada tahun 2021. Pelatihan ini bertujuan melihat *error* pemodelan CNN-LSTM dengan dan tanpa lapisan *Max Pooling* dalam melakukan prediksi pemakaian untuk melihat kebutuhan obat pada rumah sakit. Berikut ini merupakan penjelasan setiap bagian pada Gambar 3.1.

1. *Indicators* adalah variabel yang akan memengaruhi hasil dari metode utama. Indikator dinilai pada saat pengujian CNN-LSTM dimulai. Indikator yang diobservasi selama penelitian ini antara lain sebagai berikut.

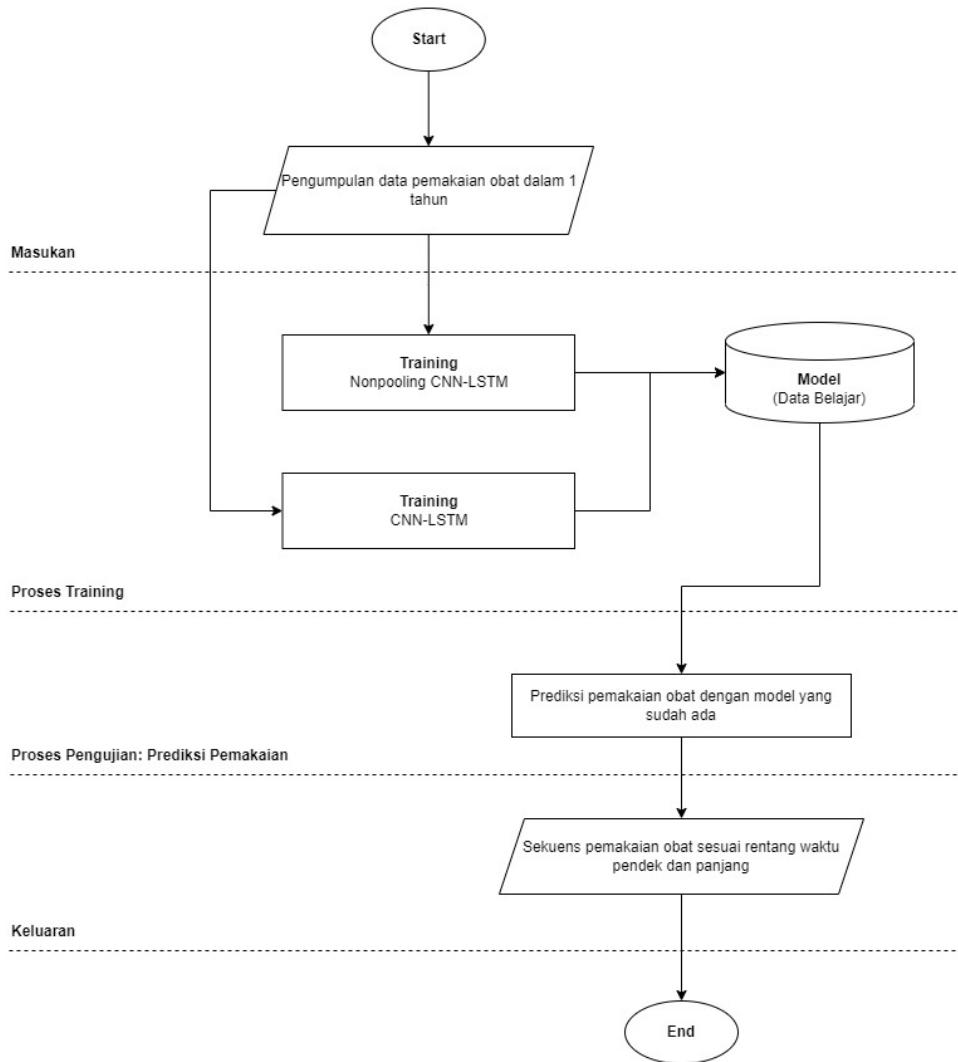
- (a) *Filters* merupakan banyak *feature map* yang akan dihasilkan dalam satu kali konvolusi pada *CNN* serta menentukan banyak *kernel* untuk memproses *feature map*. Seperti yang sudah dijelaskan pada bagian 2.1.2.1, *kernel* ini akan melakukan ekstraksi fitur. Maka, *kernel* yang semakin banyak akan menghasilkan fitur yang semakin banyak. Masing-masing operasi konvolusi menghasilkan *feature map* dua dimensi. Semakin banyak *filter* dalam satu *convolutional layer*, semakin banyak informasi atau fitur yang dapat diperoleh dari citra masukan. Namun, sama seperti jumlah konvolusi, jika jumlah *filter* terlalu banyak, model yang dibangun cenderung tidak mudah mencapai *generalization*. Karena itu, variabel ini diobservasi untuk menentukan berapa banyak *filter* yang tepat dengan kombinasi jumlah *filter* bagi arsitektur *CNN* yang dibangun untuk mendapatkan fitur.
- (b) *Max Pooling Layer* merupakan lapisan pada *CNN* yang berfungsi untuk mengambil nilai maksimum dari hasil convolusi dan akan menghasilkan lapisan baru dengan ukuran yang lebih kecil. Pengambilan nilai maksimum ini berdasarkan ukuran *kernel* yang telah ditentukan sebelumnya. Adanya lapisan ini dapat membuat pekerjaan lebih efisien, namun pada kasus data *time-series* hal ini dapat menyebabkan terjadinya kehilangan informasi. Karena itu, variabel ini diobservasi untuk menentukan pengaruh lapisan *Max Pooling* pada arsitektur CNN-LSTM.
- (c) *Units* merupakan konfigurasi jumlah *hidden neuron* yang akan dihitung pada arsitektur LSTM. Semakin banyak jumlah *units* akan mempengaruhi kepada banyaknya proses atau informasi yang dapat diproses oleh LSTM. Variabel ini akan diobservasi untuk menentukan jumlah *units* pada arsitektur CNN-LSTM.
- (d) *Epoch* merupakan jumlah iterasi selama proses pelatihan berlangsung. Nilai *epoch* yang optimal ditentukan berdasarkan hasil dari proses pelatihan. Variabel ini akan diobservasi untuk menetukan jumlah *epoch* pada arsitektur CNN-LSTM.
- (e) *Learning rate* merupakan seberapa besar nilai hasil pelatihan dari satu iterasi akan mempengaruhi hasil iterasi berikutnya. Variabel ini diobservasi untuk menentukan besar *learning rate* pada arsitektur CNN-LSTM
2. *Proposed Method* adalah bagian yang menjelaskan proses penelitian dari awal hingga akhir. Proses ini dimulai dengan membuat model CNN-LSTM dengan dan tanpa lapisan *Max Pooling* lalu diuji untuk memperoleh hasil prediksi

pemakaian obat dalam bentuk sekvens. Sekuens tersebut kemudian diuji untuk melihat nilai *error*.

3. *Objectives* adalah bagian yang menjelaskan target yang akan menjadi acuan pengukuran. Dalam penelitian ini, target tersebut adalah *error* dari estimasi sekvens pemakaian obat oleh model CNN-LSTM dengan dan tanpa lapisan *Max Pooling*.
4. *Measurement* adalah satuan ukur yang digunakan untuk mengukur hal-hal yang ada pada bagian *Objectives*. Dalam penelitian ini, digunakan metrik RMSE sebagai nilai evaluasi nilai *error* pemodelan CNN-LSTM dengan dan tanpa lapisan *Max Pooling*.

### 3.3 Analisis Urutan Proses Global

Penelitian ini akan menggunakan CNN-LSTM dengan dan tanpa lapisan *Max Pooling* untuk melakukan prediksi pemakaian obat. Setelah dilakukan pelatihan, diharapkan arsitektur yang dibangun dapat melakukan prediksi pemakaian obat dengan tepat. Hasil estimasi pemakaian obat kemudian akan diuji kembali dengan *dataset*. Gambar 3.2 menunjukkan urutan proses global pada penelitian ini dalam bentuk *flowchart*.



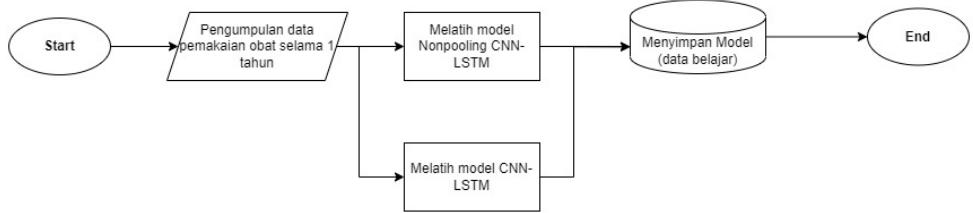
**Gambar 3.2** Flowchart urutan proses global

Sistem prediksi pemakaian obat terbagi atas 2 proses, yaitu proses pelatihan dan proses pengujian. Proses pelatihan dilakukan untuk mendapatkan model CNN-LSTM dengan dan tanpa lapisan *Max Pooling* yang optimal untuk menghasilkan *error* yang kecil. Proses pengujian dilakukan untuk mencari sekuens pemakaian obat sesuai dengan rentang waktu prediksi pendek dan panjang.

### 3.3.1 Proses Pelatihan

Pada penelitian ini, proses pelatihan model CNN-LSTM dengan dan tanpa lapisan *Max Pooling* digambarkan pada Gambar 3.3.

## BAB 3 ANALISIS DAN PERANCANGAN SISTEM

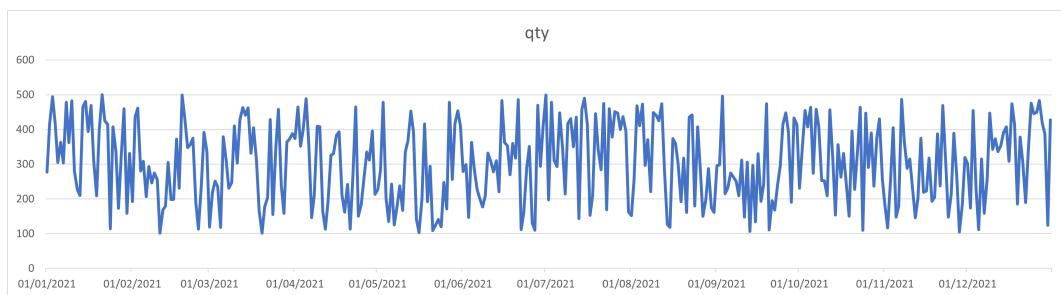


**Gambar 3.3** Flowchart pelatihan sistem prediksi pemakaian obat

Berikut adalah uraian proses pelatihan dari *flowchart* pada Gambar 3.3 yang dilakukan dalam penelitian ini.

1. Arsitektur CNN-LSTM dengan dan tanpa lapisan *Max Pooling* yang akan digunakan pada penelitian ini akan mempengaruhi proses pengujian. Data pertama akan diproses pada lapisan CNN untuk melakukan ekstraksi fitur dan *seasonality* jarak pendek yang nantinya akan diberikan secara utuh kepada lapisan LSTM karena tidak menggunakan lapisan *Max Pooling*. Kemudian lapisan LSTM akan mempelajari data kembali untuk nantinya dikeluarkan hasil prediksi berupa nilai pemakaian obat.
2. Sebagai masukan untuk model CNN-LSTM dengan dan tanpa lapisan *Max Pooling* yang dibangun, digunakan *dataset* larik 2 dimensi dimana dimensi pertama adalah waktu dan dimensi kedua adalah jumlah pemakaian obat. Gambar 3.4 adalah visualisasi dari data pemakaian obat selama 1 tahun di tahun 2021.

Proses pelatihan model CNN-LSTM dengan dan tanpa lapisan *Max Pooling* terdiri atas 2 proses pada masing-masing model, yaitu pada lapisan CNN dengan dan tanpa lapisan *Max Pooling* dan pada lapisan LSTM. Pada bagian berikutnya akan dijelaskan tahap pelatihan dengan CNN dan LSTM.



**Gambar 3.4** Gambaran *dataset* dengan keterangan sumbu x dan y

### 3.3.1.1 CNN-LSTM

Berikut ini adalah algoritme dalam proses CNN untuk menghasilkan fitur yang nantinya akan diberikan kepada lapisan LSTM. Proses ini akan dilakukan secara

berulang berdasarkan jumlah iterasi yang telah ditentukan. Algoritme 3.1 merupakan penjelasan secara umum bagaimana proses CNN-LSTM dilakukan.

---

### **ALGORITME 3.1 CNN-LSTM**

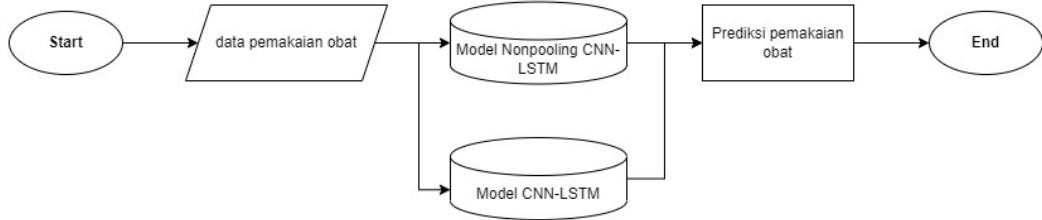
---

- 1: Masukan merupakan larik 2 dimensi dimana dimensi pertama adalah waktu dan dimensi kedua adalah jumlah, maka dari itu yang digunakan untuk pelatihan hanya merupakan larik dengan ukuran  $365 \times 1$ .
  - 2: Inisialisasi nilai *kernel*, *weight*, *bias*. Nilai *kernel* diinisialisasi untuk melakukan konvolusi pada *convolutional layer* dan pada lapisan *dense* untuk mengeluarkan nilai keluaran, sedangkan nilai *weight* dan *bias* untuk melakukan perhitungan pada lapisan LSTM. Nilai *kernel* dan *weight* diinisialisasikan dengan nilai acak terdistribusi normal sesuai dengan Persamaan 2.4. Sedangkan nilai *bias* pada tahap pertama akan menggunakan nilai *default* yaitu 0.
  - 3: Lakukan proses konvolusi pada setiap *convolutional layer*.
  - 4: Konvolusi akan dilakukan sebanyak 2 kali sesuai dengan arsitektur pada 2.11. Setiap sehabis dilakukan operasi konvolusi, akan dilakukan operasi pada lapisan *Max Pooling* yang akan mengurangi dimensi dari masukan. Jumlah lapisan *Max Pooling* akan disesuaikan yaitu 2 lapisan, 1 lapisan dan tanpa lapisan *Max Pooling* atau dapat juga disebut dengan *Nonpooling* CNN-LSTM.
  - 5: Proses akan dilanjutkan dengan memberikan nilai keluaran dari CNN kepada lapisan LSTM.
  - 6: Proses pada lapisan LSTM akan menggunakan fungsi aktivasi *tanh* dan ReLU seperti yang ada pada 2.1.4. Pada lapisan ini akan dihitung nilai dari *input gate*, *forget gate*, *cell state* dan *output gate*.
  - 7: Hitung hasil keluaran lapisan *dense* atau *fully connected layer* untuk menjadi nilai keluaran berupa prediksi pemakaian obat.
  - 8: Simpan model untuk digunakan pada saat pengujian.
- 

Pada langkah ke-4 di Algoritme 3.1, total lapisan Max Pooling akan dibagi menjadi 3 jenis arsitektur, yaitu arsitektur dengan 2 lapisan *Max Pooling* berarti setiap konvolusi selesai dilakukan akan dilakukan operasi *Max Pooling*, arsitektur dengan 1 lapisan *Max Pooling* berarti setelah 2 kali konvolusi akan dilakukan 1 kali operasi *Max Pooling* dan arsitektur tanpa lapisan *Max Pooling* atau *Nonpooling* CNN-LSTM berarti pada lapisan CNN hanya akan dilakukan operasi konvolusi saja tanpa melakukan operasi *Max Pooling*.

### 3.3.2 Proses Pengujian

Pada penelitian ini, proses pengujian model digambarkan pada Gambar 3.3.



**Gambar 3.5** Flowchart pengujian sistem prediksi pemakaian obat

Berikut ini adalah uraian proses pengujian dari *flowchart* pada Gambar 3.5 yang dilakukan dalam penelitian ini.

1. Masukan data pemakaian obat dengan ukuran  $365 \times 1$  yang akan dilakukan untuk prediksi sesuai dengan *forecasting window* pendek maupun panjang.
2. Ambil model dari CNN-LSTM dengan dan tanpa lapisan *Max Pooling* yang sudah dihasilkan pada proses pelatihan.
3. Gunakan model tersebut untuk melakukan prediksi pemakaian obat dari data uji. Model ini digunakan untuk melakukan proses konvolusi tanpa *Max Pooling* pada lapisan *Nonpooling CNN* serta proses konvolusi dengan *Max Pooling* pada CNN untuk mempelajari *seasonality* jangka pendek yang kemudian akan diberikan kepada lapisan LSTM yang nantinya akan menghasilkan hasil prediksi.

### 3.4 Analisis Manual

Pada bagian ini, dilakukan analisis tahapan proses yang akan dilakukan dalam sistem. Analisis dilakukan dengan contoh dan ilustrasi perhitungan manual. Analisis manual ini akan menggunakan data 5 hari untuk memprediksi 1 hari ke depan.

#### 3.4.1 Dataset

*Dataset* yang digunakan dalam penelitian ini adalah data pemakaian obat per hari selama 1 tahun pada tahun 2021 di sebuah rumah sakit yang berada di Jakarta, Indonesia. *Dataset* didapatkan dari sebuah perusahaan Sistem Informasi Menejemen Rumah Sakit yang berada di Jakarta, Indonesia dan diberikan secara anonimus baik untuk nama obat dan nama rumah sakit. Data pemakaian obat ini berbentuk dalam berkas .csv (*comma seperated value*) yang berisikan 365 baris tanggal selama tahun 2021 dan jumlah pemakaian obat sesuai tanggalnya. Visualisasi keseluruhan data terdapat pada Gambar 3.4.

### 3.4.2 *Nonpooling CNN-LSTM*

Berikut ini akan dijelaskan perhitungan untuk proses-proses yang dilalui dalam pembangunan model *Nonpooling CNN-LSTM* berdasarkan algoritme yang sudah dijabarkan pada bagian 3.3.1. Arsitektur ini terdiri atas 3 lapisan, yaitu lapisan *Nonpooling CNN*, lapisan LSTM dan lapisan *dense* atau *fully connected layer*.

#### 3.4.2.1 Perhitungan *Nonpooling CNN*

Masukan berupa larik 1 dimensi dengan ukuran  $365 \times 1$  akan dimasukan ke lapisan *Nonpooling CNN* terlebih dahulu. Contoh nilai larik terdapat pada tabel 3.1 memiliki ukuran  $5 \times 1$  dan akan digunakan untuk melakukan operasi konvolusi antara matriks dengan *kernel*. Pada penelitian ini, operasi konvolusi akan berjalan secara 1 arah ke samping dikarenakan data yang digunakan merupakan data *time-series* seperti yang telah dijelaskan pada 2.1.2.1

**Tabel 3.1** Contoh larik

277	417	494	417	305
-----	-----	-----	-----	-----

*Kernel* yang digunakan dalam penelitian ini berukuran  $30 \times 1$ , di mana 1 merupakan dimensi *height* dari larik masukan dan 30 merupakan dimensi *width* dari larik masukan agar proses konvolusi dapat melihat 30 nilai sekaligus. Dengan mengoperasikan nilai *kernel* kepada larik masukan, akan didapatkan sebuah *feature map* satu dimensi. Proses konvolusi bergerak secara satu dimensi, di mana pergerakan *kernel* adalah ke arah samping kanan. Nilai *kernel* pada contoh perhitungan ini berukuran  $2 \times 1$ . Nilai awal *kernel* dalam contoh perhitungan manual dan yang digunakan dalam penelitian didapatkan dengan inisialisasi awal acak terdistribusi normal sesuai dengan Persamaan 2.4, dengan nilai *mean* = 0 dan standar deviasi = 0,5. Contoh *kernel* tersebut dapat dilihat pada tabel 3.2.

**Tabel 3.2** Contoh nilai *kernel*  $2 \times 1$

0.1044	0.030146
--------	----------

Perhitungan untuk sel [0, 0], sel [1,0], dan sel-sel selanjutnya memiliki pola yang sama yang dapat dilihat pada Persamaan 2.5. Perhitungan dilakukan hingga mencapai sel [x, y] yang berada pada ujung kanan bawah larik masukan. Hasil perkalian konvolusi  $w \times x$  disebut sebagai *feature map*. Proses perkalian dilakukan menggunakan *stride* (pergerakan indeks larik) bernilai 1. Sebelum dilakukan perhitungan, larik masukan akan diberikan *padding* terlebih dahulu. Hal ini

bertujuan agar larik hasil konvolusi memiliki panjang yang sama dengan larik masukan. Nilai *padding* yang akan digunakan adalah nilai 0. Maka dari itu larik yang akan dilakukan operasi konvolusi menjadi seperti dibawah ini.

**Tabel 3.3** Contoh larik

277	417	494	417	305	0
-----	-----	-----	-----	-----	---

Hasil perhitungan operasi konvolusi yang dilakukan merupakan konvolusi 1 dimensi seperti ilustrasi di Gambar 2.4 yang hasil perhitungannya sesuai dengan Persamaan 2.5 dan Persamaan 2.1. Nilai *bias* yang digunakan adalah 0. Hasil konvolusi antara larik dan *kernel* pada contoh kasus sel [0, 0] adalah sebagai berikut.

$$\begin{aligned}
 v_k &= (w_{k0,0}x_{0,0} + b_{0,0}) + (w_{k1,0}x_{1,0} + b_{1,0}) \\
 &= (277 * 0.1044 + 0) + (417 * 0.030146 + 0) \\
 &= 41.489682
 \end{aligned}$$

Setelah konvolusi selesai dilakukan, didapatkan *feature map* berukuran  $5 \times 1$  seperti pada Tabel 3.4. Ukuran *feature map* dapat berubah bergantung pada *kernel* yang digunakan dan *stride* yang dipakai pada lapisan konvolusi. Jumlah *filter* akan berpengaruh kepada jumlah *feature map* yang dihasilkan. Jika *filter* yang digunakan berjumlah 32 pada satu lapisan konvolusi, maka akan dihasilkan 32 *feature map*. Jumlah *filter* yang digunakan bergantung kepada arsitektur yang dipakai. Tabel 3.4 merupakan *feature map* hasil konvolusi yang menggunakan 1 *filter*.

**Tabel 3.4** Contoh *feature map* hasil konvolusi

41.489682	58.426924	64.144482	52.72933	42.784998
-----------	-----------	-----------	----------	-----------

Karena lapisan pertama merupakan lapisan *Nonpooling CNN*, maka *feature map* yang telah dihasilkan tidak akan dilakukan perhitungan *Max Pooling*. Maka dari itu nilai yang ada dalam *feature map* tersebut akan dimasukan ke dalam lapisan

LSTM yang akan dijelaskan lebih lanjut pada bagian 3.4.2.2.

### 3.4.2.2 Perhitungan LSTM

Setelah dilakukan perhitungan pada lapisan *Nonpooling* CNN dan menghasilkan *feature map*, langkah berikutnya adalah melakukan perhitungan pada lapisan LSTM. Seperti yang telah dibahas sebelumnya pada Bagian 2.1.4, lapisan ini akan menghitung *input gate*, *forget gate*, *cell state* dan *output gate*. Langkah pertama adalah melakukan inisialisasi nilai bobot dan bias untuk *input gate*, *forget gate*, *cell* dan *output gate*. Inisialisasi ini menggunakan *gausial distribution* dengan *mean* = 0 dan *std* = 0,5. Sesuai pada Bagian 2.1.4, masing-masing *gate* memiliki 2 bobot dan 1 bias, maka dari itu terdapat 8 bobot dan 4 bias yang harus diinisialisasikan terlebih dahulu. Berikut adalah inisialisasi dari masing-masing *gate*. Perhitungan akan menggunakan fungsi aktivasi ReLU dan *tanh* seperti yang sudah dibahas pada bagian 2.1.3. Fungsi aktivasi ReLU akan digunakan diterapkan pada perhitungan *gate* sedangkan fungsi aktivasi *tanh* akan diterapkan pada perhitungan *candidate state* dan nilai keluaran.

1. Inisialisasi nilai bobot dan *bias* pada *input gate*.

$$W_u = \begin{bmatrix} -0.64220 & -0.13910 & 0.42470 & -0.74550 & -0.89280 \\ 0.15150 & 0.21010 & 0.58110 & -0.020940 & -0.32080 \\ 0.25550 & 0.020920 & -0.20380 & -0.31210 & 0.28700 \\ 0.80000 & -0.56660 & -0.13470 & -0.83260 & -0.52940 \\ 0.53240 & 0.077130 & -0.14730 & 0.83840 & -0.19260 \end{bmatrix}$$

$$R_u = \begin{bmatrix} -0.33270 & -1.2440 & 0.26770 & -0.20980 & 0.074580 \\ 0.47430 & -0.0030220 & 0.62060 & 0.21340 & 0.026960 \\ 0.66820 & 0.19730 & -0.35240 & 0.34950 & 0.0025130 \\ 0.26230 & 0.63160 & 0.40020 & -0.19910 & 0.89960 \\ -0.84100 & 0.30370 & 0.69530 & -0.36870 & 0.25060 \end{bmatrix}$$

$$b_u = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

2. Inisialisasi nilai bobot dan *bias* pada *candidate state*.

$$W_{\bar{h}} = \begin{bmatrix} -0.042160 & -0.40840 & -0.32040 & -0.29200 & -0.74820 \\ 0.32400 & 0.58910 & 0.25840 & 0.51780 & 0.60620 \\ -0.22980 & -0.23720 & -0.62320 & 0.49310 & 0.24230 \\ 0.50480 & -1.0130 & -0.71360 & 0.33950 & -0.61370 \\ -0.39210 & 0.12640 & -0.022060 & 0.80220 & 0.036120 \end{bmatrix}$$

$$R_{\bar{h}} = \begin{bmatrix} -0.40520 & 0.16320 & 0.21780 & -0.0071840 & 0.41630 \\ 0.70990 & 1.5030 & 0.34580 & -0.0048140 & -0.71000 \\ -0.65940 & 0.17790 & 0.36630 & 0.12870 & 0.39480 \\ 0.60180 & -0.13430 & -0.39560 & -0.67070 & -0.97020 \\ 0.0018580 & 0.60030 & -0.37040 & -0.49820 & -0.73800 \end{bmatrix}$$

$$b_h = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

3. Inisialisasi nilai bobot dan *bias* pada *forget gate*.

$$W_f = \begin{bmatrix} -0.33390 & -0.055780 & 0.060340 & 0.17870 & -0.19800 \\ 0.35340 & -0.56940 & -0.41500 & 0.45970 & -0.51810 \\ -0.21700 & -0.56380 & 1.0630 & 0.22850 & -0.16080 \\ -0.18710 & -0.35190 & 0.17220 & -0.55190 & 0.37890 \\ -1.0690 & 0.10680 & 0.12700 & 0.008233 & -0.39140 \end{bmatrix}$$

$$R_f = \begin{bmatrix} 0.0056150 & -0.44130 & 0.88370 & 0.65300 & 0.17920 \\ 0.45240 & 0.93330 & 0.41220 & 0.48090 & -0.28720 \\ 0.18380 & -0.20220 & -0.64060 & -0.64900 & -0.26450 \\ -0.65270 & -0.22710 & -0.17060 & -0.086930 & -0.71810 \\ 0.57990 & 0.33270 & -0.41020 & -0.69790 & -0.11650 \end{bmatrix}$$

$$b_f = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

4. Inisialisasi nilai bobot dan *bias* pada *output gate*.

$$W_o = \begin{bmatrix} -0.48530 & -0.042330 & -0.49050 & -0.22460 & -0.18820 \\ 0.063690 & -0.23460 & 0.16280 & 0.53000 & -0.15680 \\ 1.0220 & 0.74460 & 0.012930 & 0.40940 & -0.21790 \\ -0.045900 & -0.087540 & 0.16220 & 1.2770 & -0.87750 \\ 0.011170 & -0.83700 & -0.19930 & -0.86200 & -0.82720 \end{bmatrix}$$

$$R_o = \begin{bmatrix} 0.52350 & -0.69080 & 0.47550 & 0.31400 & -0.28620 \\ 0.56460 & 0.63700 & 0.22930 & 0.15670 & -0.20780 \\ 0.13610 & -0.35800 & -0.16660 & 0.16340 & 0.074710 \\ 0.19950 & 0.66100 & -0.020360 & -0.38690 & -0.59090 \\ 0.023970 & 0.31670 & 0.72550 & 0.50990 & -0.015850 \end{bmatrix}$$

$$b_o = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

5. Inisialisasi nilai pada *cell state* dan *candidate state* untuk  $t$  ke-0.

$$y_0 = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} \quad c_0 = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

Setelah melakukan inisialisasi, tahap berikutnya adalah melakukan perhitungan untuk masing-masing *gate*. Tahapan di bawah ini merupakan contoh perhitungan

untuk masing-masing *gate* hingga menjadi nilai akhir.

1. Perhitungan *input gate* sesuai dengan Persamaan 2.9.

$$f_u[1] = \begin{bmatrix} -0.64220 & -0.13910 & 0.42470 & -0.74550 & -0.89280 \\ 0.15150 & 0.21010 & 0.58110 & -0.020940 & -0.32080 \\ 0.25550 & 0.020920 & -0.20380 & -0.31210 & 0.28700 \\ 0.80000 & -0.56660 & -0.13470 & -0.83260 & -0.52940 \\ 0.53240 & 0.07710 & -0.14730 & 0.83840 & -0.19260 \end{bmatrix} \odot \begin{bmatrix} 41.489682 \\ 58.426924 \\ 64.144482 \\ 52.72933 \\ 42.784998 \end{bmatrix} + \begin{bmatrix} -0.33270 & -1.2440 & 0.26770 & -0.20980 & 0.074580 \\ 0.47430 & -0.0030220 & 0.62060 & 0.21340 & 0.026960 \\ 0.66820 & 0.19730 & -0.35240 & 0.34950 & 0.0025130 \\ 0.26230 & 0.63160 & 0.40020 & -0.19910 & 0.89960 \\ -0.84100 & 0.30370 & 0.69530 & -0.36870 & 0.25060 \end{bmatrix} \odot \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

Dari perhitungan di atas, diperoleh matriks untuk *input gate* seperti berikut:

$$f_u[1] = f \begin{pmatrix} -85.03785 \\ 41.00596 \\ -5.42726 \\ -75.10602 \\ 53.11321 \end{pmatrix}$$

Berikut adalah hasil perhitungan *input gate* yang telah diterapkan fungsi aktivasi ReLU:

$$f_u[1] = \begin{pmatrix} 0 \\ 41.00596 \\ 0 \\ 0 \\ 53.11321 \end{pmatrix}$$

2. Perhitungan *candidate state* sesuai dengan Persamaan 2.10.

$$f_{\bar{h}}[1] = \begin{bmatrix} -0.042160 & -0.40840 & -0.32040 & -0.29200 & -0.74820 \\ 0.32400 & 0.58910 & 0.25840 & 0.51780 & 0.60620 \\ -0.22980 & -0.23720 & -0.62320 & 0.49310 & 0.24230 \\ 0.50480 & -1.0130 & -0.71360 & 0.33950 & -0.61370 \\ -0.39210 & 0.12640 & -0.022060 & 0.80220 & 0.036120 \end{bmatrix} \odot \begin{bmatrix} 41.489682 \\ 58.426924 \\ 64.144482 \\ 52.72933 \\ 42.784998 \end{bmatrix} + \begin{bmatrix} -0.40520 & 0.16320 & 0.21780 & -0.0071840 & 0.41630 \\ 0.70990 & 1.5030 & 0.34580 & -0.0048140 & -0.71000 \\ -0.65940 & 0.17790 & 0.36630 & 0.12870 & 0.39480 \\ 0.60180 & -0.13430 & -0.39560 & -0.67070 & -0.97020 \\ 0.0018580 & 0.60030 & -0.37040 & -0.49820 & -0.73800 \end{bmatrix} \odot \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

Dari perhitungan di atas, diperoleh matriks untuk *candidate state* seperti berikut:

$$f_{\bar{h}}[1] = g_1 \begin{pmatrix} -93.57135 \\ 117.67640 \\ -27.00039 \\ -92.37153 \\ 33.54689 \end{pmatrix}$$

Berikut adalah hasil perhitungan *candidate state* yang telah diterapkan fungsi aktivasi *tanh*:

$$f_{\bar{h}}[1] = \begin{bmatrix} -1 \\ 1 \\ -1 \\ -1 \\ 1 \end{bmatrix}$$

3. Perhitungan *forget gate* sesuai dengan Persamaan 2.11.

$$f_f[1] = \begin{bmatrix} -0.33390 & -0.055780 & 0.060340 & 0.17870 & -0.19800 \\ 0.35340 & -0.56940 & -0.41500 & 0.45970 & -0.51810 \\ -0.21700 & -0.56380 & 1.0630 & 0.22850 & -0.16080 \\ -0.18710 & -0.35190 & 0.17220 & -0.55190 & 0.37890 \\ -1.0690 & 0.10680 & 0.12700 & 0.008233 & -0.39140 \end{bmatrix} \odot \begin{bmatrix} 41.489682 \\ 58.426924 \\ 64.144482 \\ 52.72933 \\ 42.784998 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

$$\begin{bmatrix} 0.0056150 & -0.44130 & 0.88370 & 0.65300 & 0.17920 \\ 0.45240 & 0.93330 & 0.41220 & 0.48090 & -0.28720 \\ 0.18380 & -0.20220 & -0.64060 & -0.64900 & -0.26450 \\ -0.65270 & -0.22710 & -0.17060 & -0.086930 & -0.71810 \\ 0.57990 & 0.33270 & -0.41020 & -0.69790 & -0.11650 \end{bmatrix} \odot \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

Dari perhitungan di atas, diperoleh matriks untuk *forget gate* seperti berikut:

$$f_f[1] = f \begin{pmatrix} -12.29067 \\ -43.15303 \\ 31.41004 \\ -30.16755 \\ -46.27805 \end{pmatrix}$$

Berikut adalah hasil perhitungan *forget gate* yang telah diterapkan fungsi aktivasi ReLU:

$$f_f[1] = \begin{bmatrix} 0 \\ 0 \\ 31.41004 \\ 0 \\ 0 \end{bmatrix}$$

4. Perhitungan *cell state* sesuai dengan Persamaan 2.12.

$$h[1] = \begin{bmatrix} 0 \\ 41.00596 \\ 0 \\ 0 \\ 53.11321 \end{bmatrix} \odot \begin{bmatrix} -1 \\ 1 \\ -1 \\ -1 \\ 1 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} \odot \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

Dari perhitungan di atas, diperoleh matriks untuk *cell state* seperti berikut:

$$h[1] = \begin{bmatrix} 0 \\ -41.01 \\ 0 \\ 0 \\ -53.11 \end{bmatrix}$$

5. Perhitungan *output gate* sesuai dengan Persamaan 2.13.

$$f_o[1] = \begin{bmatrix} -0.48530 & -0.042330 & -0.49050 & -0.22460 & -0.18820 \\ 0.063690 & -0.23460 & 0.16280 & 0.53000 & -0.15680 \\ 1.0220 & 0.74460 & 0.012930 & 0.40940 & -0.21790 \\ -0.045900 & -0.087540 & 0.16220 & 1.2770 & -0.87750 \\ 0.011170 & -0.83700 & -0.19930 & -0.86200 & -0.82720 \end{bmatrix} \odot \begin{bmatrix} 41.489682 \\ 58.426924 \\ 64.144482 \\ 52.72933 \\ 42.784998 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

$$\begin{bmatrix} 0.52350 & -0.69080 & 0.47550 & 0.31400 & -0.28620 \\ 0.56460 & 0.63700 & 0.22930 & 0.15670 & -0.20780 \\ 0.13610 & -0.35800 & -0.16660 & 0.16340 & 0.074710 \\ 0.19950 & 0.66100 & -0.020360 & -0.38690 & -0.59090 \\ 0.023970 & 0.31670 & 0.72550 & 0.50990 & -0.015850 \end{bmatrix} \odot \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

Dari perhitungan di atas, diperoleh matriks untuk *output gate* seperti berikut:

$$f_o[1] = f \begin{pmatrix} -73.96616 \\ 20.61610 \\ 101.44409 \\ 33.17668 \\ -142.06832 \end{pmatrix}$$

Berikut adalah hasil perhitungan *output gate* yang telah diterapkan fungsi aktivasi ReLU:

$$f_o[1] = \begin{bmatrix} 0 \\ 20.6161 \\ 101.44409 \\ 33.17668 \\ 0 \end{bmatrix}$$

Hasil dari perhitungan untuk *output gate* dan *cell state* akan digunakan untuk mendapatkan nilai keluaran sesuai dengan Persamaan 2.14.

$$y[1] = \begin{bmatrix} 0 \\ 20.6161 \\ 101.44409 \\ 33.17668 \\ 0 \end{bmatrix} \odot g_2 \begin{pmatrix} 0 \\ -41.01 \\ 0 \\ 0 \\ -53.11 \end{pmatrix}$$

Dari perhitungan di atas, diperoleh matriks untuk nilai keluaran seperti berikut:

$$y[1] = \begin{bmatrix} 0 \\ 20.6161 \\ 101.44409 \\ 33.17668 \\ 0 \end{bmatrix}$$

### 3.4.2.3 Perhitungan Dense

Setelah dilakukan perhitungan pada lapisan LSTM, langkah berikutnya adalah melakukan perhitungan pada lapisan *dense* atau *fully connected layer*. Hal ini bertujuan untuk menghubungkan seluruh *neuron* yang ada untuk menghasilkan nilai keluaran.

Pada lapisan *dense*, akan dilakukan perhitungan sesuai dengan Persamaan 2.6. Ukuran *kernel* pada contoh perhitungan manual ini adalah  $5 \times 1$  yang dihasilkan dari nilai acak terdistribusi normal sesuai dengan Persamaan 2.4. Contoh nilai *kernel* untuk lapisan *dense* dapat dilihat pada tabel 3.5 berikut. Contoh nilai *kernel* yang digunakan adalah sebagai berikut.

**Tabel 3.5** Contoh *kernel* pada lapisan *dense*

0.298860	0.22722	-0.869150	1.13740	-0.542370
----------	---------	-----------	---------	-----------

Perhitungan pada lapisan ini dapat dilihat sebagai berikut. Hasil keluaran dari lapisan LSTM akan dilakukan perhitungan *dot product* dengan *kernel*. Fungsi aktivasi yang digunakan pada lapisan *dense* ini adalah ReLU seperti pada Bagian 2.1.3.1. Hasil dari lapisan *dense* berikut merupakan prediksi pemakaian obat di hari keenam berdasarkan data 5 hari yang dipelajari.

$$\begin{aligned}
 y &= f(W^T x + b) \\
 &= f( \\
 &\quad (0.298860 * 0) + (0.227220 * 20.6161) + \\
 &\quad (-0.869150 * 101.44409) + (1.13740 * 33.17668) + \\
 &\quad (-0.542370 * 0) \\
 &\quad ) \\
 &= f(91.5011695) \\
 &= 91.5011695
 \end{aligned}$$

### 3.4.3 CNN-LSTM

Berikut ini akan dijelaskan perhitungan untuk proses-proses yang dilalui dalam pembangunan model CNN-LSTM berdasarkan algoritme yang sudah dijabarkan pada bagian 3.3.1. Arsitektur ini terdiri atas 3 lapisan, yaitu lapisan CNN, lapisan LSTM dan lapisan *dense* atau *fully connected layer*. Pada bagian ini, akan digunakan konfigurasi yang sama seperti pada Bagian 3.4.2 namun yang membedakan adalah adanya perhitungan pada lapisan Max Pooling pada CNN.

#### 3.4.3.1 Perhitungan CNN

Masukan berupa larik 1 dimensi dengan ukuran  $365 \times 1$  akan dimasukan ke lapisan *Nonpooling* CNN terlebih dahulu. Contoh nilai larik terdapat pada tabel 3.6 memiliki ukuran  $5 \times 1$  dan akan digunakan untuk melakukan operasi konvolusi antara matriks dengan *kernel*. Pada penelitian ini, operasi konvolusi akan berjalan secara 1 arah ke samping dikarenakan data yang digunakan merupakan data *time-series* seperti yang telah dijelaskan pada 2.1.2.1

**Tabel 3.6** Contoh larik

277	417	494	417	305
-----	-----	-----	-----	-----

*Kernel* yang digunakan dalam penelitian ini berukuran  $30 \times 1$ , di mana 1 merupakan dimensi *height* dari larik masukan dan 30 merupakan dimensi *width* dari larik masukan agar proses konvolusi dapat melihat 30 nilai sekaligus. Dengan mengoperasikan nilai *kernel* kepada larik masukan, akan didapatkan sebuah *feature map* satu dimensi. Proses konvolusi bergerak secara satu dimensi, di mana pergerakan *kernel* adalah ke arah samping kanan. Nilai *kernel* pada contoh

perhitungan ini berukuran  $2 \times 1$ . Nilai awal *kernel* dalam contoh perhitungan manual dan yang digunakan dalam penelitian didapatkan dengan inisialisasi awal acak terdistribusi normal sesuai dengan Persamaan 2.4, dengan nilai *mean* = 0 dan standar deviasi = 0,5. Contoh *kernel* pada tabel 3.7 merupakan konfigurasi *kernel* yang sama dengan pada tabel 3.2.

**Tabel 3.7** Contoh nilai *kernel*  $2 \times 1$

0.1044	0.030146
--------	----------

Perhitungan untuk sel [0, 0], sel [1,0], dan sel-sel selanjutnya memiliki pola yang sama yang dapat dilihat pada Persamaan 2.5. Perhitungan dilakukan hingga mencapai sel [x, y] yang berada pada ujung kanan bawah larik masukan. Hasil perkalian konvolusi  $w \times x$  disebut sebagai *feature map*. Proses perkalian dilakukan menggunakan *stride* (pergerakan indeks larik) bernilai 1. Sebelum dilakukan perhitungan, larik masukan akan diberikan *padding* terlebih dahulu. Hal ini bertujuan agar larik hasil konvolusi memiliki panjang yang sama dengan larik masukan. Nilai *padding* yang akan digunakan adalah nilai 0. Maka dari itu larik yang akan dilakukan operasi konvolusi menjadi seperti dibawah ini.

**Tabel 3.8** Contoh larik

277	417	494	417	305	0
-----	-----	-----	-----	-----	---

Hasil perhitungan operasi konvolusi yang dilakukan merupakan konvolusi 1 dimensi seperti ilustrasi di Gambar 2.4 yang hasil perhitungannya sesuai dengan Persamaan 2.5 dan Persamaan 2.1. Nilai *bias* yang digunakan adalah 0. Hasil konvolusi antara larik dan *kernel* pada contoh kasus sel [0, 0] adalah sebagai berikut.

$$\begin{aligned}
 v_k &= (w_{k0,0}x_{0,0} + b_{0,0}) + (w_{k1,0}x_{1,0} + b_{1,0}) \\
 &= (277 * 0.1044 + 0) + (417 * 0.030146 + 0) \\
 &= 41.489682
 \end{aligned}$$

Setelah konvolusi selesai dilakukan, didapatkan *feature map* berukuran  $5 \times 1$  seperti pada Tabel 3.9. Ukuran *feature map* dapat berubah bergantung pada *kernel*

yang digunakan dan *stride* yang dipakai pada lapisan konvolusi. Jumlah *filter* akan berpengaruh kepada jumlah *feature map* yang dihasilkan. Jika *filter* yang digunakan berjumlah 32 pada satu lapisan konvolusi, maka akan dihasilkan 32 *feature map*. Jumlah *filter* yang digunakan bergantung kepada arsitektur yang dipakai. Tabel 3.9 merupakan *feature map* hasil konvolusi yang menggunakan 1 *filter*.

**Tabel 3.9** Contoh *feature map* hasil konvolusi

41.489682	58.426924	64.144482	52.72933	42.784998
-----------	-----------	-----------	----------	-----------

Setelah melakukan konvolusi, langkah berikutnya adalah melakukan operasi *Max Pooling* seperti yang ada pada Bagian 2.1.2.2 Untuk contoh analisis manual ini, parameter *spatial extent* yang akan digunakan adalah 2 dengan *stride* adalah 1. Operasi akan dimulai dari sel [0,0] dan [1,0] kemudian bergerak 1 sel ke [1,0] dan [2,0] dan seterusnya hingga mencapai keseluruhan data. Setiap operasinya akan mencari nilai maksimum dari 2 nilai yang dibandingkan. Tabel 3.10 merupakan hasil dari operasi pada lapisan *Max Pooling*.

**Tabel 3.10** Contoh *feature map* hasil konvolusi

58.426924	64.144482	64.144482	52.72933
-----------	-----------	-----------	----------

Terlihat pada tabel 3.10, jumlah panjang data berkurang menjadi 4 data. Langkah berikutnya adalah memberikan nilai hasil *Max Pooling* ke dalam lapisan LSTM yang akan dijelaskan lebih lanjut pada bagian 3.4.3.2.

#### 3.4.3.2 Perhitungan LSTM

Setelah dilakukan perhitungan pada lapisan CNN dan menghasilkan *feature map*, langkah berikutnya adalah melakukan perhitungan pada lapisan LSTM. Seperti yang telah dibahas sebelumnya pada Bagian 2.1.4, lapisan ini akan menghitung *input gate*, *forget gate*, *cell state* dan *output gate*. Langkah pertama adalah melakukan inisialisasi nilai bobot dan bias untuk *input gate*, *forget gate*, *cell* dan *output gate*. Inisialisasi ini menggunakan *gausial distribution* dengan *mean* = 0 dan *std* = 0,5. Sesuai pada Bagian 2.1.4, masing-masing *gate* memiliki 2 bobot dan 1 bias, maka dari itu terdapat 8 bobot dan 4 bias yang harus diinisialisasikan terlebih dahulu. Berikut adalah inisialisasi dari masing-masing *gate*. Perhitungan akan menggunakan fungsi aktivasi ReLU dan *tanh* seperti yang sudah dibahas

pada bagian 2.1.3. Fungsi aktivasi ReLU akan digunakan diterapkan pada perhitungan *gate* sedangkan fungsi aktivasi *tanh* akan diterapkan pada perhitungan *candidate state* dan nilai keluaran.

1. Inisialisasi nilai bobot dan *bias* pada *input gate*.

$$W_u = \begin{bmatrix} -0.64220 & -0.13910 & 0.42470 & -0.74550 \\ 0.15150 & 0.21010 & 0.58110 & -0.020940 \\ 0.25550 & 0.020920 & -0.20380 & -0.31210 \\ 0.80000 & -0.56660 & -0.13470 & -0.83260 \end{bmatrix}$$

$$R_u = \begin{bmatrix} -0.33270 & -1.2440 & 0.26770 & -0.20980 \\ 0.47430 & -0.0030220 & 0.62060 & 0.21340 \\ 0.66820 & 0.19730 & -0.35240 & 0.34950 \\ 0.26230 & 0.63160 & 0.40020 & -0.19910 \end{bmatrix}$$

$$b_u = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

2. Inisialisasi nilai bobot dan *bias* pada *candidate state*.

$$W_{\bar{h}} = \begin{bmatrix} -0.042160 & -0.40840 & -0.32040 & -0.29200 \\ 0.32400 & 0.58910 & 0.25840 & 0.51780 \\ -0.22980 & -0.23720 & -0.62320 & 0.49310 \\ 0.50480 & -1.0130 & -0.71360 & 0.33950 \end{bmatrix}$$

$$R_{\bar{h}} = \begin{bmatrix} -0.40520 & 0.16320 & 0.21780 & -0.0071840 \\ 0.70990 & 1.5030 & 0.34580 & -0.0048140 \\ -0.65940 & 0.17790 & 0.36630 & 0.12870 \\ 0.60180 & -0.13430 & -0.39560 & -0.67070 \end{bmatrix}$$

$$b_h = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

3. Inisialisasi nilai bobot dan *bias* pada *forget gate*.

$$W_f = \begin{bmatrix} -0.33390 & -0.055780 & 0.060340 & 0.17870 \\ 0.35340 & -0.56940 & -0.41500 & 0.45970 \\ -0.21700 & -0.56380 & 1.0630 & 0.22850 \\ -0.18710 & -0.35190 & 0.17220 & -0.55190 \end{bmatrix}$$

$$R_f = \begin{bmatrix} 0.0056150 & -0.44130 & 0.88370 & 0.65300 \\ 0.45240 & 0.93330 & 0.41220 & 0.48090 \\ 0.18380 & -0.20220 & -0.64060 & -0.64900 \\ -0.65270 & -0.22710 & -0.17060 & -0.086930 \end{bmatrix}$$

$$b_f = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

4. Inisialisasi nilai bobot dan *bias* pada *output gate*.

$$W_o = \begin{bmatrix} -0.48530 & -0.042330 & -0.49050 & -0.22460 \\ 0.063690 & -0.23460 & 0.16280 & 0.53000 \\ 1.0220 & 0.74460 & 0.012930 & 0.40940 \\ -0.045900 & -0.087540 & 0.16220 & 1.2770 \end{bmatrix}$$

$$R_o = \begin{bmatrix} 0.52350 & -0.69080 & 0.47550 & 0.31400 \\ 0.56460 & 0.63700 & 0.22930 & 0.15670 \\ 0.13610 & -0.35800 & -0.16660 & 0.16340 \\ 0.19950 & 0.66100 & -0.020360 & -0.38690 \end{bmatrix}$$

$$b_o = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

5. Inisialisasi nilai pada *cell state* dan *candidate state* untuk  $t$  ke-0.

$$y_0 = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} \quad c_0 = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

Setelah melakukan inisialisasi, tahap berikutnya adalah melakukan perhitungan untuk masing-masing *gate*. Tahapan di bawah ini merupakan contoh perhitungan untuk masing-masing *gate* hingga menjadi nilai akhir.

1. Perhitungan *input gate* sesuai dengan Persamaan 2.9.

$$f_u[1] = \begin{bmatrix} -0.64220 & -0.13910 & 0.42470 & -0.74550 \\ 0.15150 & 0.21010 & 0.58110 & -0.020940 \\ 0.25550 & 0.020920 & -0.20380 & -0.31210 \\ 0.80000 & -0.56660 & -0.13470 & -0.83260 \end{bmatrix} \odot \begin{bmatrix} 58.426924 \\ 64.144482 \\ 64.144482 \\ 52.72933 \end{bmatrix} + \begin{bmatrix} -0.33270 & -1.2440 & 0.26770 & -0.20980 \\ 0.47430 & -0.0030220 & 0.62060 & 0.21340 \\ 0.66820 & 0.19730 & -0.35240 & 0.34950 \\ 0.26230 & 0.63160 & 0.40020 & -0.19910 \end{bmatrix} \odot \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

Dari perhitungan di atas, diperoleh matriks untuk *input gate* seperti berikut:

$$f_u[1] = f \left( \begin{bmatrix} -58.51182205 \\ 58.49864097 \\ -13.25948768 \\ -42.14542618 \end{bmatrix} \right)$$

Berikut adalah hasil perhitungan *input gate* yang telah diterapkan fungsi aktivasi ReLU:

$$f_u[1] = \begin{bmatrix} 0 \\ 58.49864097 \\ 0 \\ 0 \end{bmatrix}$$

2. Perhitungan *candidate state* sesuai dengan Persamaan 2.10.

$$f_{\bar{h}}[1] = \begin{bmatrix} -0.042160 & -0.40840 & -0.32040 & -0.29200 \\ 0.32400 & 0.58910 & 0.25840 & 0.51780 \\ -0.22980 & -0.23720 & -0.62320 & 0.49310 \\ 0.50480 & -1.0130 & -0.71360 & 0.33950 \end{bmatrix} \odot \begin{bmatrix} 58.426924 \\ 64.144482 \\ 64.144482 \\ 52.72933 \end{bmatrix} + \begin{bmatrix} -0.40520 & 0.16320 & 0.21780 & -0.0071840 \\ 0.70990 & 1.5030 & 0.34580 & -0.0048140 \\ -0.65940 & 0.17790 & 0.36630 & 0.12870 \\ 0.60180 & -0.13430 & -0.39560 & -0.67070 \end{bmatrix} \odot \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

Dari perhitungan di atas, diperoleh matriks untuk *candidate state* seperti berikut:

$$f_{\tilde{h}}[1] = g_1 \begin{pmatrix} -64.60874196 \\ 100.5960189 \\ -42.61558683 \\ -63.35634385 \end{pmatrix}$$

Berikut adalah hasil perhitungan *candidate state* yang telah diterapkan fungsi aktivasi *tanh*:

$$f_{\tilde{h}}[1] = \begin{bmatrix} -1 \\ 1 \\ -1 \\ -1 \end{bmatrix}$$

3. Perhitungan *forget gate* sesuai dengan Persamaan 2.11.

$$f_f[1] = \begin{bmatrix} -0.33390 & -0.055780 & 0.060340 & 0.17870 \\ 0.35340 & -0.56940 & -0.41500 & 0.45970 \\ -0.21700 & -0.56380 & 1.0630 & 0.22850 \\ -0.18710 & -0.35190 & 0.17220 & -0.55190 \end{bmatrix} \odot \begin{bmatrix} 58.426924 \\ 64.144482 \\ 64.144482 \\ 52.72933 \end{bmatrix} + \begin{bmatrix} 0.0056150 & -0.44130 & 0.88370 & 0.65300 \\ 0.45240 & 0.93330 & 0.41220 & 0.48090 \\ 0.18380 & -0.20220 & -0.64060 & -0.64900 \\ -0.65270 & -0.22710 & -0.17060 & -0.086930 \end{bmatrix} \odot \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

Dari perhitungan di atas, diperoleh matriks untuk *forget gate* seperti berikut:

$$f_f[1] = f \left( \begin{bmatrix} -9.793519815 \\ -18.25608014 \\ 31.39093481 \\ -51.55975812 \end{bmatrix} \right)$$

Berikut adalah hasil perhitungan *forget gate* yang telah diterapkan fungsi aktivasi ReLU:

$$f_f[1] = \begin{bmatrix} 0 \\ 0 \\ 31.39093481 \\ 0 \end{bmatrix}$$

4. Perhitungan *cell state* sesuai dengan Persamaan 2.12.

$$h[1] = \begin{bmatrix} 0 \\ 58.49864097 \\ 0 \\ 0 \end{bmatrix} \odot \begin{bmatrix} -1 \\ 1 \\ -1 \\ -1 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \\ 31.39093481 \\ 0 \end{bmatrix} \odot \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

Dari perhitungan di atas, diperoleh matriks untuk *cell state* seperti berikut:

$$h[1] = \begin{bmatrix} 0 \\ -117.00 \\ 0 \\ 0 \end{bmatrix}$$

5. Perhitungan *output gate* sesuai dengan Persamaan 2.13.

$$f_o[1] = \begin{bmatrix} -0.48530 & -0.042330 & -0.49050 & -0.22460 \\ 0.063690 & -0.23460 & 0.16280 & 0.53000 \\ 1.0220 & 0.74460 & 0.012930 & 0.40940 \\ -0.045900 & -0.087540 & 0.16220 & 1.2770 \end{bmatrix} \odot \begin{bmatrix} 58.426924 \\ 64.144482 \\ 64.144482 \\ 52.72933 \end{bmatrix} + \begin{bmatrix} 0.52350 & -0.69080 & 0.47550 & 0.31400 \\ 0.56460 & 0.63700 & 0.22930 & 0.15670 \\ 0.13610 & -0.35800 & -0.16660 & 0.16340 \\ 0.19950 & 0.66100 & -0.020360 & -0.38690 \end{bmatrix} \odot \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

Dari perhitungan di atas, diperoleh matriks untuk *output gate* seperti berikut:

$$f_o[1] = f \left( \begin{bmatrix} -65.91403031 \\ 27.32478805 \\ 108.3239185 \\ 70.72052006 \end{bmatrix} \right)$$

Berikut adalah hasil perhitungan *output gate* yang telah diterapkan fungsi aktivasi ReLU:

$$f_o[1] = \begin{bmatrix} 0 \\ 27.32478805 \\ 108.3239185 \\ 70.72052006 \end{bmatrix}$$

Hasil dari perhitungan untuk *output gate* dan *cell state* akan digunakan untuk mendapatkan nilai keluaran sesuai dengan Persamaan 2.14.

$$y[1] = \begin{bmatrix} 0 \\ 27.32478805 \\ 108.3239185 \\ 70.72052006 \end{bmatrix} \odot g_2 \left( \begin{bmatrix} 0 \\ -117.00 \\ 0 \\ 0 \end{bmatrix} \right)$$

Dari perhitungan di atas, diperoleh matriks untuk nilai keluaran seperti berikut:

$$y[1] = \begin{bmatrix} 0 \\ -54.65 \\ -216.65 \\ -141.44 \end{bmatrix}$$

### 3.4.3.3 Perhitungan Dense

Setelah dilakukan perhitungan pada lapisan LSTM, langkah berikutnya adalah melakukan perhitungan pada lapisan *dense* atau *fully connected layer*. Hal ini bertujuan untuk menghubungkan seluruh *neuron* yang ada untuk menghasilkan nilai keluaran.

Pada lapisan *dense*, akan dilakukan perhitungan sesuai dengan Persamaan 2.6. Ukuran *kernel* pada contoh perhitungan manual ini adalah  $4 \times 1$  yang dihasilkan dari nilai acak terdistribusi normal sesuai dengan Persamaan 2.4. Contoh nilai *kernel* untuk lapisan *dense* dapat dilihat pada tabel 3.11 berikut. Contoh nilai

*kernel* yang digunakan adalah sebagai berikut.

**Tabel 3.11** Contoh *kernel* pada lapisan *dense*

0.298860	0.22722	-0.869150	1.13740
----------	---------	-----------	---------

Perhitungan pada lapisan ini dapat dilihat sebagai berikut. Hasil keluaran dari lapisan LSTM akan dilakukan perhitungan *dot product* dengan *kernel*. Fungsi aktivasi yang digunakan pada lapisan *dense* ini adalah ReLU seperti pada Bagian 2.1.3.1. Hasil dari lapisan *dense* berikut merupakan prediksi pemakaian obat di hari keenam berdasarkan data 5 hari yang dipelajari.

$$\begin{aligned}
 y &= f(W^T x + b) \\
 &= f( \\
 &\quad (0.298860 * 0) + (0.227220 * -54.65) + \\
 &\quad (-0.869150 * -216.65) + (1.13740 * -141.44) \\
 &\quad ) \\
 &= f(15.00695176) \\
 &= 15.00695176
 \end{aligned}$$

#### 3.4.4 Root Mean Squared Error (RMSE)

Bagian ini merupakan perhitungan *error* dari hasil prediksi model CNN-LSTM yang menggunakan ataupun tanpa lapisan *Max Pooling*. Perhitungan *error* yang digunakan adalah *Root Mean Squared Error* (RMSE) dengan cara menghitung rata-rata selisih antara hasil prediksi dengan data asli, dikuadratkan lalu diakarkan. Pada Bagian 3.4.1, data hari keenam adalah 363, maka hasil prediksi akan dibandingkan dengan nilai tersebut. Berikut ini adalah perhitungan RMSE untuk model *Nonpooling CNN-LSTM*.

### BAB 3 ANALISIS DAN PERANCANGAN SISTEM

---

$$\begin{aligned}RMSE_{Nonpool} &= \sqrt{\sum_{i=1}^n \left( \frac{y_i - \bar{y}_i}{n} \right)^2} \\&= \sqrt{\left( \frac{363 - 91.5011695}{1} \right)^2} \\&= 271.4988305\end{aligned}$$

Sedangkan perhitungan di bawah ini merupakan perhitungan RMSE untuk model CNN-LSTM.

$$\begin{aligned}RMSE_{CNN-LSTM} &= \sqrt{\sum_{i=1}^n \left( \frac{y_i - \bar{y}_i}{n} \right)^2} \\&= \sqrt{\left( \frac{363 - 15.00695176}{1} \right)^2} \\&= 347.99304824\end{aligned}$$

## BAB 4 IMPLEMENTASI DAN PENGUJIAN

Bab ini menjelaskan proses implementasi dan pengujian terhadap sistem yang telah dibangun berdasarkan penjelasan pada bab sebelumnya. Hal yang akan dibahas adalah lingkungan implementasi sistem, implementasi perangkat lunak, implementasi aplikasi, proses dan hasil pengujian sistem, serta analisis kesalahan.

### 4.1 Lingkungan Implementasi

Bagian ini membahas perangkat yang digunakan dalam proses pembangunan sistem. Perangkat yang digunakan terdiri dari perangkat keras dan perangkat lunak.

#### 4.1.1 Spesifikasi Perangkat Keras

Penelitian ini dibangun dengan menggunakan *personal computer* (PC) sebagai perangkat keras utama. Spesifikasi perangkat keras utama yang digunakan dalam pembangunan aplikasi adalah sebagai berikut.

1. *Motherboard* MSI B460M Pro.
2. *Processor* Intel Core i5-10400F CPU @ 2.9GHz.
3. *Solid State Drive* kapasitas 512GB.
4. RAM dengan kapasitas 32GB.
5. GPU NVIDIA GeForce RTX 3060 VRAM 12GB, 1.78 GHz, 3584 CUDA Cores.

#### 4.1.2 Lingkungan Perangkat Lunak

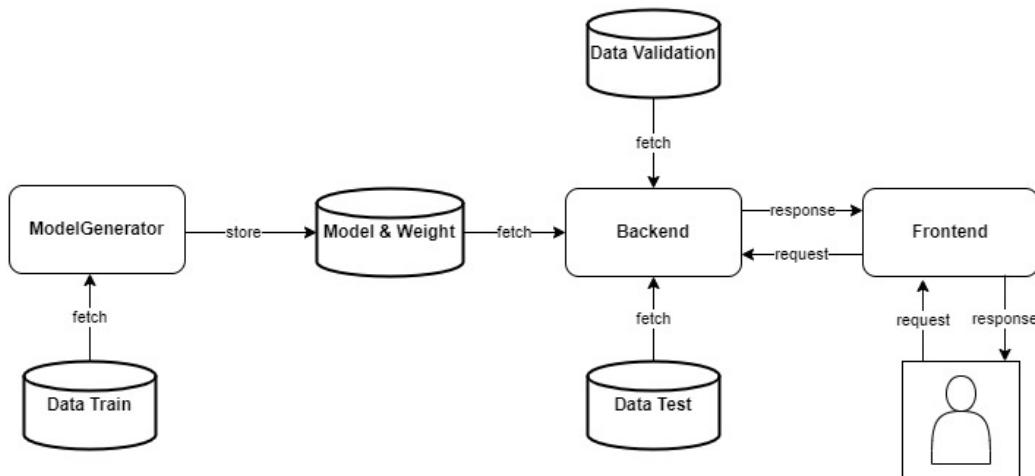
Lingkungan perangkat lunak yang digunakan dalam pembangunan aplikasi adalah sebagai berikut.

1. Sistem Operasi Windows 11 Home 64 bit.
2. Framework: Tensorflow (v2.8.0), Tensorflowjs (v3.14.0), cuDNN (v8.1), CUDA (v11.2), Microsoft Visual Studio 2022, Node js (v16.14.0), Angular (v13.1.1).
3. *Development Tools*: Jupyter Notebook (v6.4.5), Visual Studio Code (v1.65.2).

### 4.2 Implementasi Perangkat Lunak

Bagian ini membahas implementasi perangkat lunak dari sistem. Implementasi perangkat lunak pada penelitian ini menggunakan 3 jenis bahasa pemrograman yaitu, *Python*, *TypeScript* dan *Angular*. Bahasa pemrograman *Python* digunakan untuk membangun dan melatih model pembelajaran mesin lalu menyimpannya ke

dalam berkas .json serta bebannya dalam berkas .bin. Pada penelitian ini, *project* yang menggunakan bahasa pemrograman *Python* akan disimpan dalam bentuk *folder* bernama *ModelGenerator*. Bahasa pemrograman *TypeScript* digunakan untuk memuat model yang telah dilatih serta memproses masukan dari *form* tampilan, kemudian memberikan hasil berupa larik hasil prediksi model serta nilai minimum, maksimum dan *error*. Pada penelitian ini, *project* yang menggunakan bahasa pemrograman *TypeScript* akan disimpan dalam bentuk *folder* bernama *Backend*. Bahasa pemrograman *Angular* digunakan untuk membangun tampilan yang berisikan *form* masukan, grafik serta penjelasan singkat dari grafik. Pada penelitian ini, *project* yang menggunakan bahasa pemrograman *Angular* akan disimpan dalam bentuk *folder* bernama *Frontend*. Gambar 4.1 merupakan gambaran dari arsitektur perangkat lunak yang menggunakan 3 bahasa pemrograman.



Gambar 4.1 Arsitektur Diagram Implementasi Perangkat Lunak

### 4.2.1 Daftar *Project* dan *Method*

Masing-masing dari *project* memiliki *method* tersendiri yang digunakan untuk memproses bagiannya. Berikut adalah rincian *method* yang digunakan pada setiap *project*.

#### 4.2.1.1 *ModelGenerator*

*Project ModelGenerator* berfungsi membangun, melatih dan menyimpan model. Tabel 4.1 menunjukkan daftar *method* yang digunakan dalam *project ModelGenerator*.

**Tabel 4.1** Daftar *method* pada *project ModelGenerator*

No.	Method	Masukan	Keluaran	Keterangan
1	build_model	filter: int[] units: int maxPool: int	Membangun model CNN-LSTM	Membangun model dengan lapisan CNN dan LSTM yang mengikuti konfigurasi sesuai nilai masukan.
2	train_model	model epoch: int X_train: int[] Y_train: int[] lr: float	model	Melatih model dengan data latih sesuai konfigurasi yang telah ditentukan.
3	save_model	model folder_name: string model_name: string weight_name: string	model.json, weight.h5	Melakukan penyimpanan model hasil pelatihan serta bobotnya.
4	convert_model	model folder_name: string model_name: string weight_name: string	model.json, weight.bin	Melakukan penyimpanan model untuk mengikuti standar yang bisa dibaca oleh pustaka tensorflowjs.
5	all_process	n_filter: int[][] units: int[] epoch: int[] maxPool: int[] lr: float[] X_train: int[] Y_train: int[]	-	Melakukan semua proses pembangunan model, pelatihan, pengujian dan penyimpanan sesuai gabungan kombinasi dari konfigurasi masukan.

#### 4.2.1.2 Backend

*Project Backend* merupakan bagian yang akan memproses prediksi dengan menggunakan model yang telah disimpan dari hasil pelatihan. Tabel 4.2

## BAB 4 IMPLEMENTASI DAN PENGUJIAN

---

menunjukkan daftar *method* yang digunakan dalam *project Backend*.

**Tabel 4.2** Daftar *method* pada *project Backend*

No.	Method	Masukan	Keluaran	Keterangan
1	existsSync	path: string	boolean	Melakukan pengecekan sebuah <i>path</i> apakah ada atau tidak ada.
2	loadLayersModel	path: string	-	Memuat model dari <i>path</i> berkas .json ke dalam variabel.
3	mkdirSync	path: string	folder	Membuat direktori baru berdasarkan masukan.
4	createWriteStream	path: string	file	Membuat berkas baru yang akan ditulis nantinya.
5	readFileSync	path: string	file	Memuat berkas berdasarkan <i>path</i> masukan.
6	rmse	total: int n: int	rmse: float	Menghitung nilai <i>error</i> RMSE dari total selisih hasil prediksi dengan data asli yang dibagi dengan jumlah data kemudian dikuadratkan lalu diakarkan kembali.
7	getPredictions	epoch: int learningRate: int filter: int[] units: int maxPool: int data: int[] validation: int[] range: int	actual: int[] result: int[] rmse: int	Melakukan prediksi menggunakan model yang telah dimuat.

#### **4.2.1.3 Frontend**

*Project Frontend* merupakan bagian yang akan memproses tampilan berdasarkan hasil respon pemberian aplikasi. Tabel 4.3 menunjukkan daftar *method* yang digunakan dalam *project Frontend*.

**Tabel 4.3** Daftar *method* pada *project Frontend*

No.	Method	Masukan	Keluaran	Keterangan
1	calculateData	epoch: int learningRate: int filter: int[] units: int maxPool: int data: int[] validation: int[] range: int	actual: int[] result: int[] rmse: int	Memproses masukan dari tampilan dan memberikannya kepada kelas <i>Backend</i> untuk diproses dan mengembalikan nilai keluaran untuk nantinya diproses pada tampilan.
2	subscribe	-	-	Memulai proses pada method calculateData sebelumnya dan menunggu hingga proses tersebut selesai dan mendapatkan nilai keluaran dari <i>Backend</i> .

**Tabel 4.3** Daftar *method* pada *class* Frontend

No.	Method	Masukan	Keluaran	Keterangan
3	handleSubmit	-	chartData: obj rmse: float minActual: int maxActual: int minPredict: float maxPredict: float	Menghubungkan masukan form masukan yang terdapat di tampilan ke class <i>backend</i> untuk mendapatkan chartData yang berupa hasil respon dari class <i>backend</i> , mencari nilai maksimum dan minimum dari data asli serta data hasil prediksi serta menampilkan grafik yang berisikan data asli dan data hasil prediksi serta informasi tambahan di bawah grafik.
4	detectChanges	-	-	Memeriksa jika adanya perubahan yang terjadi pada data yang akan diproses menjadi grafik sehingga aplikasi dapat mengetahui jika terdapat perubahan data dan melakukan pemetaan ulang data baru tersebut ke grafik pada tampilan.

#### 4.2.2 Penggunaan *Development Tools*

Pada penelitian ini, ada 2 jenis *development tools* yang digunakan, yaitu Jupiter Notebook dan Visual Studio Code. Jupiter Notebook dan Visual Studio Code akan diakses secara *local*. Jupiter Notebook sendiri akan digunakan untuk melakukan pembangunan serta pelatihan model yang nantinya akan disimpan untuk dimuat pada aplikasi. Sedangkan Visual Studio Code akan digunakan untuk membangun *backend* dan *frontend* aplikasi. Pemilikan akses *development tools* secara *local* ini

dikarenakan spesifikasi perangkat yang digunakan di *local* cukup memenuhi untuk melakukan proses pelatihan.

### 4.2.3 Implementasi Penggunaan *Dataset*

Seperti yang sudah dijelaskan pada bagian 3.4.1, *dataset* untuk penelitian ini diambil dari sebuah perusahaan Sistem Informasi Manejemen Rumah Sakit (SIMRS) yang ada di Jakarta, Indonesia. Data yang akan digunakan untuk membangun model merupakan data pemakaian obat pada rumah sakit tertentu selama tahun 2021. Pembagian data latih dan data pengujian sebagai berikut, data pengujian berupa data 30 hari terakhir pada tahun 2021, selain itu akan digunakan untuk pelatihan. Data akan dilakukan pembagian kembali terlebih dahulu di awal setiap 30 hari dengan bergeser 1 harinya kemudian dimasukan ke dalam larik 2 dimensi. Kemudian hasil prediksi dari model akan dibandingkan dengan data pemakaian obat 90 hari pertama tahun 2022 untuk dihitung errornya dalam bentuk RMSE.

**Tabel 4.4** Perincian Penggunaan *Dataset* untuk Implementasi

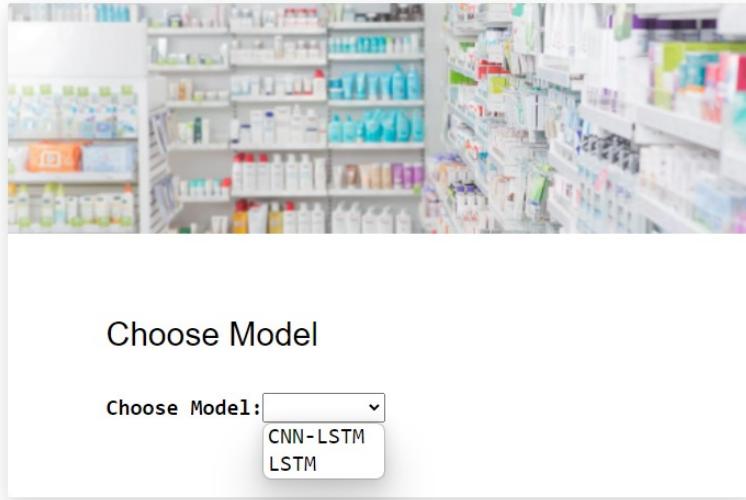
No	Dataset	Total Data	Pembagian Data	
			Pelatihan	Pengujian
1	Pemakaian Obat A tahun 2021	365	335	30
2	Pemakaian Obat A tahun 2022	90	-	-

### 4.3 Implementasi Aplikasi

Bagian ini menjelaskan sisi aplikasi dan tampilan yang digunakan untuk mempermudah akses terhadap pengguna aplikasi. Tampilan dibuat untuk proses pengujian, dimana pengguna dapat memilih rentang waktu prediksi yang ingin dilakukan, kemudian aplikasi akan menampilkan tampilan berupa grafik membandingkan hasil prediksi dengan data asli. Berikut adalah rincian dari implementasi pada aplikasi dan tampilan.

1. Gambar 4.2 merupakan tampilan awal ketika aplikasi diakses oleh pengguna. Pada halaman ini, pengguna diminta untuk memilih terlebih dahulu model apa yang hendak digunakan untuk melakukan prediksi. Pada tampilan akan tersedia 2 jenis model, yaitu CNN-LSTM dan LSTM.

## BAB 4 IMPLEMENTASI DAN PENGUJIAN



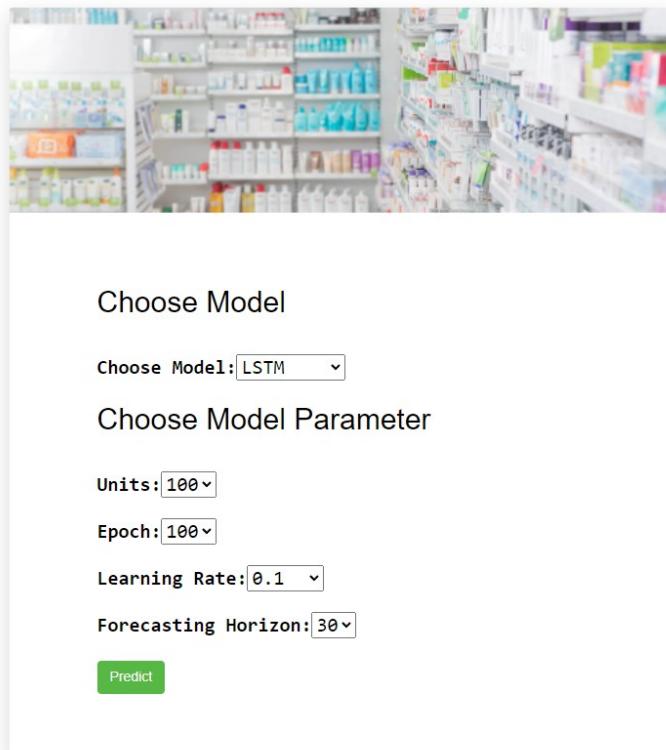
**Gambar 4.2** Tampilan awal aplikasi

2. Gambar 4.3 merupakan tampilan ketika model CNN-LSTM dipilih oleh pengguna. Pada halaman ini, pengguna diminta untuk memasukkan kombinasi dari arsitektur yang akan digunakan untuk memprediksi yaitu *filter*, *units*, *epoch*, *learning rate*, jumlah lapisan *Max Pooling* dan panjang *forecasting horizon*. Hasil prediksi akan ditampilkan berdasarkan model dari kombinasi dari arsitektur yang dipilih.

A screenshot of the same application interface as in Gambar 4.2, but with the "CNN-LSTM" option selected in the dropdown menu. Below the dropdown, the text "Choose Model Parameter" is displayed. A series of dropdown menus allow the user to set parameters: "Filter: 16 & 32", "Units: 100", "Epoch: 100", "Learning Rate: 0.1", "Max Pooling Layer: 0", and "Forecasting Horizon: 30". At the bottom of the form is a green "Predict" button.

**Gambar 4.3** Tampilan setelah memilih model CNN-LSTM

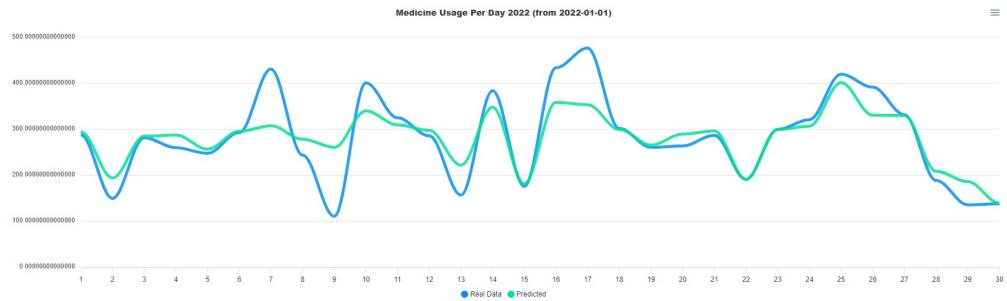
3. Gambar 4.4 merupakan tampilan ketika model LSTM dipilih oleh pengguna. Mirip seperti pada Gambar 4.3, pada halaman ini juga pengguna diminta untuk memasukkan kombinasi dari arsitektur yang akan digunakan untuk memprediksi yaitu *units*, *epoch*, *learning rate* dan panjang *forecasting horizon*. Hasil prediksi akan ditampilkan berdasarkan model dari kombinasi dari arsitektur yang dipilih.



**Gambar 4.4** Tampilan setelah memilih model LSTM

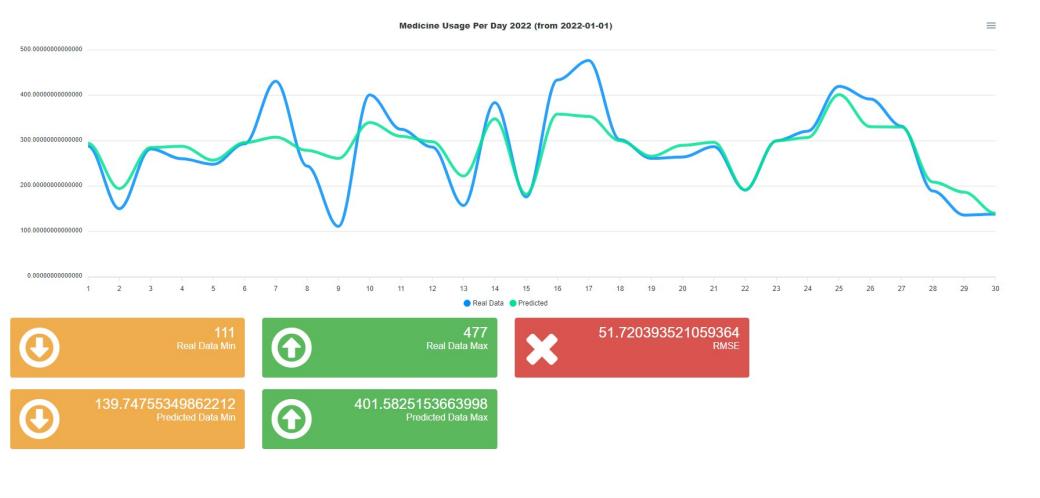
4. Setelah memilih kombinasi dari arsitektur yang akan digunakan untuk memprediksi, pengguna dapat menekan tombol *predict* untuk menampilkan hasil prediksi dalam bentuk grafik. Gambar 4.5 merupakan contoh tampilan hasil prediksi yang dikeluarkan sistem dalam bentuk grafik. Terdapat 2 garis pada grafik, garis biru menggambarkan data asli sedangkan garis hijau menggambarkan data hasil prediksi sistem.

## BAB 4 IMPLEMENTASI DAN PENGUJIAN



**Gambar 4.5** Tampilan ketika pengguna telah menekan tombol *predict*

5. Selain menampilkan grafik, sistem juga akan menampilkan nilai *error* dalam bentuk nilai RMSE pada bagian bawah grafik serta ringkasan informasi mengenai data yang ditampilkan seperti nilai maksimum dan nilai minimum dari data asli serta data hasil prediksi. Gambar 4.6 merupakan contoh tampilan sistem yang menampilkan informasi lain di bawah grafik yang dibuat oleh sistem.



**Gambar 4.6** Tampilan informasi mengenai data pada grafik

### 4.4 Pengujian

Bagian ini menjelaskan pengujian terhadap sistem prediksi pemakaian obat rumah sakit yang telah dibuat. Pengujian akan dilakukan seperti berikut.

#### 4.4.1 Pengujian Nilai *Epoch*

*Epoch* diuji untuk mengetahui berapa banyak *epoch* yang optimal bagi arsitektur yang dibangun agar model tidak terlalu banyak belajar. Nilai *epoch* yang akan diuji adalah 100, 150, 200 dan 250.

### 4.4.2 Pengujian *Filter*

Jumlah *filter* yang digunakan dalam satu lapisan konvolusi akan memengaruhi akurasi. Dengan jumlah *filter* yang tepat, fitur akan semakin banyak diekstrak dari data. Pada penelitian ini digunakan 2 buah lapisan konvolusi dengan memiliki filter yang berbeda untuk masing-masing lapisan konvolusinya. Kombinasi pengujian *filter* yang akan dilakukan adalah 16 untuk konvolusi pertama dan 32 untuk konvolusi kedua, 32 untuk konvolusi pertama dan 64 untuk konvolusi kedua serta 64 untuk konvolusi pertama dan 128 untuk konvolusi kedua.

### 4.4.3 Pengujian *Units*

Jumlah *units* merupakan jumlah dari *hidden states* untuk algoritma pembelajaran mesin LSTM yang akan mempengaruhi kemampuan belajar algoritma tersebut. Nilai *units* yang akan diuji adalah 100, 200 dan 300.

### 4.4.4 Pengujian *Learning Rate*

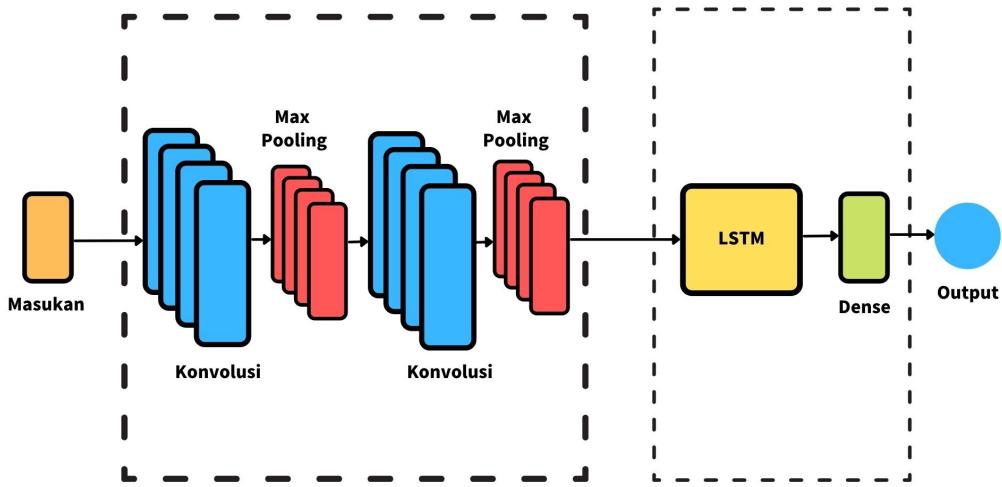
*Learning rate* merupakan seberapa besar hasil pembelajaran sebuah iterasi akan berpengaruh untuk melakukan pembaharuan nilai bobot. Nilai *learning rate* yang akan diuji adalah 0.1, 0.01 dan 0.001.

### 4.4.5 Pengujian *Max Pooling*

Berikut ini adalah rancangan arsitektur berdasarkan lapisan *Max Pooling* yang akan diuji. Ada 3 buah rancangan arsitektur sebagai berikut.

#### 1. Rancangan Arsitektur 1

Gambar 4.7 adalah ilustrasi dari arsitektur 1.



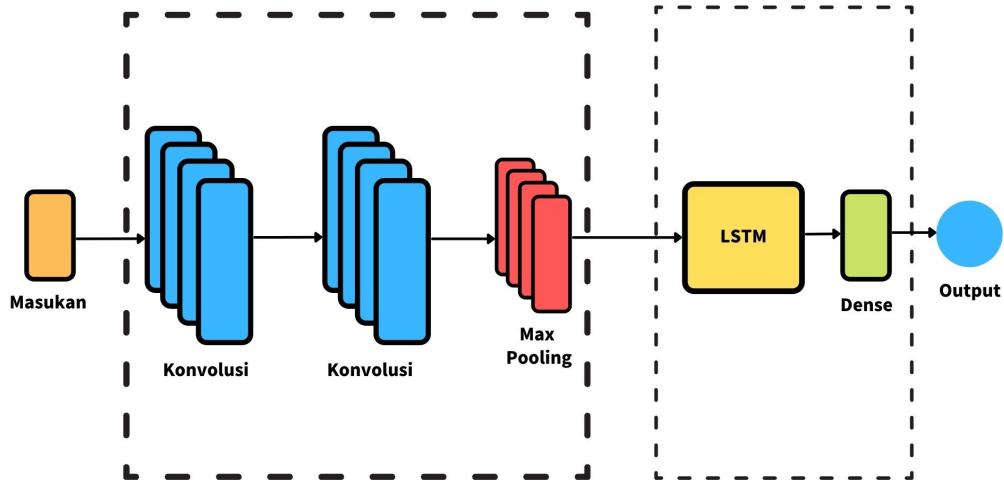
**Gambar 4.7** Rancangan arsitektur CNN-LSTM dengan 2 lapisan Max Pooling

Berikut ini adalah urutan proses yang akan dilakukan pada arsitektur pertama berdasarkan Gambar 4.7.

- 1 lapisan konvolusi dengan kombinasi *filter* seperti pada Bagian 4.4.2, fungsi aktivasi ReLU dengan menggunakan *padding same*, ukuran *kernel 2*, *bias initializer zeros* dan *kernel initializer random normal*.
- 1 lapisan *Max Pooling* dengan *pool size 2* dan *strides 1*.
- 1 lapisan konvolusi dengan kombinasi *filter* seperti pada Bagian 4.4.2, fungsi aktivasi ReLU dengan menggunakan *padding same*, ukuran *kernel 2*, *bias initializer zeros* dan *kernel initializer random normal*.
- 1 lapisan *Max Pooling* dengan *pool size 2* dan *strides 1*.
- 1 lapisan LSTM dengan kombinasi jumlah *units* seperti pada Bagian 4.4.3, fungsi aktivasi ReLu dan *recurrent activation function tanh*, *bias initializer zeros* dan *kernel initializer random normal*.
- 1 lapisan *dense* dengan fungsi aktivasi ReLU, *bias initializer zeros* dan *kernel initializer random normal*.

## 2. Rancangan Arsitektur 2

Gambar 4.8 adalah ilustrasi dari arsitektur 2.



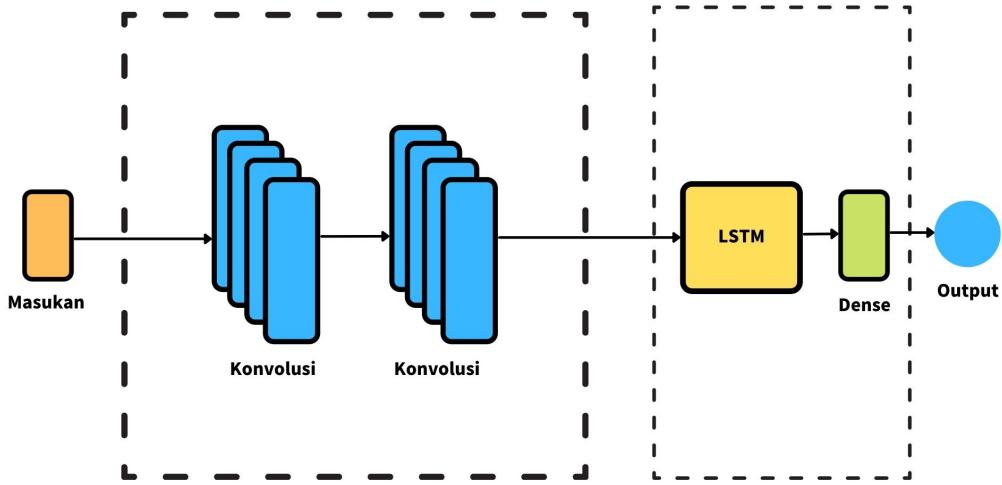
**Gambar 4.8** Rancangan arsitektur CNN-LSTM dengan 1 lapisan Max Pooling

Berikut ini adalah urutan proses yang akan dilakukan pada arsitektur pertama berdasarkan Gambar 4.8.

- 1 lapisan konvolusi dengan kombinasi *filter* seperti pada Bagian 4.4.2, fungsi aktivasi ReLU dengan menggunakan *padding same*, ukuran *kernel 2*, *bias initializer zeros* dan *kernel initializer random normal*.
- 1 lapisan konvolusi dengan kombinasi *filter* seperti pada Bagian 4.4.2, fungsi aktivasi ReLU dengan menggunakan *padding same*, ukuran *kernel 2*, *bias initializer zeros* dan *kernel initializer random normal*.
- 1 lapisan *Max Pooling* dengan *pool size 2* dan *strides 1*.
- 1 lapisan LSTM dengan kombinasi jumlah *units* seperti pada Bagian 4.4.3, fungsi aktivasi ReLu dan *recurrent activation function tanh*, *bias initializer zeros* dan *kernel initializer random normal*.
- 1 lapisan *dense* dengan fungsi aktivasi ReLU, *bias initializer zeros* dan *kernel initializer random normal*.

### 3. Rancangan Arsitektur 3

Gambar 4.9 adalah ilustrasi dari arsitektur 3.



**Gambar 4.9** Rancangan arsitektur CNN-LSTM tanpa lapisan Max Pooling (*Nonpooling CNN-LSTM*)

Berikut ini adalah urutan proses yang akan dilakukan pada arsitektur pertama berdasarkan Gambar 4.9.

- 1 lapisan konvolusi dengan kombinasi *filter* seperti pada Bagian 4.4.2, fungsi aktivasi ReLU dengan menggunakan *padding same*, ukuran *kernel* 2, *bias initializer zeros* dan *kernel initializer random normal*.
- 1 lapisan konvolusi dengan kombinasi *filter* seperti pada Bagian 4.4.2, fungsi aktivasi ReLU dengan menggunakan *padding same*, ukuran *kernel* 2, *bias initializer zeros* dan *kernel initializer random normal*.
- 1 lapisan LSTM dengan kombinasi jumlah *units* seperti pada Bagian 4.4.3, fungsi aktivasi ReLu dan *recurrent activation function tanh*, *bias initializer zeros* dan *kernel initializer random normal*.
- 1 lapisan *dense* dengan fungsi aktivasi ReLU, *bias initializer zeros* dan *kernel initializer random normal*.

#### 4.4.6 Pengujian *Forecasting Horizon*

*Forecasting horizon* merupakan panjang sekuens yang akan diprediksi oleh model. Pada penelitian ini, nilai *forecasting horizon* yang akan diuji adalah 30 hari dan 90 hari.

#### 4.4.7 Skenario Pengujian

Tabel 4.5 merupakan rincian dari keseluruhan parameter yang akan diuji untuk model CNN-LSTM pada penelitian ini. Masing-masing parameter *epoch*, *units*, *filter* dan *learning rate* akan dicoba setiap kombinasinya sehingga menghasilkan

## BAB 4 IMPLEMENTASI DAN PENGUJIAN

---

total 108 skenario untuk setiap arsitektur seperti pada Bagian 4.4.5 tiap *forecasting horizon*. Sehingga setiap arsitektur akan memiliki 216 skenario karena memiliki 2 jenis *forecasting horizon* yang akan diuji yaitu 30 hari dan 90 hari. Pada penelitian ini terdapat 3 arsitektur seperti yang sudah dijelaskan pada Bagian 4.4.5. Total skenario yang diuji dapat dihitung dengan mengalikan total kombinasi nilai *epoch*, *units*, *filter*, *learning rate*, lapisan *Max Pooling* dan *forecasting horizon*. Sehingga total skenario yang akan diuji adalah 648 skenario.

**Tabel 4.5** Rincian keseluruhan skenario pengujian yang akan diuji untuk model CNN-LSTM

No	Pengujian	Kombinasi	Total
1	Epoch	100, 150, 200, 250	4
2	Units	100, 200, 300	3
3	Filter	16 dan 32, 32 dan 64, 64 dan 128	3
4	Learning rate	0.1, 0.01, 0.001	3
5	Max Pooling layer	2 lapisan, 1 lapisan, tanpa Max Pooling	3
6	Forecasting Horizon	30 hari, 90 hari	2
Total skenario			648

Pada penelitian ini juga akan dibandingkan melakukan prediksi obat sesuai skenario yang telah ditentukan dengan menggunakan model LSTM murni. Pada model LSTM, nilai *units* akan mengikuti seperti pada Bagian 4.4.3, nilai *epoch* akan mengikuti seperti pada Bagian 4.4.1, *learning rate* akan mengikuti seperti pada Bagian 4.4.4 dan *forecasting horizon* akan mengikuti seperti pada Bagian 4.4.6. Tabel 4.6 merupakan rincian skenario pengujian untuk model LSTM.

**Tabel 4.6** Rincian keseluruhan skenario pengujian yang akan diuji untuk model LSTM

No	Pengujian	Kombinasi	Total
1	Epoch	100, 150, 200, 250	4
2	Units	100, 200, 300	3
4	Learning rate	0.1, 0.01, 0.001	3
6	Forecasting Horizon	30 hari, 90 hari	2
Total skenario			72

Pemilihan parameter pengujian pada penelitian ini akan dibatasi hanya seperti

yang sudah dirincikan di Tabel 4.5 dan Tabel 4.6. Hal ini dikarenakan pengujian dengan nilai parameter dibawah dan diatas nilai parameter yang telah ditentukan memiliki perubahan yang tidak terlalu signifikan. Hal ini akan lebih lanjut dijelaskan di setiap arsitektur yang diuji pada Bagian 4.5 .

### 4.5 Hasil Pengujian

Berdasarkan pemaparan yang sudah dijelaskan pada bagian 4.4 , berikut ini merupakan seluruh hasil pengujian yang sudah dilakukan. Pengujian jumlah *epoch*, jumlah *filter* dan jumlah *units* yang telah dilakukan dengan mengombinasikan semua nilai. Hasil pengujian ini dikelompokkan berdasarkan arsitektur, dimana pada setiap arsitektur, diujikan setiap kombinasi nilai jumlah *epoch*, *learning rate*, jumlah *filter*, jumlah *units* serta lapisan *Max Pooling* untuk mencari nilai *error* yang terkecil. Sedangkan untuk model LSTM kombinasi yang diuji merupakan nilai jumlah *units*, jumlah *epoch* dan *learning rate*. Pengujian akan dilakukan terhadap kemampuan prediksi setiap arsitektur untuk *forecasting horizon* 30 hari dan 90 hari ke depan.

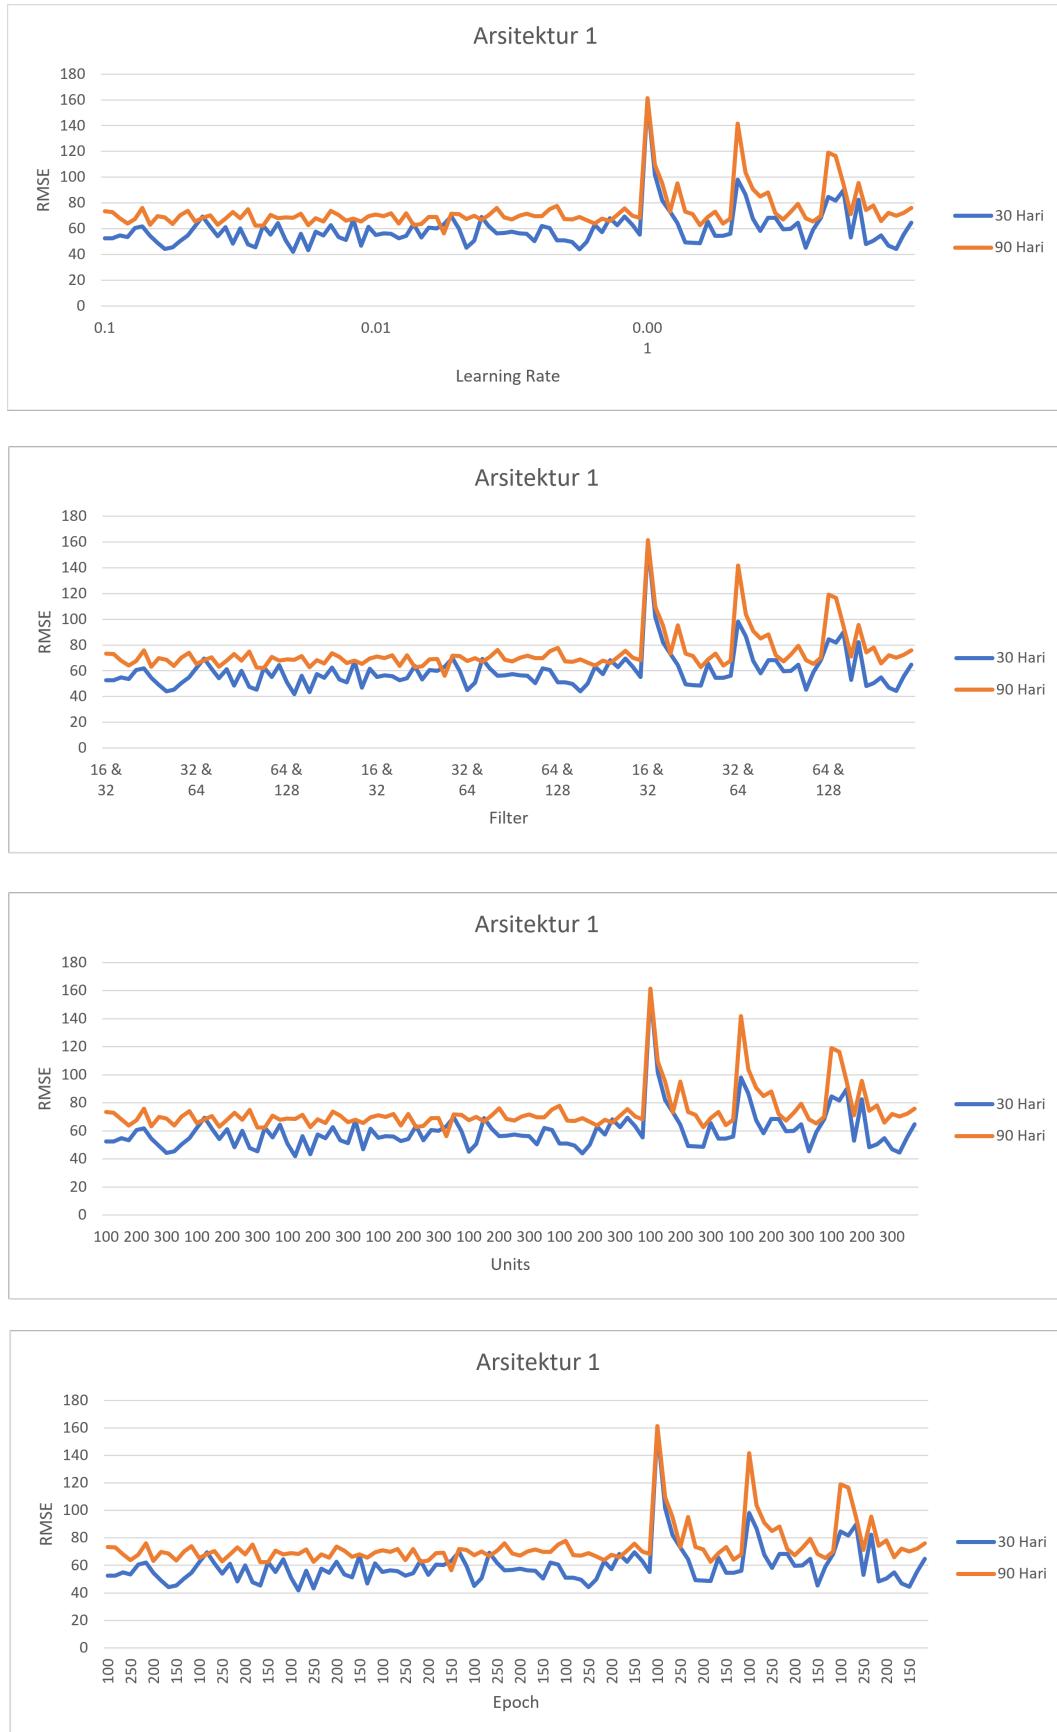
#### 4.5.1 Pengujian pada Arsitektur 1

Bagian ini akan merangkum hasil pengujian pada arsitektur pertama. Penjelasan dibagi berdasarkan hasil pengujian untuk *forecasting horizon* 30 hari dan 90 hari ke depan. Tabel 4.7 merupakan ringkasan dari seluruh hasil pengujian parameter pada arsitektur 1 untuk *forecasting horizon* 30 hari dan 90 hari. Dapat dilihat pada tabel bahwa hasil pengujian untuk *forecasting horizon* 30 hari memiliki nilai minimum, maksimum dan rata-rata yang relatif lebih rendah jika dibandingkan dengan hasil pengujian untuk *forecasting horizon* 90 hari. Hal ini dikarenakan model harus memprediksi lebih banyak dan menggunakan hasil prediksi model tersebut lebih banyak jika dibandingkan dengan saat memprediksi untuk *forecasting horizon* 30 hari.

**Tabel 4.7** Ringkasan hasil pengujian arsitektur 1 untuk *forecasting horizon* 30 hari dan 90 hari

No	Forecasting Horizon	RMSE		
		Min	Max	Average
1	30 hari	41.94477427	159.9604274	59.88385331
2	90 hari	56.33234525	161.4569449	73.88349207

## BAB 4 IMPLEMENTASI DAN PENGUJIAN



**Gambar 4.10** Perbandingan RMSE berdasarkan parameter pengujian untuk arsitektur 1

Gambar 4.10 merupakan keseluruhan nilai RMSE yang didapatkan dari seluruh skenario pengujian untuk arsitektur 1 yang dibagi berdasarkan *learning rate*, *filter*, *units* dan *epoch*. Jika dilihat, nilai RMSE mulai naik cukup tinggi dimulai nilai *learning rate* = 0.001. Kemudian mulai menurun seiring dengan adanya kenaikan nilai parameter lain seperti jumlah *filter*, *units* dan *epoch*. Hal ini terjadi dikarenakan model *learning rate* mempengaruhi kemampuan belajar model ditambah dengan kombinasi nilai parameter lain yang kecil membuat model semakin sedikit mempelajari pola data. Hal ini dapat kita lihat dengan adanya penurunan nilai RMSE ketika nilai parameter lain bertambah.

Pada nilai parameter *learning rate* = 0.1 dan 0.001 tidak terlalu terlihat banyak perubahan nilai RMSE dikarenakan meskipun dengan nilai parameter lain yang kecil, model masih dapat mempelajari pola data dengan baik. Nilai RMSE juga cenderung tidak banyak mengalami perubahan untuk setiap kombinasi parameter jumlah *filter*, *units* dan *epoch* pada nilai parameter *learning rate* = 0.1 dan 0.001. Hal ini yang membuat pemilihan nilai parameter dibatasi seperti yang sudah dibahas sebelumnya pada Bagian 4.4 .

### 4.5.2 Pengujian pada Arsitektur 2

Tabel 4.8 merupakan ringkasan dari seluruh hasil pengujian parameter pada arsitektur 2 untuk *forecasting horizon* 30 hari dan 90 hari. Dapat dilihat pada tabel bahwa hasil pengujian untuk *forecasting horizon* 30 hari memiliki nilai minimum, maksimum dan rata-rata yang relatif lebih rendah jika dibandingkan dengan hasil pengujian untuk *forecasting horizon* 90 hari. Hal ini dikarenakan model harus memprediksi lebih banyak dan menggunakan hasil prediksi model tersebut lebih banyak jika dibandingkan dengan saat memprediksi untuk *forecasting horizon* 30 hari. Tetapi dapat dilihat untuk nilai maksimum *forecasting horizon* 30 hari dan 90 hari tidak memiliki perbedaan yang terlalu jauh. Hal ini terjadi karena model arsitektur 2 dapat lebih mempelajari data lebih baik sehingga menghasilkan nilai prediksi lebih baik. Hal ini juga berarti ketika model hendak memprediksi sekvens yang lebih panjang, hasil prediksi dari model tersebut sendiri akan lebih baik digunakan untuk memprediksi data berikutnya.

## BAB 4 IMPLEMENTASI DAN PENGUJIAN

---

**Tabel 4.8** Ringkasan hasil pengujian arsitektur 2 untuk *forecasting horizon* 30 hari dan 90 hari

No	Forecasting Horizon	RMSE		
		Min	Max	Average
1	30 hari	39.92536417	131.363996	59.86119405
2	90 hari	56.4606841	133.7051125	72.34490647

## BAB 4 IMPLEMENTASI DAN PENGUJIAN



**Gambar 4.11** Perbandingan RMSE berdasarkan parameter pengujian untuk arsitektur 1

Gambar 4.11 merupakan keseluruhan nilai RMSE yang didapatkan dari seluruh skenario pengujian untuk arsitektur 2 yang dibagi berdasarkan *learning rate*, *filter*, *units* dan *epoch*. Jika dilihat, mirip seperti pada Gambar 4.10 nilai RMSE mulai naik cukup tinggi dimulai nilai *learning rate* = 0.001. Kemudian mulai menurun seiring dengan adanya kenaikan nilai parameter lain seperti jumlah *filter*, *units* dan *epoch*. Tetapi jika dibandingkan dengan Gambar 4.10, meskipun menurun tetapi nilai RMSE masih cukup fluktuatif dan titik puncak nilai RMSE lebih rendah. Hal ini terjadi karena berbeda dengan arsitektur 1, arsitektur 2 hanya memiliki 1 lapisan *Max Pooling* sehingga total data yang terpotong oleh operasi *Max Pooling* lebih sedikit.

Pada nilai parameter *learning rate* = 0.1 dan 0.001 tidak terlalu terlihat banyak perubahan nilai RMSE dikarenakan meskipun dengan nilai parameter lain yang kecil, model masih dapat mempelajari pola data dengan baik. Berbeda dengan Gambar 4.10, nilai RMSE cenderung mengalami perubahan (fluktuatif) untuk setiap kombinasi parameter jumlah *filter*, *units* dan *epoch* pada nilai parameter *learning rate* = 0.1 dan 0.001 namun secara keseluruhan memiliki nilai RMSE yang lebih kecil. Seperti yang sudah dibahas sebelumnya, hal ini mungkin terjadi dikarenakan jumlah lapisan *Max Pooling* yang lebih sedikit yaitu 1 lapisan saja. Hal ini mempengaruhi pemilihan kombinasi parameter yang tepat agar model tidak terlalu banyak atau terlalu sedikit mempelajari pola data. Perubahan nilai RMSE yang tidak terlalu signifikan membuat pemilihan nilai parameter dibatasi seperti yang sudah dibahas sebelumnya pada Bagian 4.4 .

### 4.5.3 Pengujian pada Arsitektur 3

Tabel 4.9 merupakan ringkasan dari seluruh hasil pengujian parameter pada arsitektur 3 untuk *forecasting horizon* 30 hari dan 90 hari. Dapat dilihat pada tabel bahwa hasil pengujian untuk *forecasting horizon* 30 hari memiliki nilai minimum, maksimum dan rata-rata yang relatif lebih rendah jika dibandingkan dengan hasil pengujian untuk *forecasting horizon* 90 hari. Hal ini dikarenakan model harus memprediksi lebih banyak dan menggunakan hasil prediksi model tersebut lebih banyak jika dibandingkan dengan saat memprediksi untuk *forecasting horizon* 30 hari. Model arsitektur 3 juga memiliki nilai maksimum *forecasting horizon* 30 hari dan 90 hari dengan perbedaan yang terlalu jauh. Hal ini terjadi karena model arsitektur 3 juga dapat lebih mempelajari data lebih baik sehingga menghasilkan nilai prediksi lebih baik. Hal ini juga berarti ketika model hendak memprediksi sekuens yang lebih panjang, hasil prediksi dari model tersebut sendiri akan lebih baik digunakan untuk memprediksi data berikutnya.

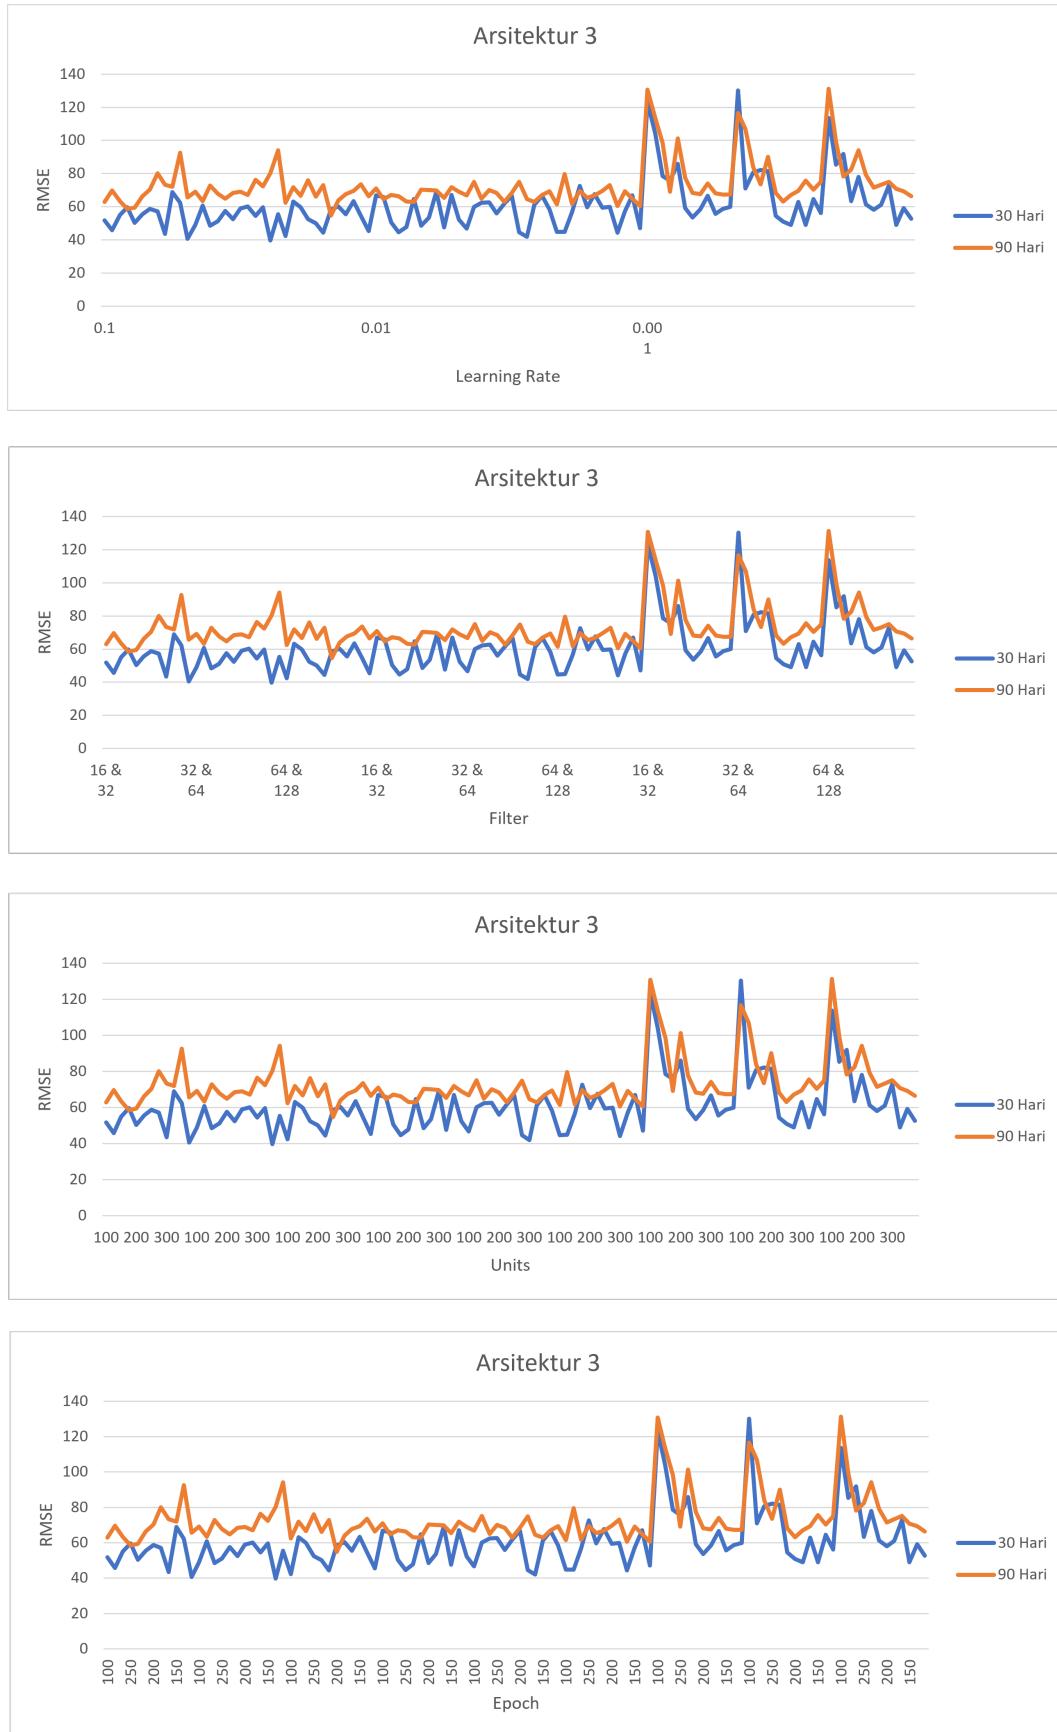
## BAB 4 IMPLEMENTASI DAN PENGUJIAN

---

**Tabel 4.9** Ringkasan hasil pengujian arsitektur 3 untuk *forecasting horizon* 30 hari dan 90 hari

No	Forecasting Horizon	RMSE		
		Min	Max	Average
1	30 hari	39.63529315	130.2061305	60.68535708
2	90 hari	54.68132489	131.1586901	73.09096309

## BAB 4 IMPLEMENTASI DAN PENGUJIAN



**Gambar 4.12** Perbandingan RMSE berdasarkan parameter pengujian untuk arsitektur 1

Gambar 4.12 merupakan keseluruhan nilai RMSE yang didapatkan dari seluruh skenario pengujian untuk arsitektur 2 yang dibagi berdasarkan *learning rate*, *filter*, *units* dan *epoch*. Jika dilihat, mirip seperti pada Gambar 4.10 dan Gambar 4.11 nilai RMSE mulai naik cukup tinggi dimulai nilai *learning rate* = 0.001. Kemudian cenderung menurun seiring dengan adanya kenaikan nilai parameter lain seperti jumlah *filter*, *units* dan *epoch*. Tetapi jika dibandingkan dengan Gambar 4.10, meskipun menurun tetapi nilai RMSE masih cukup fluktuatif dan titik puncak nilai RMSE lebih rendah dan fluktiasinya lebih dapat terlihat jika dibandingkan dengan Gambar 4.11. Hal ini terjadi karena berbeda dengan arsitektur 1 dan arsitektur 2, arsitektur 3 ini tidak memiliki lapisan *Max Pooling* sehingga tidak ada data yang terpotong oleh operasi *Max Pooling*. Hal ini menyebabkan model lebih sensitif terhadap perubahan nilai parameter.

Pada nilai parameter *learning rate* = 0.1 dan 0.001 cukup terlihat banyak perubahan nilai RMSE berbeda dengan Gambar 4.10 dan Gambar 4.11. Fluktuasi nilai RMSE cukup terlihat di setiap kombinasi parameter jumlah *filter*, *units* dan *epoch* pada nilai parameter *learning rate* = 0.1 dan 0.001 dan secara keseluruhan memiliki nilai RMSE yang lebih tinggi jika dibandingkan dengan kedua arsitektur sebelumnya. Seperti yang sudah dibahas sebelumnya, hal ini mungkin terjadi dikarenakan tidak adanya lapisan *Max Pooling*. Hal ini sangat mempengaruhi pemilihan kombinasi parameter yang tepat agar model tidak terlalu banyak atau terlalu sedikit mempelajari pola data. Perubahan nilai RMSE memang cukup terlihat, tetapi perbedaannya untuk setiap kombinasi nilai parameter tidak terlalu signifikan membuat pemilihan nilai parameter dibatasi seperti yang sudah dibahas sebelumnya pada Bagian 4.4 .

### 4.5.4 Pengujian pada model LSTM

Tabel 4.10 merupakan ringkasan dari seluruh hasil pengujian parameter pada model LSTM untuk *forecasting horizon* 30 hari dan 90 hari. Sama seperti ketiga arsitektur CNN-LSTM, nilai RMSE juga lebih rendah untuk *forecasting horizon* 30 hari jika dibandingkan dengan 90 hari.

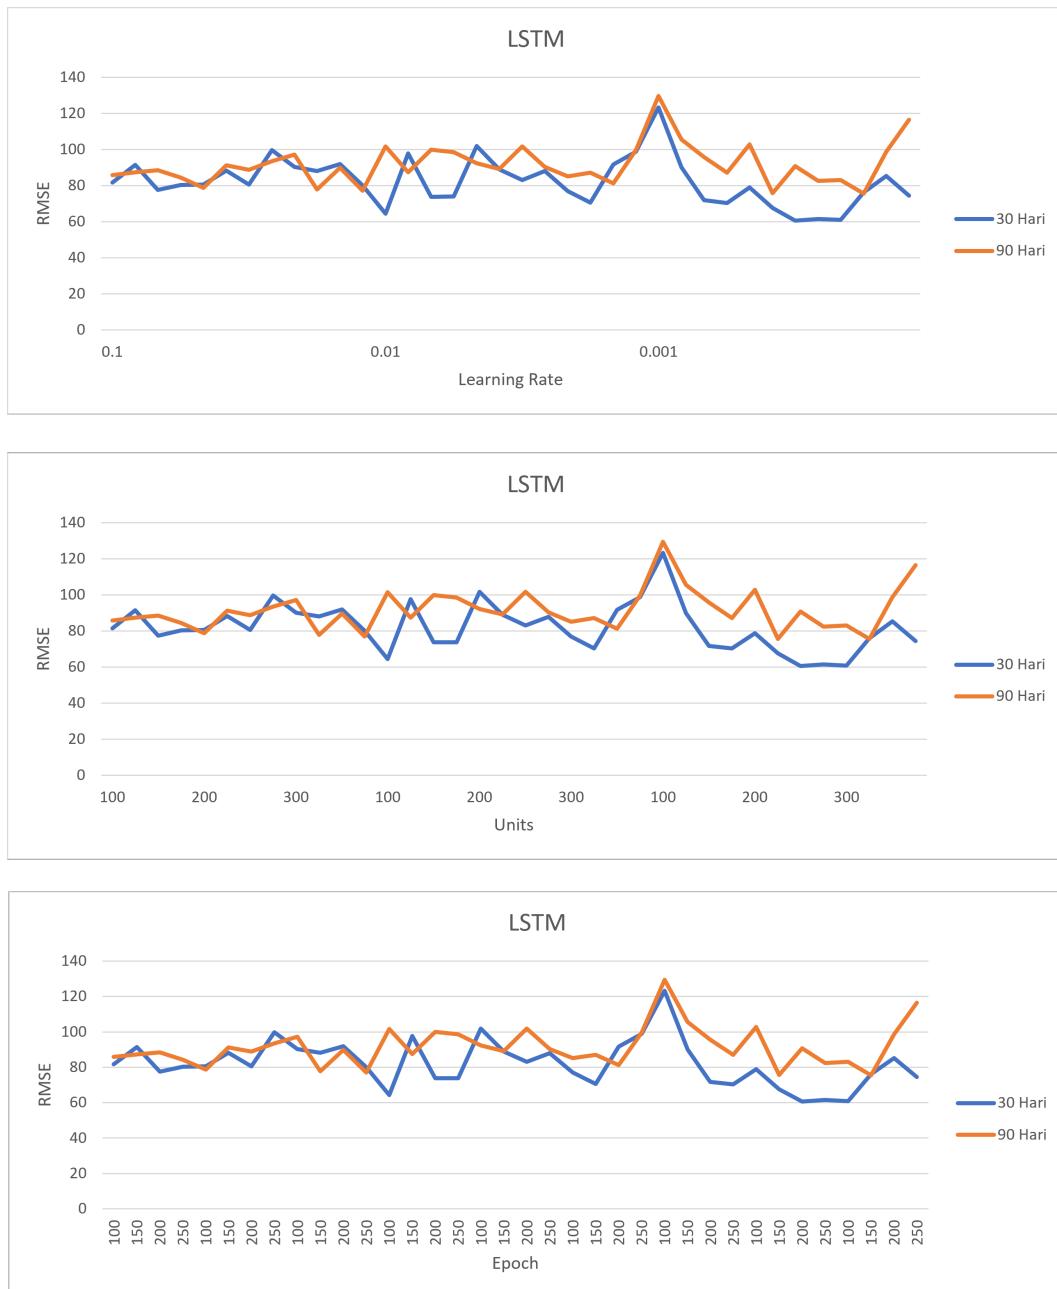
**Tabel 4.10** Ringkasan hasil pengujian model LSTM untuk *forecasting horizon* 30 hari dan 90 hari

No	Forecasting Horizon	RMSE		
		Min	Max	Average
1	30 hari	60.60345886	123.2707383	82.2321592

## BAB 4 IMPLEMENTASI DAN PENGUJIAN

**Tabel 4.10** Ringkasan hasil pengujian model LSTM untuk *forecasting horizon* 30 hari dan 90 hari

No	Forecasting Horizon	RMSE		
		Min	Max	Average
2	90 hari	75.50361953	129.5106816	91.59110308



**Gambar 4.13** Perbandingan RMSE berdasarkan parameter pengujian untuk arsitektur 1

Gambar 4.13 merupakan keseluruhan nilai RMSE yang didapatkan dari seluruh skenario pengujian untuk model LSTM yang dibagi berdasarkan *learning rate*,

*units* dan *epoch*. Jika dilihat, mirip seperti pada Gambar 4.10, Gambar 4.11 dan Gambar 4.12, nilai RMSE mulai naik cukup tinggi dimulai nilai *learning rate* = 0.001. Kemudian cenderung menurun seiring dengan adanya kenaikan nilai parameter lain seperti jumlah *filter*, *units* dan *epoch*. Tetapi jika dibandingkan dengan Gambar 4.10, Gambar 4.11 dan Gambar 4.12, meskipun menurun tetapi nilai RMSE mulai naik ketika kombinasi parameter lain mencapai nilai maksimum dari skenario pengujian. Hal ini mungkin terjadi dikarenakan berbeda dengan ketiga arsitektur sebelumnya, model LSTM ini hanya memiliki lapisan LSTM saja sehingga model cenderung mengalami *overfit* ketika nilai parameter *units* semakin tinggi.

Pada nilai parameter *learning rate* = 0.1 dan 0.001 cukup terlihat banyak perubahan nilai RMSE berbeda dengan Gambar 4.10, Gambar 4.11 dan Gambar 4.12. Fluktuasi nilai RMSE cukup terlihat di setiap kombinasi parameter *units* dan *epoch* pada nilai parameter *learning rate* = 0.1 dan 0.001 dan secara keseluruhan memiliki nilai RMSE yang lebih tinggi jika dibandingkan dengan kedua arsitektur sebelumnya. Selain itu perbedaan juga terlihat dimana fluktuasi nilai RMSE pada *forecasting horizon* 30 hari dan 90 hari tidak terlalu memiliki perbedaan jauh, hanya saja memang nilai maksimum RMSE untuk *forecasting horizon* 90 hari lebih tinggi jika dibandingkan dengan *forecasting horizon* 30 hari.

### 4.5.5 Pembahasan Umum Hasil Pengujian

Gambar 4.14 dan Gambar 4.15 merupakan keseluruhan perbandingan nilai RMSE berdasarkan setiap parameter pengujian dari seluruh arsitektur untuk *forecasting horizon* 30 hari dan 90 hari. Gambar grafik serupa yang merincikan pengujian nilai parameter terhadap nilai RMSE adalah Gambar 4.13. Sedangkan Tabel 4.11 merupakan tabel ringkasan dari keseluruhan hasil uji coba yang telah dilakukan pada Bagian 4.5.1 hingga 4.5.4 berupa nilai minimum, maksimum dan rata-rata RMSE dari setiap arsitektur yang telah diuji coba. Berikut adalah gambar yang merangkum keseluruhan hasil pengujian dari ketiga arsitektur yang telah dilakukan serta tabel rangkuman dari seluruh pengujian yang dilakukan.

## BAB 4 IMPLEMENTASI DAN PENGUJIAN



**Gambar 4.14** Perbandingan RMSE berdasarkan parameter pengujian dari ketiga arsitektur arsitektur pada *forecasting horizon* 30 hari

## BAB 4 IMPLEMENTASI DAN PENGUJIAN



**Gambar 4.15** Perbandingan RMSE berdasarkan parameter pengujian dari ketiga arsitektur arsitektur pada *forecasting horizon* 90 hari

**Tabel 4.11** Ringkasan keseluruhan hasil pengujian

No	Model	Forecasting Horizon	RMSE		
			Min	Max	Average
1	Arsitektur 1	30 hari	41.94477427	159.9604274	59.88385331
2		90 hari	56.33234525	161.4569449	73.88349207
3	Arsitektur 2	30 hari	39.92536417	131.363996	59.86119405
4		90 hari	56.4606841	133.7051125	72.34490647
5	Arsitektur 3	30 hari	39.63529315	130.2061305	60.68535708
6		90 hari	54.68132489	131.1586901	73.09096309
7	LSTM	30 hari	60.60345886	123.2707383	82.2321592
8		90 hari	75.50361953	129.5106816	91.59110308

Dari seluruh hasil pengujian arsitektur CNN-LSTM dan model LSTM yang sudah dituliskan pada Bagian 4.5.1 hingga 4.5.4, jika dikaitkan dengan rumusan masalah pada Bagian 1.2 dan dilihat pada Gambar 4.14, Gambar 4.15, Gambar 4.13 dan Tabel 4.11, maka keterkaitan konfigurasi jumlah *epoch*, *learning rate*, jumlah *filter*, jumlah *units* serta lapisan *Max Pooling* secara menyeluruh terhadap nilai RMSE untuk *forecasting horizon short range forecast* dan *long range forecast* dapat dijelaskan sebagai berikut.

1. Arsitektur CNN-LSTM memiliki performa rata-rata yang lebih baik jika dibandingkan dengan model LSTM saja. Hal ini dapat dilihat dari nilai rata-rata RMSE dan nilai minimum RMSE yang lebih kecil. Akan tetapi, model LSTM memiliki nilai maksimum RMSE yang lebih kecil jika dibandingkan dengan arsitektur CNN-LSTM. Hal ini dapat terjadi karena adanya pemrosesan oleh lapisan CNN terlebih dahulu sebelum diproses oleh LSTM. Sehingga ketika lapisan CNN tidak dapat mempelajari data dengan baik, maka lapisan LSTM akan mempelajari *feature map* yang kurang baik. Sedangkan pada model LSTM saja, model langsung mempelajari dari data bukan dari *feature map* yang dihasilkan oleh lapisan CNN.
2. *Nonpooling CNN-LSTM* (arsitektur 3) memiliki nilai maksimum RMSE paling medekati jika dibandingkan dengan model LSTM saja pada *forecasting horizon* 30 hari, yaitu 131.1586901 untuk *Nonpooling CNN-LSTM* dan 129.5106816 untuk model LSTM saja. Hal ini dapat terjadi karena disaat nilai parameter yang sedikit menyebabkan model kurang belajar, *Nonpooling CNN-LSTM* tidak

- memiliki lapisan *Max Pooling* sehingga lebih banyak pola yang dapat dipelajari oleh model.
3. Dapat dilihat bahwa perbedaan CNN-LSTM (arsitektur 1 dan 2) jika dibandingkan dengan *Nonpooling* CNN-LSTM (arsitektur 3) terlihat pada sensitifitas model terhadap perubahan nilai parameter. *Nonpooling* CNN-LSTM terlihat lebih sensitif terhadap perubahan nilai parameter, hal ini dapat dilihat pada Gambar 4.14 dan Gambar 4.15, *Nonpooling* CNN-LSTM memiliki nilai RMSe yang lebih fluktuatif jika dibandingkan dengan CNN-LSTM seiring dengan perubahan nilai parameter. Hal ini dapat dilihat pada Tabel 4.11 dimana *Nonpooling* CNN-LSTM memiliki nilai rata-rata RMSE yang lebih besar. Akan tetapi *Nonpooling* CNN-LSTM memiliki kelebihan jika dibandingkan dengan CNN-LSTM dimana saat nilai parameter yang kecil (terutama nilai parameter *learning rate*), nilai maksimum RMSE yang dihasilkan lebih kecil seperti dapat dilihat pada Tabel 4.11 baik untuk *forecasting horizon* 30 hari maupun 90 hari.
  4. *Overfitting* juga dapat dilihat dari hasil pengujian yang telah dilakukan. Sebelumnya, *overfitting* adalah kondisi ketika model terlalu banyak belajar pola data dan tidak dapat melakukan generasi pada data lain diluar data yang dipelajari. Pada penelitian ini, kasus-kasus *overfitting* yang terjadi antara lain seperti pada Gambar 3.205, 1.205, 2.169, 3.133 dan 3.206. Dapat dilihat bahwa kebanyakan kasus *overfitting* terjadi pada model dengan nilai parameter tinggi terutama pada jumlah *filter* yang tinggi. Hal ini membuat model terlalu banyak mempelajari pola pada data latih sehingga kurang performanya kurang baik pada saat melakukan prediksi. Selain itu, kasus *overfitting* banyak terjadi pada model *Nonpooling* CNN-LSTM (arsitektur 3) dibandingkan dengan model CNN-LSTM (arsitektur 1 dan 2). Hal ini terjadi karena lapisan CNN pada model *Nonpooling* CNN-LSTM terlalu banyak belajar pola data yang disebabkan tidak adanya lapisan *Max Pooling*.
  5. Untuk keseluruhan hasil pengujian, nilai *error* ketika melakukan prediksi 30 hari ke depan lebih kecil dibandingkan dengan ketika melakukan prediksi 90 hari ke depan. Hal ini dikarenakan data hasil prediksi akan digunakan untuk melakukan prediksi kembali. Pada rentang 90 hari, semakin banyak data hasil prediksi yang digunakan untuk memprediksi kembali maka hasilnya nilai *error* menjadi lebih tinggi. Selain itu, seluruh model memiliki kenaikan nilai RMSE yang cukup tinggi ketika nilai parameter *learning rate* = 0.001 namun perlahan kembali menurun saat nilai parameter lain mulai bertambah. Kombinasi nilai parameter terhadap nilai parameter *learning rate* terlihat sangat berpengaruh terhadap nilai RMSE.

Secara umum, dapat diambil kesimpulan bahwa kombinasi yang tepat dari jumlah *filter*, *units*, *learning rate*, *epoch* serta lapisan *Max Pooling* memiliki pengaruh terhadap kemampuan sistem untuk mempelajari data. Terutama jumlah *filter* sangat berpengaruh terhadap terjadinya *overfitting* pada model *Nonpooling CNN-LSTM*. Selain itu nilai parameter *learning rate* juga berpengaruh terhadap kombinasi nilai parameter lain yang dipilih. Jika nilai parameter *learning rate* terlalu kecil, maka perlu dikompensasikan oleh nilai parameter lain yang lebih tinggi. Namun, dari pembahasan hasil arsitektur tersebut, untuk menentukan keputusan pengambilan hasil model yang terbaik, pada dasarnya bergantung dari sudut pandang kepada hasil pengujian. Model yang terbaik tidak dapat ditentukan hanya dalam sebuah kesimpulan tunggal karena ada beberapa hal yang dapat dipertimbangkan lebih lanjut sebelum menyatakan suatu model merupakan model yang terbaik. Hal yang perlu diperhatikan dalam menentukan hasil prediksi model merupakan prediksi setiap harinya. Jika dibutuhkan rata-rata penggunaan selama 1 bulan maka akan lebih baik untuk melihat rata-rata dari keseluruhan hasil prediksi model.

### 4.6 Analisis Kesalahan

Ada beberapa kesalahan yang terjadi selama proses pengujian sistem prediksi obat rumah sakit. Beberapa kesalahan yang akan dibahas adalah sebagai berikut.

1. Berdasarkan hasil pengujian, ditemukan bahwa data pemakaian obat yang dipakai memiliki tingkat fluktuasi yang cukup tinggi dengan besar perubahan yang berbeda-beda pada rentang periode tertentu baik pada data latih, data uji coba serta data validasi. Hal ini menyebabkan rata-rata hasil prediksi terbaik yang dilakukan sistem masih memiliki *error* yang sedikit tinggi yaitu menyimpang sejauh 39.63529315 (10,82%) pada *forecasting horizon* 30 hari. Selain itu, kesulitan melakukan prediksi pola data semakin tinggi ketika sistem melakukan prediksi dengan rentang waktu yang lebih jauh yaitu pada *forecasting horizon* 90 hari. Hal ini terlihat dari rata-rata prediksi terbaik yang dilakukan sistem memiliki nilai yang sedikit tinggi yaitu menyimpang sejauh 54.58132489 (14,91%). Nilai *error* tersebut tergolong masih cukup tinggi dikarenakan rentang data validasi yang digunakan memiliki nilai minimum 111 dan nilai maksimum 477 atau memiliki rentang 366. Nilai *error* dinilai sedikit tinggi dikarenakan hasil prediksi merupakan prediksi pemakaian sebuah obat, dimana berdasarkan 2.3.1. rumah sakit dianjurkan untuk memiliki 10-20% stok lebih sebagai stok penyangga. Jika rumah sakit memutuskan untuk menjadikan hasil prediksi sebagai total yang harus dibeli (berdasarkan pemakaian + stok

penyangga), total stok penyangga juga tidak terlalu konsisten karena nilai *error* dapat berubah-ubah (stok penyangga tidak akan konstan sesuai dengan kebijakan rumah sakit).

2. Model yang telah dilatih dan memiliki performa terbaik hanya dapat melakukan prediksi untuk obat yang dipelajari saja pada rumah sakit tersebut. Hal ini dikarenakan karakteristik data yang berbeda-beda untuk setiap obat baik di rumah sakit lain maupun rumah sakit tersebut. Selain itu, obat dengan nama yang sama di rumah sakit A akan memiliki karakteristik yang berbeda dengan obat pada rumah sakit B. Hal ini membuat model harus dibangun untuk setiap obat di setiap rumah sakit. Selain itu pada model *Nonpooling CNN-LSTM* yang memiliki karakteristik lebih sensitif terhadap nilai parameter yang dipilih akan membuat pemilihan nilai parameter lebih sulit untuk menghasilkan performa terbaik model.

## BAB 5 KESIMPULAN DAN SARAN

Bab ini berisi kesimpulan yang dilandasi oleh penelitian dan pengujian yang telah dilakukan. Selain itu, bab ini juga dilengkapi dengan saran yang dapat digunakan atau dipertimbangkan untuk penelitian di masa depan.

### 5.1 Kesimpulan

Kesimpulan dari pembuatan sistem prediksi dengan menggunakan model *Nonpooling CNN-LSTM* serta dengan model *CNN-LSTM* dan *LSTM* melalui pengujian yang telah dilakukan berdasarkan tujuan penelitian adalah sebagai berikut.

1. Konfigurasi parameter untuk setiap model dan *forecasting horizon* untuk meminimalisasi nilai RMSE adalah sebagai berikut. Model *CNN-LSTM* dengan 2 lapisan *Max Pooling* pada *forecasting horizon* 30 hari menggunakan konfigurasi parameter *filter* = 64 dan 128, *units* = 100, *learning rate* = 0.1 dan *epoch* = 150. Sedangkan untuk *forecasting horizon* 90 hari, konfigurasi parameter yang digunakan adalah *filter* = 16 dan 32, *units* = 300, *learning rate* = 0.01 dan *epoch* = 150. Untuk model *CNN-LSTM* dengan 2 lapisan *Max Pooling* pada *forecasting horizon* 30 hari menggunakan kombinasi parameter *filter* = 32 dan 64, *units* = 200, *learning rate* = 0.01 dan *epoch* = 100. Sedangkan untuk *forecasting horizon* 90 hari menggunakan kombinasi parameter yang digunakan adalah *filter* = 16 dan 32, *units* = 200, *learning rate* = 0.01 dan *epoch* = 100. Pada model *Nonpooling CNN-LSTM* (*CNN-LSTM* tanpa lapisan *Max Pooling*) pada *forecasting horizon* 30 hari menggunakan kombinasi parameter *filter* = 32 dan 64, *units* = 300, *learning rate* = 0.1 dan *epoch* = 200. Sedangkan untuk *forecasting horizon* 90 hari menggunakan kombinasi parameter yang digunakan adalah *filter* = 64 dan 128, *units* = 200, *learning rate* = 0.1 dan *epoch* = 200. Konfigurasi lapisan *Max Pooling* mempengaruhi konfigurasi parameter jumlah *filter*, *units*, *epoch* dan *learning rate*. Optimasi konfigurasi parameter perlu dilakukan sesuai dengan konfigurasi lapisan *Max Pooling* yang dipilih agar model tidak mengalami *overfitting*. Selain itu kombinasi parameter jumlah *filter*, *units*, *epoch* dan *learning rate* juga berpengaruh satu sama lain. Untuk mendapatkan nilai RMSE paling optimal dari model, diperlukan konsiderasi dari pemilihan masing-masing parameter agar nilai parameter tidak terlalu kecil maupun terlalu besar.
2. Hasil prediksi pemakaian obat rumah sakit yang menggunakan model

*Nonpooling* CNN-LSTM memiliki nilai RMSE terkecil jika dibandingkan dengan model CNN-LSTM dan LSTM baik untuk *forecasting horizon short range forecast* dan *long range forecast*. Akan tetapi rata-rata RMSE yang dihasilkan oleh model *Nonpooling* CNN-LSTM memiliki nilai RMSE yang lebih tinggi jika dibandingkan dengan model CNN-LSTM. Hal ini dikarenakan sensitifitas model *Nonpooling* CNN-LSTM terhadap pemilihan kombinasi parameter jumlah *filter*, *units*, *epoch* dan *learning rate* lebih tinggi dibandingkan dengan model CNN-LSTM. Keseluruhan dari hasil pengujian menunjukan bahwa nilai RMSE yang lebih kecil ketika model melakukan prediksi pada *forecasting horizon short range forecast* dibandingkan dengan *long range forecast*. Hal ini dikarenakan hasil prediksi dari model digunakan kembali sebagai bahan untuk memprediksi hari berikutnya membuat hasil prediksi pada *forecasting horizon long range forecast* semakin banyak menggunakan data hasil prediksi model tersebut.

### 5.2 Saran

Saran dari peneliti untuk pengembangan sistem prediksi pemakaian obat rumah sakit pada penelitian selanjutnya adalah mempertimbangkan untuk melakukan dekomposisi sinyal CEEMDAN pada data obat dengan karakteristik tingkat fluktuasi cukup tinggi seperti pada penelitian [5]. Metode dekomposisi sinyal CEEMDAN pada penelitian [5] dapat membagi-bagi data atau sinyal fluktuasi pemakaian obat pada data *time-series* menjadi beberapa bagian sesuai tingkat fluktuasinya dari rendah ke tinggi. Dengan melakukan metode dekomposisi sinyal CEEMDAN, model mungkin dapat menghasilkan performa lebih baik serta lebih general dapat diterapkan kepada data obat lain karena model dapat mempelajari tingkat fluktuasi yang berbeda pada data secara terpisah.

## DAFTAR REFERENSI

- [1] Kementerian Kesehatan Republik Indonesia. *Pedoman Penyusunan Rencana Kebutuhan Obat dan Pengendalian Persediaan Obat di Rumah Sakit*. 2019.
- [2] S. Kaushik, A. Choudhury, P. K. Sheron, N. Dasgupta, S. Natarajan, L. A. Pickett, and V. Dutt, “AI in Healthcare: Time-series Forecasting Using Statistical, Neural, and Ensemble Architectures,” in *Frontiers in Big Data*, vol. 3, 2020..
- [3] S., Chan, Oktavianti, I., and Puspita, V., “A Deep Learning CNN and AI-tuned SVM for Electricity Consumption Forecasting: Multivariate Time Series Data,” in *IEEE 10th Annual Information Technology, Electronics and Mobile Communication Conference (IEMCON)*, 2019.
- [4] S. Liu, H. Ji, and M. C. Wang, “Nonpooling Convolutional Neural Network Forecasting for Seasonal Time Series with Trends,” in *IEEE Transactions on Neural Networks and Learning Systems*, vol. 31, no. 8, pp. 2879–2888, 2020.
- [5] J. Cao, Z. Li, and J. Li, “Financial Time Series Forecasting Model Based on CEEMDAN and LSTM,” in *Physica A: Statistical Mechanics and its Applications*, vol. 519, pp. 127–139, 2019.
- [6] I. E. Livieris, E. Pintelas, and P. Pintelas, “A CNN–LSTM Model For Gold Price Time-series Forecasting,” in *Neural Computing and Applications*, vol. 32, no. 23, pp. 17351–17360, 2020.
- [7] T. Li, M. Hua, and X. Wu, “A Hybrid CNN-LSTM Model for Forecasting Particulate Matter (PM2.5),” in *IEEE Access*, vol. 8, pp. 26933–26940, 2020.
- [8] S. Haykin, *Neural Networks and Learning Machines*, 3<sup>rd</sup> ed. Pearson, 2008.
- [9] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning, An MIT Press book*, 2016. [Online]. Available: <http://www.deeplearningbook.org>. [Accessed: January 19<sup>th</sup>, 2022].
- [10] J. Heaton, *Artificial Intelligence for Humans: Deep Learning and Neural Networks*, Volume 3, 1<sup>st</sup> ed. CreateSpace Independent Publishing Platform, 2015.

## DAFTAR REFERENSI

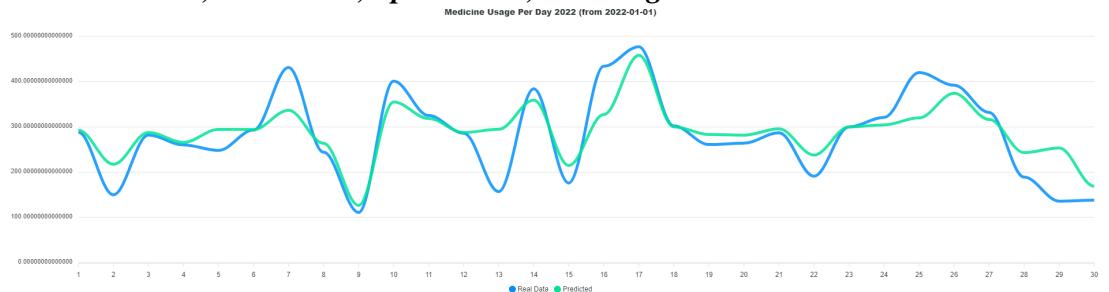
---

- [11] S. Khan, H. Rahmani, Syed Afaq Ali Shah, M. Bennamoun, “*A Guide to Convolutional Neural Networks for Computer Vision*”, 1<sup>st</sup> ed, Gérard Medioni and Sven Dickinson, Ed. California: Morgan and Claypool, pp. 45, 53, 56, 67-80, 2018.
- [12] F. Chollet, *Deep Learning with Python*, 1<sup>st</sup> ed. New York: Manning Publications, 2018.
- [13] P. Rivas, *Deep Learning for Beginners: A beginner’s guide to getting up and running with deep learning from scratch using Python*. Packt Publishing Ltd, 2020.
- [14] D. Rothman, *Artificial Intelligence by Example: Acquire Advanced AI, Machine Learning, and Deep Learning Design Skills*, 2<sup>nd</sup> ed. Birmingham: Packt Publishing Limited, 2020, pp.215-217.
- [15] Jeff Heaton, in *Artificial Intelligence for Humans: Deep Learning and Neural Networks*, Volume 3, CreateSpace Independent Publishing Platform, 2015
- [16] J., Brownlee, *Long Short-Term Memory Networks With Python*. Machine Learning Mastery, 2017.
- [17] Statistical Office of the European Union, *Glossary:Forecast*, 2014. [Online]. Available: <https://ec.europa.eu/eurostat/statistics-explained/index.php?title=Glossary:Forecasting>. [Accessed: January 19<sup>th</sup>, 2022].
- [18] Statistical Office of the European Union, *Glossary:Forecast horizon*, 2014. [Online]. Available: [https://ec.europa.eu/eurostat/statistics-explained/index.php?title=Glossary:Forecast\\_horizon#:~:text=The%20forecast%20horizon%20is%20the,\(more%20than%20two%20years\)..](https://ec.europa.eu/eurostat/statistics-explained/index.php?title=Glossary:Forecast_horizon#:~:text=The%20forecast%20horizon%20is%20the,(more%20than%20two%20years)..) [Accessed: January 19<sup>th</sup>, 2022].

## LAMPIRAN A HASIL PENGUJIAN ARSITEKTUR 1

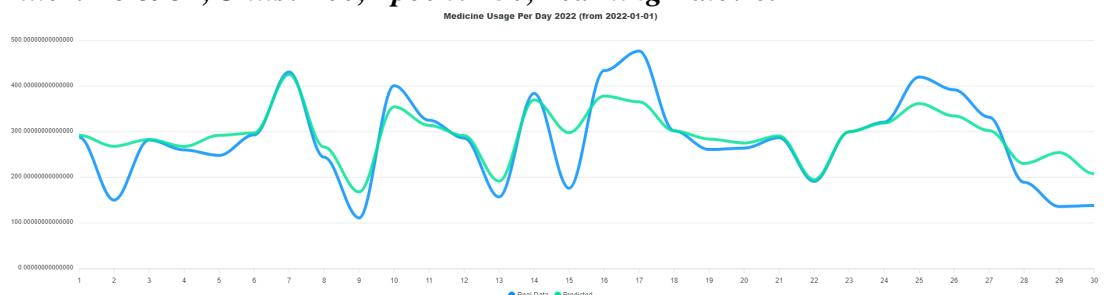
### 1.1 *Forecasting Horizon 30 hari*

#### 1. *Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.1*



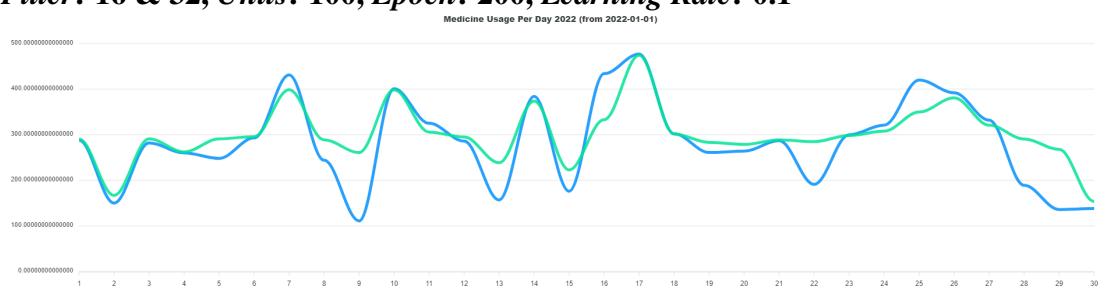
**Gambar 1.1** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.1* dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

#### 2. *Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.1*



**Gambar 1.2** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.1* dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

#### 3. *Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.1*

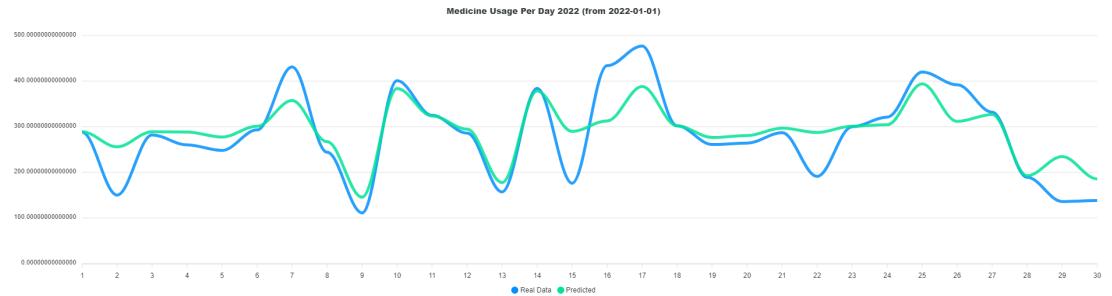


**Gambar 1.3** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.1* dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

#### 4. *Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.1*

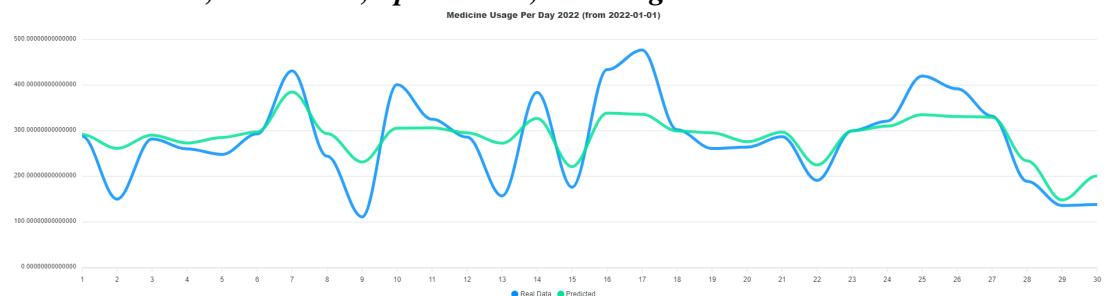
## BAB A Hasil Pengujian Arsitektur 1

---



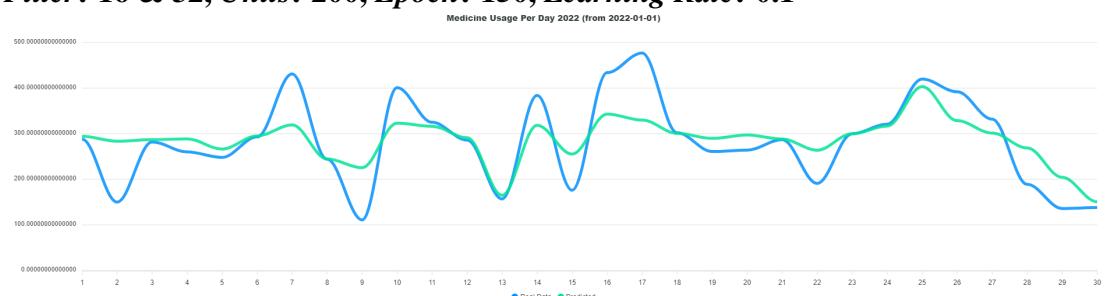
**Gambar 1.4** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 5. *Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.1*



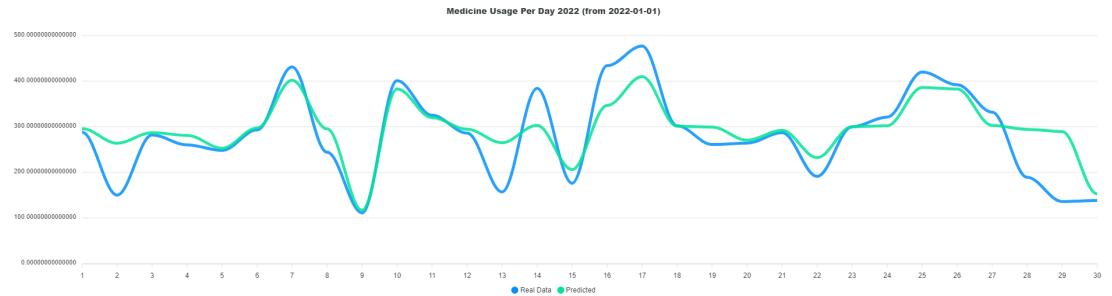
**Gambar 1.5** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 6. *Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.1*



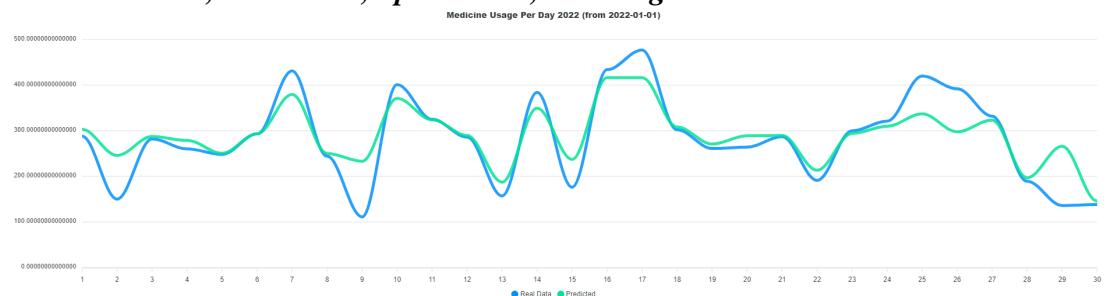
**Gambar 1.6** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 7. *Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.1*



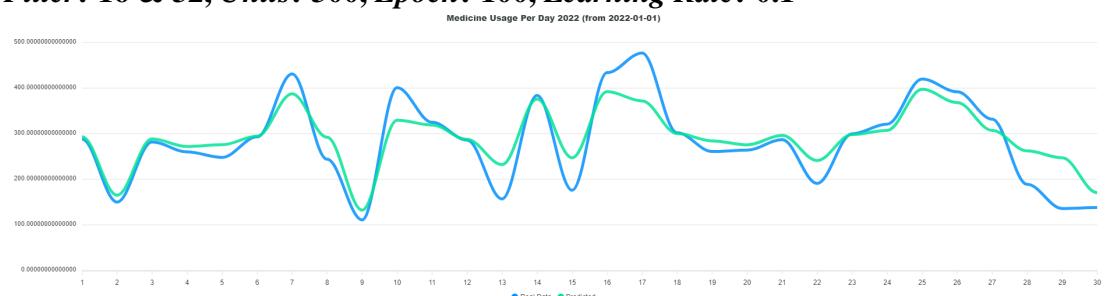
**Gambar 1.7** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 8. *Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.1*



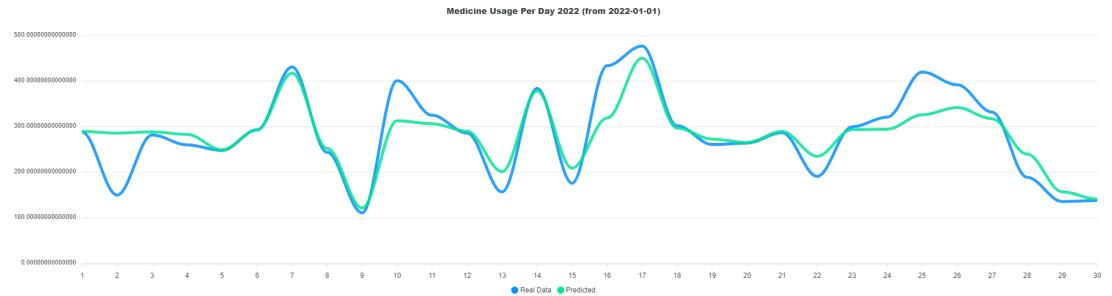
**Gambar 1.8** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 9. *Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.1*



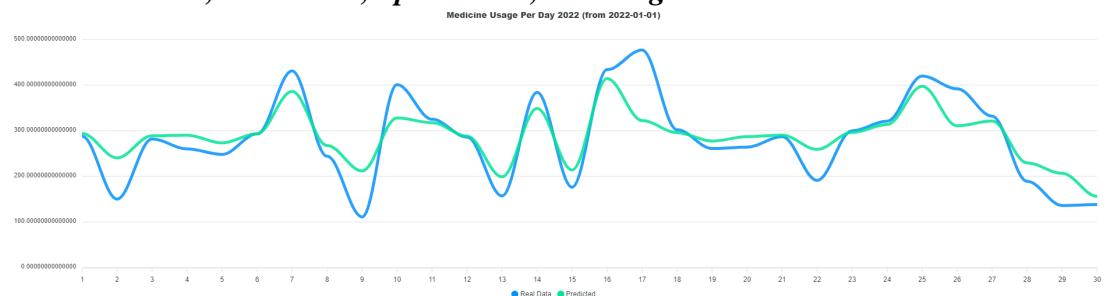
**Gambar 1.9** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 10. *Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.1*



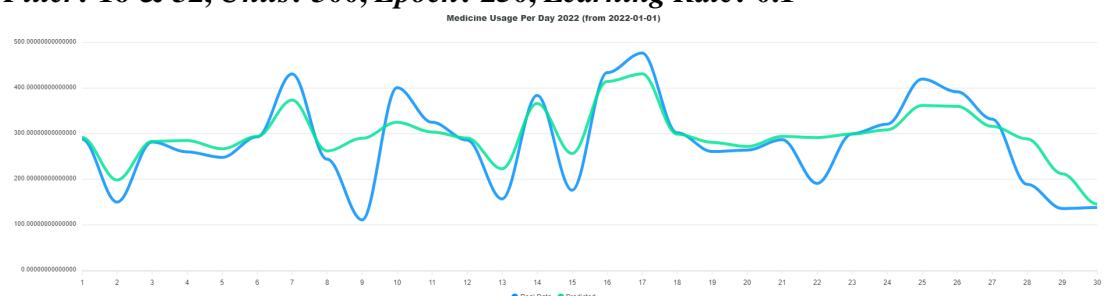
**Gambar 1.10** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 11. *Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.1*



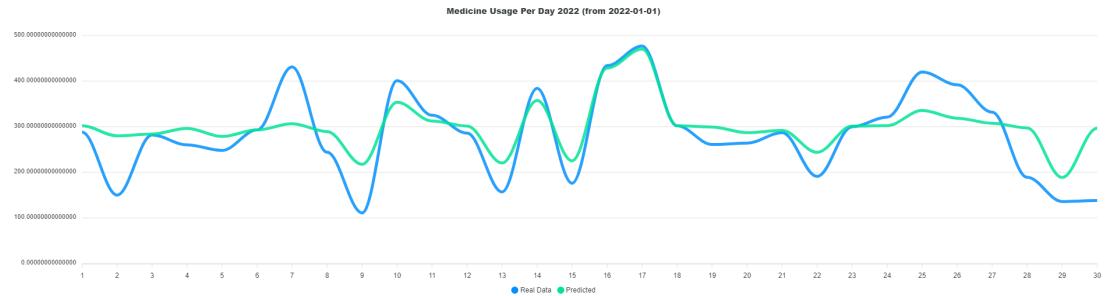
**Gambar 1.11** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 12. *Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.1*



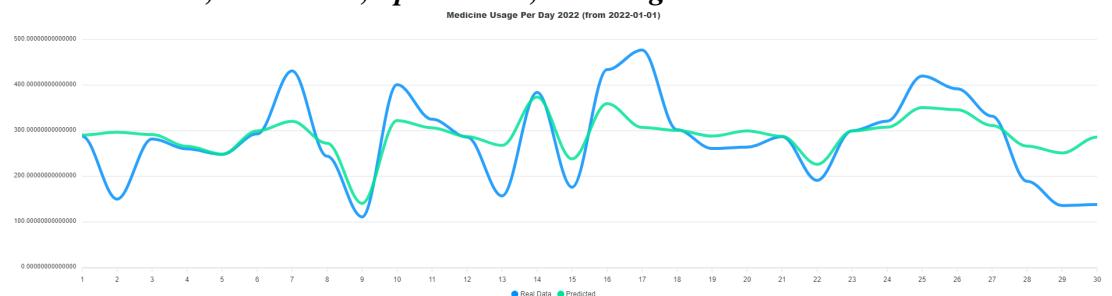
**Gambar 1.12** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 13. *Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.1*



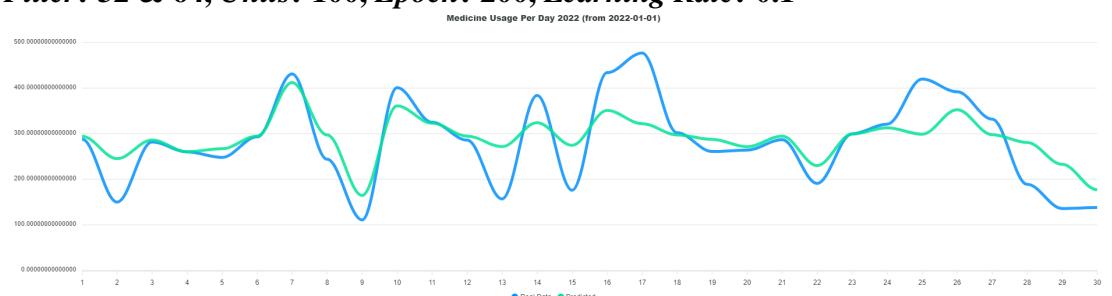
**Gambar 1.13** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 14. *Filter: 32 & 64, Units: 100, Epoch: 150, Learning Rate: 0.1*



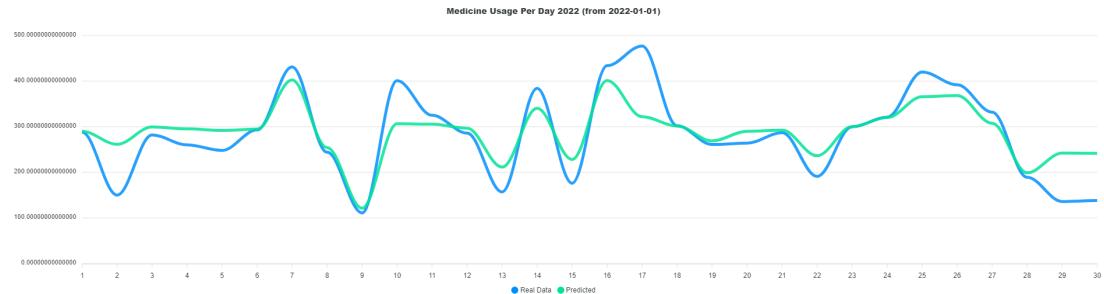
**Gambar 1.14** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 15. *Filter: 32 & 64, Units: 100, Epoch: 200, Learning Rate: 0.1*



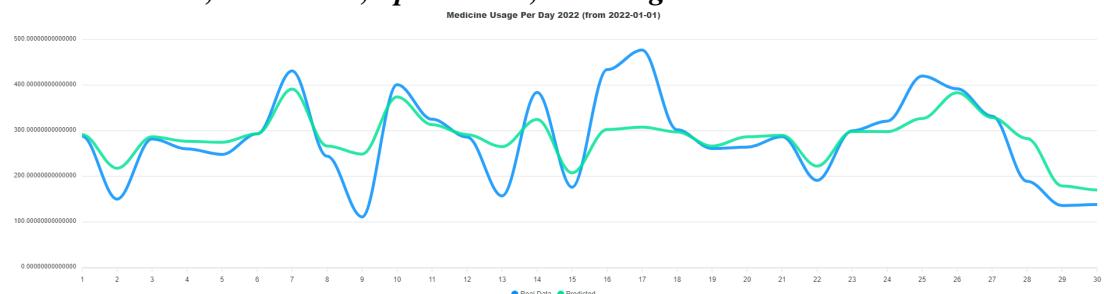
**Gambar 1.15** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 16. *Filter: 32 & 64, Units: 100, Epoch: 250, Learning Rate: 0.1*



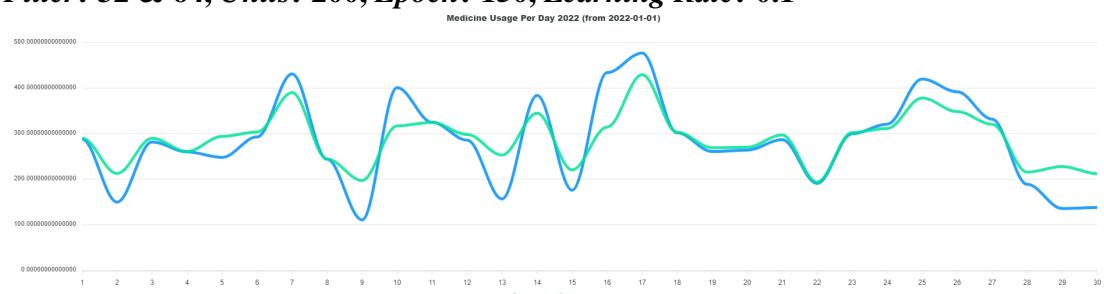
**Gambar 1.16** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 17. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.1



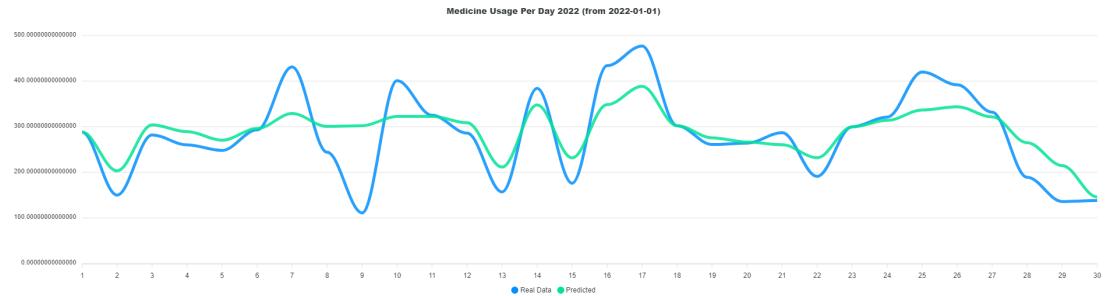
**Gambar 1.17** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 18. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.1



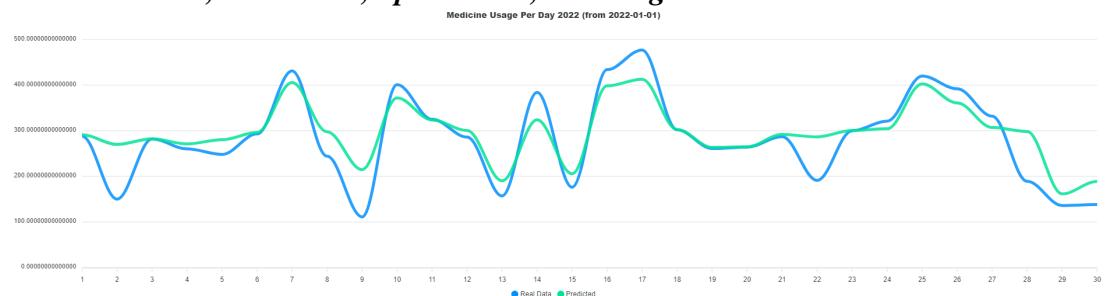
**Gambar 1.18** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 19. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.1



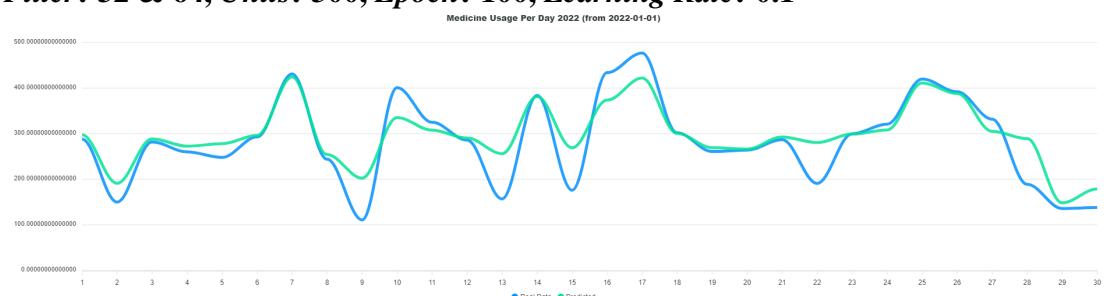
**Gambar 1.19** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 20. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1



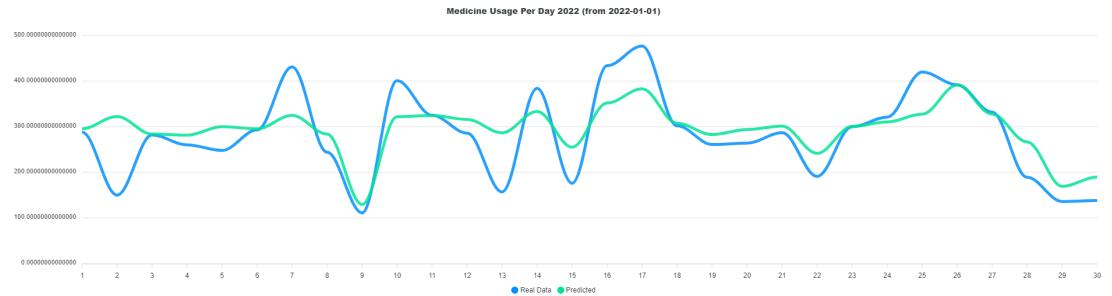
**Gambar 1.20** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 21. *Filter*: 32 & 64, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1



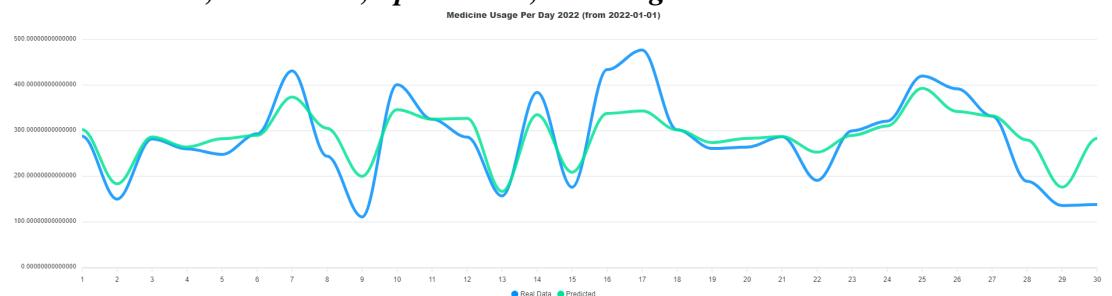
**Gambar 1.21** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 22. *Filter*: 32 & 64, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1



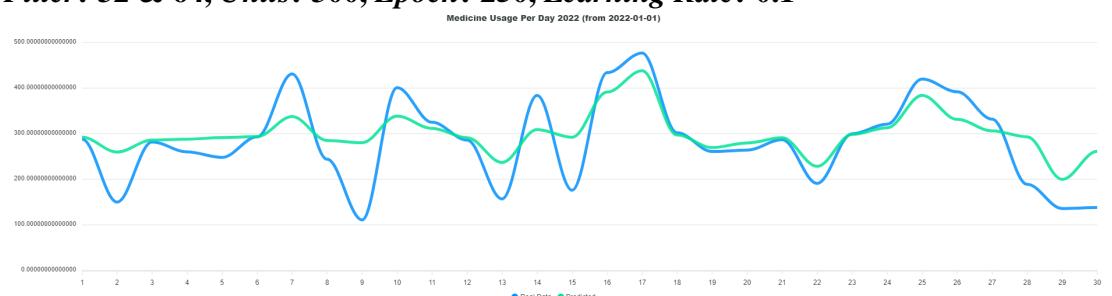
**Gambar 1.22** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 23. *Filter: 32 & 64, Units: 300, Epoch: 200, Learning Rate: 0.1*



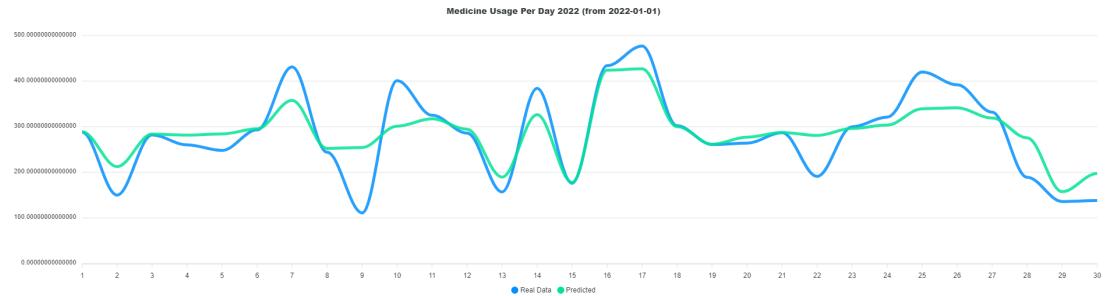
**Gambar 1.23** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 24. *Filter: 32 & 64, Units: 300, Epoch: 250, Learning Rate: 0.1*



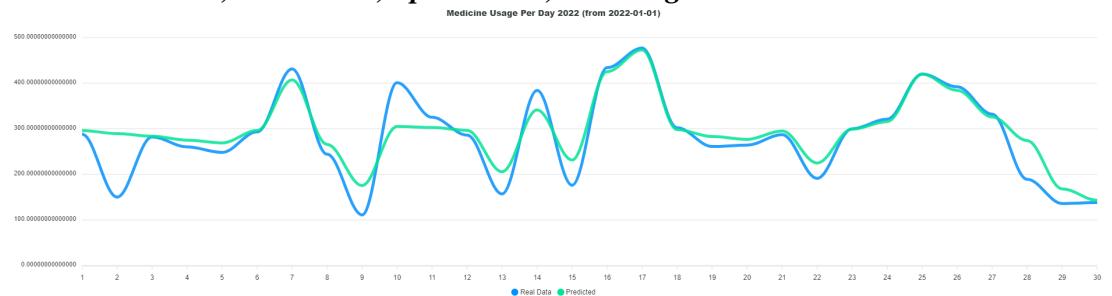
**Gambar 1.24** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 25. *Filter: 64 & 128, Units: 100, Epoch: 100, Learning Rate: 0.1*



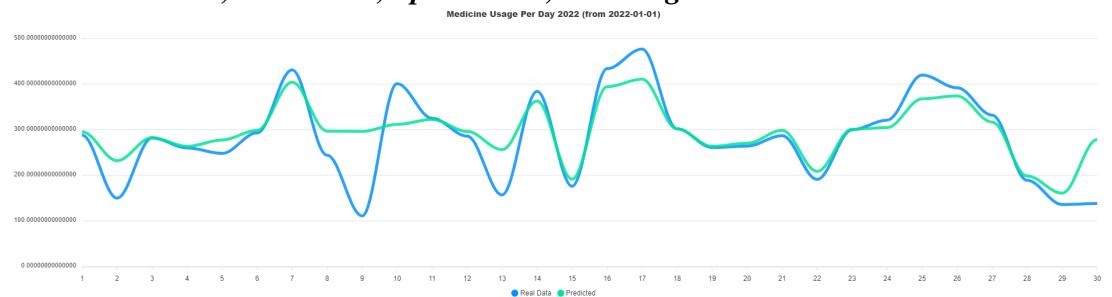
**Gambar 1.25** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 26. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.1



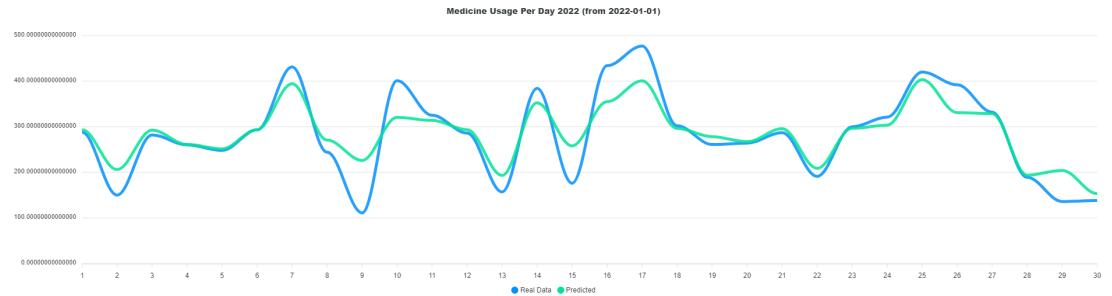
**Gambar 1.26** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 27. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.1



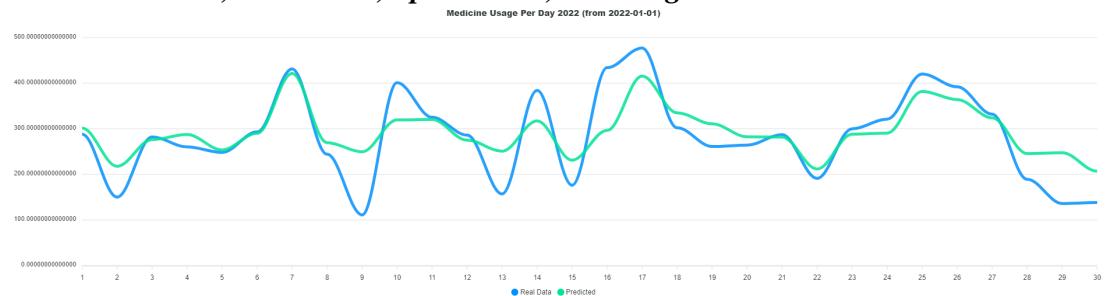
**Gambar 1.27** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 28. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.1



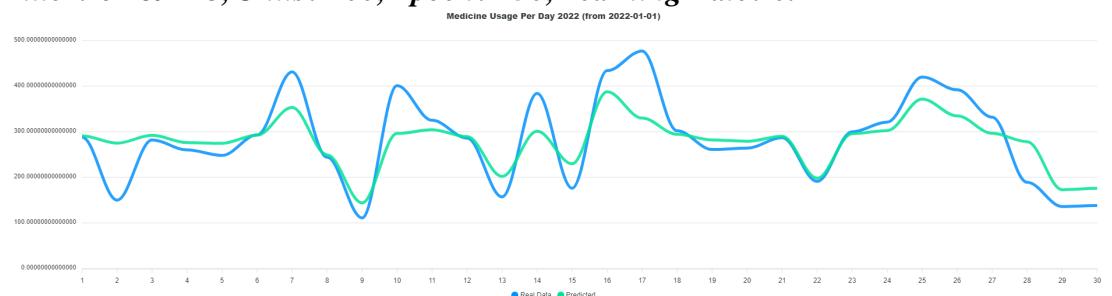
**Gambar 1.28** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 29. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.1



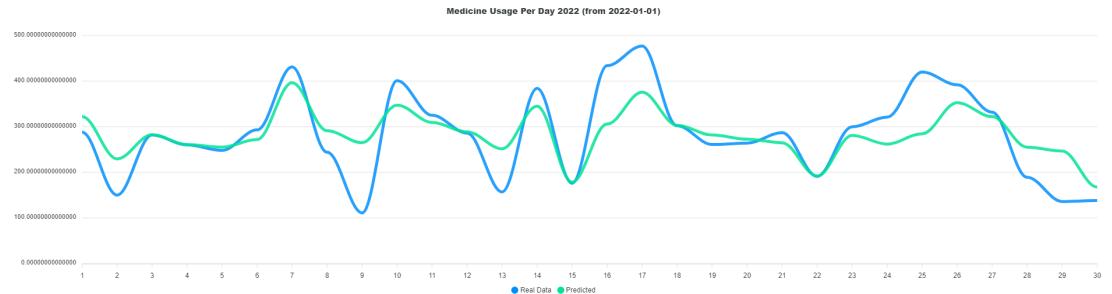
**Gambar 1.29** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 30. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.1



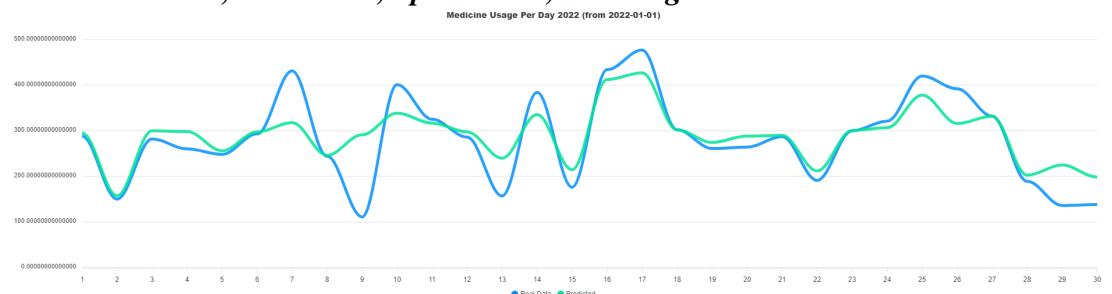
**Gambar 1.30** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 31. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.1



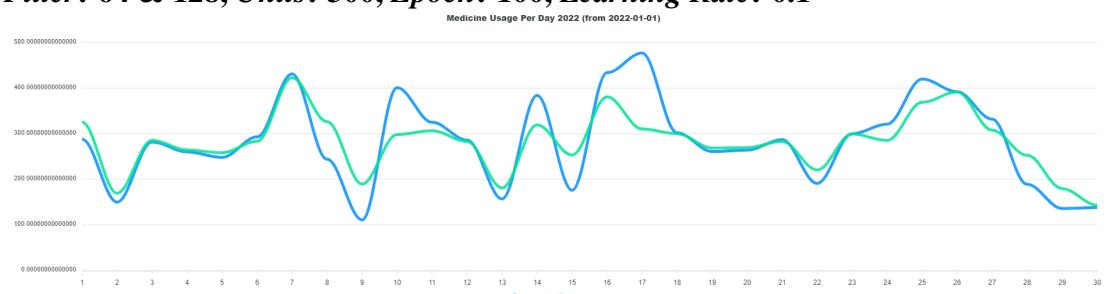
**Gambar 1.31** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 32. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1



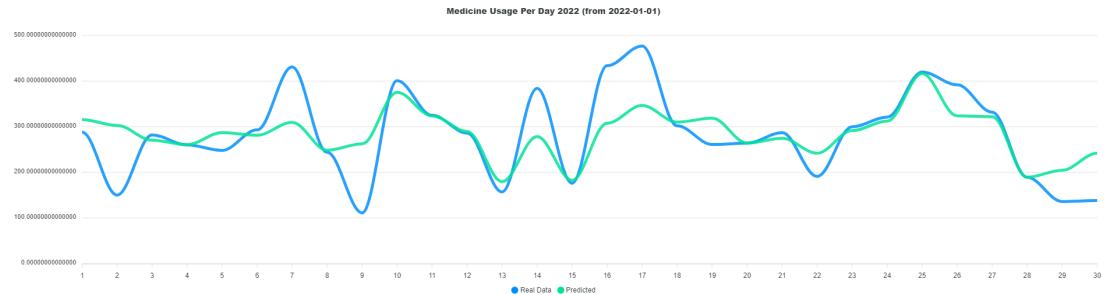
**Gambar 1.32** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 33. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1



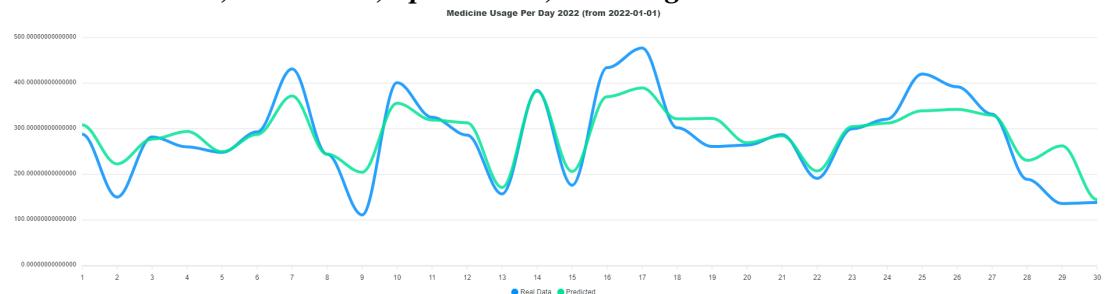
**Gambar 1.33** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 34. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1



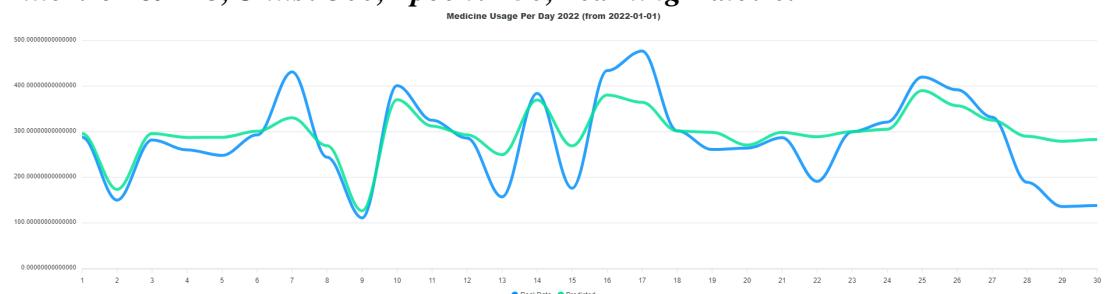
**Gambar 1.34** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 35. *Filter: 64 & 128, Units: 300, Epoch: 200, Learning Rate: 0.1*



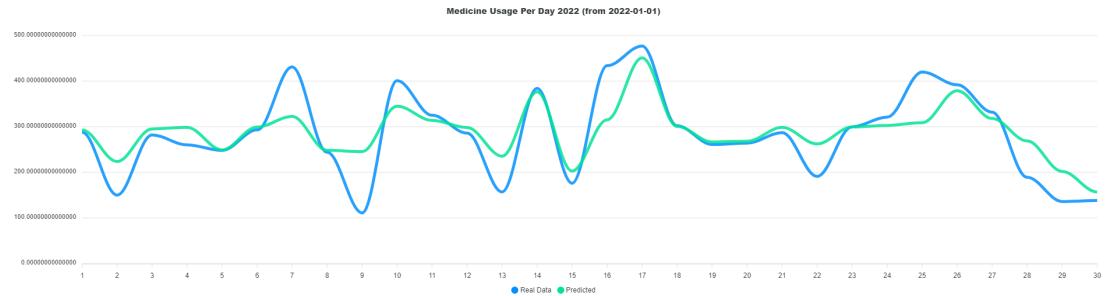
**Gambar 1.35** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 36. *Filter: 64 & 128, Units: 300, Epoch: 250, Learning Rate: 0.1*



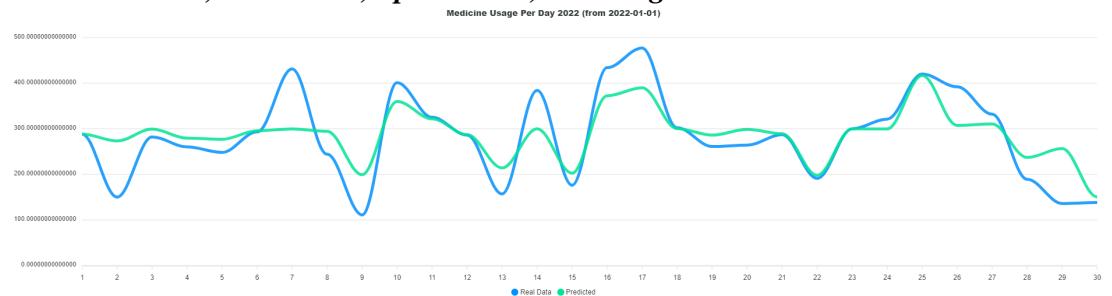
**Gambar 1.36** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 37. *Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.01*



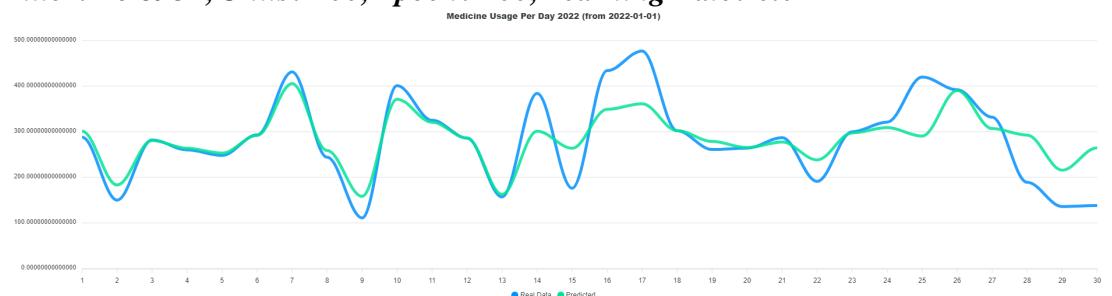
**Gambar 1.37** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 38. *Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.01*



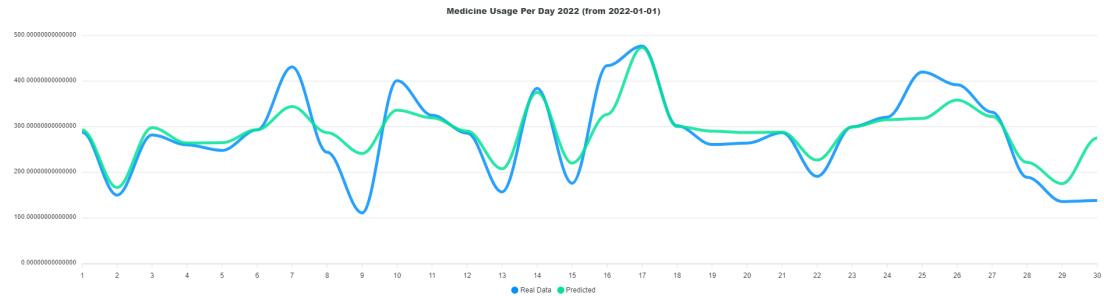
**Gambar 1.38** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 39. *Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.01*



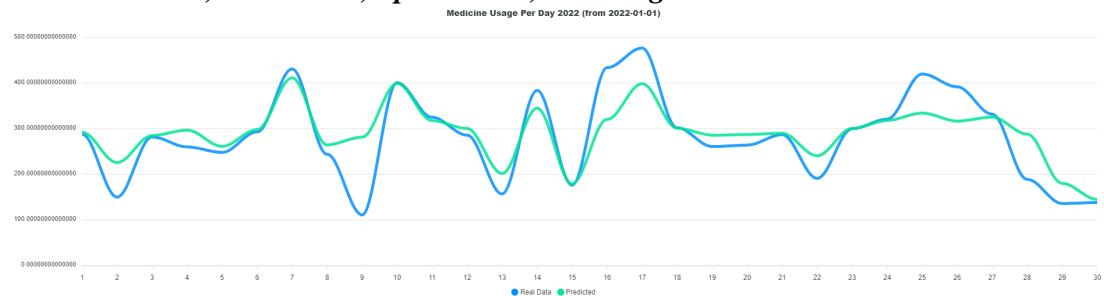
**Gambar 1.39** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 40. *Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.01*



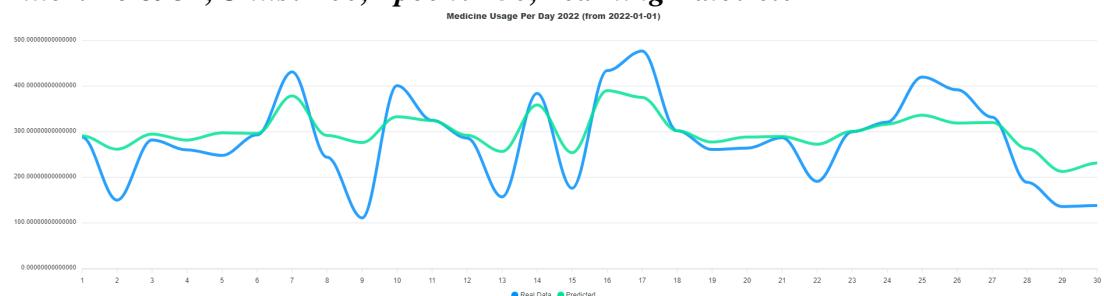
**Gambar 1.40** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 41. *Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.01*



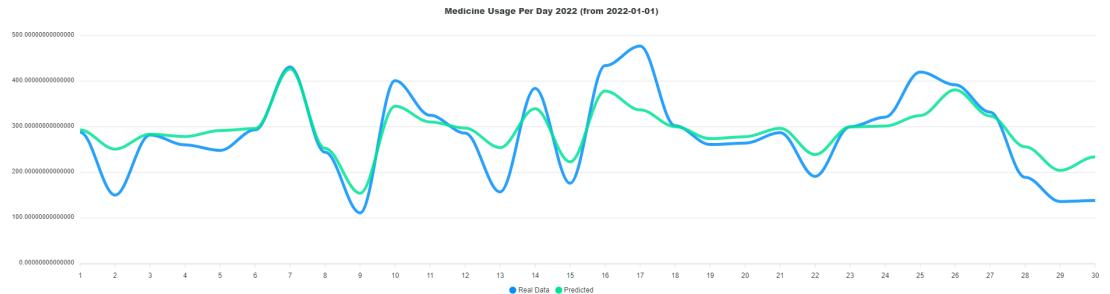
**Gambar 1.41** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 42. *Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.01*



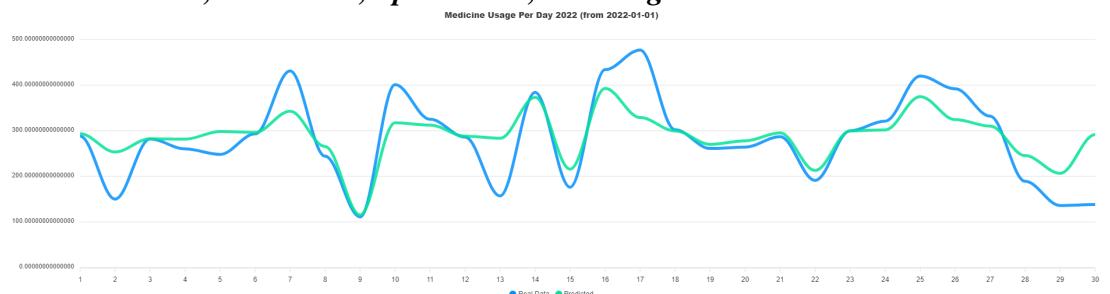
**Gambar 1.42** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 43. *Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.01*



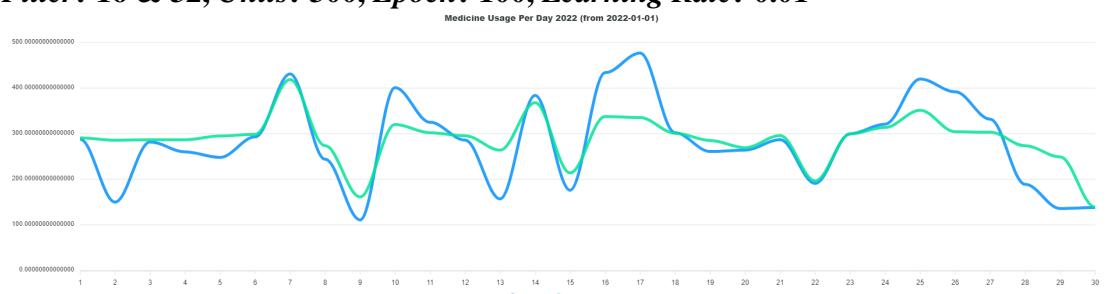
**Gambar 1.43** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 44. *Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.01*



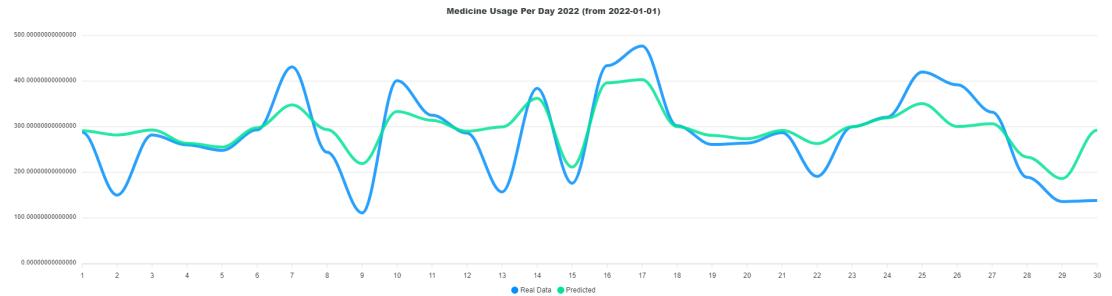
**Gambar 1.44** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 45. *Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.01*



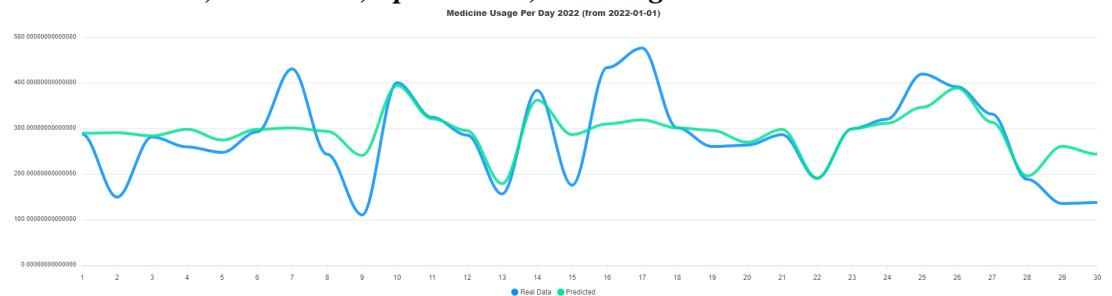
**Gambar 1.45** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 46. *Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.01*



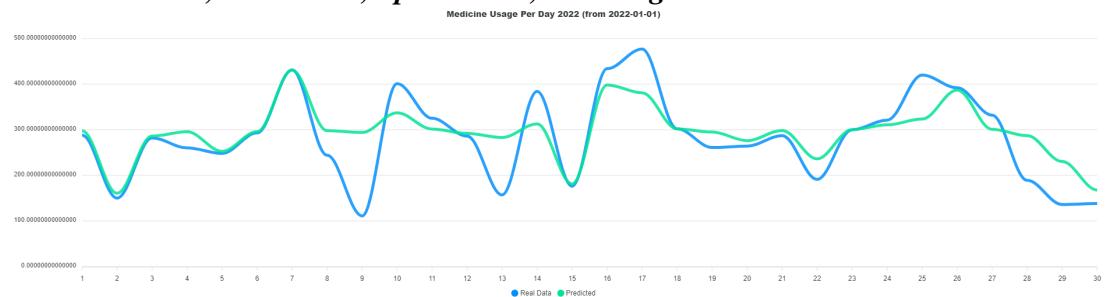
**Gambar 1.46** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 47. *Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.01*



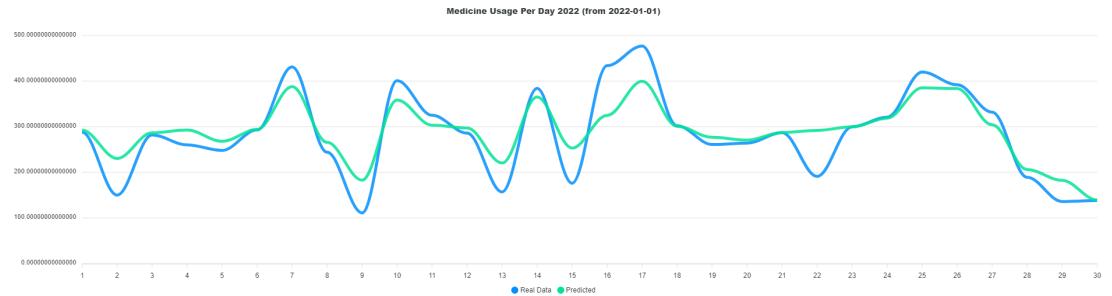
**Gambar 1.47** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 48. *Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.01*



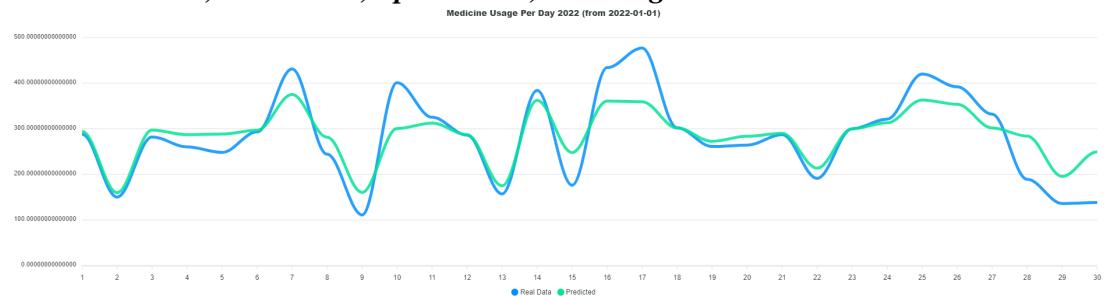
**Gambar 1.48** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 49. *Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.01*



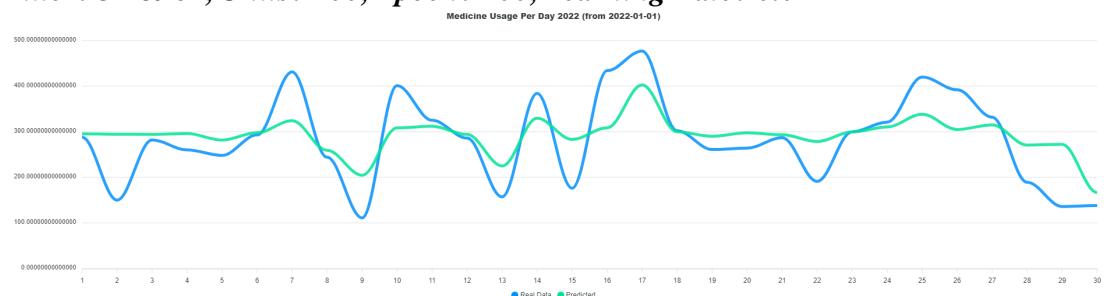
**Gambar 1.49** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 50. *Filter: 32 & 64, Units: 100, Epoch: 150, Learning Rate: 0.01*



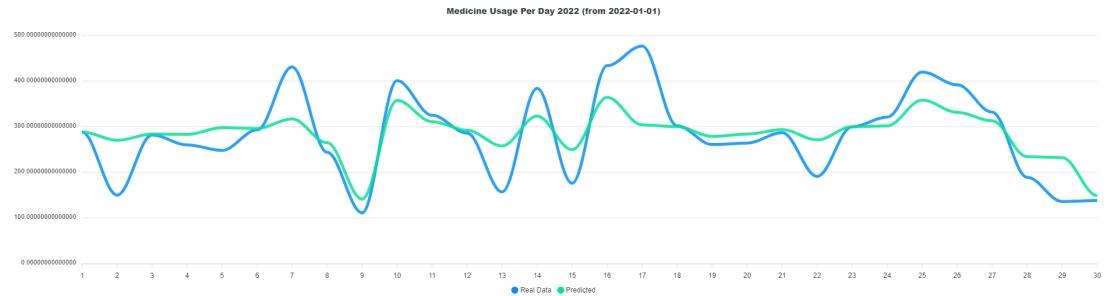
**Gambar 1.50** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 51. *Filter: 32 & 64, Units: 100, Epoch: 200, Learning Rate: 0.01*



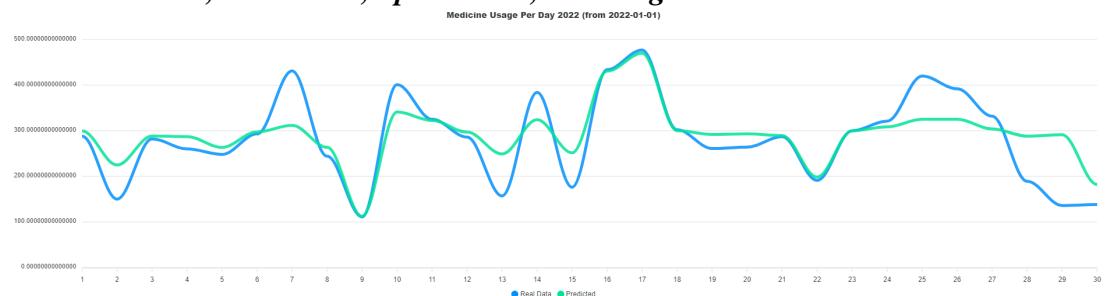
**Gambar 1.51** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 52. *Filter: 32 & 64, Units: 100, Epoch: 250, Learning Rate: 0.01*



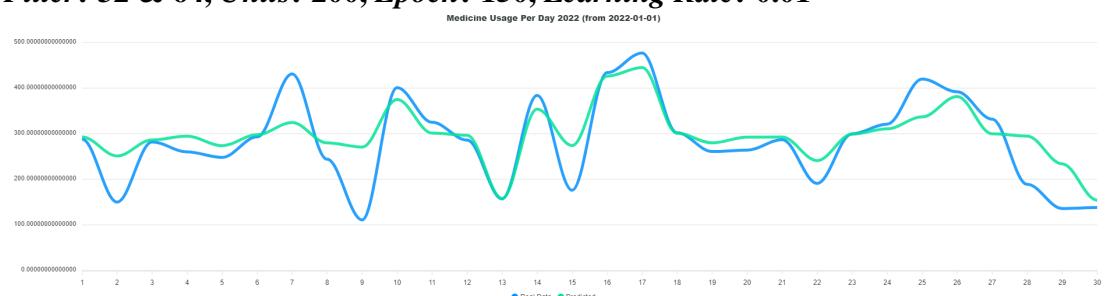
**Gambar 1.52** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 53. *Filter: 32 & 64, Units: 200, Epoch: 100, Learning Rate: 0.01*



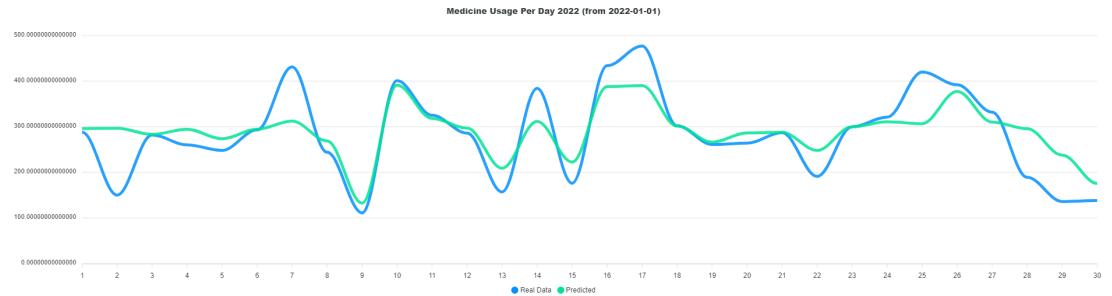
**Gambar 1.53** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 54. *Filter: 32 & 64, Units: 200, Epoch: 150, Learning Rate: 0.01*



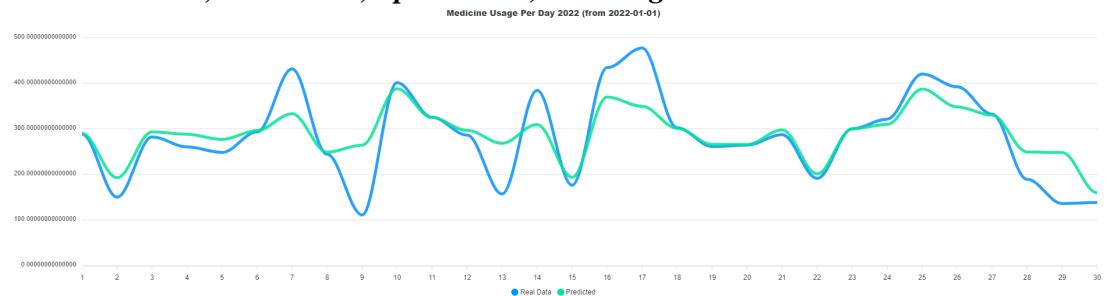
**Gambar 1.54** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 55. *Filter: 32 & 64, Units: 200, Epoch: 200, Learning Rate: 0.01*



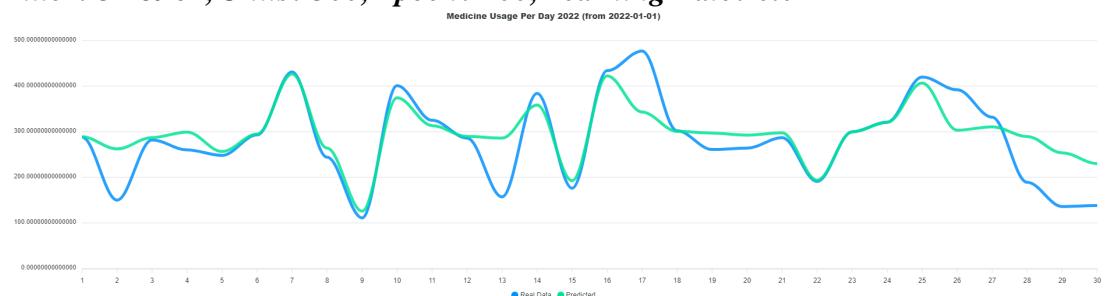
**Gambar 1.55** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 56. *Filter: 32 & 64, Units: 200, Epoch: 250, Learning Rate: 0.01*



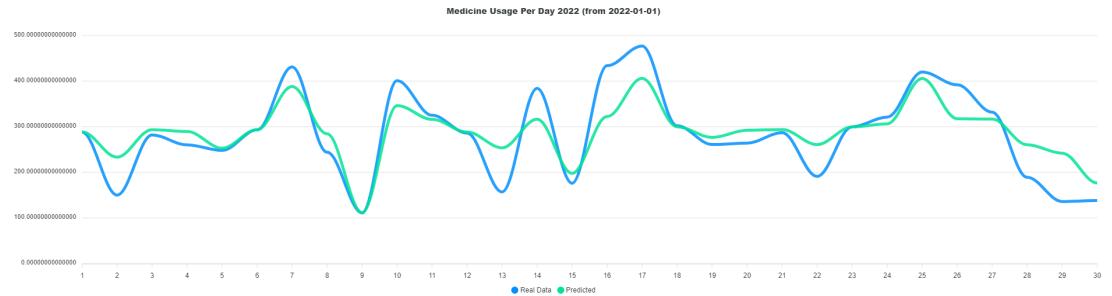
**Gambar 1.56** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 57. *Filter: 32 & 64, Units: 300, Epoch: 100, Learning Rate: 0.01*



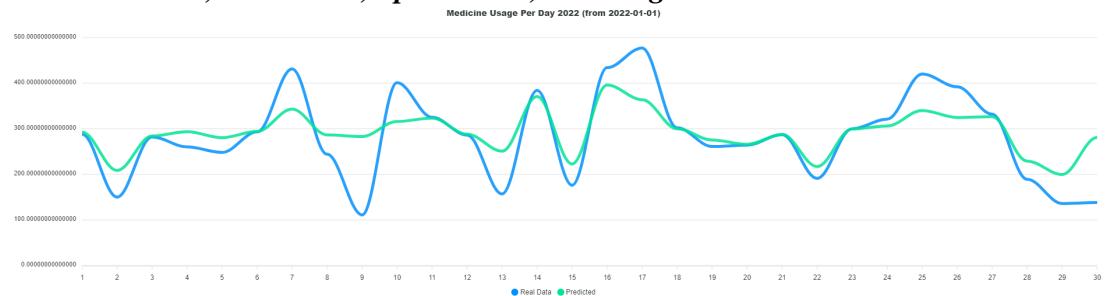
**Gambar 1.57** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 58. *Filter: 32 & 64, Units: 300, Epoch: 150, Learning Rate: 0.01*



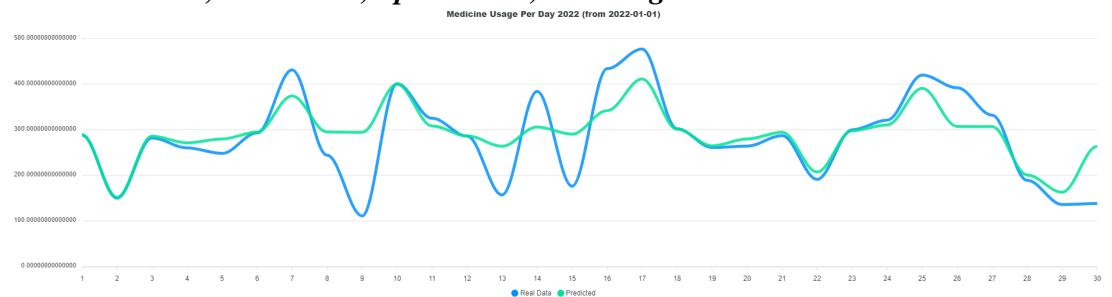
**Gambar 1.58** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 59. *Filter: 32 & 64, Units: 300, Epoch: 200, Learning Rate: 0.01*



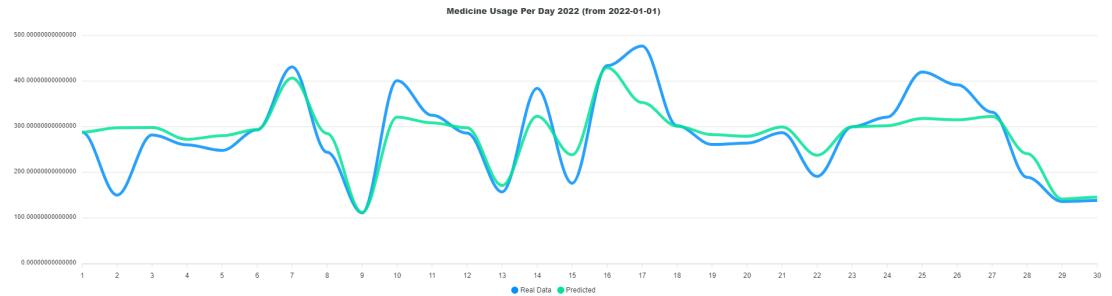
**Gambar 1.59** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 60. *Filter: 32 & 64, Units: 300, Epoch: 250, Learning Rate: 0.01*



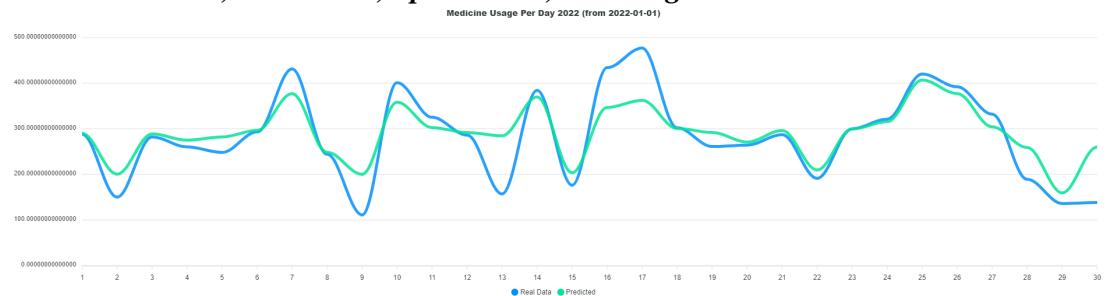
**Gambar 1.60** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 61. *Filter: 64 & 128, Units: 100, Epoch: 100, Learning Rate: 0.01*



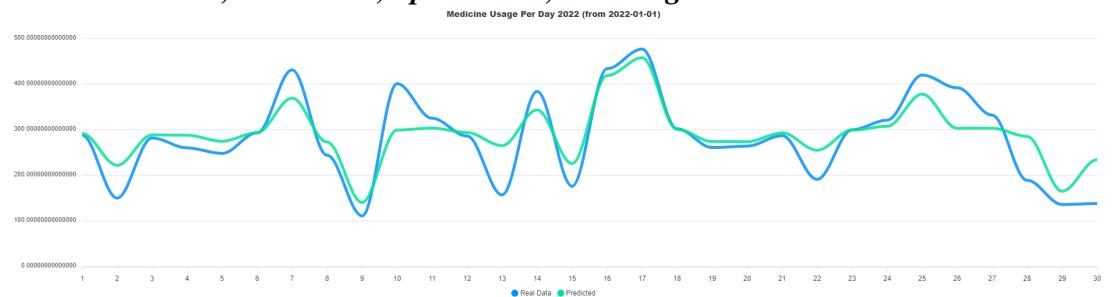
**Gambar 1.61** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 62. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01



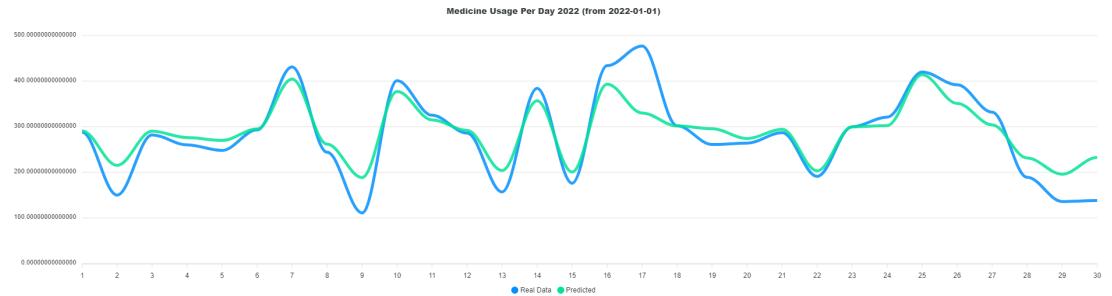
**Gambar 1.62** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 63. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01



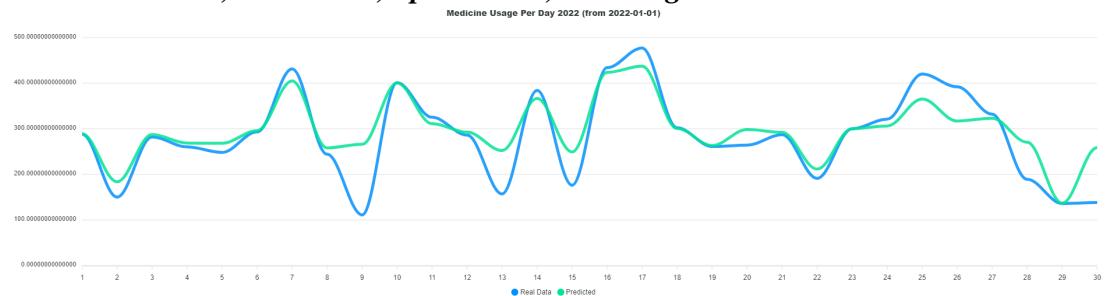
**Gambar 1.63** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 64. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01



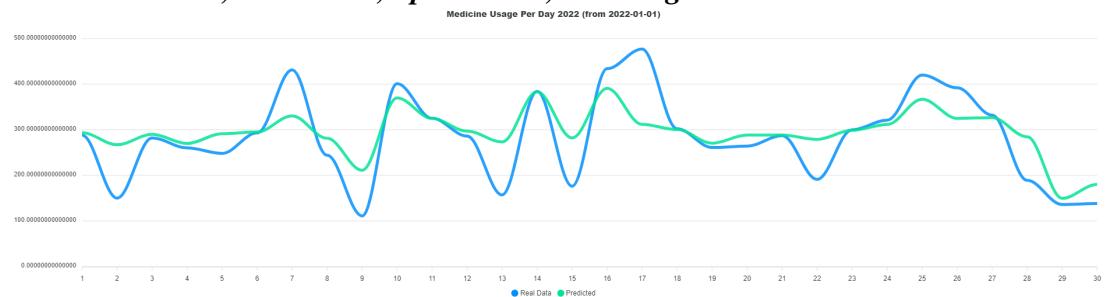
**Gambar 1.64** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 65. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.01



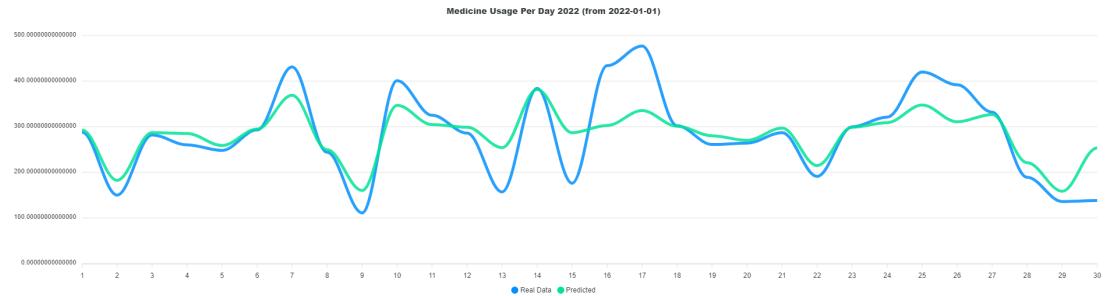
**Gambar 1.65** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 66. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.01



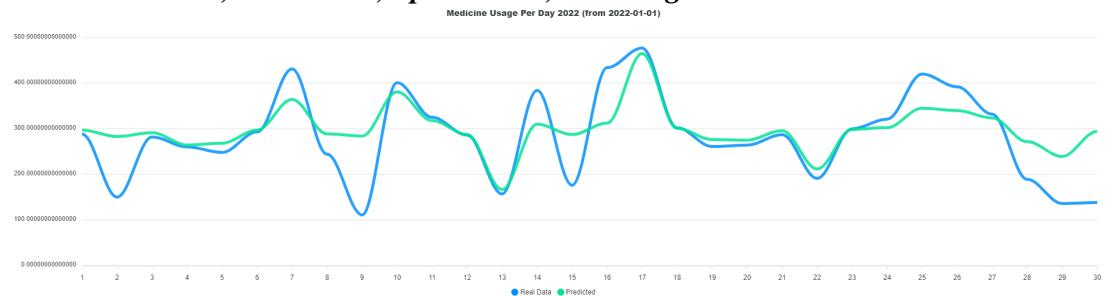
**Gambar 1.66** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 67. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.01



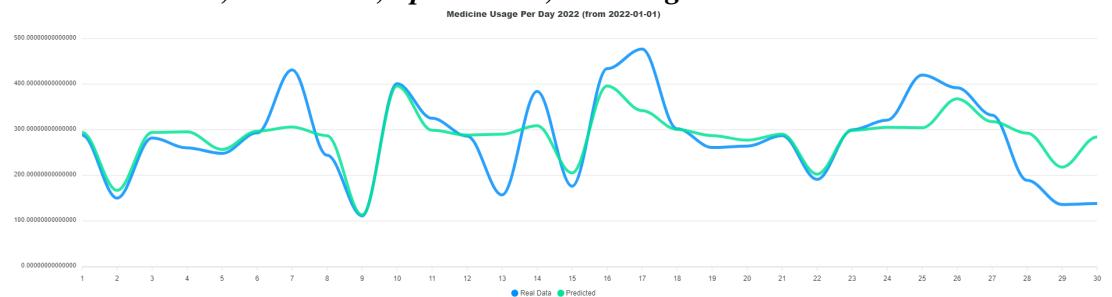
**Gambar 1.67** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 68. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.01



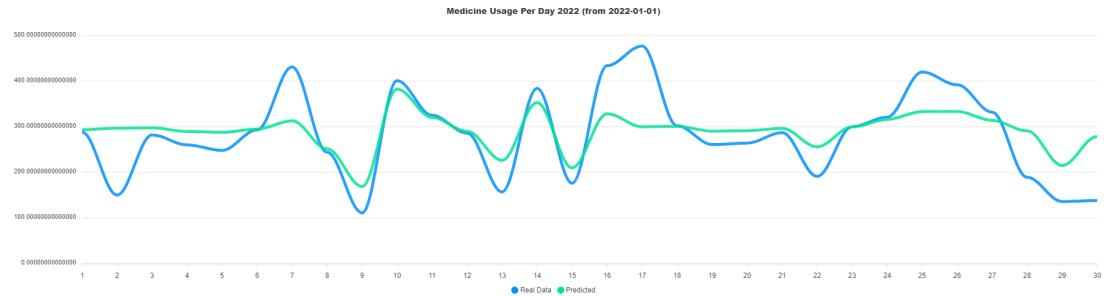
**Gambar 1.68** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 69. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.01



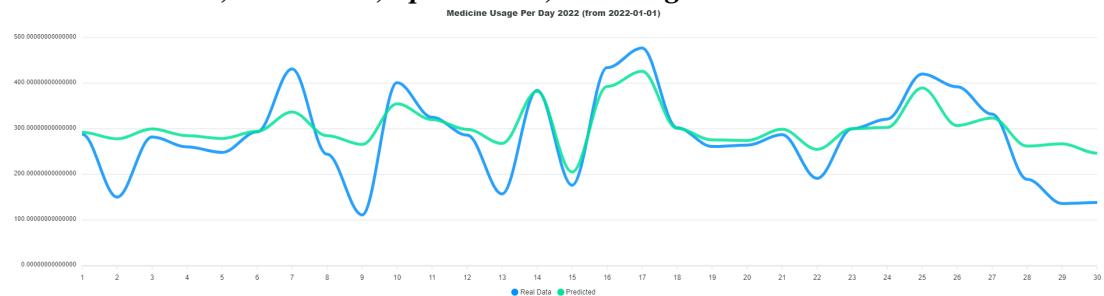
**Gambar 1.69** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 70. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.01



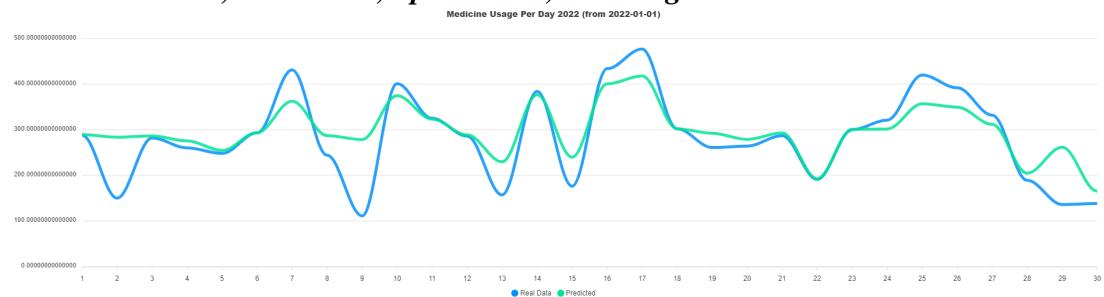
**Gambar 1.70** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 71. *Filter: 64 & 128, Units: 300, Epoch: 200, Learning Rate: 0.01*



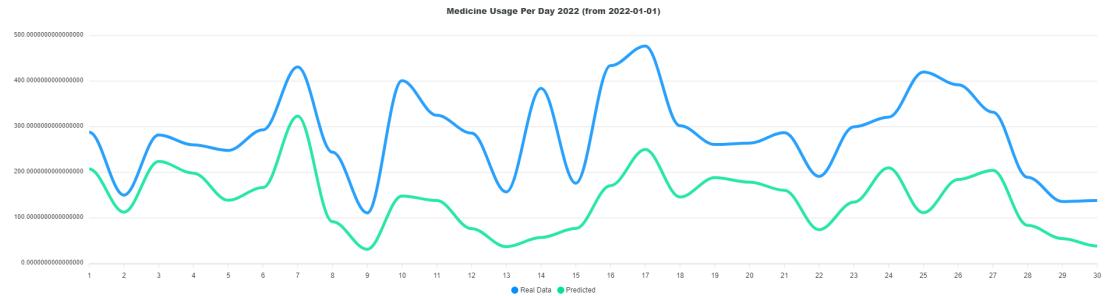
**Gambar 1.71** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 72. *Filter: 64 & 128, Units: 300, Epoch: 250, Learning Rate: 0.01*



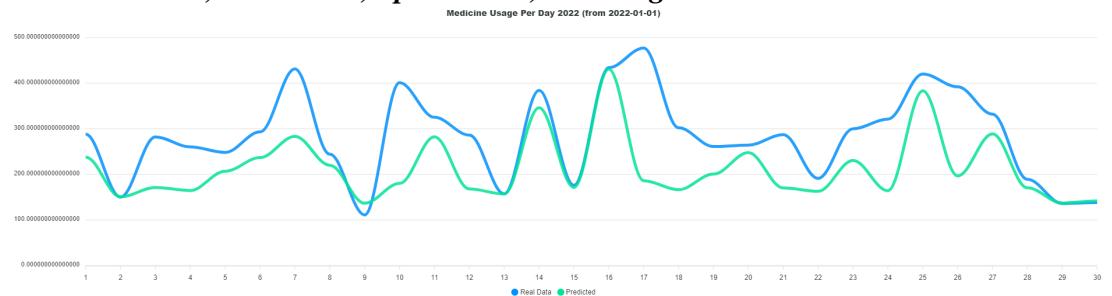
**Gambar 1.72** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 73. *Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.001*



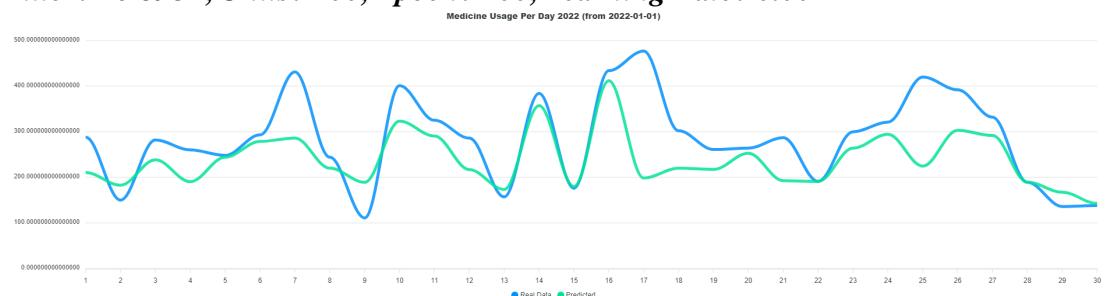
**Gambar 1.73** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 74. *Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.001*



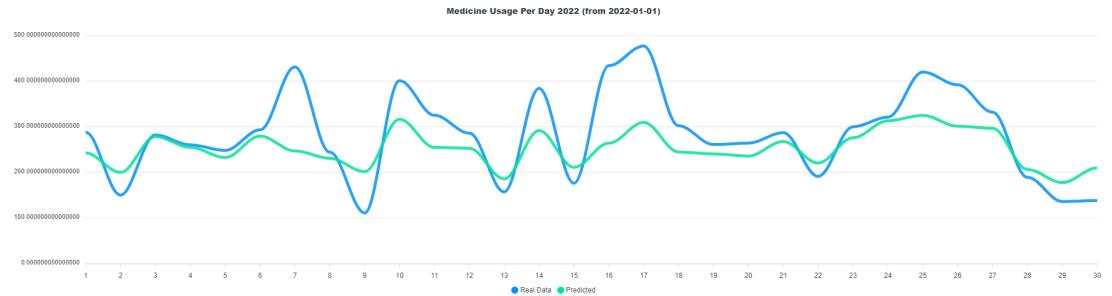
**Gambar 1.74** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 75. *Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.001*



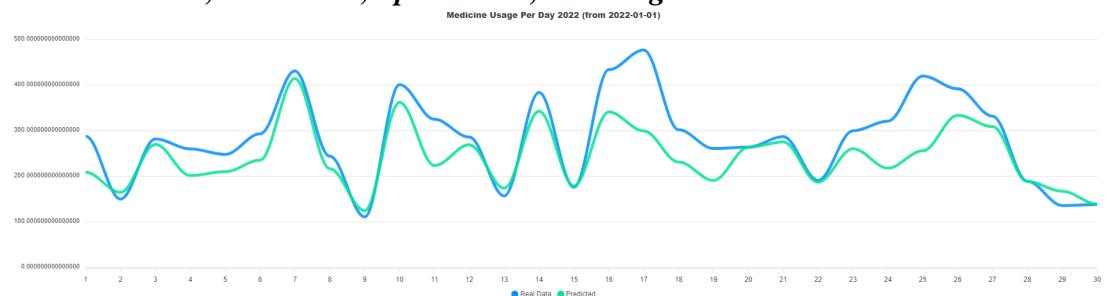
**Gambar 1.75** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 76. *Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.001*



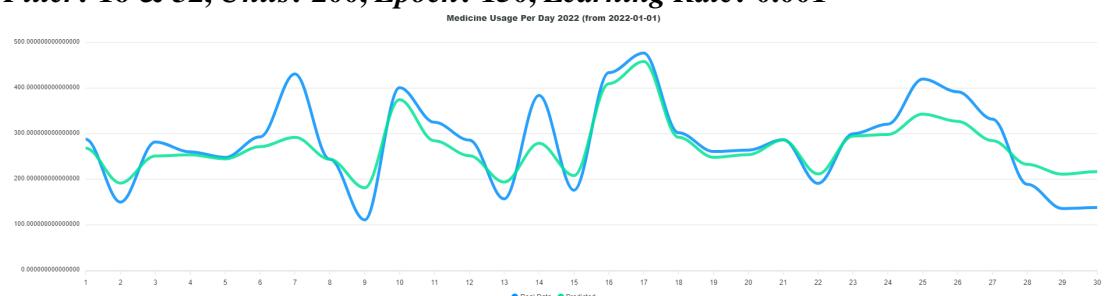
**Gambar 1.76** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 77. *Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.001*



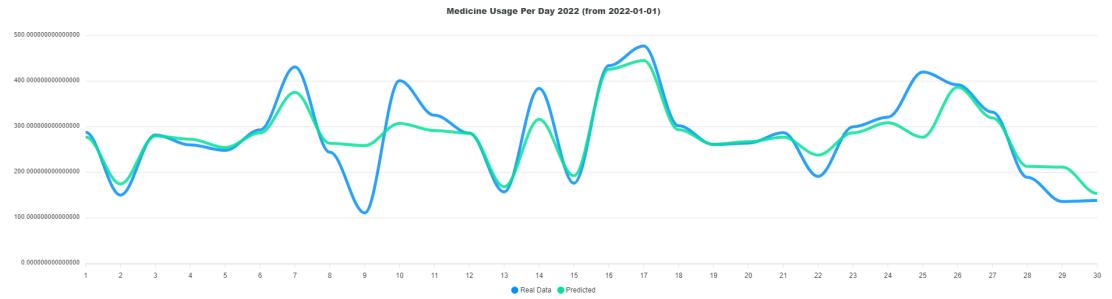
**Gambar 1.77** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 78. *Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.001*



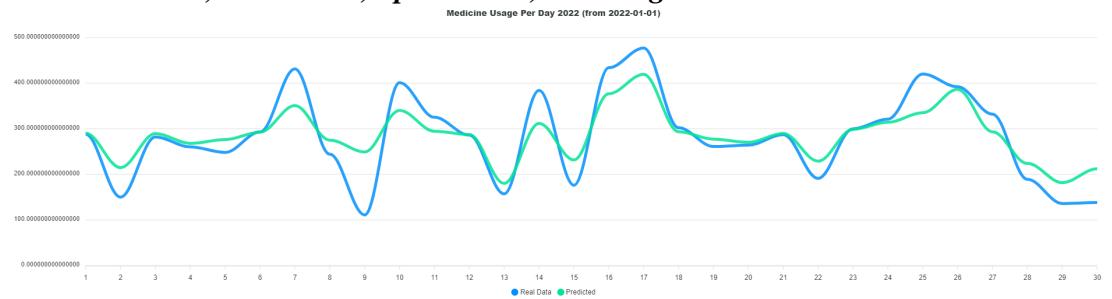
**Gambar 1.78** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 79. *Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.001*



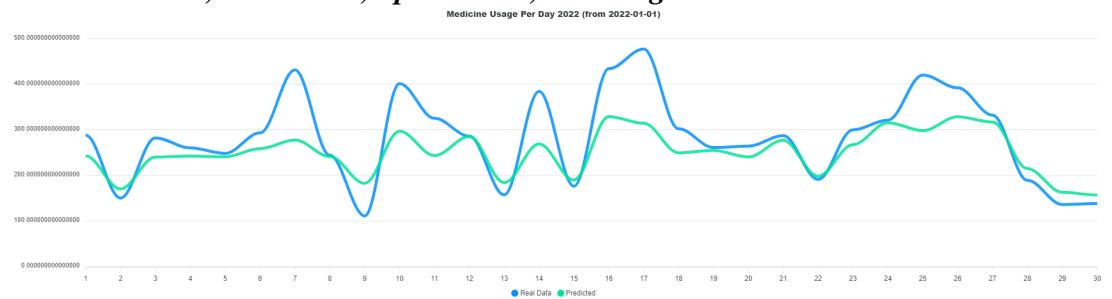
**Gambar 1.79** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 80. *Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.001*



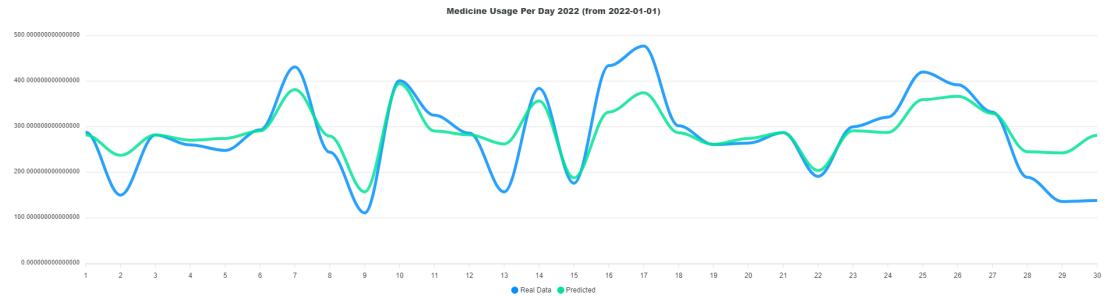
**Gambar 1.80** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 81. *Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.001*



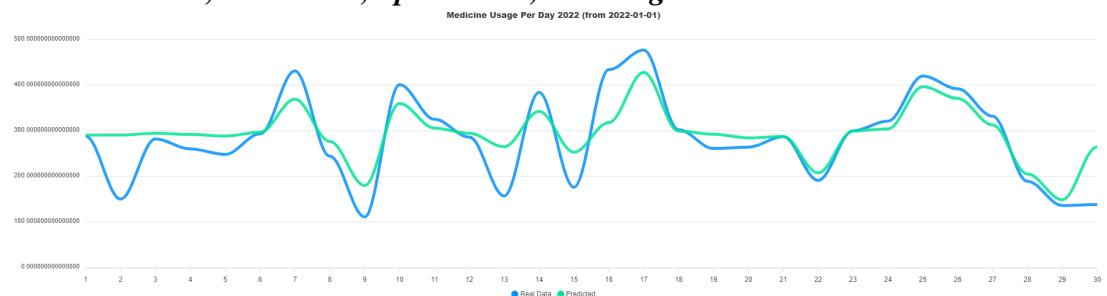
**Gambar 1.81** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 82. *Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.001*



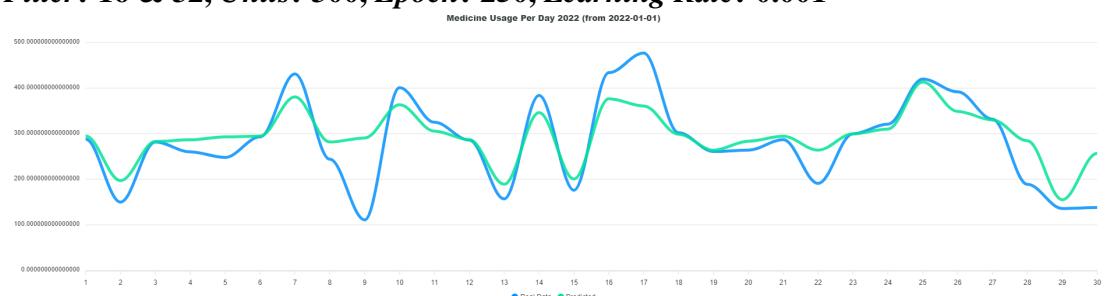
**Gambar 1.82** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 83. *Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.001*



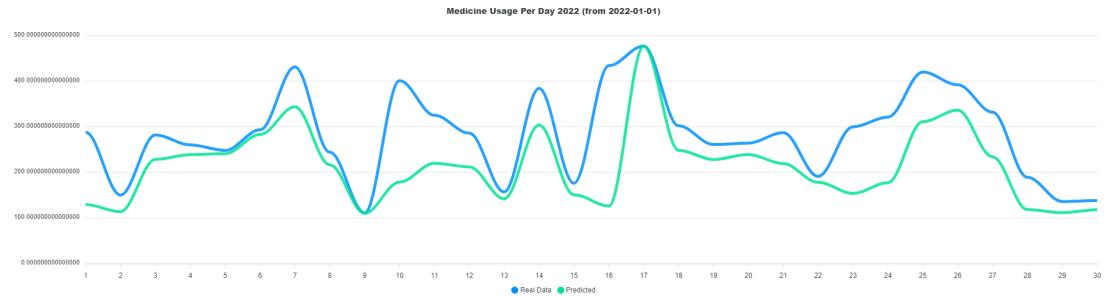
**Gambar 1.83** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 84. *Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.001*



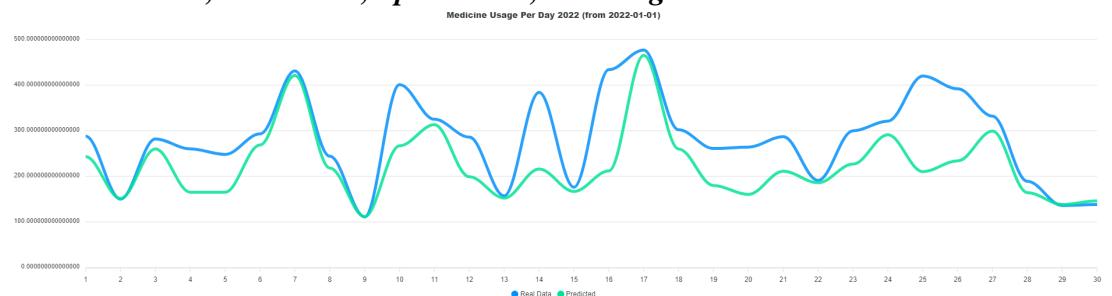
**Gambar 1.84** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 85. *Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.001*



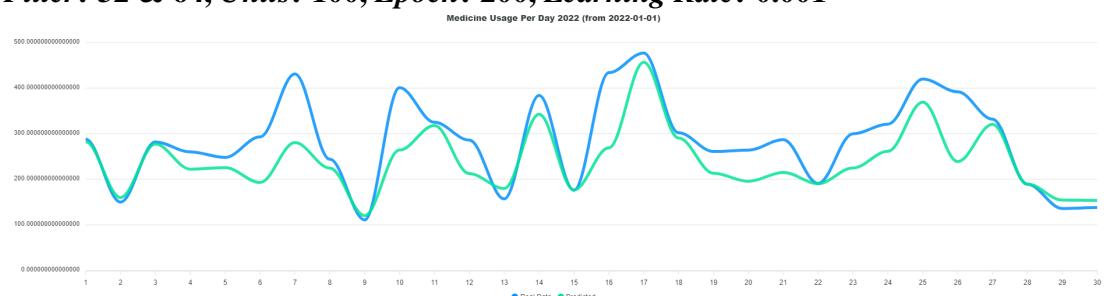
**Gambar 1.85** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 86. *Filter: 32 & 64, Units: 100, Epoch: 150, Learning Rate: 0.001*



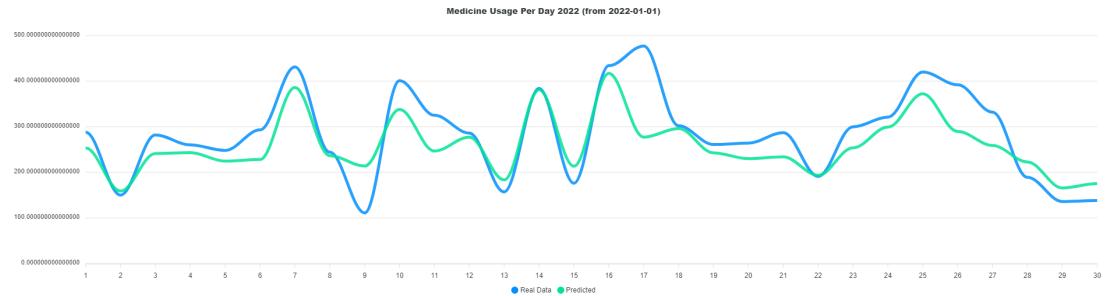
**Gambar 1.86** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 87. *Filter: 32 & 64, Units: 100, Epoch: 200, Learning Rate: 0.001*



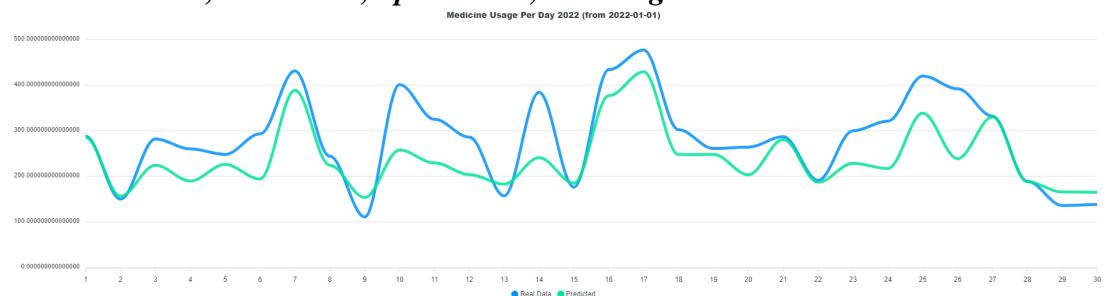
**Gambar 1.87** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 88. *Filter: 32 & 64, Units: 100, Epoch: 250, Learning Rate: 0.001*



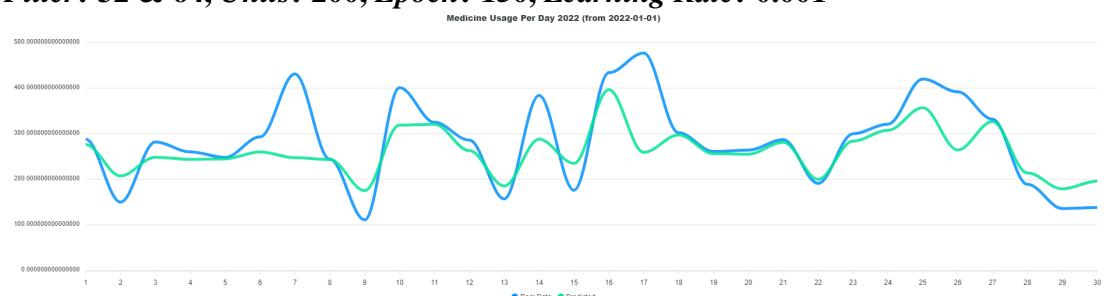
**Gambar 1.88** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 89. *Filter: 32 & 64, Units: 200, Epoch: 100, Learning Rate: 0.001*



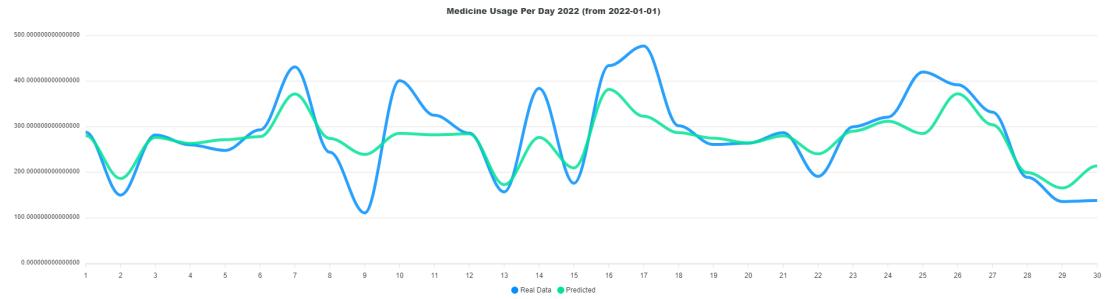
**Gambar 1.89** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 90. *Filter: 32 & 64, Units: 200, Epoch: 150, Learning Rate: 0.001*



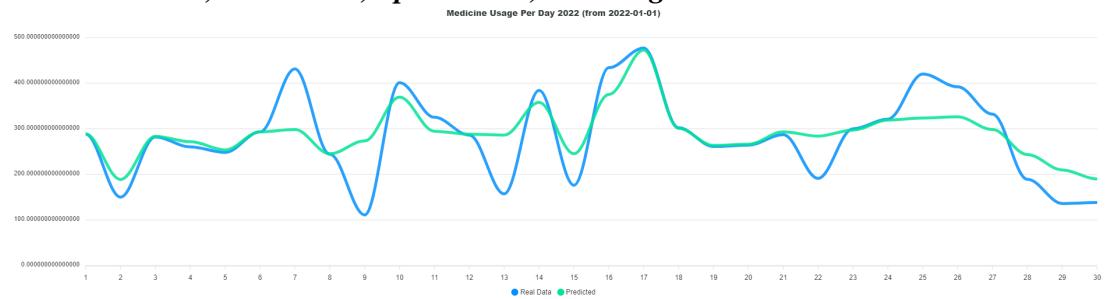
**Gambar 1.90** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 91. *Filter: 32 & 64, Units: 200, Epoch: 200, Learning Rate: 0.001*



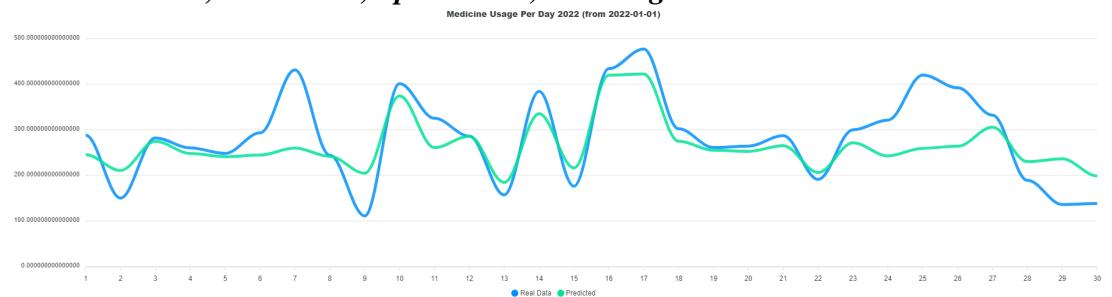
**Gambar 1.91** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 92. *Filter: 32 & 64, Units: 200, Epoch: 250, Learning Rate: 0.001*



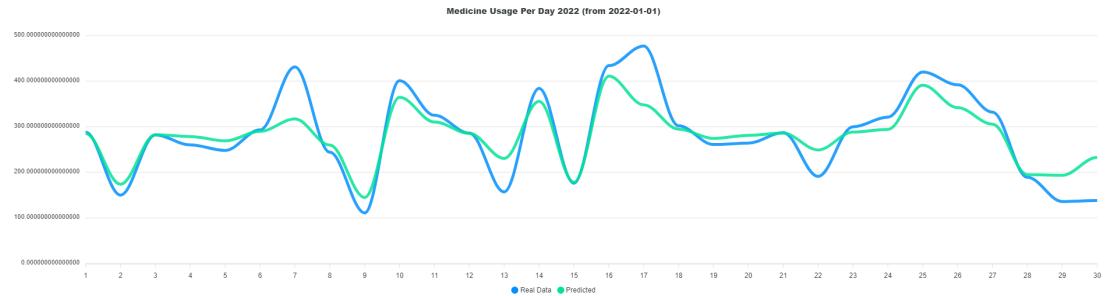
**Gambar 1.92** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 93. *Filter: 32 & 64, Units: 300, Epoch: 100, Learning Rate: 0.001*



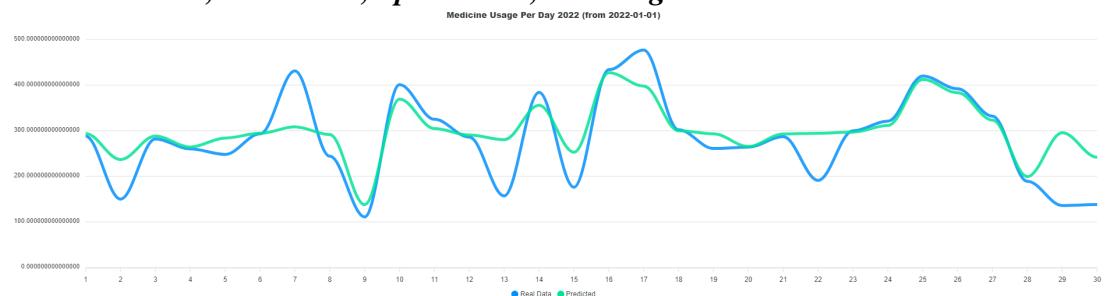
**Gambar 1.93** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 94. *Filter: 32 & 64, Units: 300, Epoch: 150, Learning Rate: 0.001*



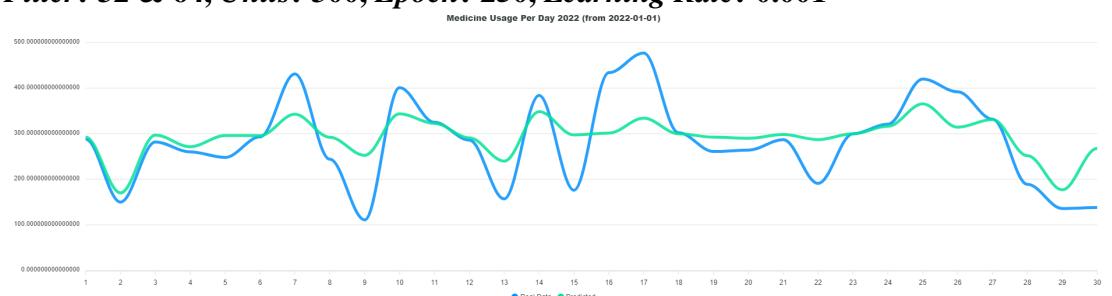
**Gambar 1.94** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 95. *Filter: 32 & 64, Units: 300, Epoch: 200, Learning Rate: 0.001*



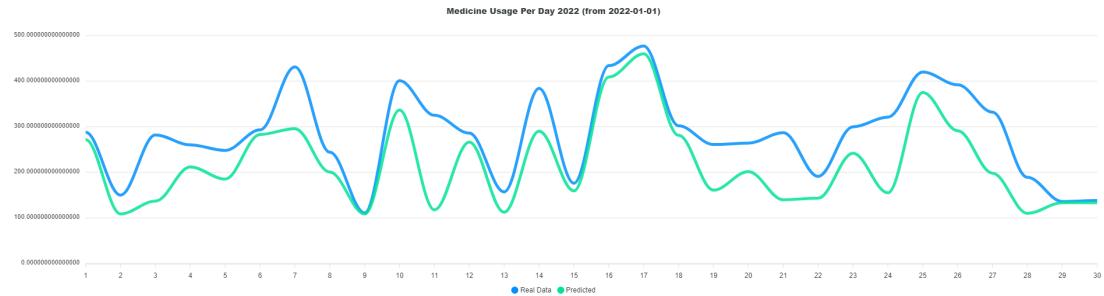
**Gambar 1.95** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 96. *Filter: 32 & 64, Units: 300, Epoch: 250, Learning Rate: 0.001*



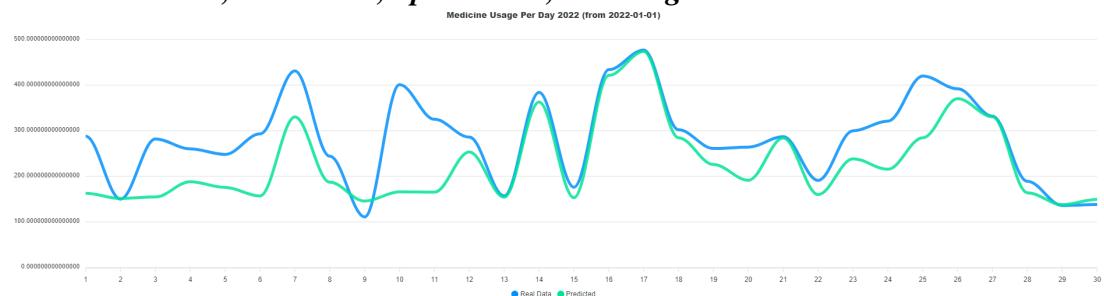
**Gambar 1.96** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 97. *Filter: 64 & 128, Units: 100, Epoch: 100, Learning Rate: 0.001*



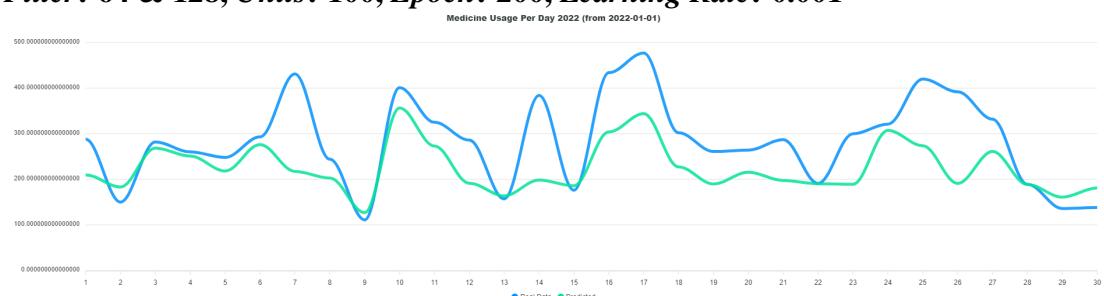
**Gambar 1.97** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 98. *Filter: 64 & 128, Units: 100, Epoch: 150, Learning Rate: 0.001*



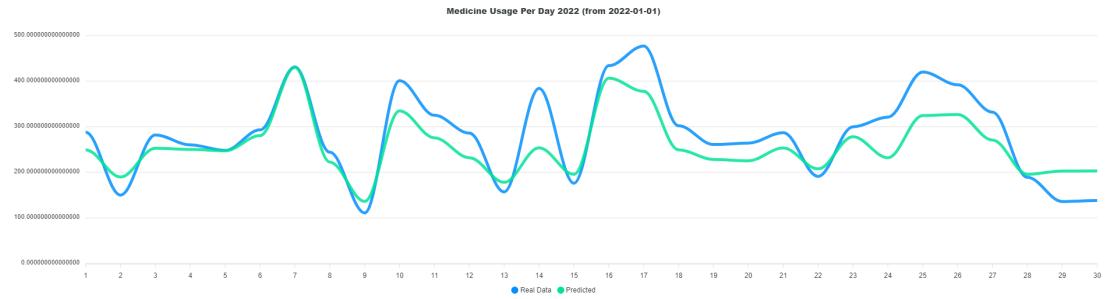
**Gambar 1.98** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 99. *Filter: 64 & 128, Units: 100, Epoch: 200, Learning Rate: 0.001*



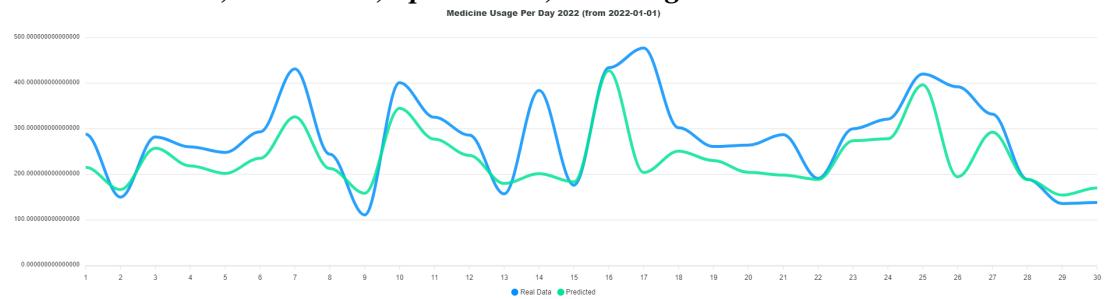
**Gambar 1.99** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 100. *Filter: 64 & 128, Units: 100, Epoch: 250, Learning Rate: 0.001*



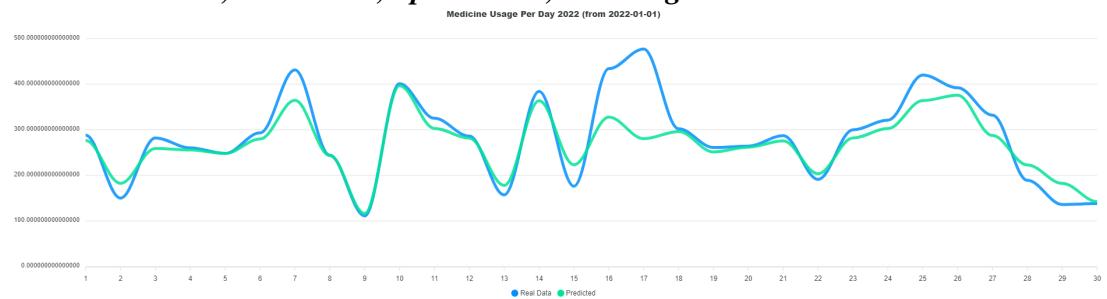
**Gambar 1.100** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 101. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001



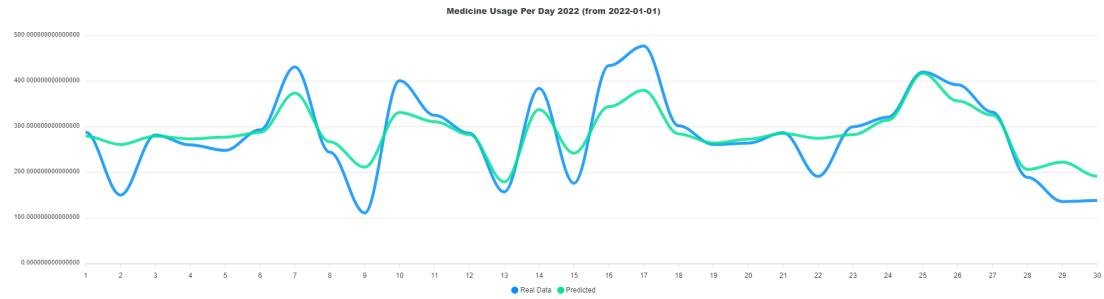
**Gambar 1.101** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 102. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001



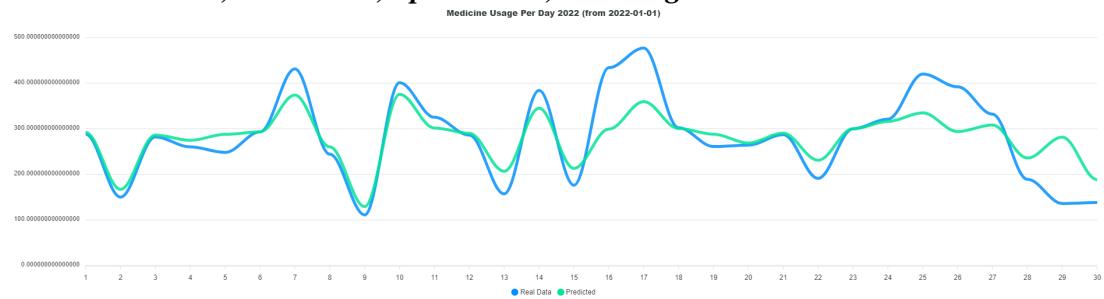
**Gambar 1.102** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 103. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001



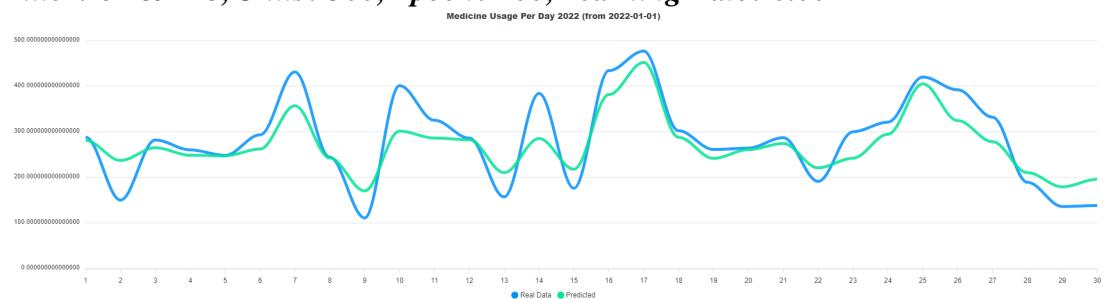
**Gambar 1.103** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 104. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.001



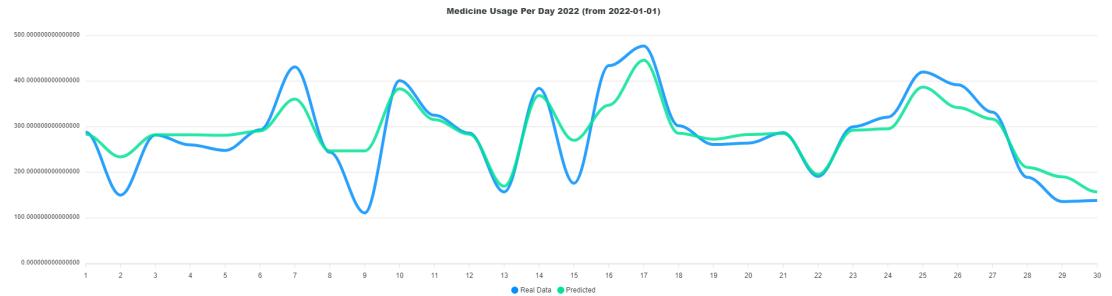
**Gambar 1.104** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 105. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.001



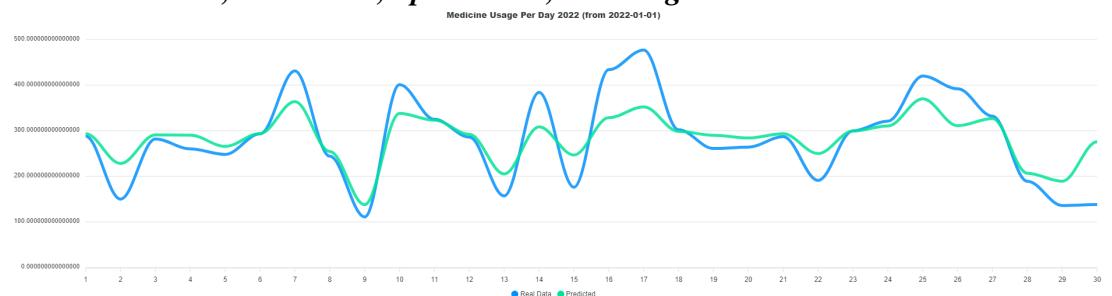
**Gambar 1.105** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 106. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.001



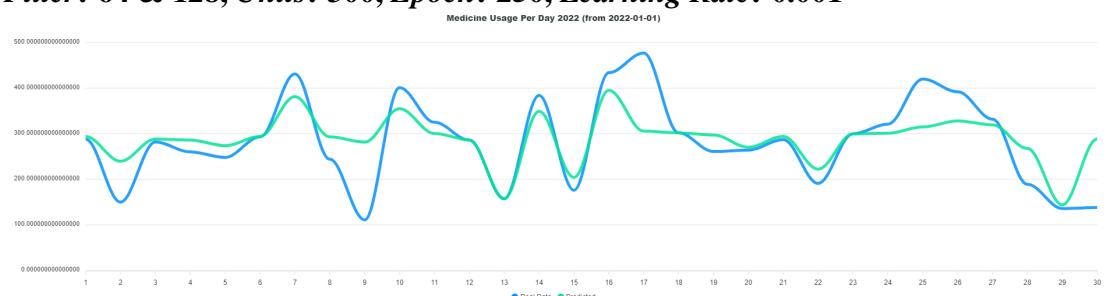
**Gambar 1.106** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 107. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.001



**Gambar 1.107** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

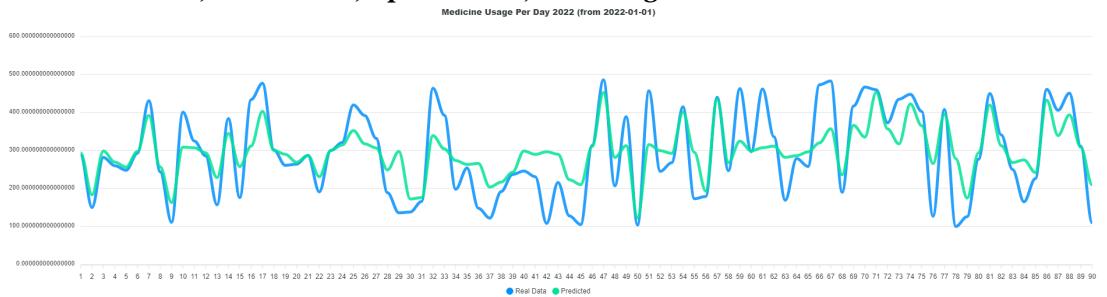
### 108. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.001



**Gambar 1.108** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 30 hari

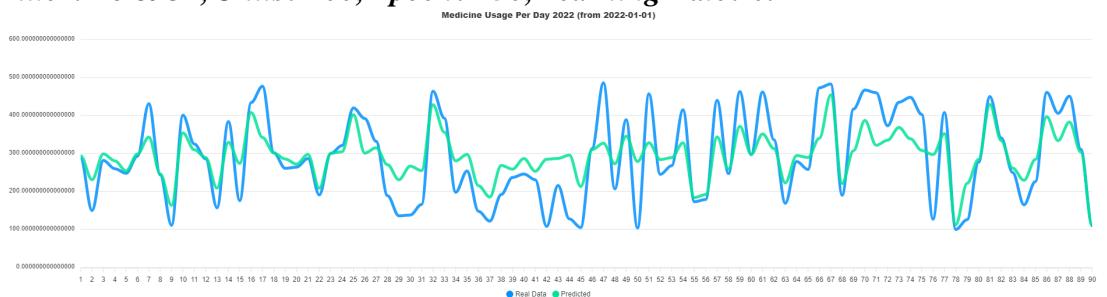
## 1.2 Forecasting Horizon 90 hari

### 1. Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.1



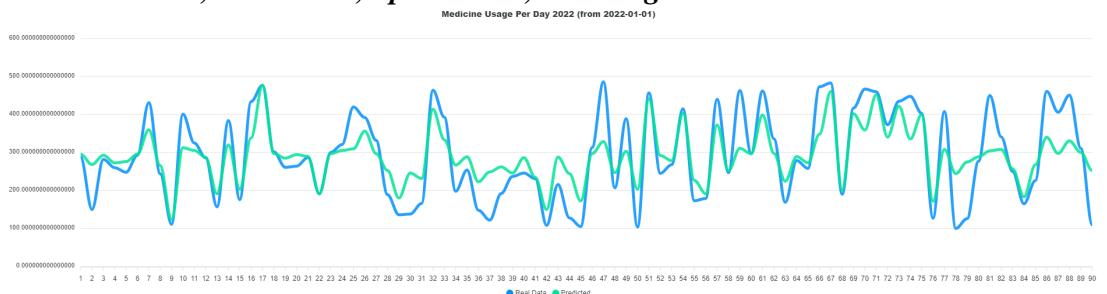
**Gambar 1.109** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 2. Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.1



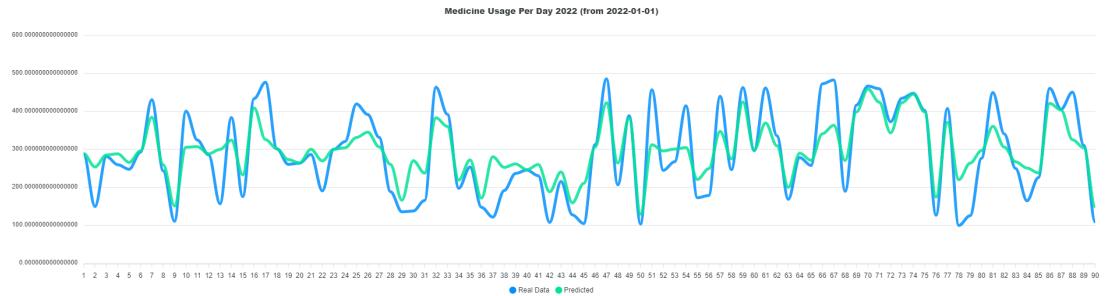
**Gambar 1.110** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 3. Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.1



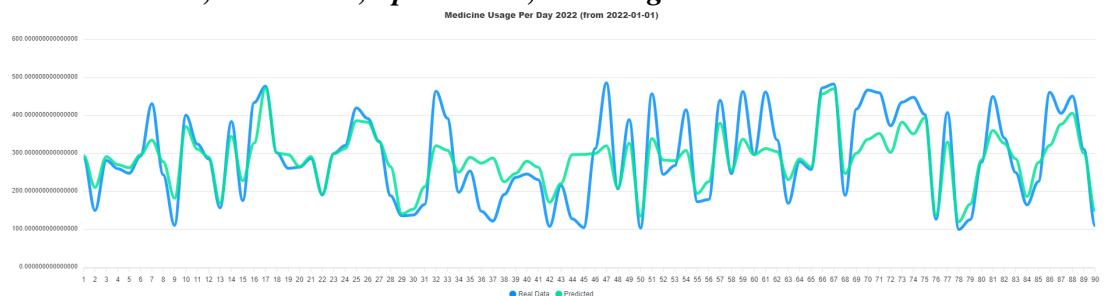
**Gambar 1.111** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 4. Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.1



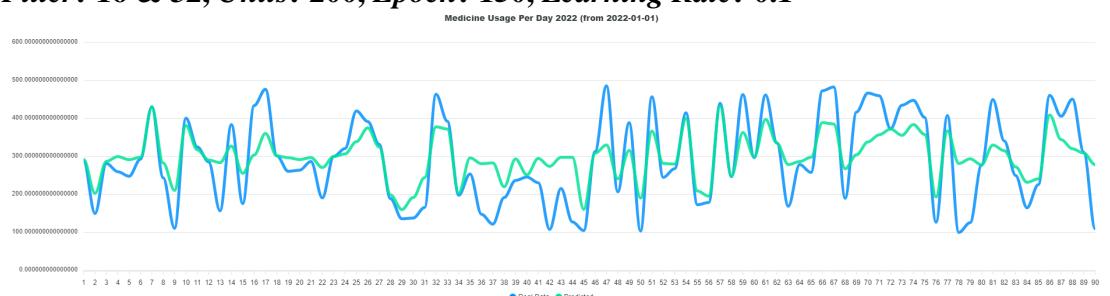
**Gambar 1.112** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 5. *Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.1*



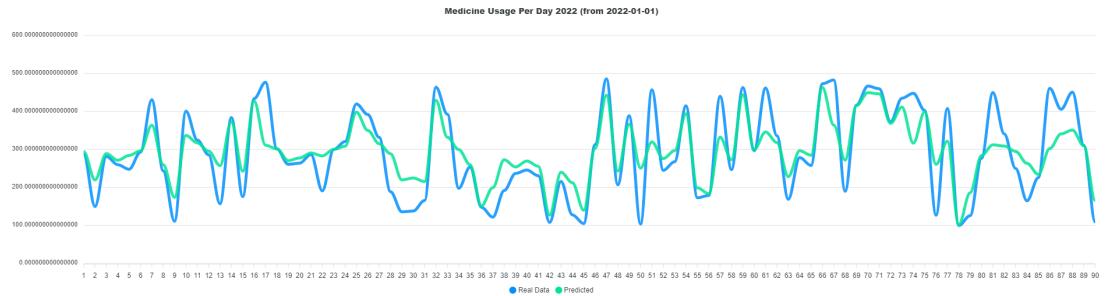
**Gambar 1.113** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 6. *Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.1*



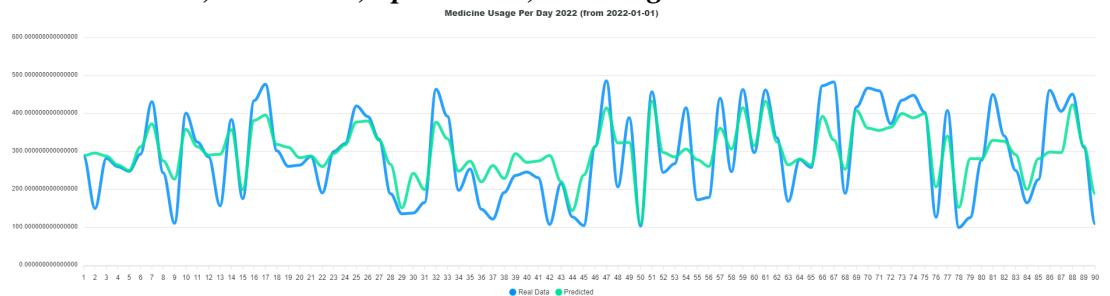
**Gambar 1.114** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 7. *Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.1*



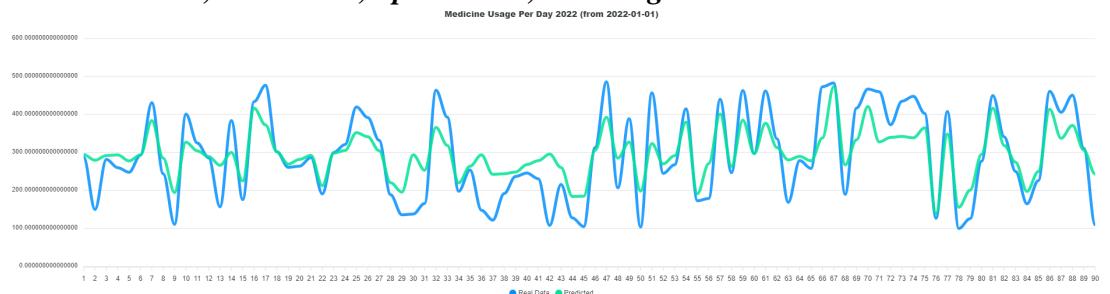
**Gambar 1.115** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 8. *Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.1*



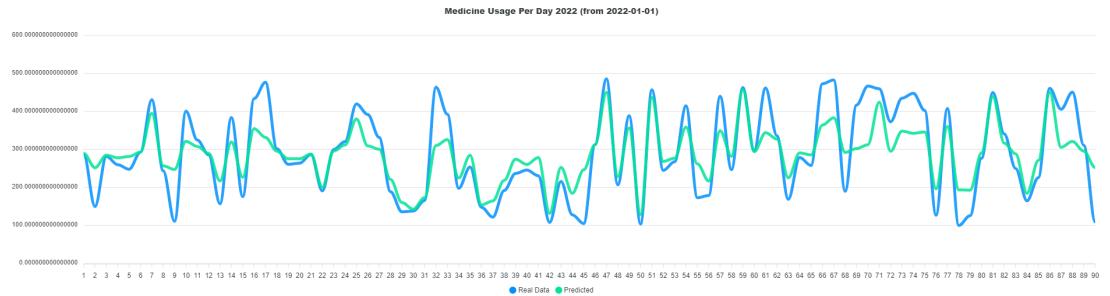
**Gambar 1.116** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 9. *Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.1*



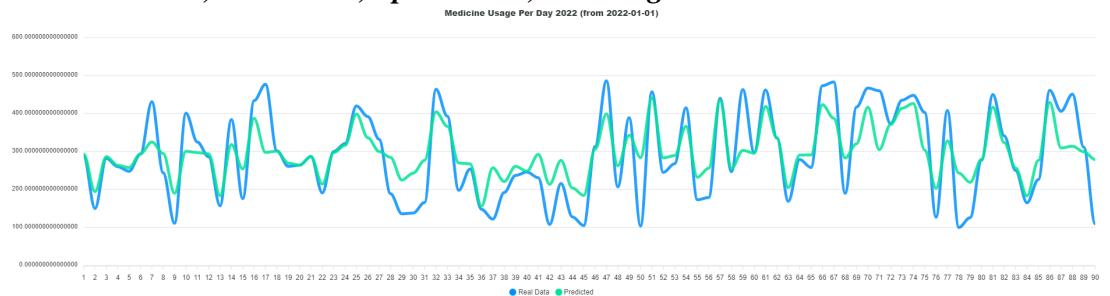
**Gambar 1.117** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 10. *Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.1*



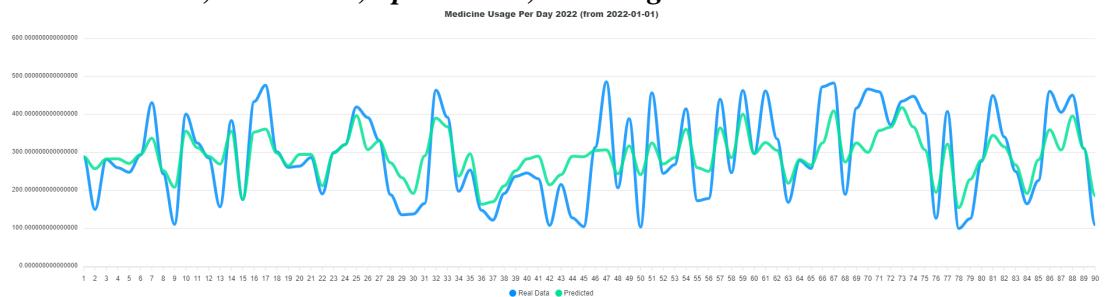
**Gambar 1.118** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 11. *Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.1*



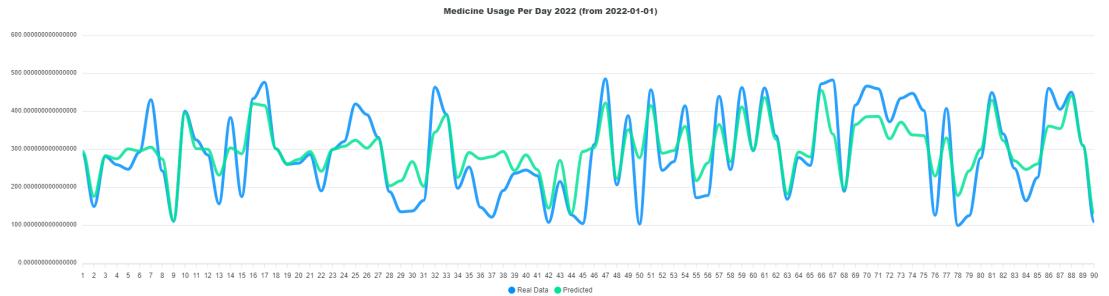
**Gambar 1.119** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 12. *Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.1*



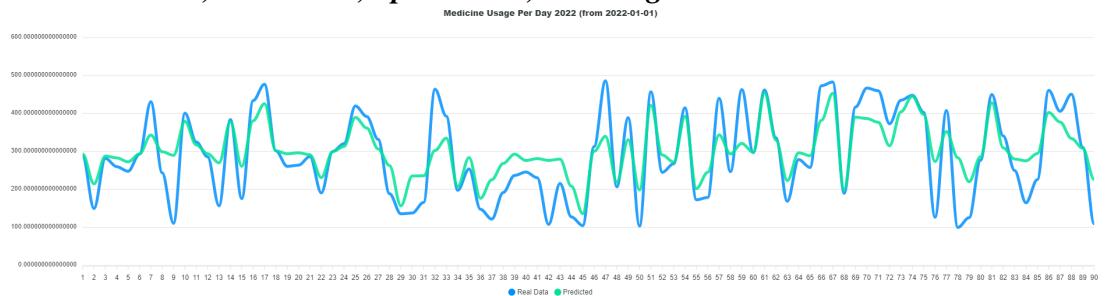
**Gambar 1.120** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 13. *Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.1*



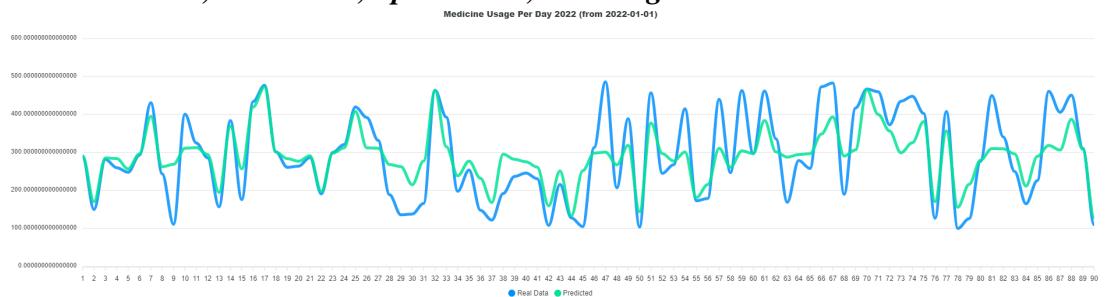
**Gambar 1.121** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 14. *Filter*: 32 & 64, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.1



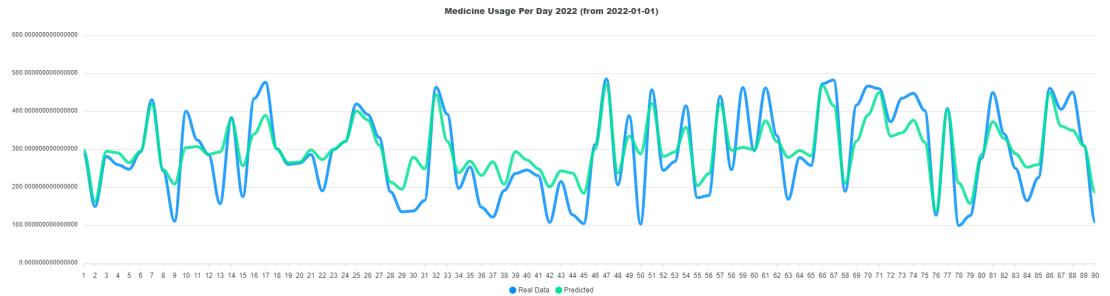
**Gambar 1.122** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 15. *Filter*: 32 & 64, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.1



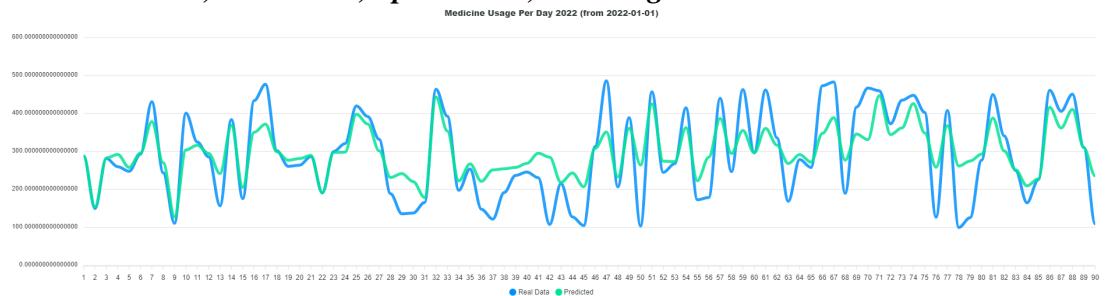
**Gambar 1.123** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 16. *Filter*: 32 & 64, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.1



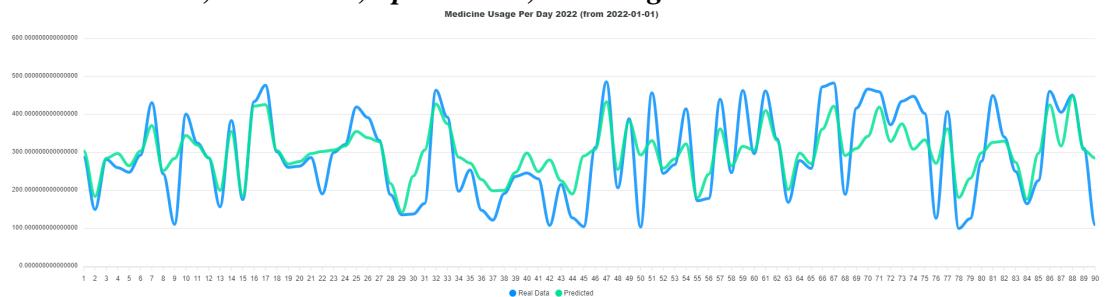
**Gambar 1.124** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 17. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.1



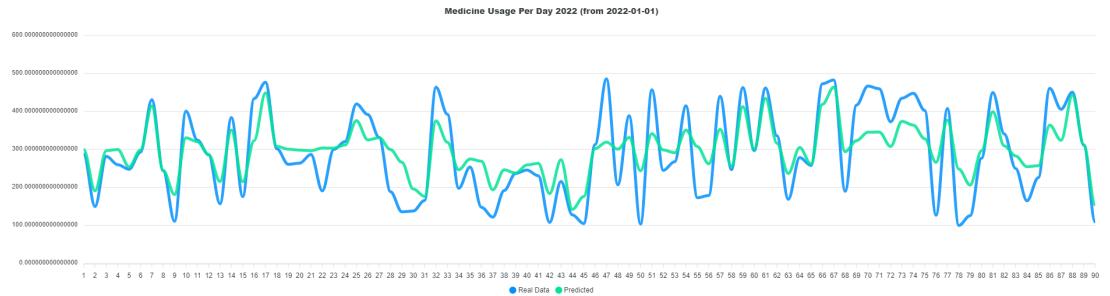
**Gambar 1.125** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 18. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.1



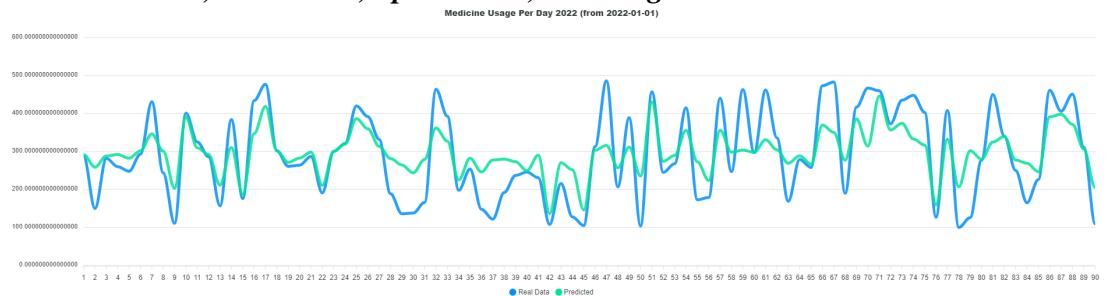
**Gambar 1.126** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 19. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.1



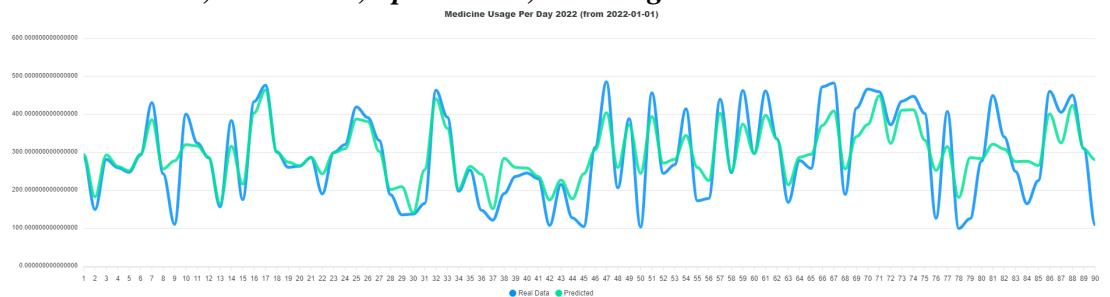
**Gambar 1.127** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 20. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1



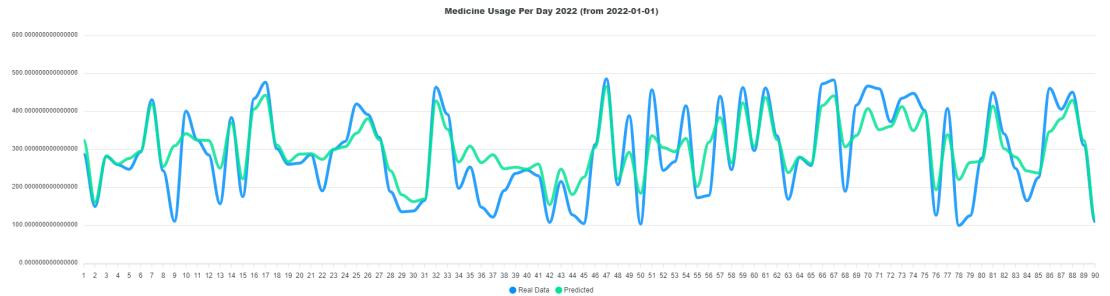
**Gambar 1.128** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 21. *Filter*: 32 & 64, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1



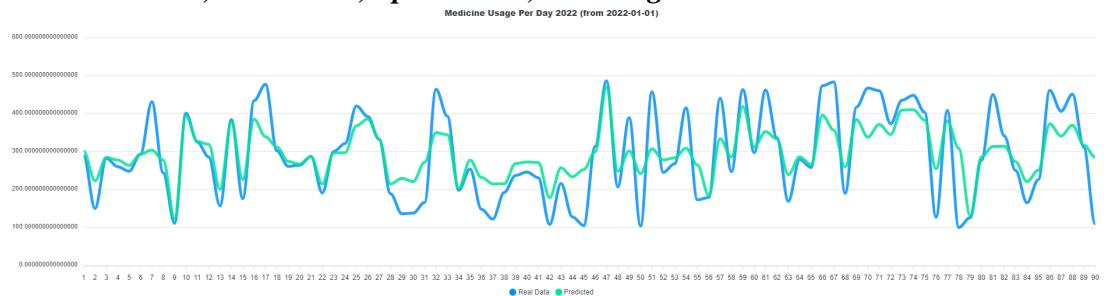
**Gambar 1.129** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 22. *Filter*: 32 & 64, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1



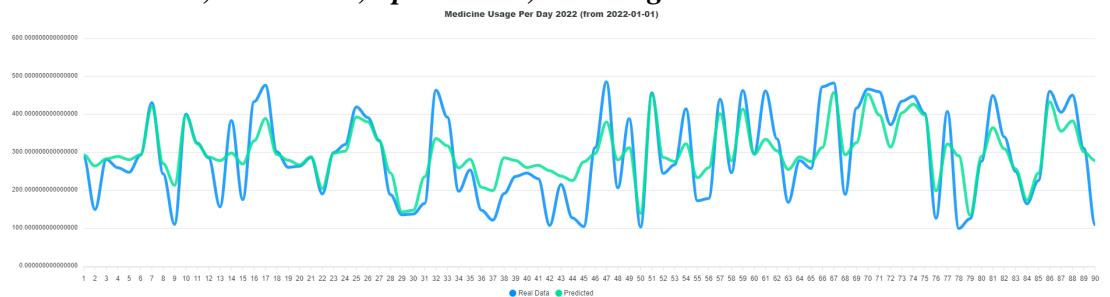
**Gambar 1.130** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 23. *Filter*: 32 & 64, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.1



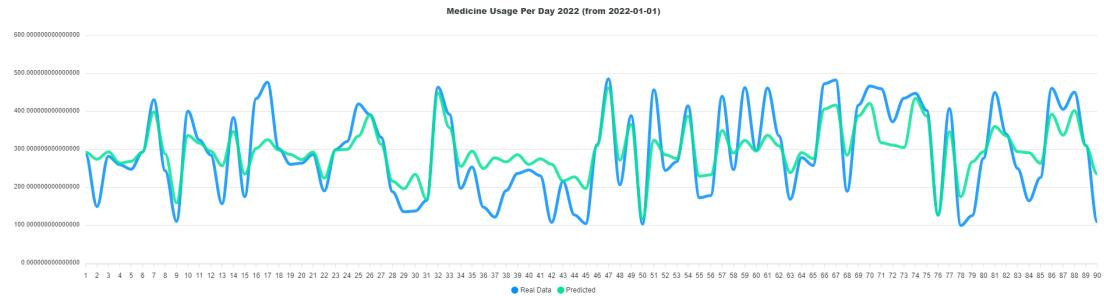
**Gambar 1.131** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 24. *Filter*: 32 & 64, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.1



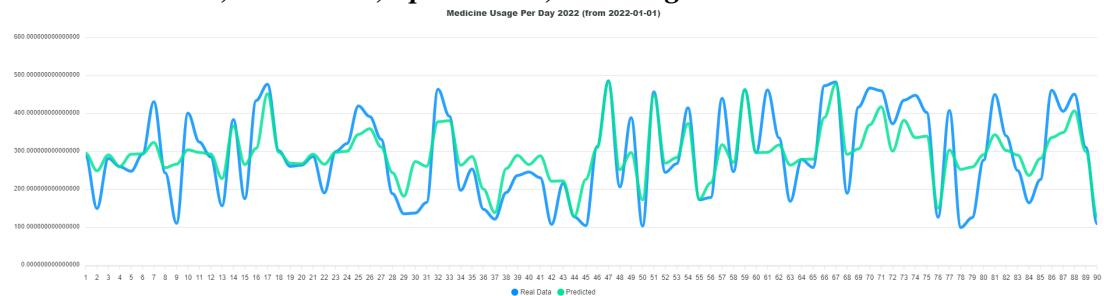
**Gambar 1.132** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 25. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.1



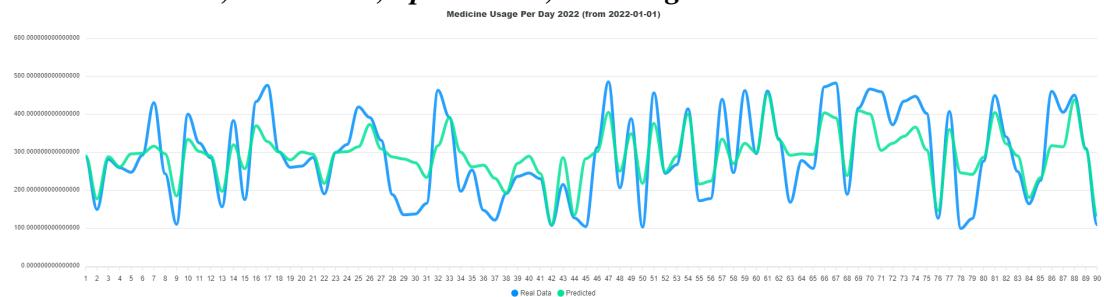
**Gambar 1.133** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 26. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.1



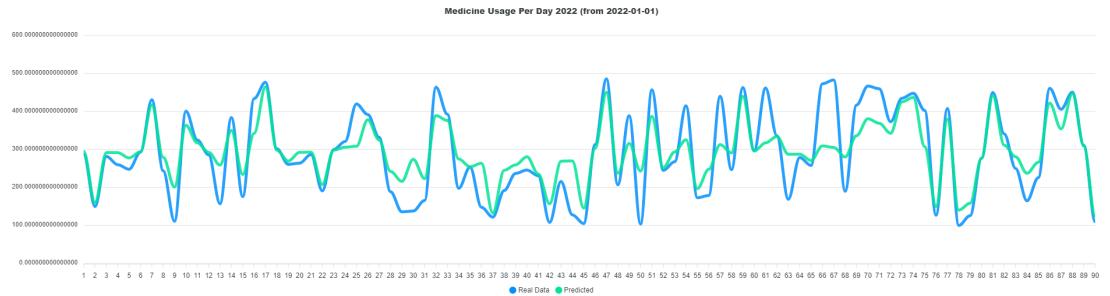
**Gambar 1.134** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 27. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.1



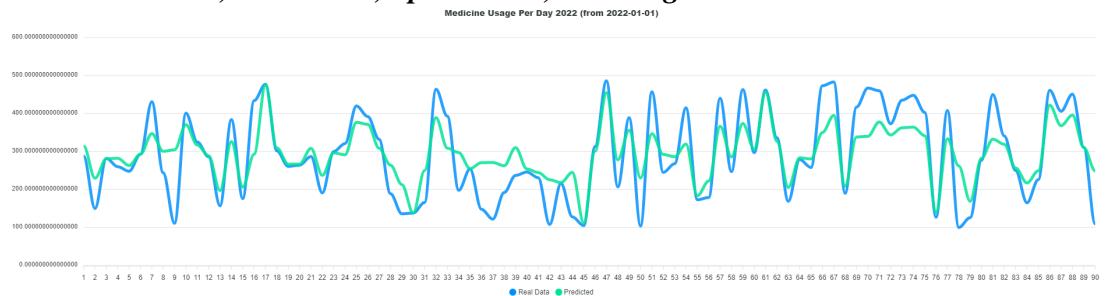
**Gambar 1.135** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 28. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.1



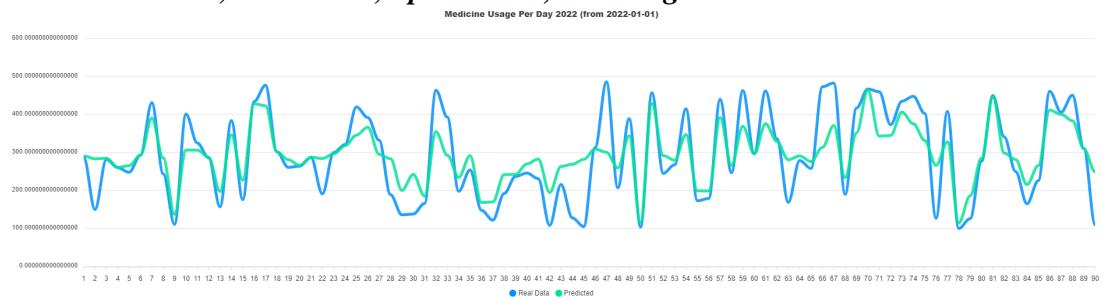
**Gambar 1.136** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 29. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.1



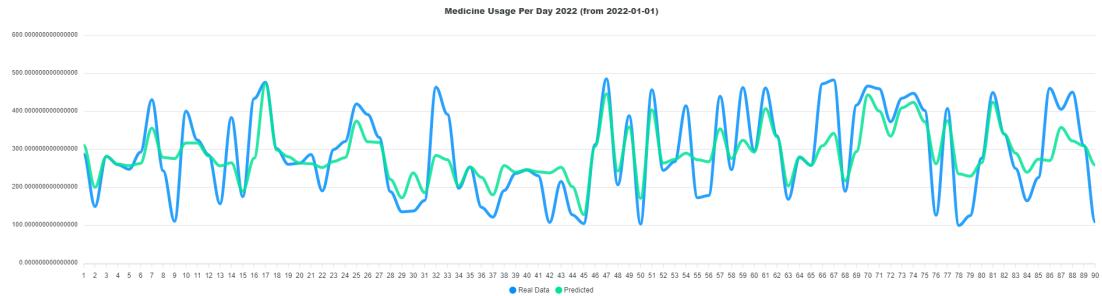
**Gambar 1.137** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 30. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.1



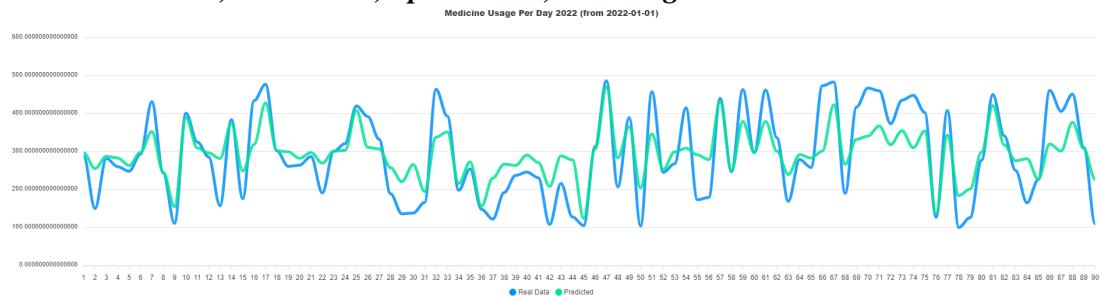
**Gambar 1.138** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 31. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.1



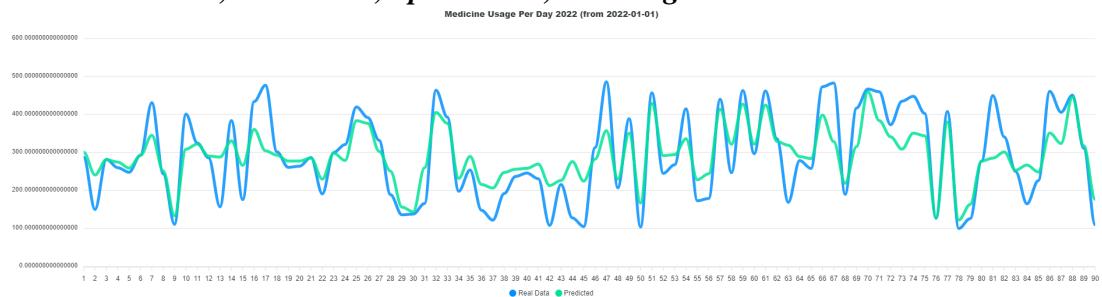
**Gambar 1.139** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 32. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1



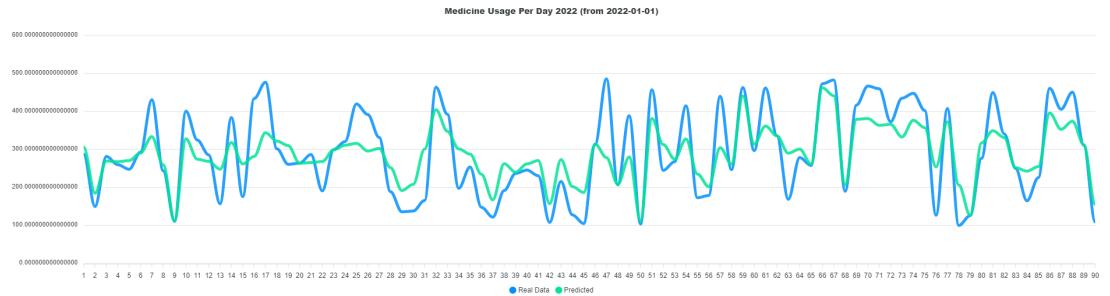
**Gambar 1.140** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 33. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1



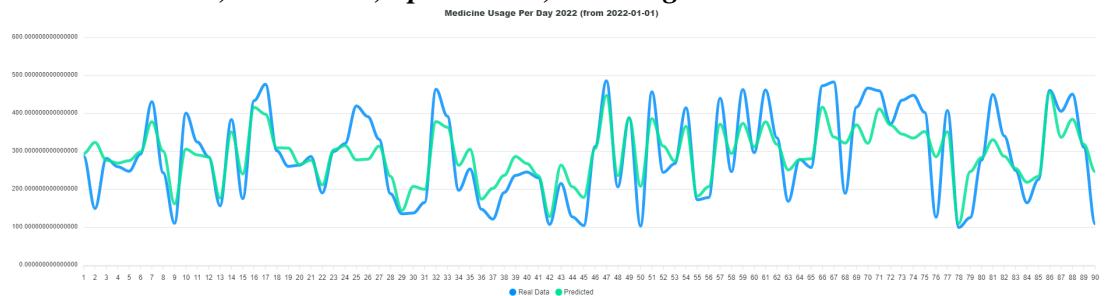
**Gambar 1.141** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 34. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1



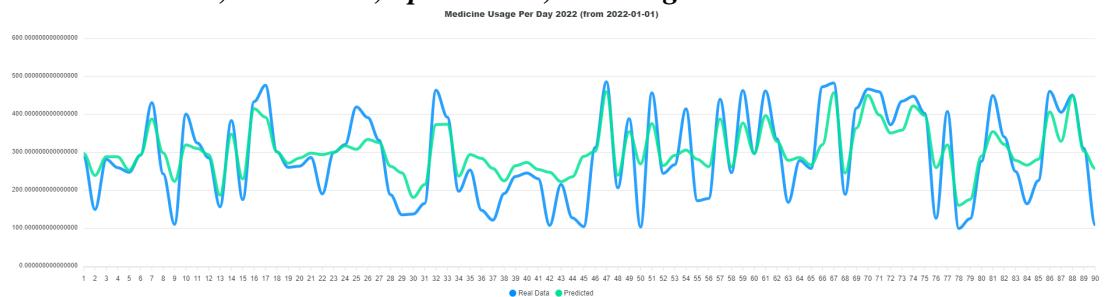
**Gambar 1.142** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 35. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.1



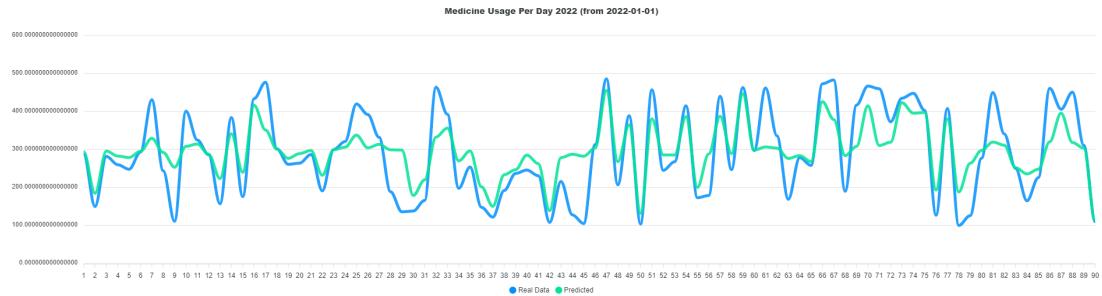
**Gambar 1.143** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 36. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.1



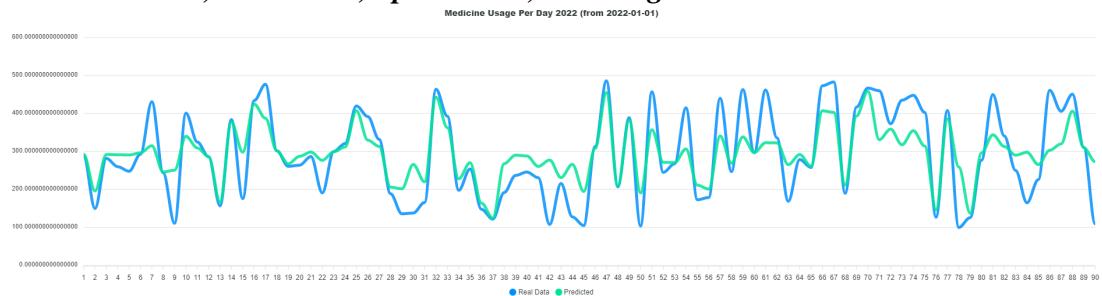
**Gambar 1.144** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.1 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 37. *Filter*: 16 & 32, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.01



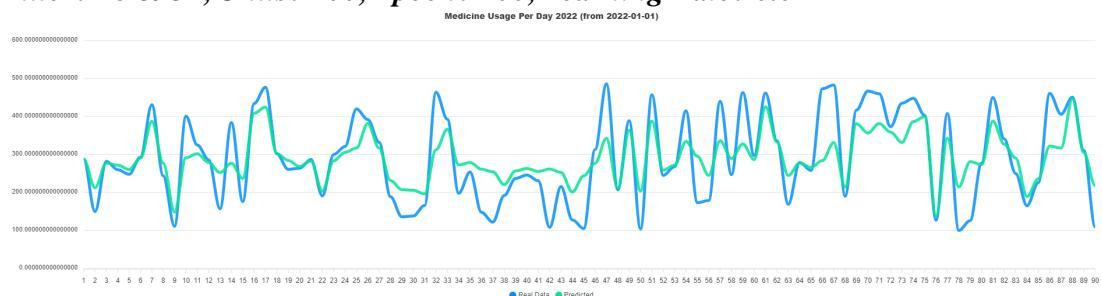
**Gambar 1.145** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 38. *Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.01*



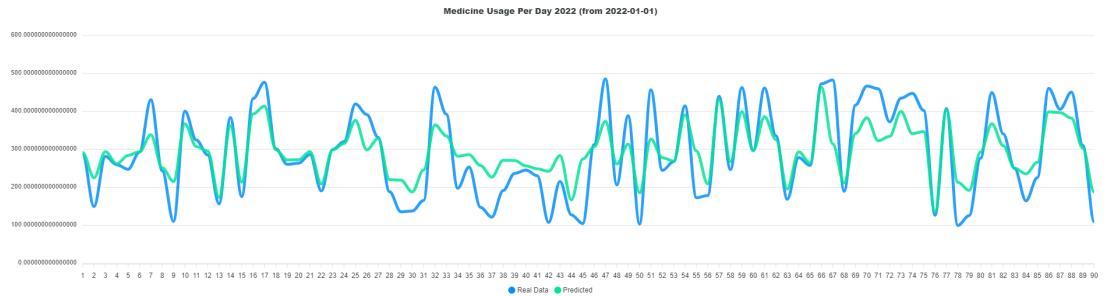
**Gambar 1.146** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 39. *Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.01*



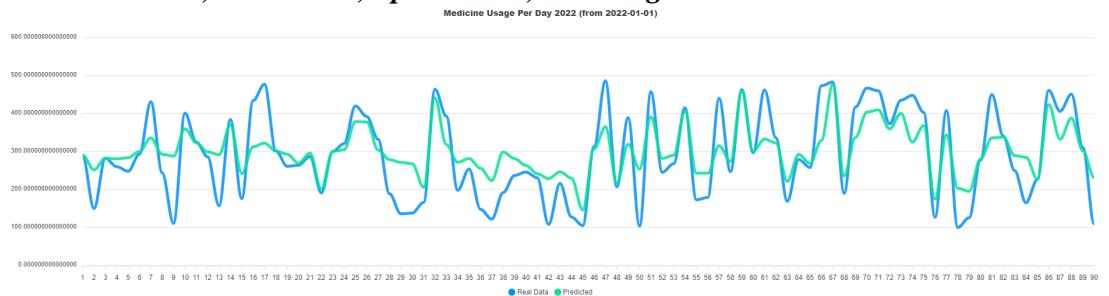
**Gambar 1.147** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 40. *Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.01*



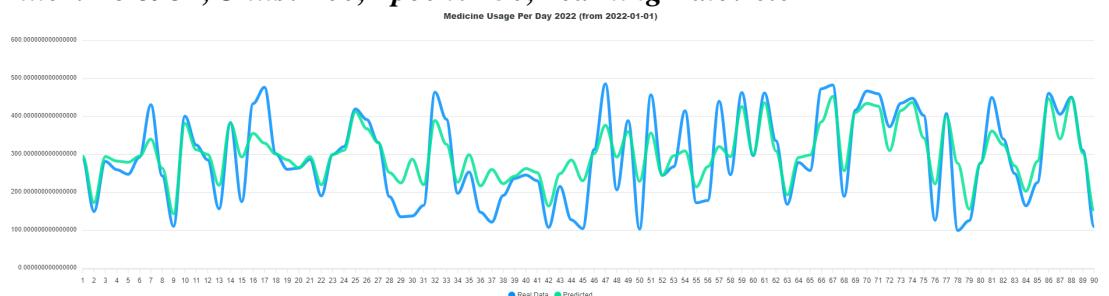
**Gambar 1.148** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 41. *Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.01*



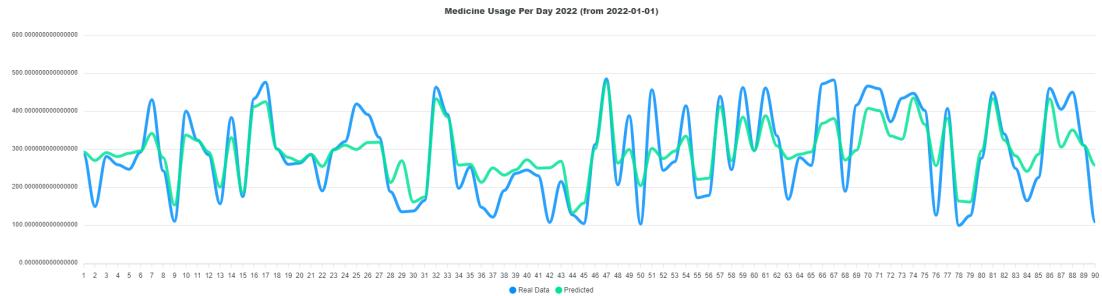
**Gambar 1.149** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 42. *Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.01*



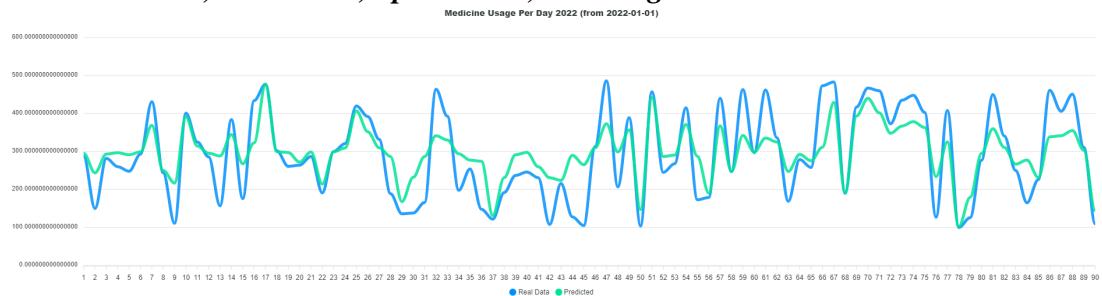
**Gambar 1.150** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 43. *Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.01*



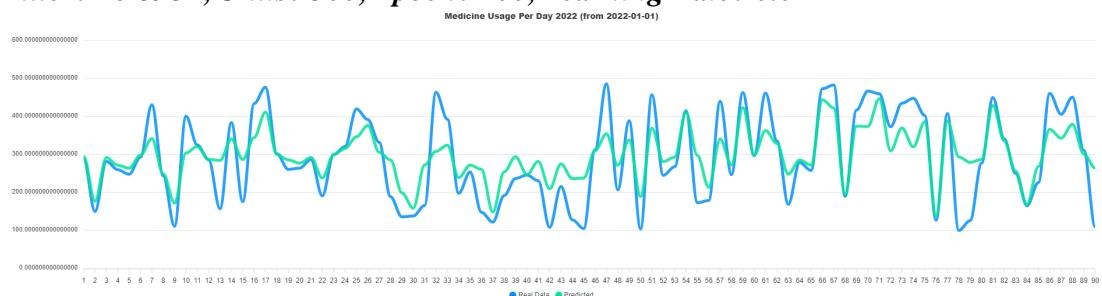
**Gambar 1.151** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 44. *Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.01*



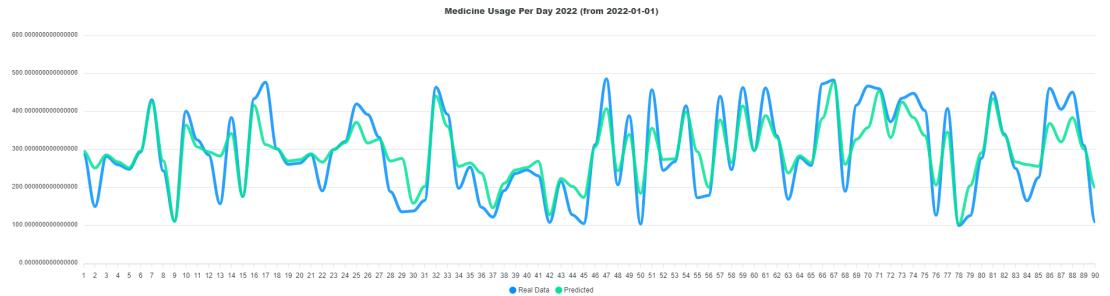
**Gambar 1.152** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 45. *Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.01*



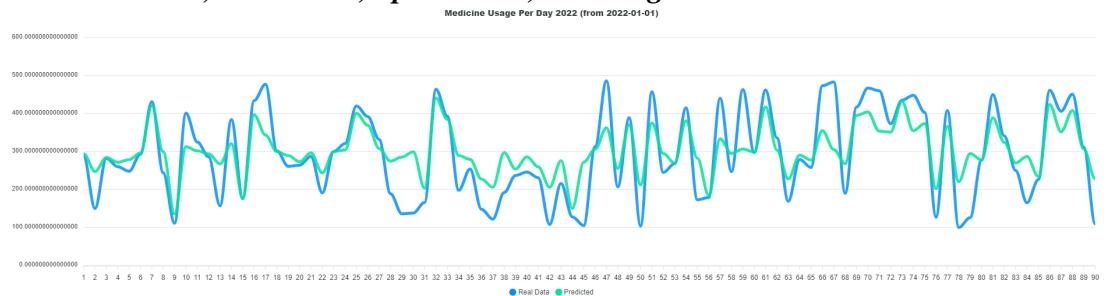
**Gambar 1.153** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 46. *Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.01*



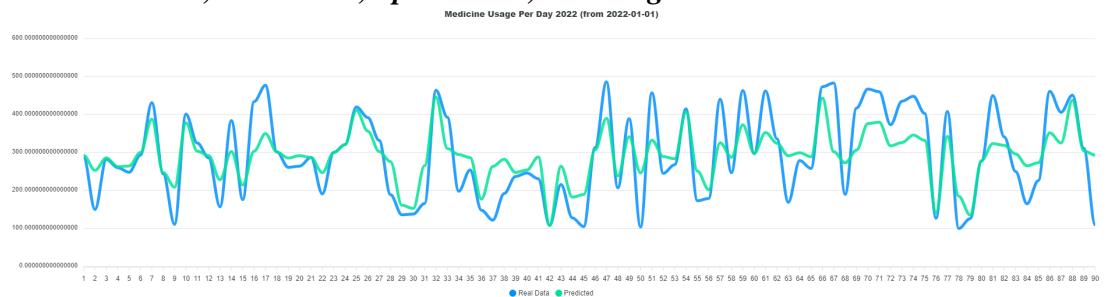
**Gambar 1.154** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 47. *Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.01*



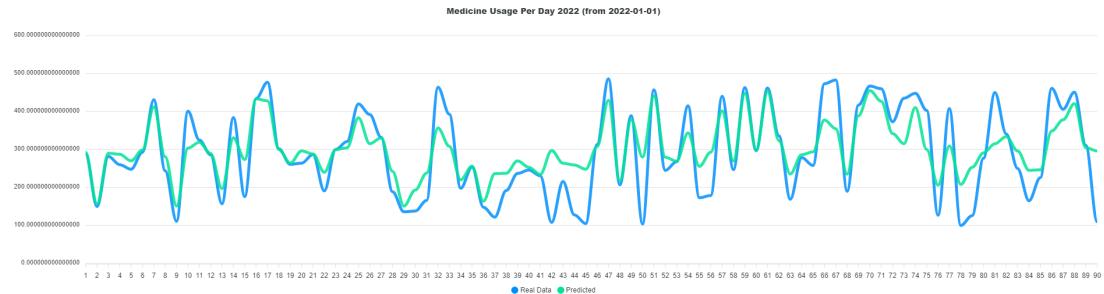
**Gambar 1.155** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 48. *Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.01*



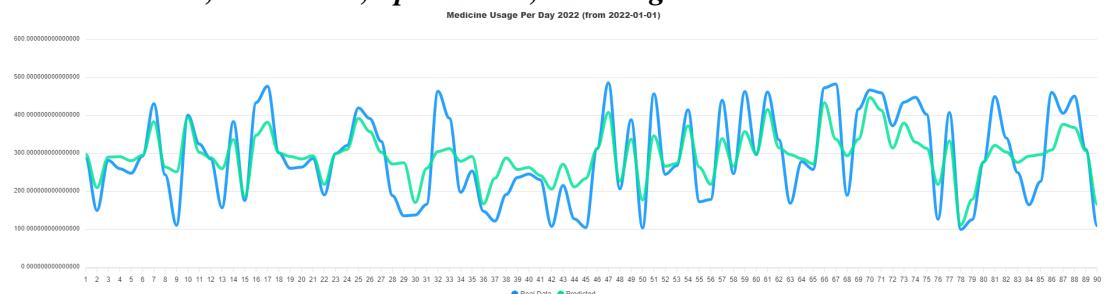
**Gambar 1.156** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 49. *Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.01*



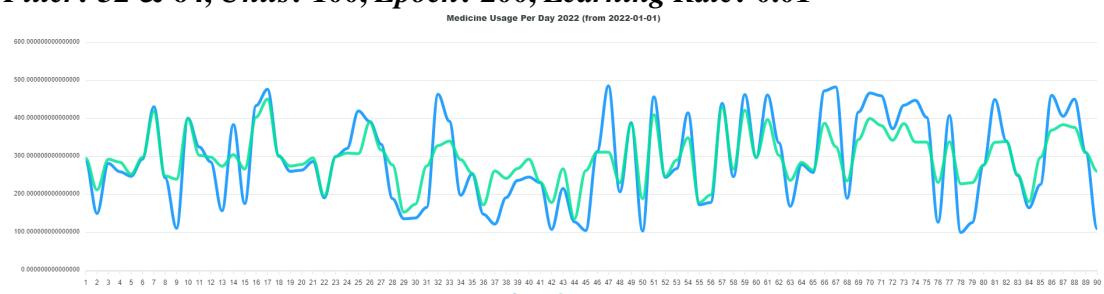
**Gambar 1.157** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 50. *Filter*: 32 & 64, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01



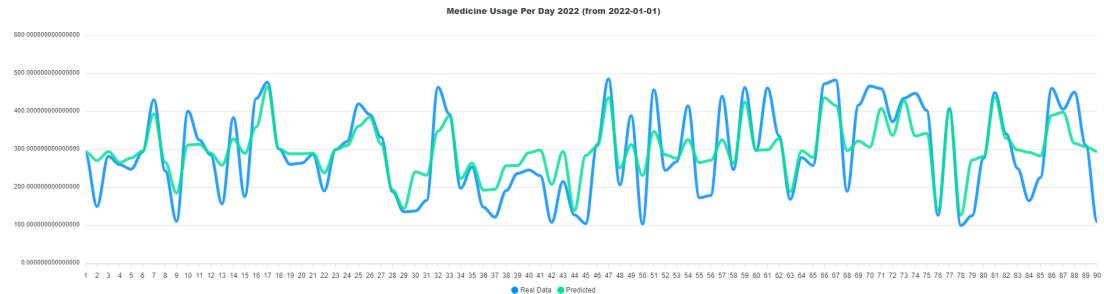
**Gambar 1.158** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 51. *Filter*: 32 & 64, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01



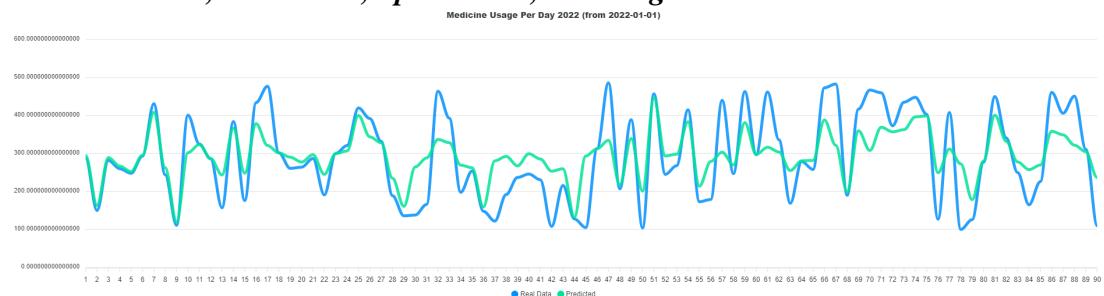
**Gambar 1.159** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 52. *Filter*: 32 & 64, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01



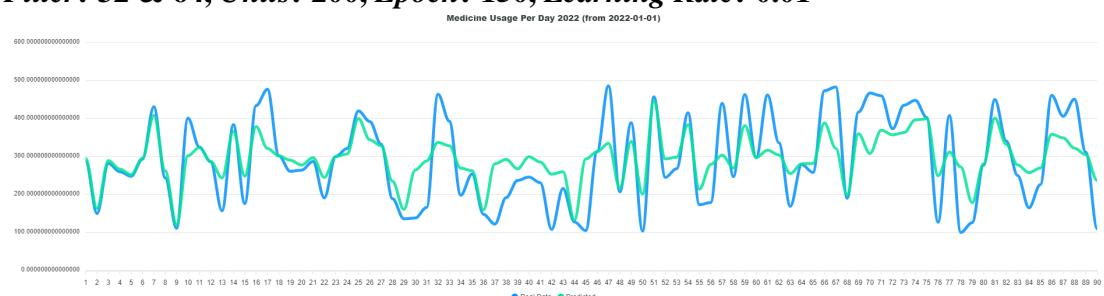
**Gambar 1.160** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 53. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.01



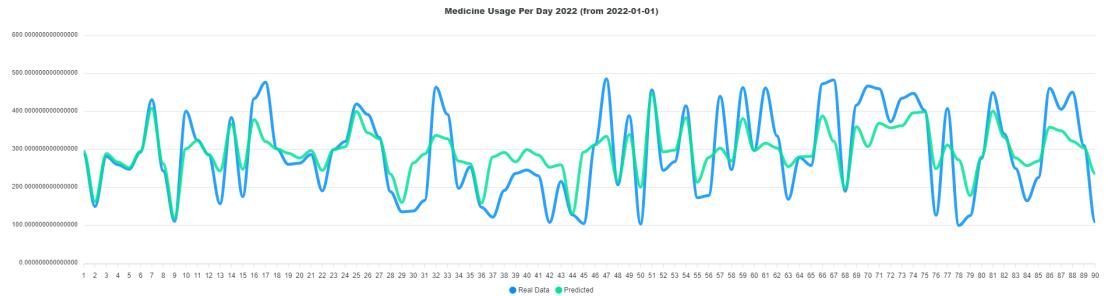
**Gambar 1.161** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 54. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.01



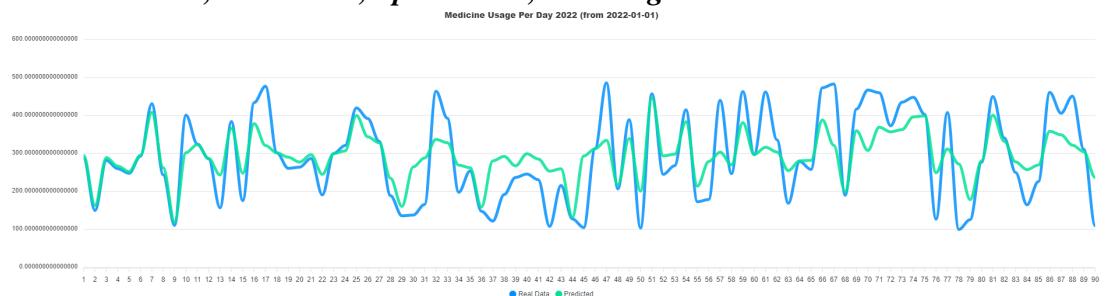
**Gambar 1.162** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 55. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.01



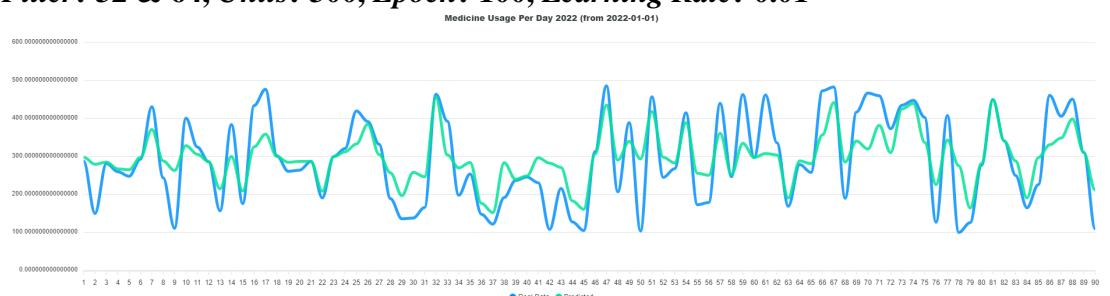
**Gambar 1.163** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 56. *Filter: 32 & 64, Units: 200, Epoch: 250, Learning Rate: 0.01*



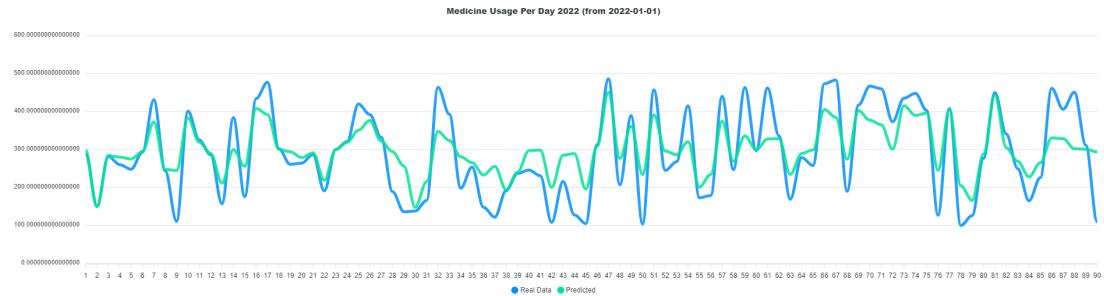
**Gambar 1.164** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 57. *Filter: 32 & 64, Units: 300, Epoch: 100, Learning Rate: 0.01*



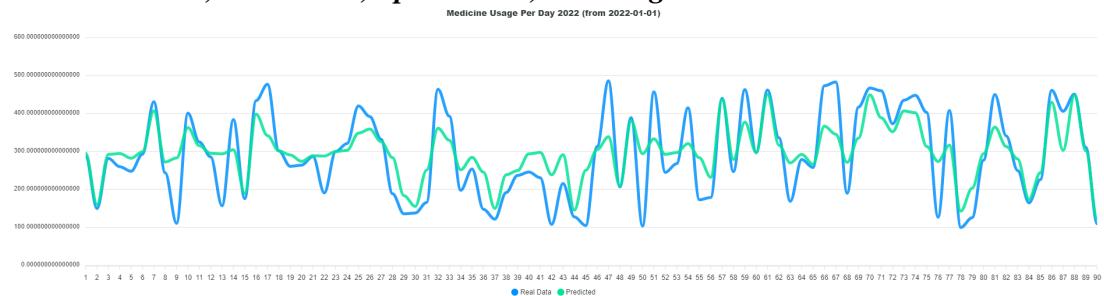
**Gambar 1.165** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 58. *Filter: 32 & 64, Units: 300, Epoch: 150, Learning Rate: 0.01*



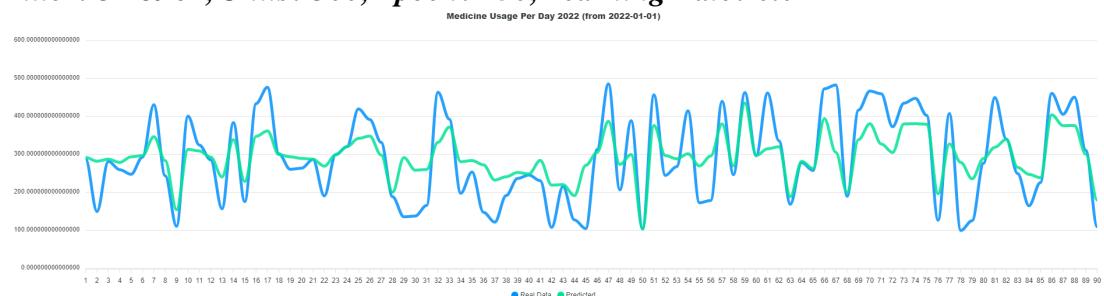
**Gambar 1.166** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 59. *Filter: 32 & 64, Units: 300, Epoch: 200, Learning Rate: 0.01*



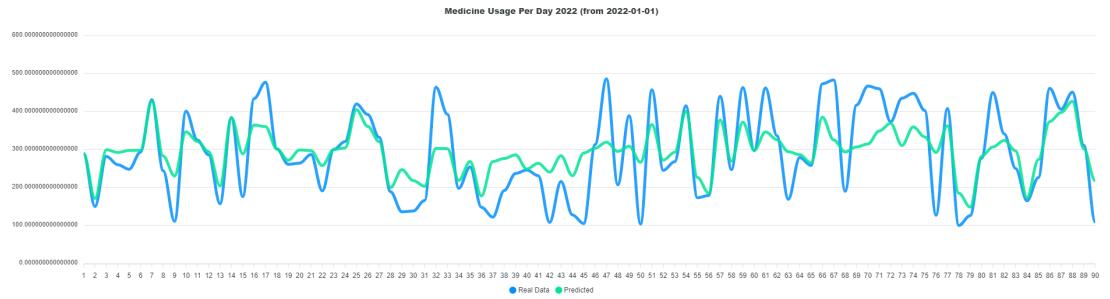
**Gambar 1.167** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 60. *Filter: 32 & 64, Units: 300, Epoch: 250, Learning Rate: 0.01*



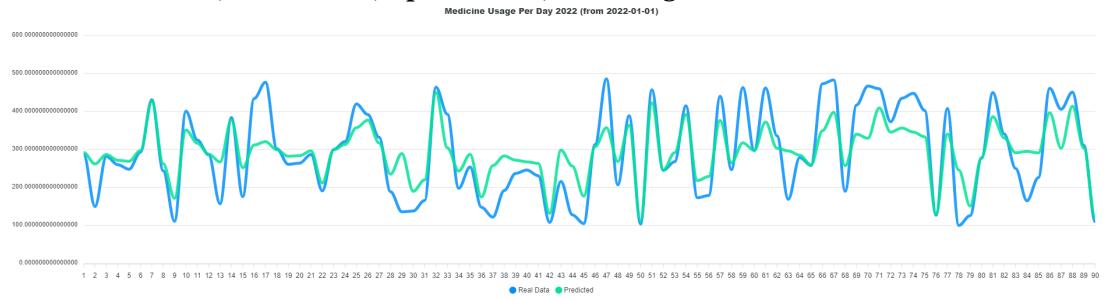
**Gambar 1.168** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 61. *Filter: 64 & 128, Units: 100, Epoch: 100, Learning Rate: 0.01*



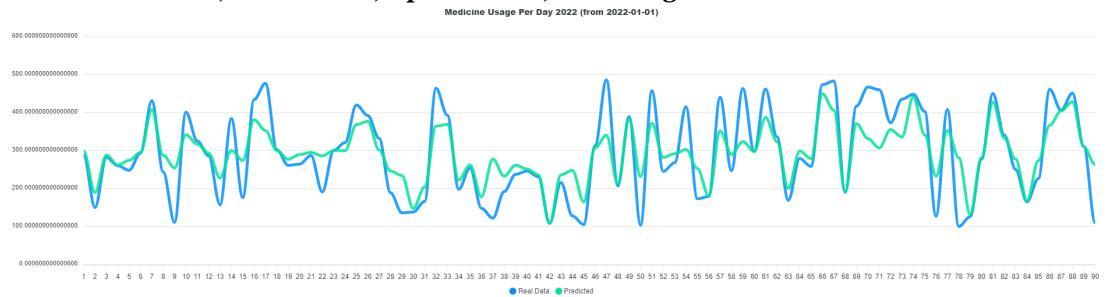
**Gambar 1.169** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 62. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01



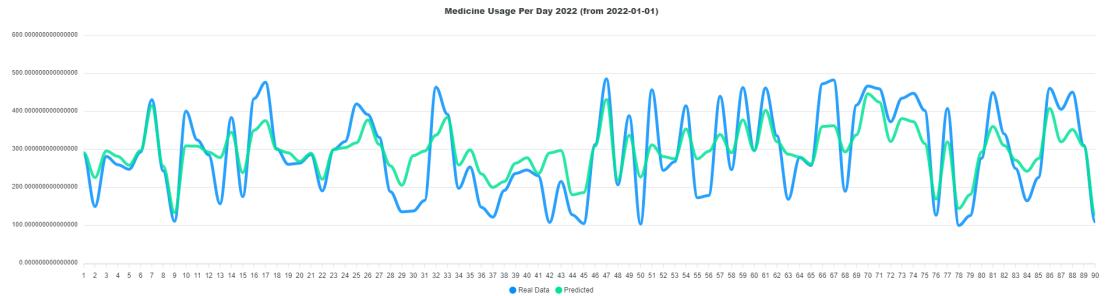
**Gambar 1.170** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 63. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01



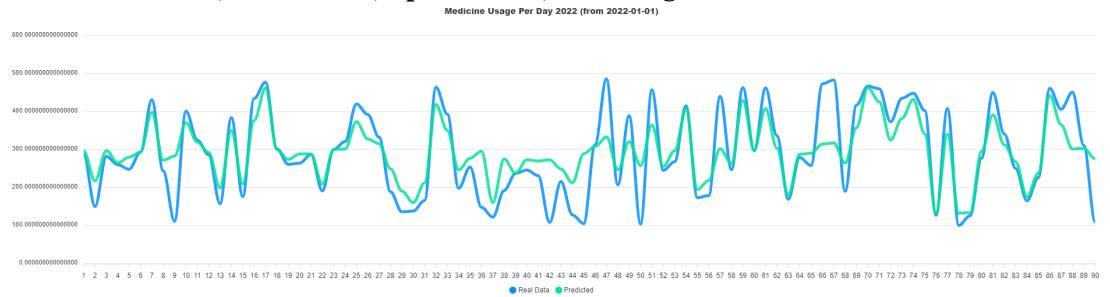
**Gambar 1.171** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 64. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01



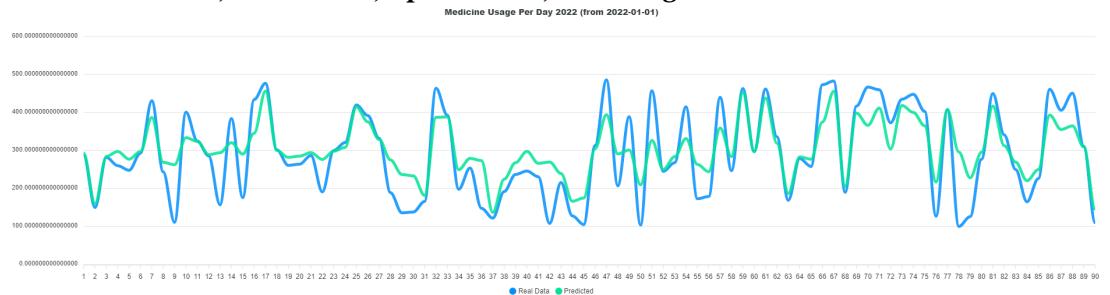
**Gambar 1.172** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 65. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.01



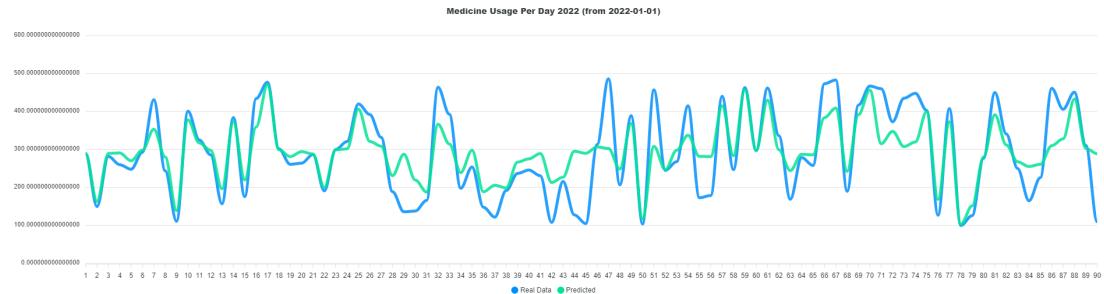
**Gambar 1.173** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 66. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.01



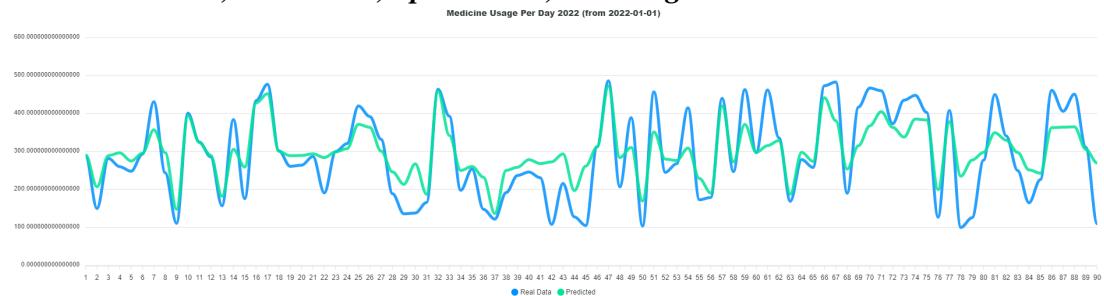
**Gambar 1.174** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 67. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.01



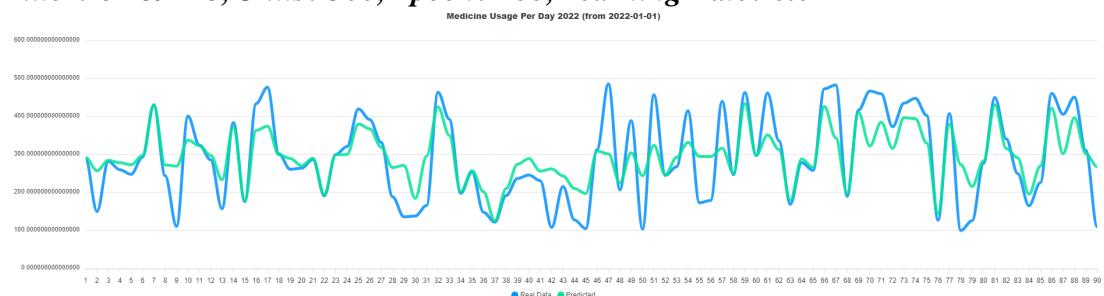
**Gambar 1.175** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 68. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.01



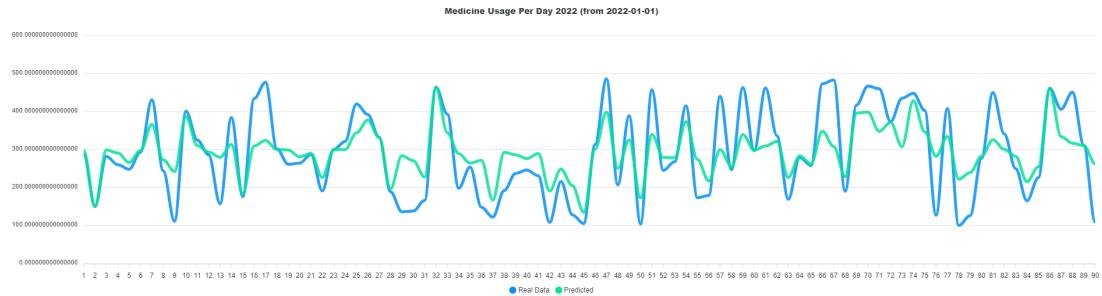
**Gambar 1.176** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 69. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.01



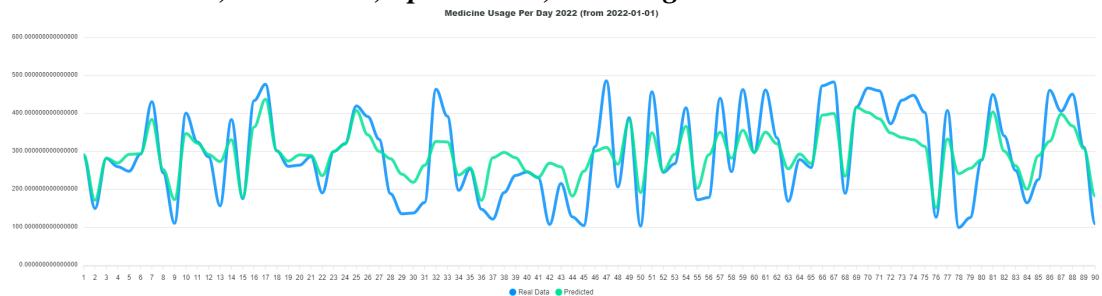
**Gambar 1.177** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 70. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.01



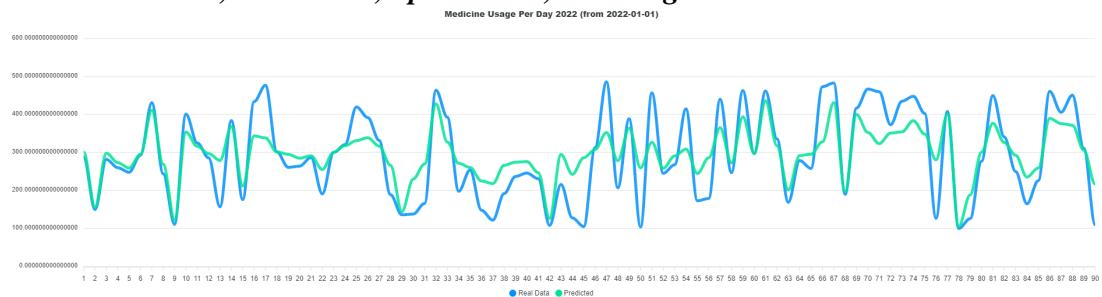
**Gambar 1.178** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 71. *Filter: 64 & 128, Units: 300, Epoch: 200, Learning Rate: 0.01*



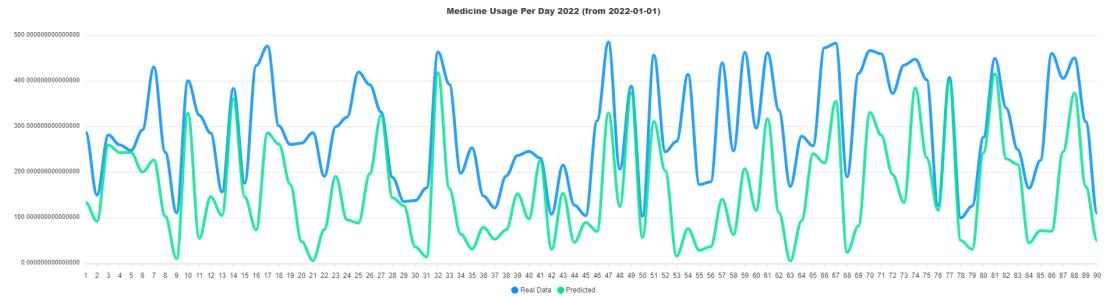
**Gambar 1.179** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 72. *Filter: 64 & 128, Units: 300, Epoch: 250, Learning Rate: 0.01*



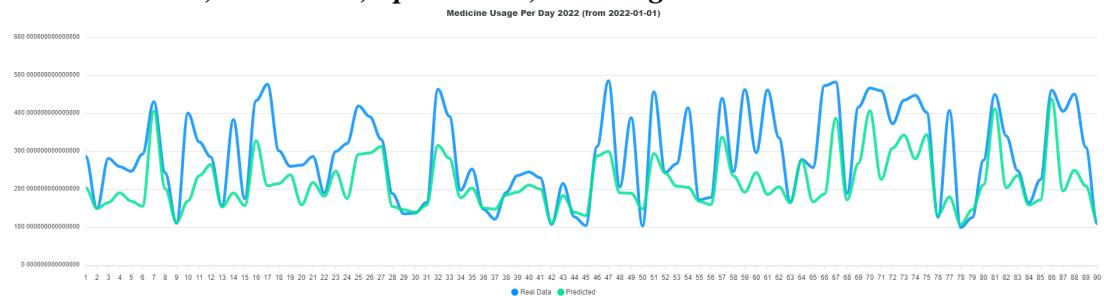
**Gambar 1.180** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.01 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 73. *Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.001*



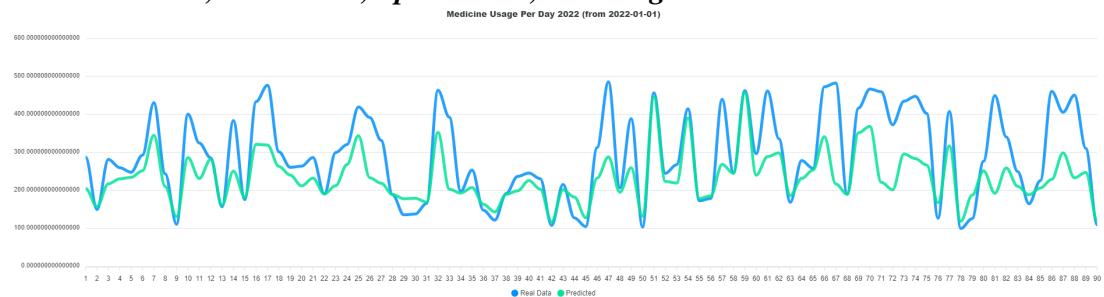
**Gambar 1.181** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 74. *Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.001*



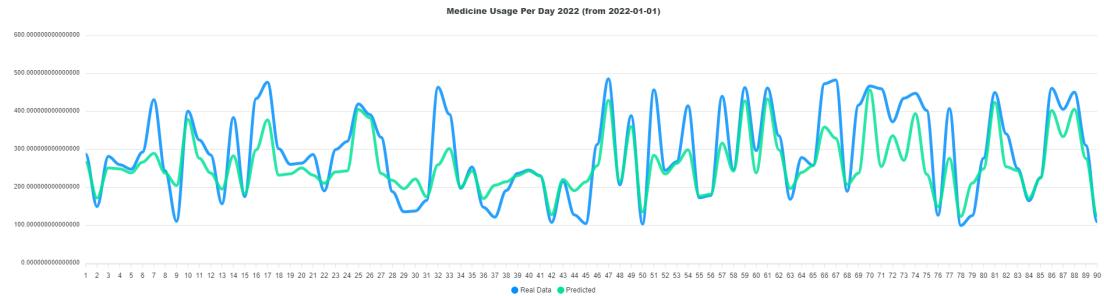
**Gambar 1.182** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 75. *Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.001*



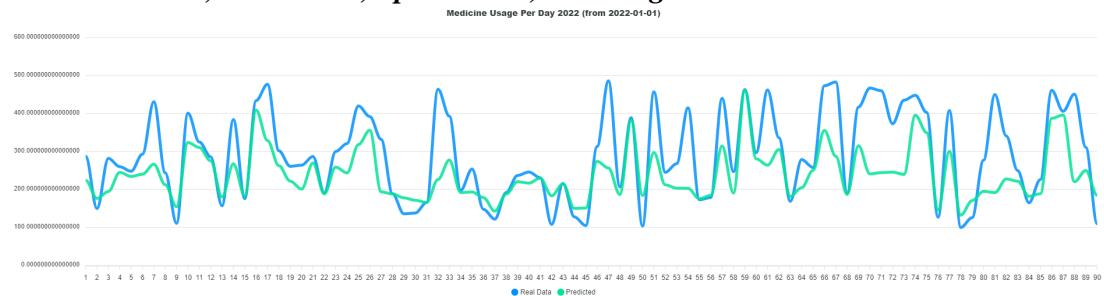
**Gambar 1.183** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 76. *Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.001*



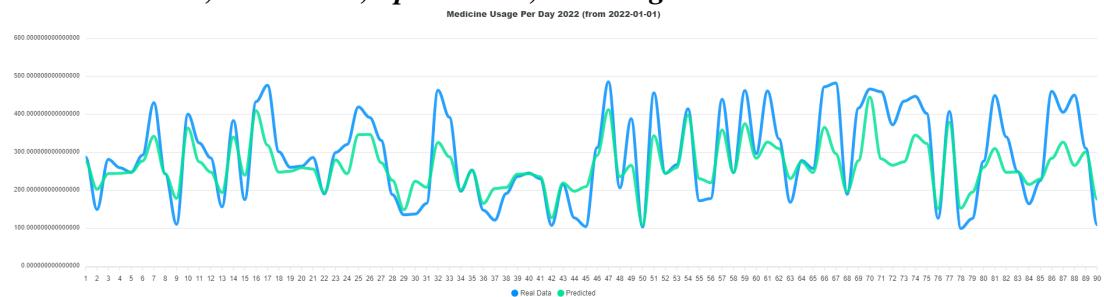
**Gambar 1.184** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 77. *Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.001*



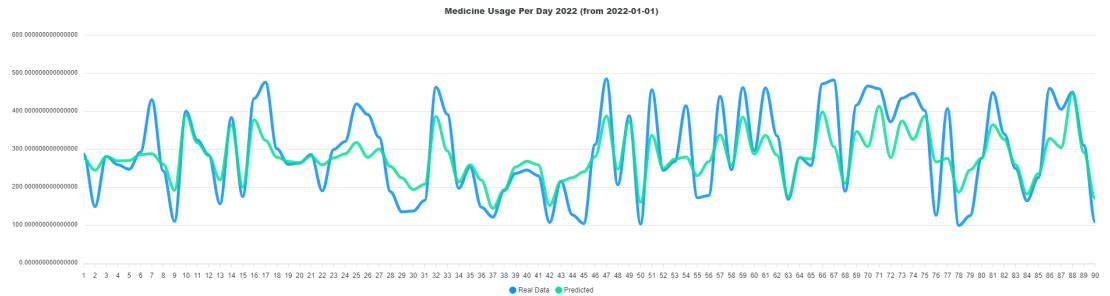
**Gambar 1.185** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 78. *Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.001*



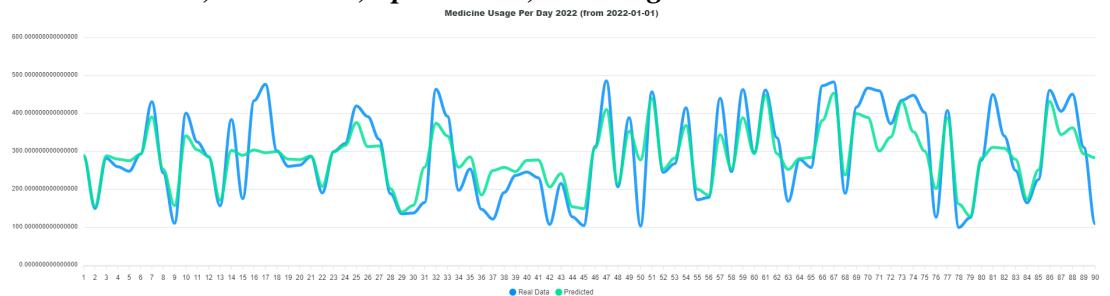
**Gambar 1.186** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 79. *Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.001*



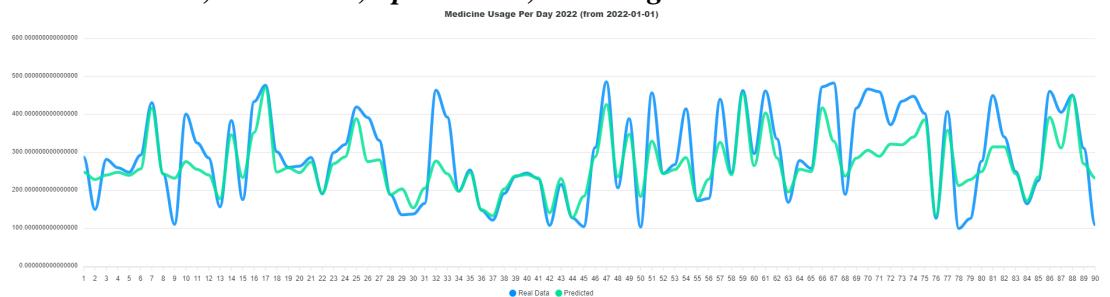
**Gambar 1.187** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 80. *Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.001*



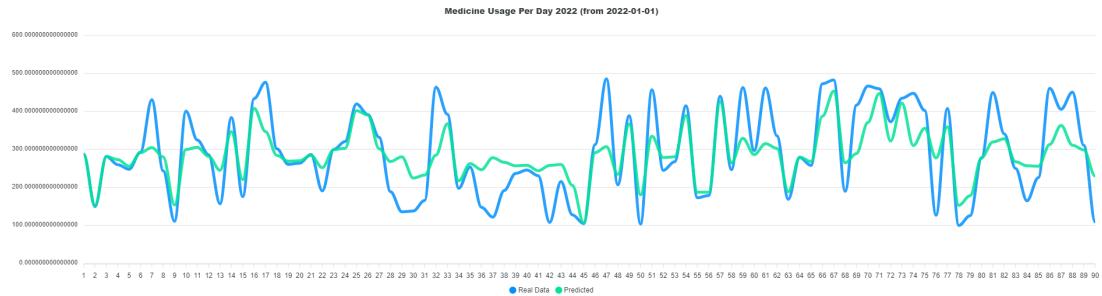
**Gambar 1.188** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 81. *Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.001*



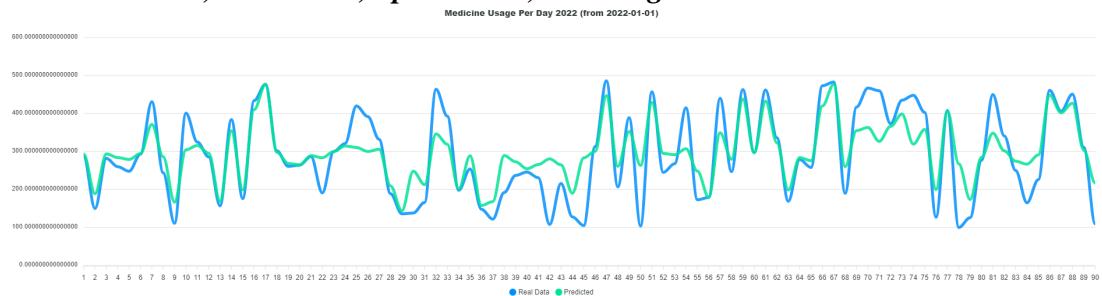
**Gambar 1.189** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 82. *Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.001*



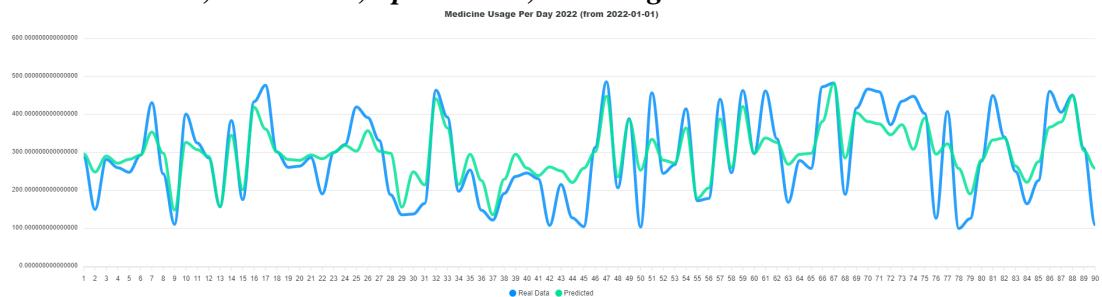
**Gambar 1.190** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 83. *Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.001*



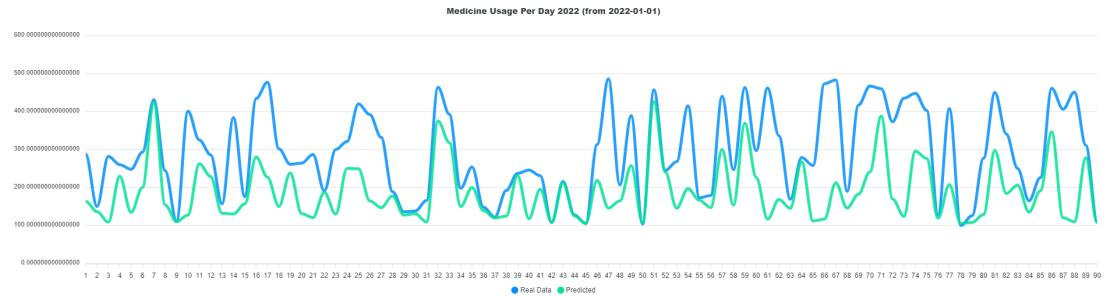
**Gambar 1.191** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 84. *Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.001*



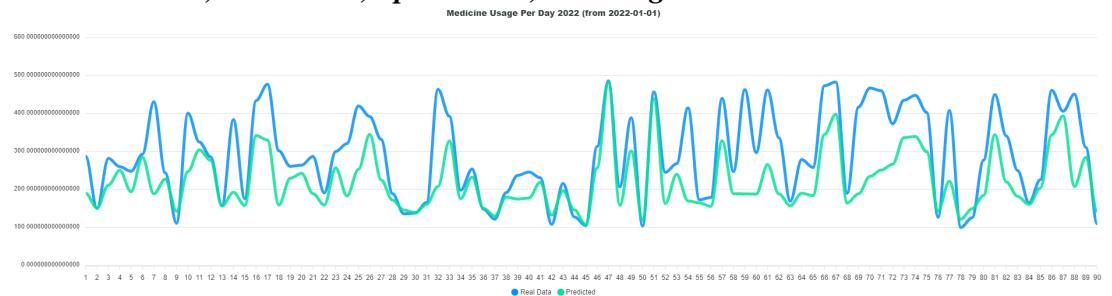
**Gambar 1.192** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 85. *Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.001*



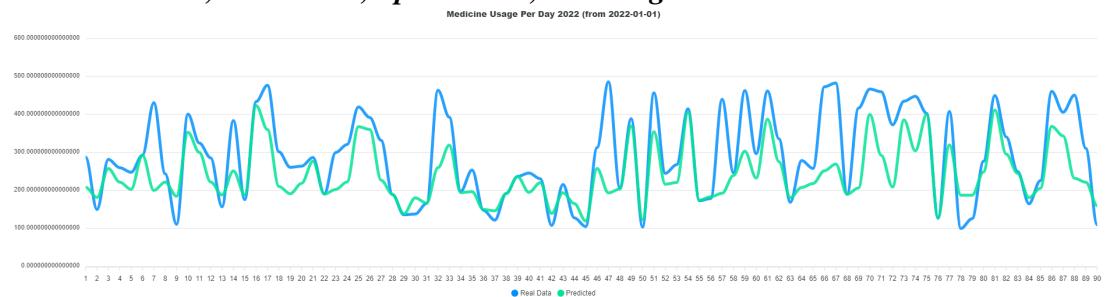
**Gambar 1.193** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 86. *Filter*: 32 & 64, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.001



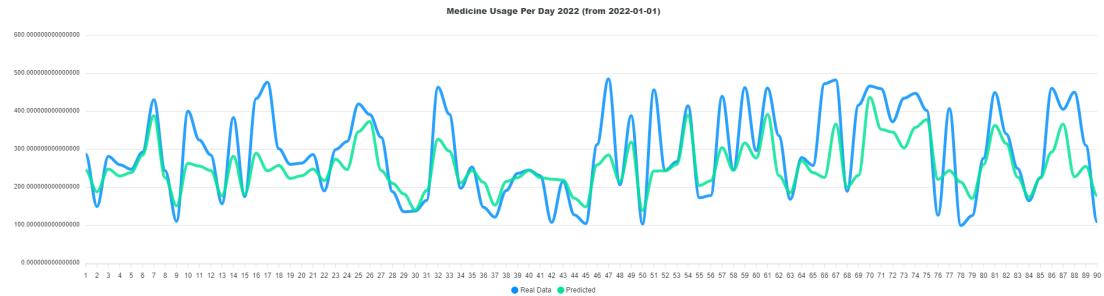
**Gambar 1.194** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 87. *Filter*: 32 & 64, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001



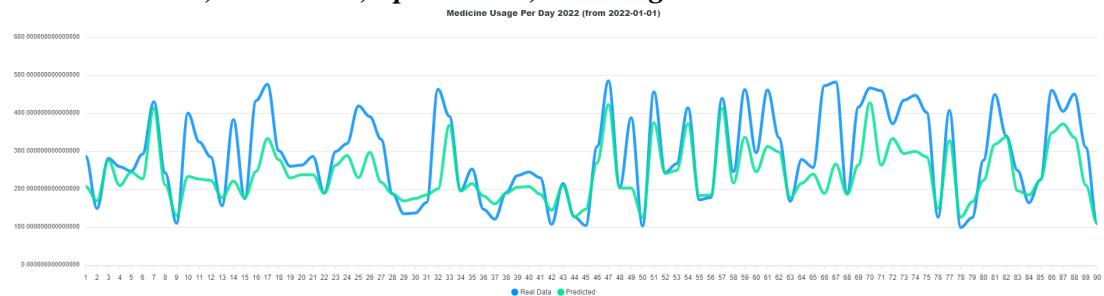
**Gambar 1.195** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 88. *Filter*: 32 & 64, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.001



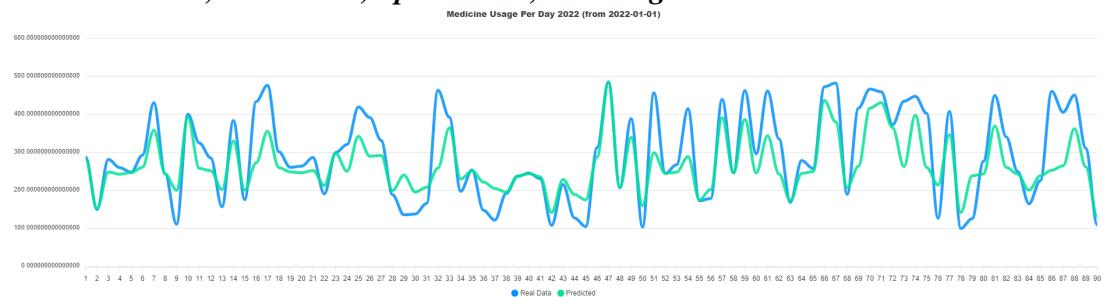
**Gambar 1.196** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 89. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001



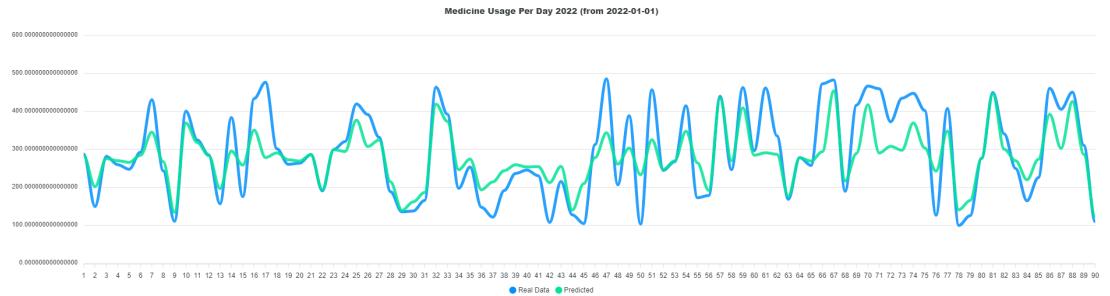
**Gambar 1.197** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 90. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001



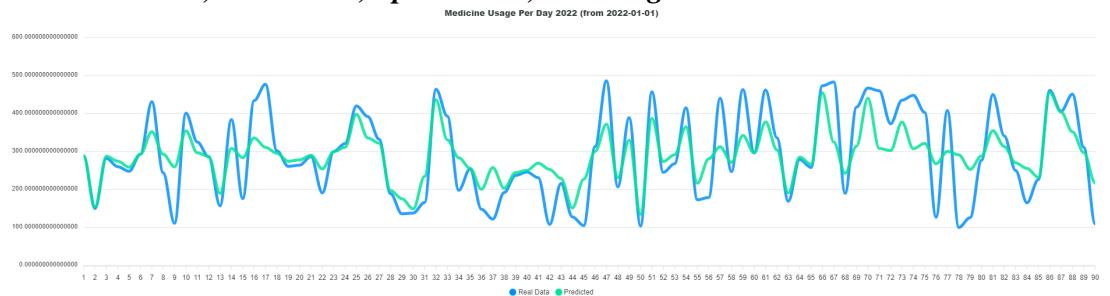
**Gambar 1.198** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 91. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001



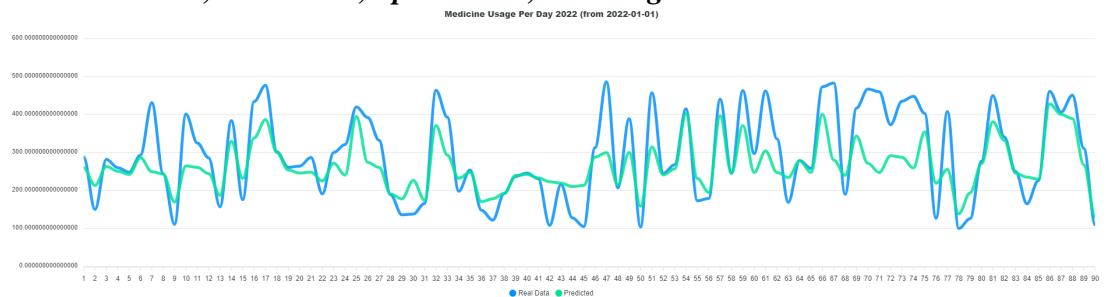
**Gambar 1.199** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 92. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.001



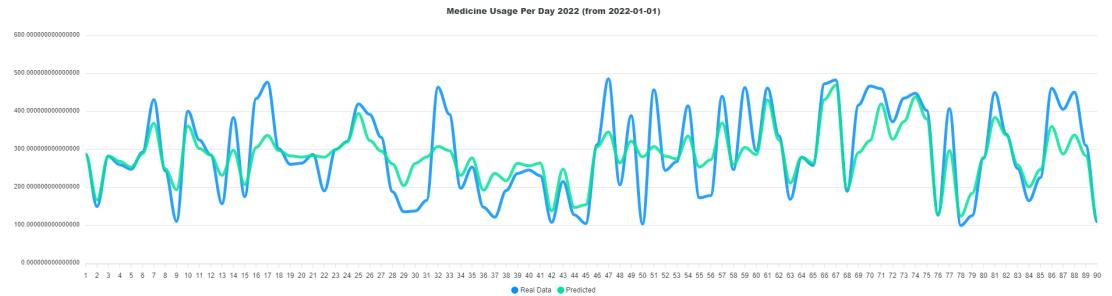
**Gambar 1.200** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 93. *Filter*: 32 & 64, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.001



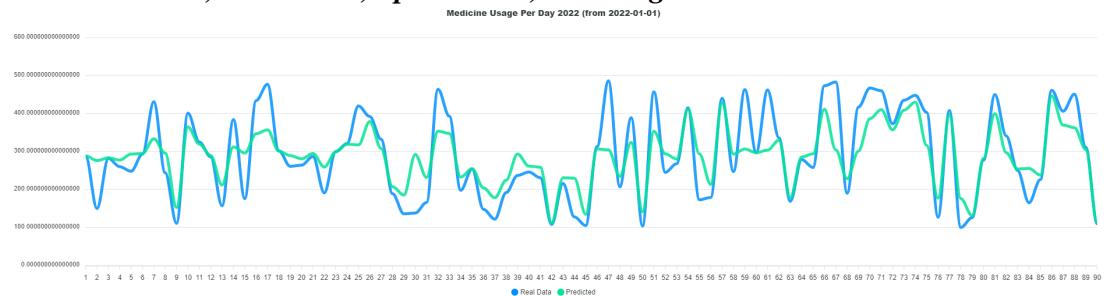
**Gambar 1.201** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 94. *Filter*: 32 & 64, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.001



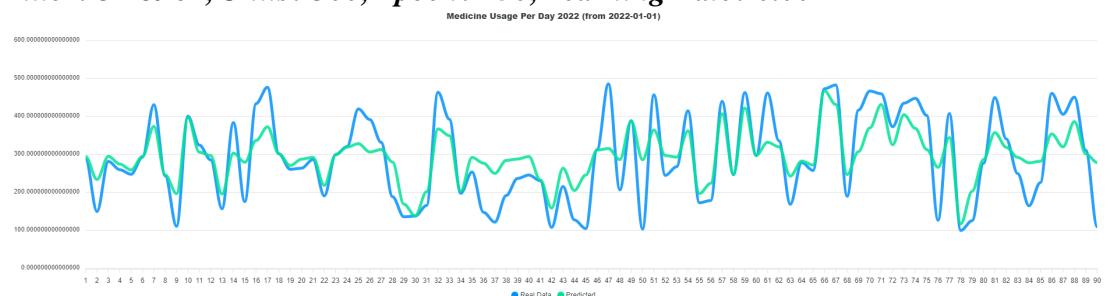
**Gambar 1.202** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 95. *Filter: 32 & 64, Units: 300, Epoch: 200, Learning Rate: 0.001*



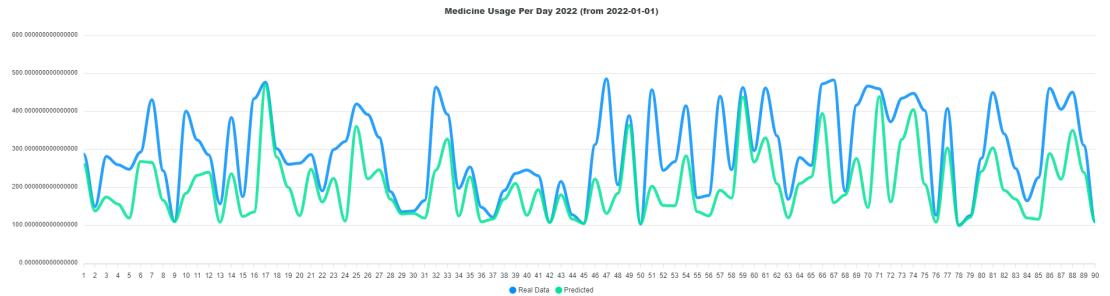
**Gambar 1.203** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 96. *Filter: 32 & 64, Units: 300, Epoch: 250, Learning Rate: 0.001*



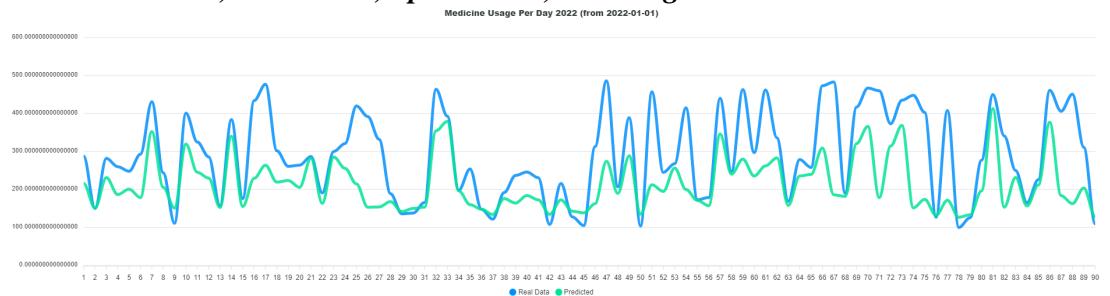
**Gambar 1.204** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 97. *Filter: 64 & 128, Units: 100, Epoch: 100, Learning Rate: 0.001*



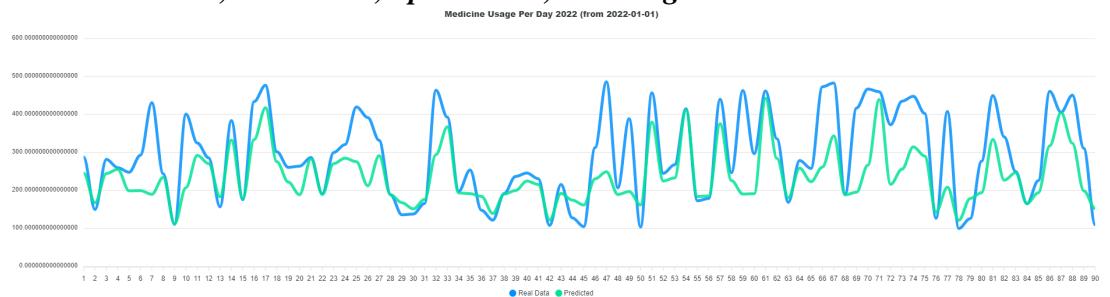
**Gambar 1.205** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 98. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.001



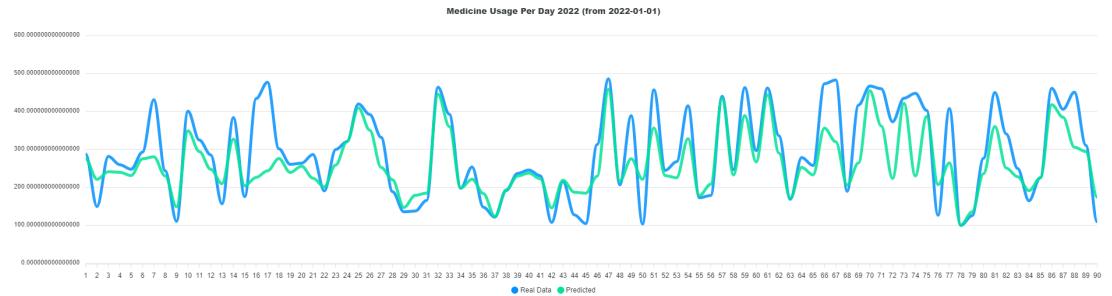
**Gambar 1.206** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 99. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001



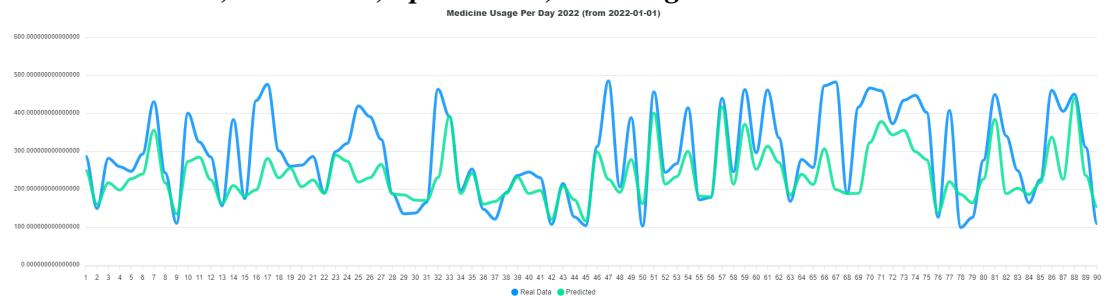
**Gambar 1.207** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 100. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.001



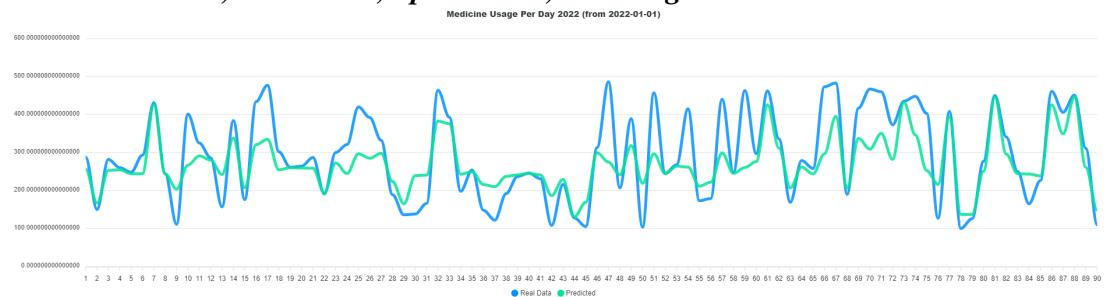
**Gambar 1.208** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 101. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001



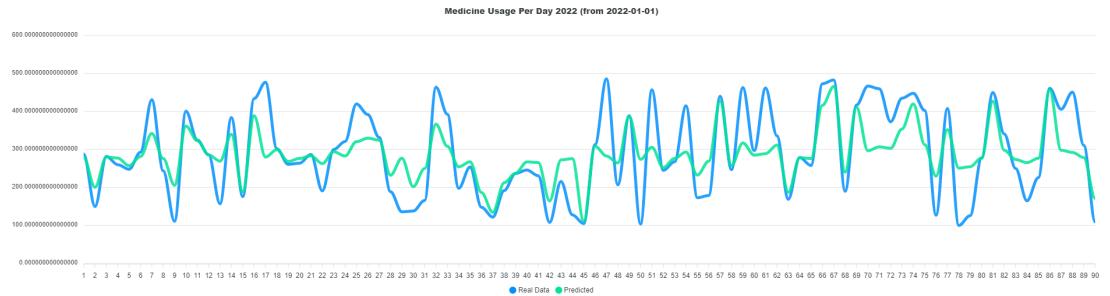
**Gambar 1.209** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 102. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001



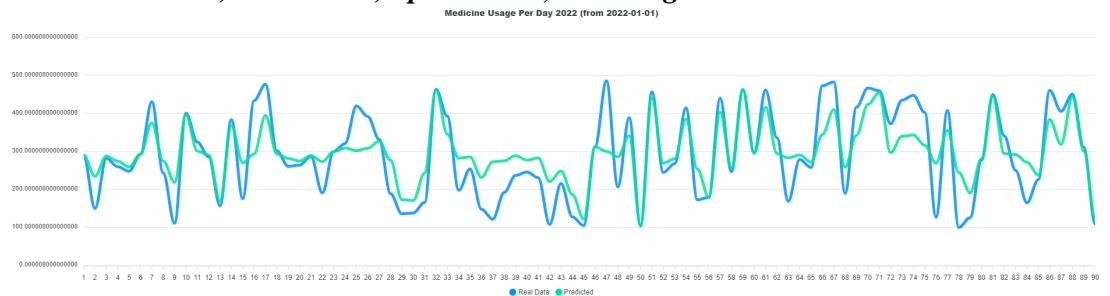
**Gambar 1.210** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 103. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001



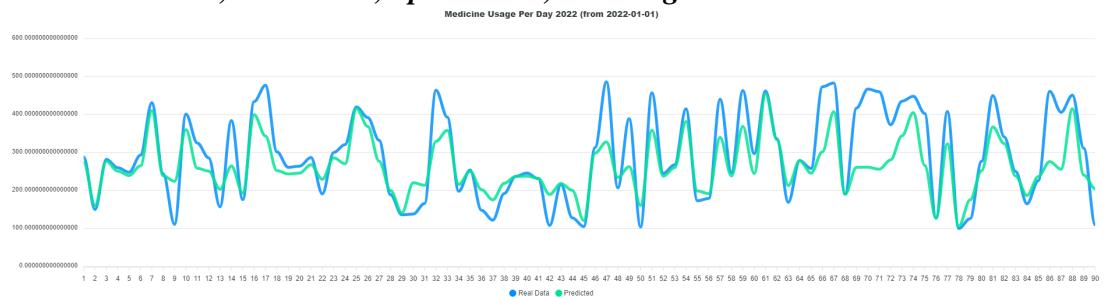
**Gambar 1.211** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 104. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.001



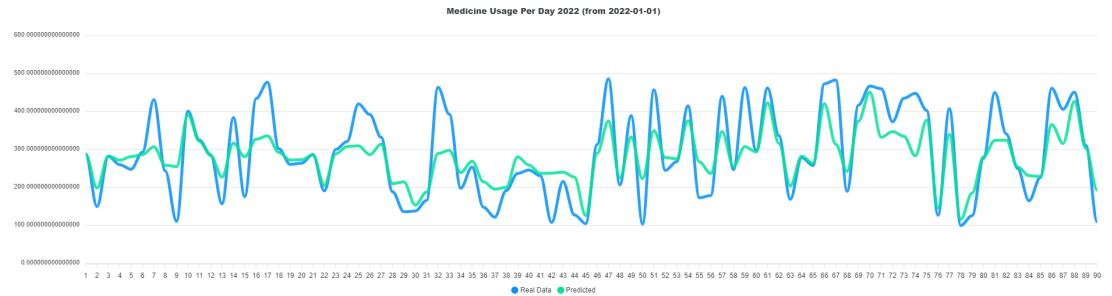
**Gambar 1.212** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 105. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.001



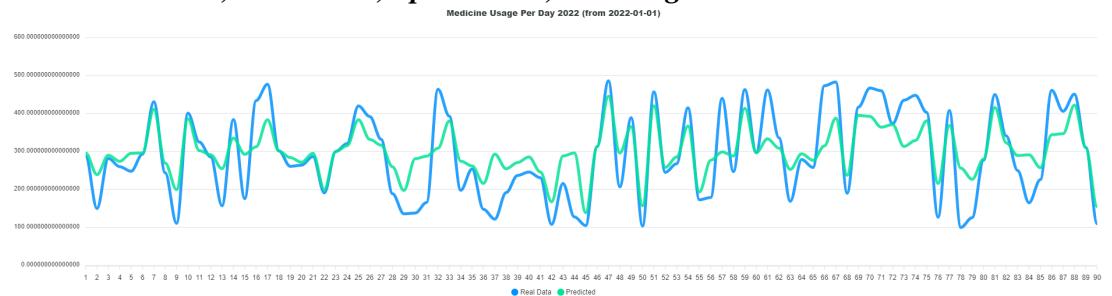
**Gambar 1.213** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 106. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.001



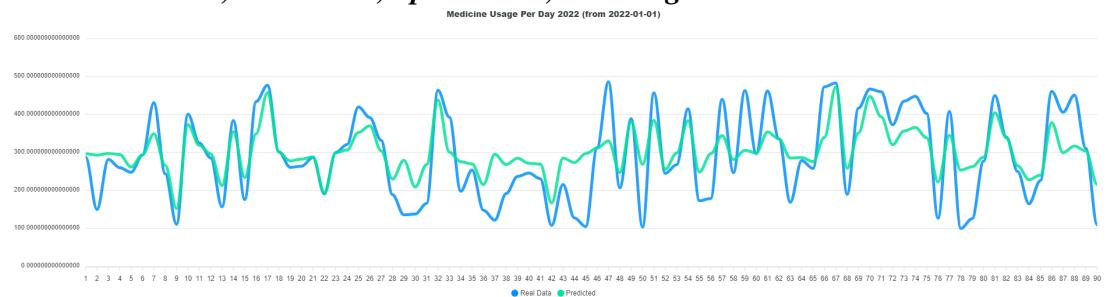
**Gambar 1.214** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 107. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.001



**Gambar 1.215** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 108. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.001

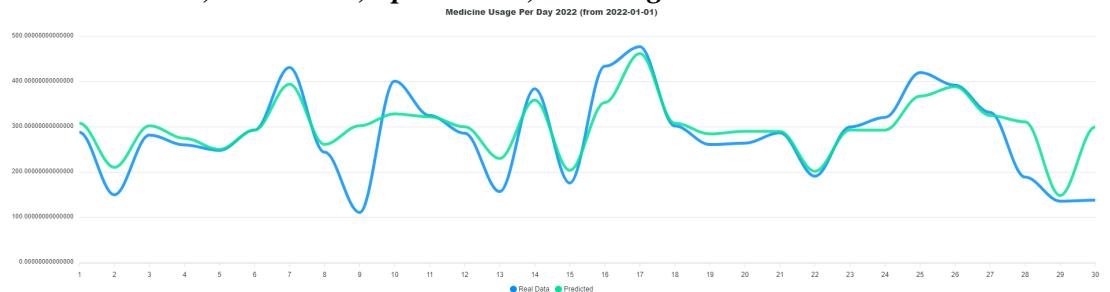


**Gambar 1.216** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.001 dan 2 lapisan *Max Pooling* untuk forecasting horizon 90 hari

## LAMPIRAN B HASIL PENGUJIAN ARSITEKTUR 2

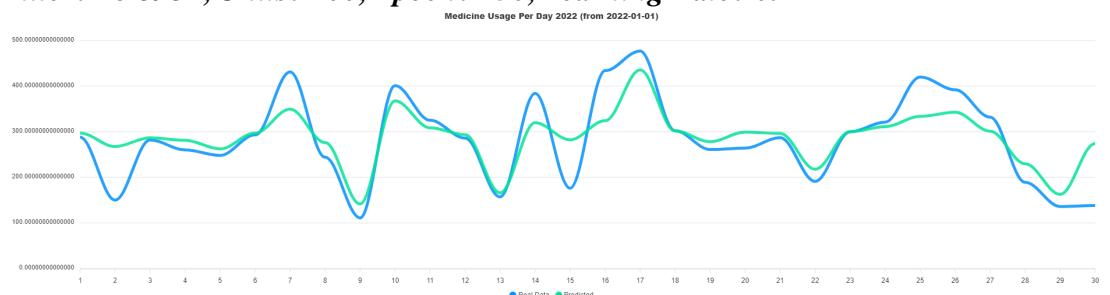
### 2.1 Forecasting Horizon 30 hari

#### 1. Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.1



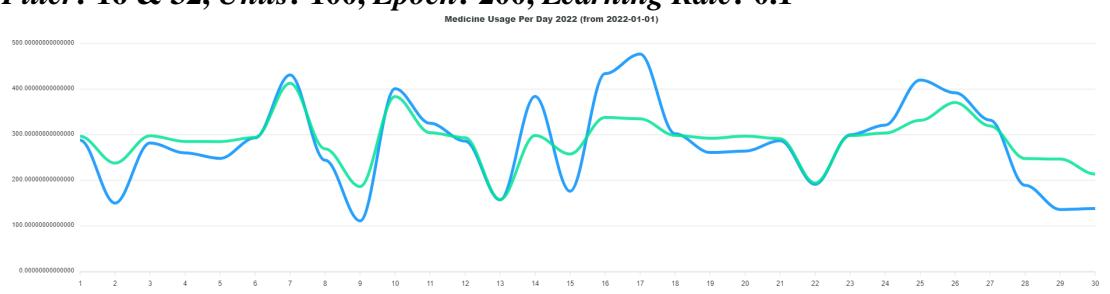
**Gambar 2.1** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

#### 2. Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.1



**Gambar 2.2** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

#### 3. Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.1

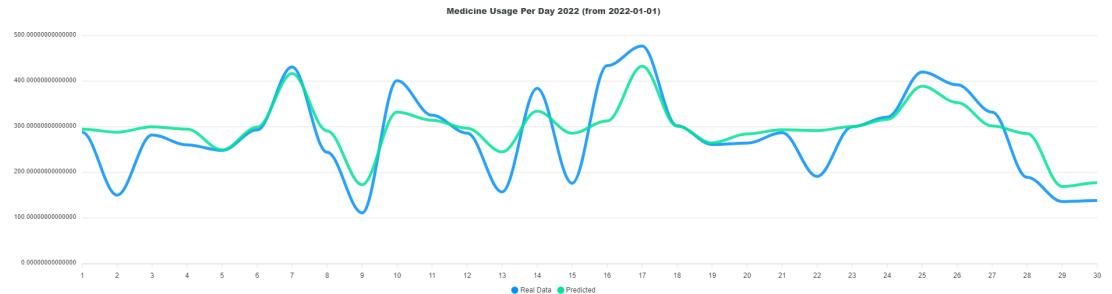


**Gambar 2.3** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

#### 4. Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.1

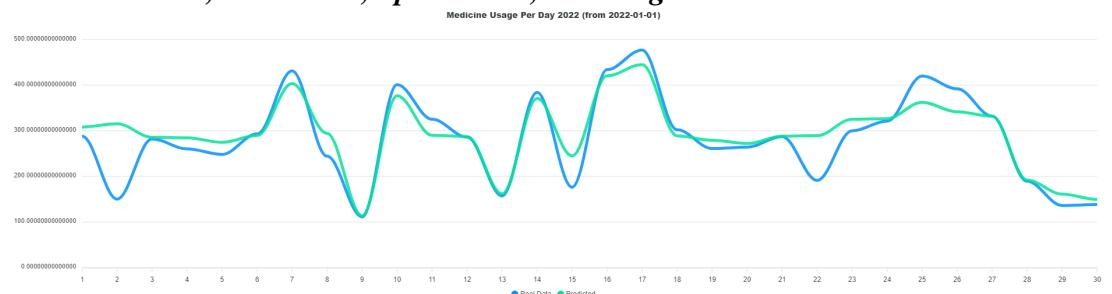
## BAB B Hasil Pengujian Arsitektur 2

---



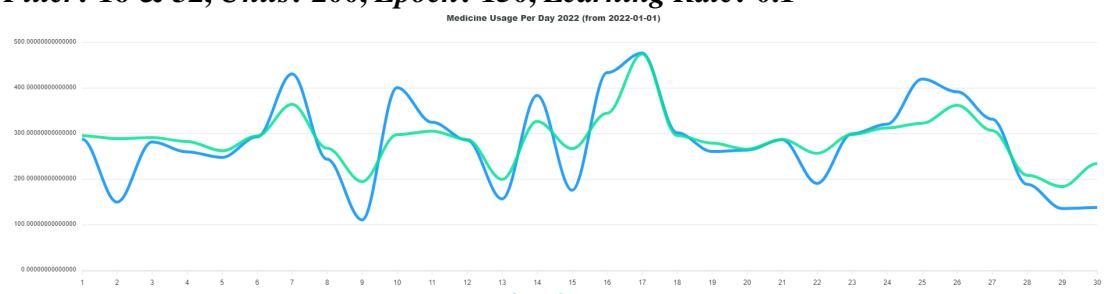
**Gambar 2.4** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 5. *Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.1*



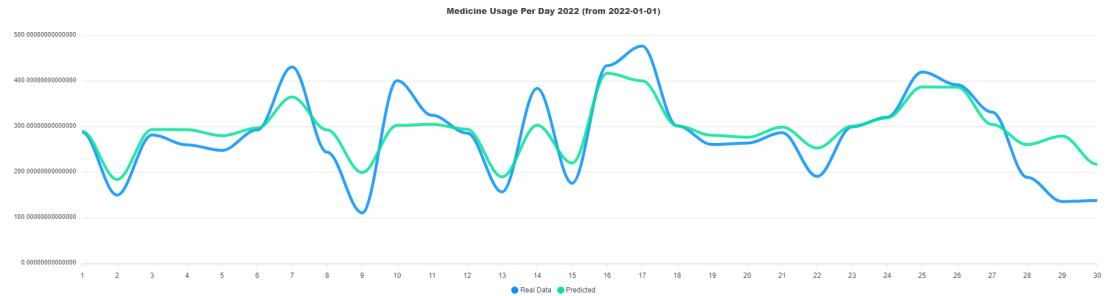
**Gambar 2.5** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 6. *Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.1*



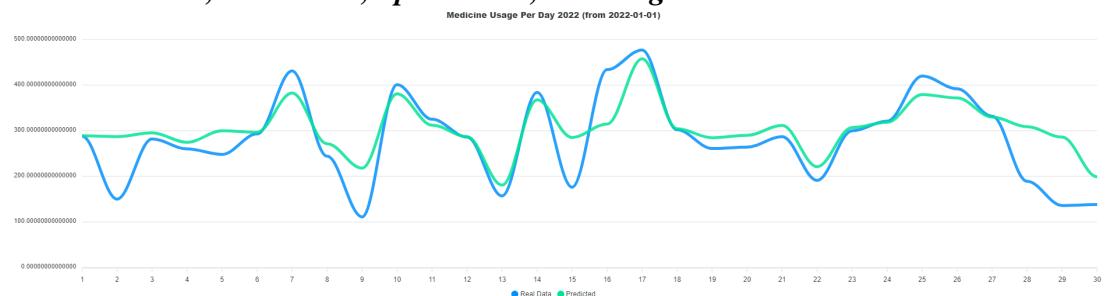
**Gambar 2.6** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 7. *Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.1*



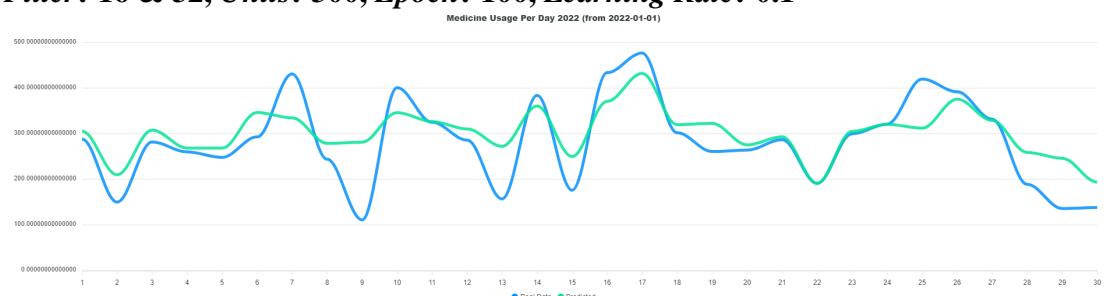
**Gambar 2.7** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 8. *Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.1*



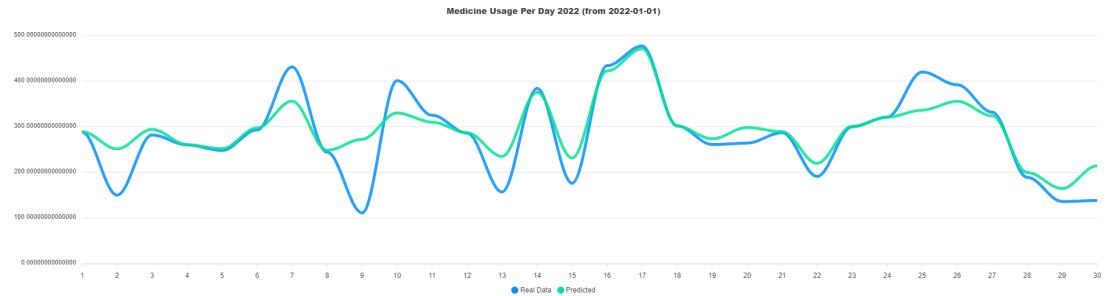
**Gambar 2.8** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 9. *Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.1*



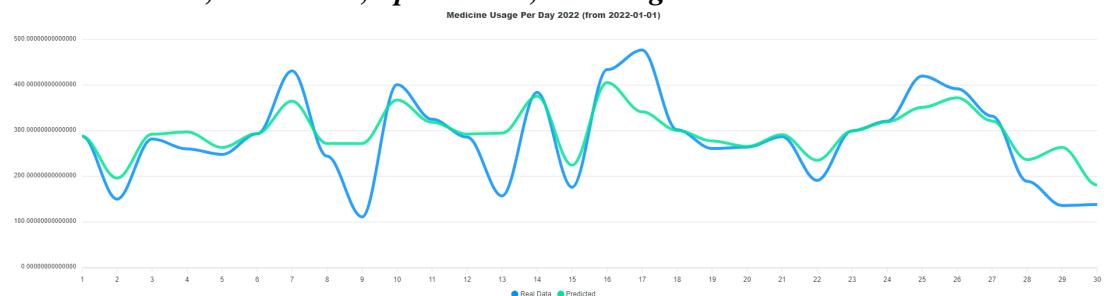
**Gambar 2.9** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 10. *Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.1*



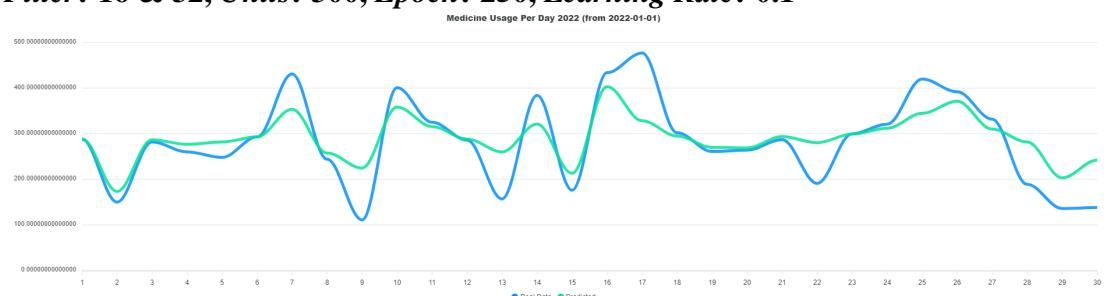
**Gambar 2.10** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 11. *Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.1*



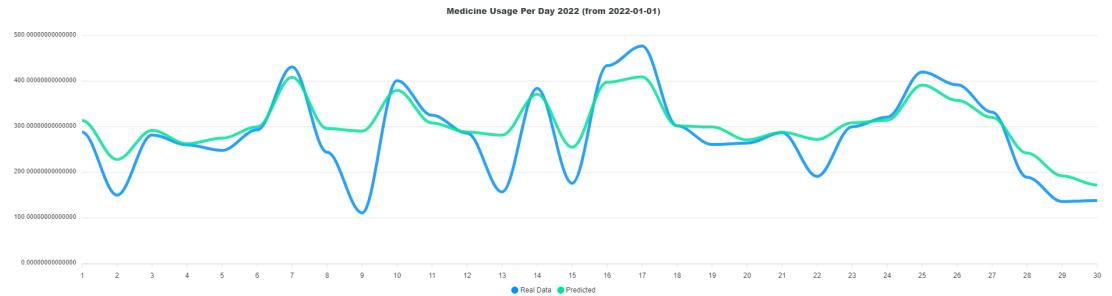
**Gambar 2.11** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 12. *Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.1*



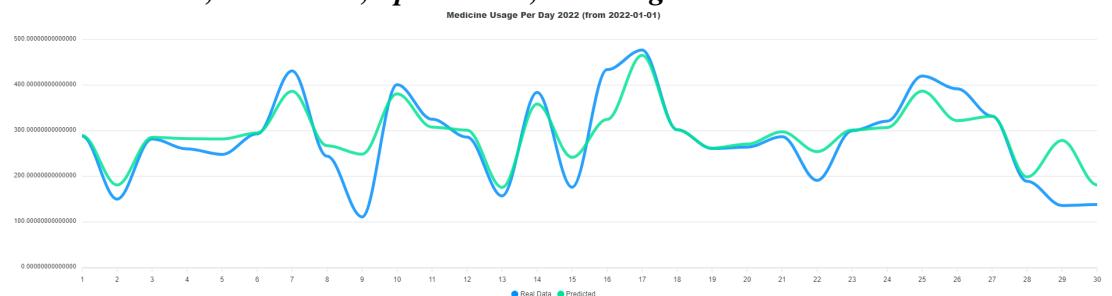
**Gambar 2.12** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 13. *Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.1*



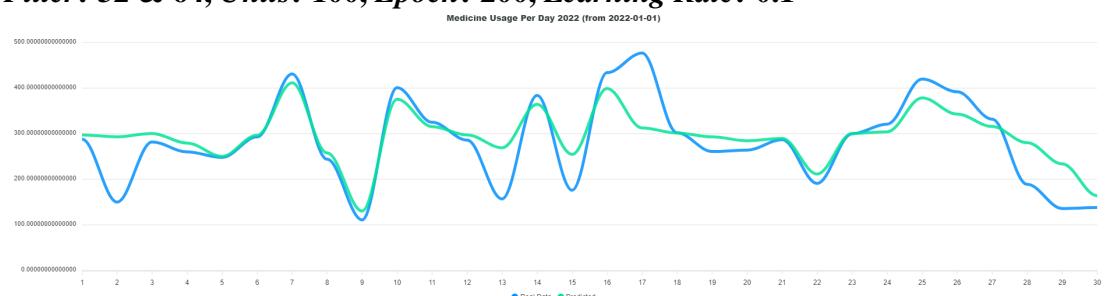
**Gambar 2.13** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 14. *Filter: 32 & 64, Units: 100, Epoch: 150, Learning Rate: 0.1*



**Gambar 2.14** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 15. *Filter: 32 & 64, Units: 100, Epoch: 200, Learning Rate: 0.1*

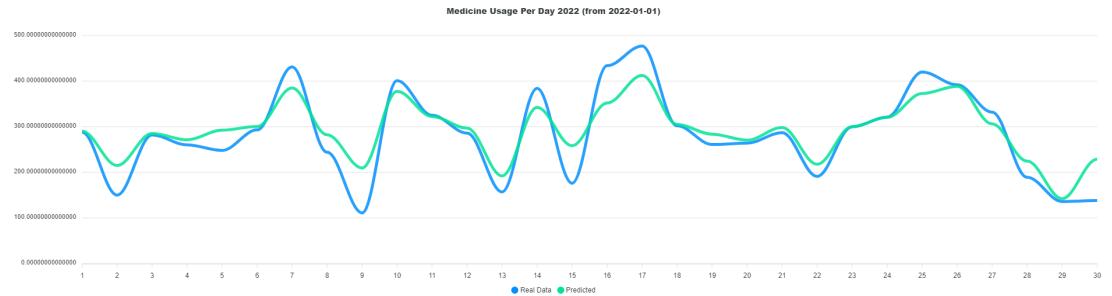


**Gambar 2.15** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 16. *Filter: 32 & 64, Units: 100, Epoch: 250, Learning Rate: 0.1*

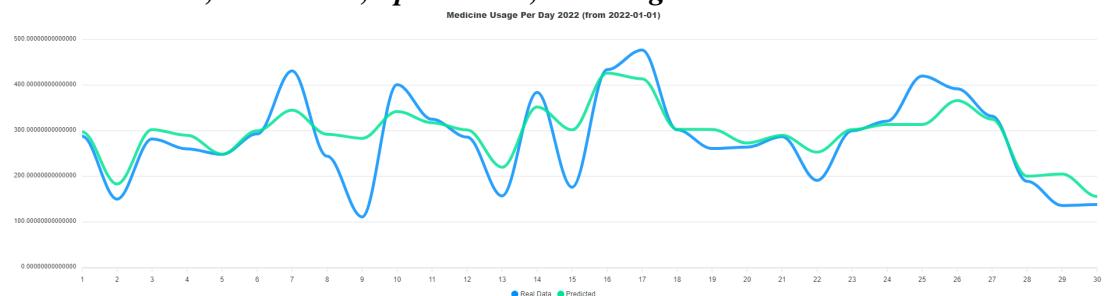
## BAB B Hasil Pengujian Arsitektur 2

---



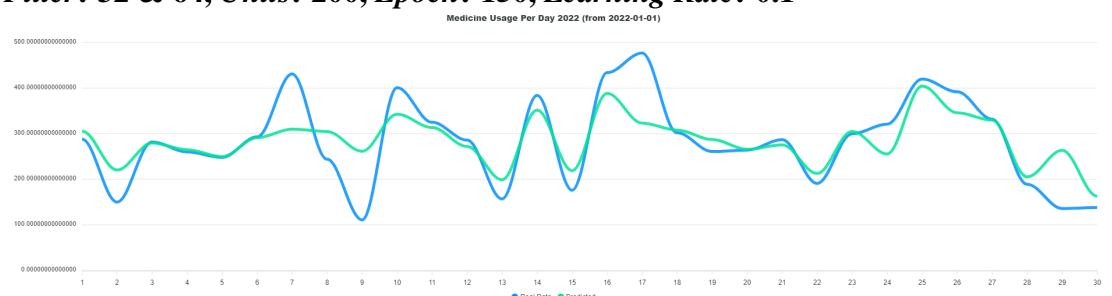
**Gambar 2.16** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 17. *Filter: 32 & 64, Units: 200, Epoch: 100, Learning Rate: 0.1*



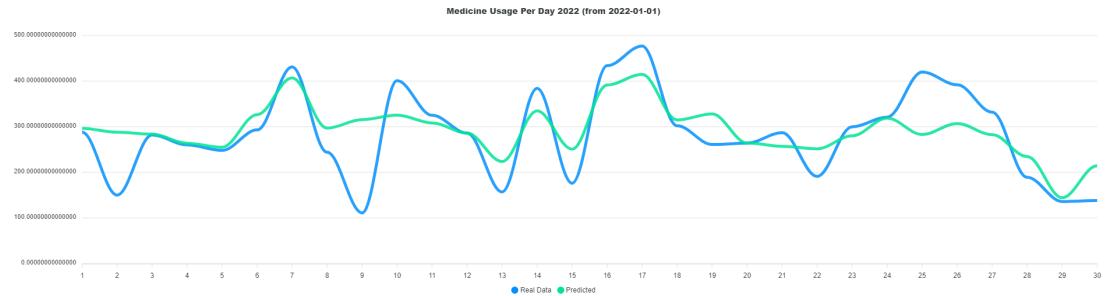
**Gambar 2.17** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 18. *Filter: 32 & 64, Units: 200, Epoch: 150, Learning Rate: 0.1*



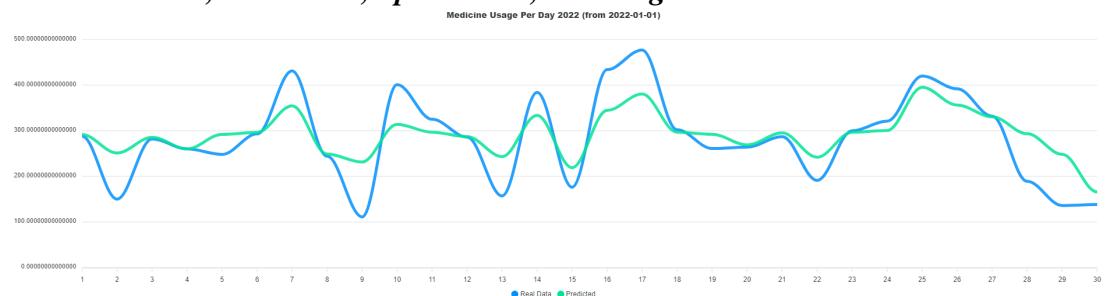
**Gambar 2.18** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 19. *Filter: 32 & 64, Units: 200, Epoch: 200, Learning Rate: 0.1*



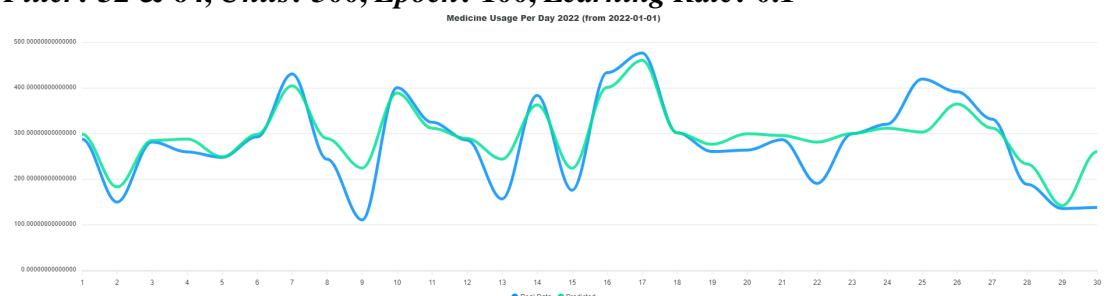
**Gambar 2.19** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 20. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1



**Gambar 2.20** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 21. *Filter*: 32 & 64, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1

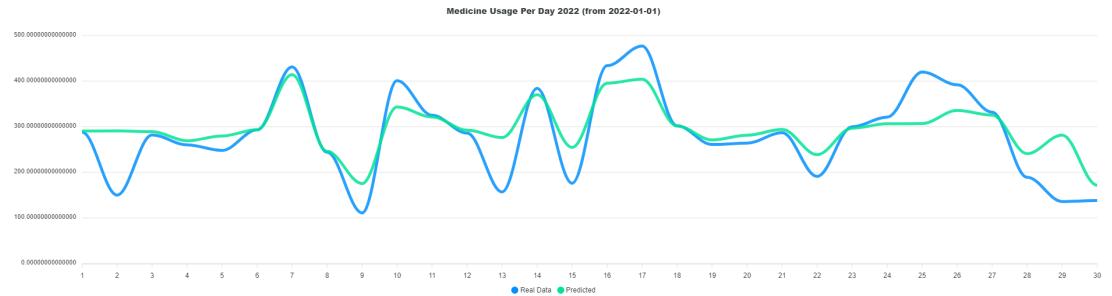


**Gambar 2.21** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 22. *Filter*: 32 & 64, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1

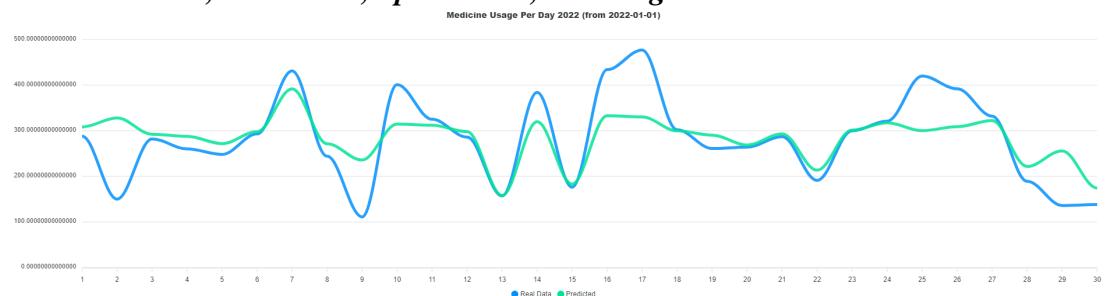
## BAB B Hasil Pengujian Arsitektur 2

---



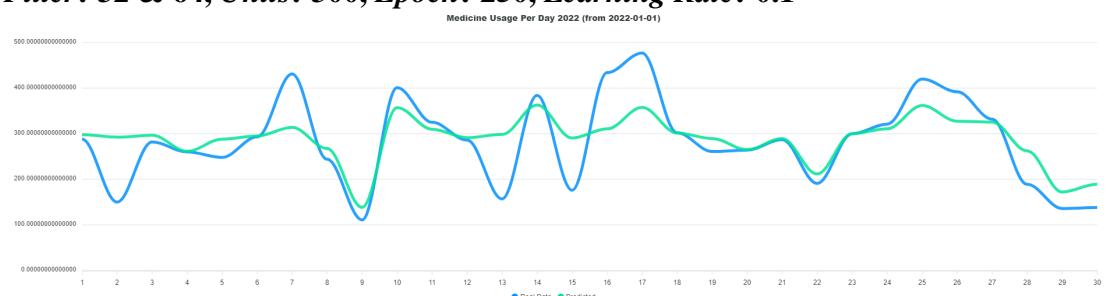
**Gambar 2.22** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 23. *Filter: 32 & 64, Units: 300, Epoch: 200, Learning Rate: 0.1*



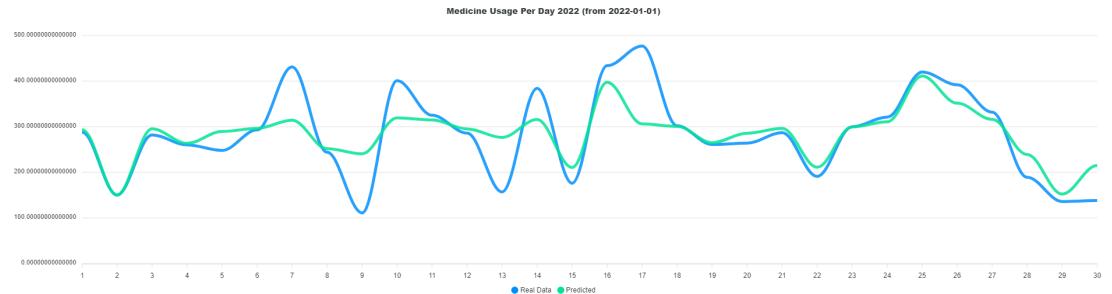
**Gambar 2.23** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 24. *Filter: 32 & 64, Units: 300, Epoch: 250, Learning Rate: 0.1*



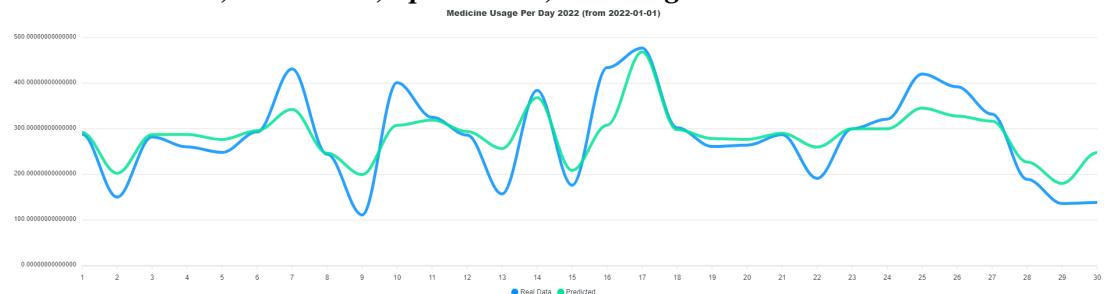
**Gambar 2.24** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 25. *Filter: 64 & 128, Units: 100, Epoch: 100, Learning Rate: 0.1*



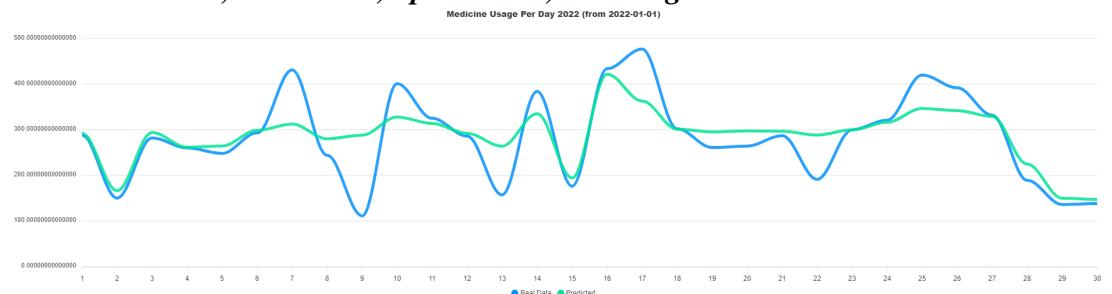
**Gambar 2.25** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 26. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.1



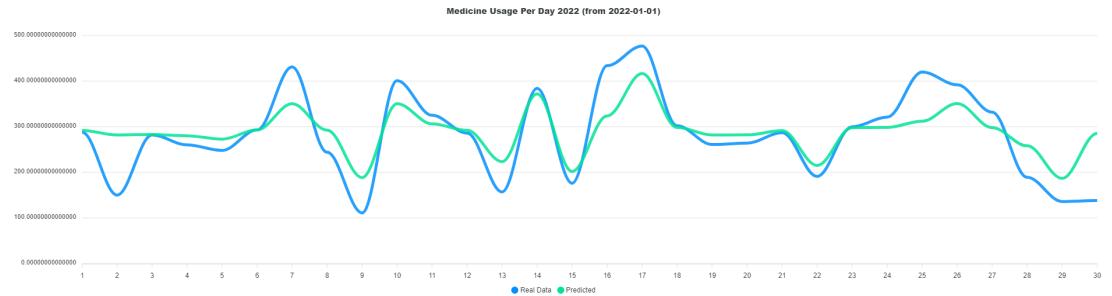
**Gambar 2.26** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 27. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.1



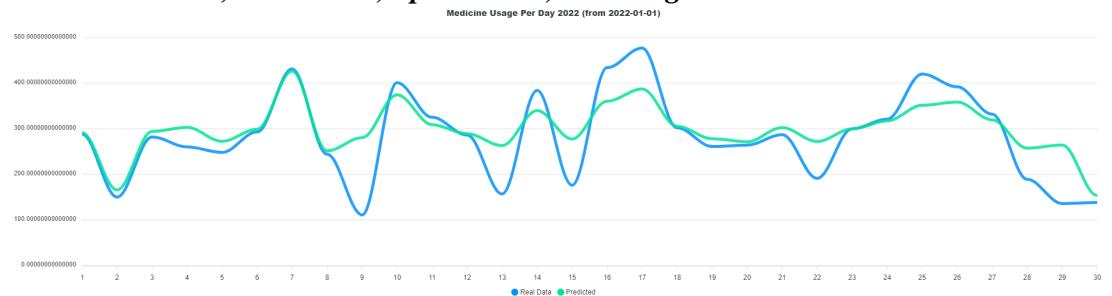
**Gambar 2.27** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 28. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.1



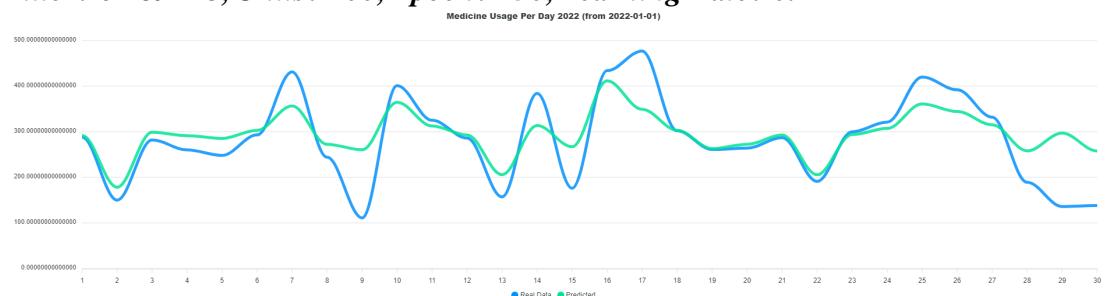
**Gambar 2.28** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 29. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.1



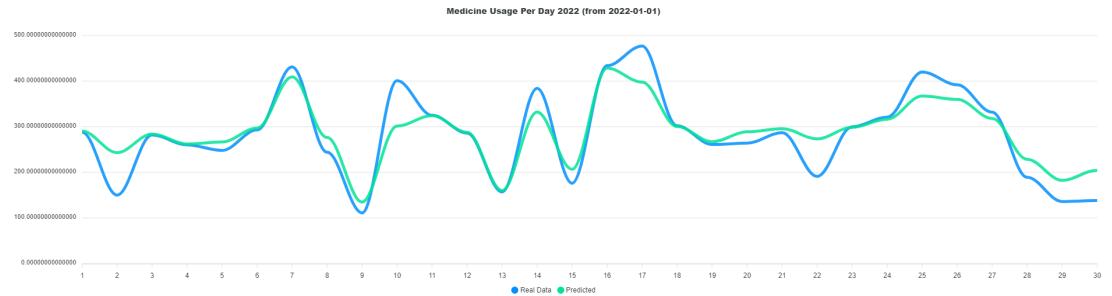
**Gambar 2.29** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 30. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.1



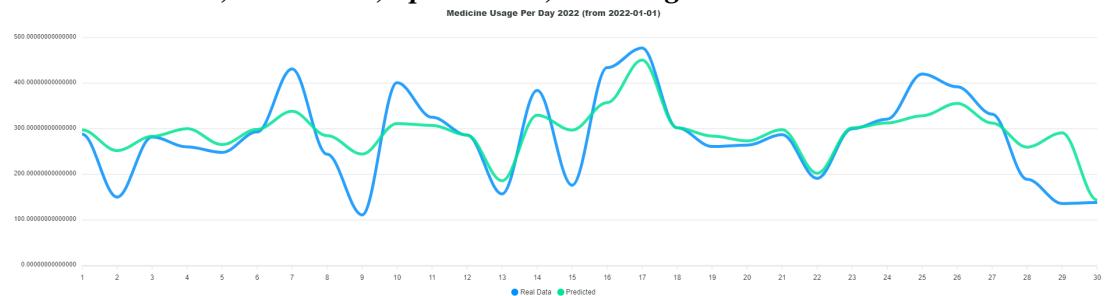
**Gambar 2.30** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 31. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.1



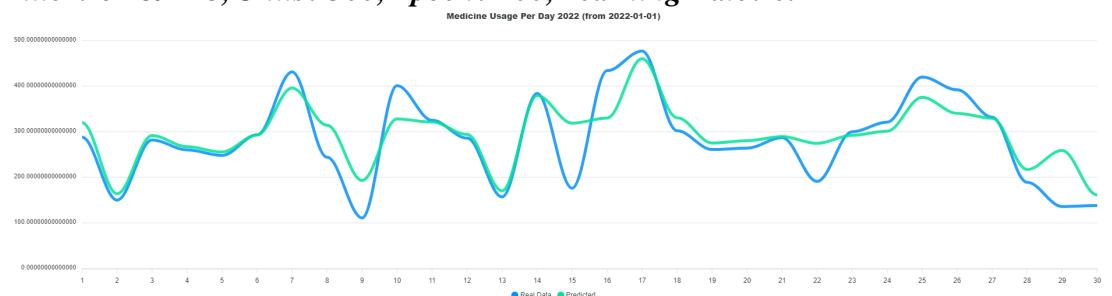
**Gambar 2.31** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 32. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1



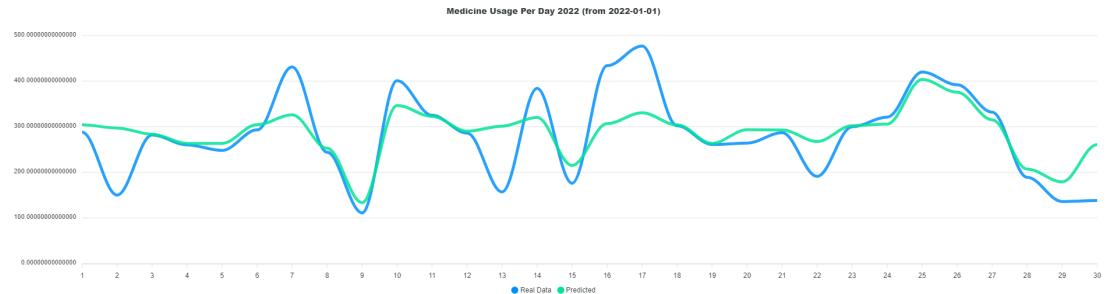
**Gambar 2.32** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 33. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1



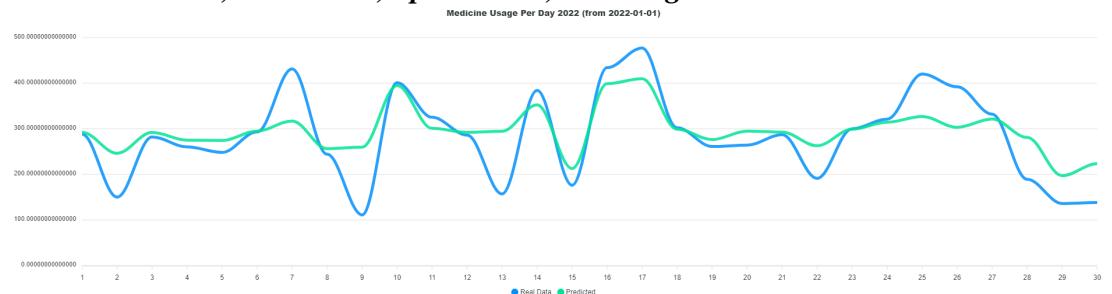
**Gambar 2.33** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 34. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1



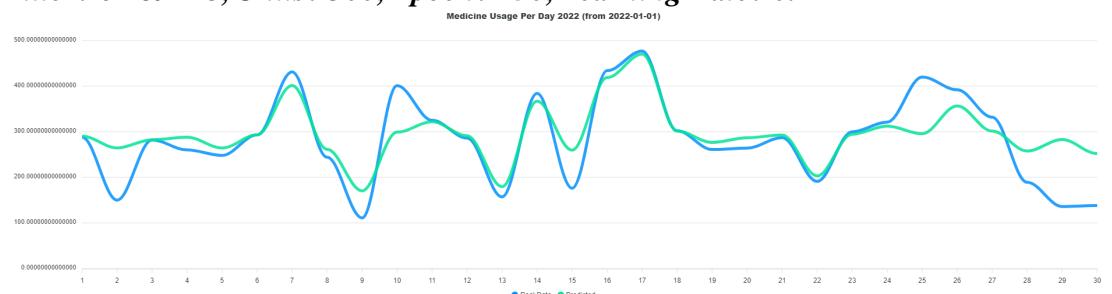
**Gambar 2.34** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 35. *Filter: 64 & 128, Units: 300, Epoch: 200, Learning Rate: 0.1*



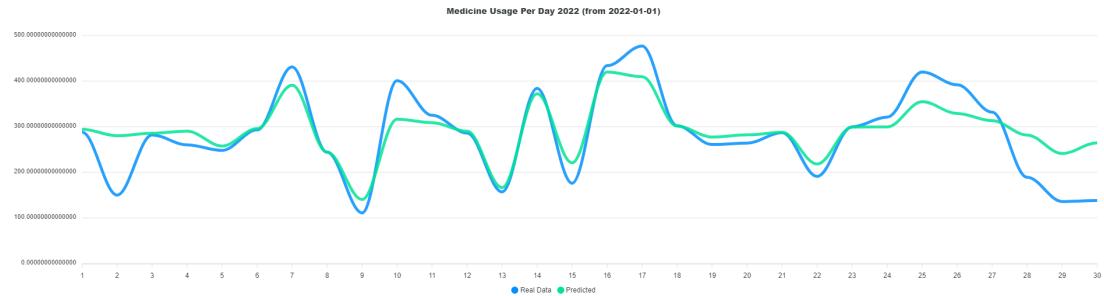
**Gambar 2.35** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 36. *Filter: 64 & 128, Units: 300, Epoch: 250, Learning Rate: 0.1*



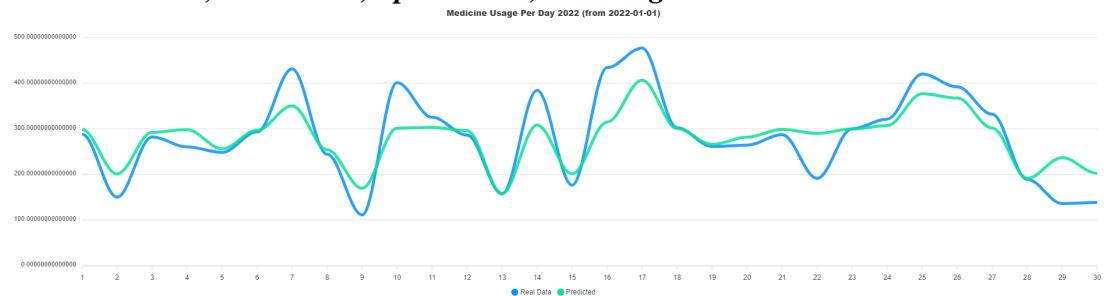
**Gambar 2.36** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 37. *Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.01*



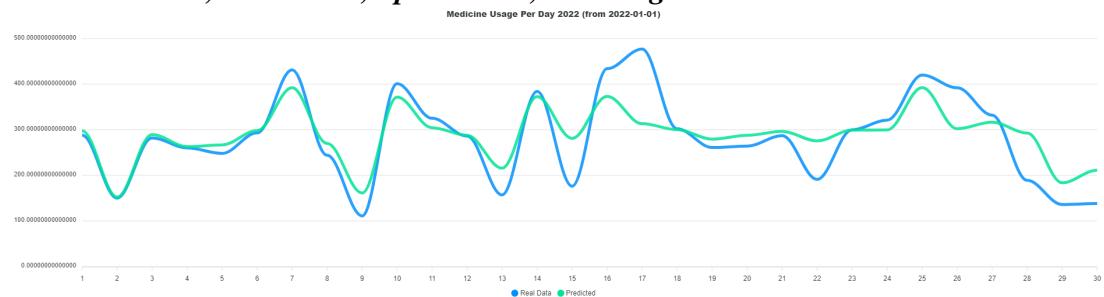
**Gambar 2.37** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 38. *Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.01*



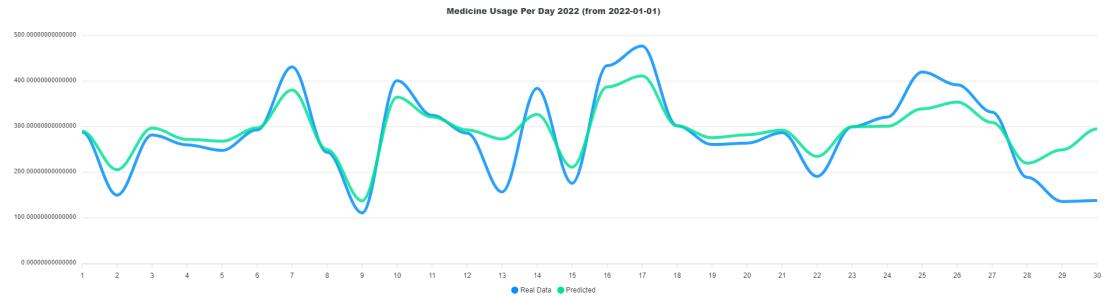
**Gambar 2.38** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 39. *Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.01*



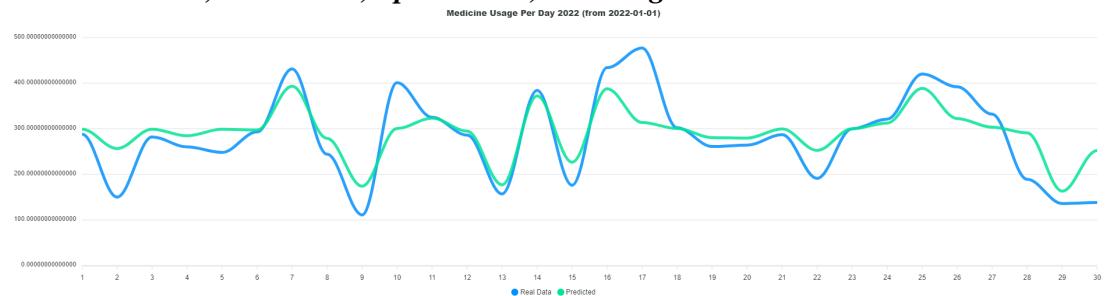
**Gambar 2.39** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 40. *Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.01*



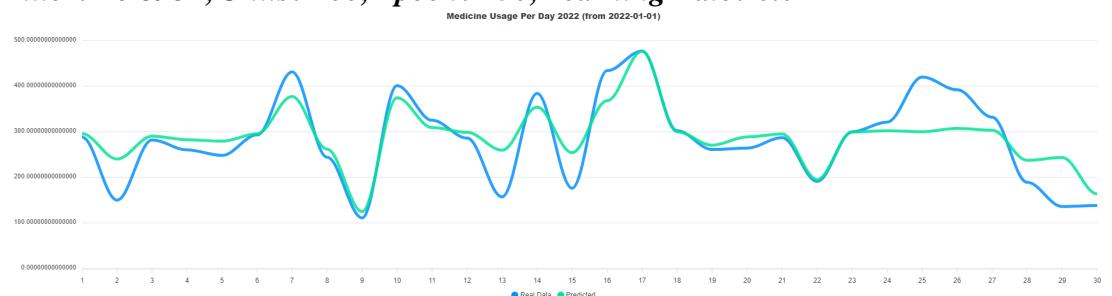
**Gambar 2.40** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 41. *Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.01*



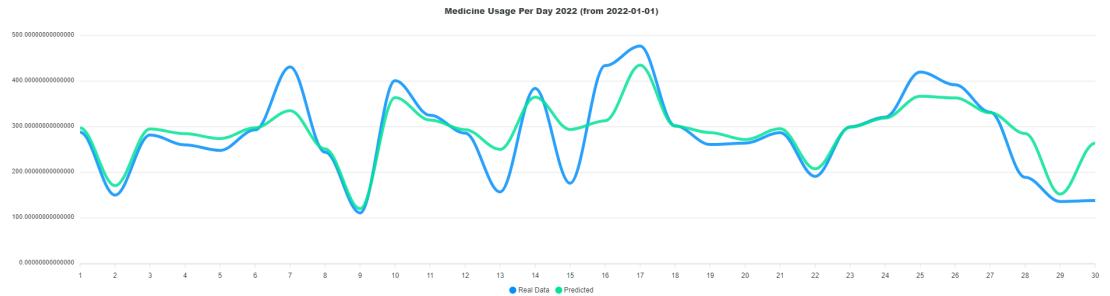
**Gambar 2.41** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 42. *Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.01*



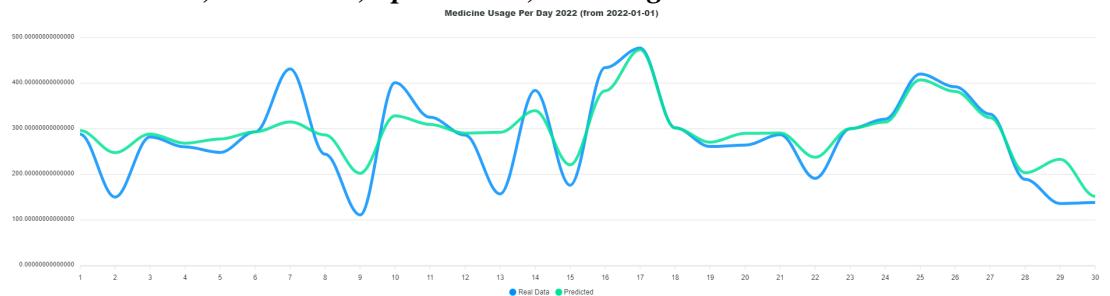
**Gambar 2.42** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 43. *Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.01*



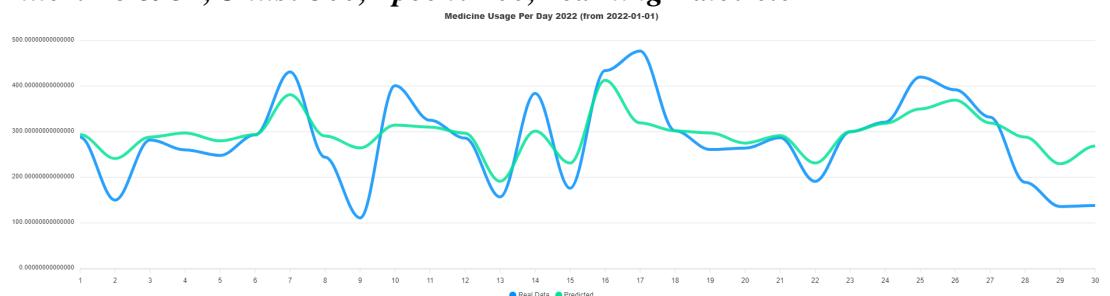
**Gambar 2.43** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 44. *Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.01*



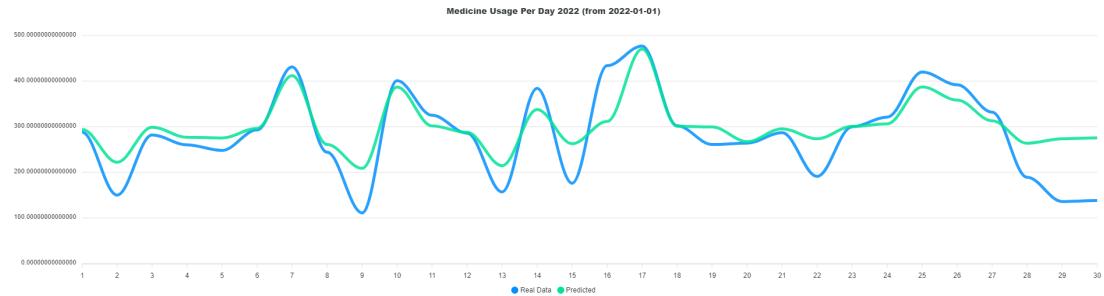
**Gambar 2.44** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 45. *Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.01*



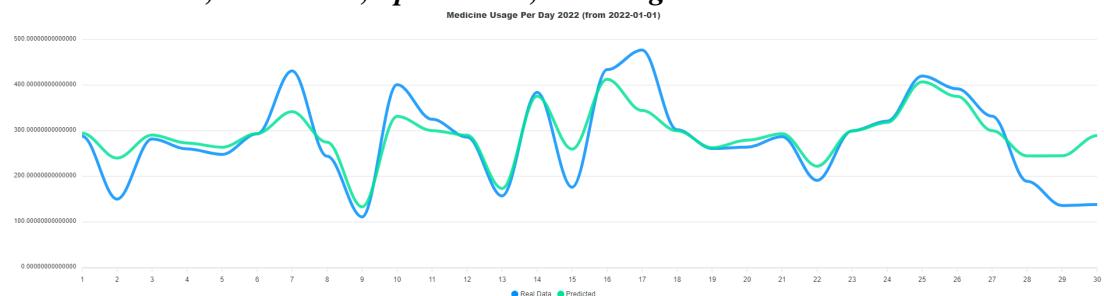
**Gambar 2.45** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 46. *Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.01*



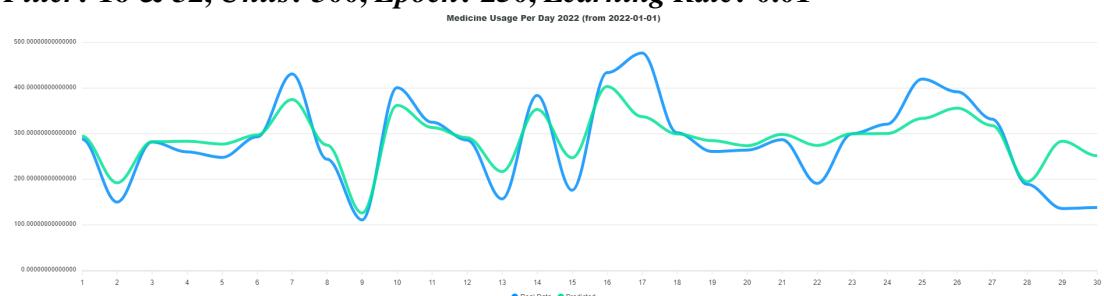
**Gambar 2.46** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 47. *Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.01*



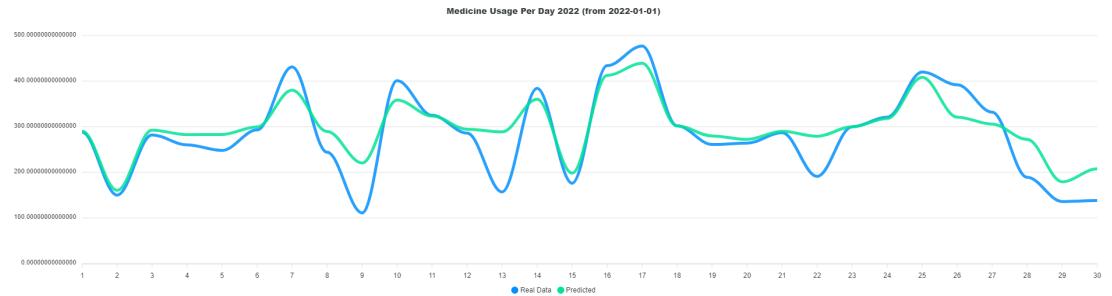
**Gambar 2.47** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 48. *Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.01*



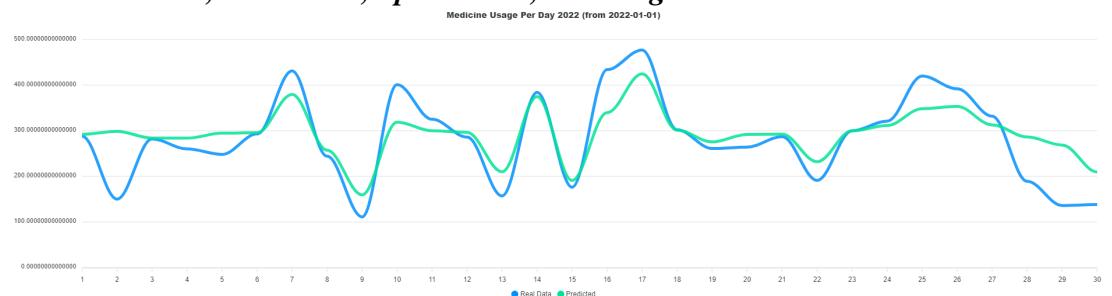
**Gambar 2.48** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 49. *Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.01*



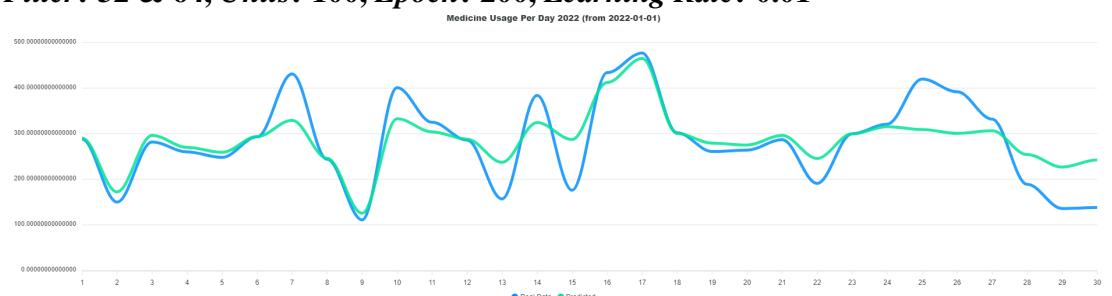
**Gambar 2.49** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 50. *Filter*: 32 & 64, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01



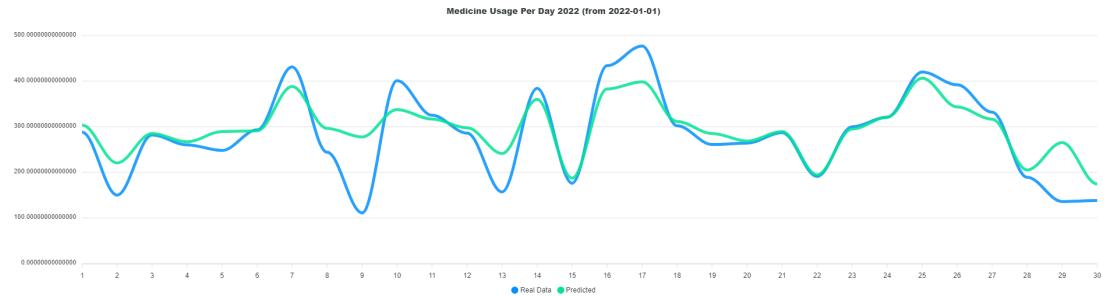
**Gambar 2.50** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 51. *Filter*: 32 & 64, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01



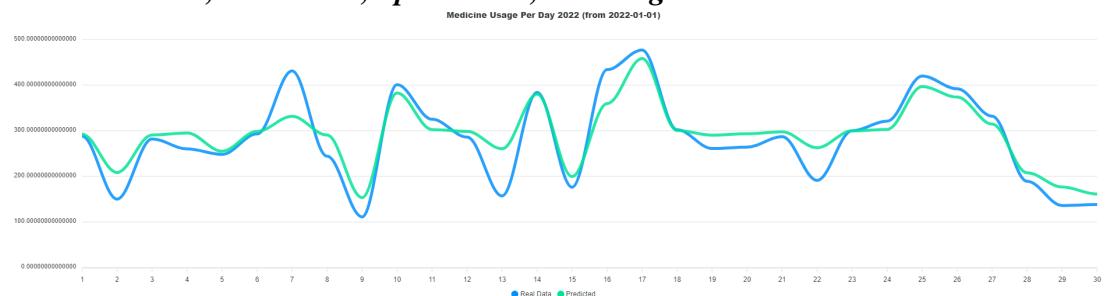
**Gambar 2.51** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 52. *Filter*: 32 & 64, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01



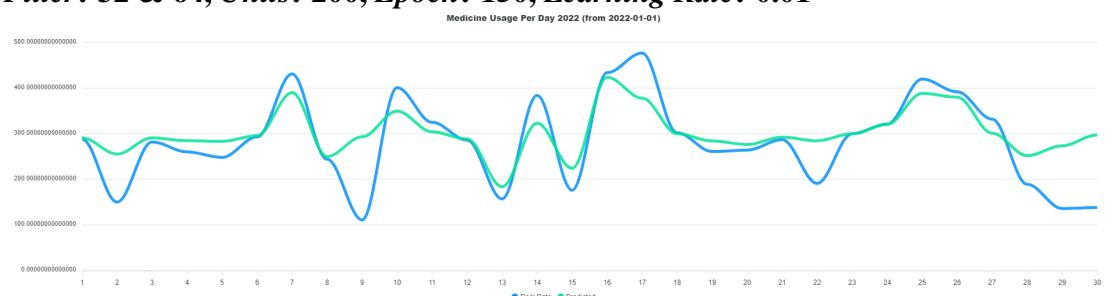
**Gambar 2.52** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 53. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.01



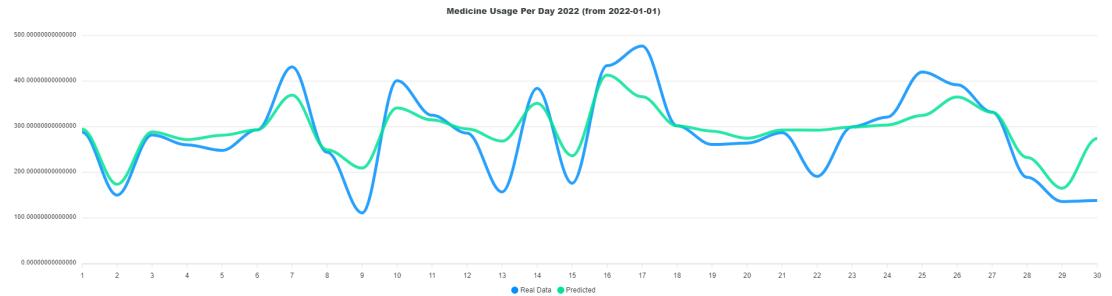
**Gambar 2.53** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 54. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.01



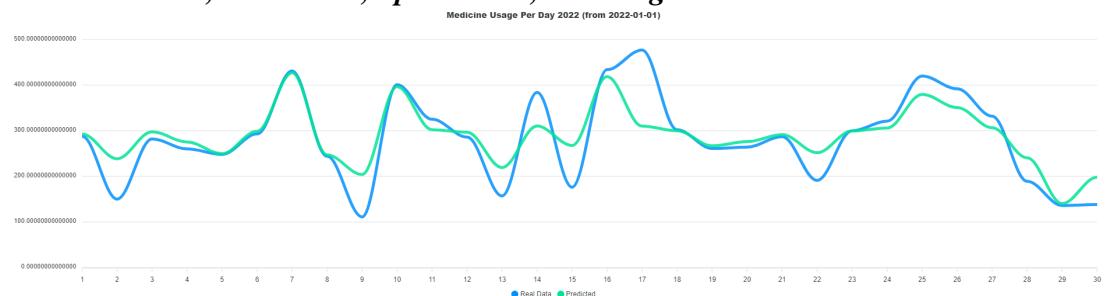
**Gambar 2.54** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 55. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.01



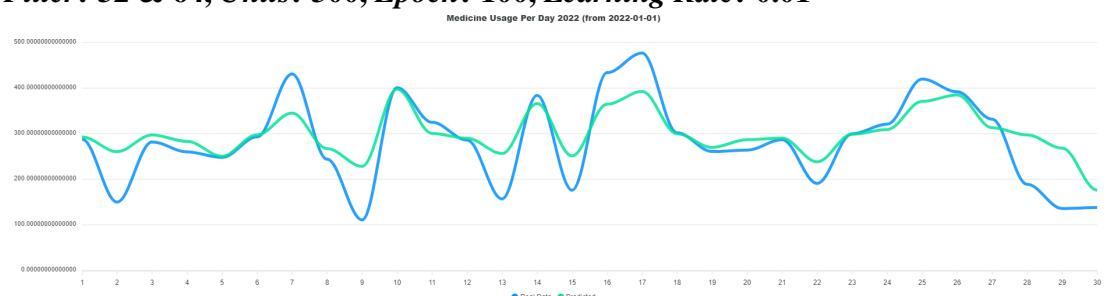
**Gambar 2.55** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 56. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.01



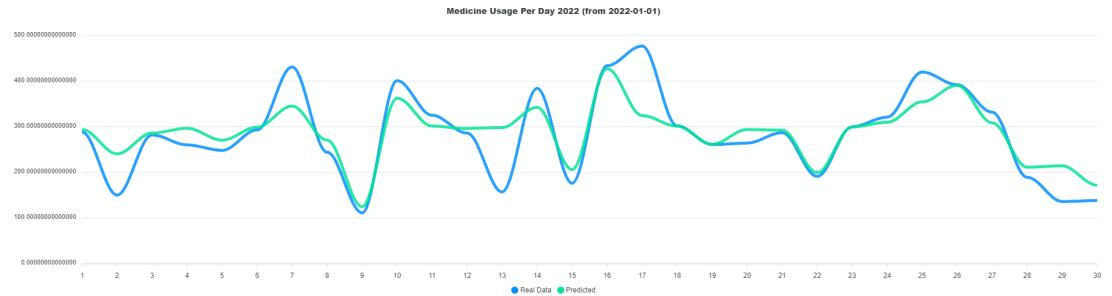
**Gambar 2.56** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 57. *Filter*: 32 & 64, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.01



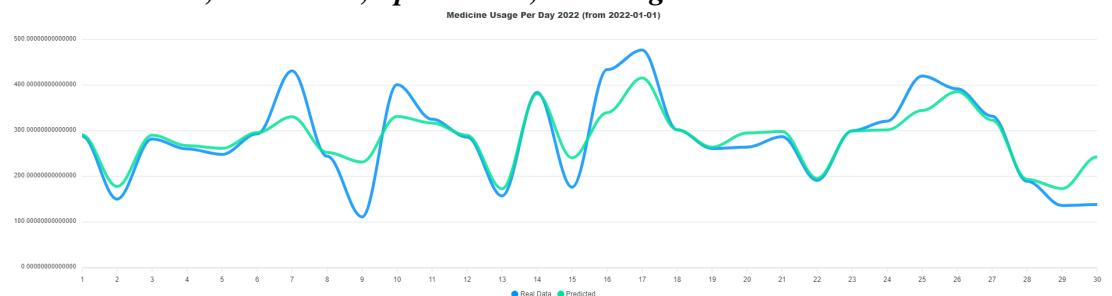
**Gambar 2.57** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 58. *Filter*: 32 & 64, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.01



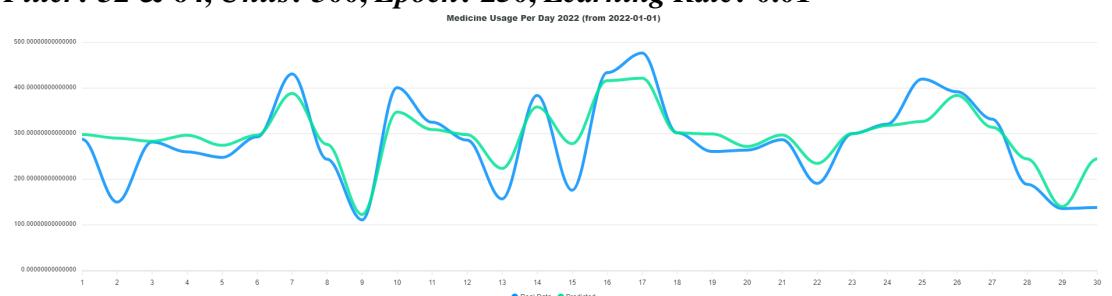
**Gambar 2.58** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 59. *Filter*: 32 & 64, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.01



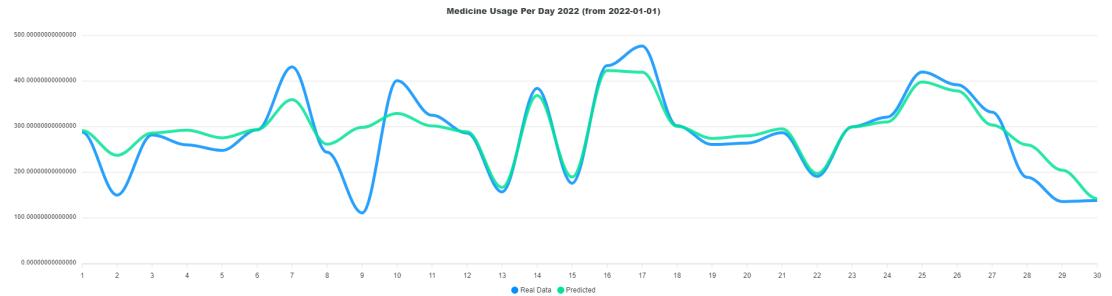
**Gambar 2.59** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 60. *Filter*: 32 & 64, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.01



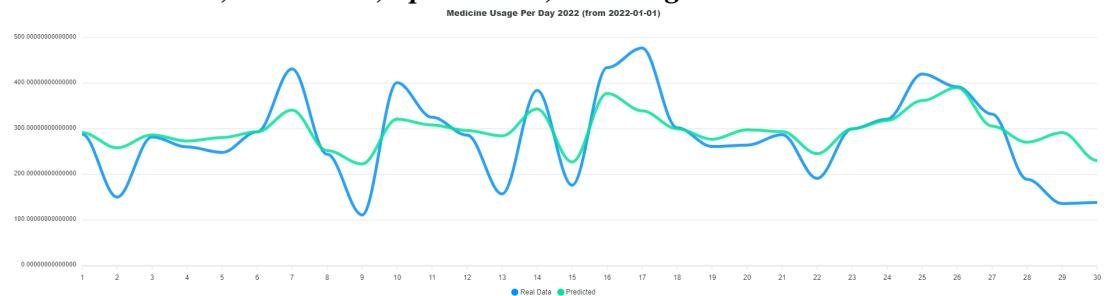
**Gambar 2.60** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 61. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.01



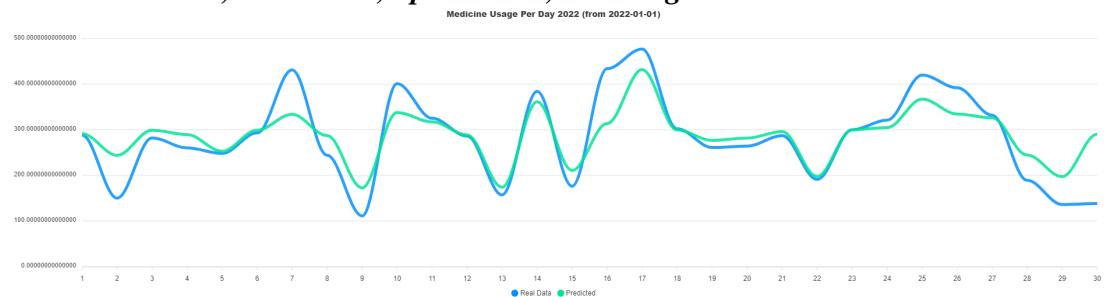
**Gambar 2.61** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 62. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01



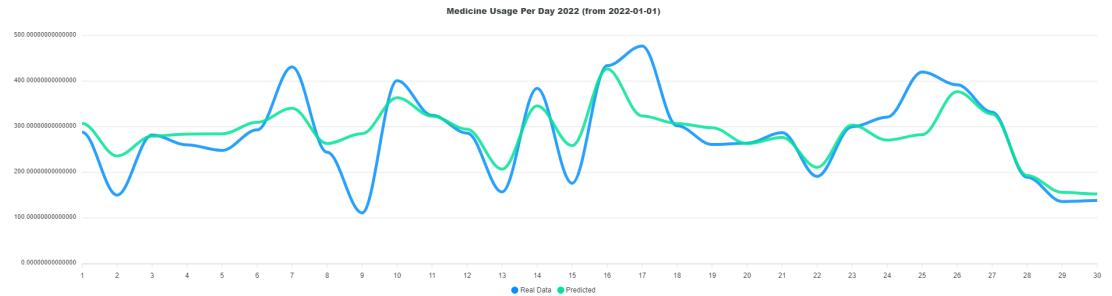
**Gambar 2.62** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 63. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01



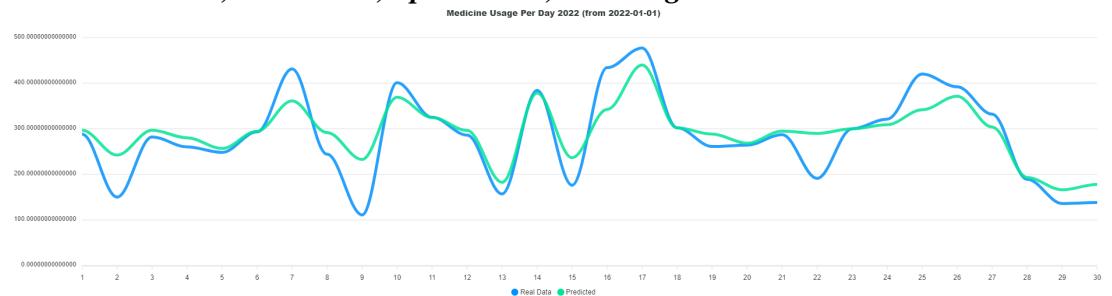
**Gambar 2.63** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 64. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01



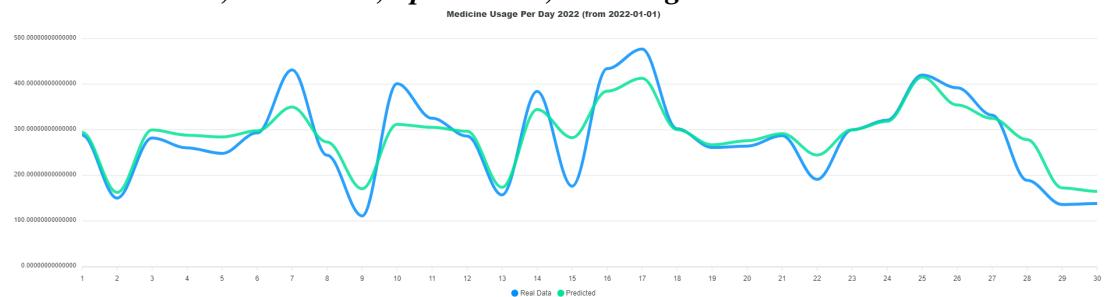
**Gambar 2.64** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 65. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.01



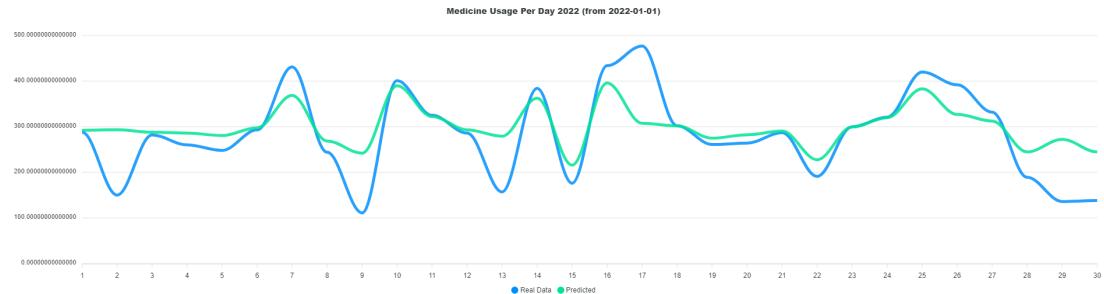
**Gambar 2.65** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 66. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.01



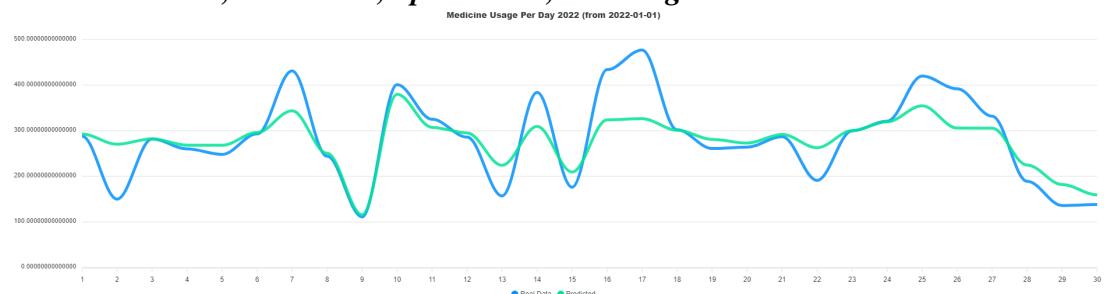
**Gambar 2.66** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 67. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.01



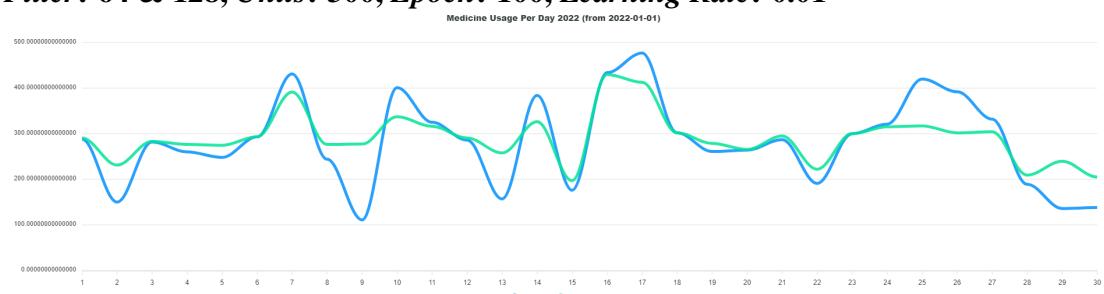
**Gambar 2.67** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 68. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.01



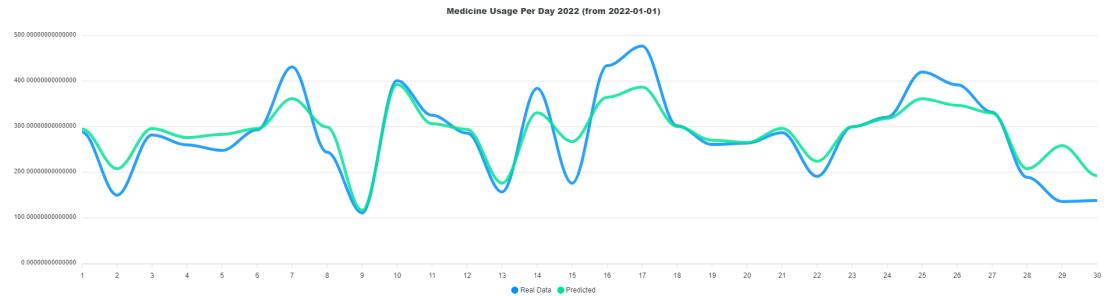
**Gambar 2.68** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 69. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.01



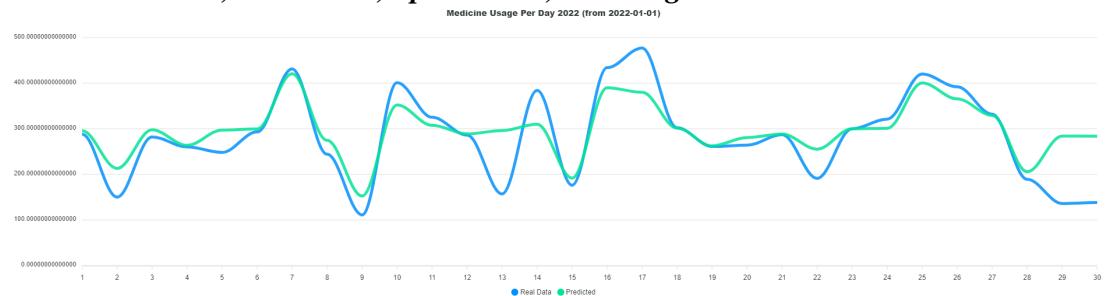
**Gambar 2.69** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 70. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.01



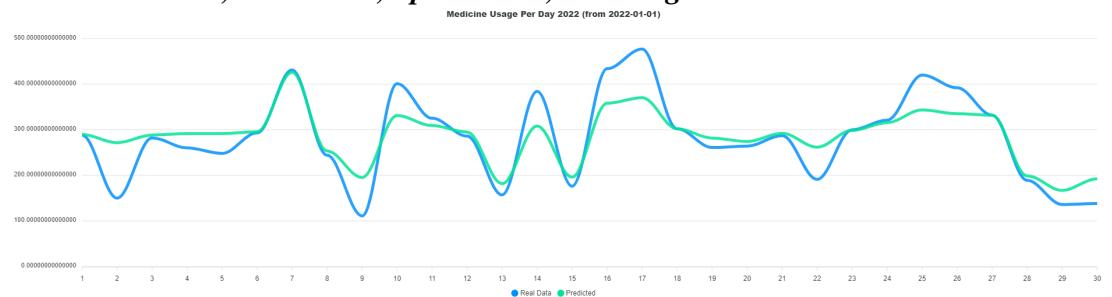
**Gambar 2.70** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 71. *Filter: 64 & 128, Units: 300, Epoch: 200, Learning Rate: 0.01*



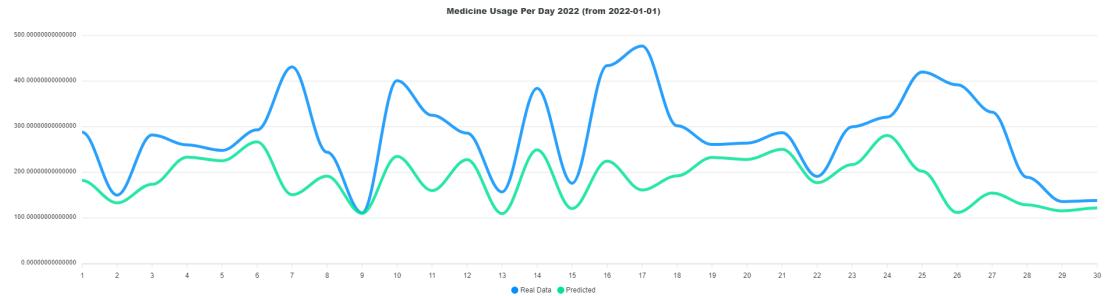
**Gambar 2.71** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 72. *Filter: 64 & 128, Units: 300, Epoch: 250, Learning Rate: 0.01*



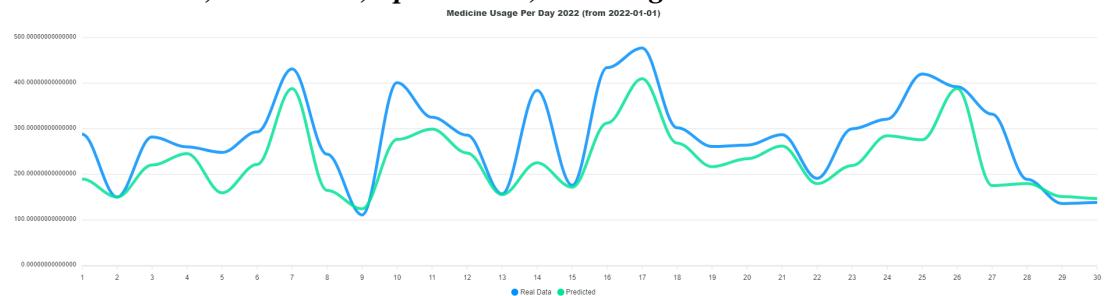
**Gambar 2.72** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 73. *Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.001*



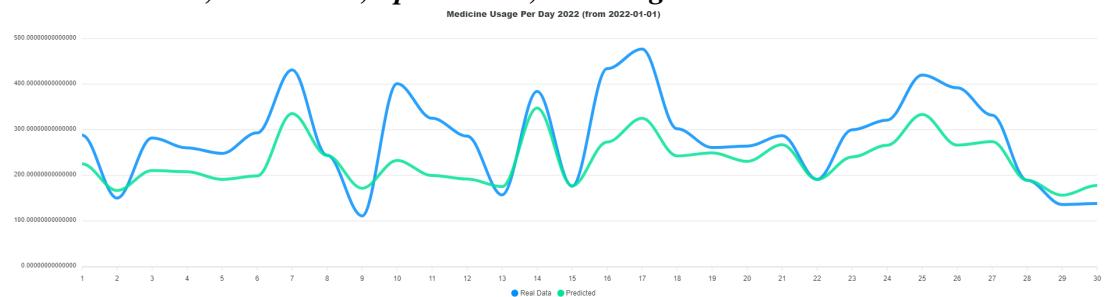
**Gambar 2.73** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 74. *Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.001*



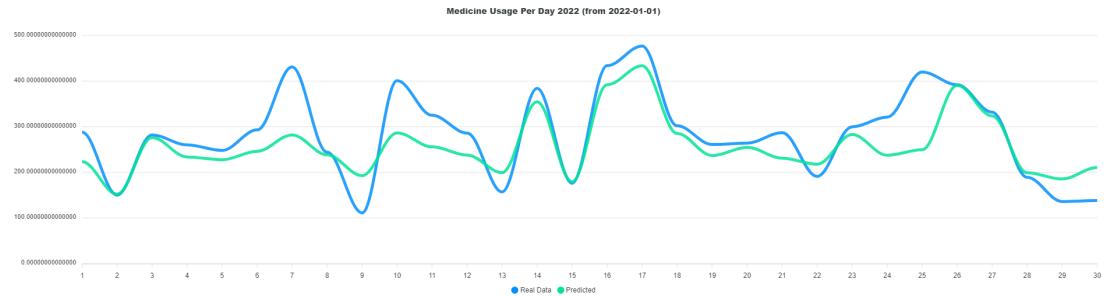
**Gambar 2.74** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 75. *Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.001*



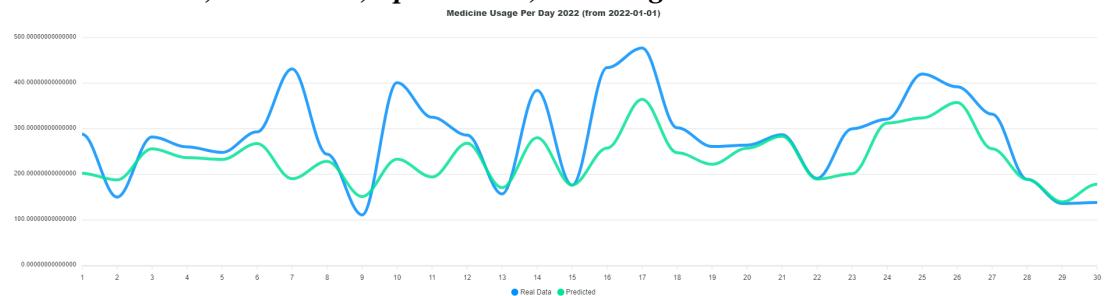
**Gambar 2.75** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 76. *Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.001*



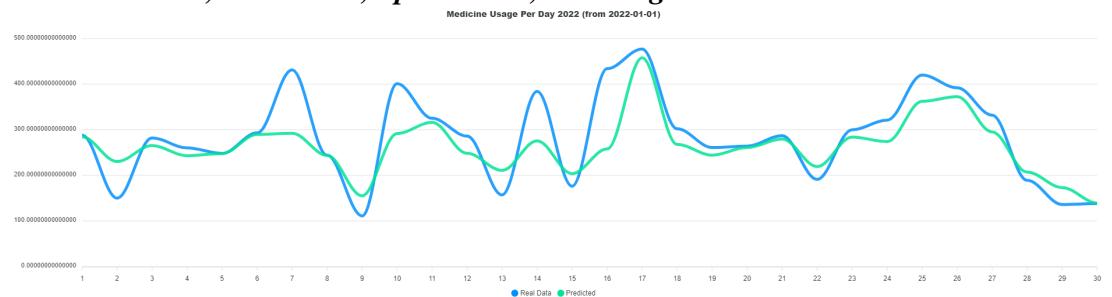
**Gambar 2.76** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 77. *Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.001*



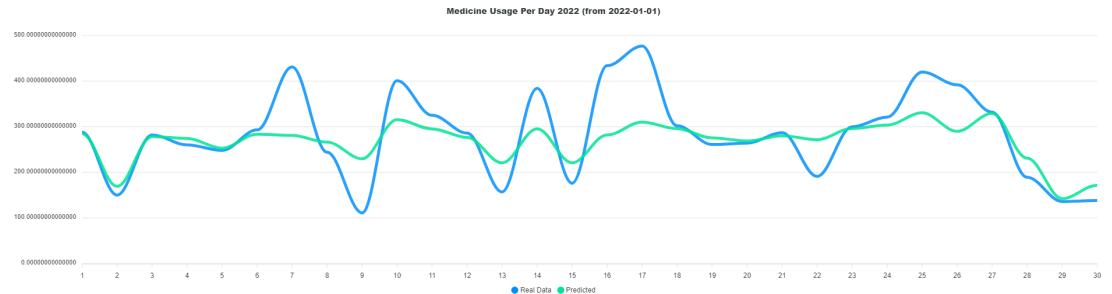
**Gambar 2.77** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 78. *Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.001*



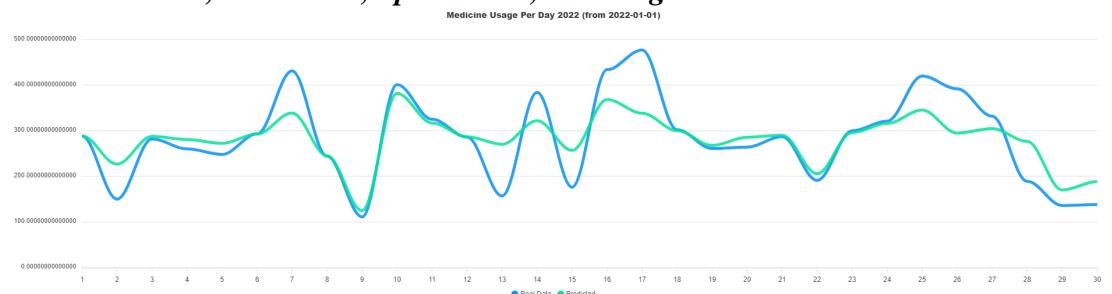
**Gambar 2.78** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 79. *Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.001*



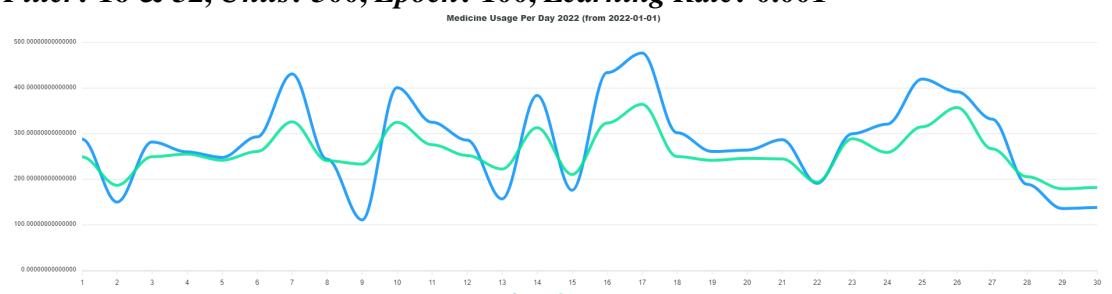
**Gambar 2.79** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 80. *Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.001*



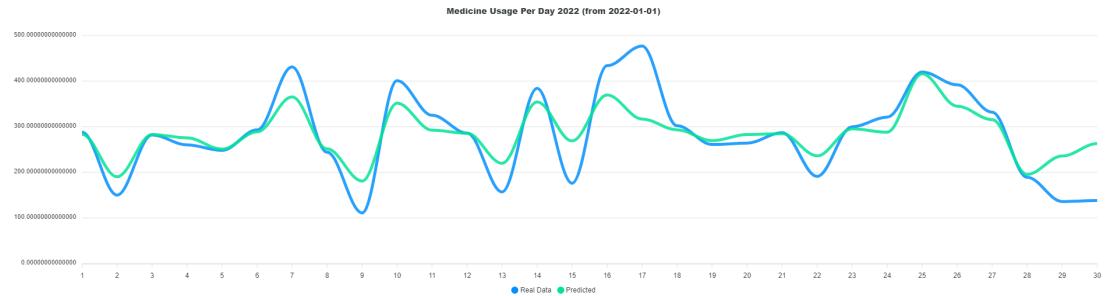
**Gambar 2.80** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 81. *Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.001*



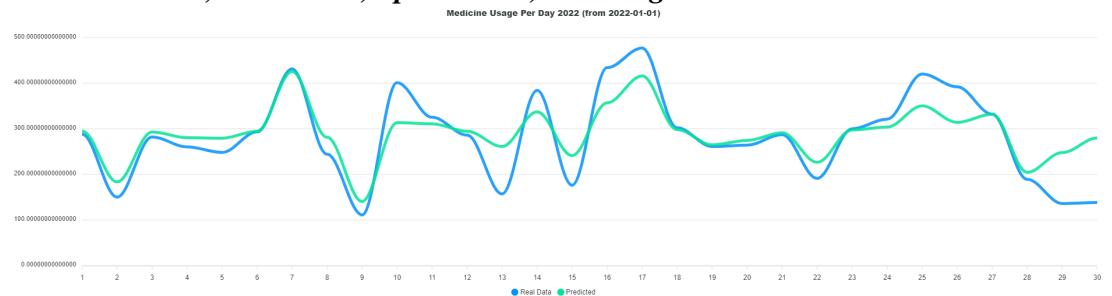
**Gambar 2.81** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 82. *Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.001*



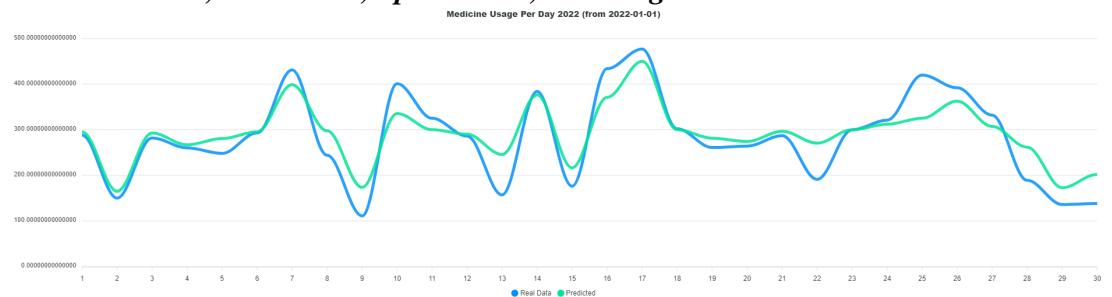
**Gambar 2.82** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 83. *Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.001*



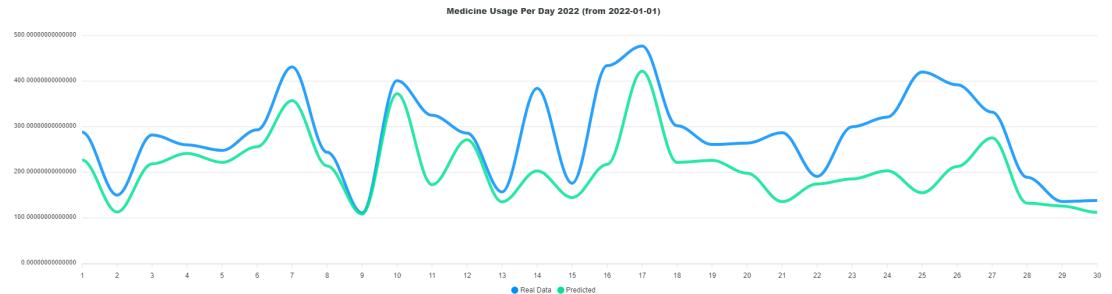
**Gambar 2.83** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 84. *Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.001*



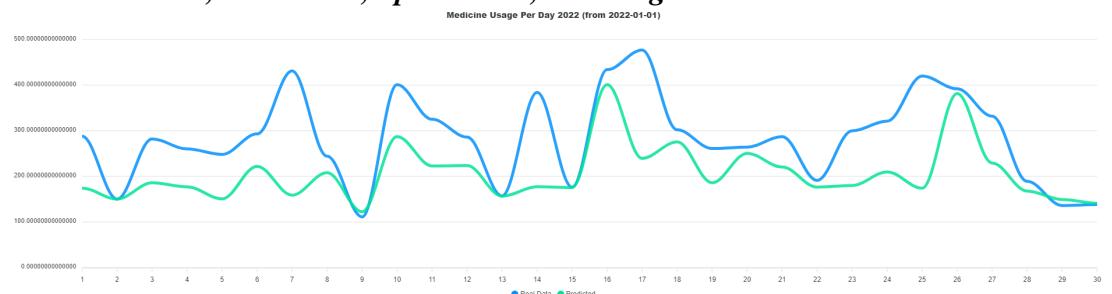
**Gambar 2.84** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 85. *Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.001*



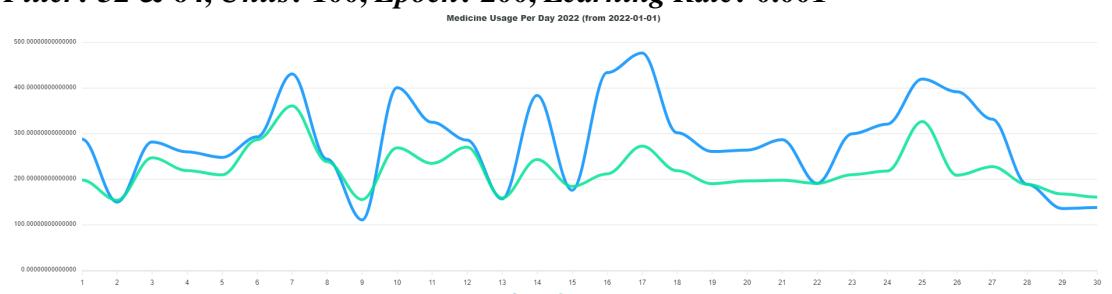
**Gambar 2.85** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 86. *Filter: 32 & 64, Units: 100, Epoch: 150, Learning Rate: 0.001*



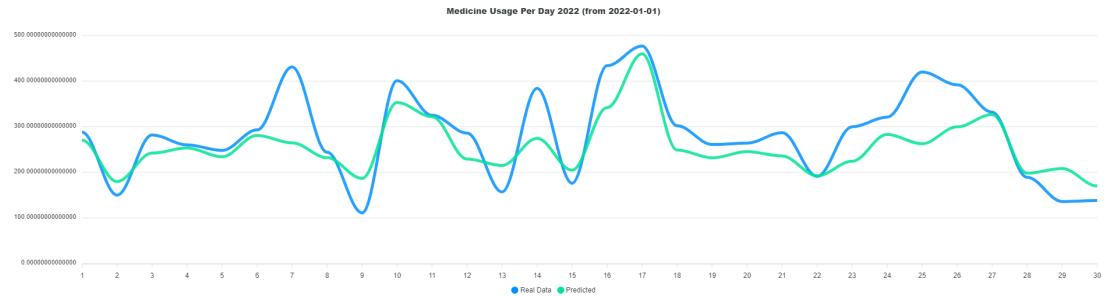
**Gambar 2.86** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 87. *Filter: 32 & 64, Units: 100, Epoch: 200, Learning Rate: 0.001*



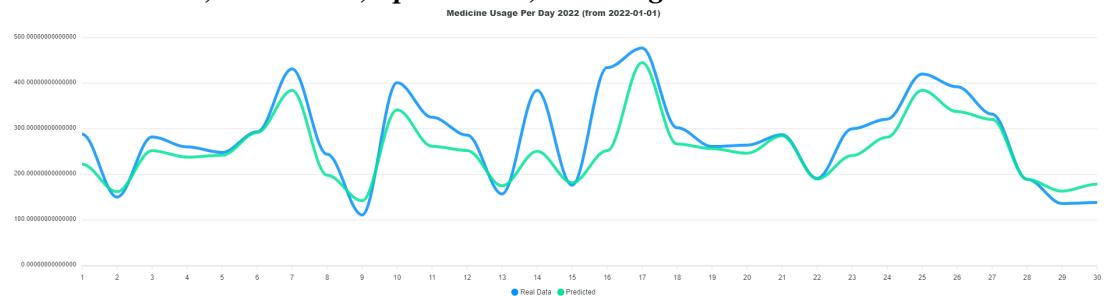
**Gambar 2.87** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 88. *Filter: 32 & 64, Units: 100, Epoch: 250, Learning Rate: 0.001*



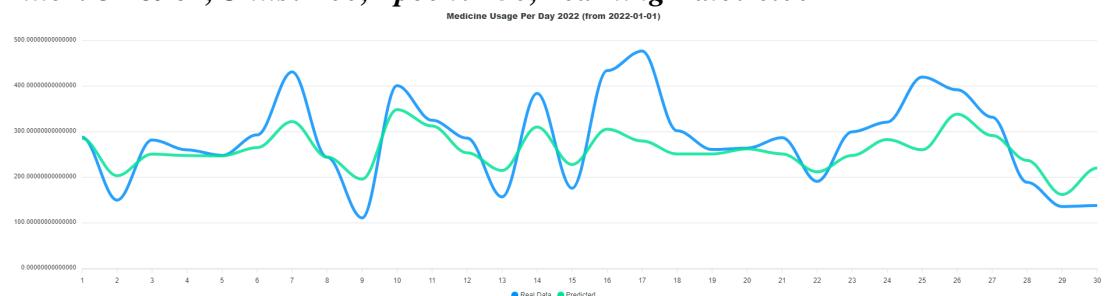
**Gambar 2.88** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

**89. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001**



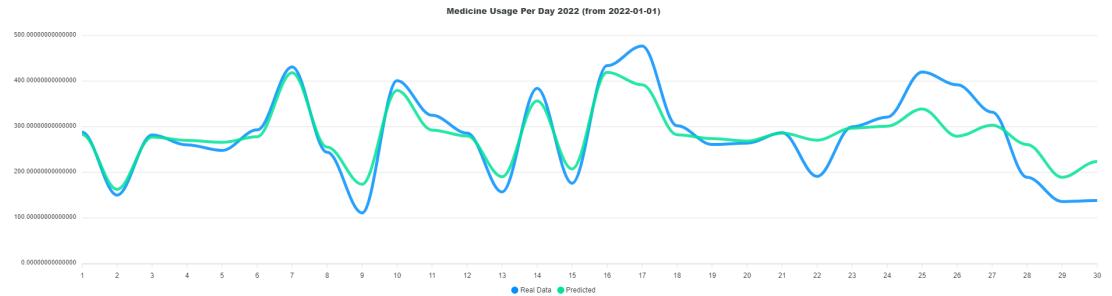
**Gambar 2.89** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

**90. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001**



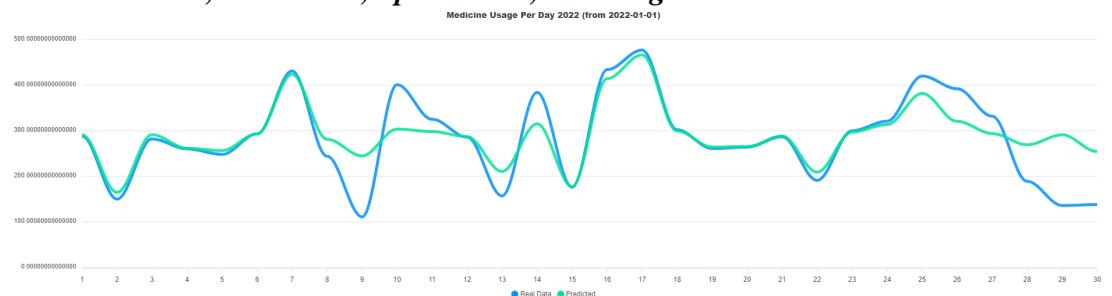
**Gambar 2.90** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

**91. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001**



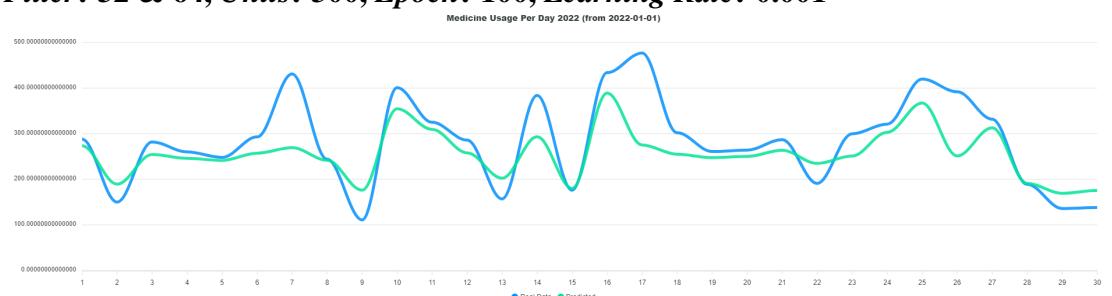
**Gambar 2.91** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 92. *Filter: 32 & 64, Units: 200, Epoch: 250, Learning Rate: 0.001*



**Gambar 2.92** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 93. *Filter: 32 & 64, Units: 300, Epoch: 100, Learning Rate: 0.001*

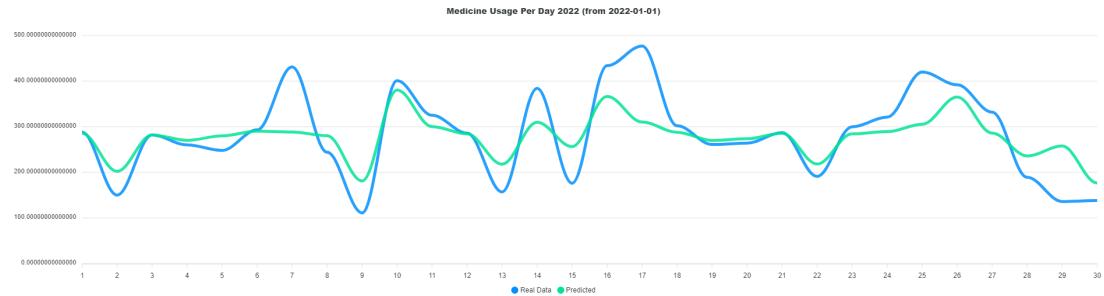


**Gambar 2.93** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 94. *Filter: 32 & 64, Units: 300, Epoch: 150, Learning Rate: 0.001*

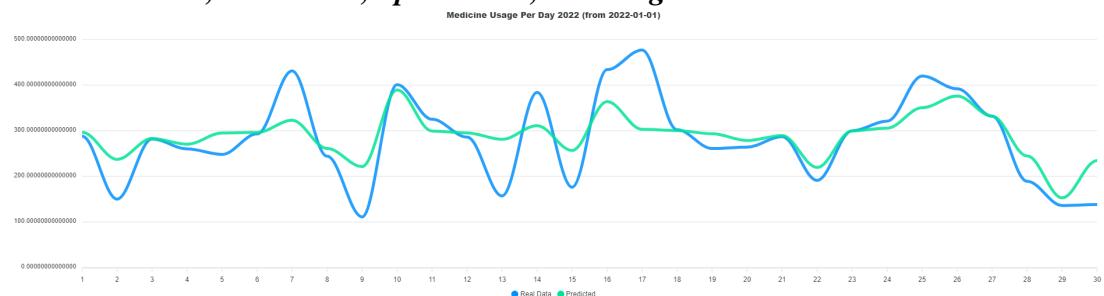
## BAB B Hasil Pengujian Arsitektur 2

---



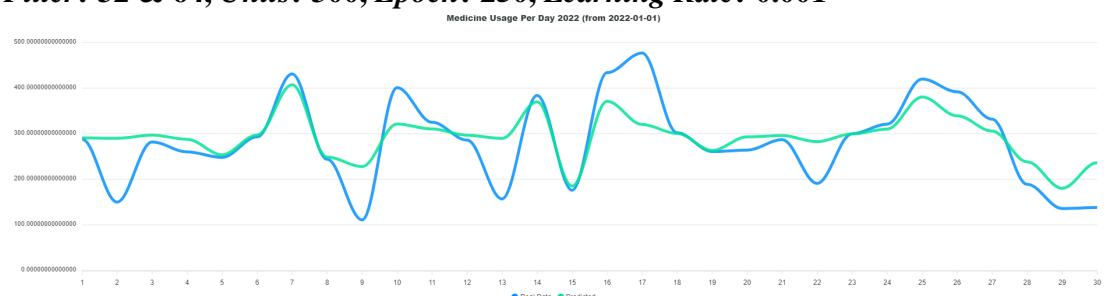
**Gambar 2.94** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 95. *Filter: 32 & 64, Units: 300, Epoch: 200, Learning Rate: 0.001*



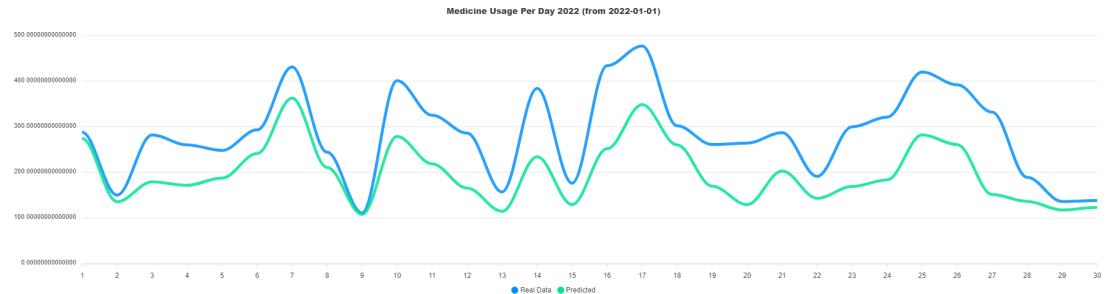
**Gambar 2.95** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 96. *Filter: 32 & 64, Units: 300, Epoch: 250, Learning Rate: 0.001*



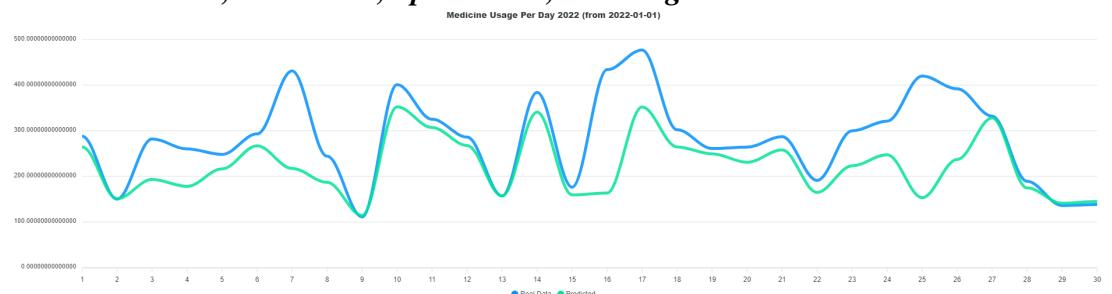
**Gambar 2.96** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 97. *Filter: 64 & 128, Units: 100, Epoch: 100, Learning Rate: 0.001*



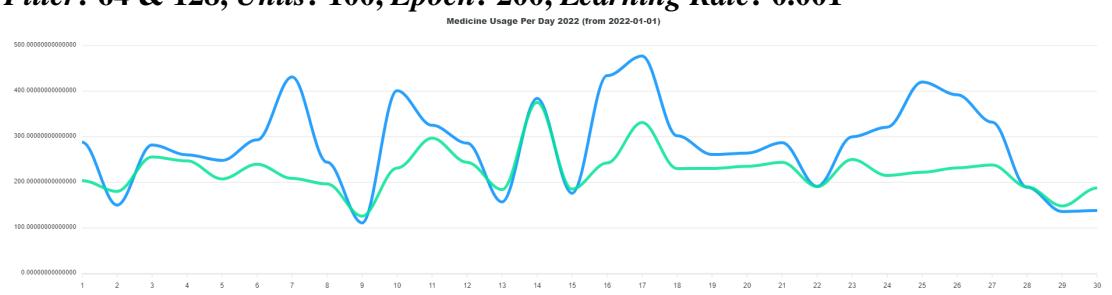
**Gambar 2.97** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 98. *Filter: 64 & 128, Units: 100, Epoch: 150, Learning Rate: 0.001*



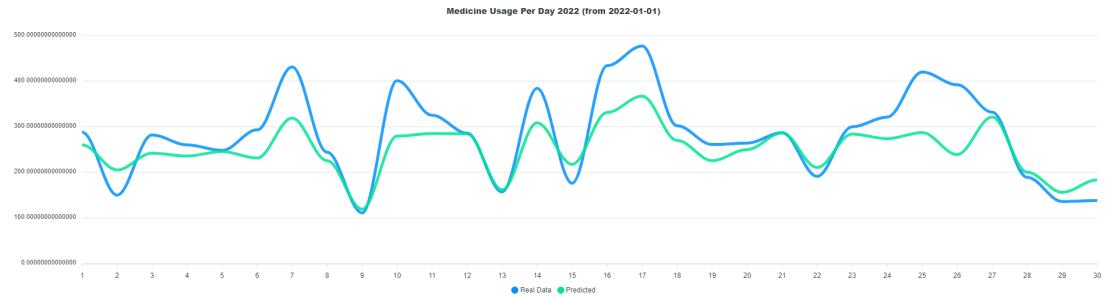
**Gambar 2.98** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 99. *Filter: 64 & 128, Units: 100, Epoch: 200, Learning Rate: 0.001*



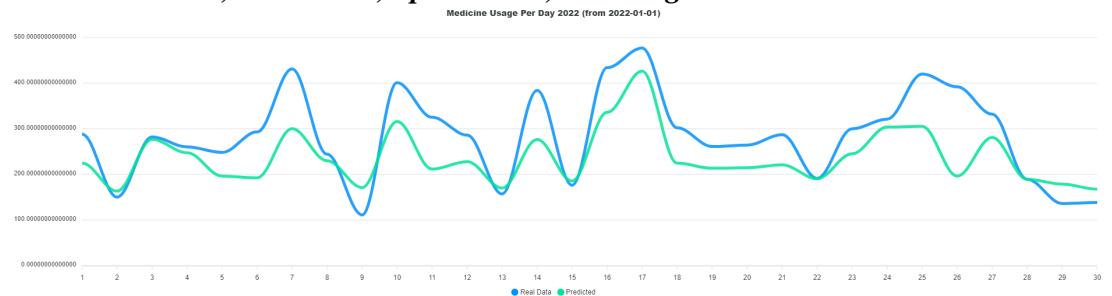
**Gambar 2.99** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 100. *Filter: 64 & 128, Units: 100, Epoch: 250, Learning Rate: 0.001*



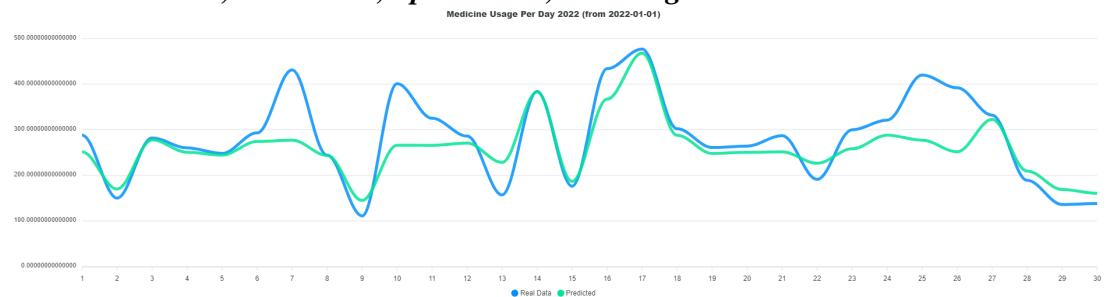
**Gambar 2.100** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 101. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001



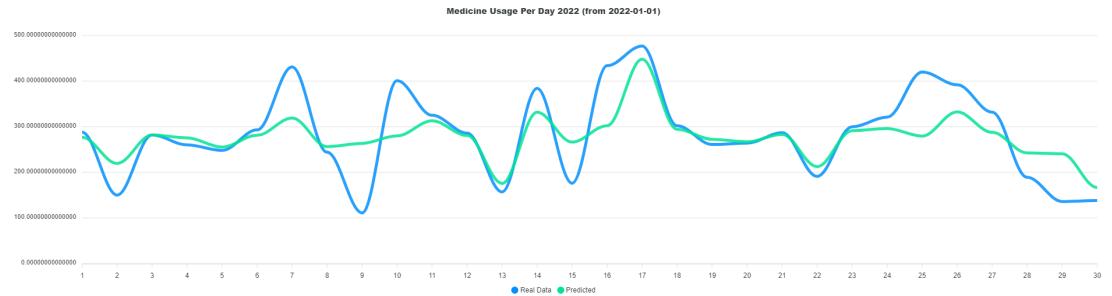
**Gambar 2.101** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 102. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001



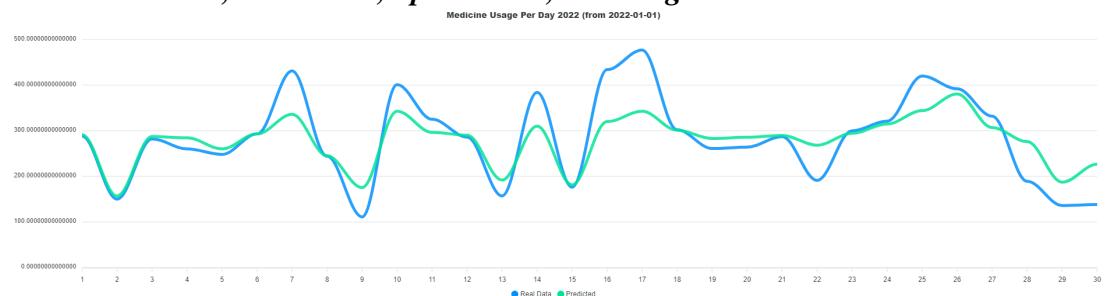
**Gambar 2.102** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 103. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001



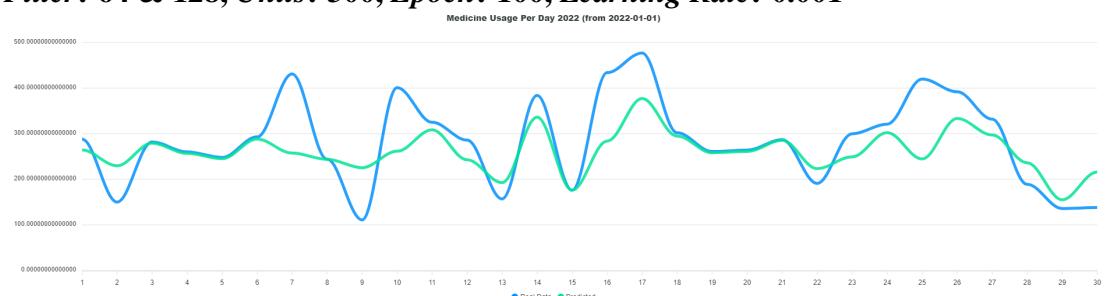
**Gambar 2.103** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 104. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.001



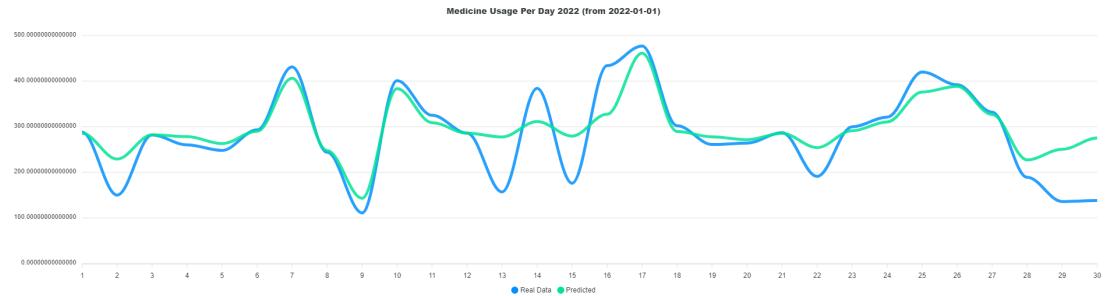
**Gambar 2.104** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 105. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.001



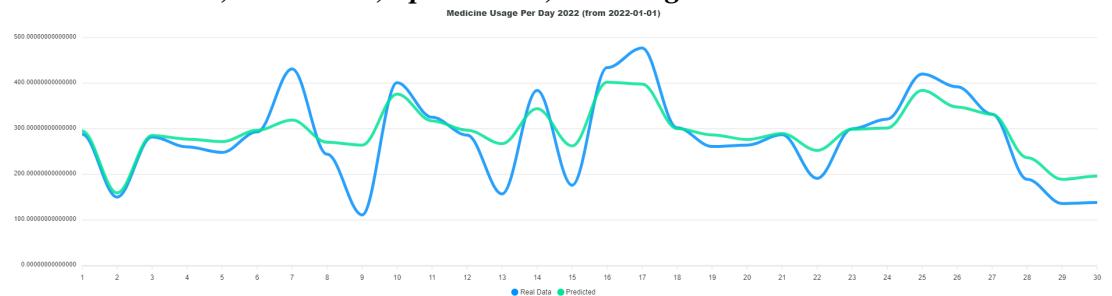
**Gambar 2.105** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 106. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.001



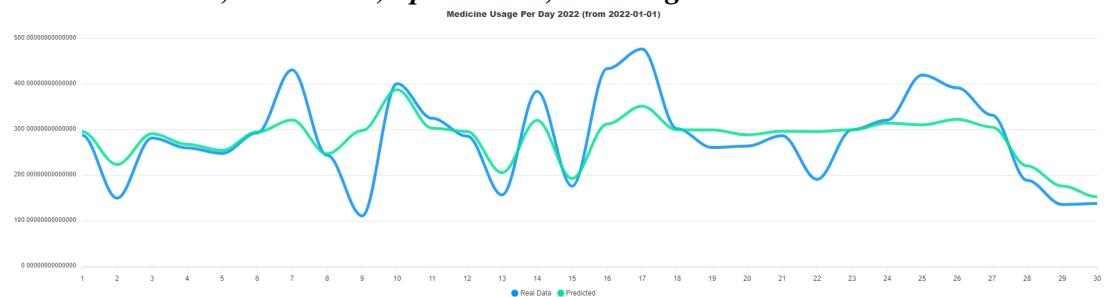
**Gambar 2.106** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 107. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.001



**Gambar 2.107** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

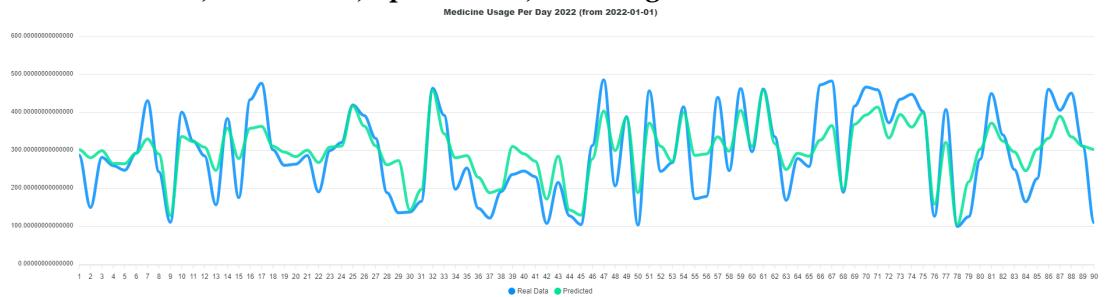
### 108. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.001



**Gambar 2.108** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 30 hari

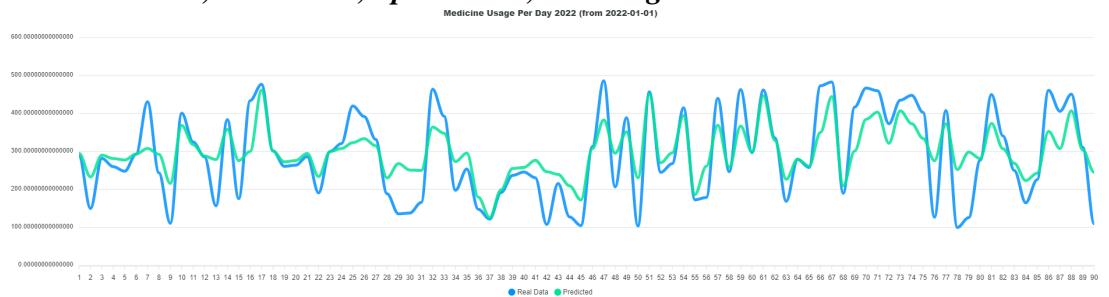
## 2.2 Forecasting Horizon 90 hari

### 1. Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.1



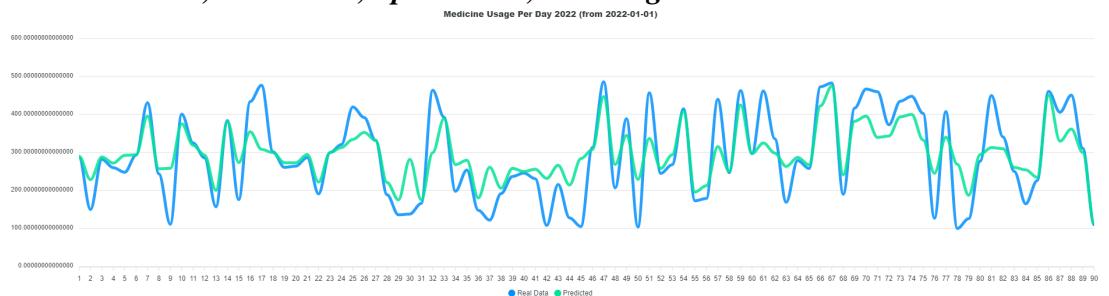
**Gambar 2.109** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 2. Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.1



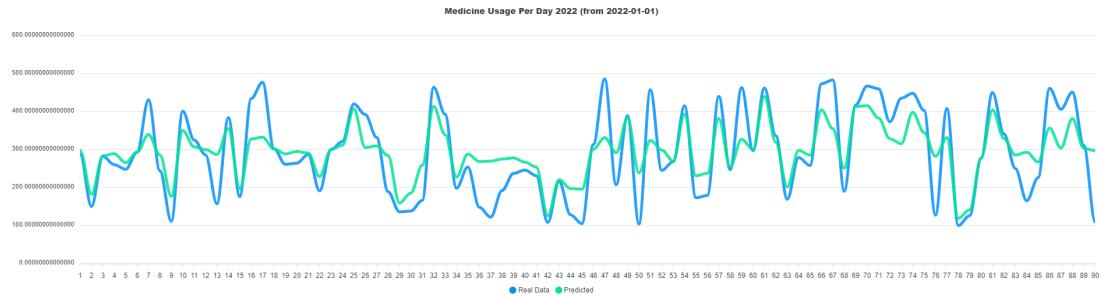
**Gambar 2.110** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 3. Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.1



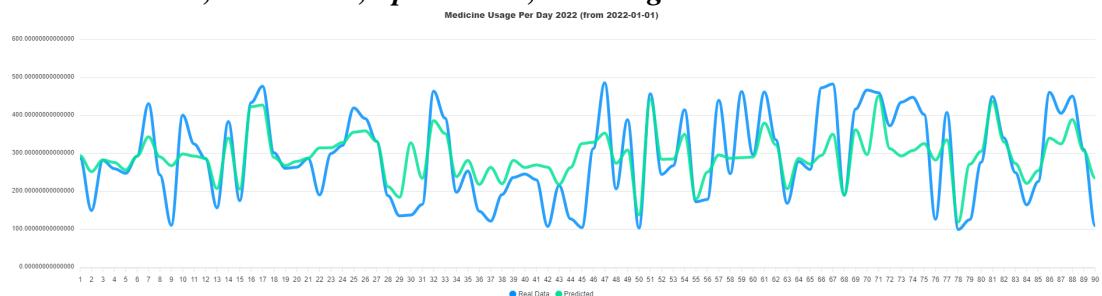
**Gambar 2.111** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 4. Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.1



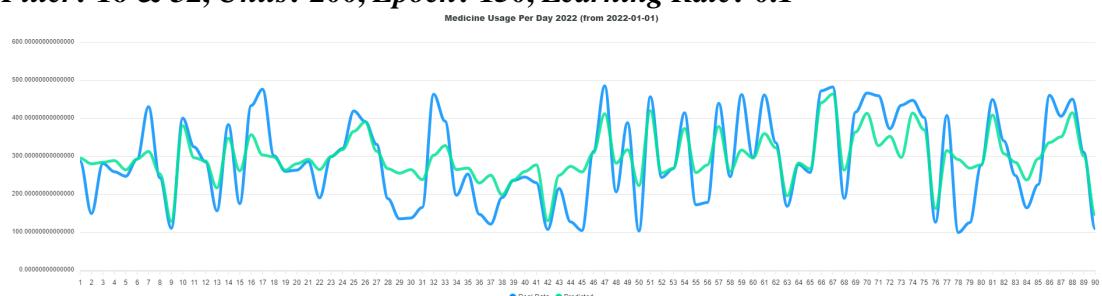
**Gambar 2.112** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 5. *Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.1*



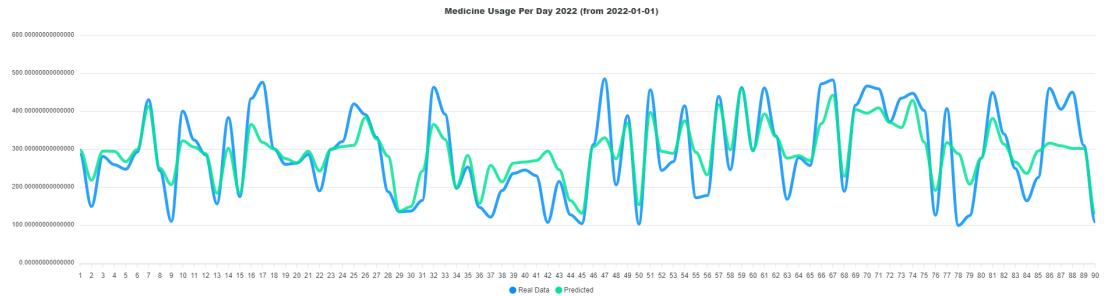
**Gambar 2.113** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 6. *Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.1*



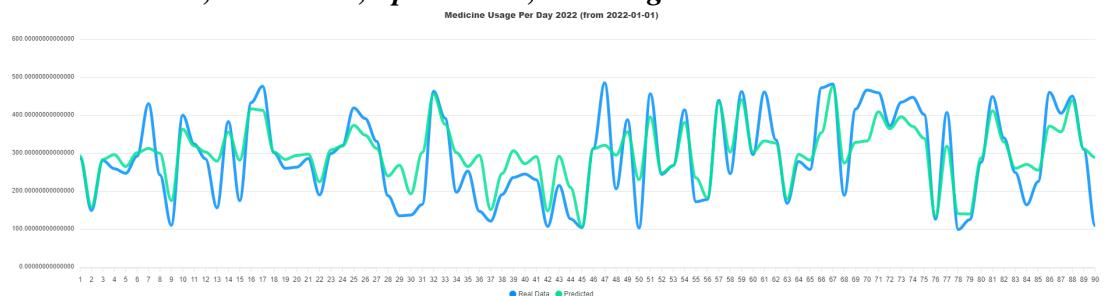
**Gambar 2.114** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 7. *Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.1*



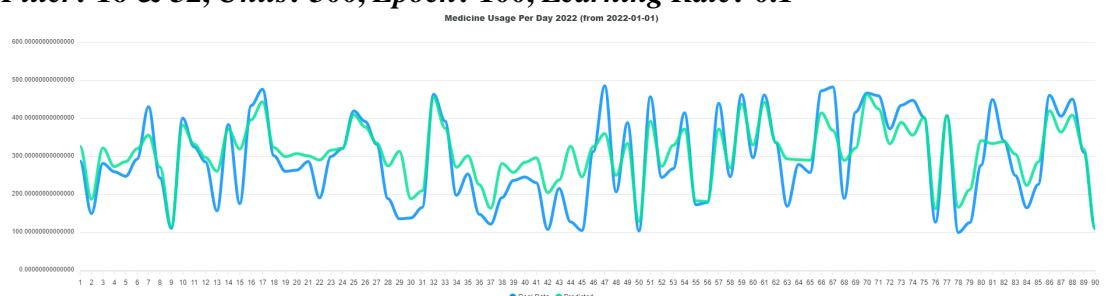
**Gambar 2.115** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 8. *Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.1*



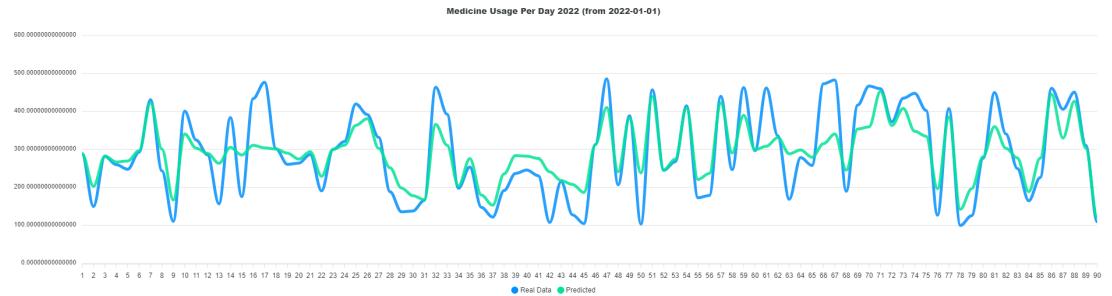
**Gambar 2.116** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 9. *Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.1*



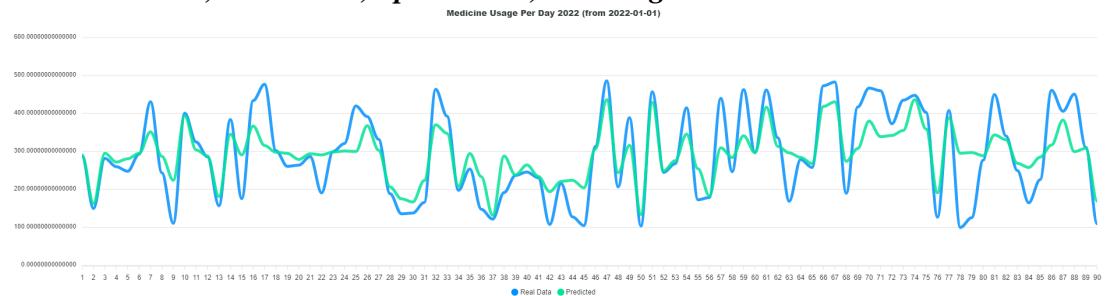
**Gambar 2.117** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 10. *Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.1*



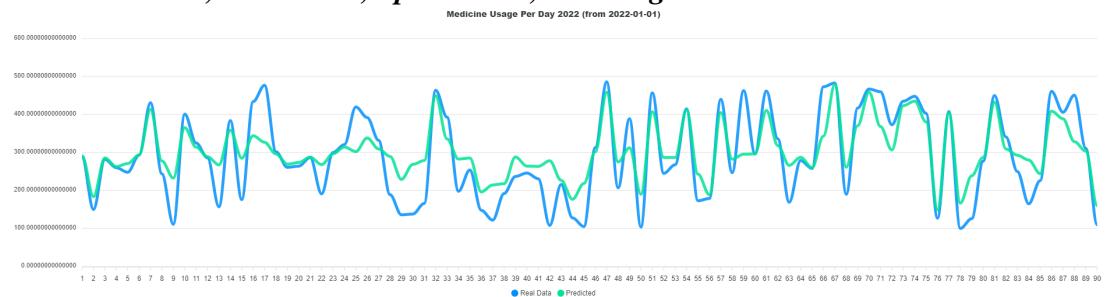
**Gambar 2.118** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 11. *Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.1*



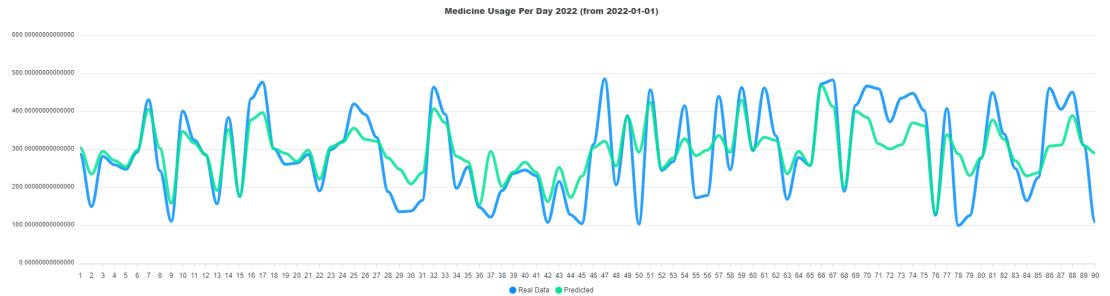
**Gambar 2.119** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 12. *Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.1*



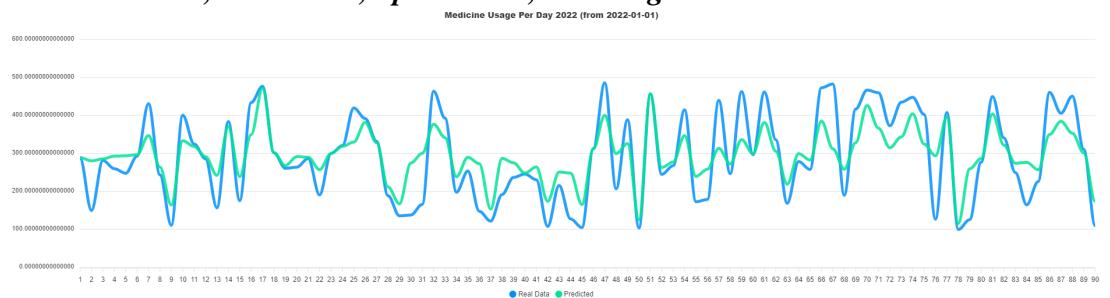
**Gambar 2.120** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 13. *Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.1*



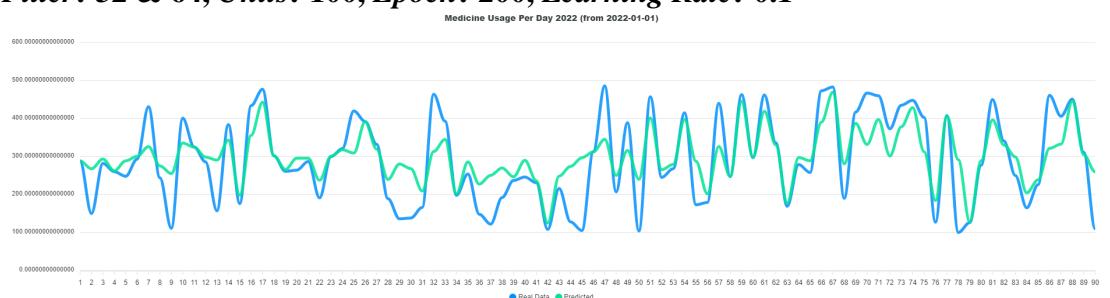
**Gambar 2.121** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 14. *Filter: 32 & 64, Units: 100, Epoch: 150, Learning Rate: 0.1*



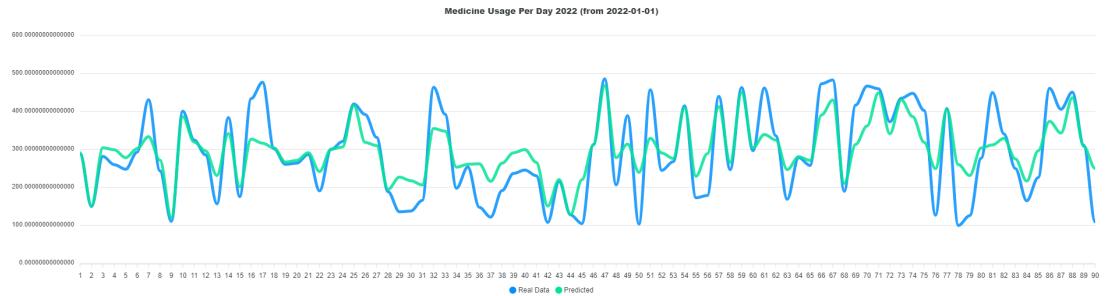
**Gambar 2.122** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 15. *Filter: 32 & 64, Units: 100, Epoch: 200, Learning Rate: 0.1*



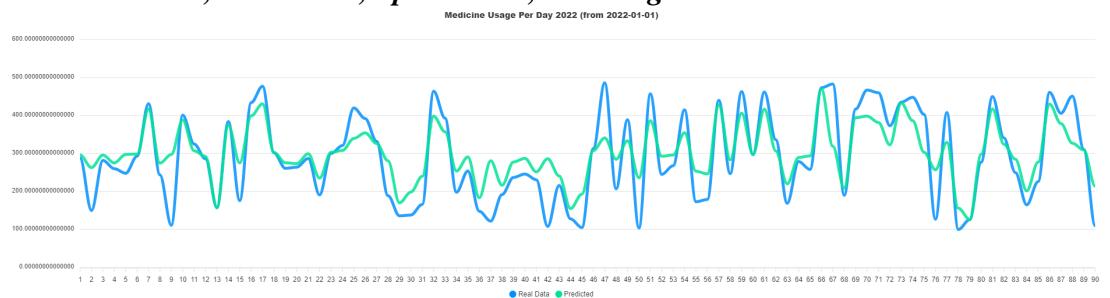
**Gambar 2.123** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 16. *Filter: 32 & 64, Units: 100, Epoch: 250, Learning Rate: 0.1*



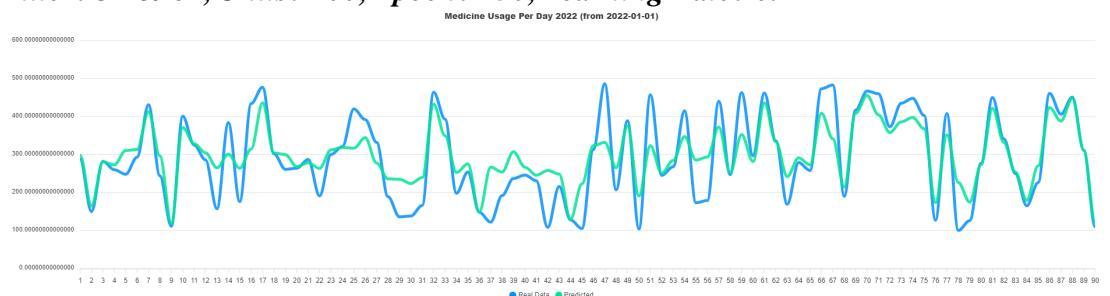
**Gambar 2.124** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 17. *Filter: 32 & 64, Units: 200, Epoch: 100, Learning Rate: 0.1*



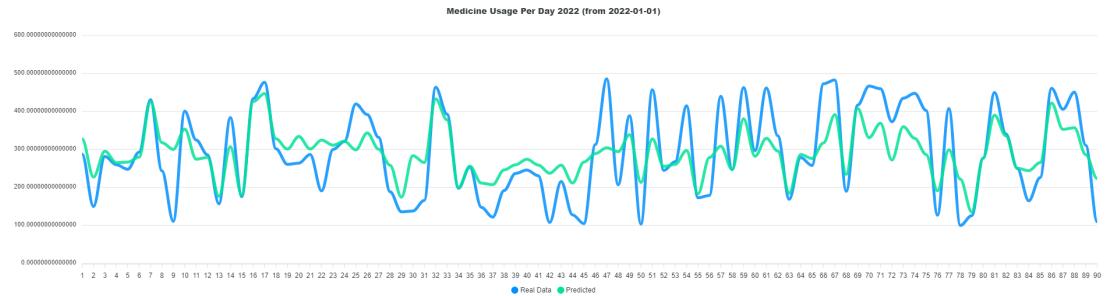
**Gambar 2.125** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 18. *Filter: 32 & 64, Units: 200, Epoch: 150, Learning Rate: 0.1*



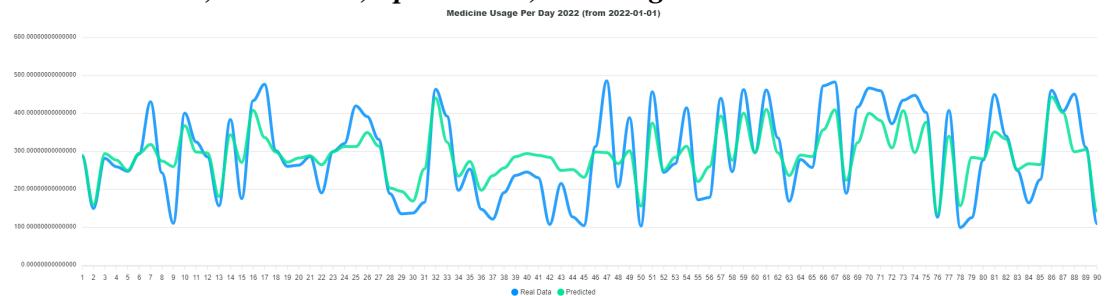
**Gambar 2.126** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 19. *Filter: 32 & 64, Units: 200, Epoch: 200, Learning Rate: 0.1*



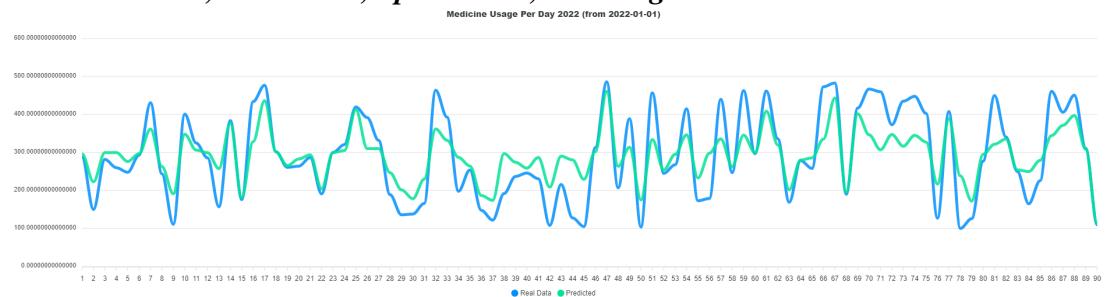
**Gambar 2.127** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 20. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1



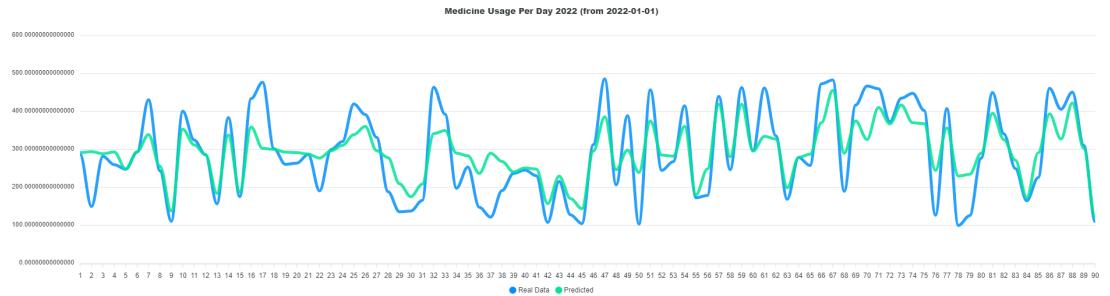
**Gambar 2.128** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 21. *Filter*: 32 & 64, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1



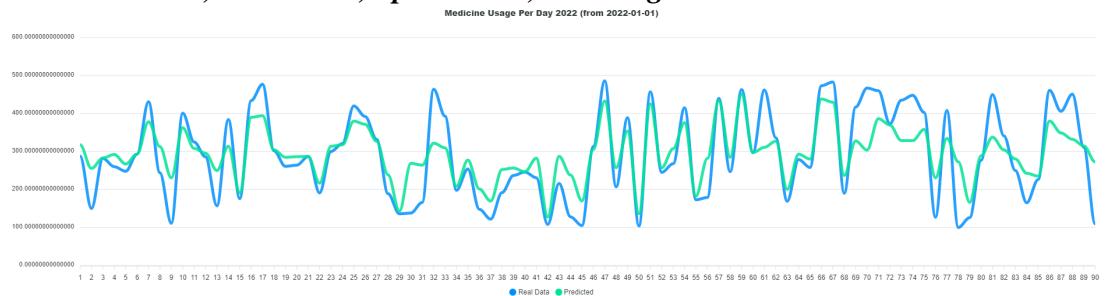
**Gambar 2.129** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 22. *Filter*: 32 & 64, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1



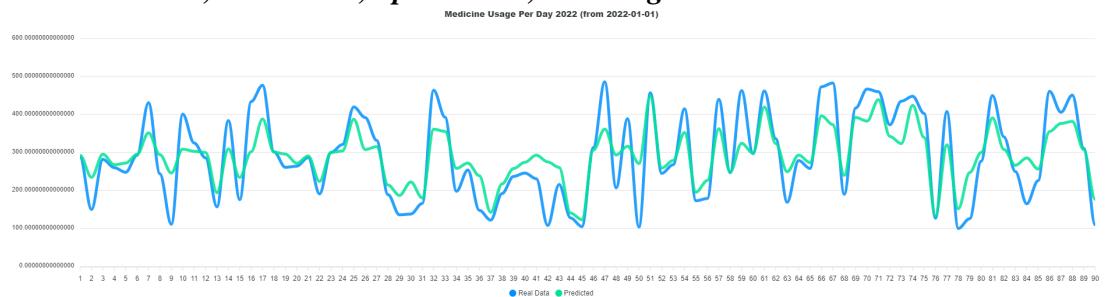
**Gambar 2.130** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 23. *Filter*: 32 & 64, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.1



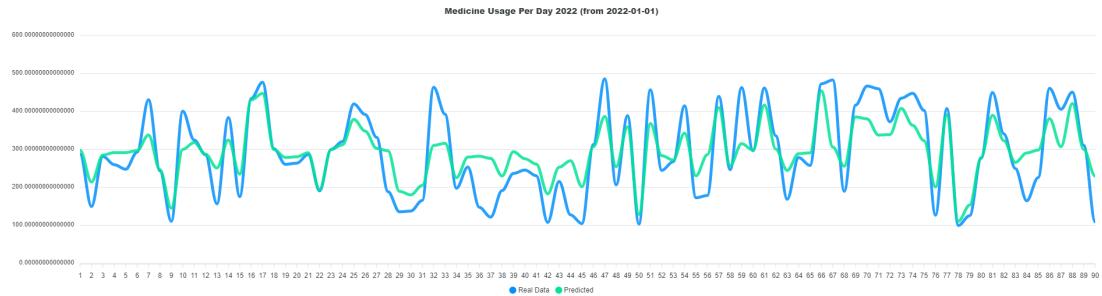
**Gambar 2.131** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 24. *Filter*: 32 & 64, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.1



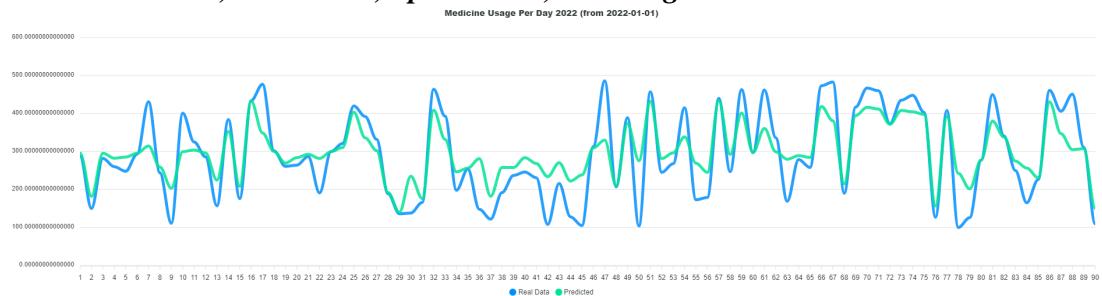
**Gambar 2.132** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 25. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.1



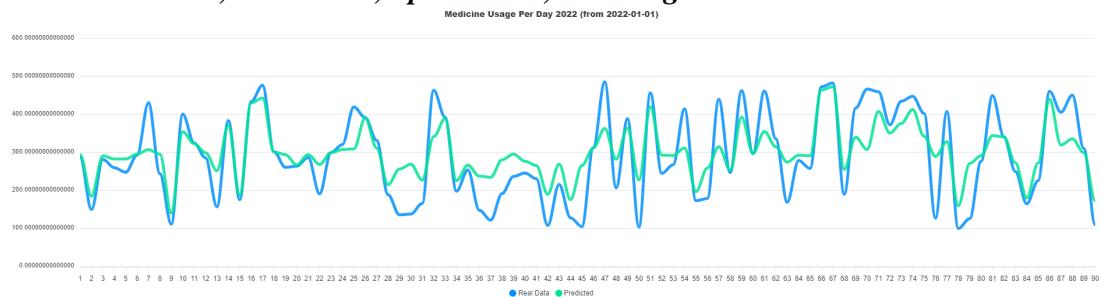
**Gambar 2.133** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 26. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.1



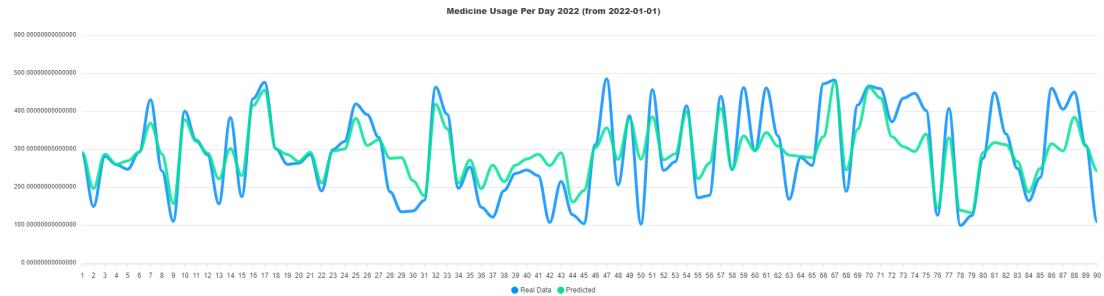
**Gambar 2.134** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 27. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.1



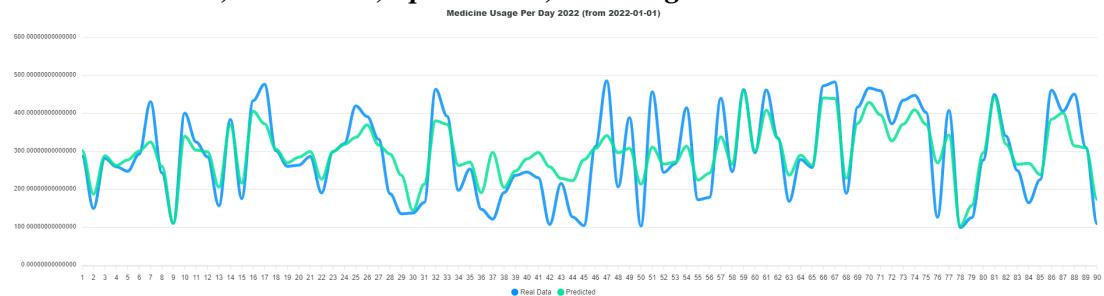
**Gambar 2.135** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 28. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.1



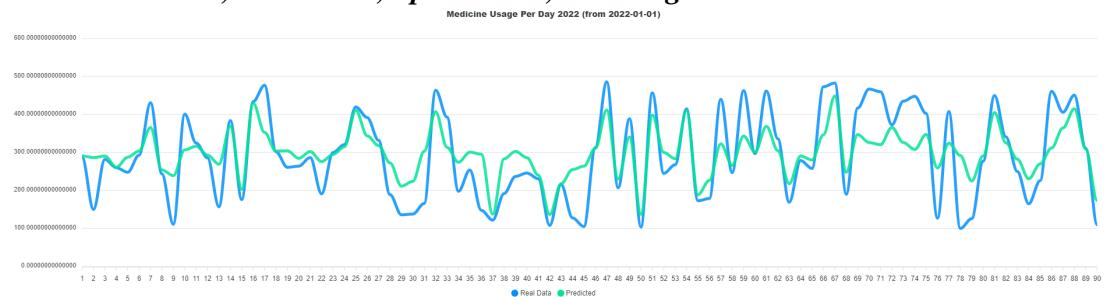
**Gambar 2.136** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 29. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.1



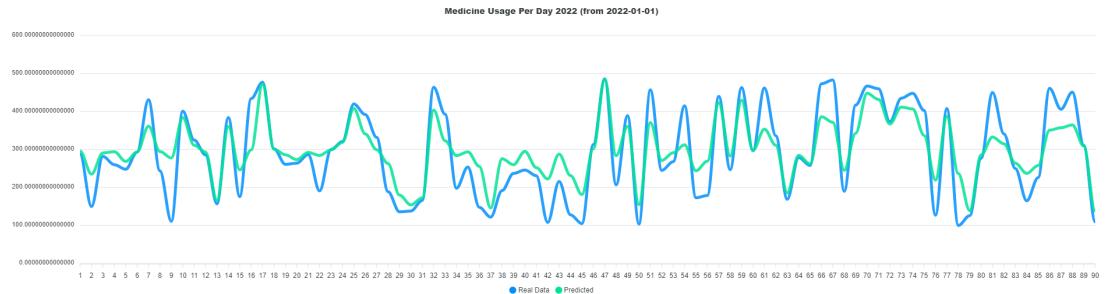
**Gambar 2.137** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 30. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.1



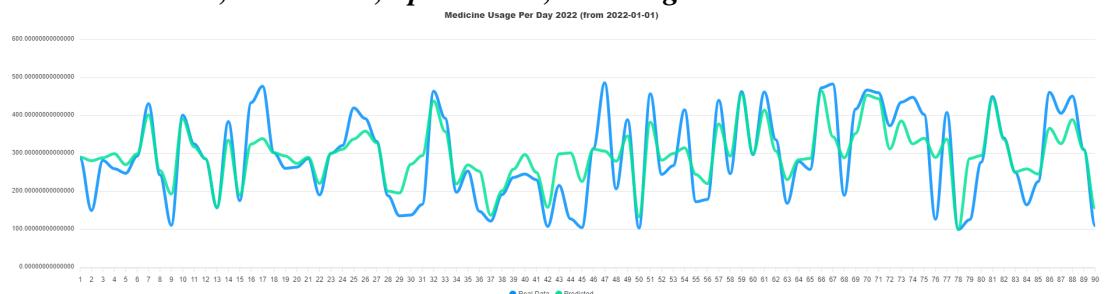
**Gambar 2.138** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 31. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.1



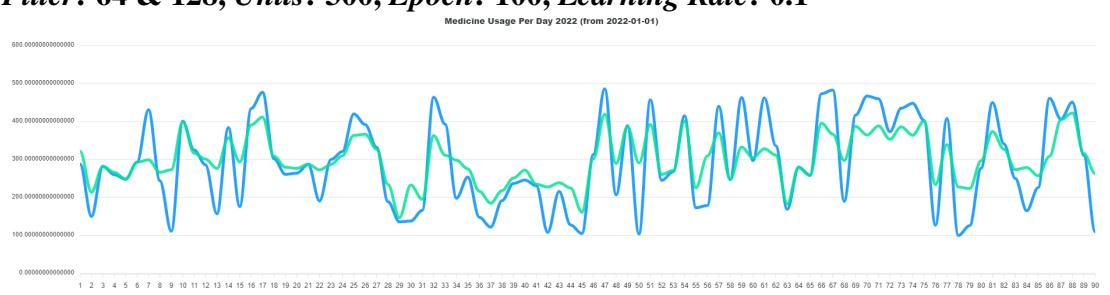
**Gambar 2.139** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 32. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1



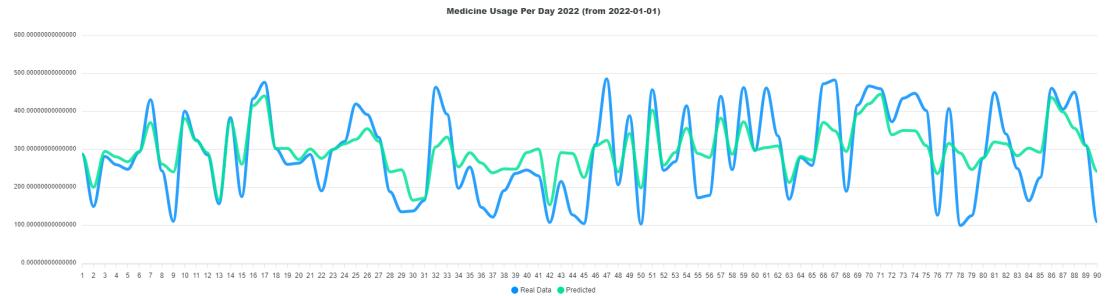
**Gambar 2.140** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 33. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1



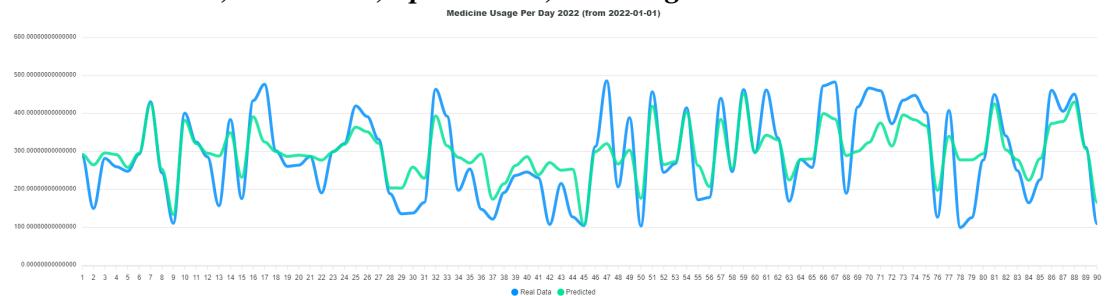
**Gambar 2.141** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 34. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1



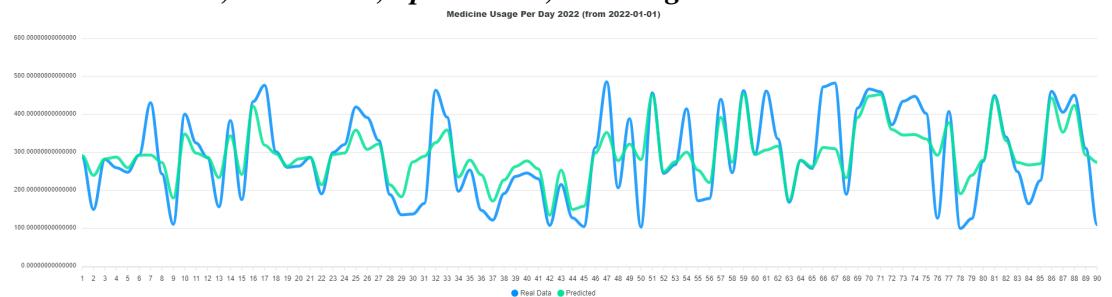
**Gambar 2.142** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 35. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.1



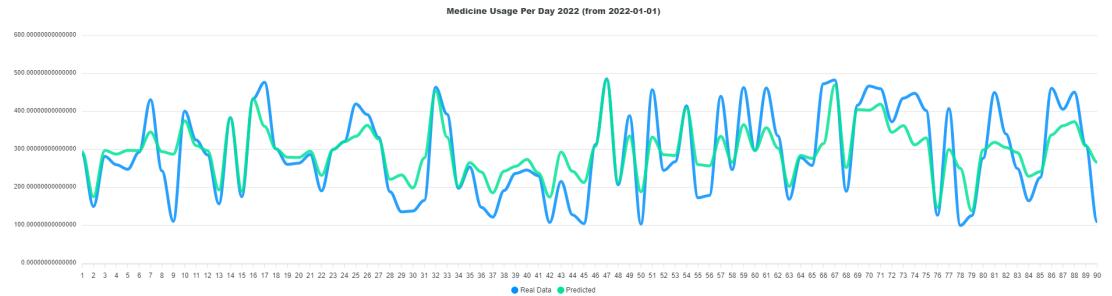
**Gambar 2.143** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 36. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.1



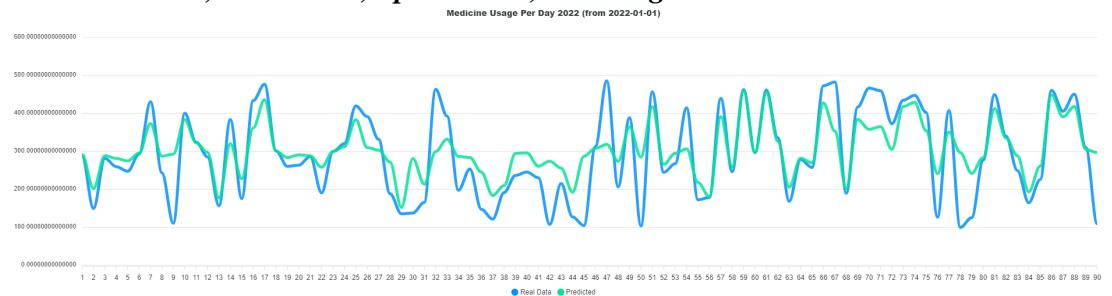
**Gambar 2.144** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.1 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 37. *Filter*: 16 & 32, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.01



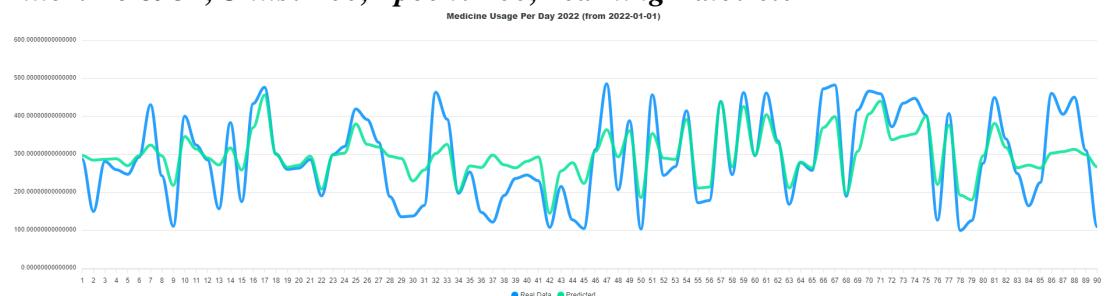
**Gambar 2.145** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 38. *Filter*: 16 & 32, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01



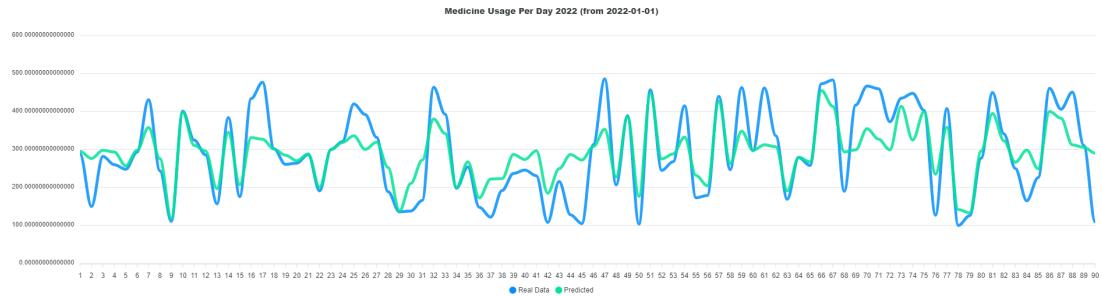
**Gambar 2.146** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 39. *Filter*: 16 & 32, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01



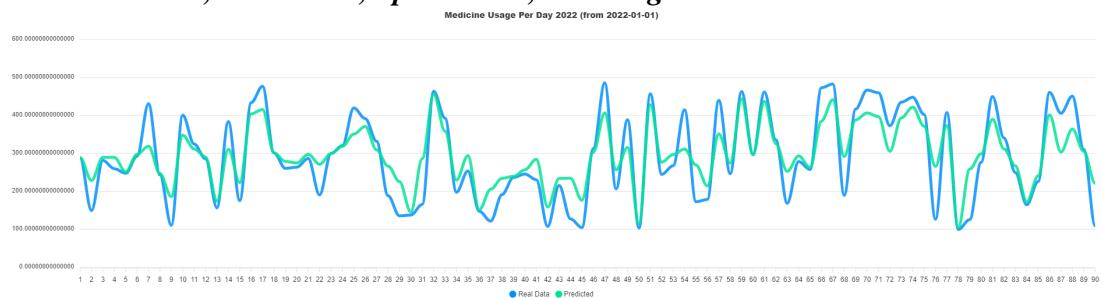
**Gambar 2.147** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 40. *Filter*: 16 & 32, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01



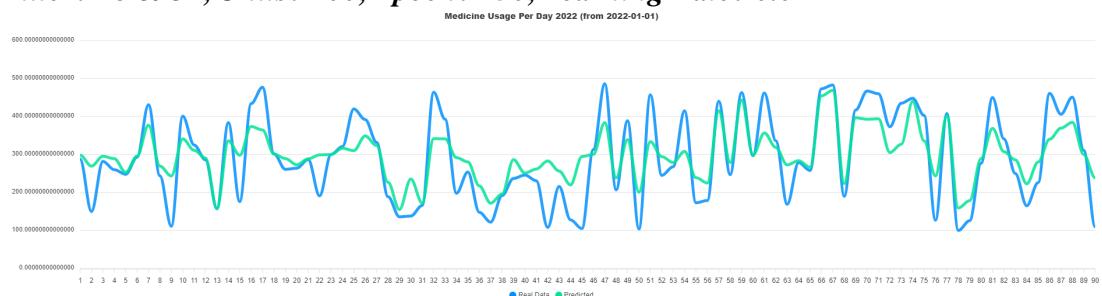
**Gambar 2.148** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 41. *Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.01*



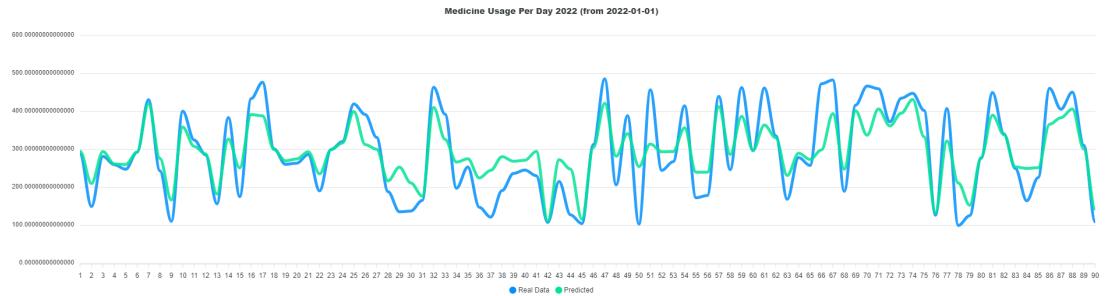
**Gambar 2.149** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 42. *Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.01*



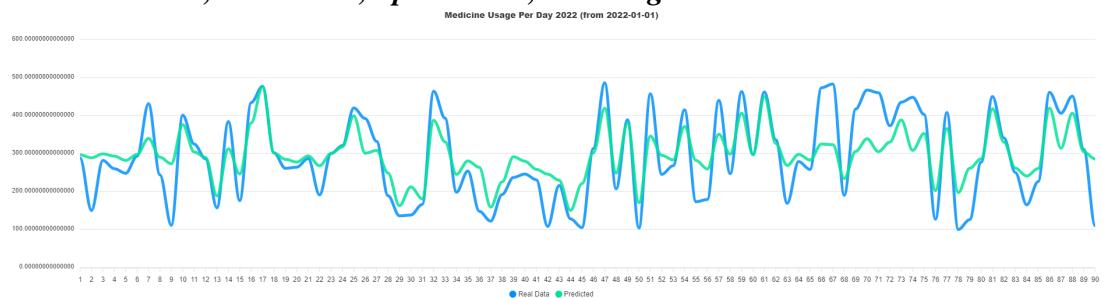
**Gambar 2.150** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 43. *Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.01*



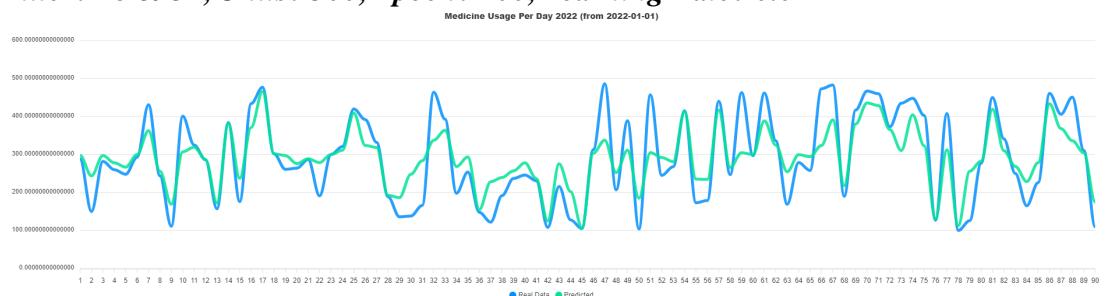
**Gambar 2.151** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 44. *Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.01*



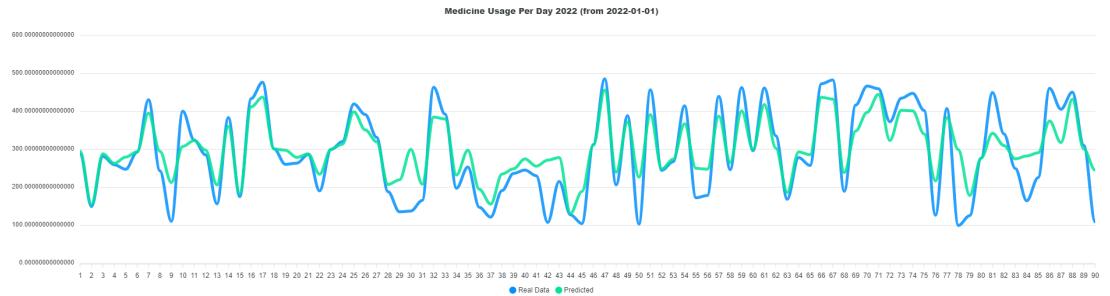
**Gambar 2.152** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 45. *Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.01*



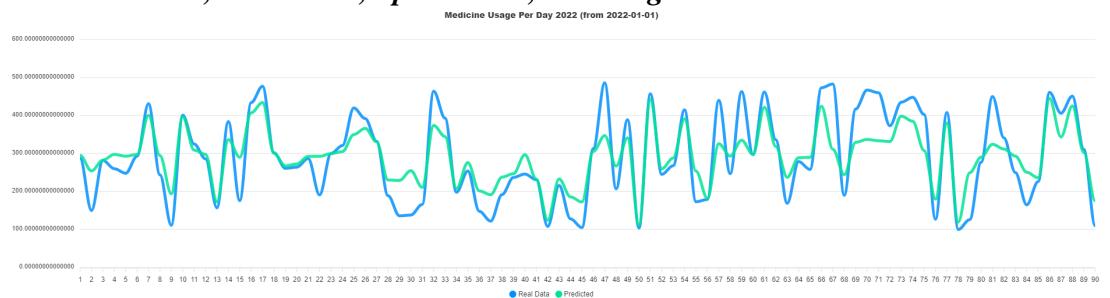
**Gambar 2.153** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 46. *Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.01*



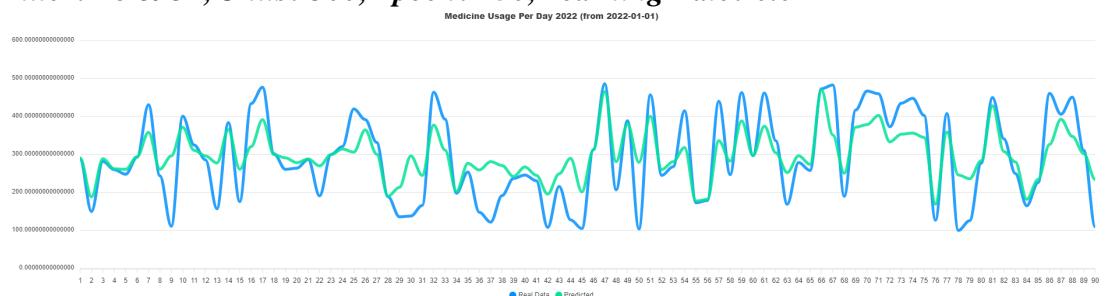
**Gambar 2.154** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 47. *Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.01*



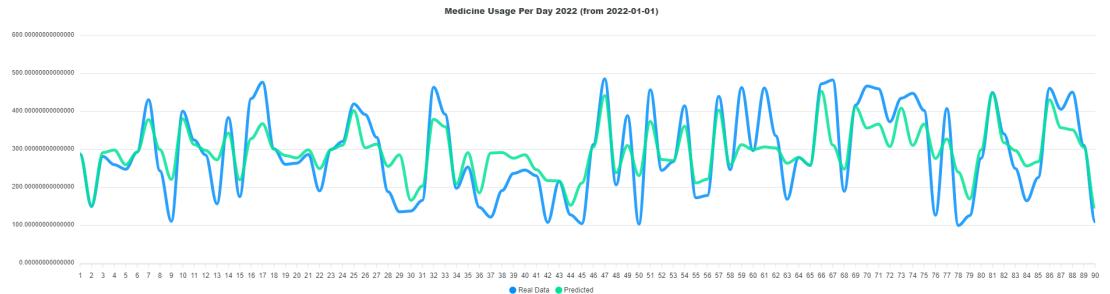
**Gambar 2.155** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 48. *Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.01*



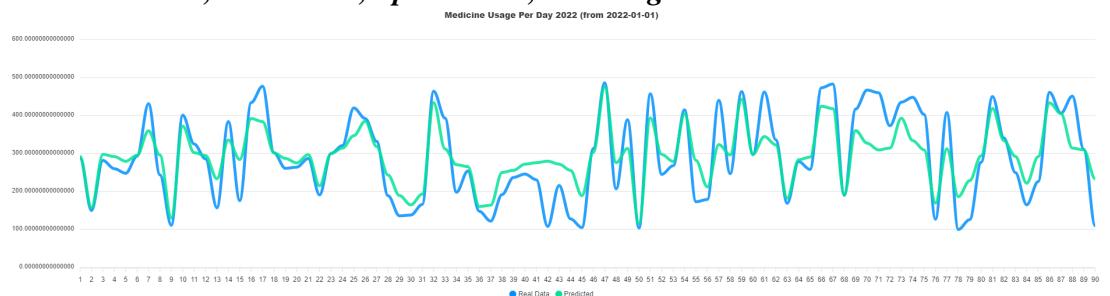
**Gambar 2.156** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 49. *Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.01*



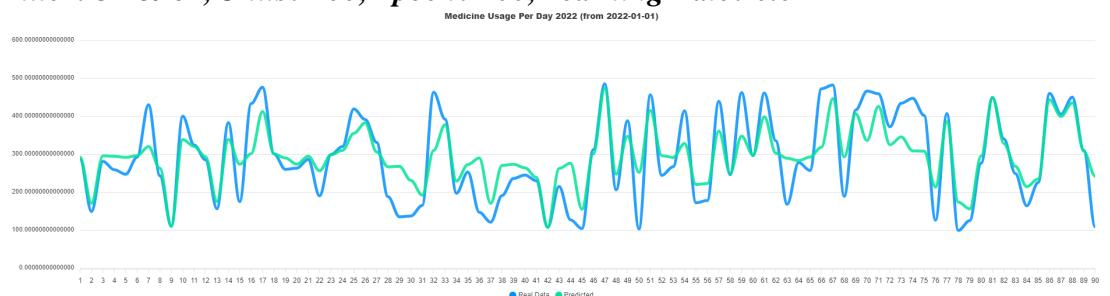
**Gambar 2.157** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 50. *Filter*: 32 & 64, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01



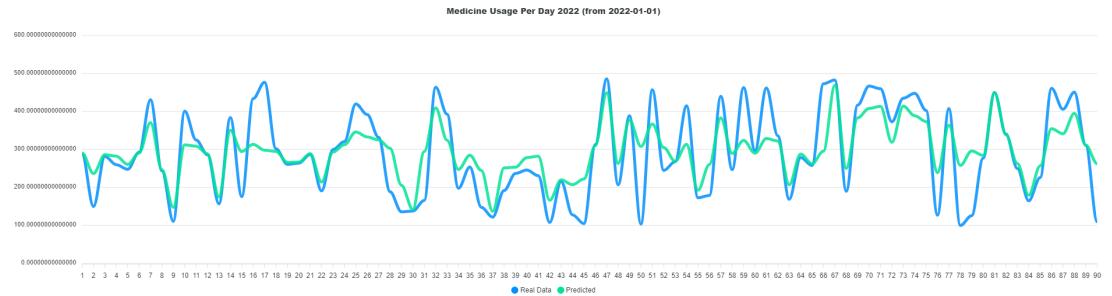
**Gambar 2.158** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 51. *Filter*: 32 & 64, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01



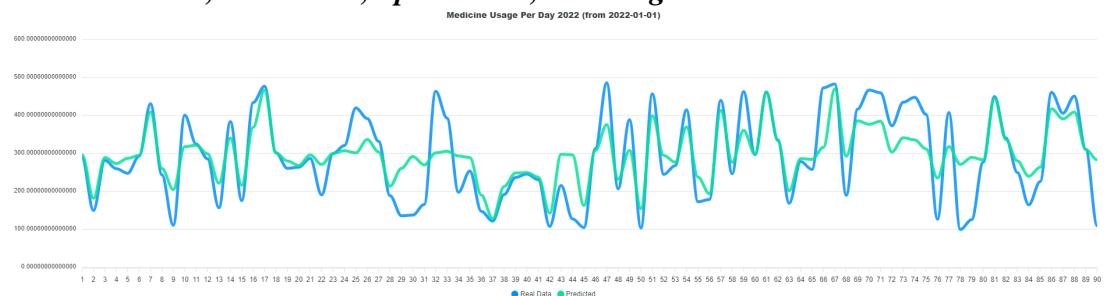
**Gambar 2.159** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 52. *Filter*: 32 & 64, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01



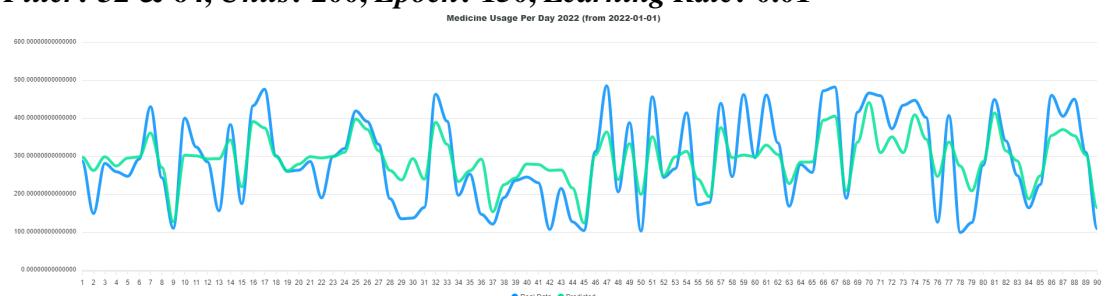
**Gambar 2.160** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 53. *Filter: 32 & 64, Units: 200, Epoch: 100, Learning Rate: 0.01*



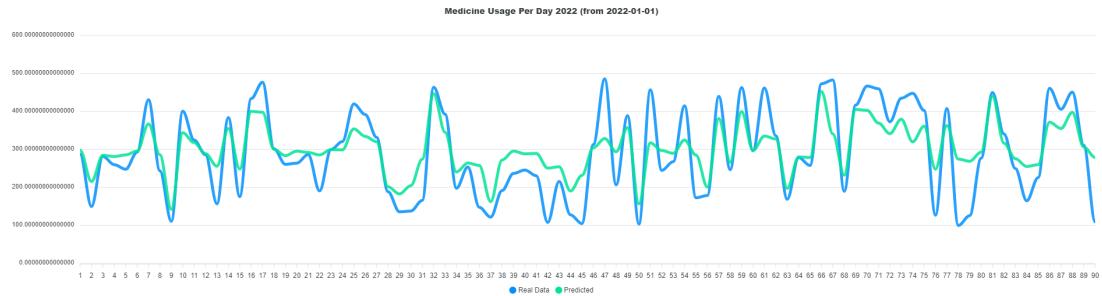
**Gambar 2.161** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 54. *Filter: 32 & 64, Units: 200, Epoch: 150, Learning Rate: 0.01*



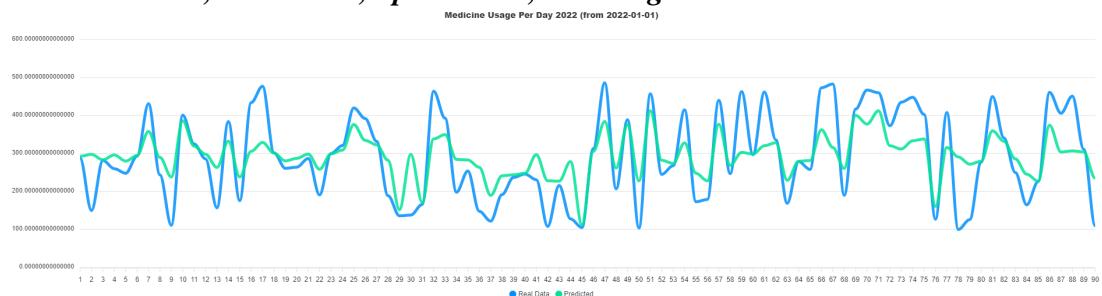
**Gambar 2.162** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 55. *Filter: 32 & 64, Units: 200, Epoch: 200, Learning Rate: 0.01*



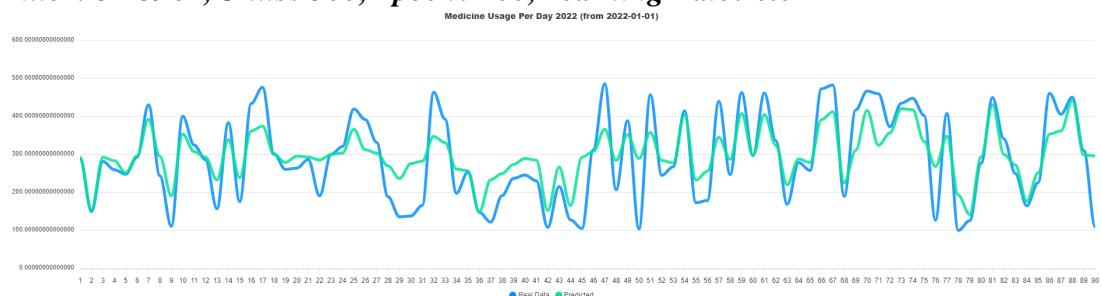
**Gambar 2.163** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 56. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.01



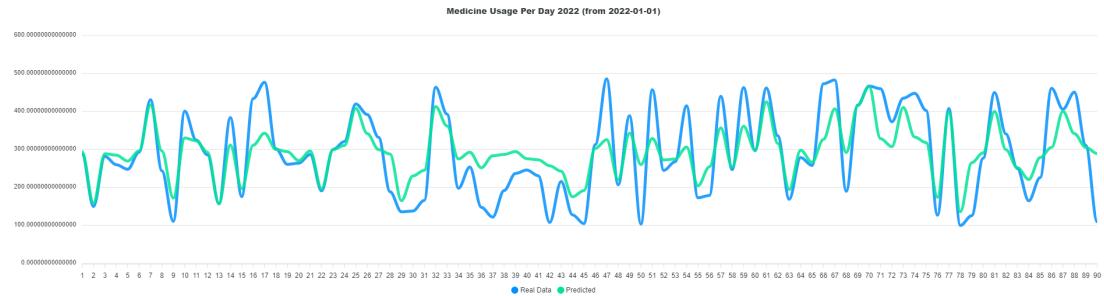
**Gambar 2.164** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 57. *Filter*: 32 & 64, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.01



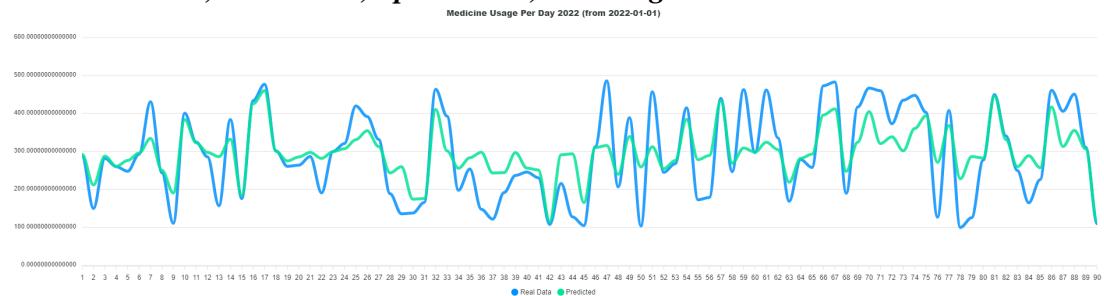
**Gambar 2.165** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 58. *Filter*: 32 & 64, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.01



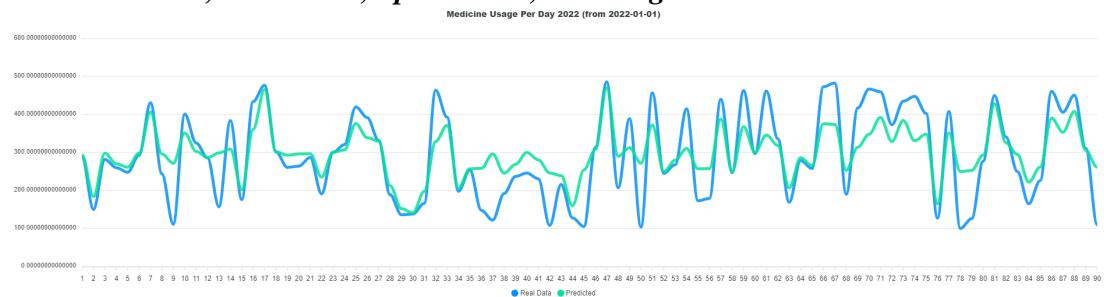
**Gambar 2.166** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 59. *Filter*: 32 & 64, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.01



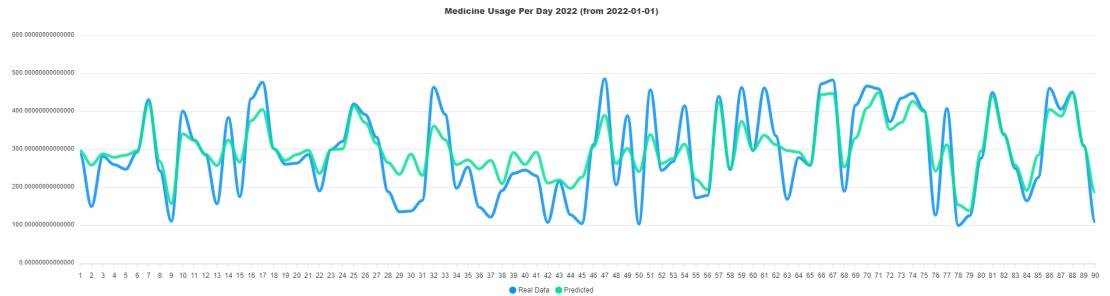
**Gambar 2.167** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 60. *Filter*: 32 & 64, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.01



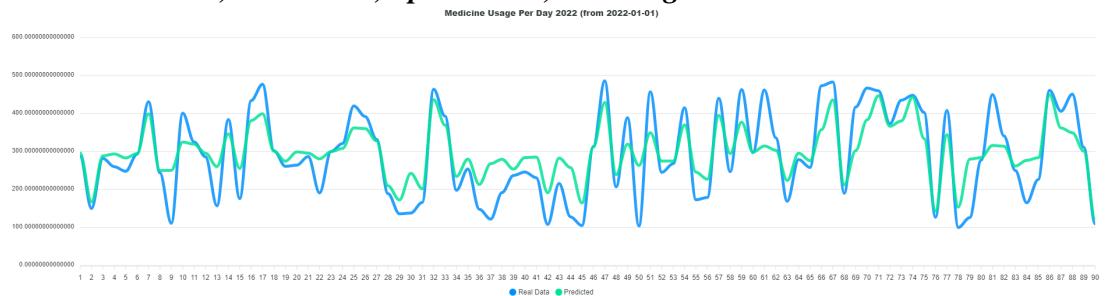
**Gambar 2.168** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 61. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.01



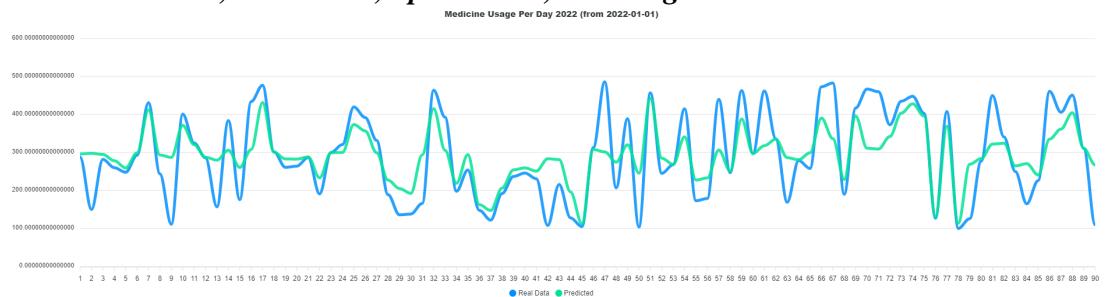
**Gambar 2.169** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

#### 62. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01



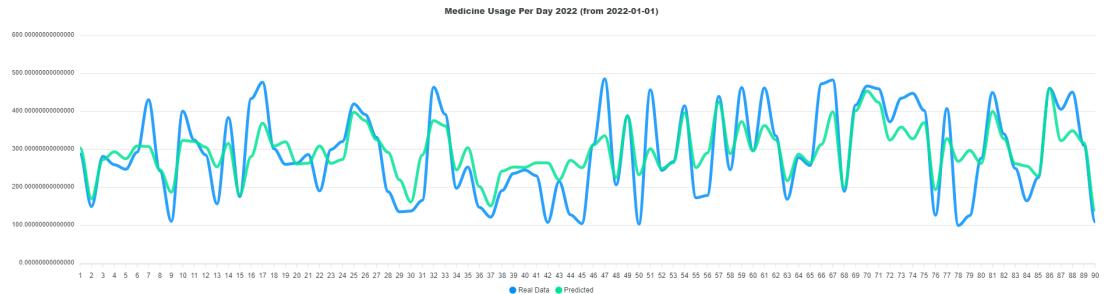
**Gambar 2.170** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

#### 63. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01



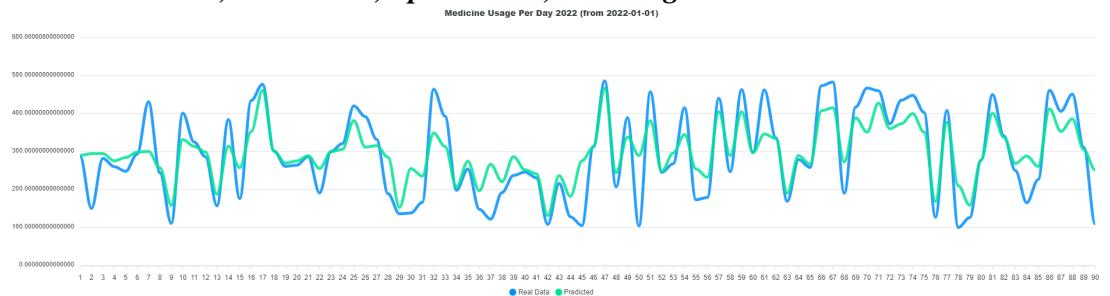
**Gambar 2.171** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

#### 64. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01



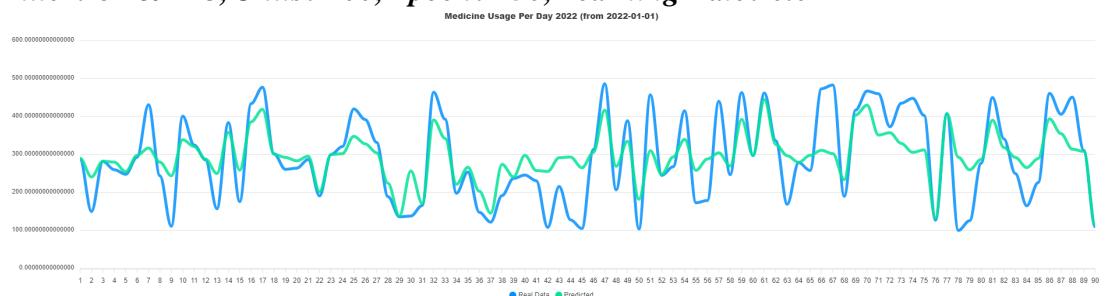
**Gambar 2.172** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 65. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.01



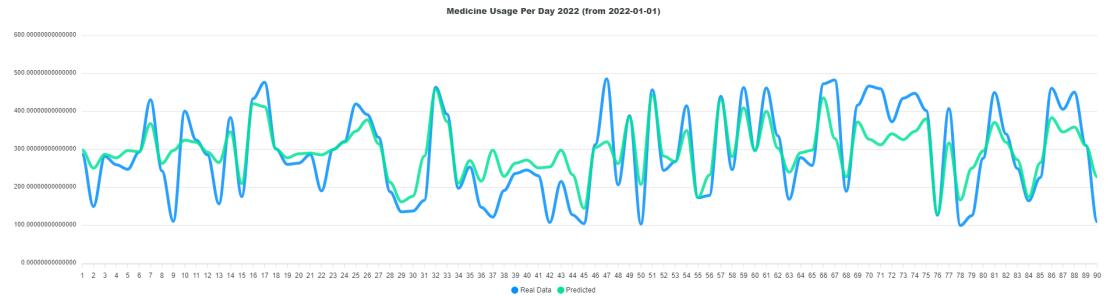
**Gambar 2.173** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 66. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.01



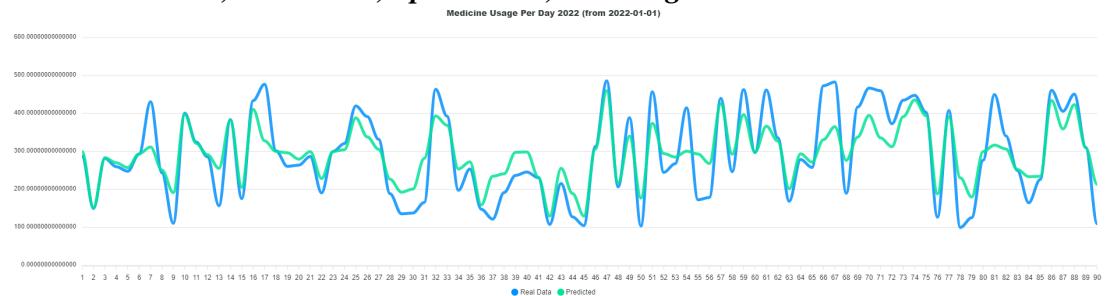
**Gambar 2.174** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 67. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.01



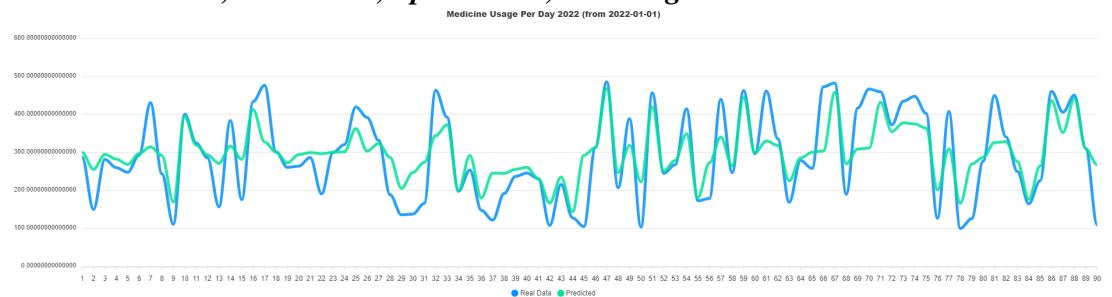
**Gambar 2.175** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 68. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.01



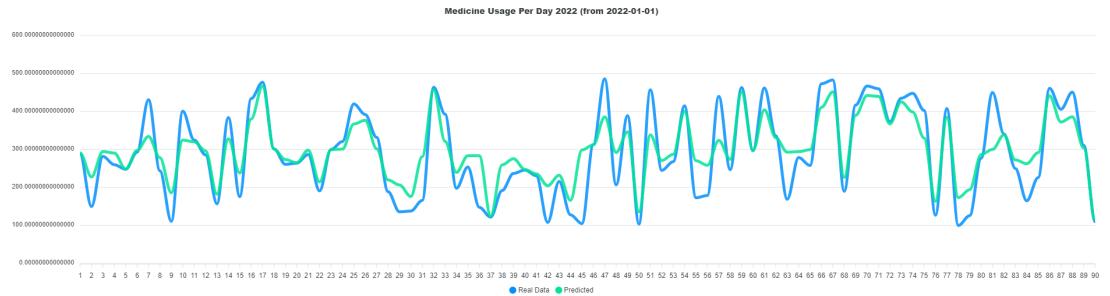
**Gambar 2.176** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 69. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.01



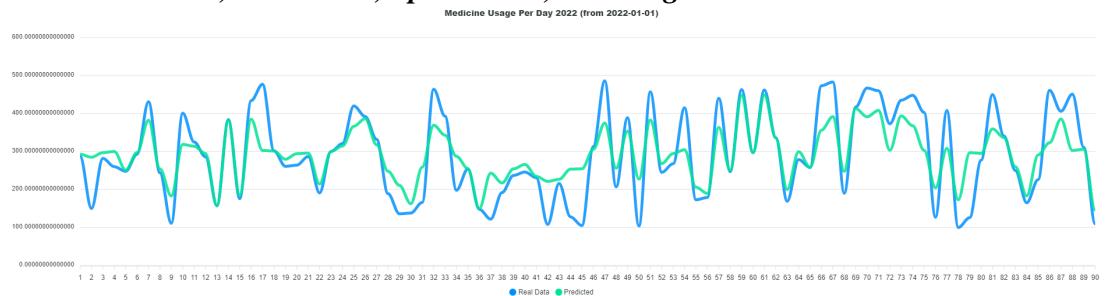
**Gambar 2.177** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 70. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.01



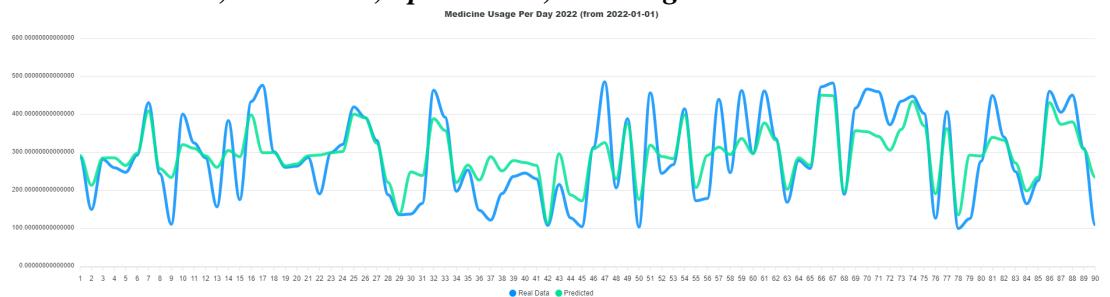
**Gambar 2.178** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 71. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.01



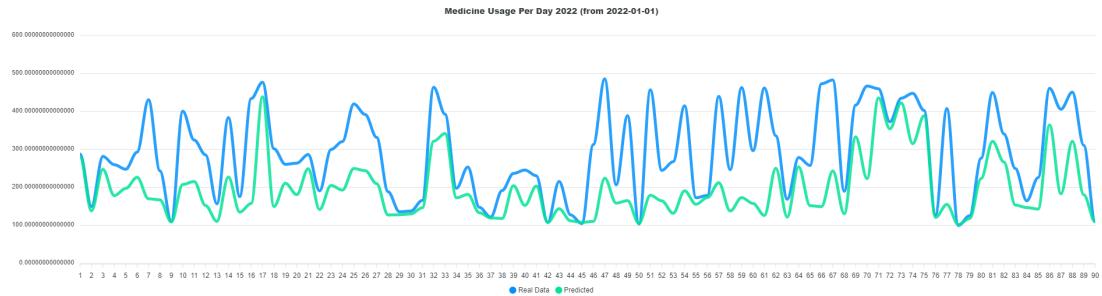
**Gambar 2.179** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 72. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.01



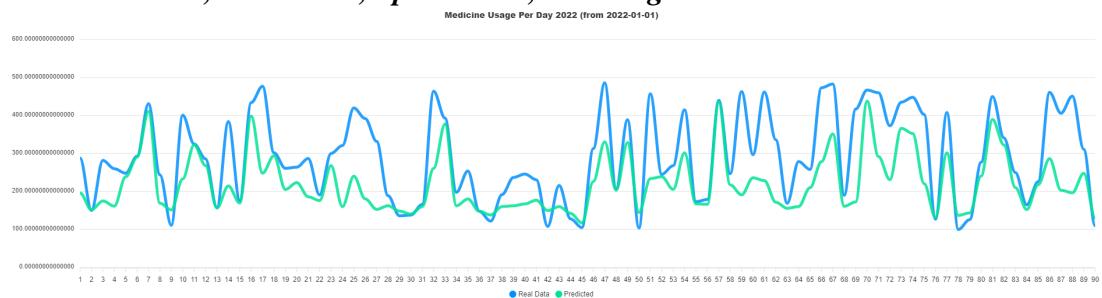
**Gambar 2.180** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.01 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 73. *Filter*: 16 & 32, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.001



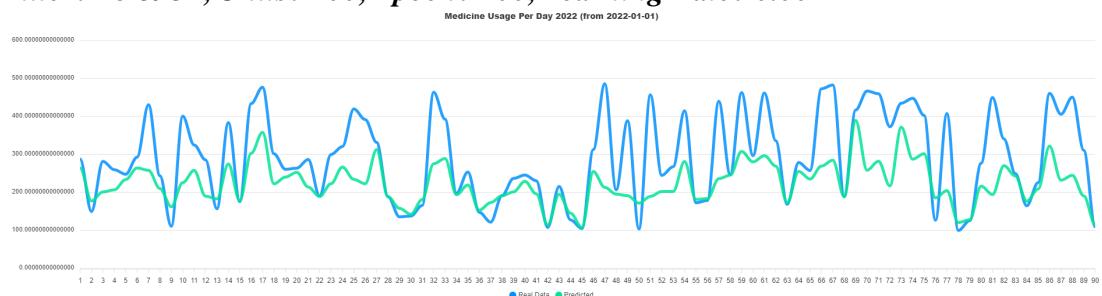
**Gambar 2.181** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 74. *Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.001*



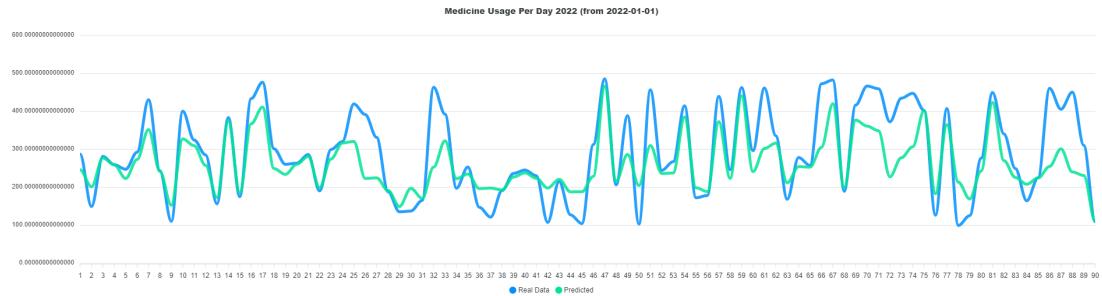
**Gambar 2.182** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 75. *Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.001*



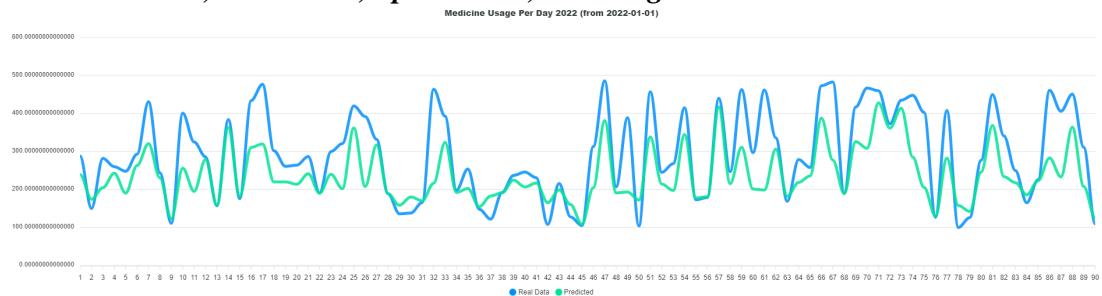
**Gambar 2.183** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 76. *Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.001*



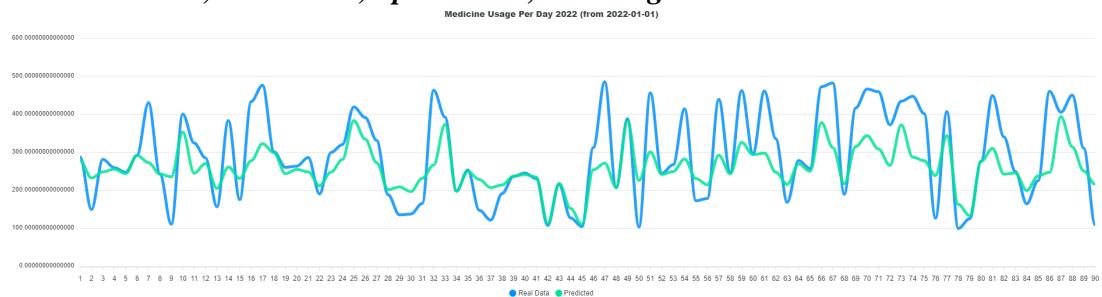
**Gambar 2.184** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 77. *Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.001*



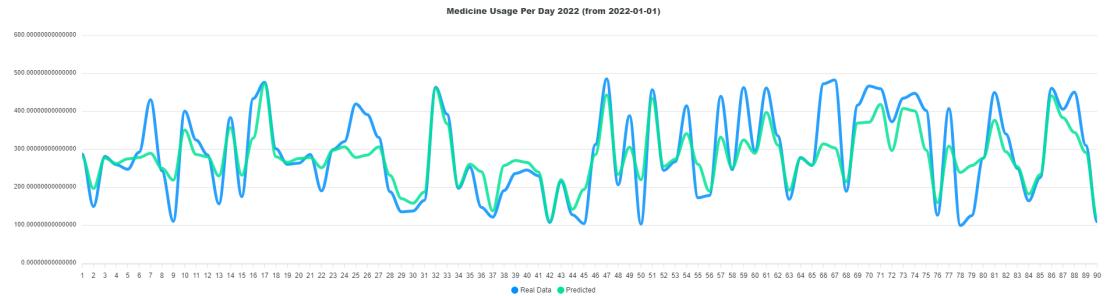
**Gambar 2.185** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 78. *Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.001*



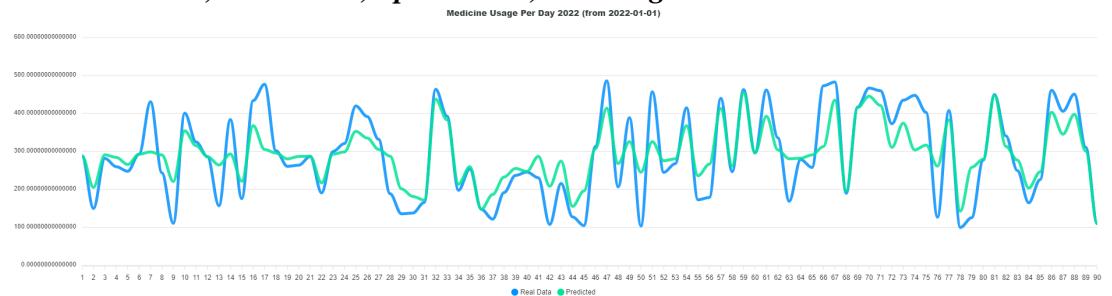
**Gambar 2.186** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 79. *Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.001*



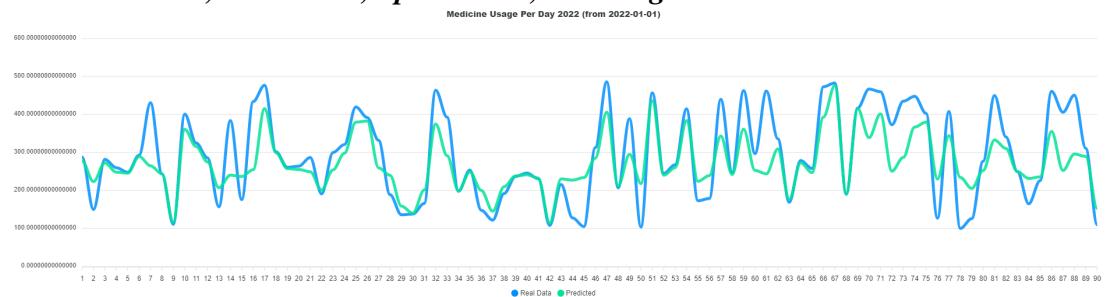
**Gambar 2.187** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 80. *Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.001*



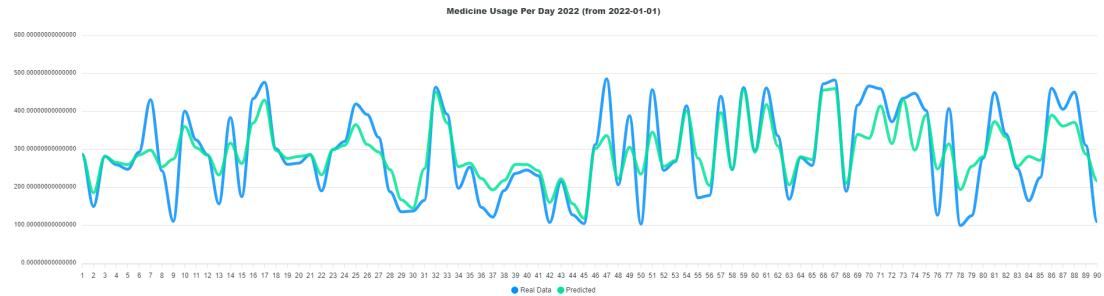
**Gambar 2.188** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 81. *Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.001*



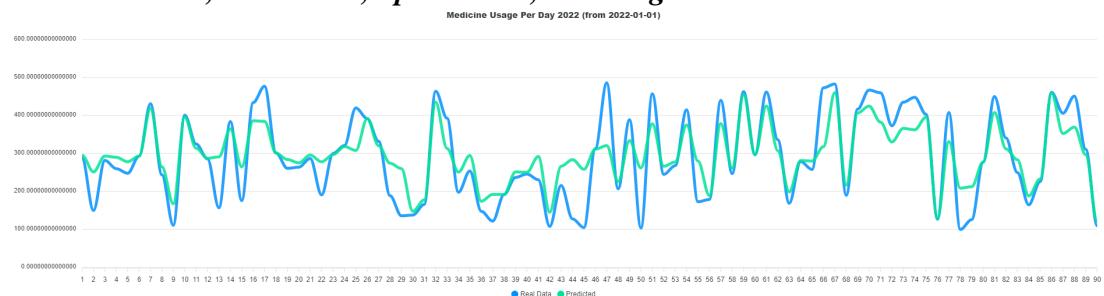
**Gambar 2.189** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 82. *Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.001*



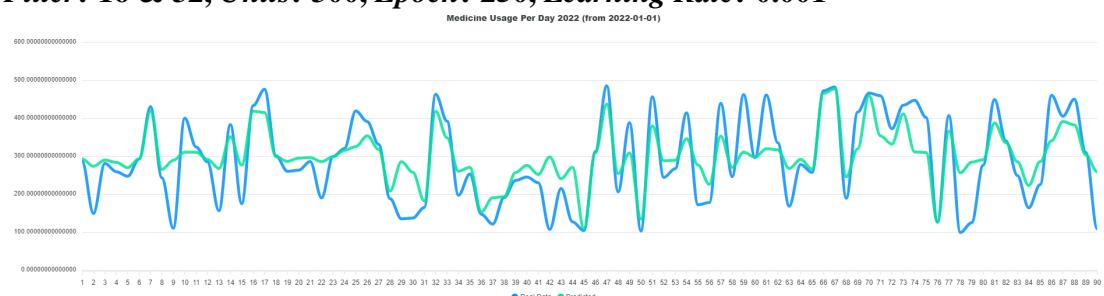
**Gambar 2.190** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 83. *Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.001*



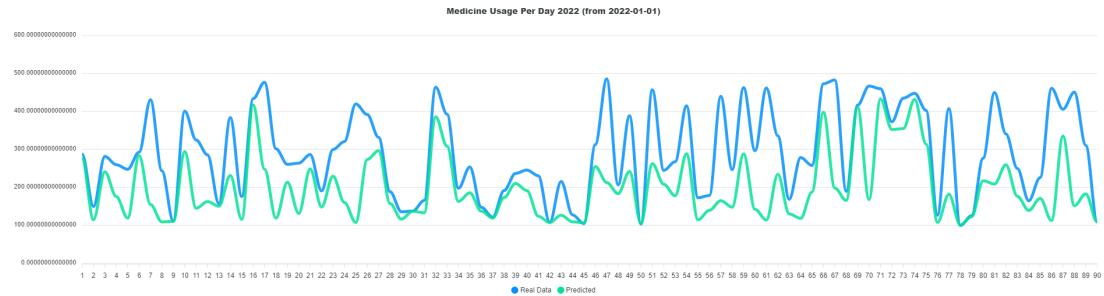
**Gambar 2.191** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 84. *Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.001*



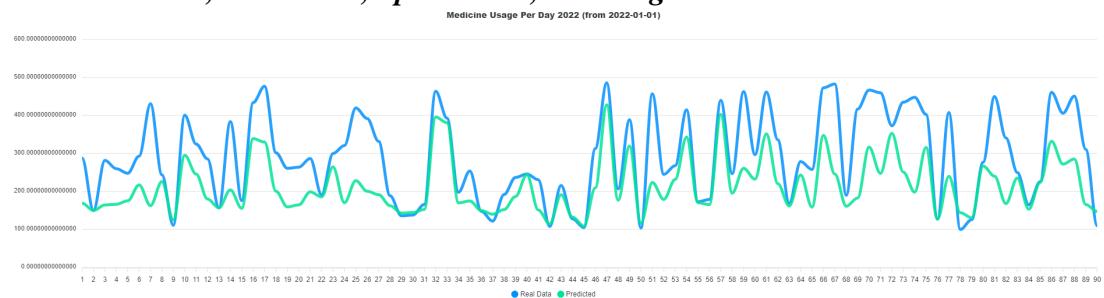
**Gambar 2.192** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 85. *Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.001*



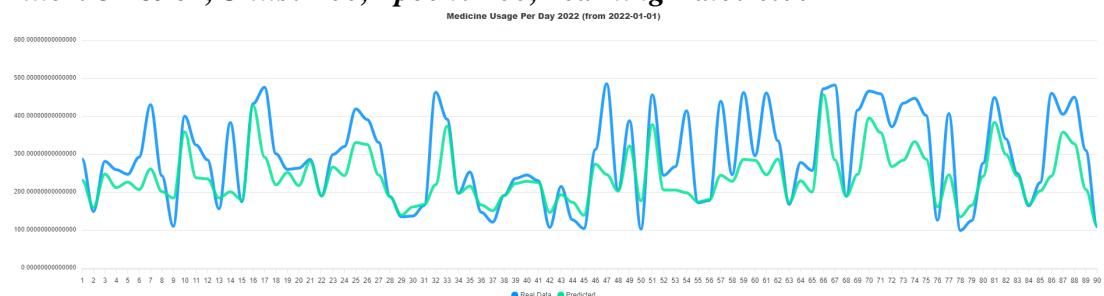
**Gambar 2.193** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 86. *Filter: 32 & 64, Units: 100, Epoch: 150, Learning Rate: 0.001*



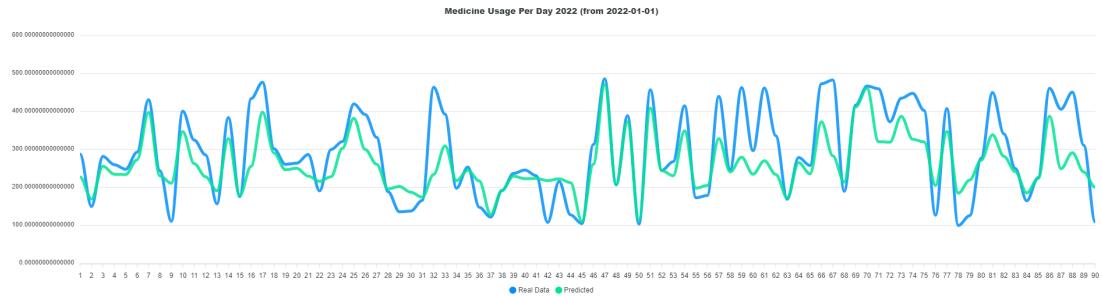
**Gambar 2.194** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 87. *Filter: 32 & 64, Units: 100, Epoch: 200, Learning Rate: 0.001*



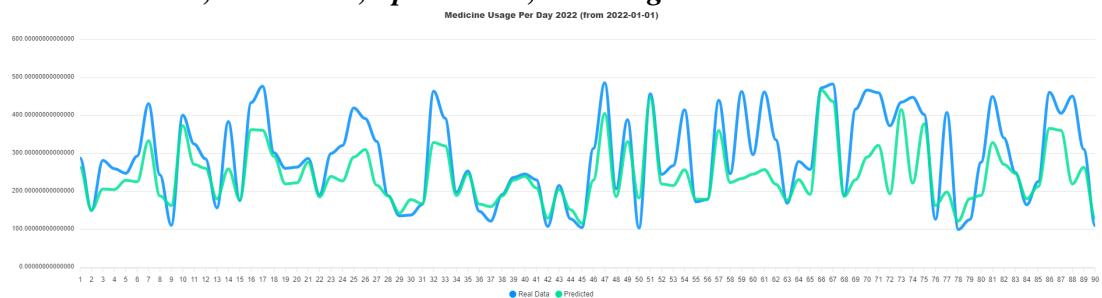
**Gambar 2.195** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 88. *Filter: 32 & 64, Units: 100, Epoch: 250, Learning Rate: 0.001*



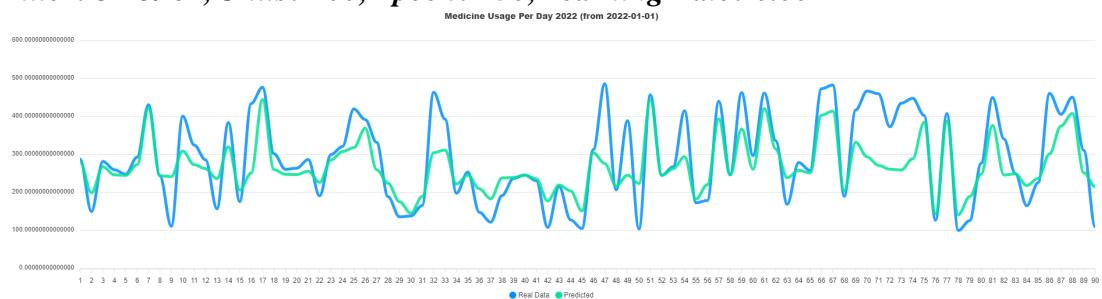
**Gambar 2.196** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 89. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001



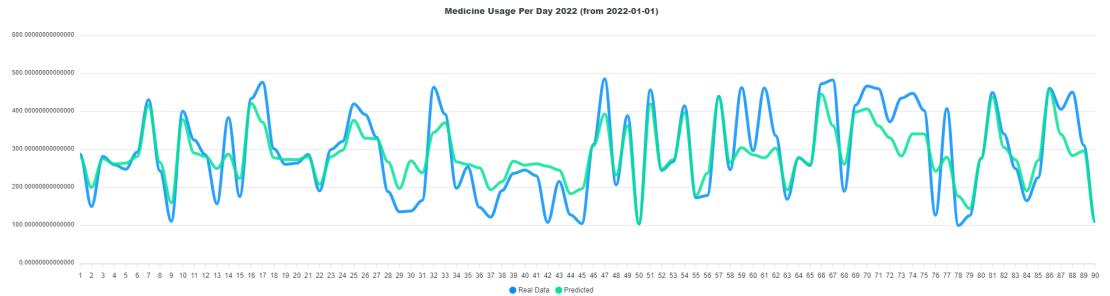
**Gambar 2.197** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 90. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001



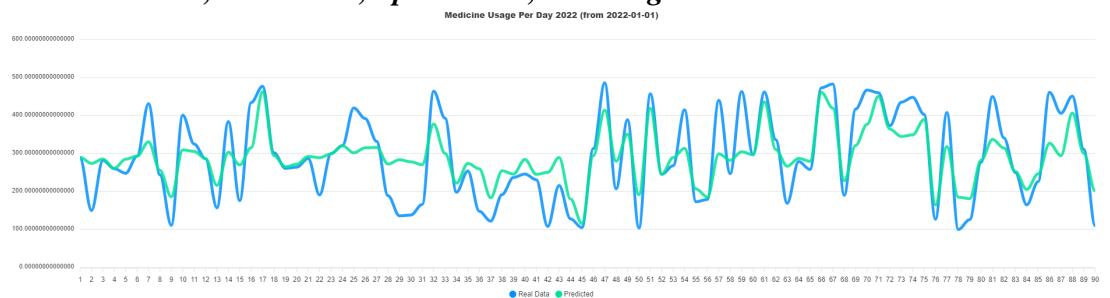
**Gambar 2.198** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 91. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001



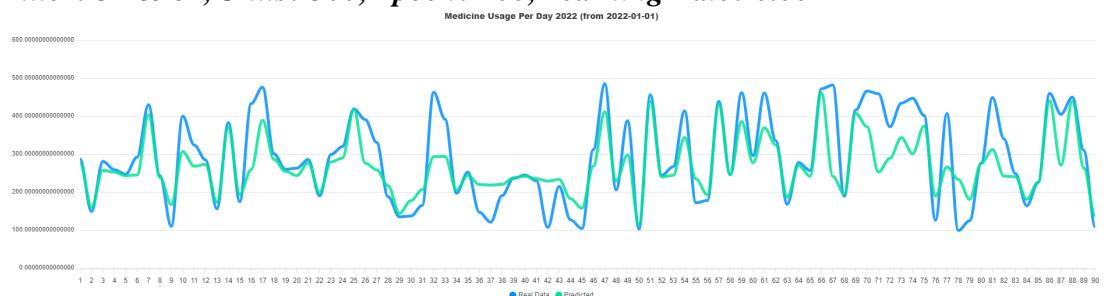
**Gambar 2.199** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 92. *Filter: 32 & 64, Units: 200, Epoch: 250, Learning Rate: 0.001*



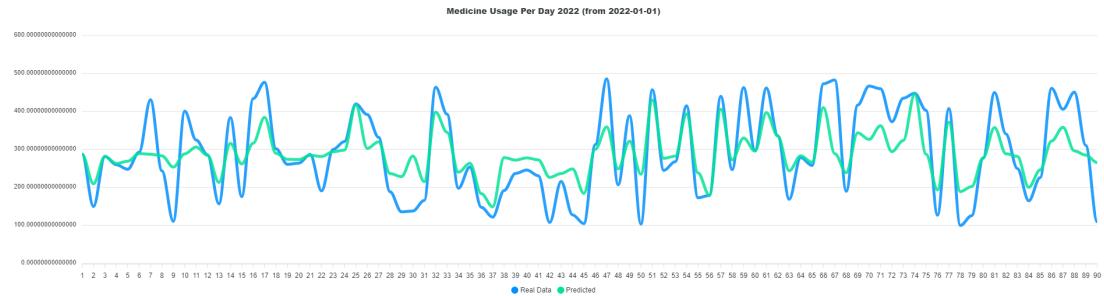
**Gambar 2.200** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 93. *Filter: 32 & 64, Units: 300, Epoch: 100, Learning Rate: 0.001*



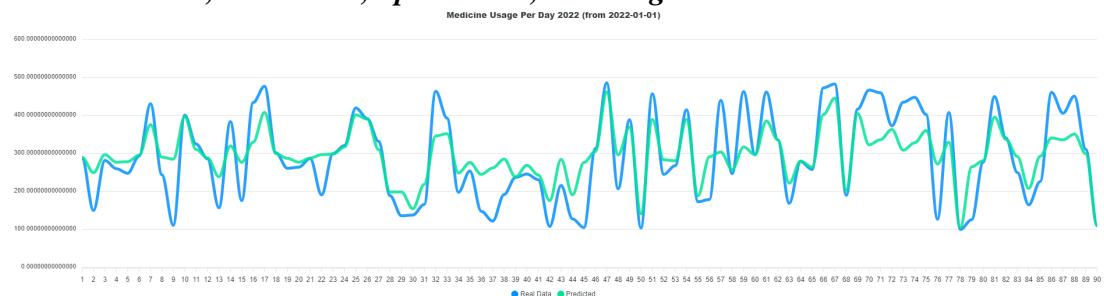
**Gambar 2.201** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 94. *Filter: 32 & 64, Units: 300, Epoch: 150, Learning Rate: 0.001*



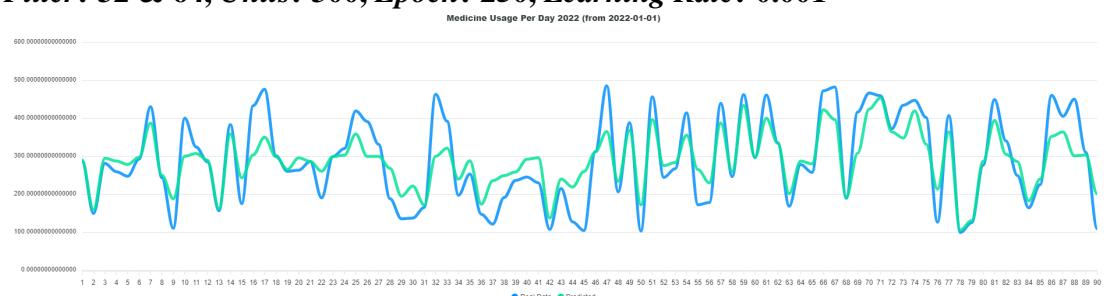
**Gambar 2.202** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 95. *Filter: 32 & 64, Units: 300, Epoch: 200, Learning Rate: 0.001*



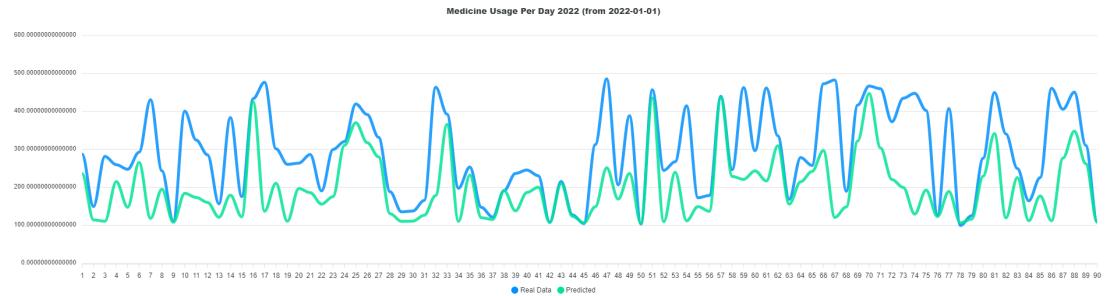
**Gambar 2.203** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 96. *Filter: 32 & 64, Units: 300, Epoch: 250, Learning Rate: 0.001*



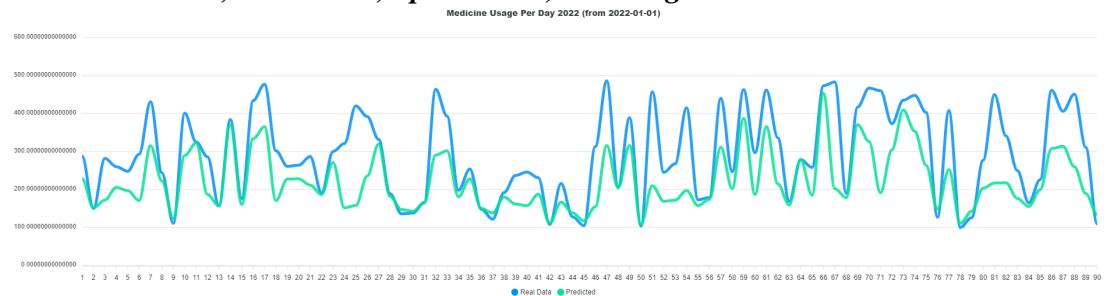
**Gambar 2.204** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 97. *Filter: 64 & 128, Units: 100, Epoch: 100, Learning Rate: 0.001*



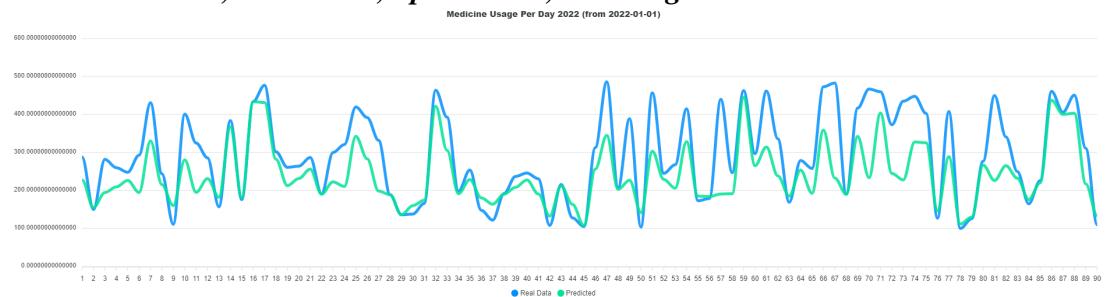
**Gambar 2.205** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 98. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.001



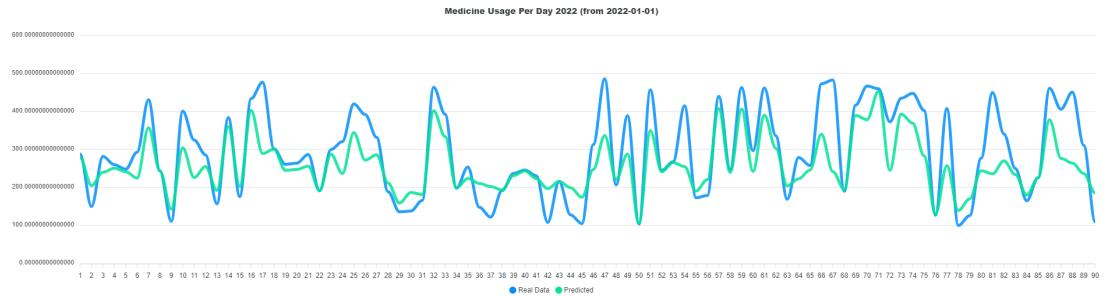
**Gambar 2.206** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 99. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001



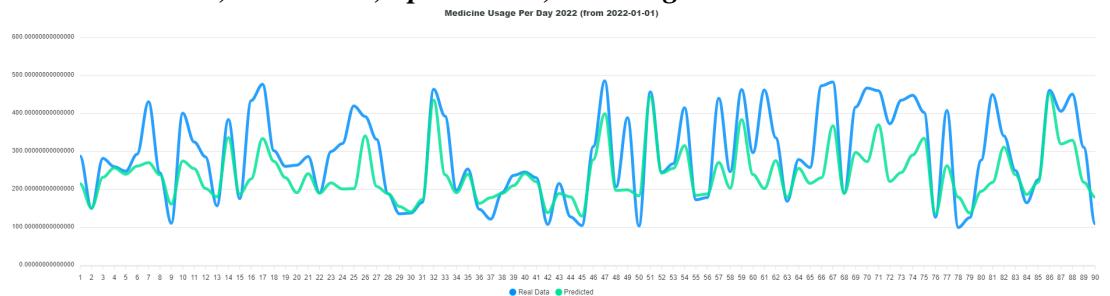
**Gambar 2.207** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 100. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.001



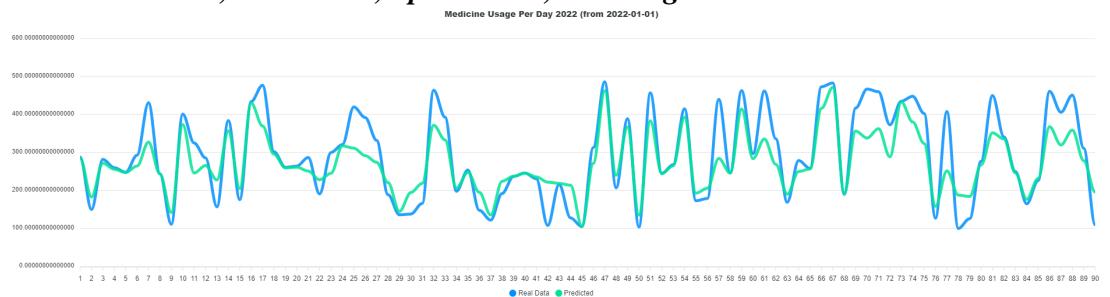
**Gambar 2.208** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

#### 101. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001



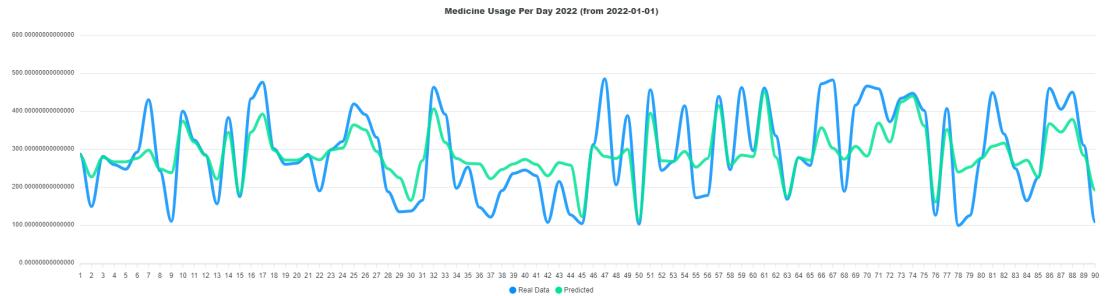
**Gambar 2.209** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

#### 102. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001



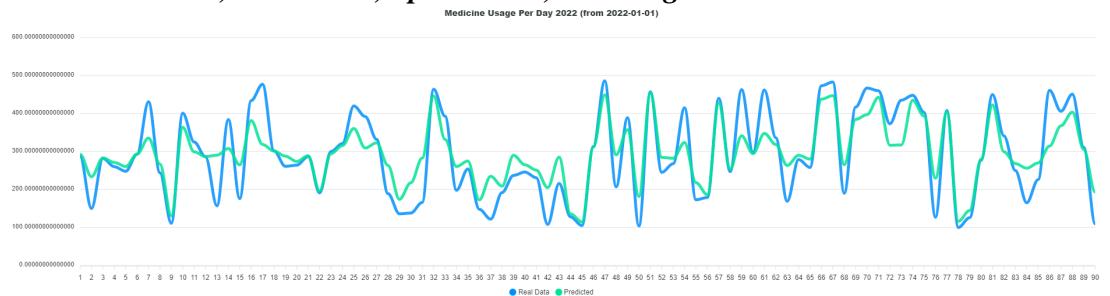
**Gambar 2.210** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

#### 103. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001



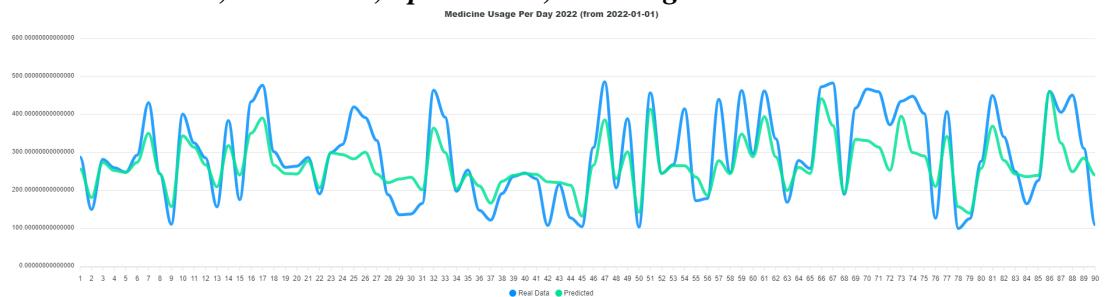
**Gambar 2.211** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 104. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.001



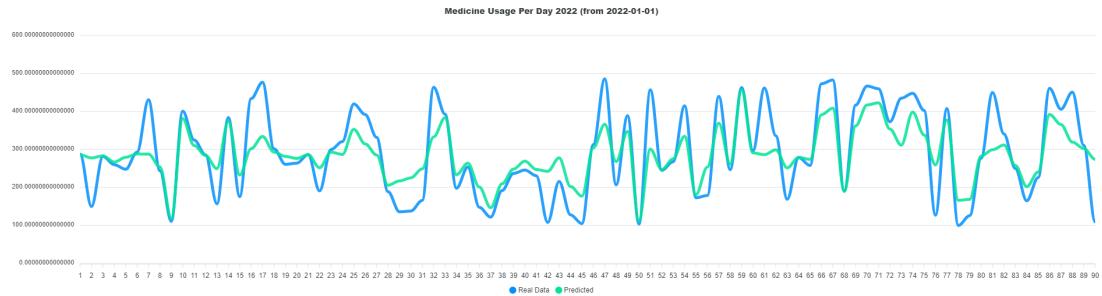
**Gambar 2.212** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 105. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.001



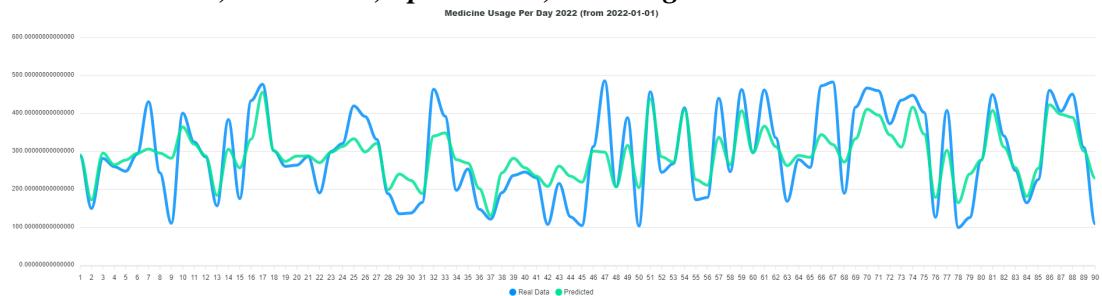
**Gambar 2.213** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 106. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.001



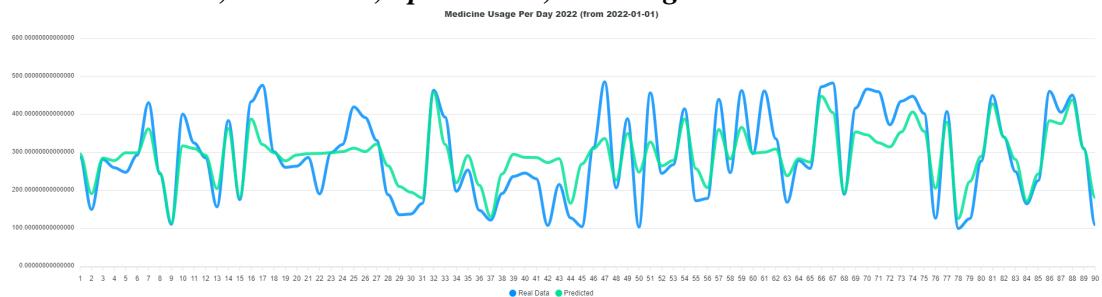
**Gambar 2.214** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

**107. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.001**



**Gambar 2.215** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

**108. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.001**

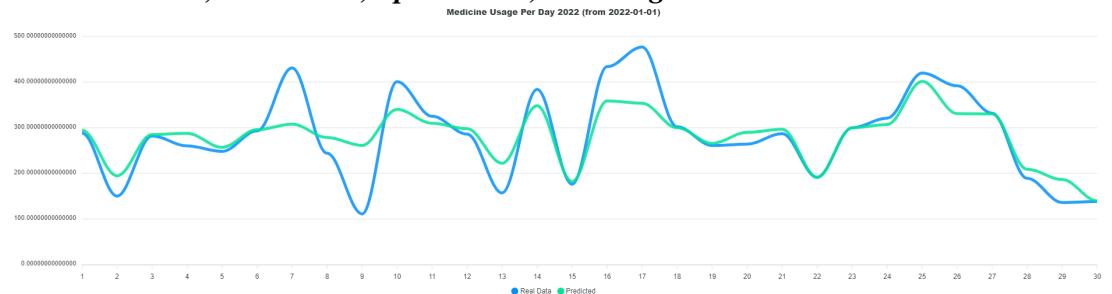


**Gambar 2.216** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.001 dan 1 lapisan *Max Pooling* untuk forecasting horizon 90 hari

## LAMPIRAN C HASIL PENGUJIAN ARSITEKTUR 3

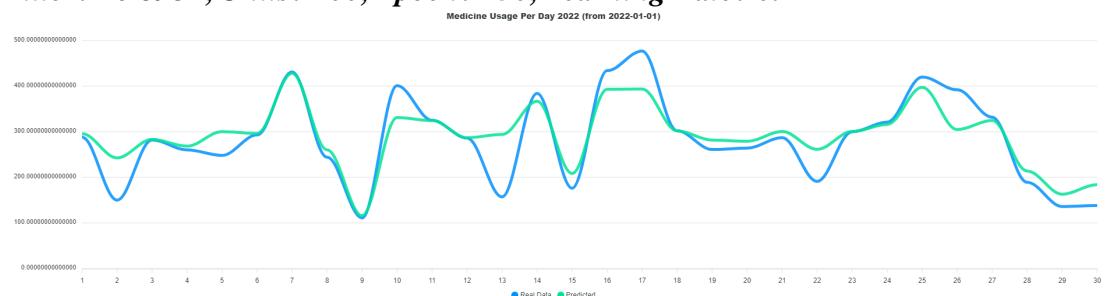
### 3.1 Forecasting Horizon 30 hari

#### 1. Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.1



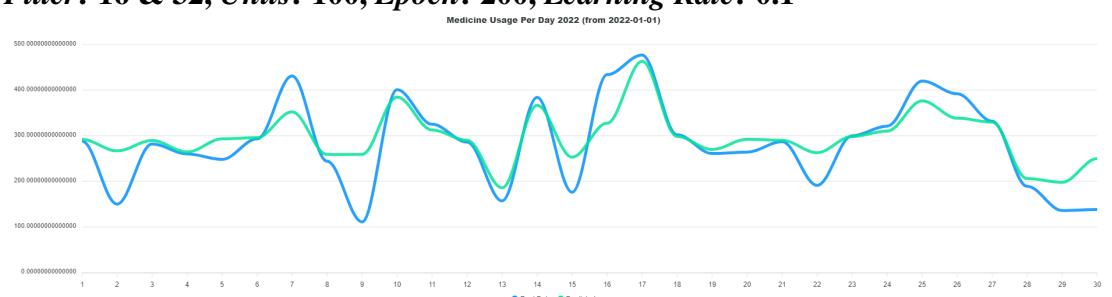
**Gambar 3.1** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

#### 2. Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.1



**Gambar 3.2** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

#### 3. Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.1

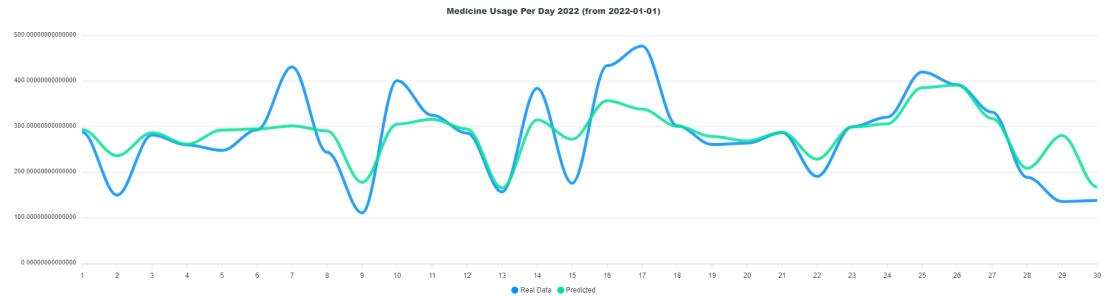


**Gambar 3.3** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

#### 4. Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.1

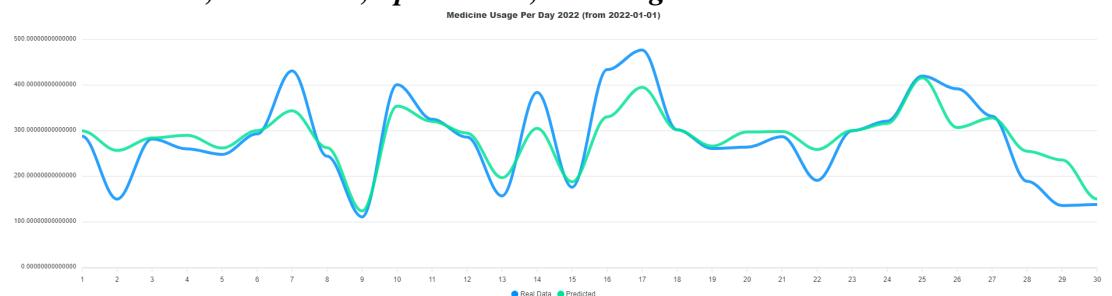
## BAB C Hasil Pengujian Arsitektur 3

---



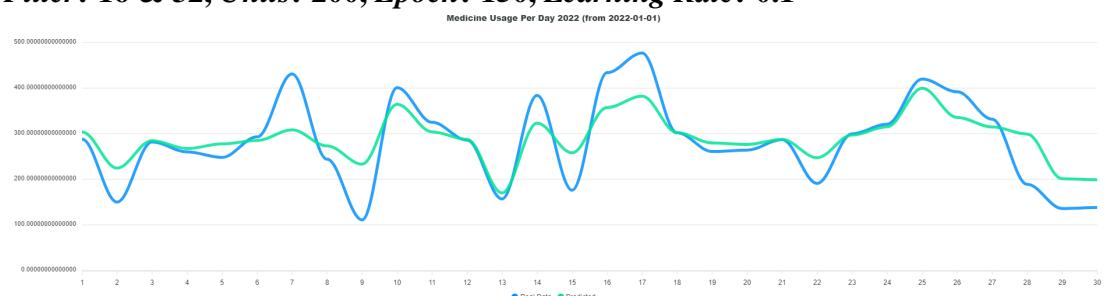
**Gambar 3.4** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 5. *Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.1*



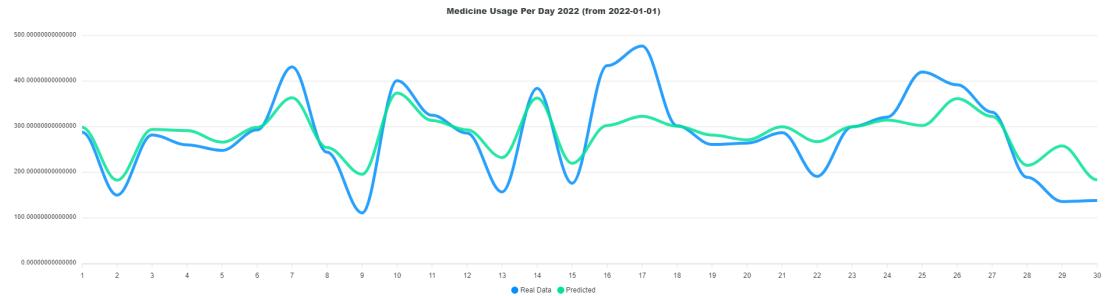
**Gambar 3.5** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 6. *Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.1*



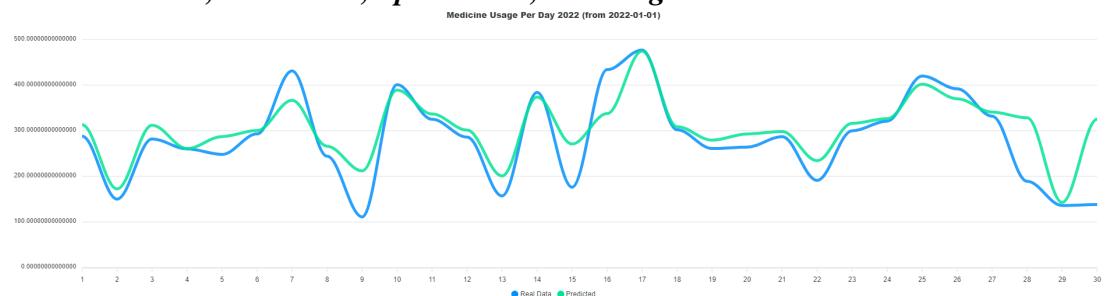
**Gambar 3.6** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 7. *Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.1*



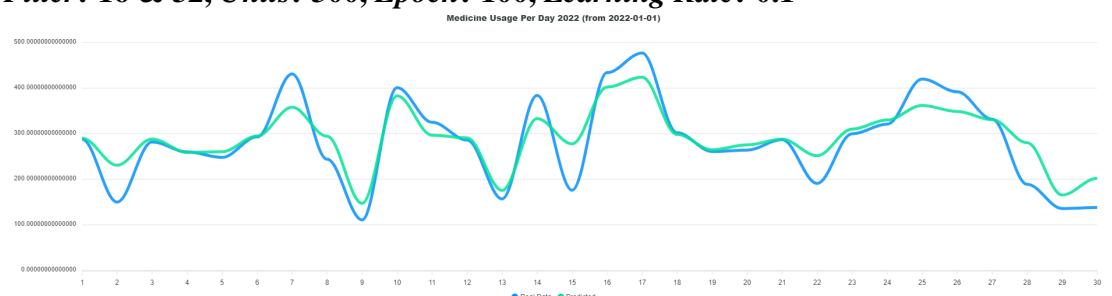
**Gambar 3.7** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 8. *Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.1*



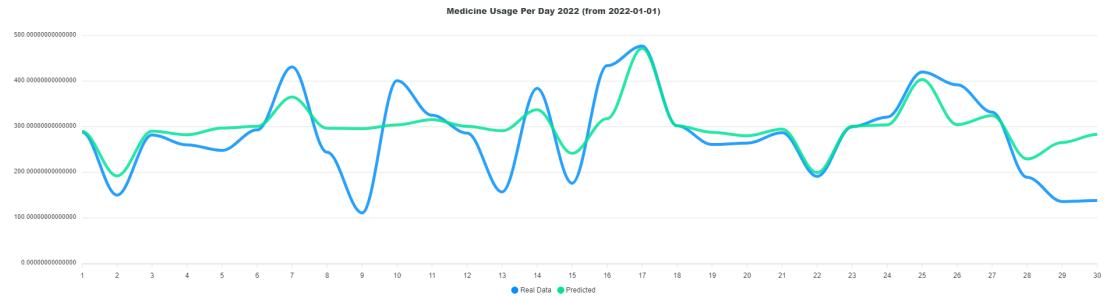
**Gambar 3.8** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 9. *Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.1*



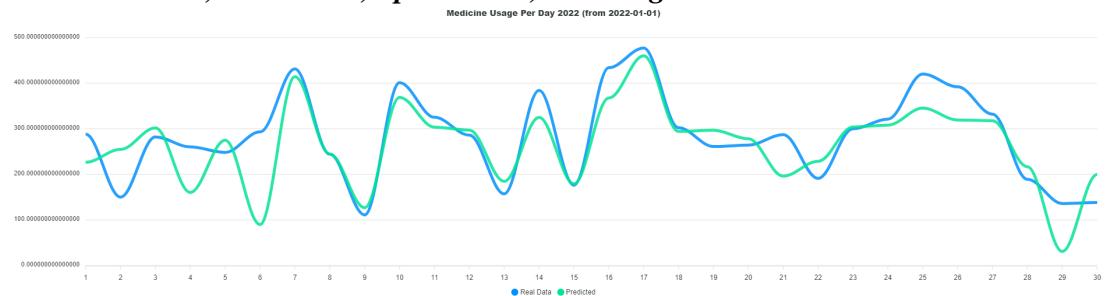
**Gambar 3.9** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 10. *Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.1*



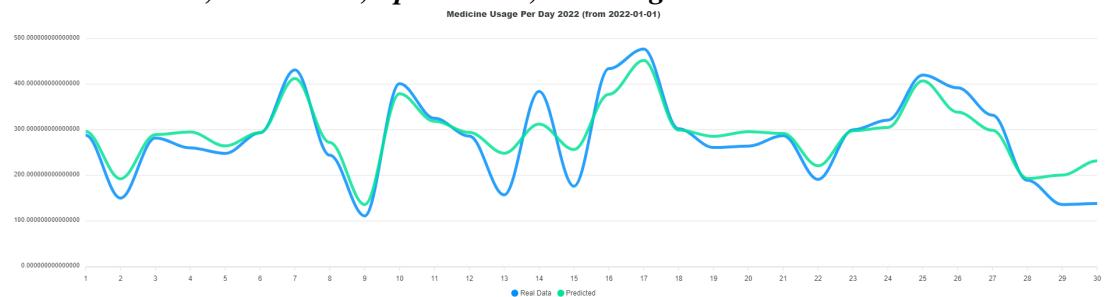
**Gambar 3.10** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 11. *Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.1*



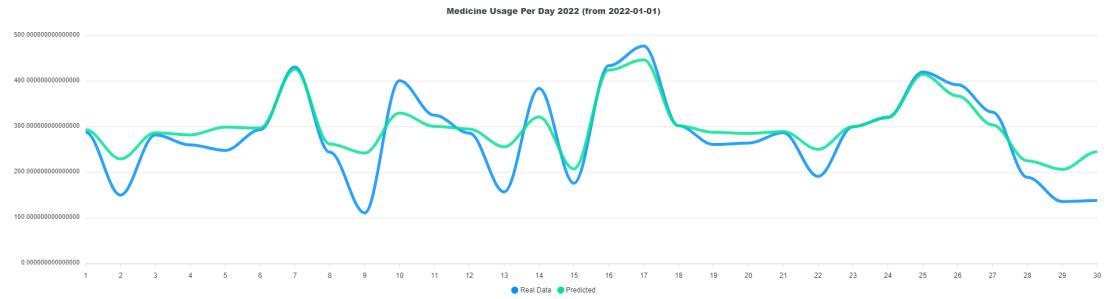
**Gambar 3.11** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 12. *Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.1*



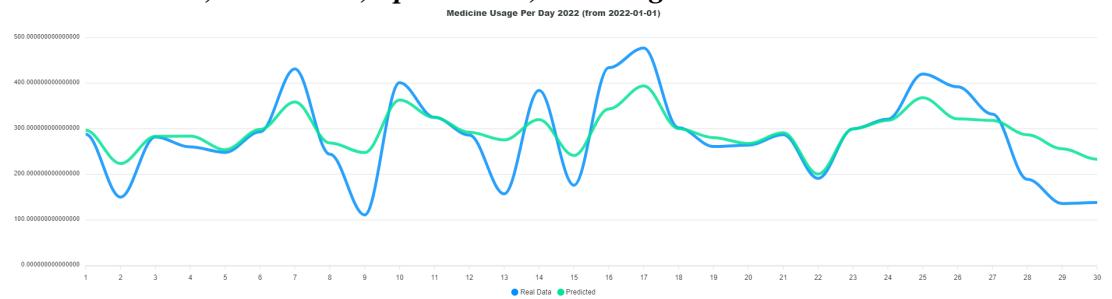
**Gambar 3.12** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 13. *Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.1*



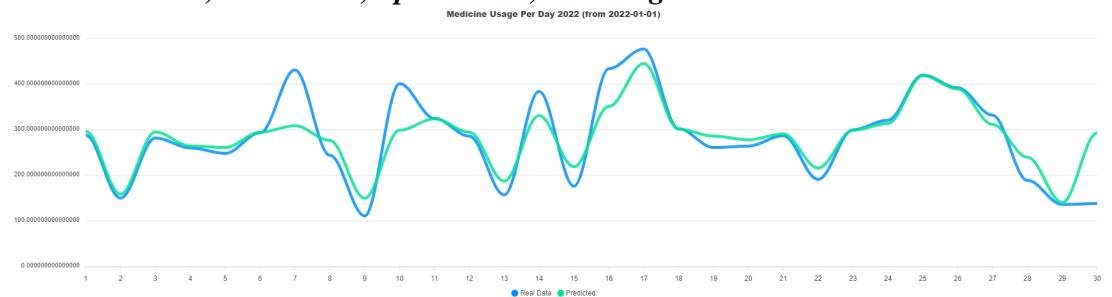
**Gambar 3.13** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 14. *Filter: 32 & 64, Units: 100, Epoch: 150, Learning Rate: 0.1*



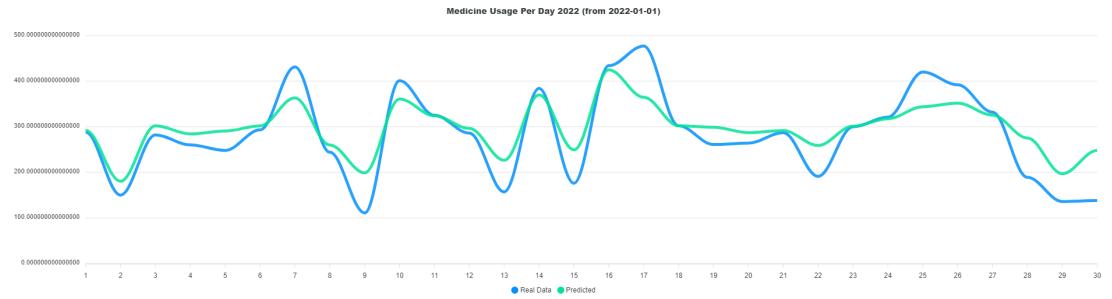
**Gambar 3.14** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 15. *Filter: 32 & 64, Units: 100, Epoch: 200, Learning Rate: 0.1*



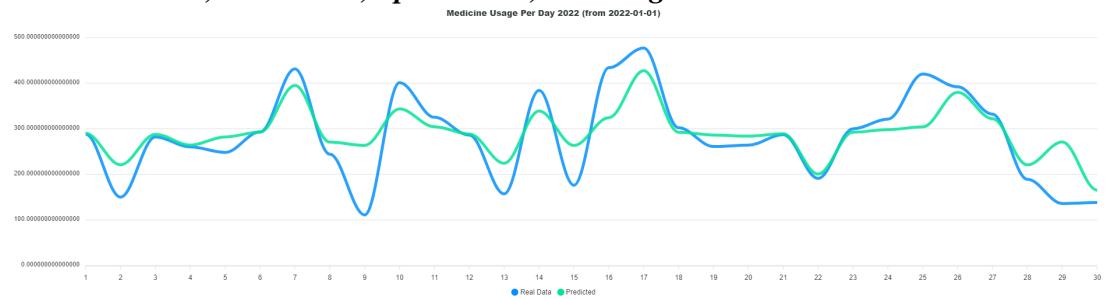
**Gambar 3.15** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 16. *Filter: 32 & 64, Units: 100, Epoch: 250, Learning Rate: 0.1*



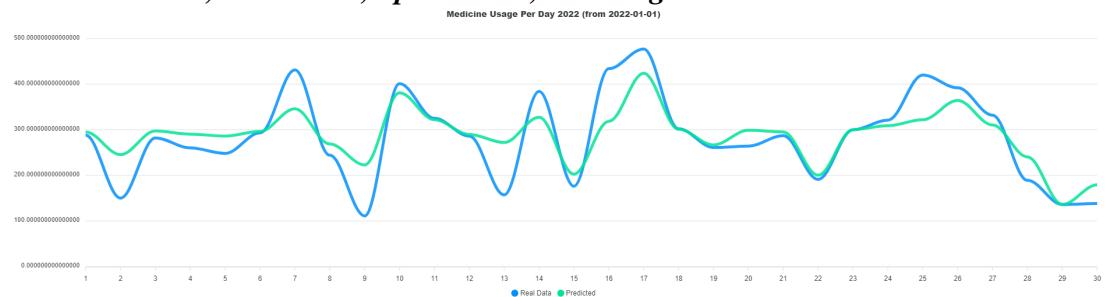
**Gambar 3.16** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 17. *Filter: 32 & 64, Units: 200, Epoch: 100, Learning Rate: 0.1*



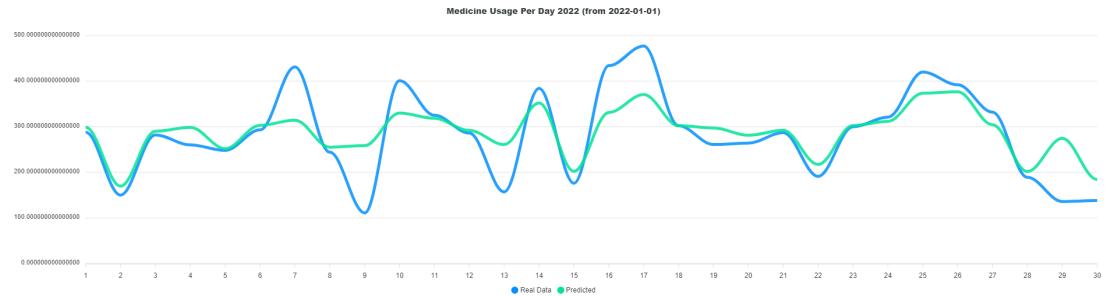
**Gambar 3.17** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 18. *Filter: 32 & 64, Units: 200, Epoch: 150, Learning Rate: 0.1*



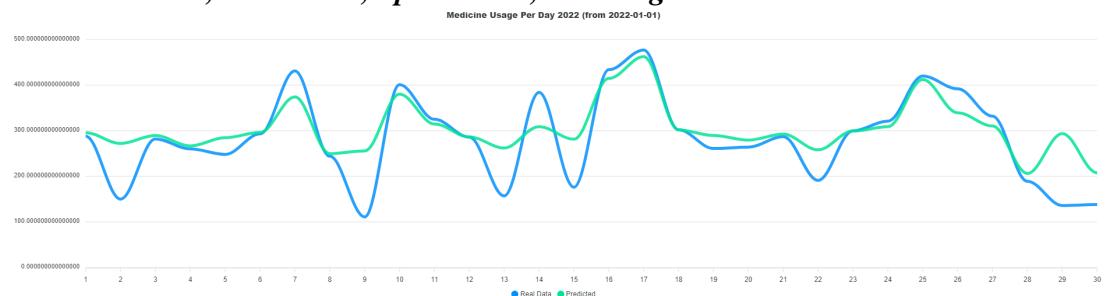
**Gambar 3.18** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 19. *Filter: 32 & 64, Units: 200, Epoch: 200, Learning Rate: 0.1*



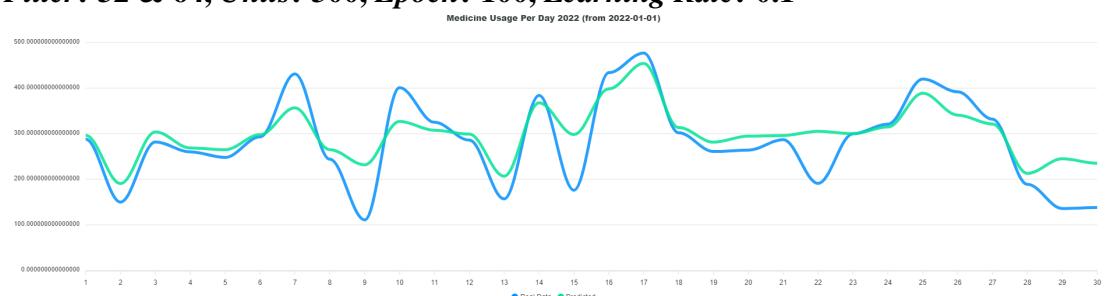
**Gambar 3.19** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 20. *Filter: 32 & 64, Units: 200, Epoch: 250, Learning Rate: 0.1*



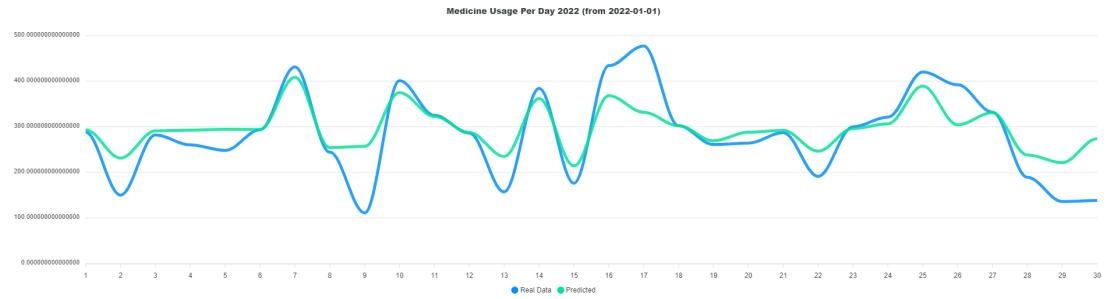
**Gambar 3.20** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 21. *Filter: 32 & 64, Units: 300, Epoch: 100, Learning Rate: 0.1*



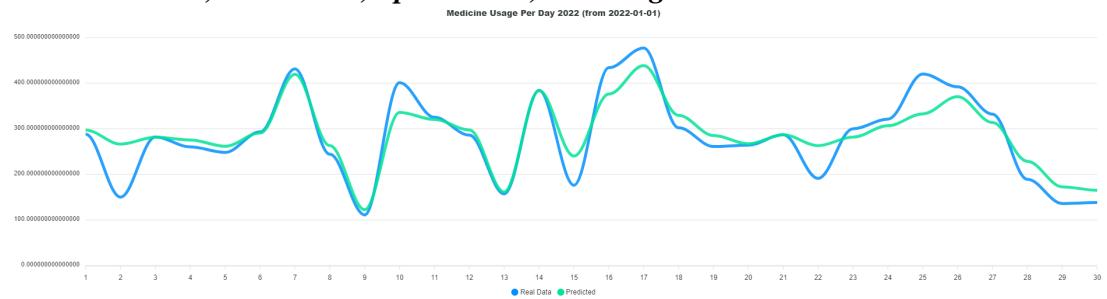
**Gambar 3.21** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 22. *Filter: 32 & 64, Units: 300, Epoch: 150, Learning Rate: 0.1*



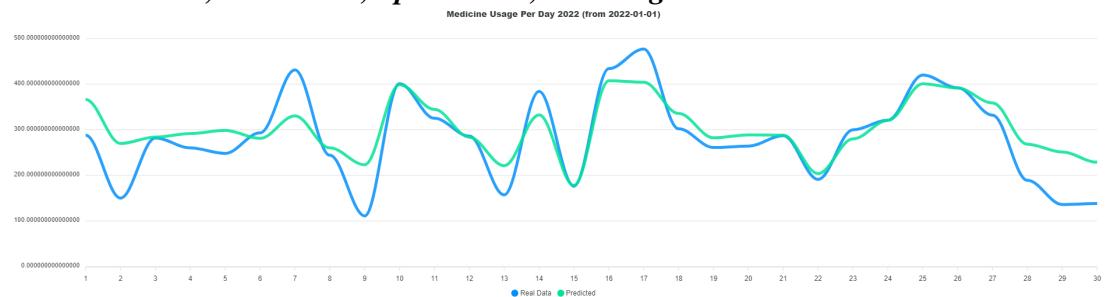
**Gambar 3.22** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 23. *Filter: 32 & 64, Units: 300, Epoch: 200, Learning Rate: 0.1*



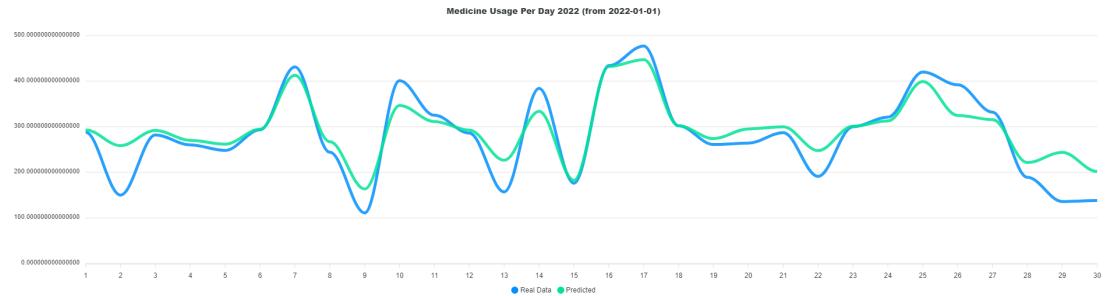
**Gambar 3.23** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 24. *Filter: 32 & 64, Units: 300, Epoch: 250, Learning Rate: 0.1*



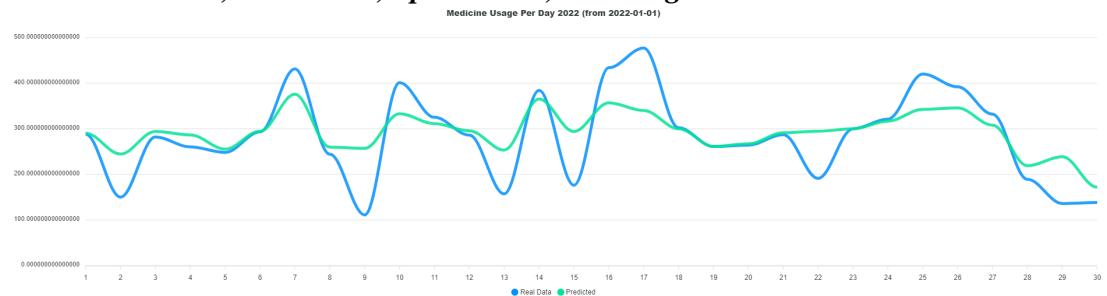
**Gambar 3.24** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 25. *Filter: 64 & 128, Units: 100, Epoch: 100, Learning Rate: 0.1*



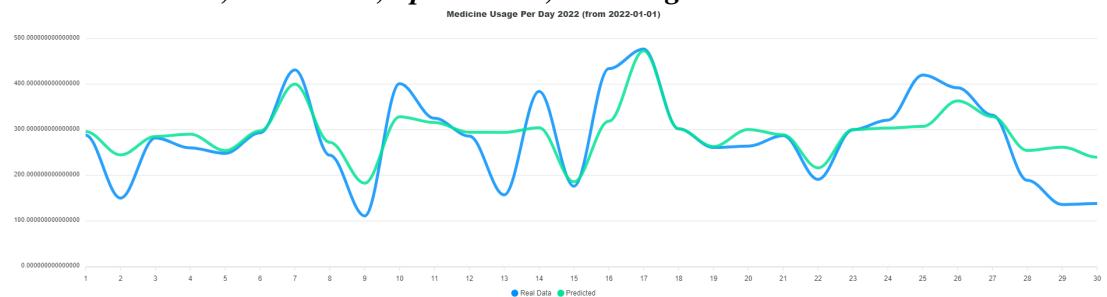
**Gambar 3.25** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 26. *Filter: 64 & 128, Units: 100, Epoch: 150, Learning Rate: 0.1*



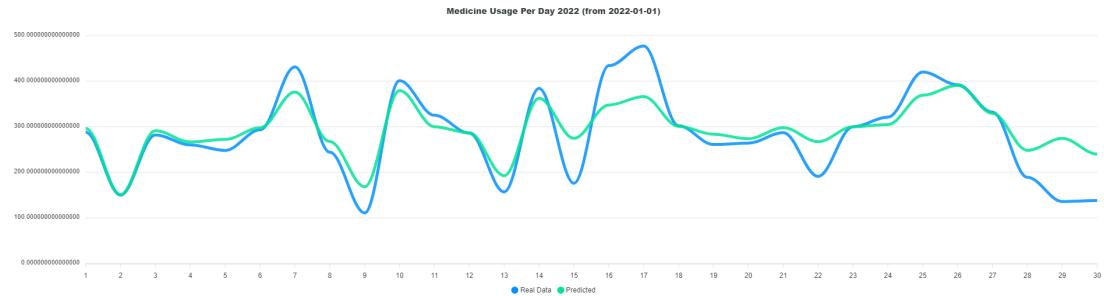
**Gambar 3.26** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 27. *Filter: 64 & 128, Units: 100, Epoch: 200, Learning Rate: 0.1*



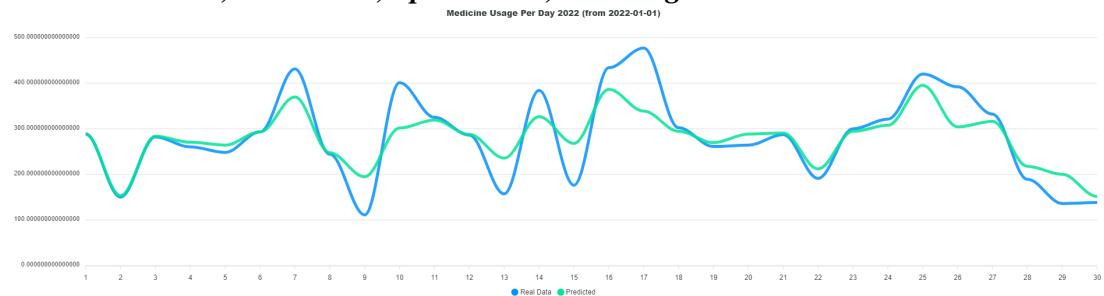
**Gambar 3.27** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 28. *Filter: 64 & 128, Units: 100, Epoch: 250, Learning Rate: 0.1*



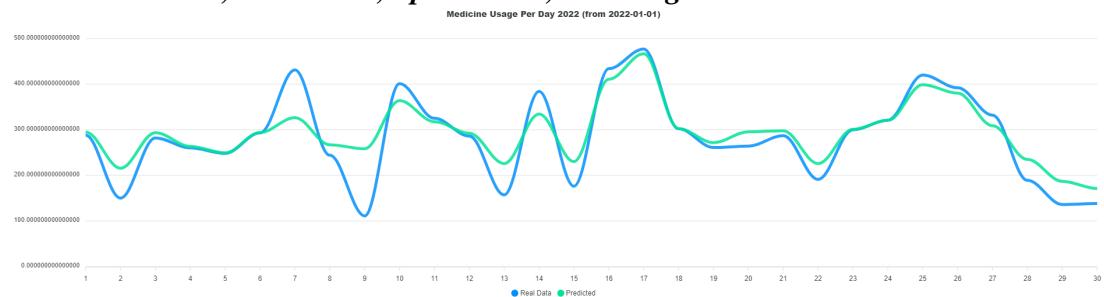
**Gambar 3.28** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 29. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.1



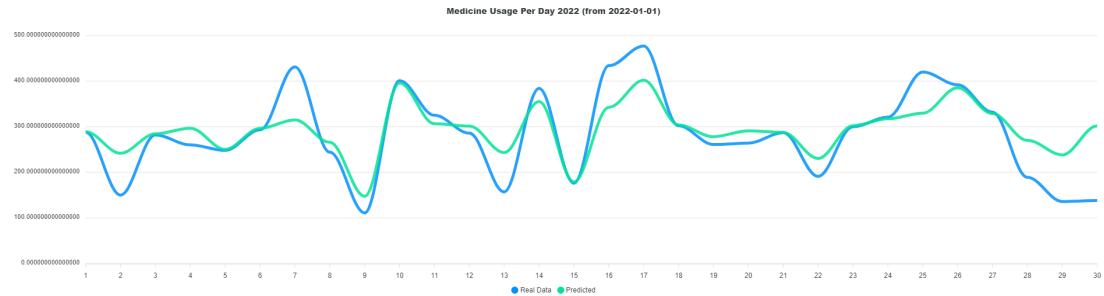
**Gambar 3.29** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 30. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.1



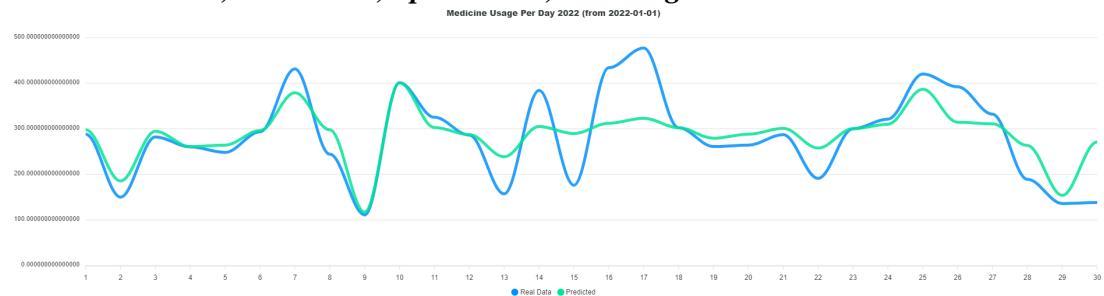
**Gambar 3.30** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 31. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.1



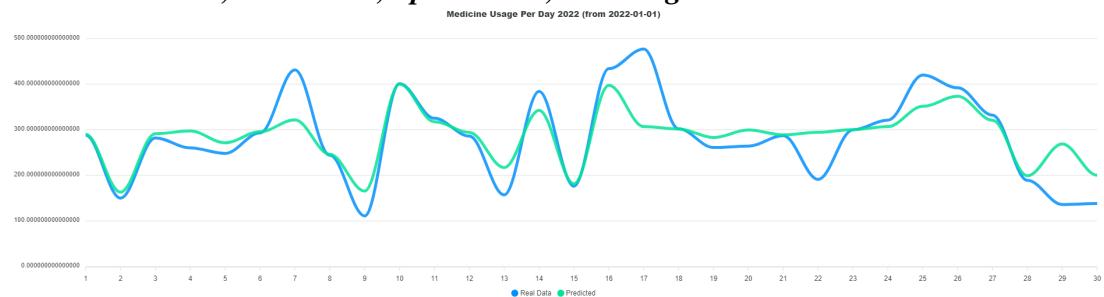
**Gambar 3.31** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 32. *Filter: 64 & 128, Units: 200, Epoch: 250, Learning Rate: 0.1*



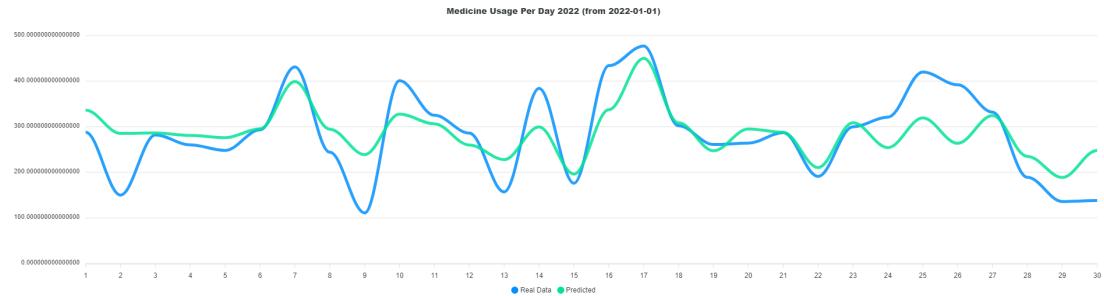
**Gambar 3.32** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 33. *Filter: 64 & 128, Units: 300, Epoch: 100, Learning Rate: 0.1*



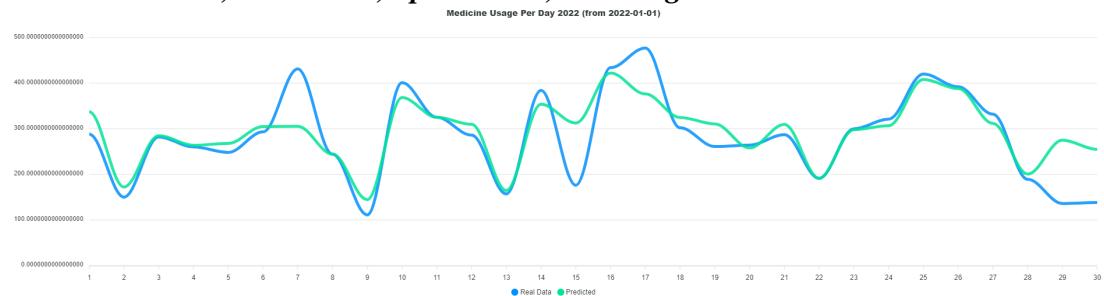
**Gambar 3.33** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 34. *Filter: 64 & 128, Units: 300, Epoch: 150, Learning Rate: 0.1*



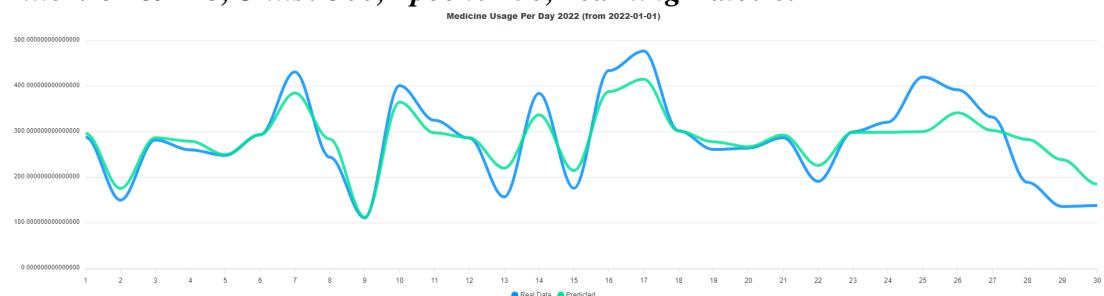
**Gambar 3.34** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 35. *Filter: 64 & 128, Units: 300, Epoch: 200, Learning Rate: 0.1*



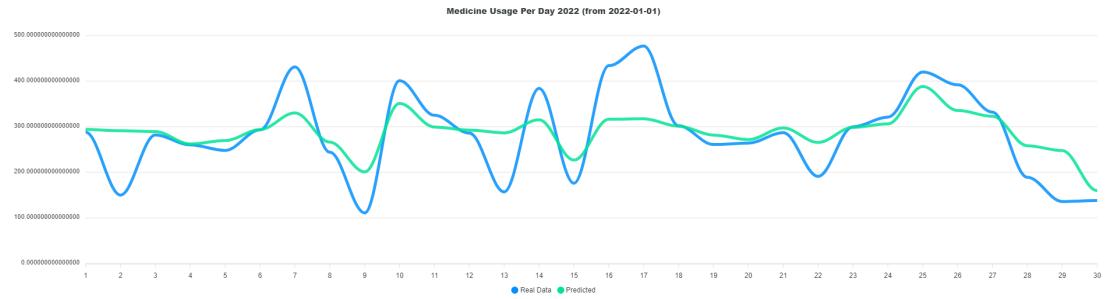
**Gambar 3.35** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 36. *Filter: 64 & 128, Units: 300, Epoch: 250, Learning Rate: 0.1*



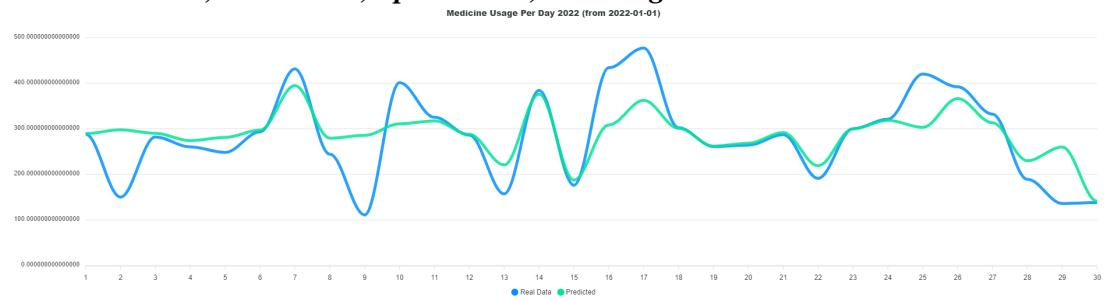
**Gambar 3.36** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 37. *Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.01*



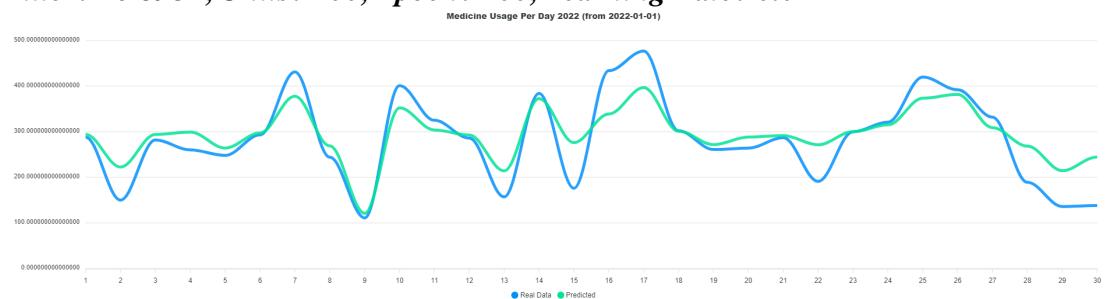
**Gambar 3.37** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 38. *Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.01*



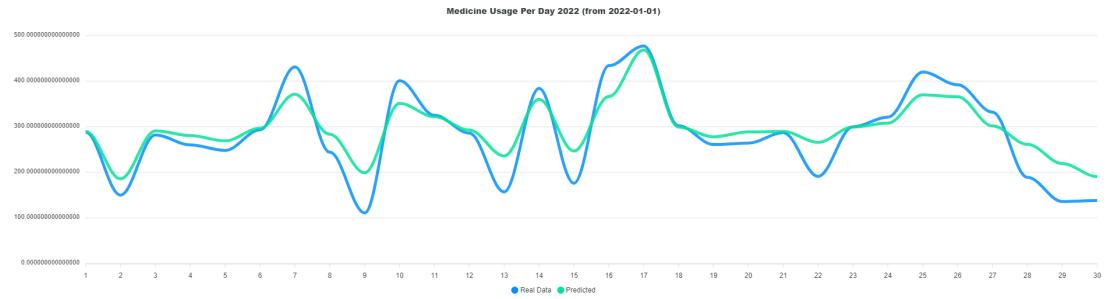
**Gambar 3.38** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 39. *Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.01*



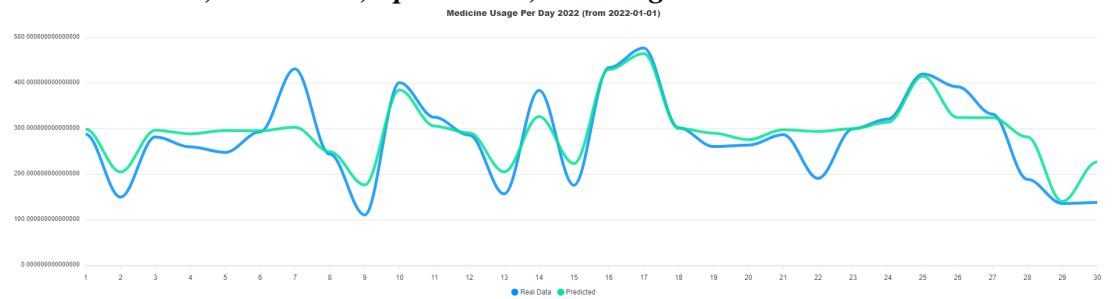
**Gambar 3.39** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 40. *Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.01*



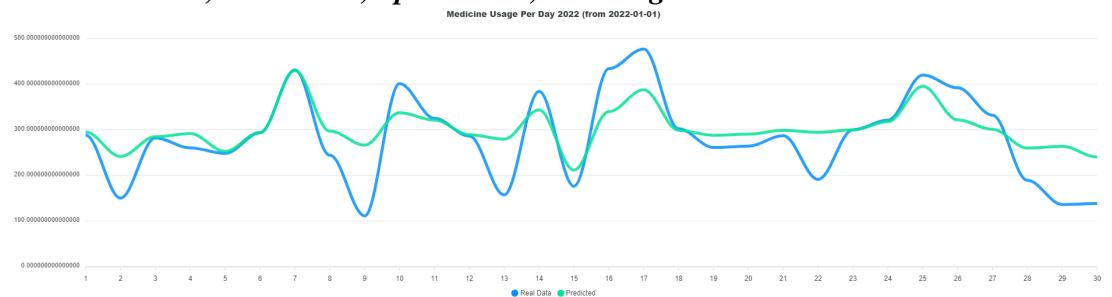
**Gambar 3.40** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 41. *Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.01*



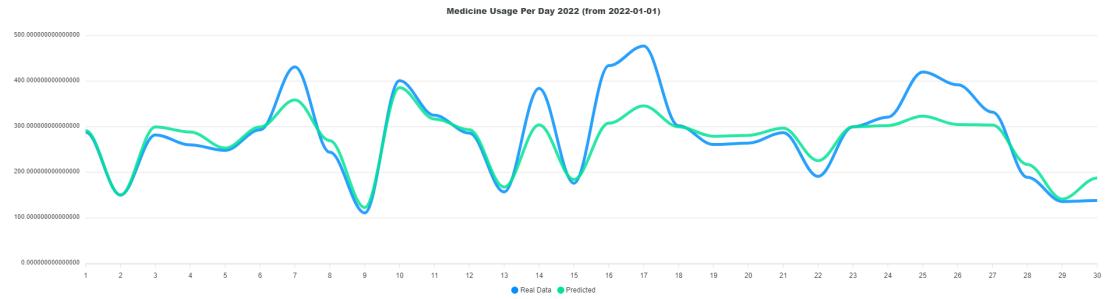
**Gambar 3.41** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 42. *Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.01*



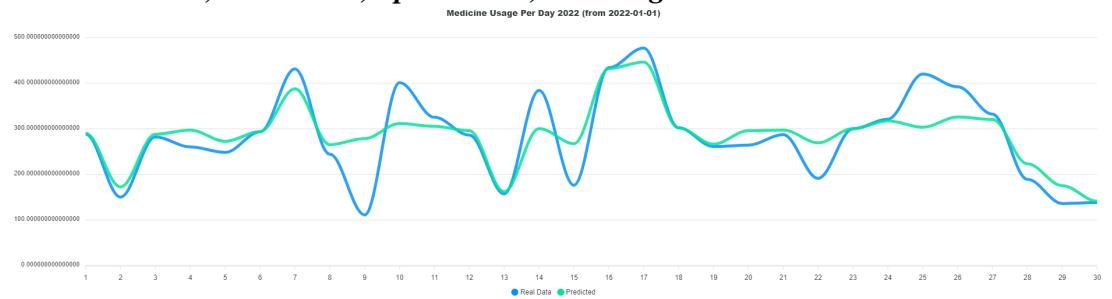
**Gambar 3.42** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 43. *Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.01*



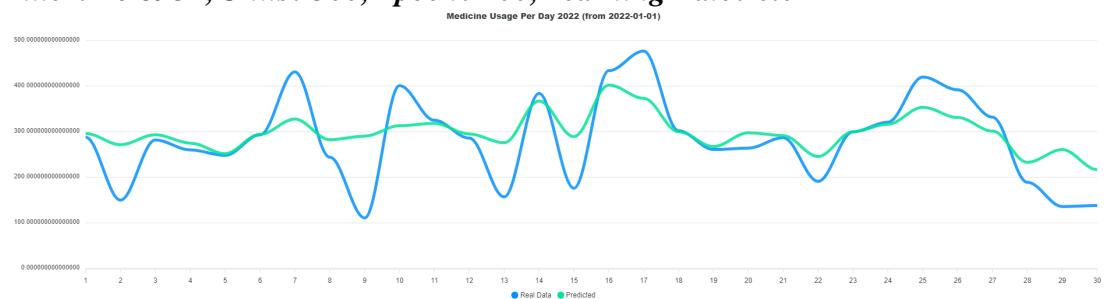
**Gambar 3.43** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 44. *Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.01*



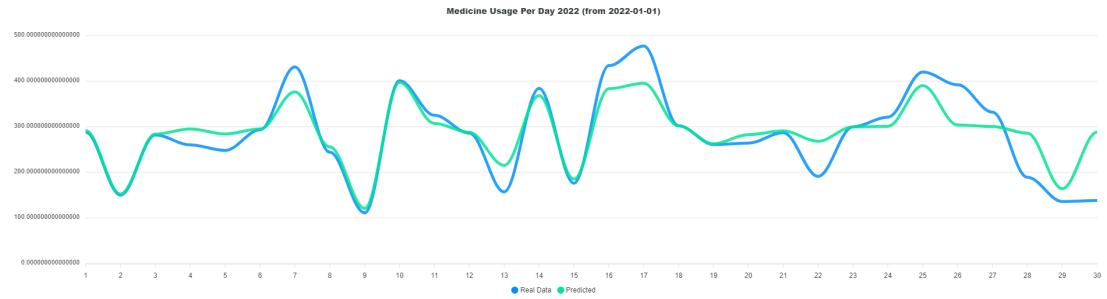
**Gambar 3.44** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 45. *Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.01*



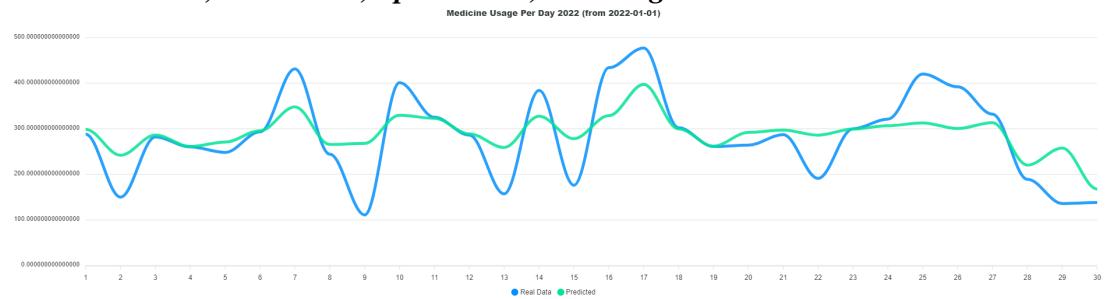
**Gambar 3.45** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 46. *Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.01*



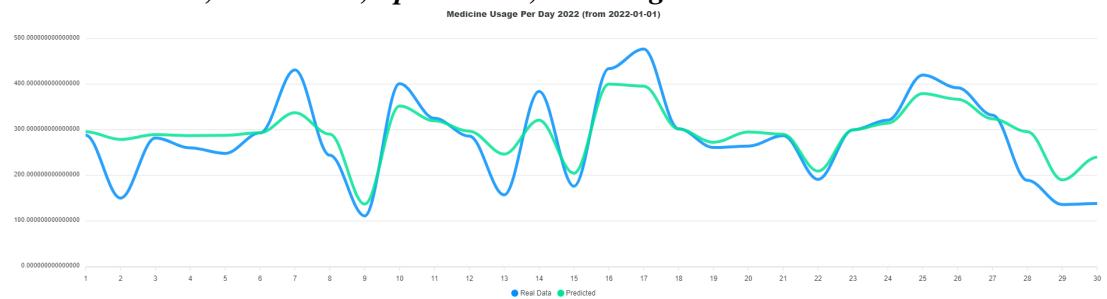
**Gambar 3.46** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 47. *Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.01*



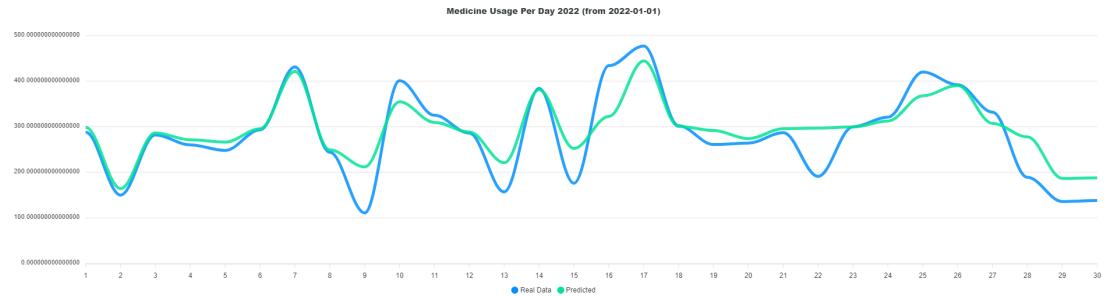
**Gambar 3.47** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 48. *Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.01*



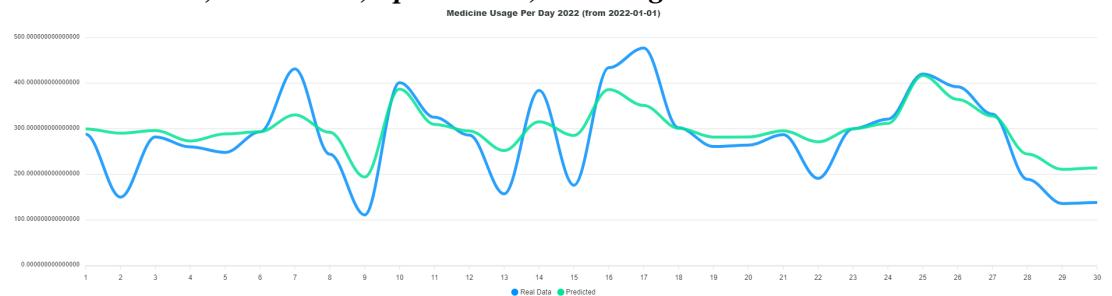
**Gambar 3.48** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 49. *Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.01*



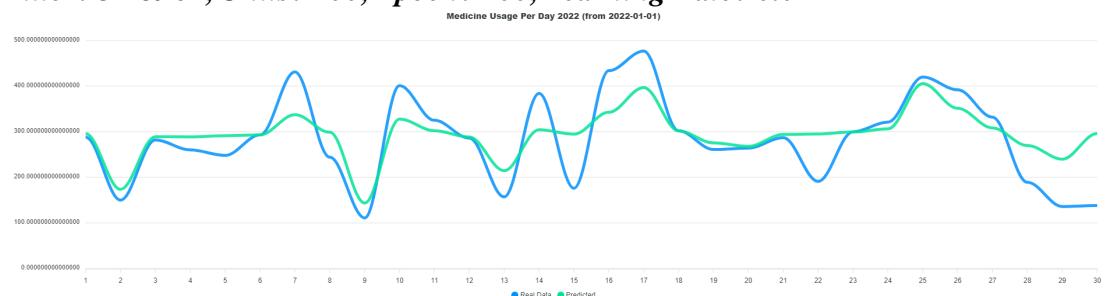
**Gambar 3.49** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 50. *Filter: 32 & 64, Units: 100, Epoch: 150, Learning Rate: 0.01*



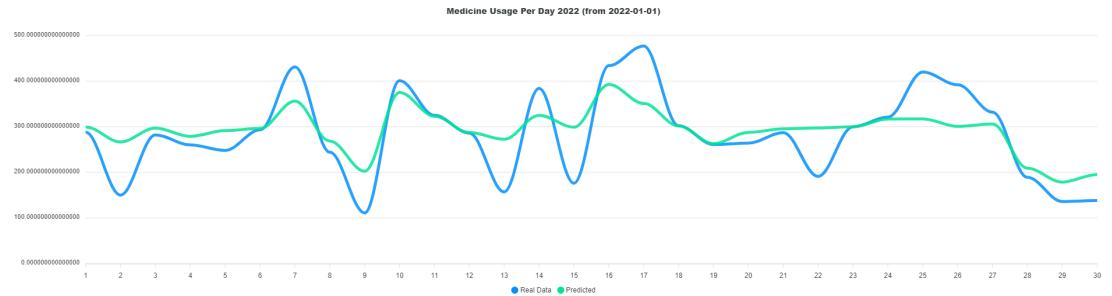
**Gambar 3.50** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 51. *Filter: 32 & 64, Units: 100, Epoch: 200, Learning Rate: 0.01*



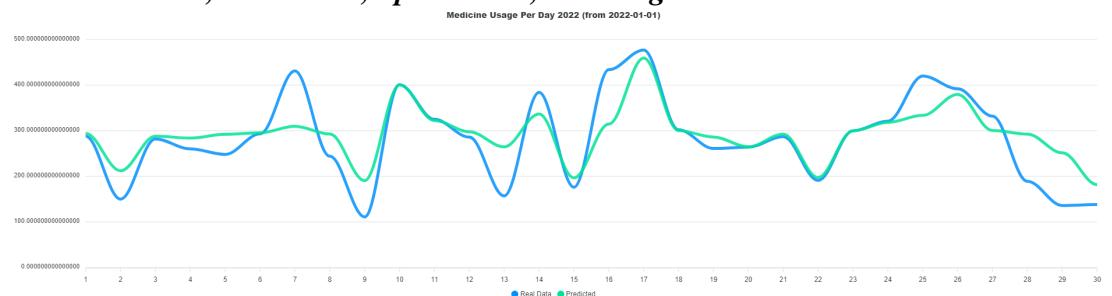
**Gambar 3.51** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 52. *Filter: 32 & 64, Units: 100, Epoch: 250, Learning Rate: 0.01*



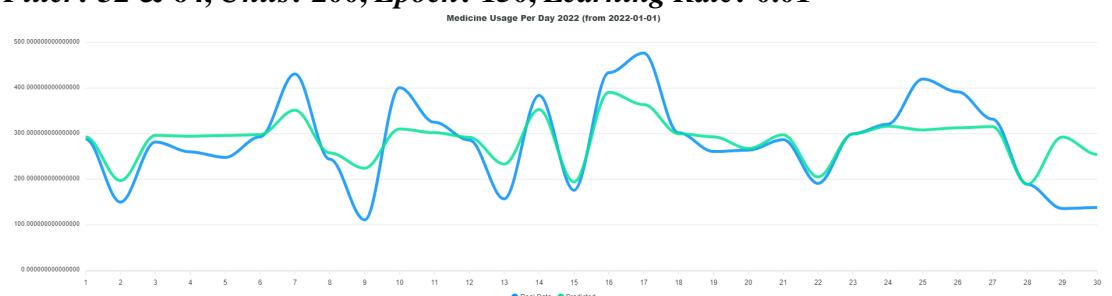
**Gambar 3.52** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 53. *Filter: 32 & 64, Units: 200, Epoch: 100, Learning Rate: 0.01*



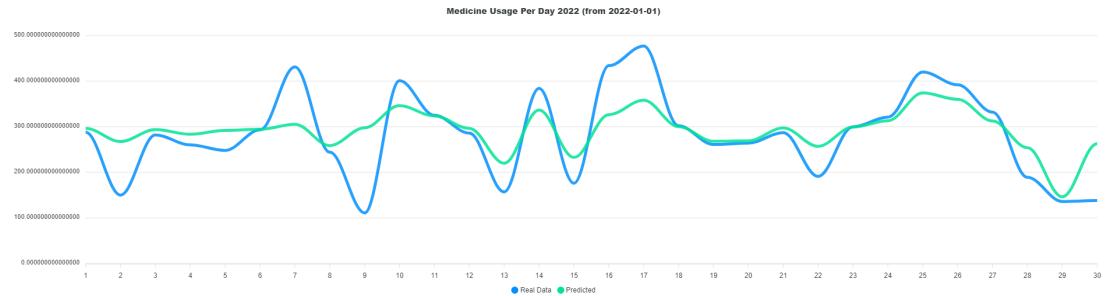
**Gambar 3.53** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 54. *Filter: 32 & 64, Units: 200, Epoch: 150, Learning Rate: 0.01*



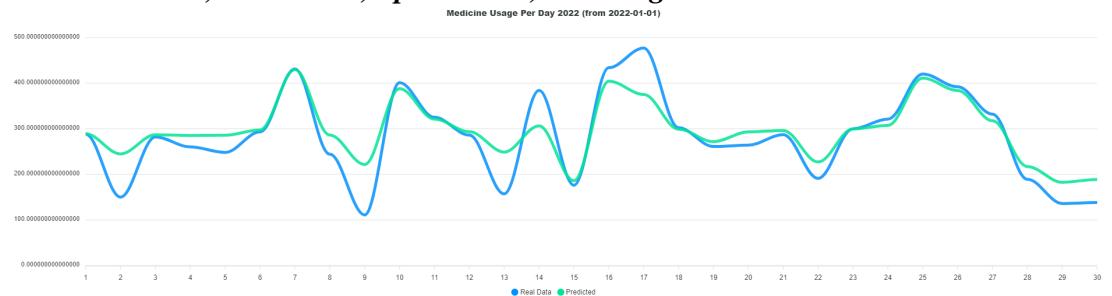
**Gambar 3.54** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 55. *Filter: 32 & 64, Units: 200, Epoch: 200, Learning Rate: 0.01*



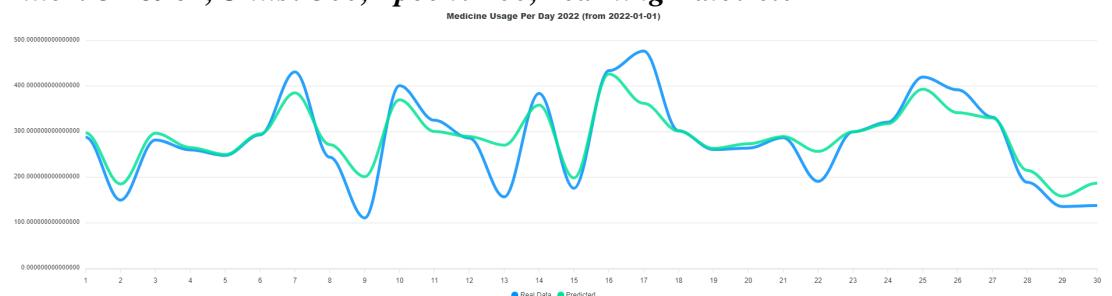
**Gambar 3.55** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 56. *Filter: 32 & 64, Units: 200, Epoch: 250, Learning Rate: 0.01*



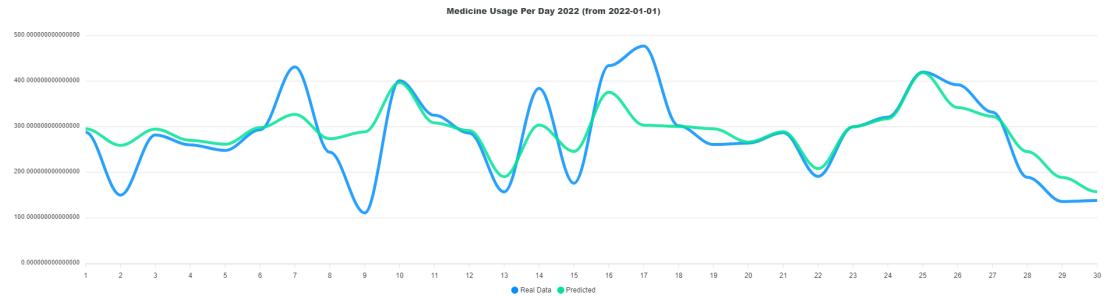
**Gambar 3.56** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 57. *Filter: 32 & 64, Units: 300, Epoch: 100, Learning Rate: 0.01*



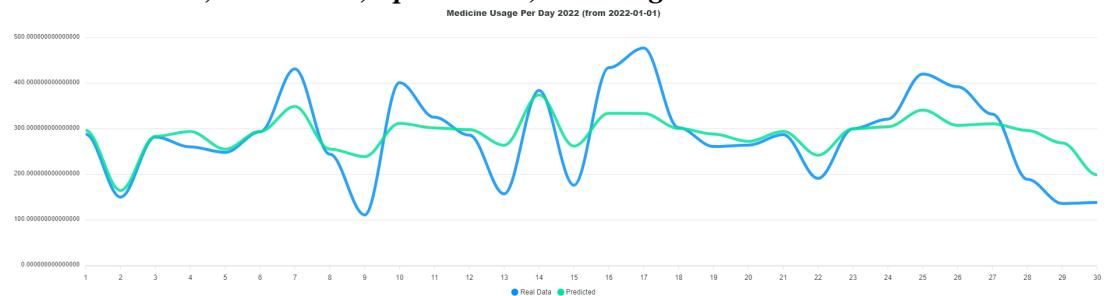
**Gambar 3.57** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 58. *Filter: 32 & 64, Units: 300, Epoch: 150, Learning Rate: 0.01*



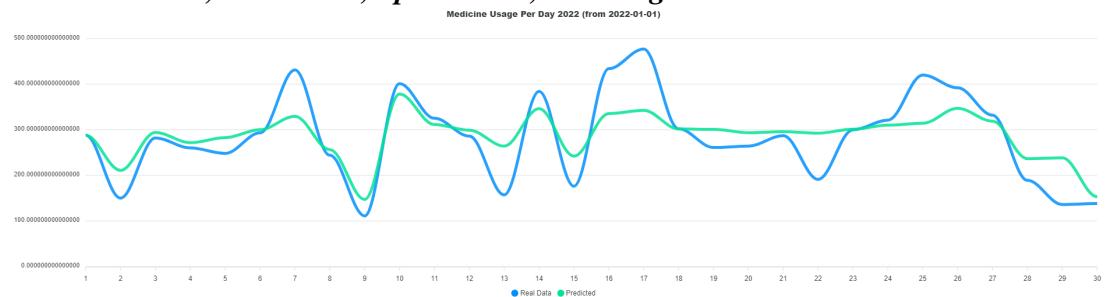
**Gambar 3.58** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 59. *Filter: 32 & 64, Units: 300, Epoch: 200, Learning Rate: 0.01*



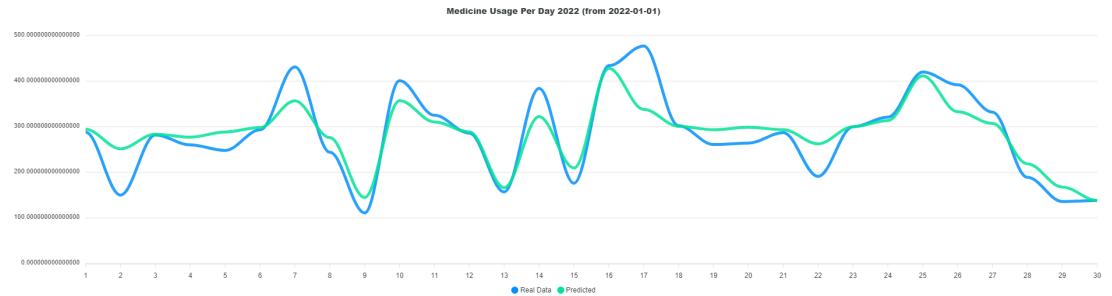
**Gambar 3.59** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 60. *Filter: 32 & 64, Units: 300, Epoch: 250, Learning Rate: 0.01*



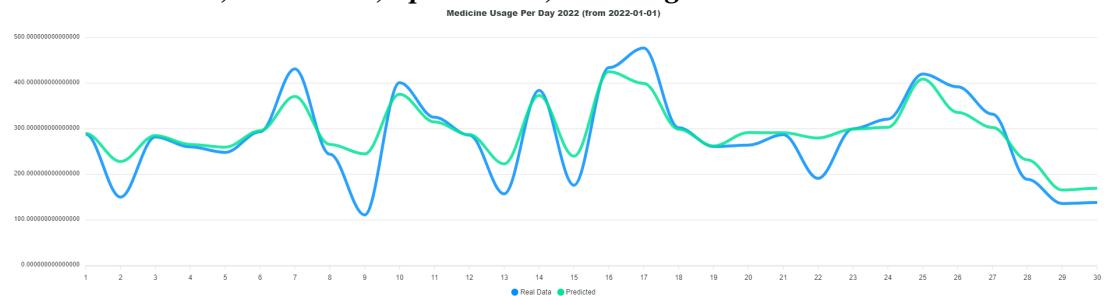
**Gambar 3.60** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 61. *Filter: 64 & 128, Units: 100, Epoch: 100, Learning Rate: 0.01*



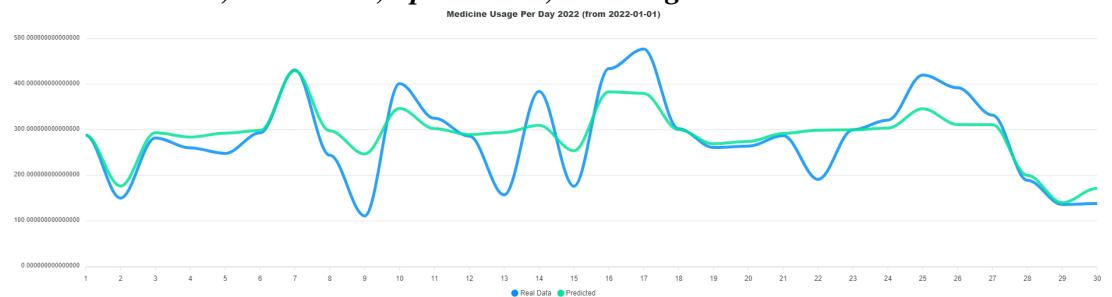
**Gambar 3.61** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 62. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01



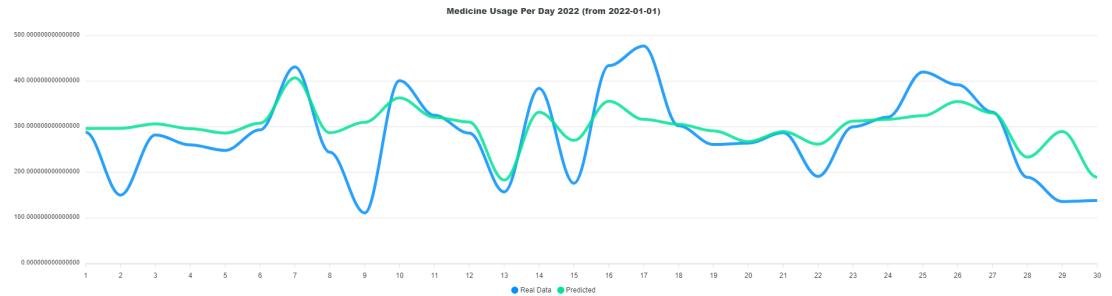
**Gambar 3.62** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 63. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01



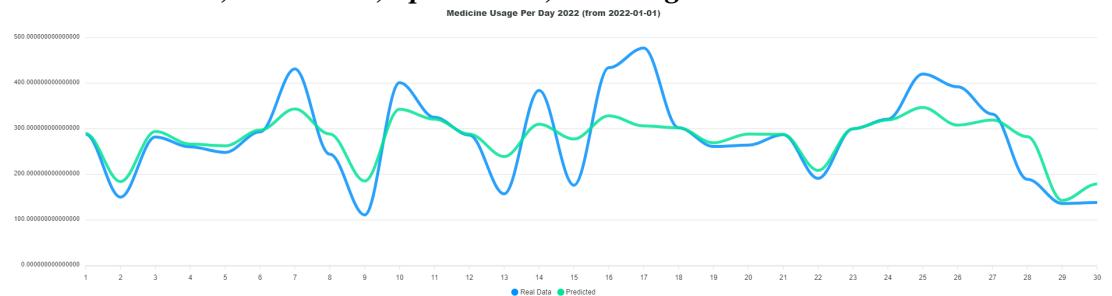
**Gambar 3.63** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 64. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01



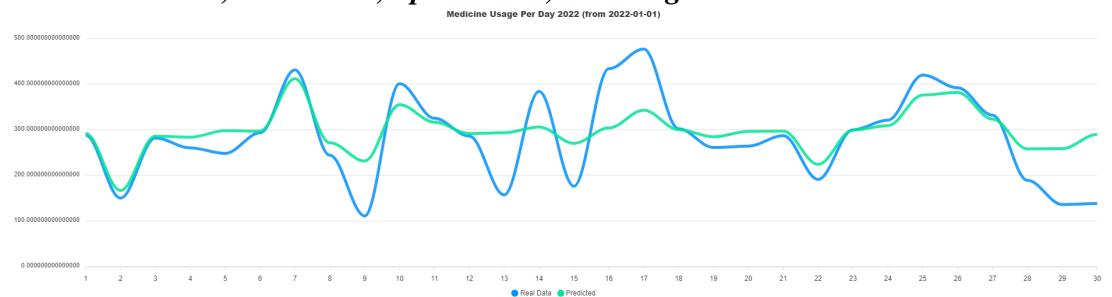
**Gambar 3.64** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 65. *Filter: 64 & 128, Units: 200, Epoch: 100, Learning Rate: 0.01*



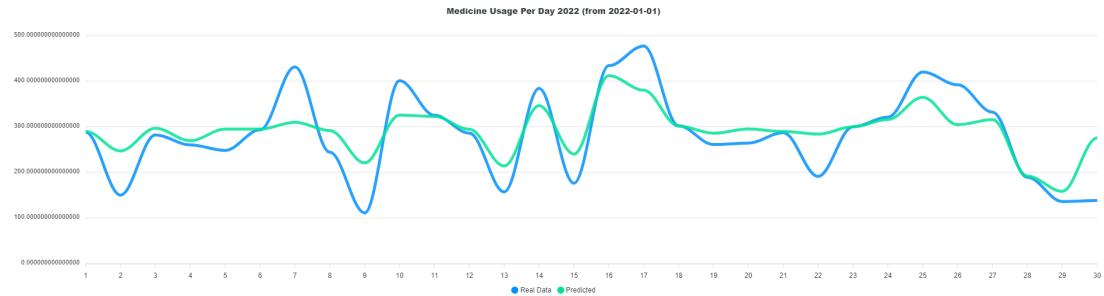
**Gambar 3.65** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 66. *Filter: 64 & 128, Units: 200, Epoch: 150, Learning Rate: 0.01*



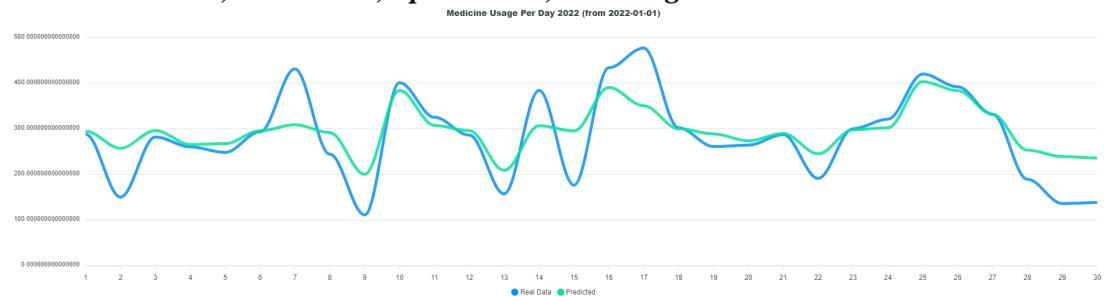
**Gambar 3.66** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 67. *Filter: 64 & 128, Units: 200, Epoch: 200, Learning Rate: 0.01*



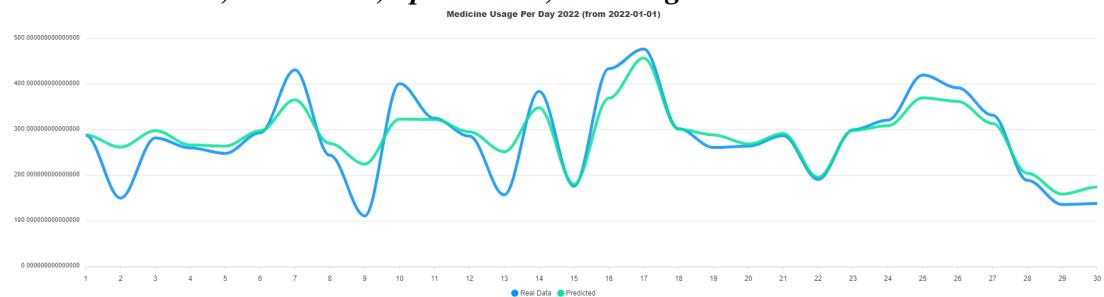
**Gambar 3.67** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 68. *Filter: 64 & 128, Units: 200, Epoch: 250, Learning Rate: 0.01*



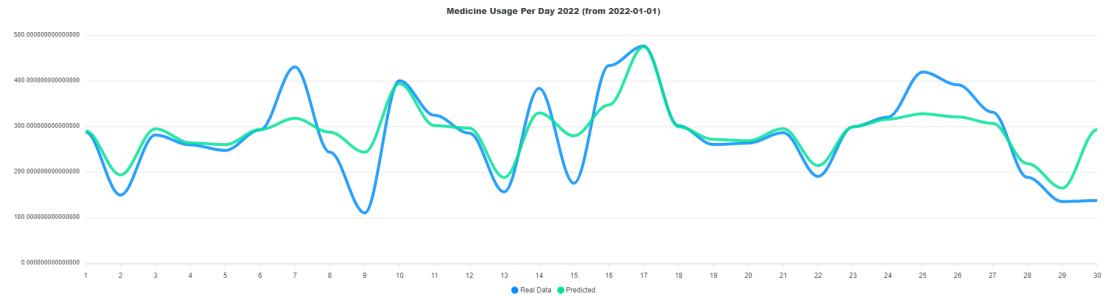
**Gambar 3.68** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 69. *Filter: 64 & 128, Units: 300, Epoch: 100, Learning Rate: 0.01*



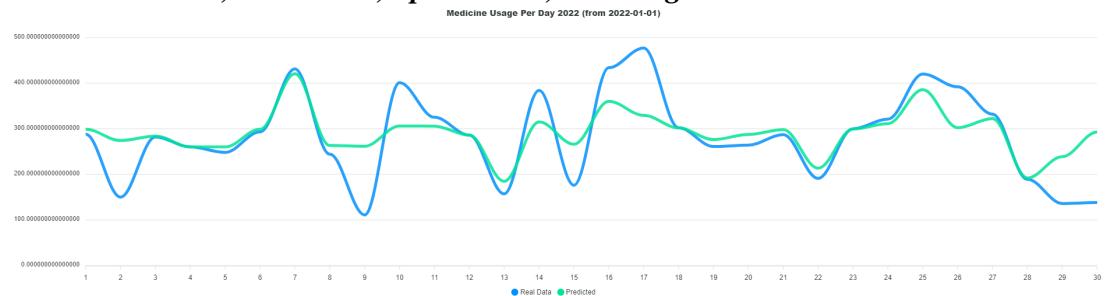
**Gambar 3.69** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 70. *Filter: 64 & 128, Units: 300, Epoch: 150, Learning Rate: 0.01*



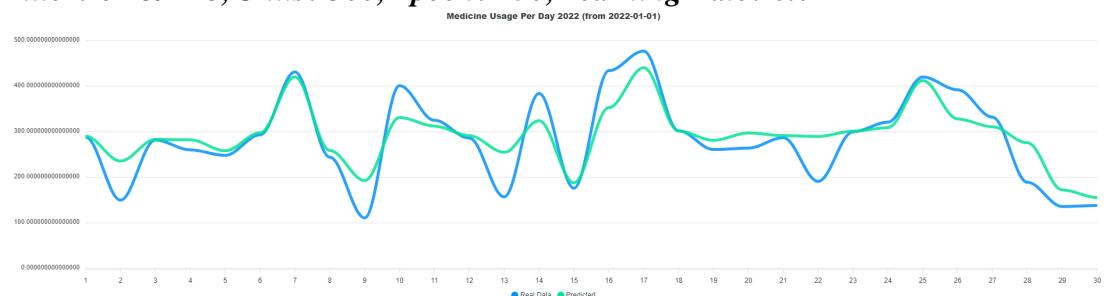
**Gambar 3.70** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 71. *Filter: 64 & 128, Units: 300, Epoch: 200, Learning Rate: 0.01*



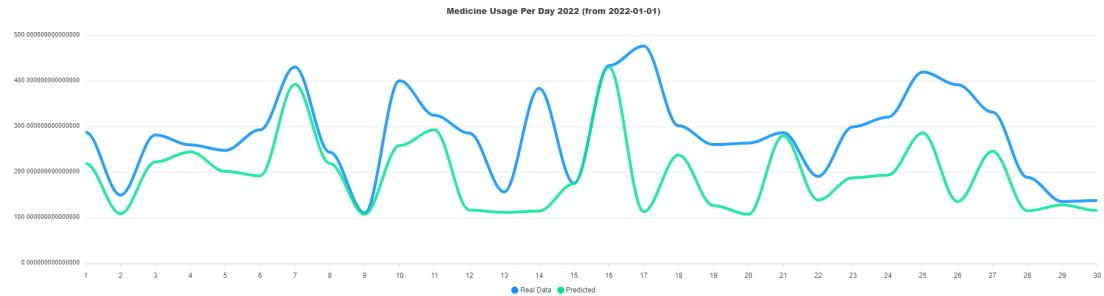
**Gambar 3.71** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 72. *Filter: 64 & 128, Units: 300, Epoch: 250, Learning Rate: 0.01*



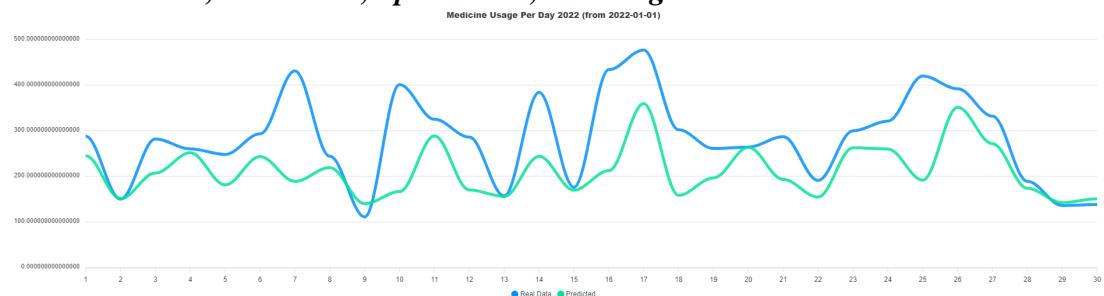
**Gambar 3.72** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 73. *Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.001*



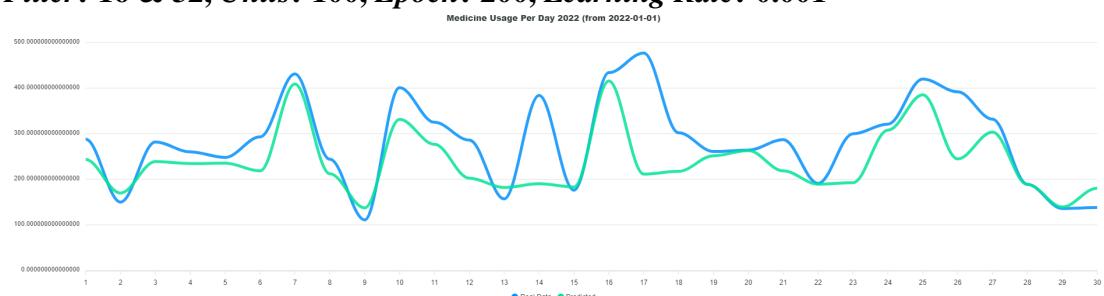
**Gambar 3.73** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 74. *Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.001*



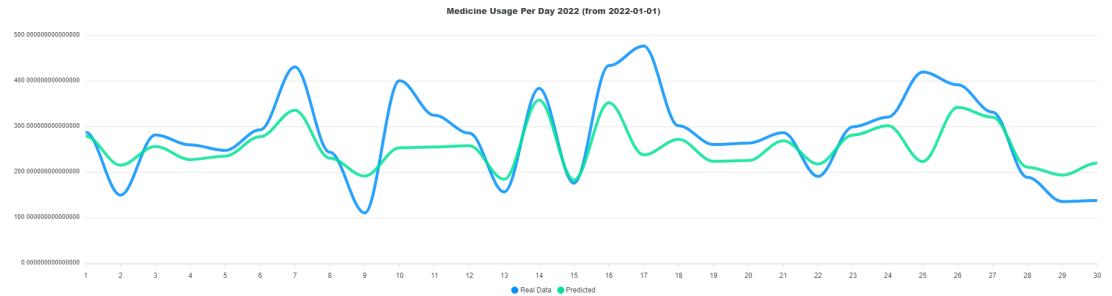
**Gambar 3.74** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 75. *Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.001*



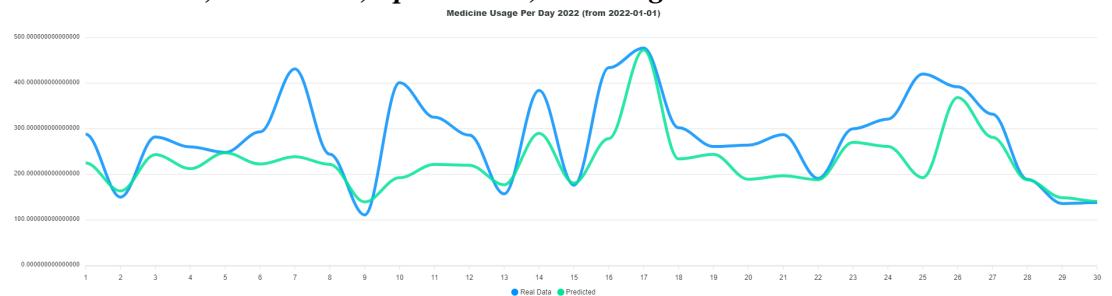
**Gambar 3.75** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 76. *Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.001*



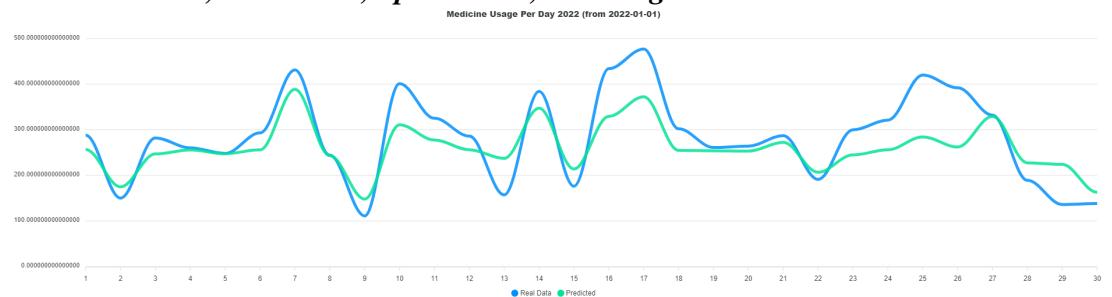
**Gambar 3.76** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 77. *Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.001*



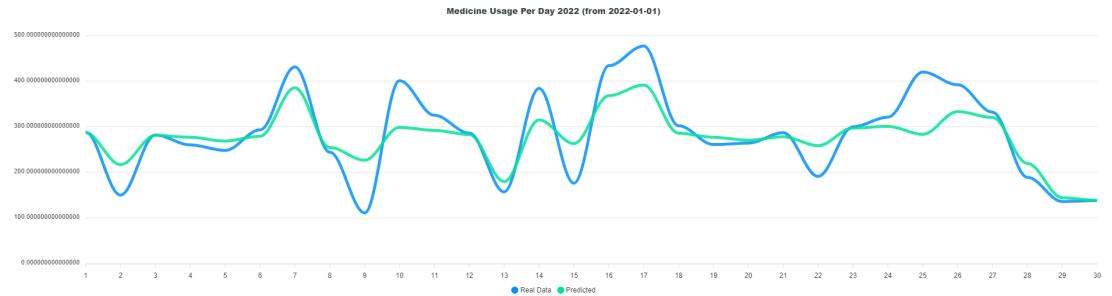
**Gambar 3.77** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 78. *Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.001*



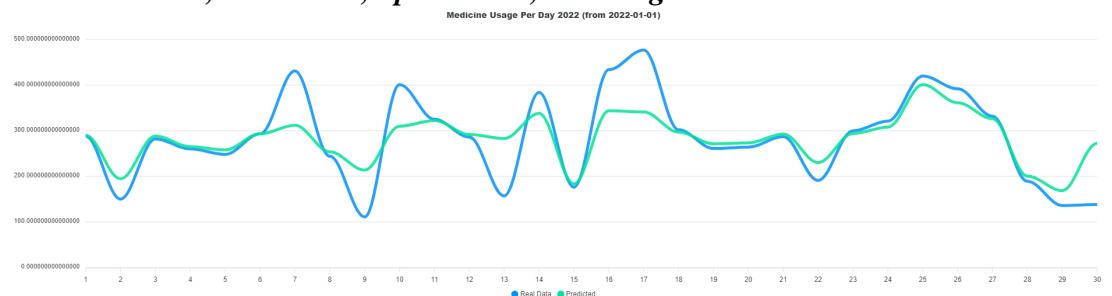
**Gambar 3.78** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 79. *Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.001*



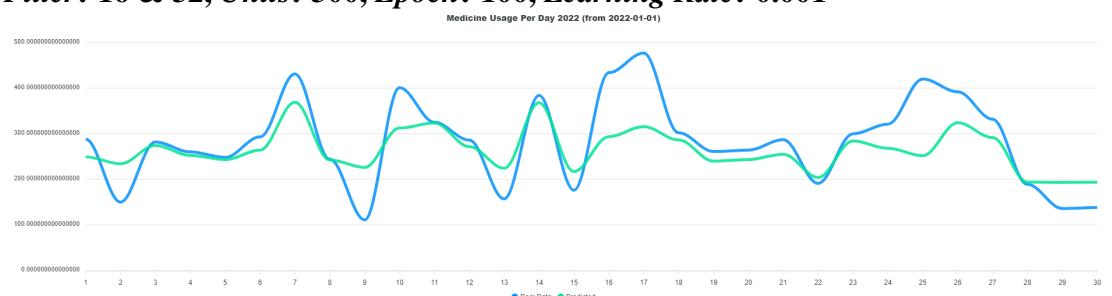
**Gambar 3.79** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 80. *Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.001*



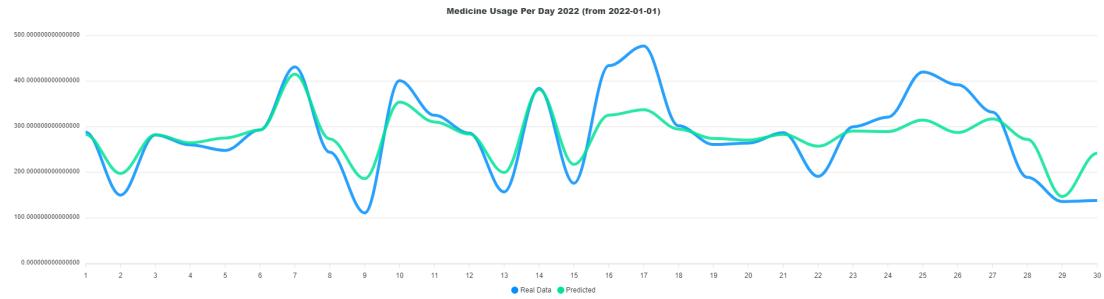
**Gambar 3.80** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 81. *Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.001*



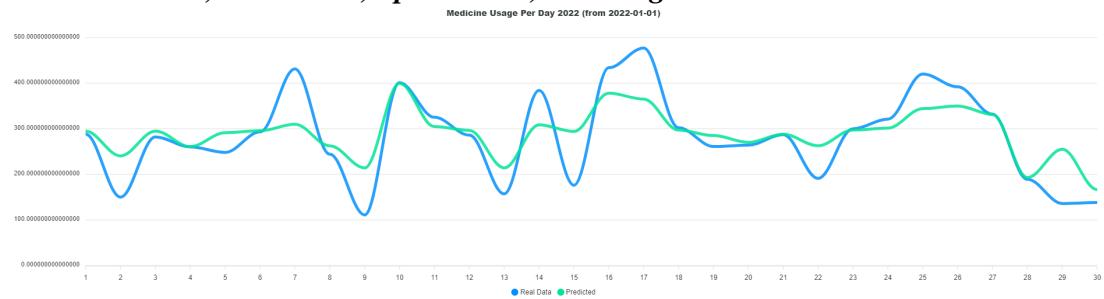
**Gambar 3.81** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 82. *Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.001*



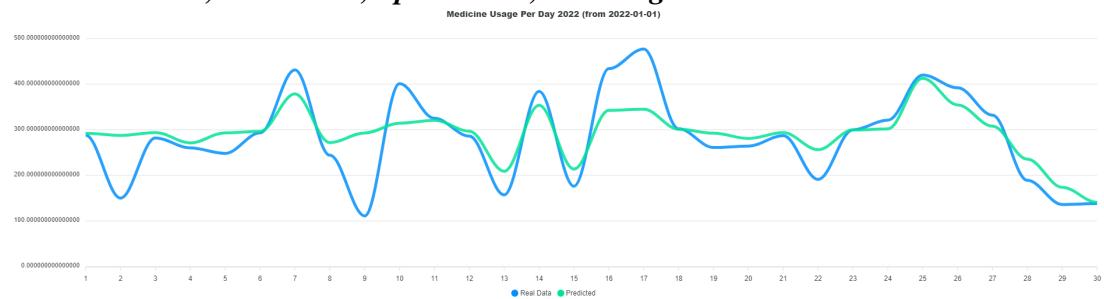
**Gambar 3.82** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 83. *Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.001*



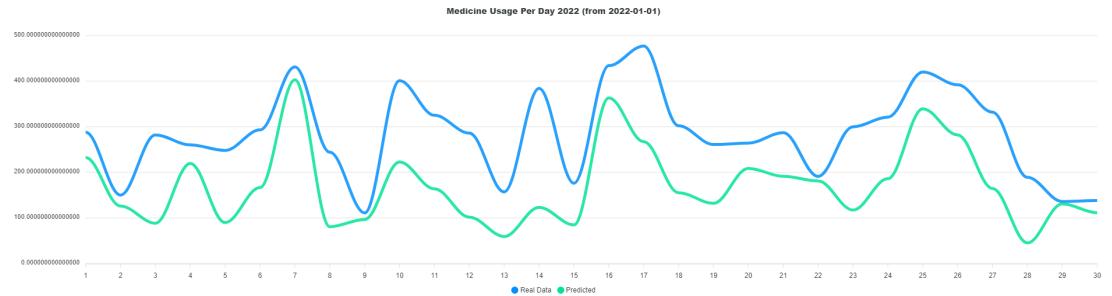
**Gambar 3.83** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 84. *Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.001*



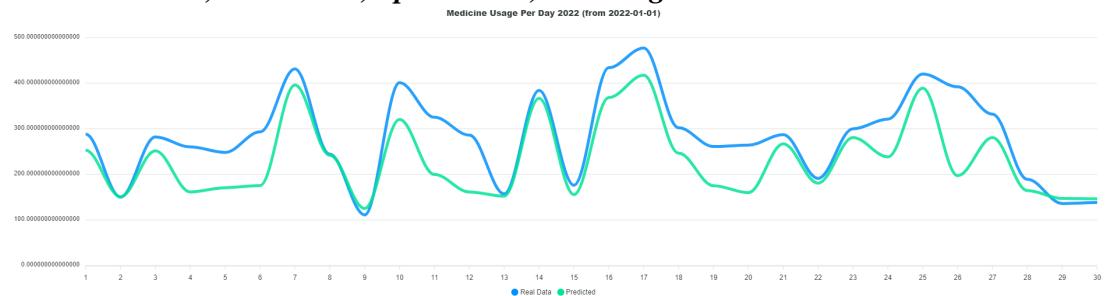
**Gambar 3.84** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 85. *Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.001*



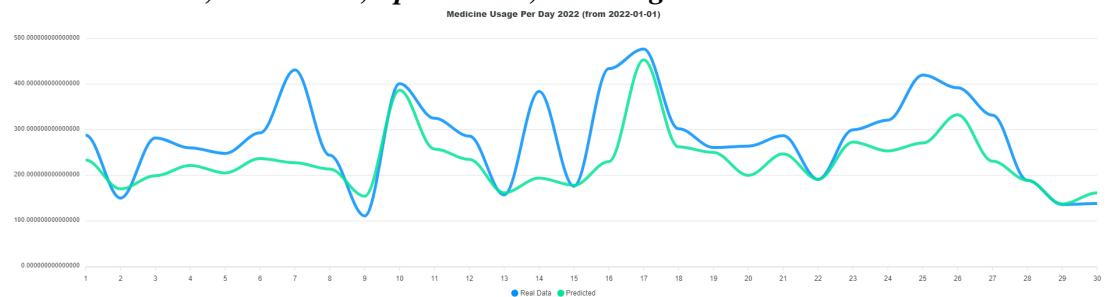
**Gambar 3.85** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 86. *Filter: 32 & 64, Units: 100, Epoch: 150, Learning Rate: 0.001*



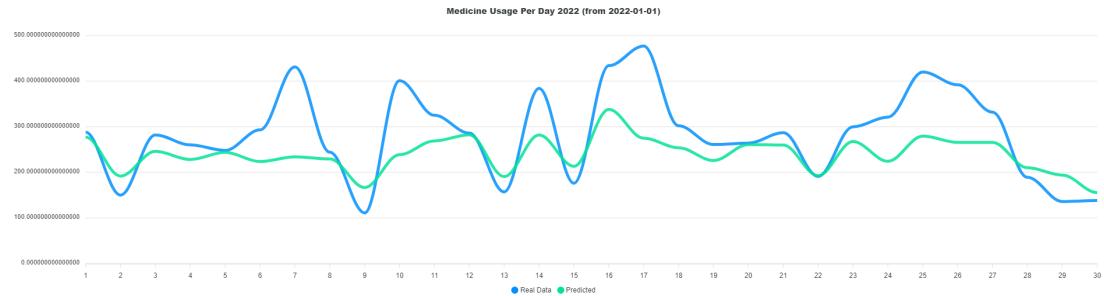
**Gambar 3.86** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 87. *Filter: 32 & 64, Units: 100, Epoch: 200, Learning Rate: 0.001*



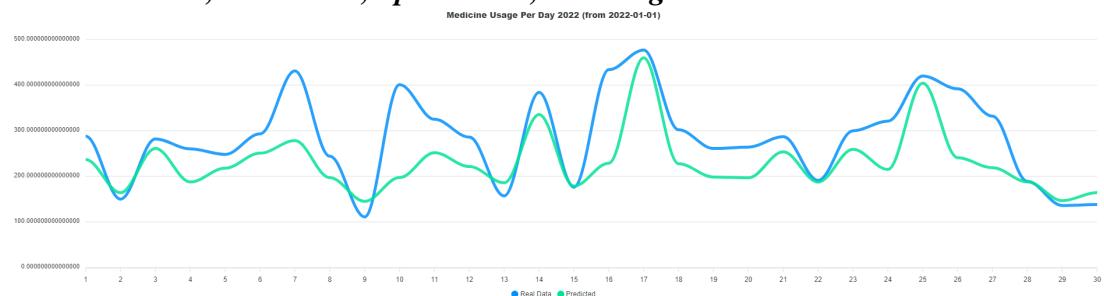
**Gambar 3.87** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 88. *Filter: 32 & 64, Units: 100, Epoch: 250, Learning Rate: 0.001*



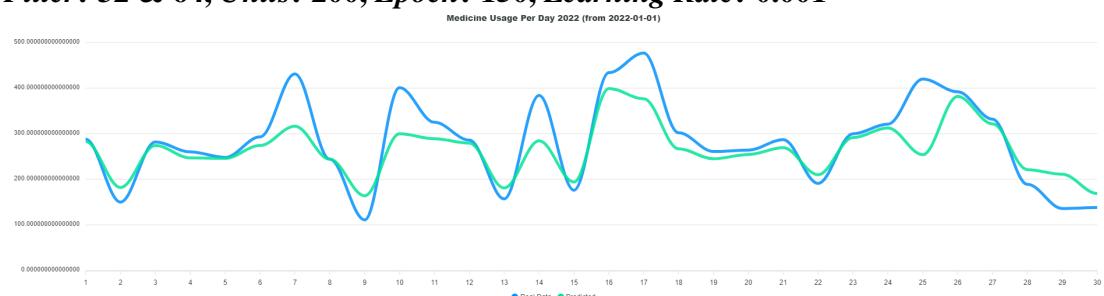
**Gambar 3.88** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 89. *Filter: 32 & 64, Units: 200, Epoch: 100, Learning Rate: 0.001*



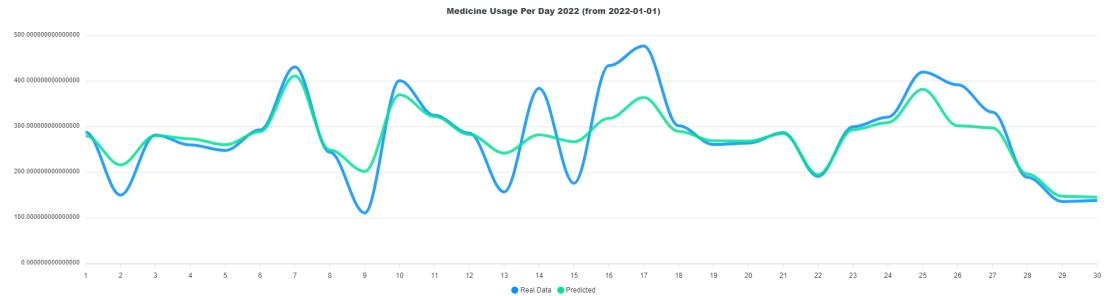
**Gambar 3.89** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 90. *Filter: 32 & 64, Units: 200, Epoch: 150, Learning Rate: 0.001*



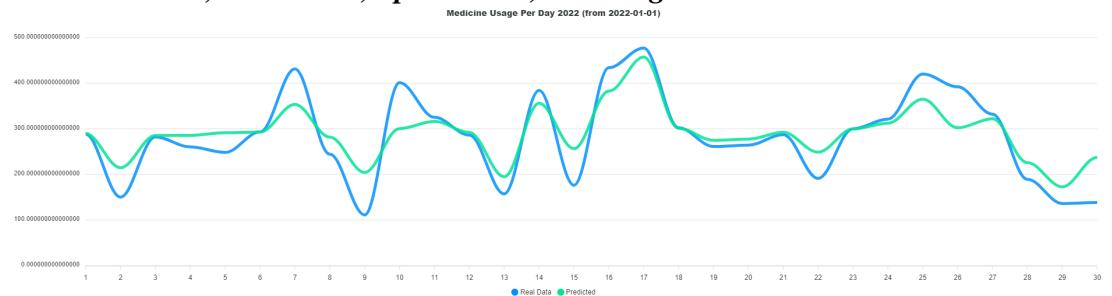
**Gambar 3.90** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 91. *Filter: 32 & 64, Units: 200, Epoch: 200, Learning Rate: 0.001*



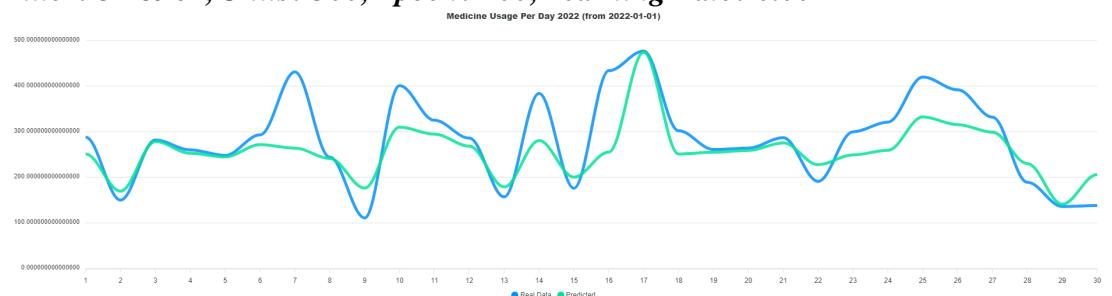
**Gambar 3.91** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 92. *Filter: 32 & 64, Units: 200, Epoch: 250, Learning Rate: 0.001*



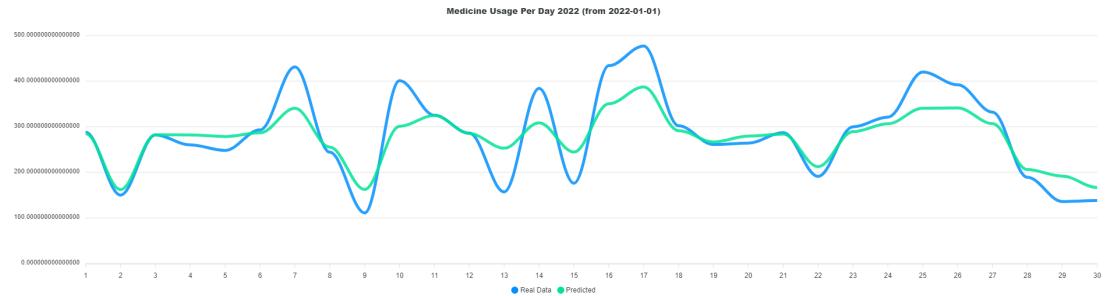
**Gambar 3.92** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 93. *Filter: 32 & 64, Units: 300, Epoch: 100, Learning Rate: 0.001*



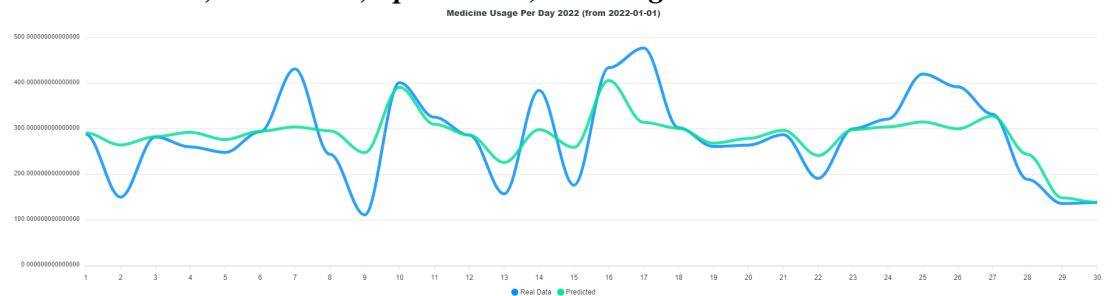
**Gambar 3.93** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 94. *Filter: 32 & 64, Units: 300, Epoch: 150, Learning Rate: 0.001*



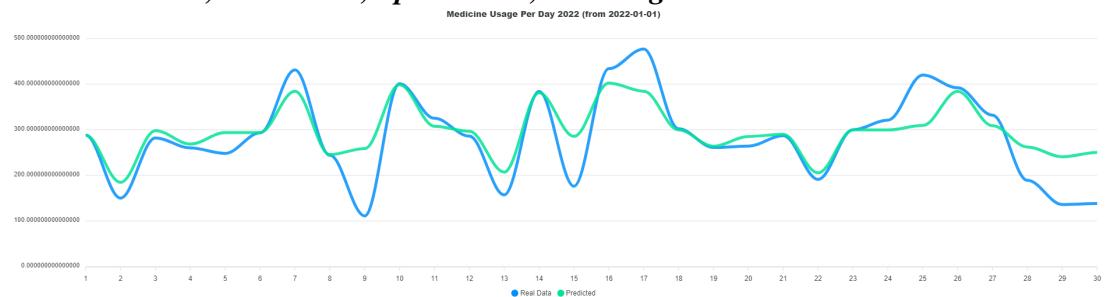
**Gambar 3.94** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 95. *Filter: 32 & 64, Units: 300, Epoch: 200, Learning Rate: 0.001*



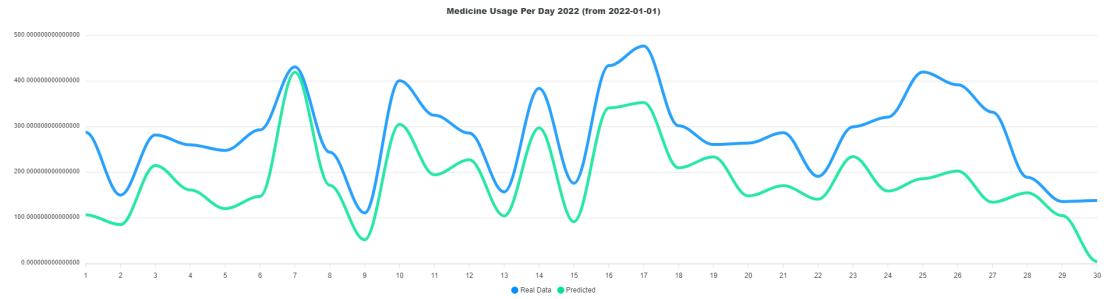
**Gambar 3.95** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 96. *Filter: 32 & 64, Units: 300, Epoch: 250, Learning Rate: 0.001*



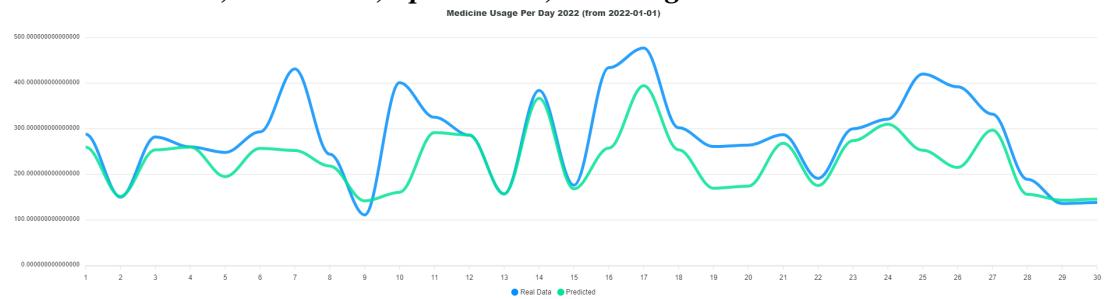
**Gambar 3.96** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 97. *Filter: 64 & 128, Units: 100, Epoch: 100, Learning Rate: 0.001*



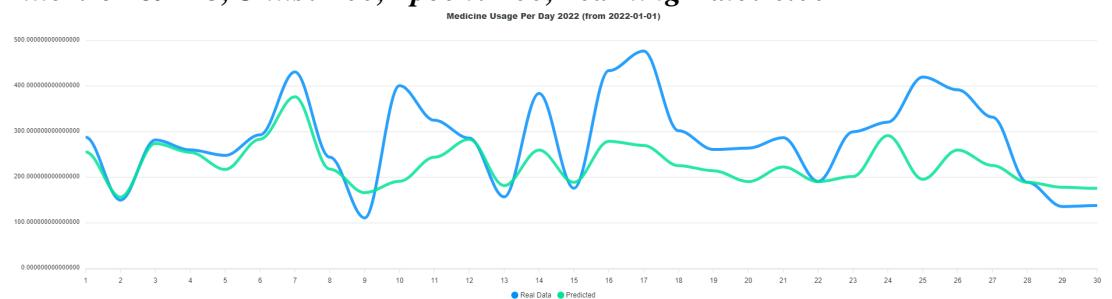
**Gambar 3.97** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

**98. Filter: 64 & 128, Units: 100, Epoch: 150, Learning Rate: 0.001**



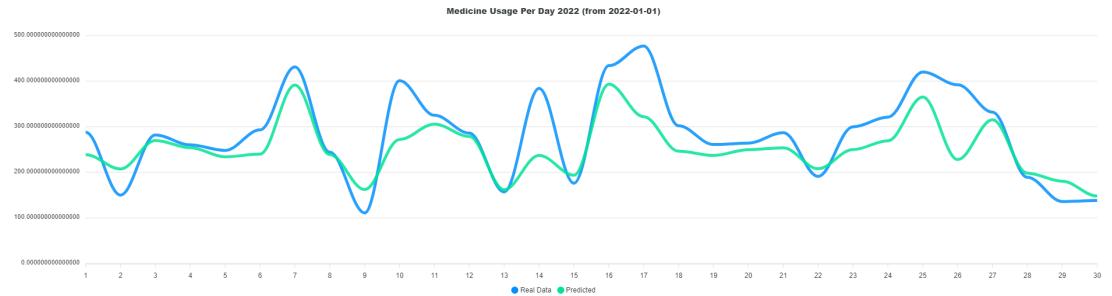
**Gambar 3.98** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

**99. Filter: 64 & 128, Units: 100, Epoch: 200, Learning Rate: 0.001**



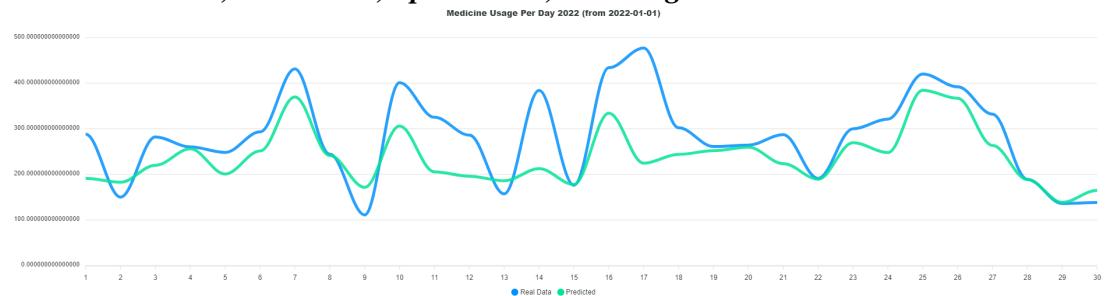
**Gambar 3.99** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

**100. Filter: 64 & 128, Units: 100, Epoch: 250, Learning Rate: 0.001**



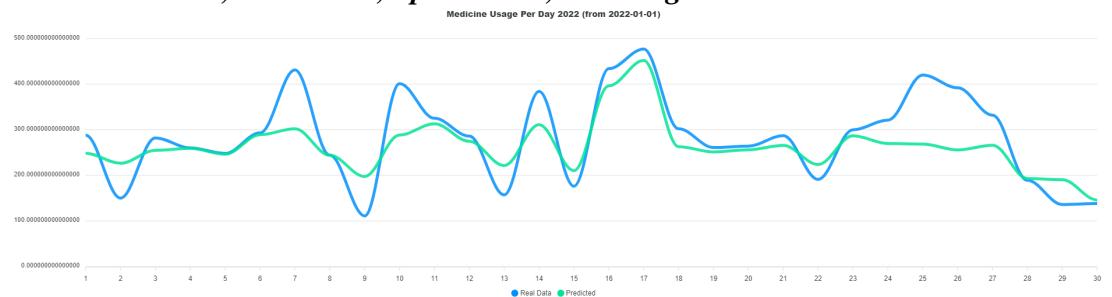
**Gambar 3.100** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 101. *Filter: 64 & 128, Units: 200, Epoch: 100, Learning Rate: 0.001*



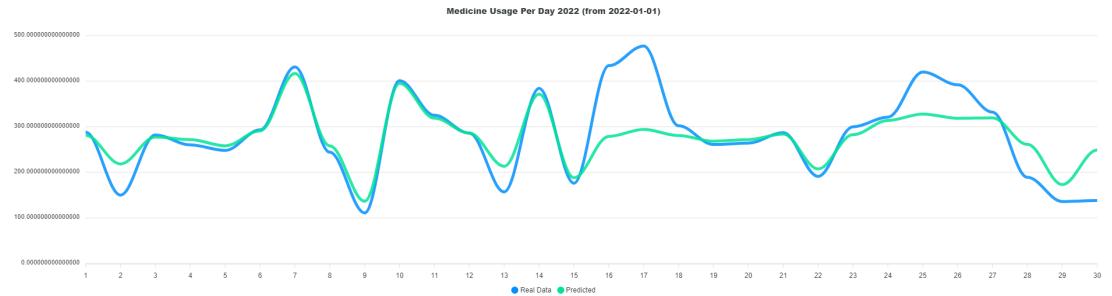
**Gambar 3.101** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 102. *Filter: 64 & 128, Units: 200, Epoch: 150, Learning Rate: 0.001*



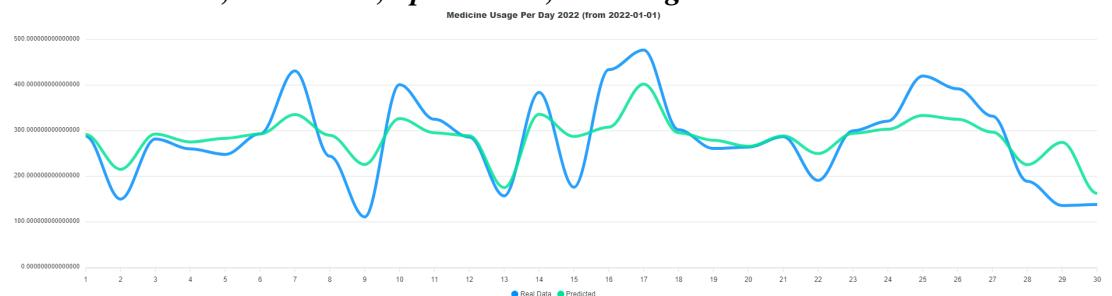
**Gambar 3.102** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 103. *Filter: 64 & 128, Units: 200, Epoch: 200, Learning Rate: 0.001*



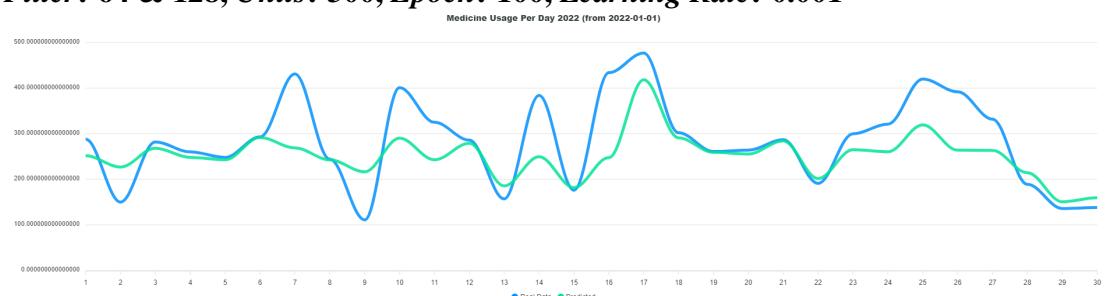
**Gambar 3.103** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 104. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.001



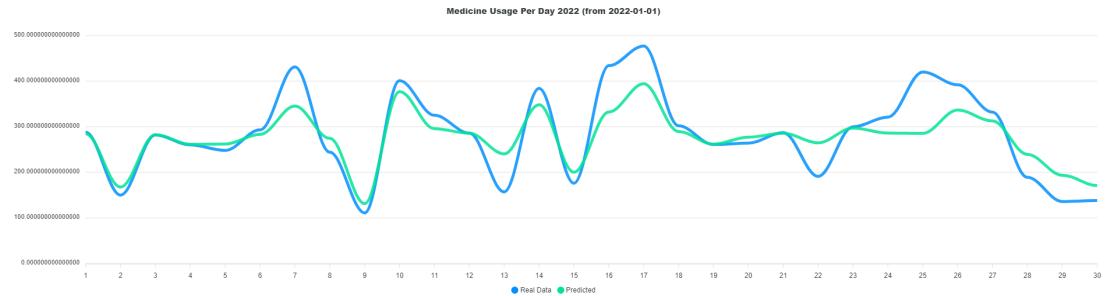
**Gambar 3.104** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 105. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.001



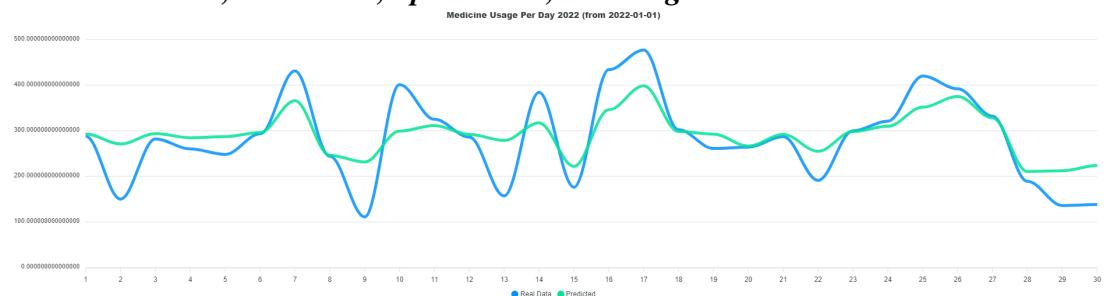
**Gambar 3.105** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 106. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.001



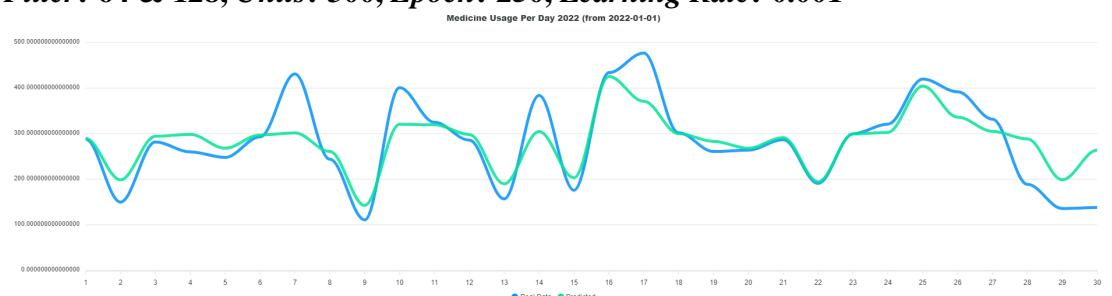
**Gambar 3.106** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

### 107. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.001



**Gambar 3.107** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

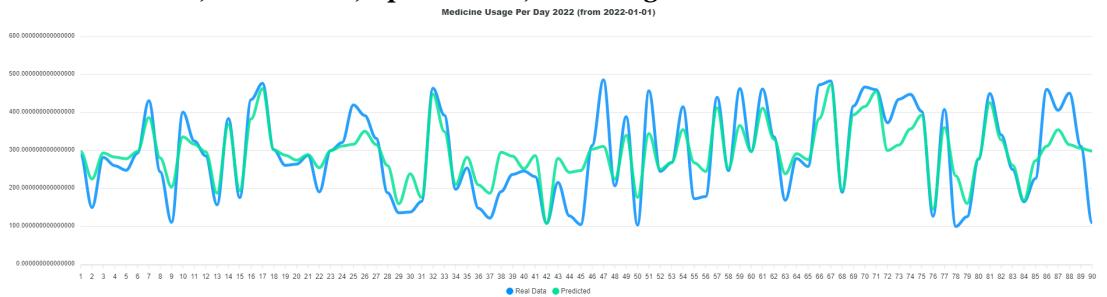
### 108. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.001



**Gambar 3.108** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 30 hari

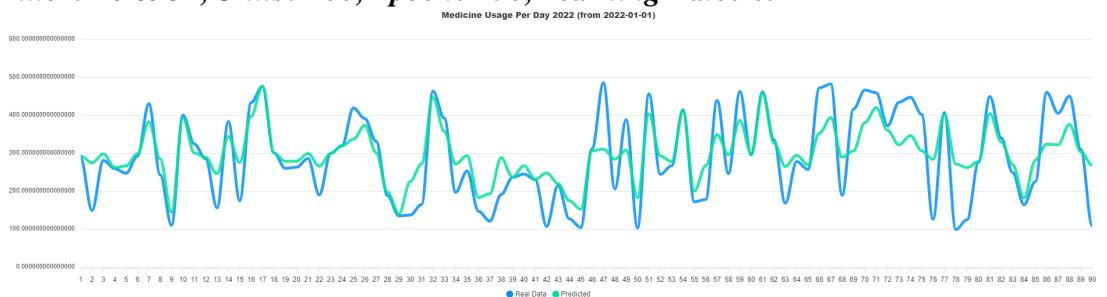
### 3.2 Forecasting Horizon 90 hari

#### 1. Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.1



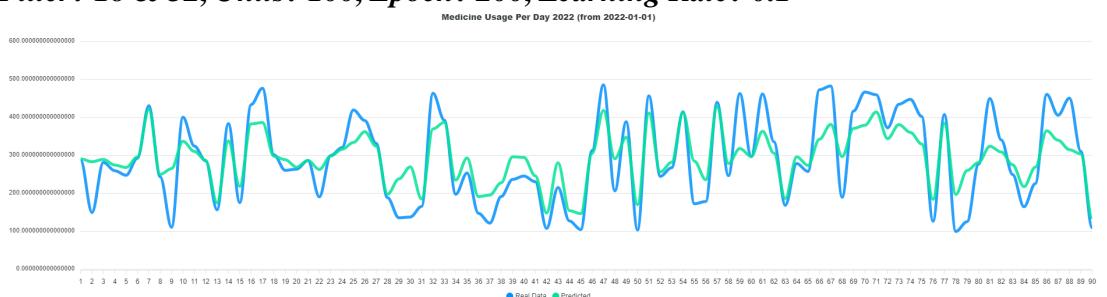
**Gambar 3.109** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

#### 2. Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.1



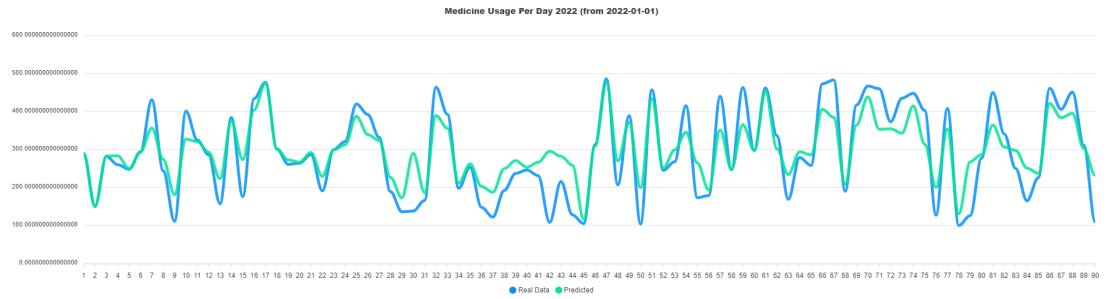
**Gambar 3.110** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

#### 3. Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.1



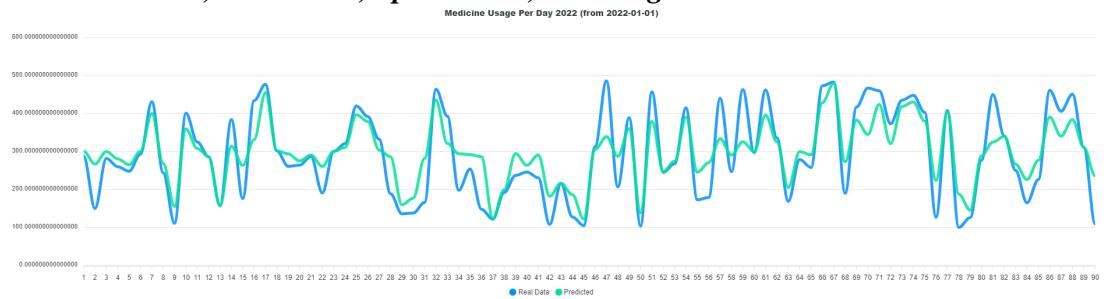
**Gambar 3.111** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

#### 4. Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.1



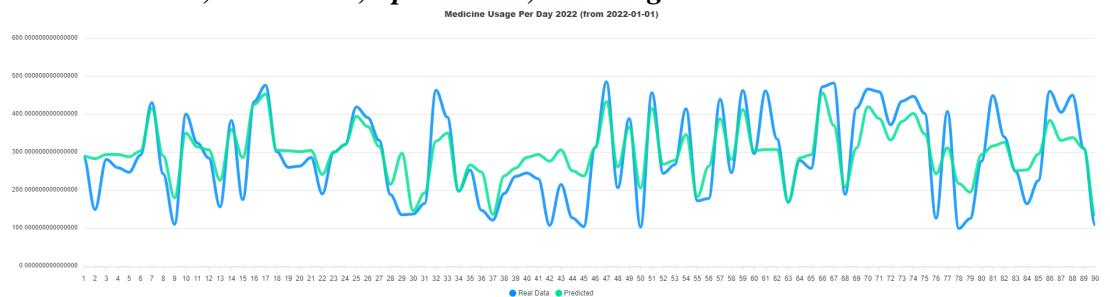
**Gambar 3.112** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 5. *Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.1*



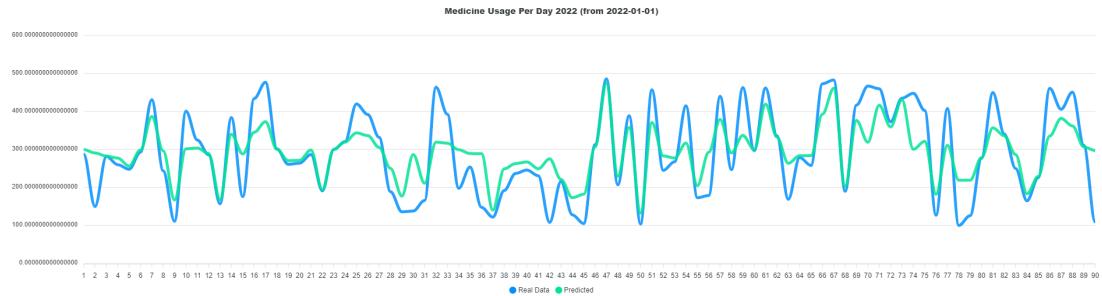
**Gambar 3.113** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 6. *Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.1*



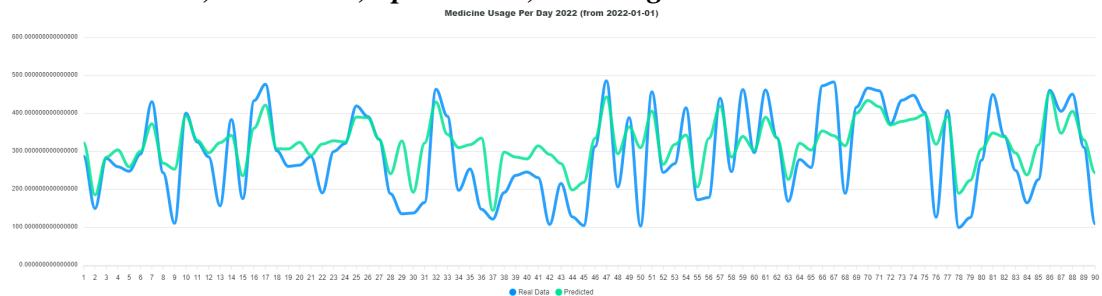
**Gambar 3.114** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 7. *Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.1*



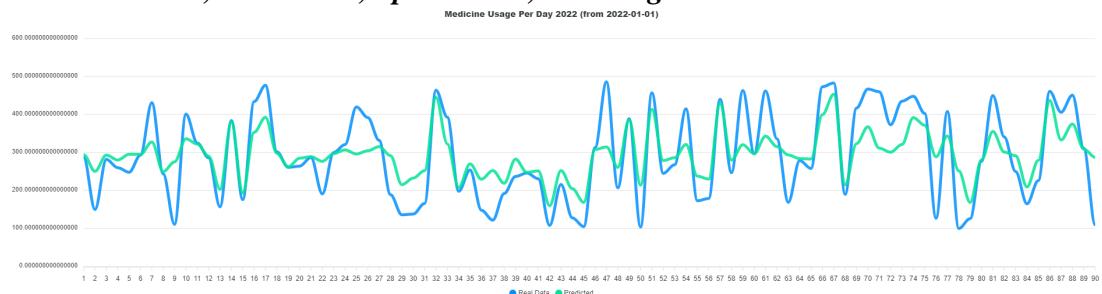
**Gambar 3.115** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 8. *Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.1*



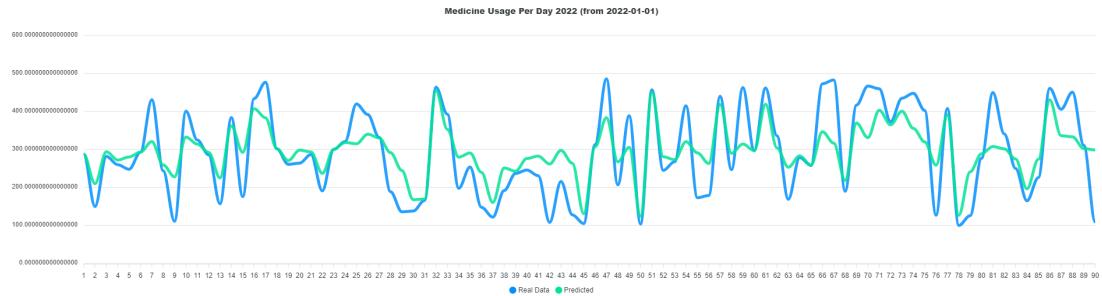
**Gambar 3.116** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 9. *Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.1*



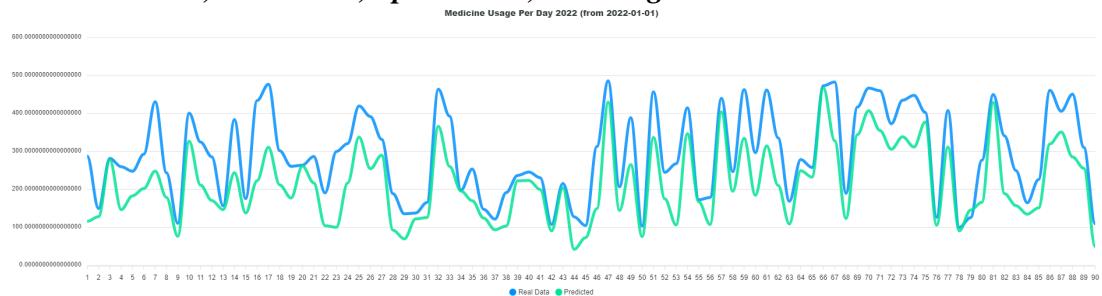
**Gambar 3.117** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 10. *Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.1*



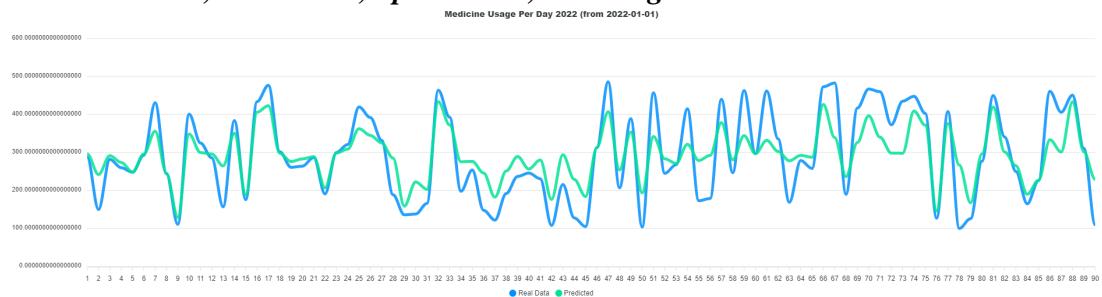
**Gambar 3.118** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 11. *Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.1*



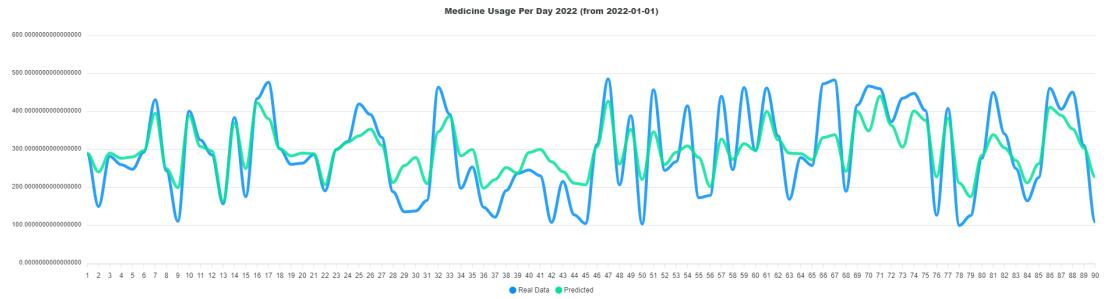
**Gambar 3.119** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 12. *Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.1*



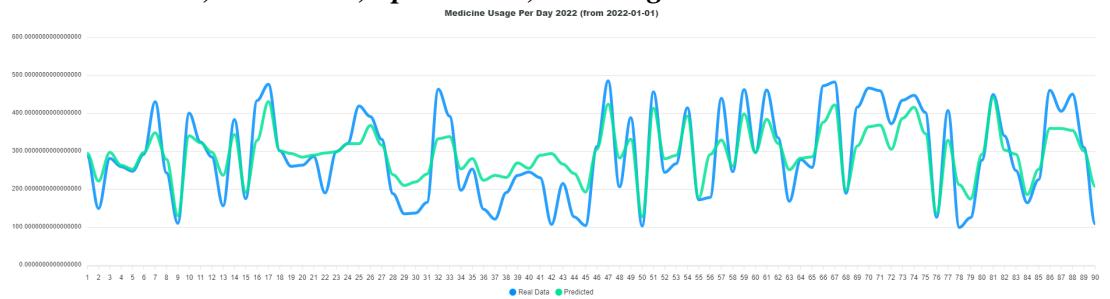
**Gambar 3.120** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 13. *Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.1*



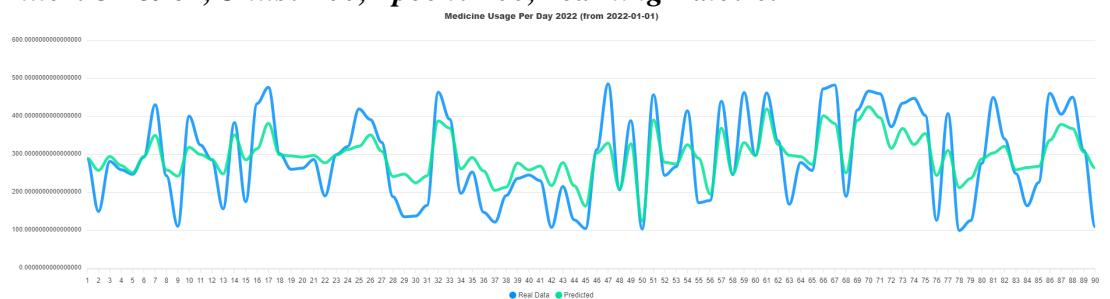
**Gambar 3.121** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 14. *Filter: 32 & 64, Units: 100, Epoch: 150, Learning Rate: 0.1*



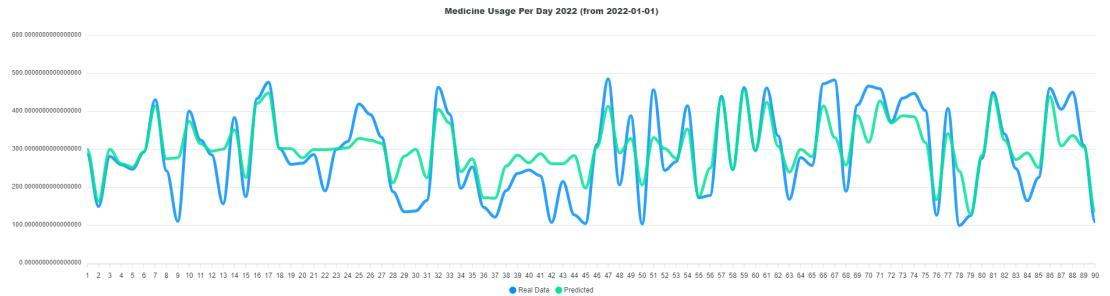
**Gambar 3.122** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 15. *Filter: 32 & 64, Units: 100, Epoch: 200, Learning Rate: 0.1*



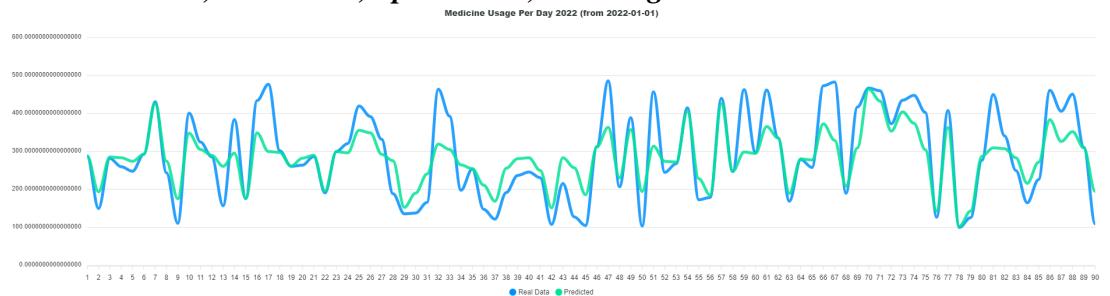
**Gambar 3.123** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 16. *Filter: 32 & 64, Units: 100, Epoch: 250, Learning Rate: 0.1*



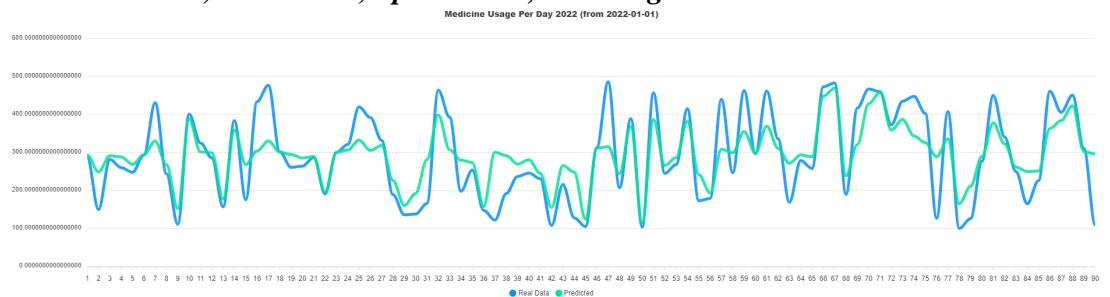
**Gambar 3.124** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 17. *Filter: 32 & 64, Units: 200, Epoch: 100, Learning Rate: 0.1*



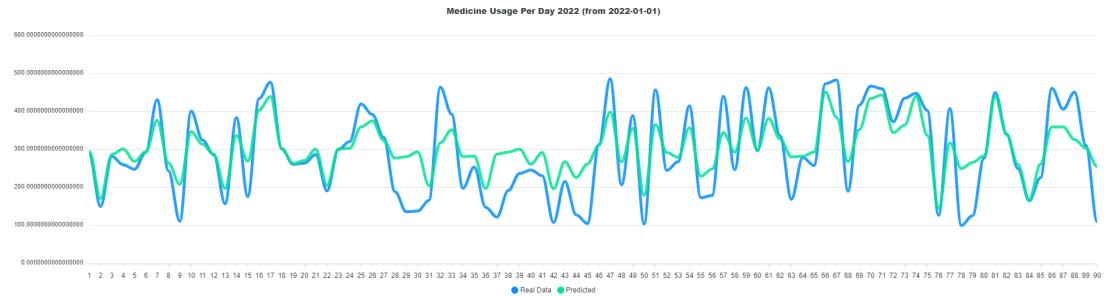
**Gambar 3.125** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 18. *Filter: 32 & 64, Units: 200, Epoch: 150, Learning Rate: 0.1*



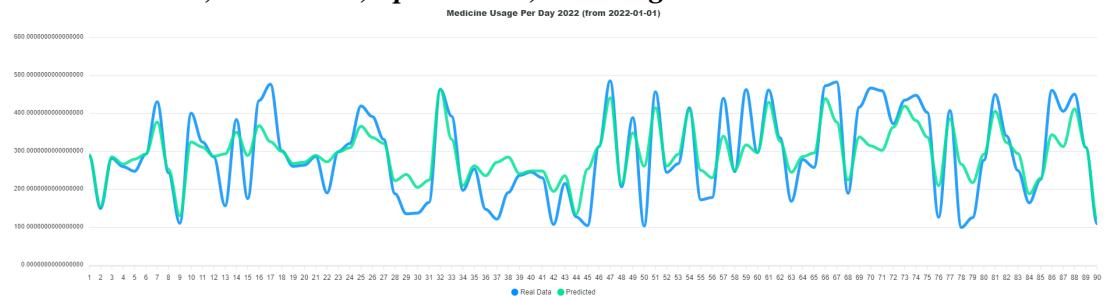
**Gambar 3.126** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 19. *Filter: 32 & 64, Units: 200, Epoch: 200, Learning Rate: 0.1*



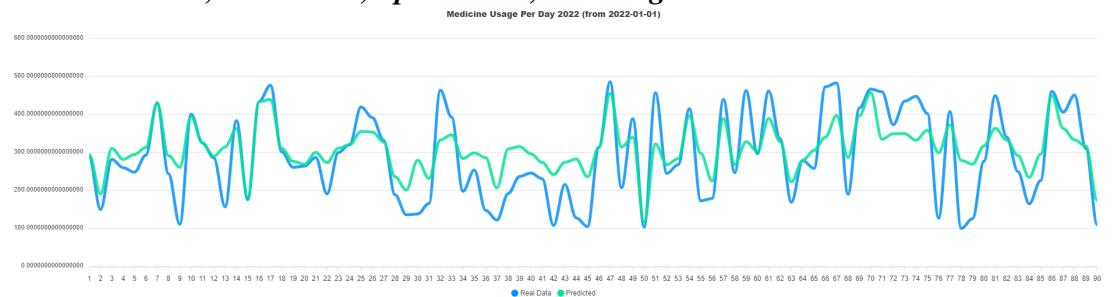
**Gambar 3.127** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 20. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1



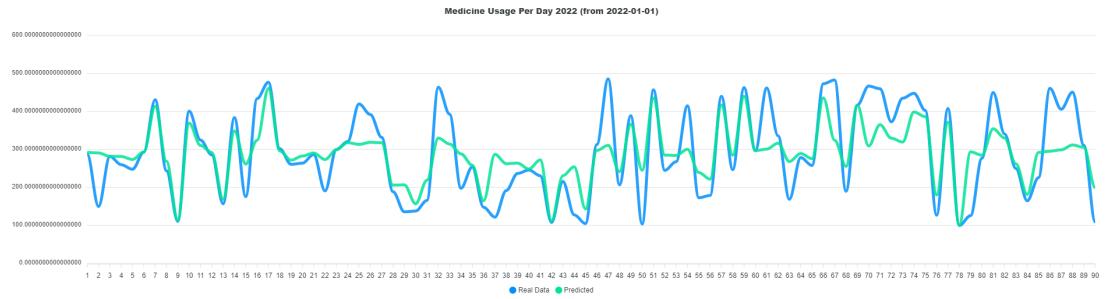
**Gambar 3.128** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 21. *Filter*: 32 & 64, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1



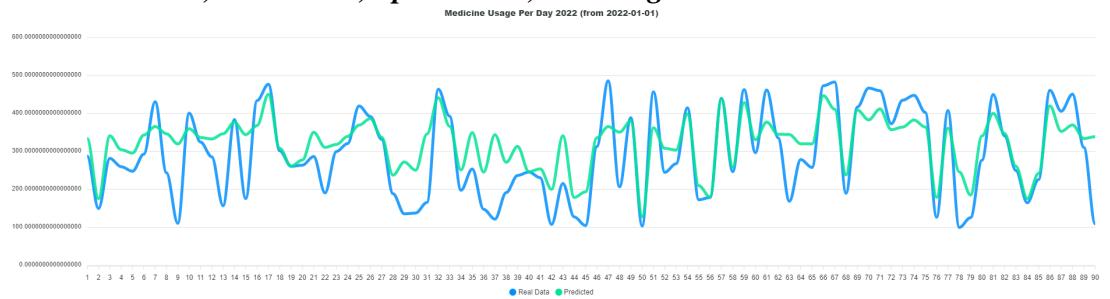
**Gambar 3.129** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 22. *Filter*: 32 & 64, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1



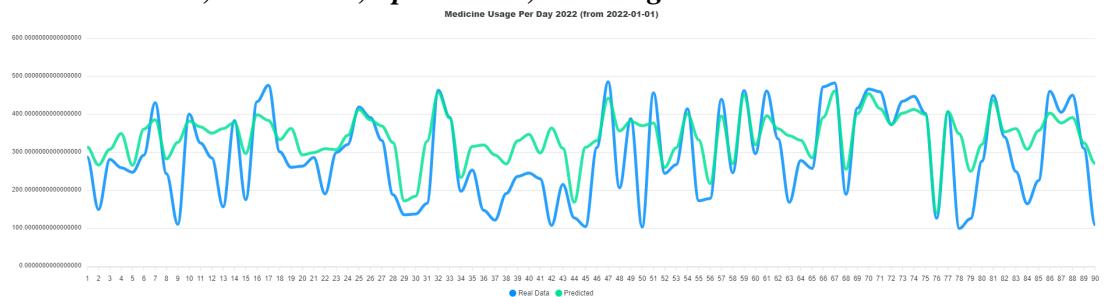
**Gambar 3.130** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 23. *Filter: 32 & 64, Units: 300, Epoch: 200, Learning Rate: 0.1*



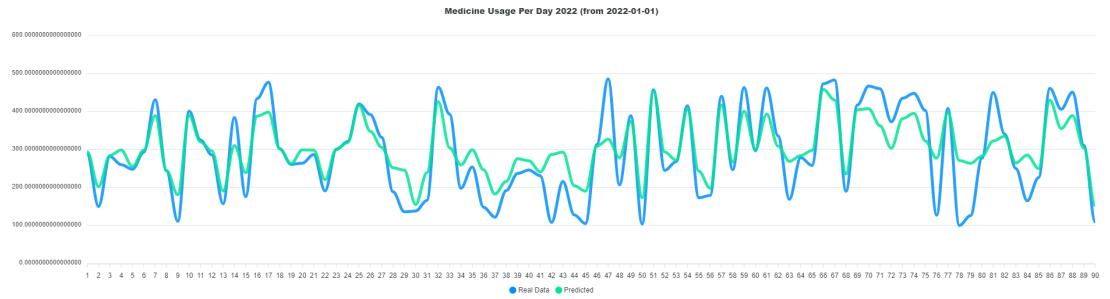
**Gambar 3.131** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 24. *Filter: 32 & 64, Units: 300, Epoch: 250, Learning Rate: 0.1*



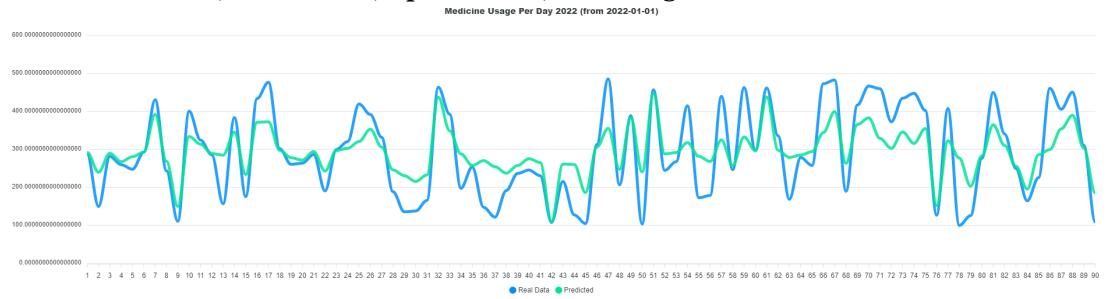
**Gambar 3.132** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 25. *Filter: 64 & 128, Units: 100, Epoch: 100, Learning Rate: 0.1*



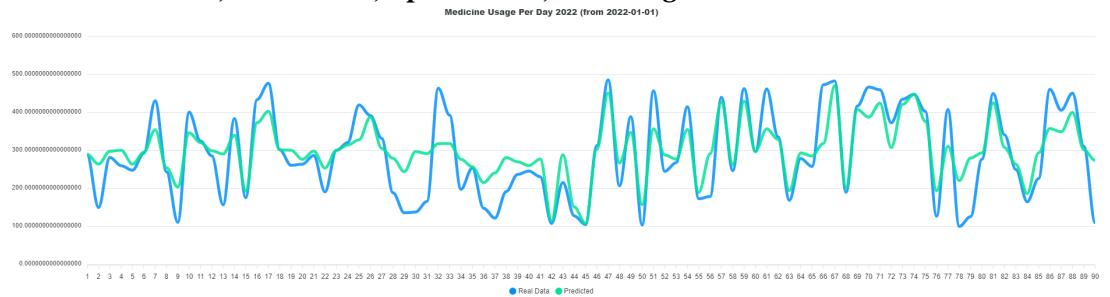
**Gambar 3.133** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 26. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.1



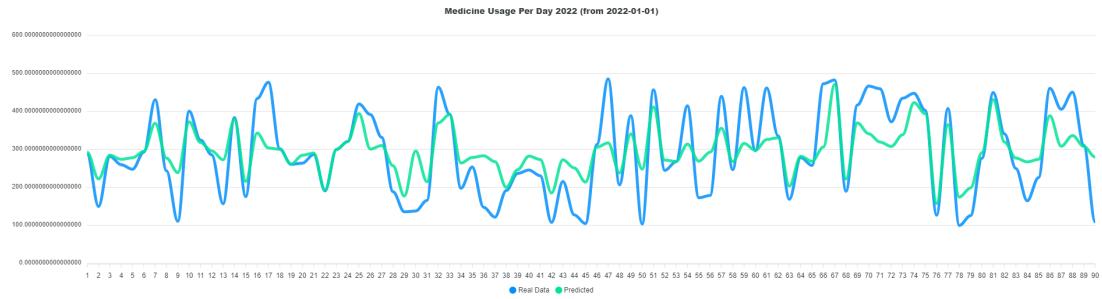
**Gambar 3.134** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 27. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.1



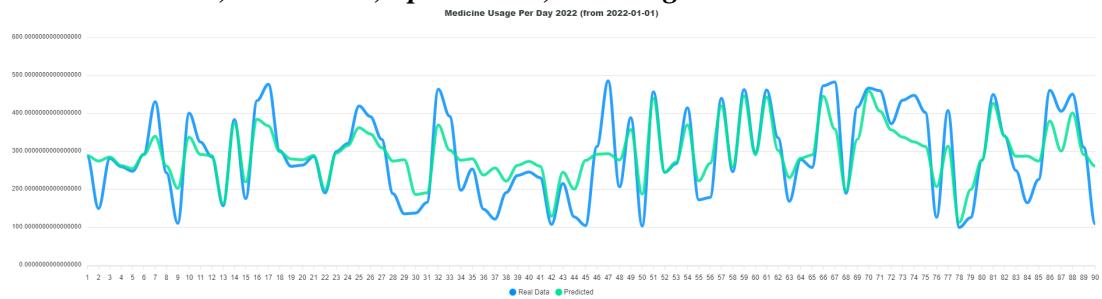
**Gambar 3.135** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 28. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.1



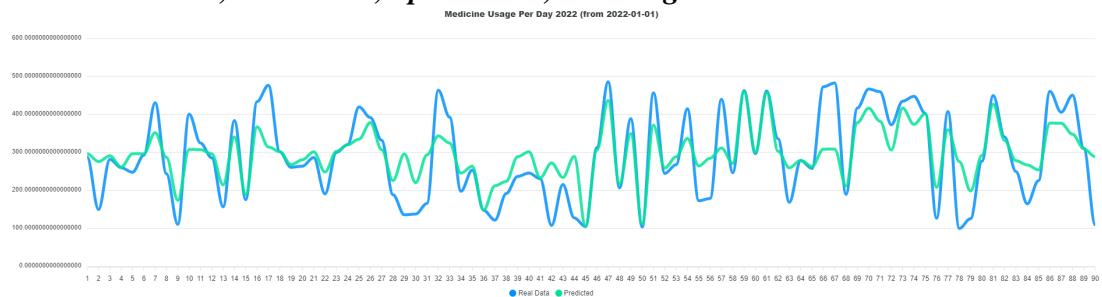
**Gambar 3.136** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 29. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.1



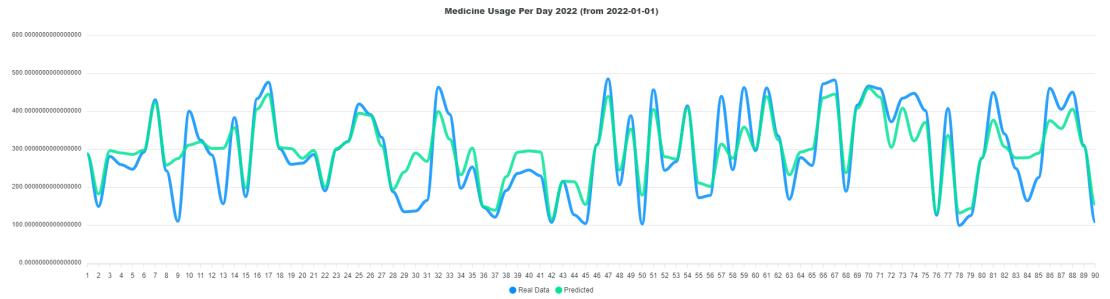
**Gambar 3.137** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 30. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.1



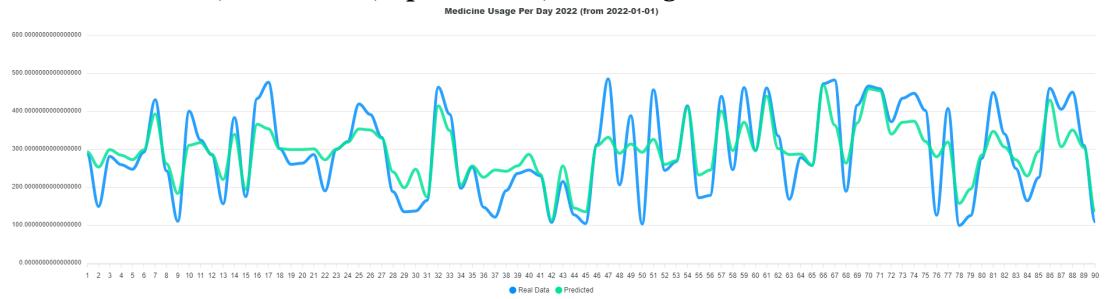
**Gambar 3.138** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 31. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.1



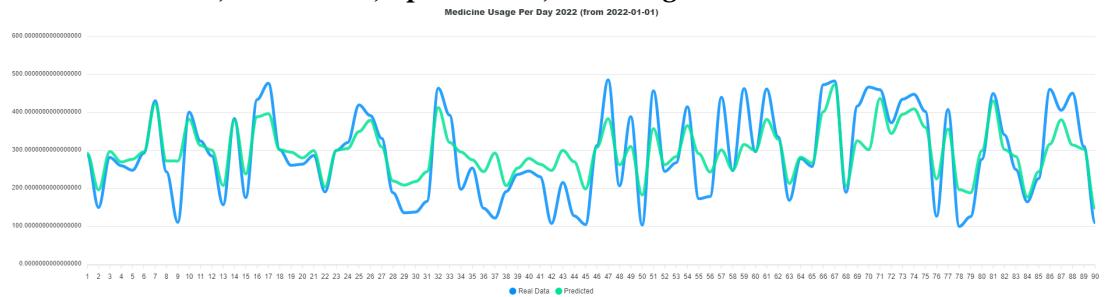
**Gambar 3.139** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 32. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1



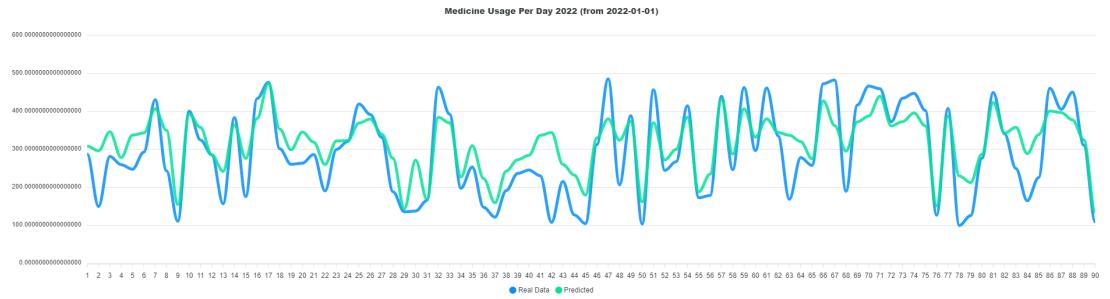
**Gambar 3.140** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 33. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1



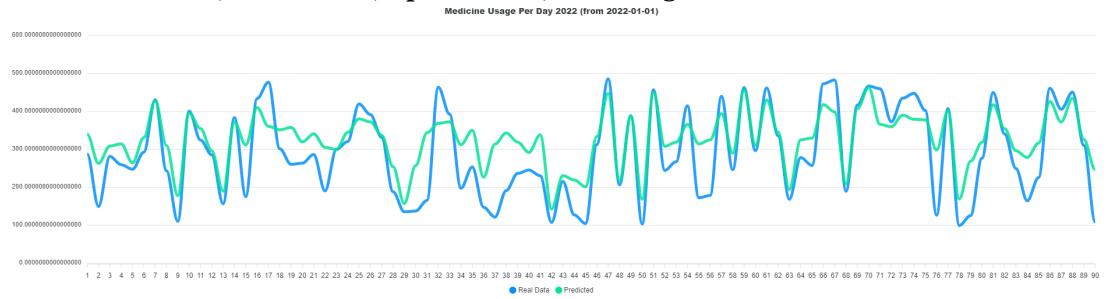
**Gambar 3.141** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 34. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1



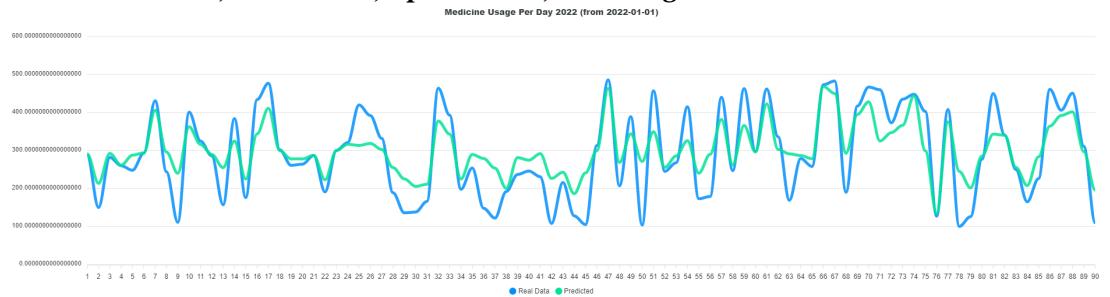
**Gambar 3.142** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 35. *Filter: 64 & 128, Units: 300, Epoch: 200, Learning Rate: 0.1*



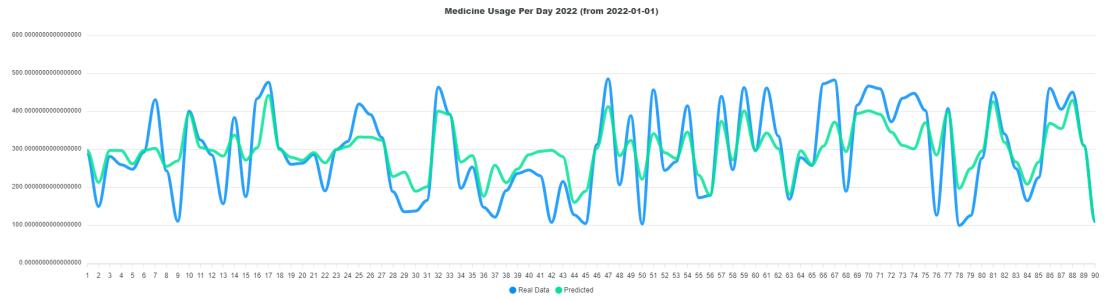
**Gambar 3.143** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 36. *Filter: 64 & 128, Units: 300, Epoch: 250, Learning Rate: 0.1*



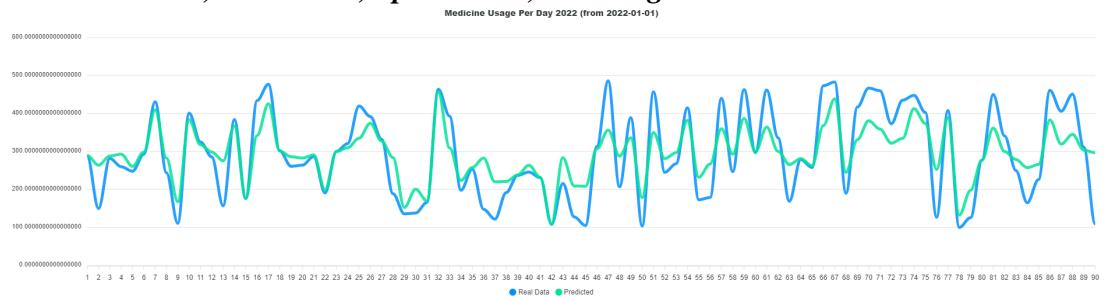
**Gambar 3.144** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.1 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 37. *Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.01*



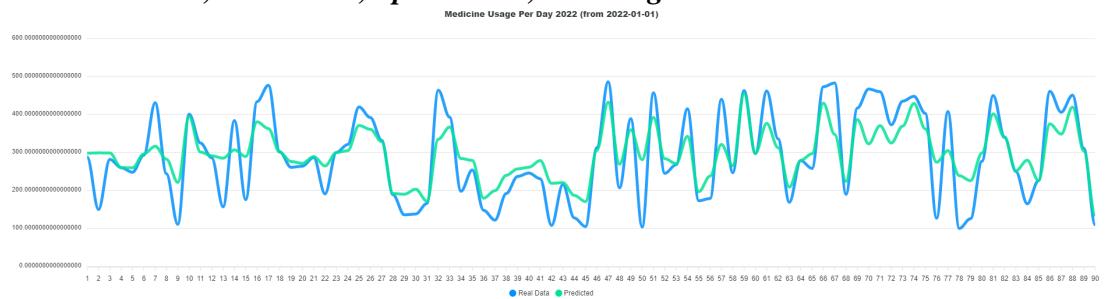
**Gambar 3.145** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 38. *Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.01*



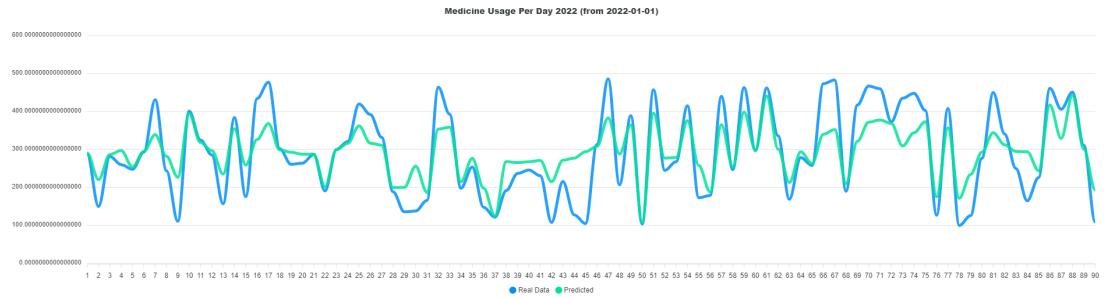
**Gambar 3.146** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 39. *Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.01*



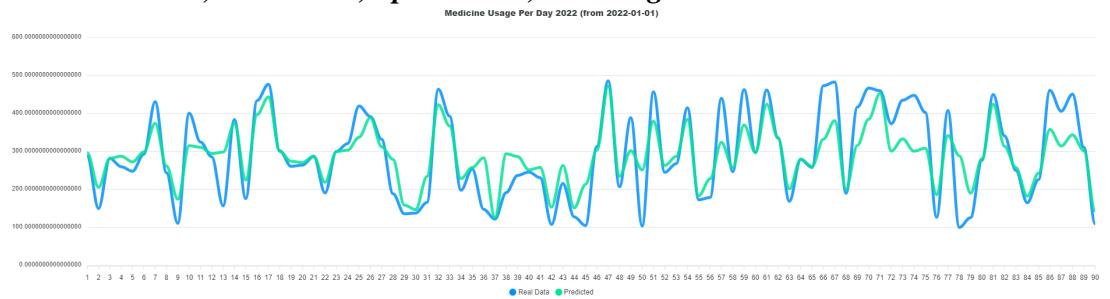
**Gambar 3.147** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 40. *Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.01*



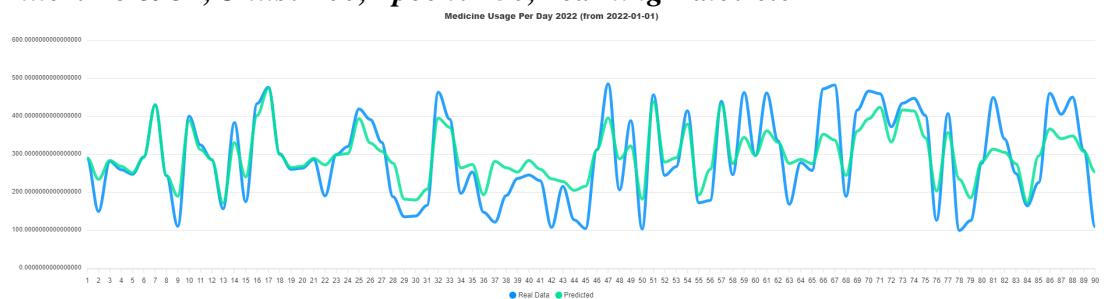
**Gambar 3.148** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 41. *Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.01*



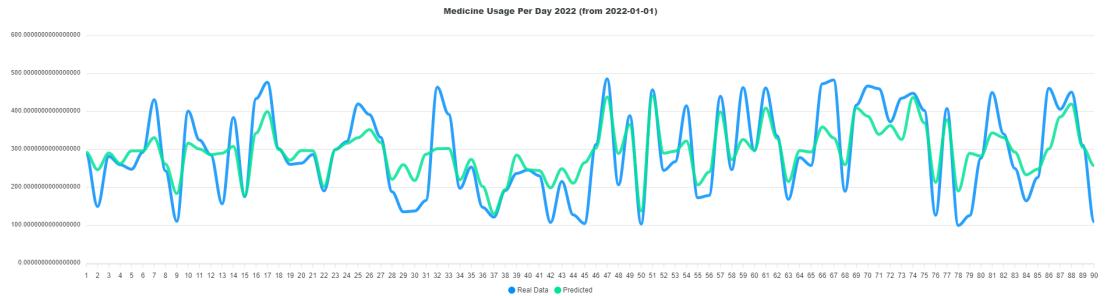
**Gambar 3.149** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 42. *Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.01*



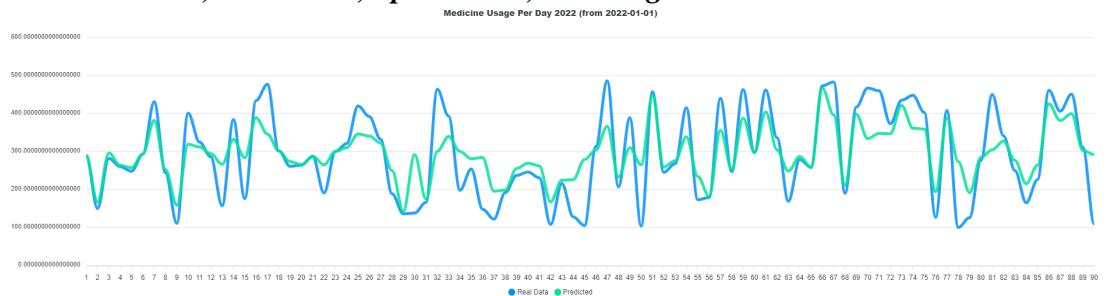
**Gambar 3.150** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 43. *Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.01*



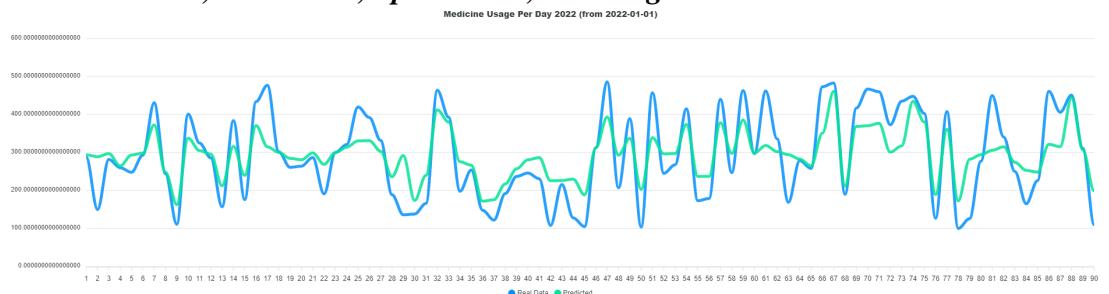
**Gambar 3.151** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 44. *Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.01*



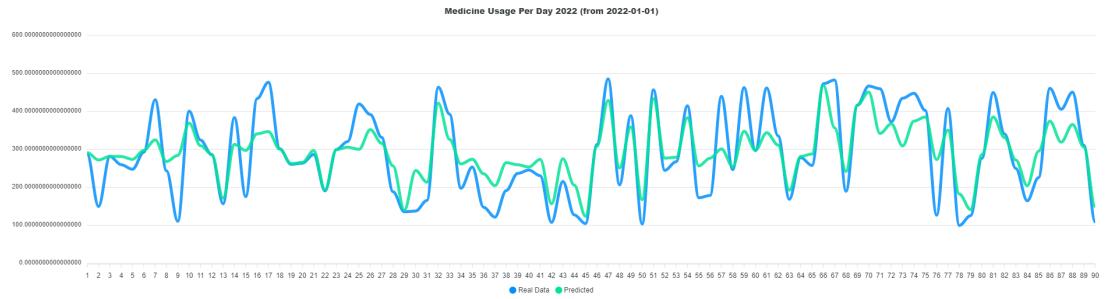
**Gambar 3.152** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 45. *Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.01*



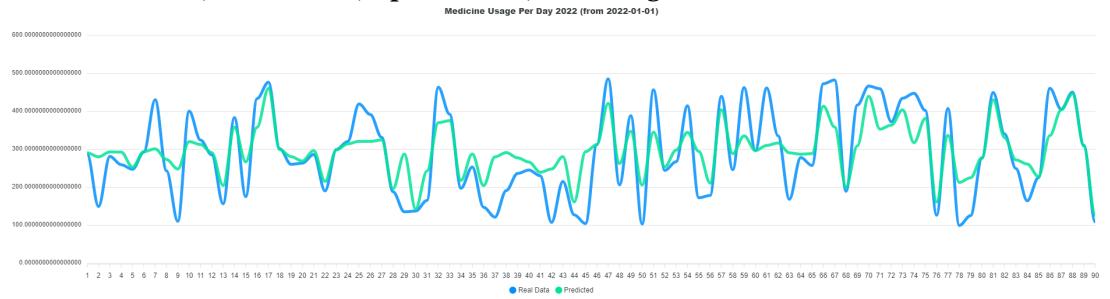
**Gambar 3.153** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 46. *Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.01*



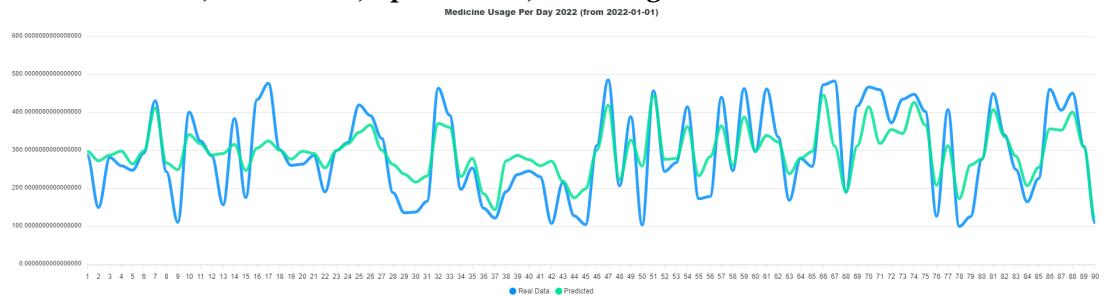
**Gambar 3.154** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

**47. Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.01**



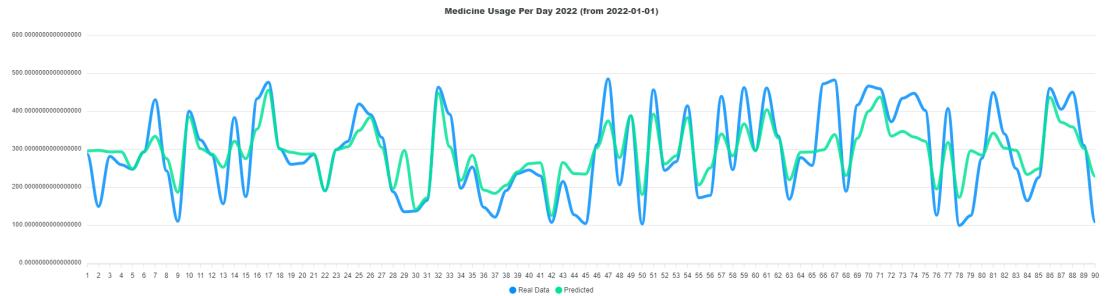
**Gambar 3.155** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

**48. Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.01**



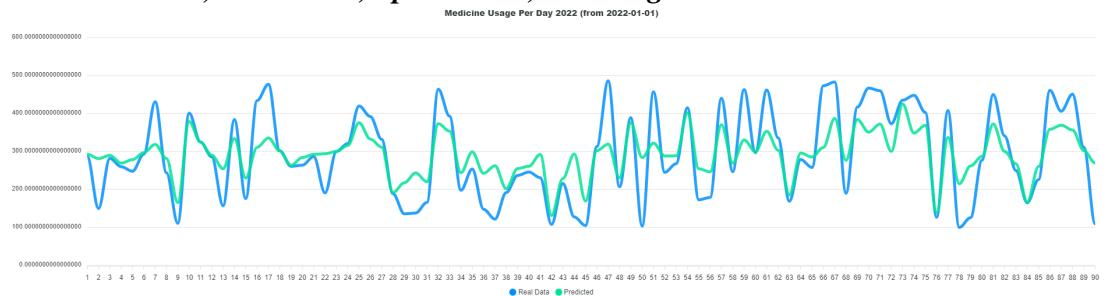
**Gambar 3.156** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

**49. Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.01**



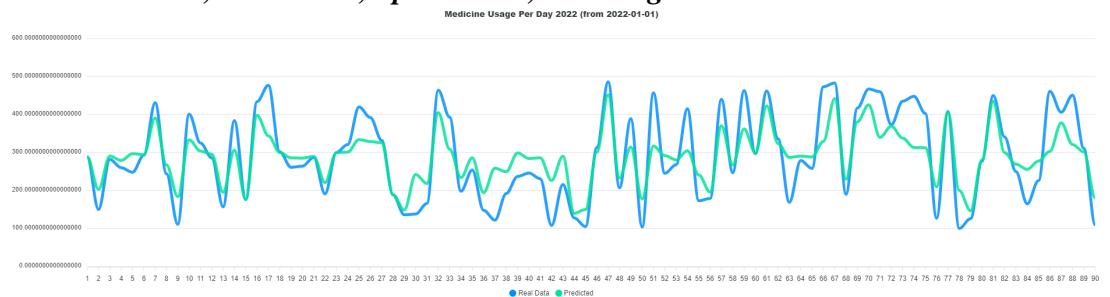
**Gambar 3.157** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 50. *Filter*: 32 & 64, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01



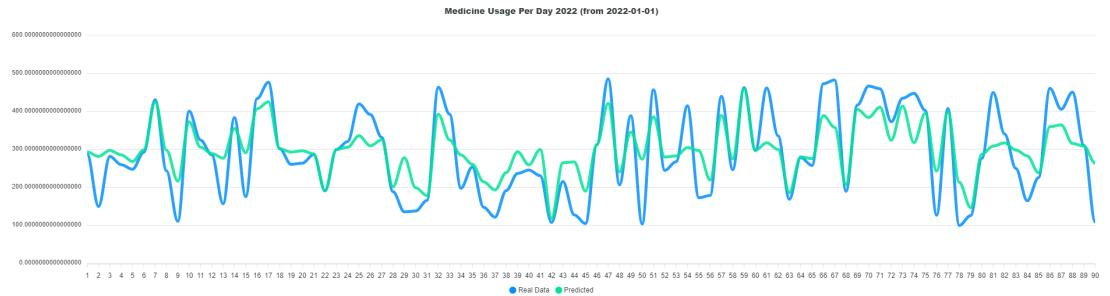
**Gambar 3.158** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 51. *Filter*: 32 & 64, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01



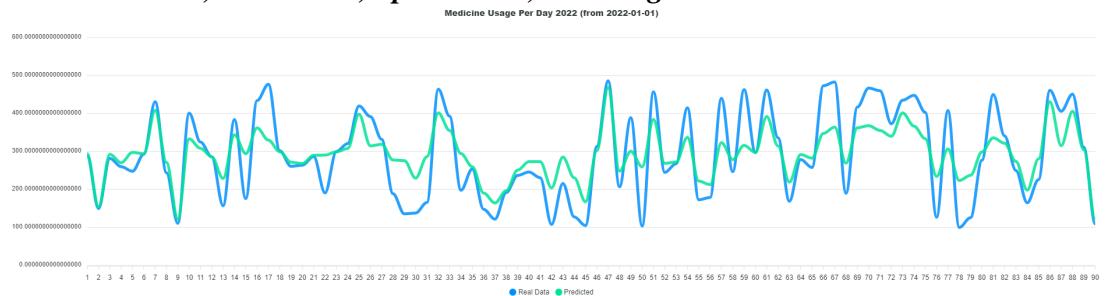
**Gambar 3.159** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 52. *Filter*: 32 & 64, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01



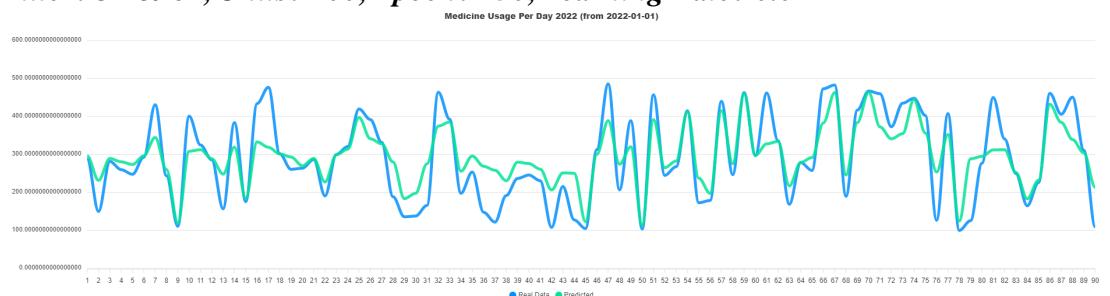
**Gambar 3.160** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 53. *Filter: 32 & 64, Units: 200, Epoch: 100, Learning Rate: 0.01*



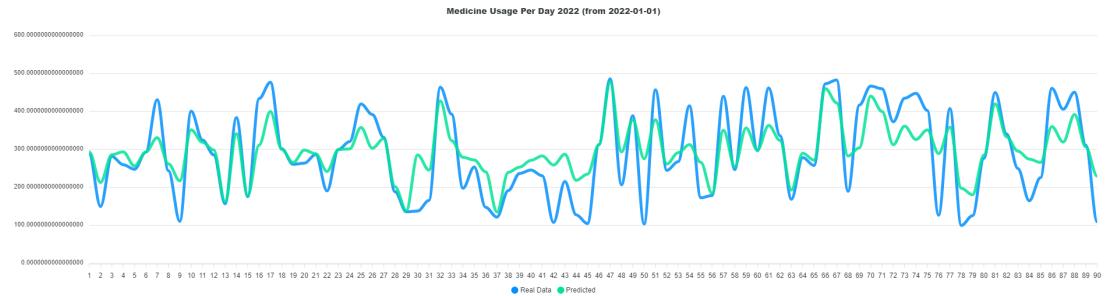
**Gambar 3.161** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 54. *Filter: 32 & 64, Units: 200, Epoch: 150, Learning Rate: 0.01*



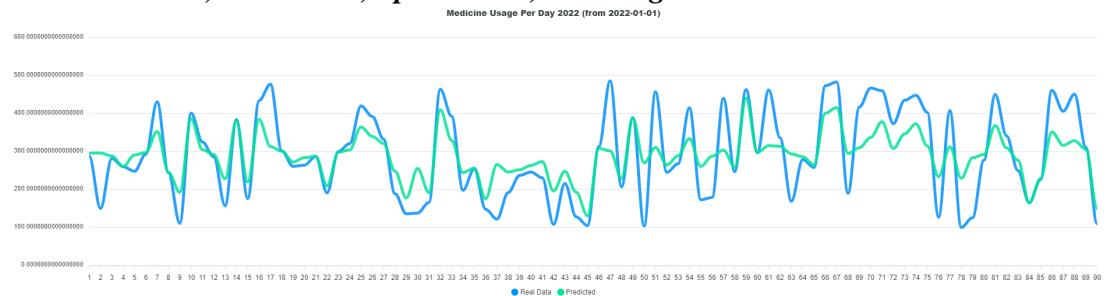
**Gambar 3.162** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 55. *Filter: 32 & 64, Units: 200, Epoch: 200, Learning Rate: 0.01*



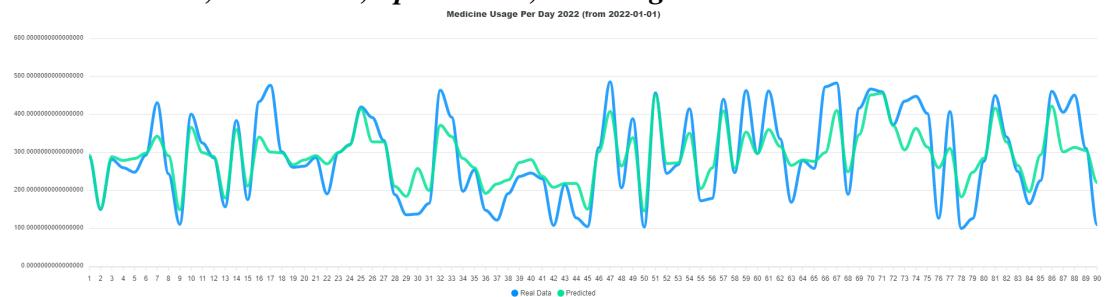
**Gambar 3.163** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 56. *Filter: 32 & 64, Units: 200, Epoch: 250, Learning Rate: 0.01*



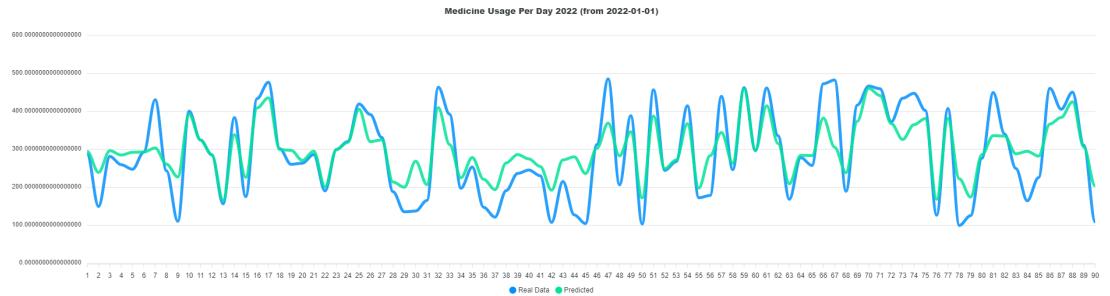
**Gambar 3.164** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 57. *Filter: 32 & 64, Units: 300, Epoch: 100, Learning Rate: 0.01*



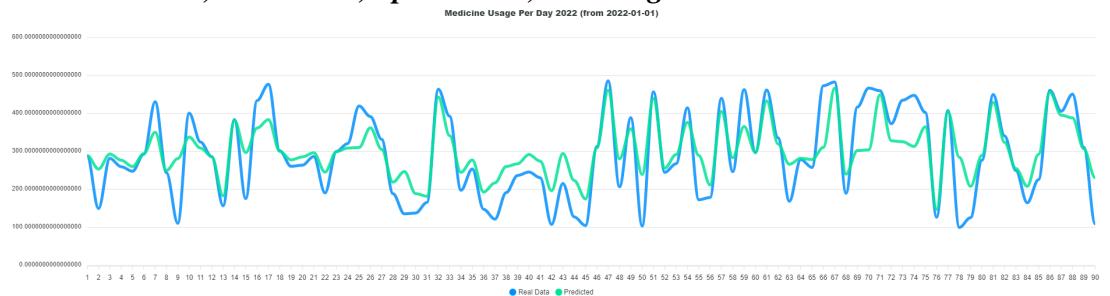
**Gambar 3.165** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 58. *Filter: 32 & 64, Units: 300, Epoch: 150, Learning Rate: 0.01*



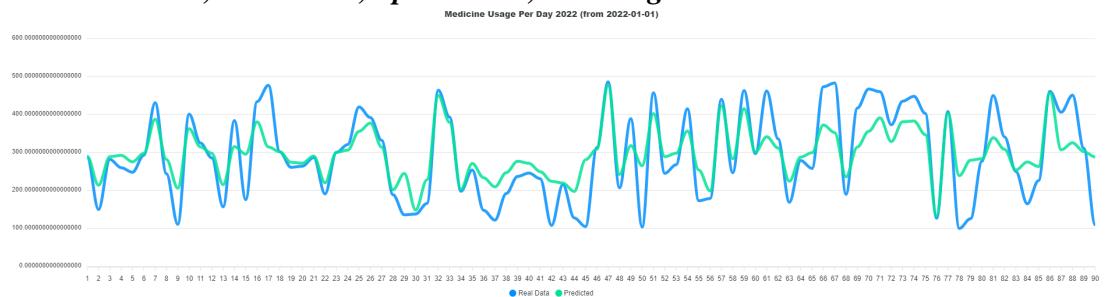
**Gambar 3.166** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 59. *Filter: 32 & 64, Units: 300, Epoch: 200, Learning Rate: 0.01*



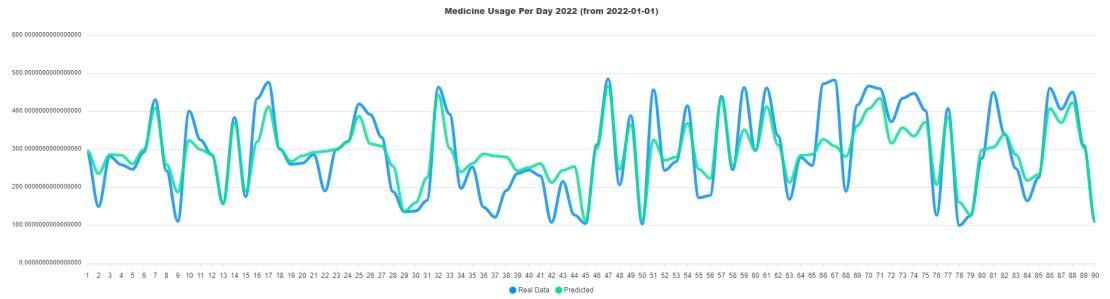
**Gambar 3.167** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 60. *Filter: 32 & 64, Units: 300, Epoch: 250, Learning Rate: 0.01*



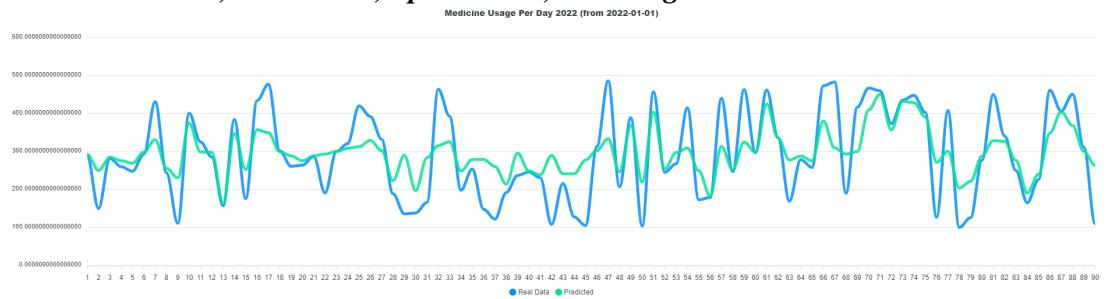
**Gambar 3.168** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 61. *Filter: 64 & 128, Units: 100, Epoch: 100, Learning Rate: 0.01*



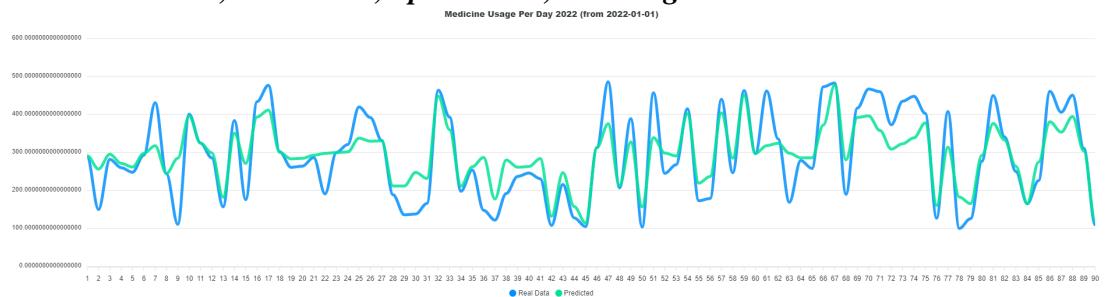
**Gambar 3.169** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 62. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01



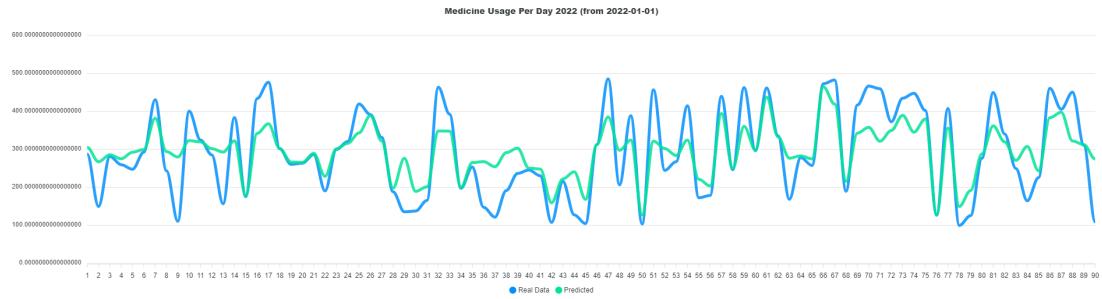
**Gambar 3.170** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 63. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01



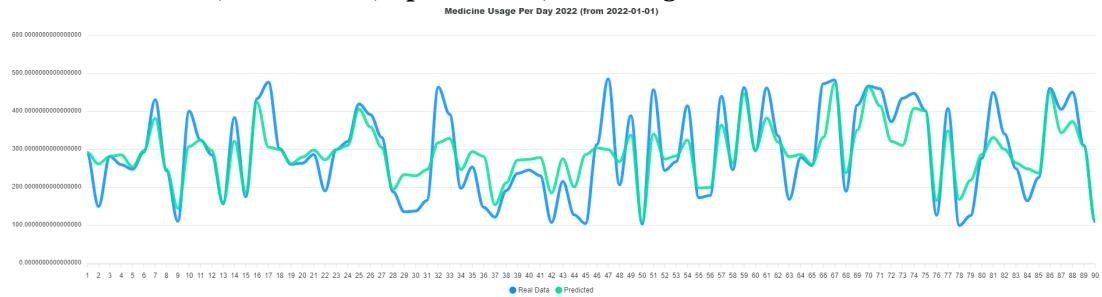
**Gambar 3.171** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 64. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01



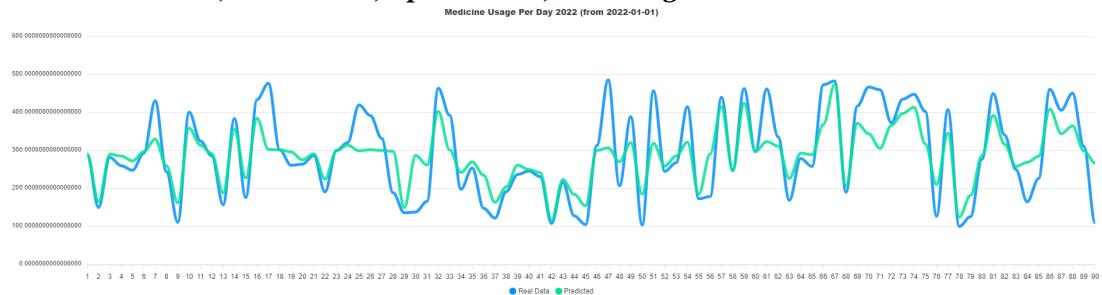
**Gambar 3.172** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 65. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.01



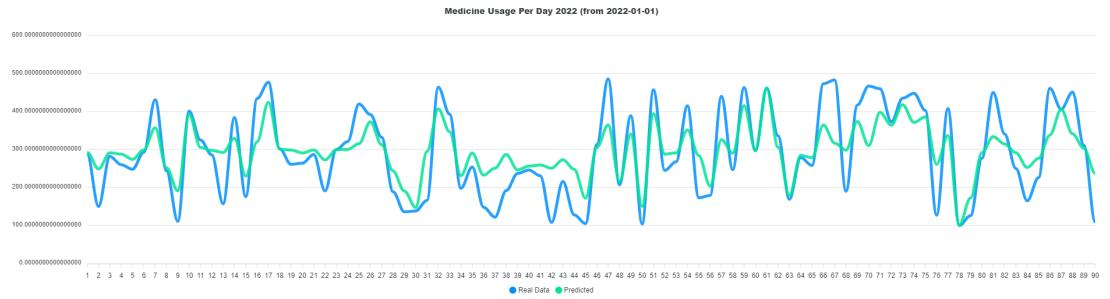
**Gambar 3.173** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 66. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.01



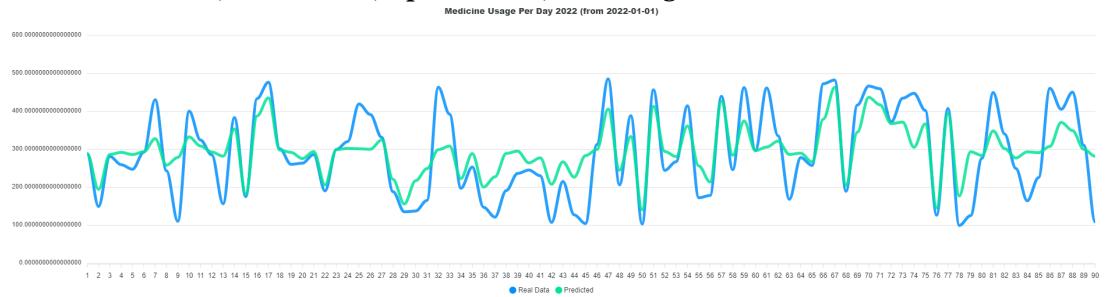
**Gambar 3.174** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 67. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.01



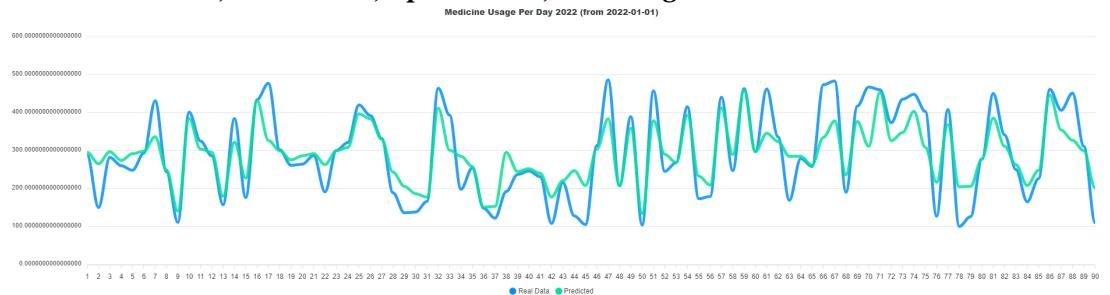
**Gambar 3.175** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 68. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.01



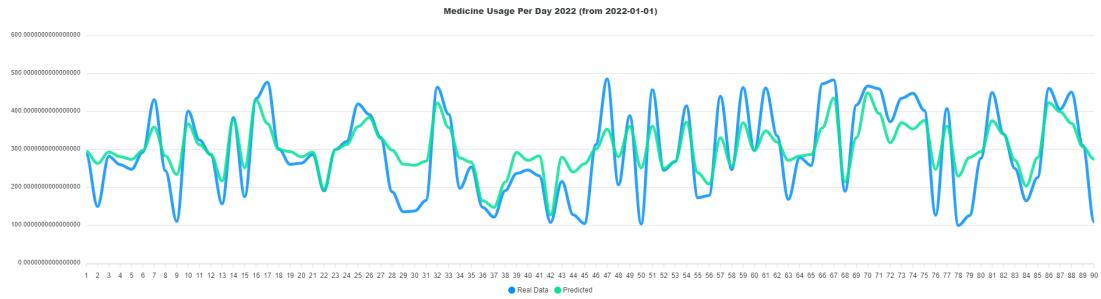
**Gambar 3.176** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 69. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.01



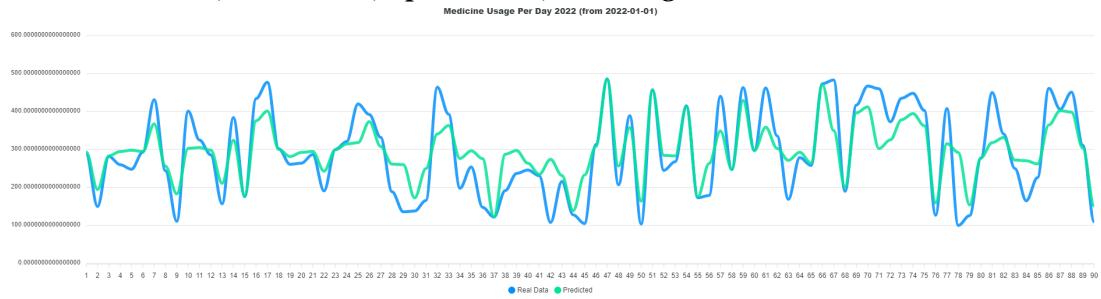
**Gambar 3.177** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 70. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.01



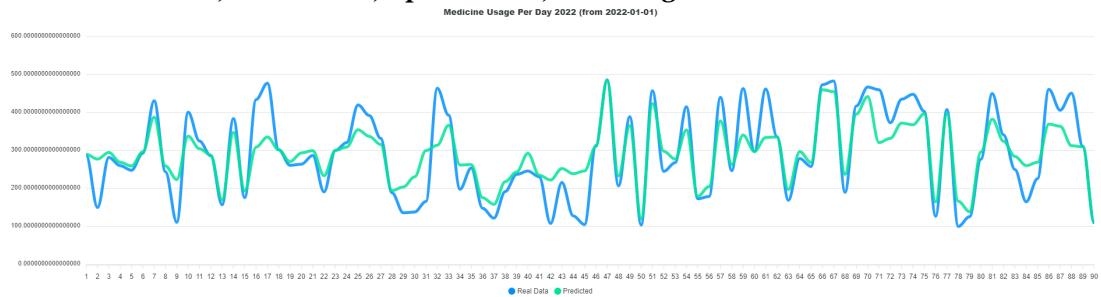
**Gambar 3.178** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 71. *Filter: 64 & 128, Units: 300, Epoch: 200, Learning Rate: 0.01*



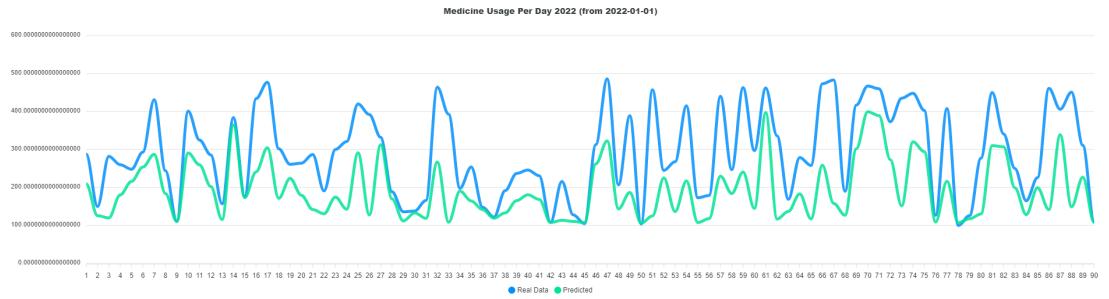
**Gambar 3.179** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 72. *Filter: 64 & 128, Units: 300, Epoch: 250, Learning Rate: 0.01*



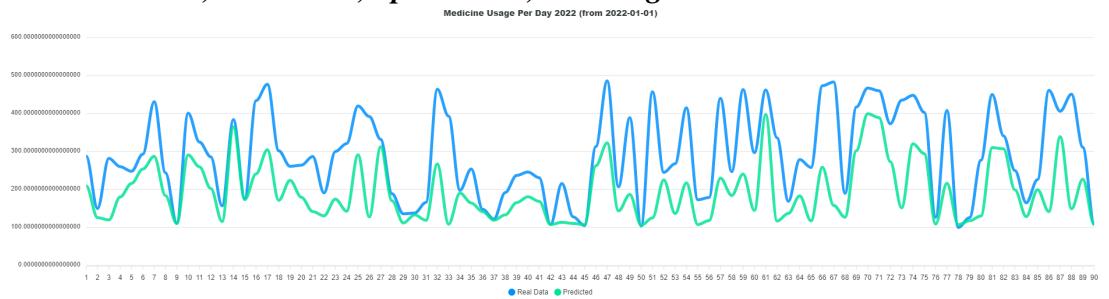
**Gambar 3.180** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.01 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 73. *Filter: 16 & 32, Units: 100, Epoch: 100, Learning Rate: 0.001*



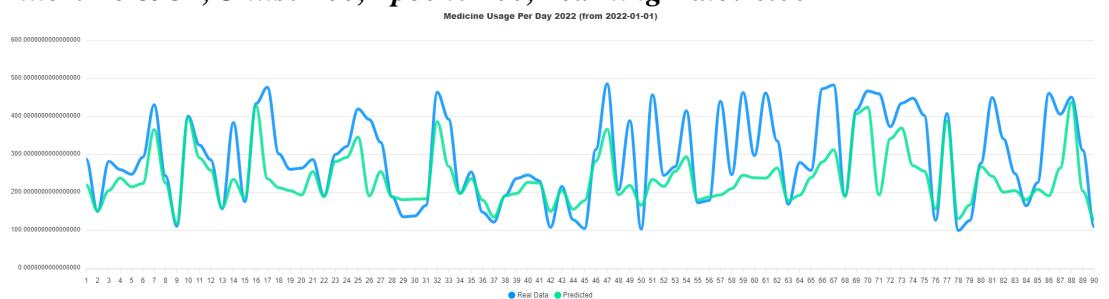
**Gambar 3.181** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 74. *Filter: 16 & 32, Units: 100, Epoch: 150, Learning Rate: 0.001*



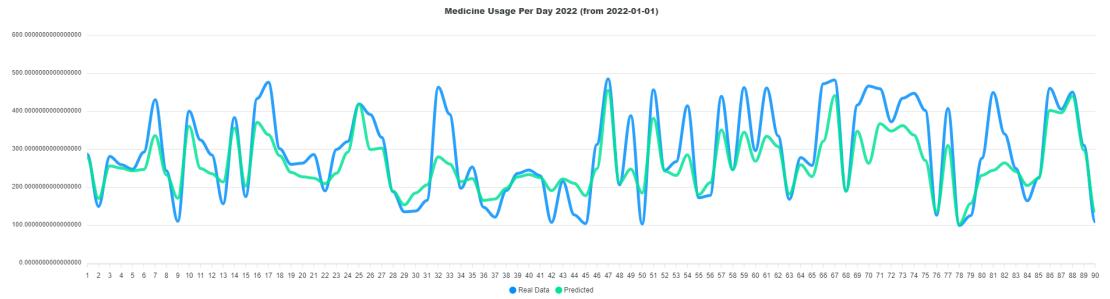
**Gambar 3.182** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 75. *Filter: 16 & 32, Units: 100, Epoch: 200, Learning Rate: 0.001*



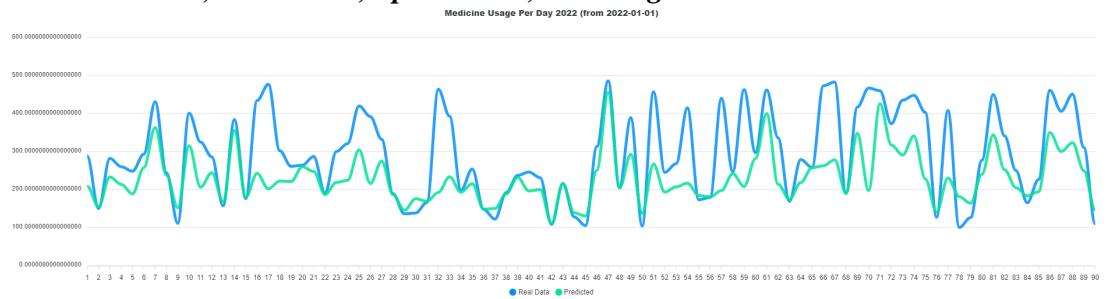
**Gambar 3.183** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 76. *Filter: 16 & 32, Units: 100, Epoch: 250, Learning Rate: 0.001*



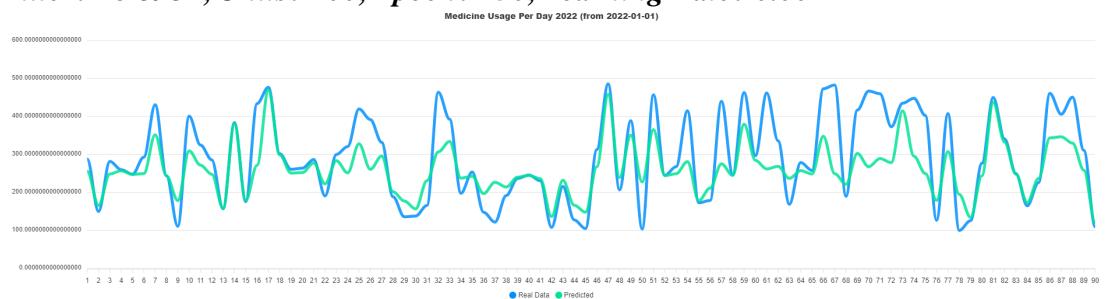
**Gambar 3.184** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 77. *Filter: 16 & 32, Units: 200, Epoch: 100, Learning Rate: 0.001*



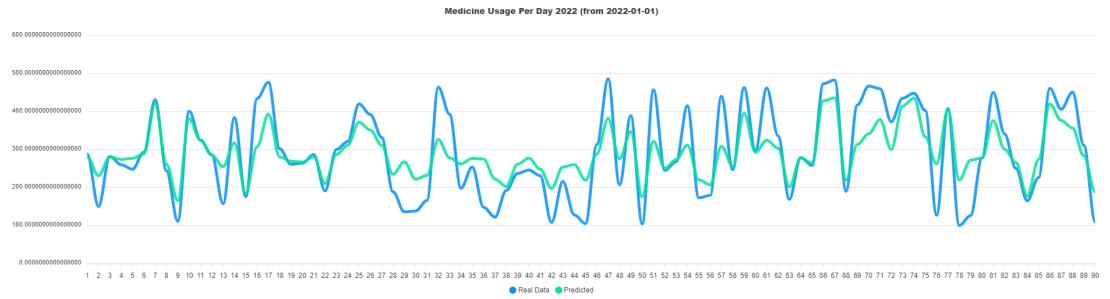
**Gambar 3.185** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 78. *Filter: 16 & 32, Units: 200, Epoch: 150, Learning Rate: 0.001*



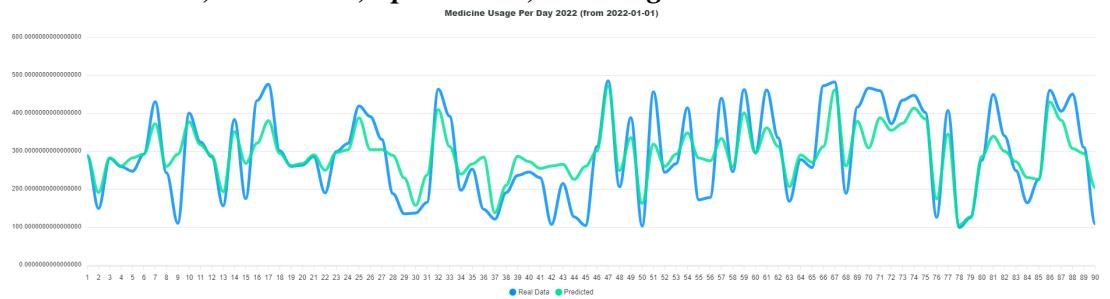
**Gambar 3.186** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 79. *Filter: 16 & 32, Units: 200, Epoch: 200, Learning Rate: 0.001*



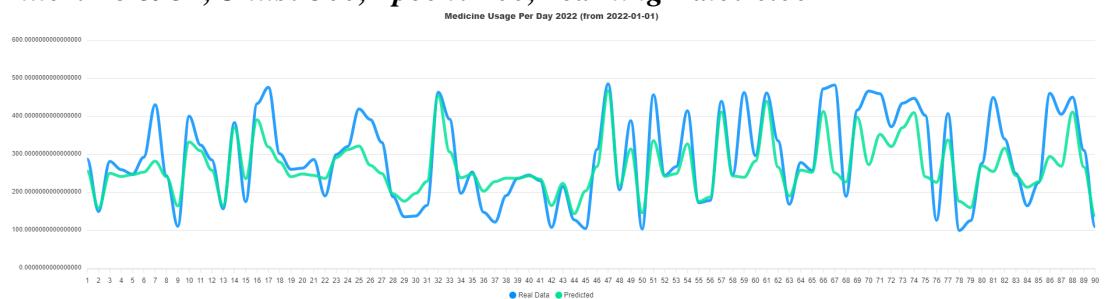
**Gambar 3.187** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 80. *Filter: 16 & 32, Units: 200, Epoch: 250, Learning Rate: 0.001*



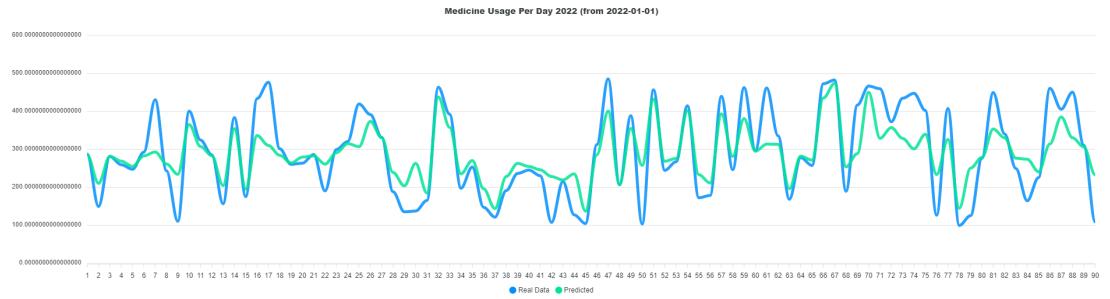
**Gambar 3.188** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 81. *Filter: 16 & 32, Units: 300, Epoch: 100, Learning Rate: 0.001*



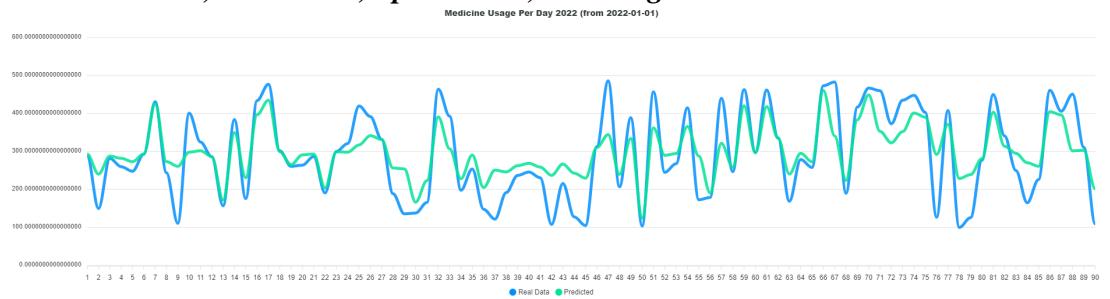
**Gambar 3.189** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 82. *Filter: 16 & 32, Units: 300, Epoch: 150, Learning Rate: 0.001*



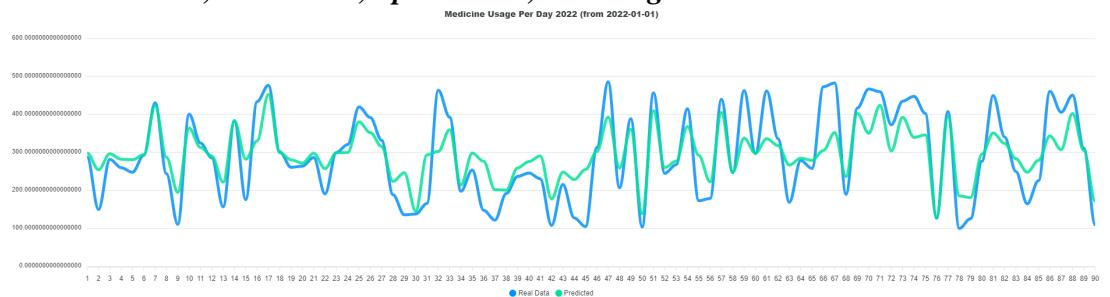
**Gambar 3.190** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 83. *Filter: 16 & 32, Units: 300, Epoch: 200, Learning Rate: 0.001*



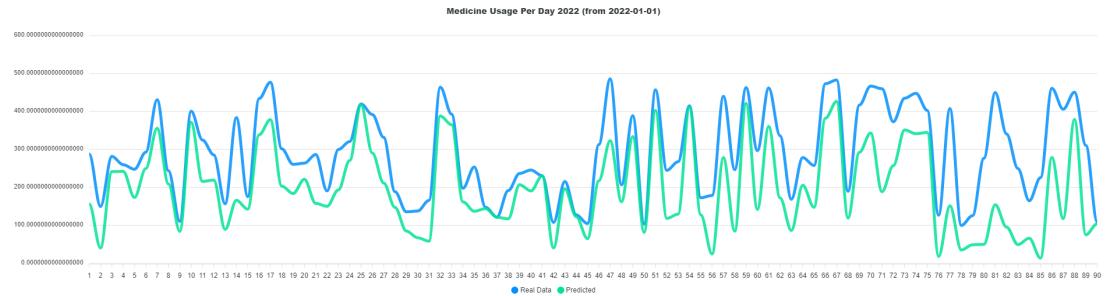
**Gambar 3.191** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 84. *Filter: 16 & 32, Units: 300, Epoch: 250, Learning Rate: 0.001*



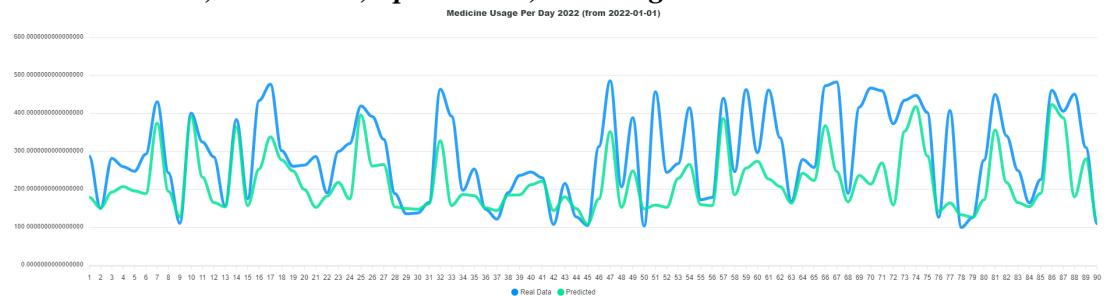
**Gambar 3.192** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 16 & 32, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 85. *Filter: 32 & 64, Units: 100, Epoch: 100, Learning Rate: 0.001*



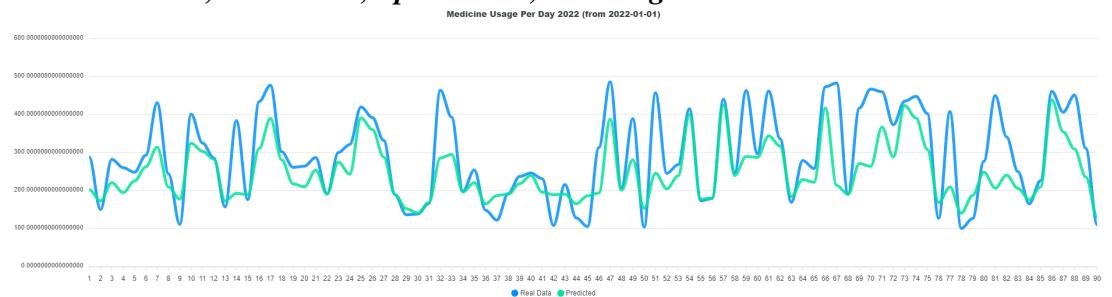
**Gambar 3.193** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 86. *Filter*: 32 & 64, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.001



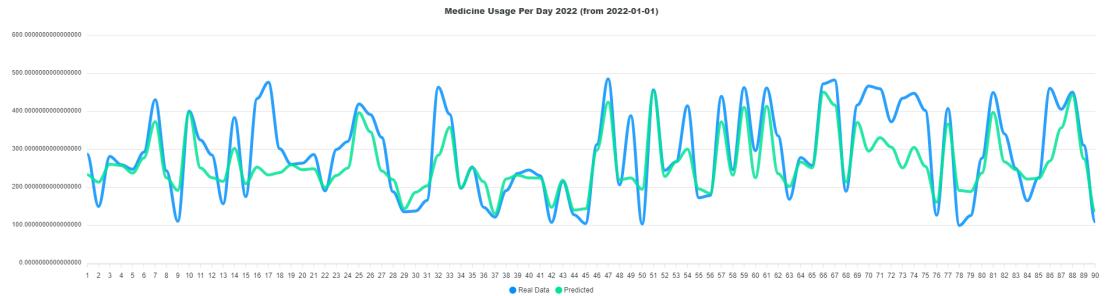
**Gambar 3.194** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 87. *Filter*: 32 & 64, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001



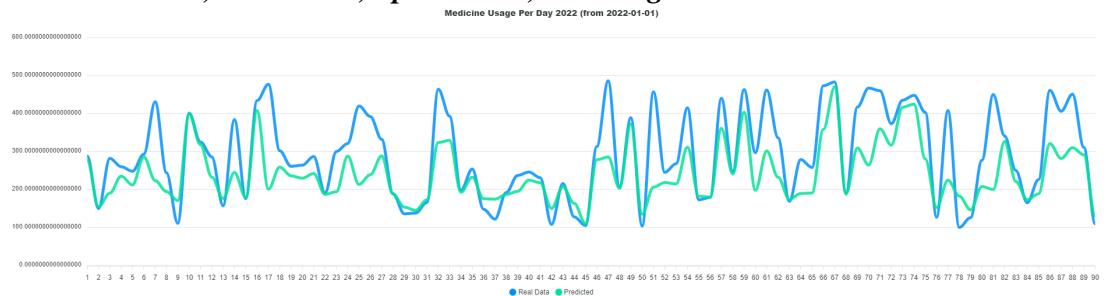
**Gambar 3.195** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 88. *Filter*: 32 & 64, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.001



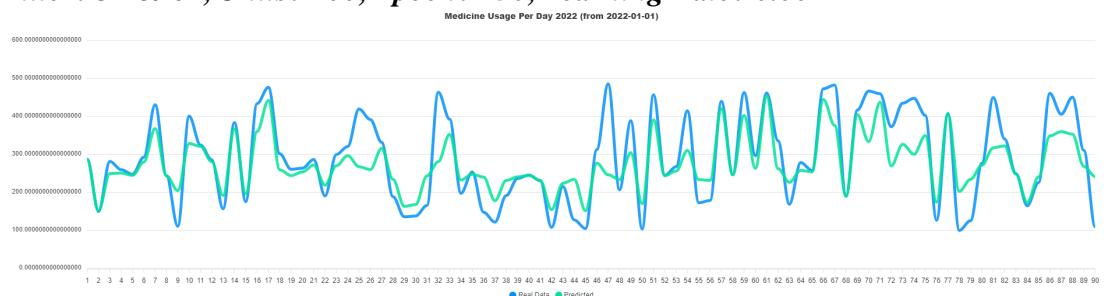
**Gambar 3.196** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 89. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001



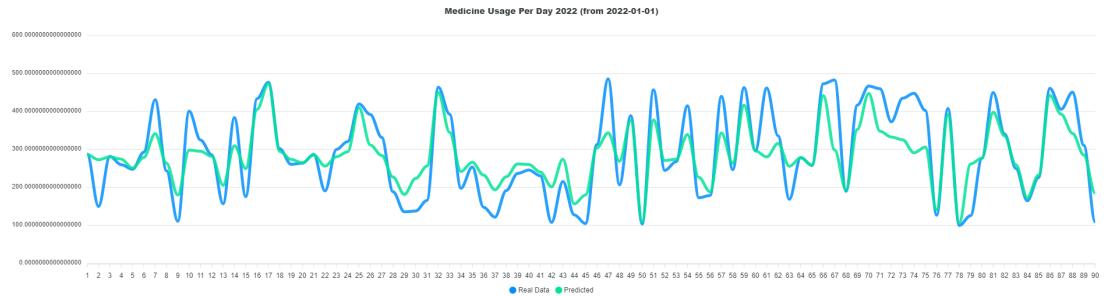
**Gambar 3.197** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 90. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001



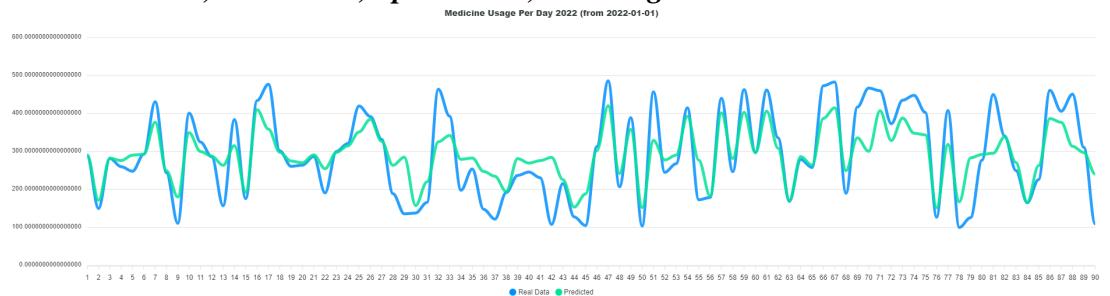
**Gambar 3.198** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 91. *Filter*: 32 & 64, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001



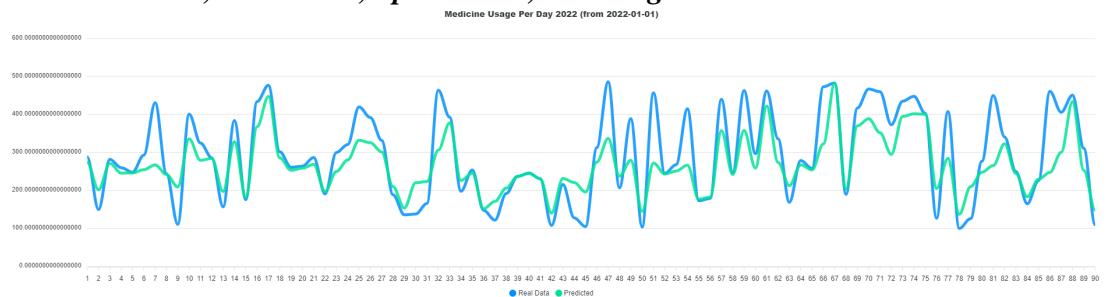
**Gambar 3.199** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 92. *Filter: 32 & 64, Units: 200, Epoch: 250, Learning Rate: 0.001*



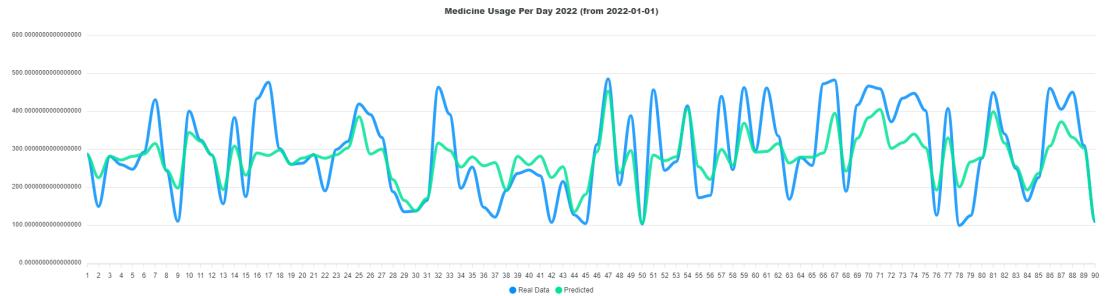
**Gambar 3.200** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 93. *Filter: 32 & 64, Units: 300, Epoch: 100, Learning Rate: 0.001*



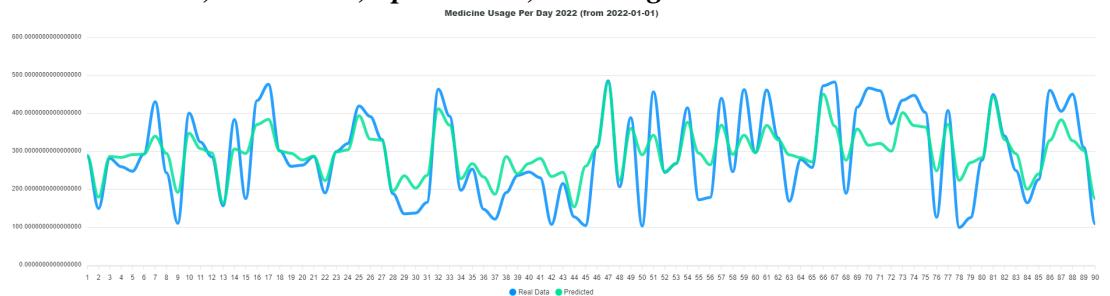
**Gambar 3.201** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 94. *Filter: 32 & 64, Units: 300, Epoch: 150, Learning Rate: 0.001*



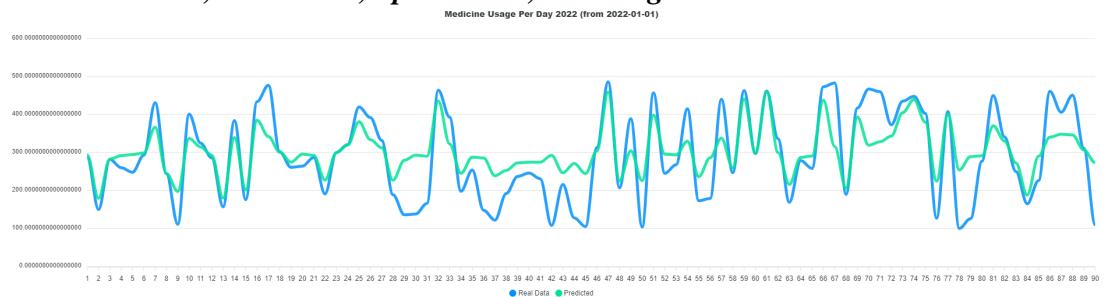
**Gambar 3.202** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 95. *Filter*: 32 & 64, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.001



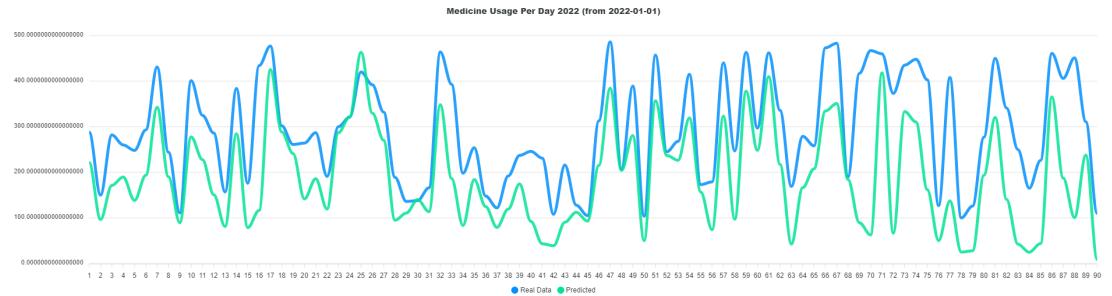
**Gambar 3.203** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 96. *Filter*: 32 & 64, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.001



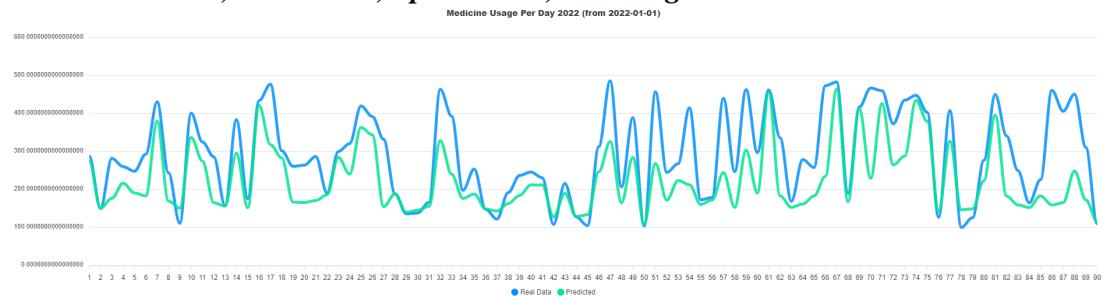
**Gambar 3.204** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 32 & 64, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 97. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.001



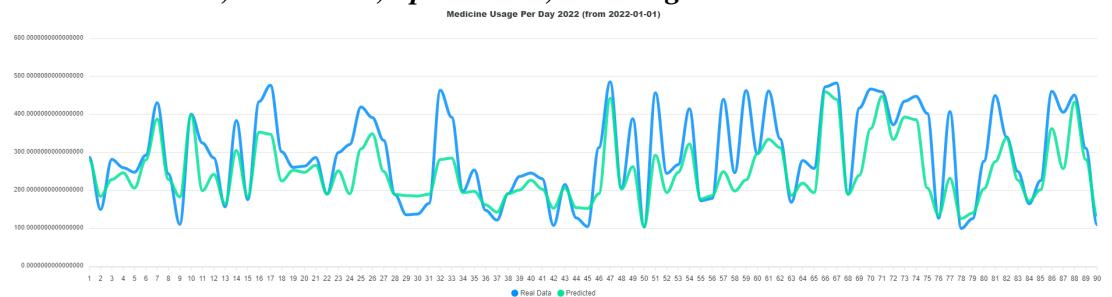
**Gambar 3.205** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 98. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.001



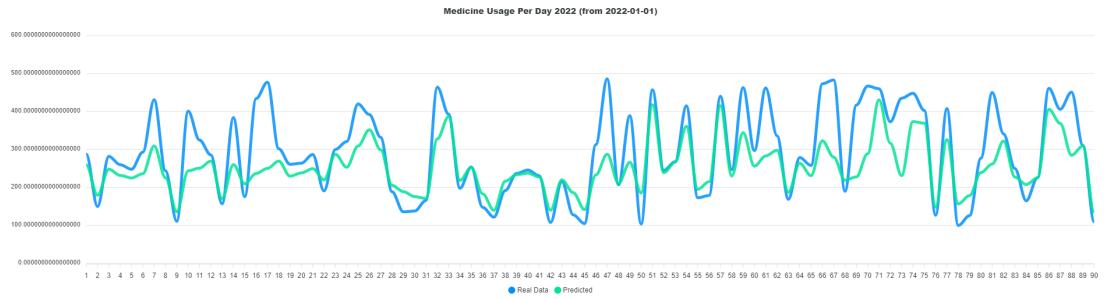
**Gambar 3.206** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 99. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001



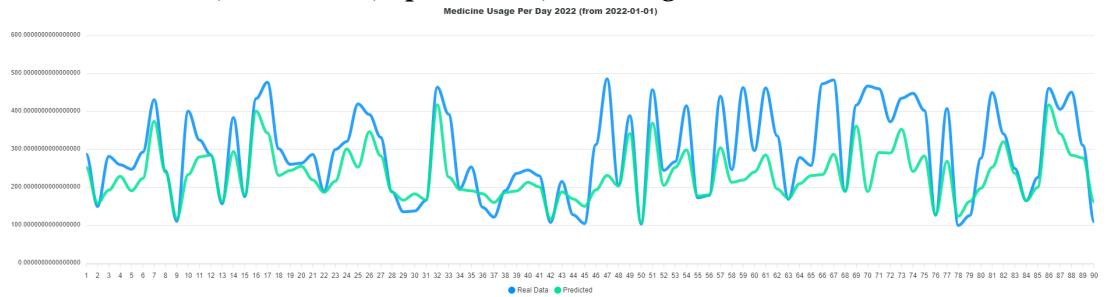
**Gambar 3.207** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 100. *Filter*: 64 & 128, *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.001



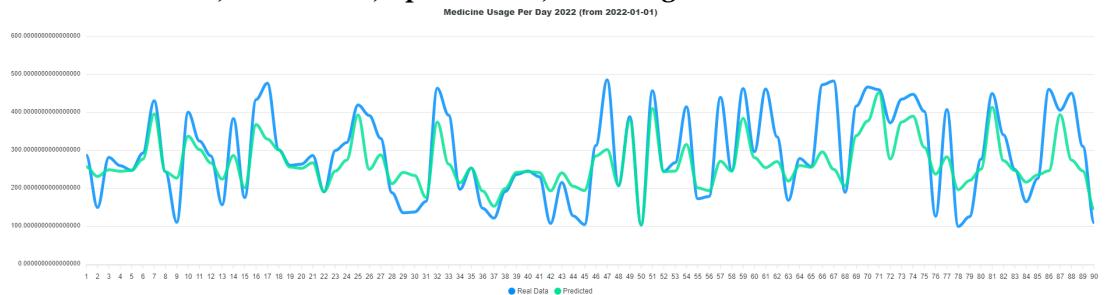
**Gambar 3.208** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 101. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001



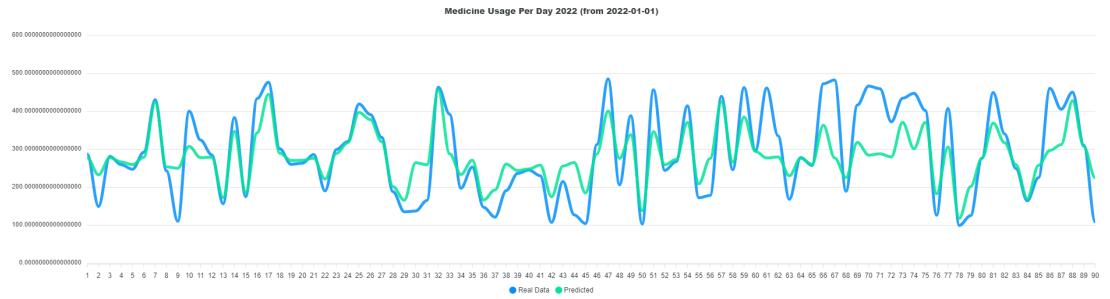
**Gambar 3.209** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 102. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001



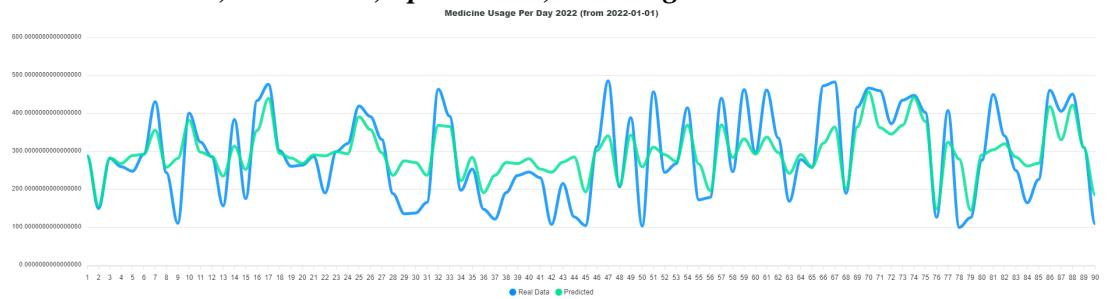
**Gambar 3.210** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 103. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001



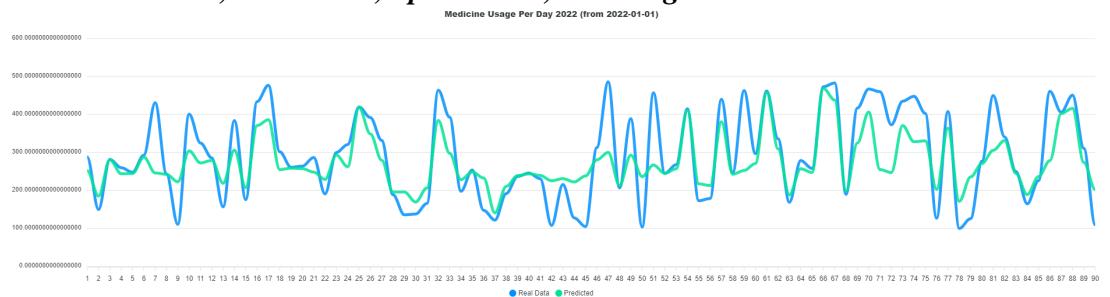
**Gambar 3.211** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 104. *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.001



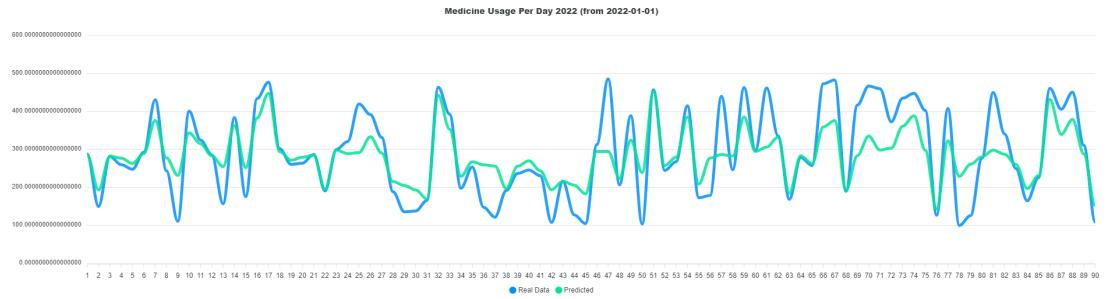
**Gambar 3.212** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 105. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.001



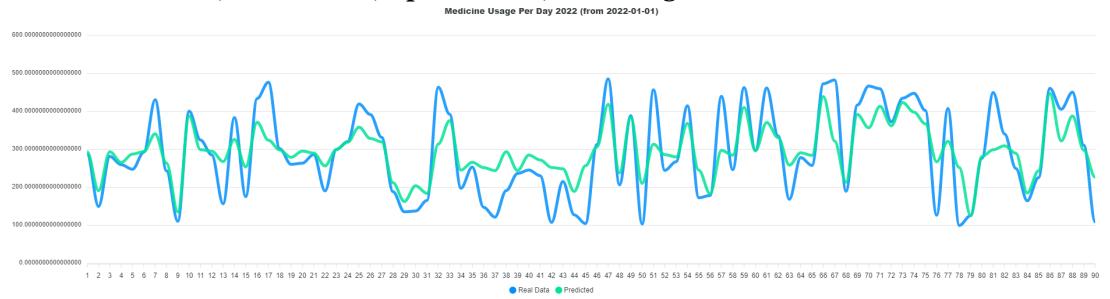
**Gambar 3.213** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 106. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.001



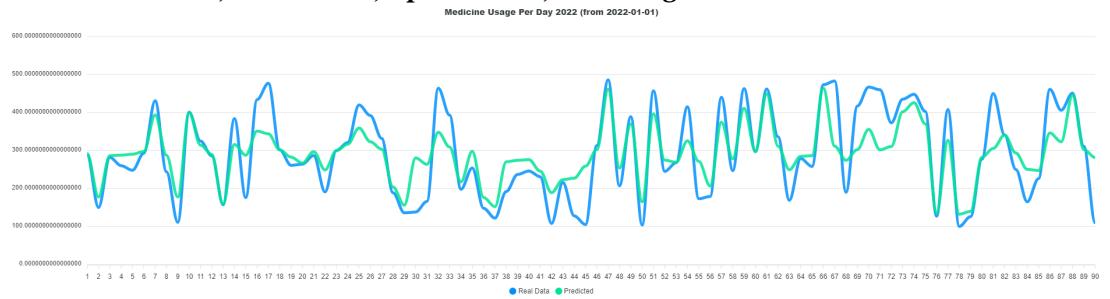
**Gambar 3.214** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 107. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.001



**Gambar 3.215** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

### 108. *Filter*: 64 & 128, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.001

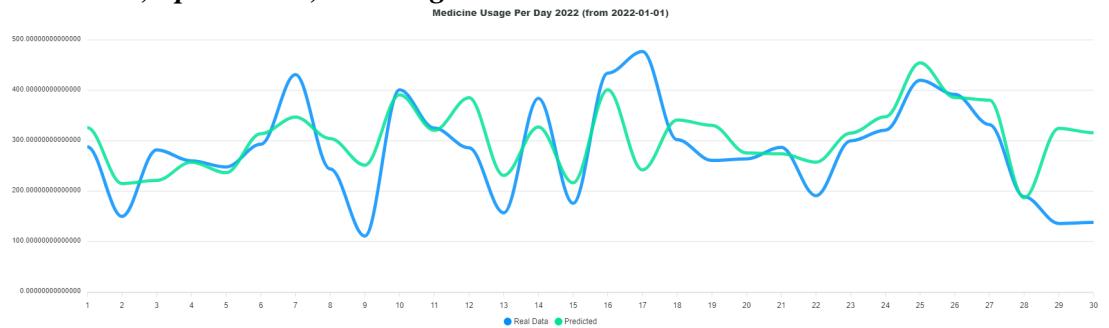


**Gambar 3.216** Perbandingan hasil prediksi dengan data asli dengan konfigurasi *Filter*: 64 & 128, *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.001 dan tanpa lapisan *Max Pooling* untuk forecasting horizon 90 hari

## LAMPIRAN D HASIL PENGUJIAN MODEL LSTM

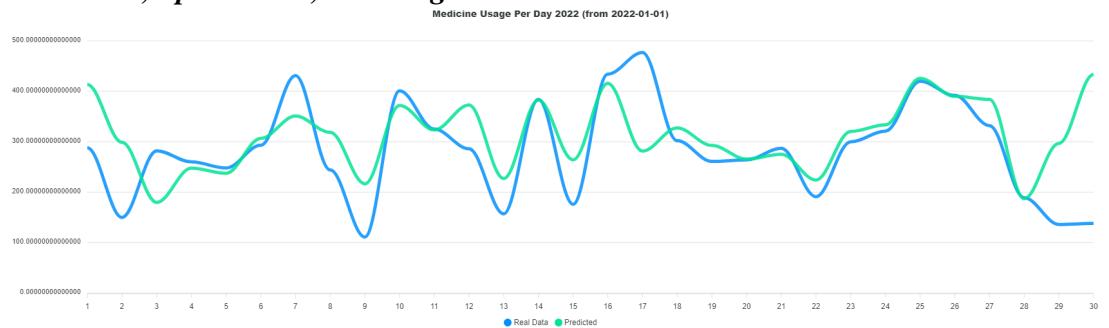
### 4.1 Forecasting Horizon 30 hari

#### 1. Units: 100, Epoch: 100, Learning Rate: 0.1



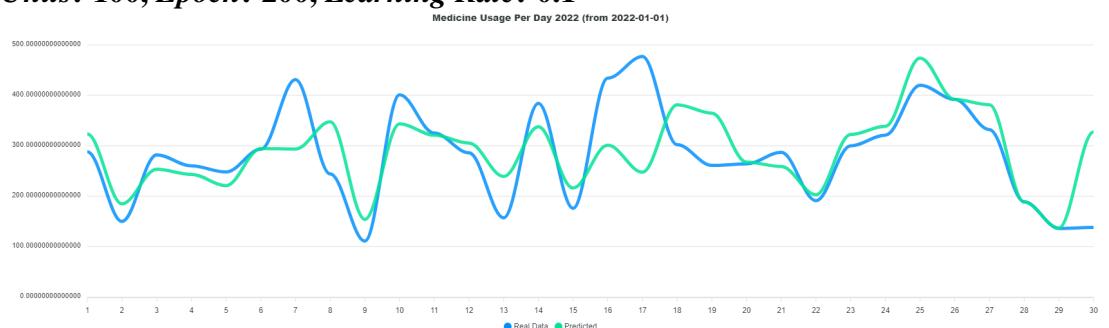
**Gambar 4.1** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units: 100, Epoch: 100, Learning Rate: 0.1* untuk forecasting horizon 30 hari

#### 2. Units: 100, Epoch: 150, Learning Rate: 0.1



**Gambar 4.2** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units: 100, Epoch: 150, Learning Rate: 0.1* untuk forecasting horizon 30 hari

#### 3. Units: 100, Epoch: 200, Learning Rate: 0.1

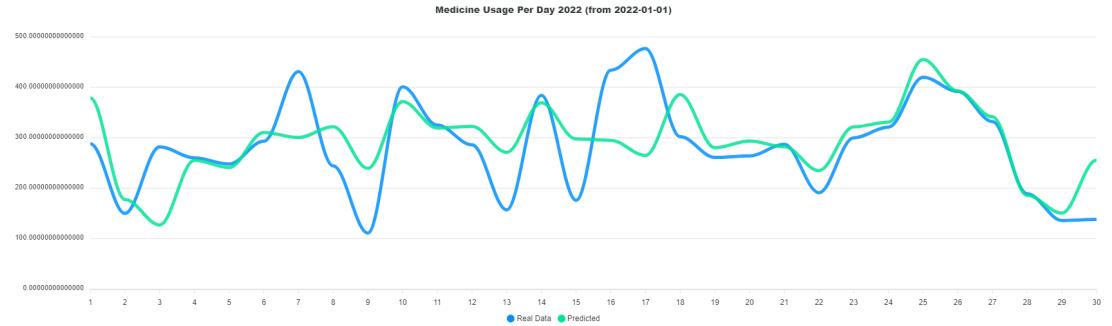


**Gambar 4.3** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units: 100, Epoch: 200, Learning Rate: 0.1* untuk forecasting horizon 30 hari

#### 4. Units: 100, Epoch: 250, Learning Rate: 0.1

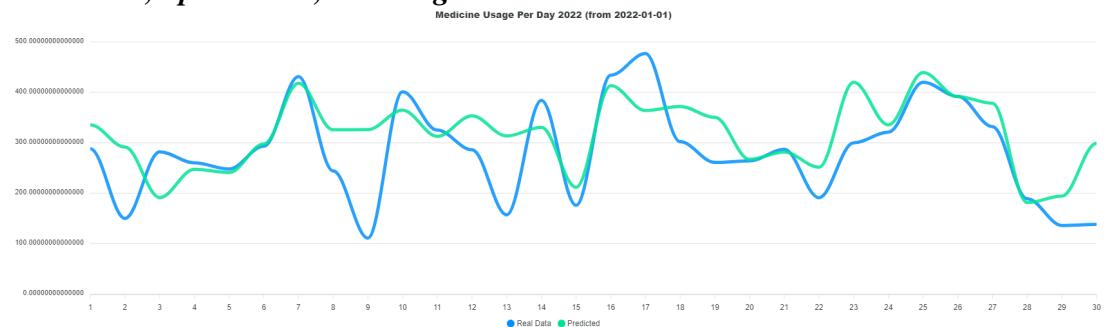
## BAB D Hasil Pengujian Model LSTM

---



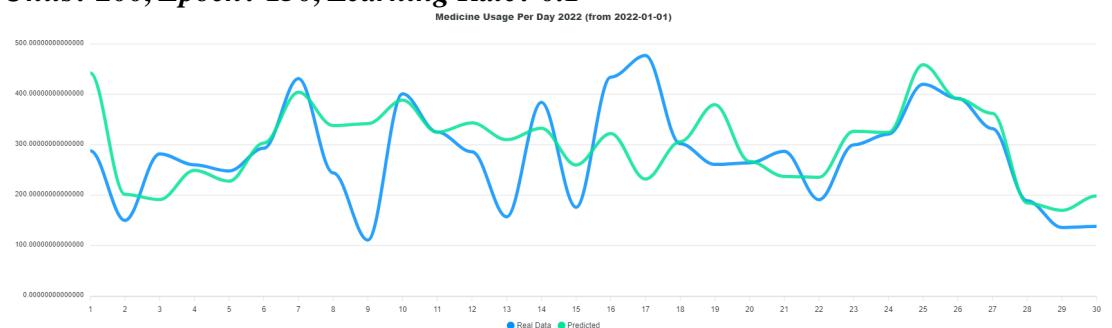
**Gambar 4.4** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.1 untuk forecasting horizon 30 hari

### 5. *Units: 200, Epoch: 100, Learning Rate: 0.1*



**Gambar 4.5** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.1 untuk forecasting horizon 30 hari

### 6. *Units: 200, Epoch: 150, Learning Rate: 0.1*

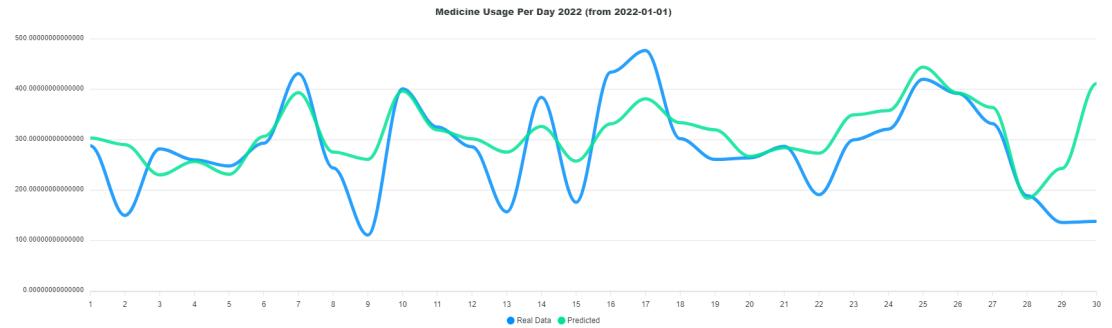


**Gambar 4.6** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.1 untuk forecasting horizon 30 hari

### 7. *Units: 200, Epoch: 200, Learning Rate: 0.1*

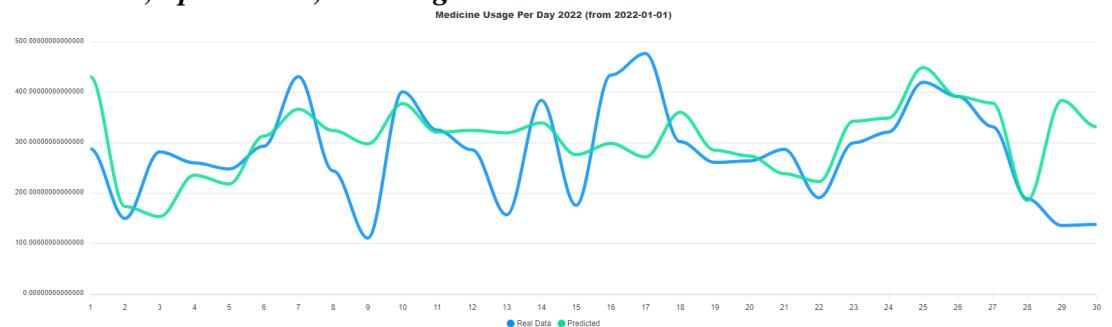
## BAB D Hasil Pengujian Model LSTM

---



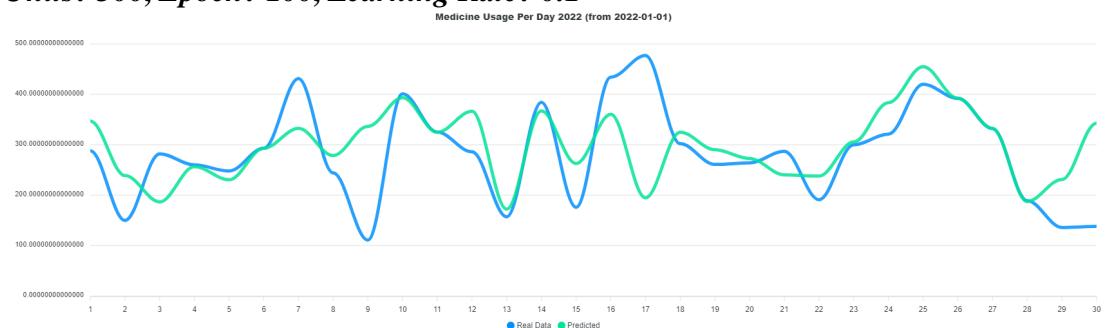
**Gambar 4.7** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.1 untuk forecasting horizon 30 hari

### 8. *Units: 200, Epoch: 250, Learning Rate: 0.1*



**Gambar 4.8** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1 untuk forecasting horizon 30 hari

### 9. *Units: 300, Epoch: 100, Learning Rate: 0.1*

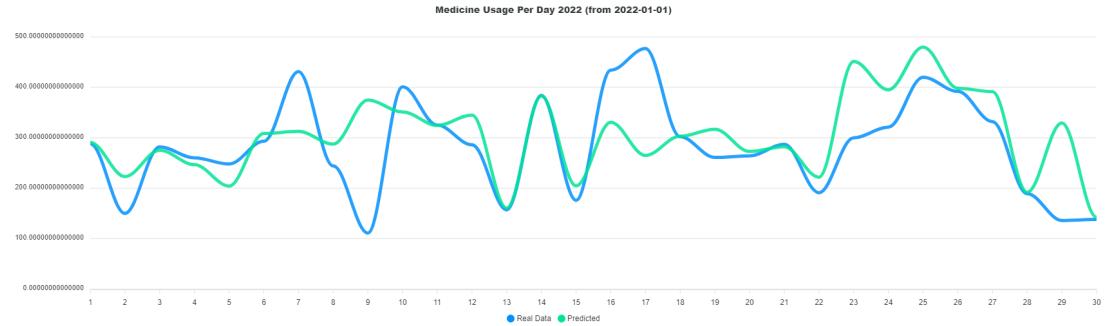


**Gambar 4.9** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1 untuk forecasting horizon 30 hari

### 10. *Units: 300, Epoch: 150, Learning Rate: 0.1*

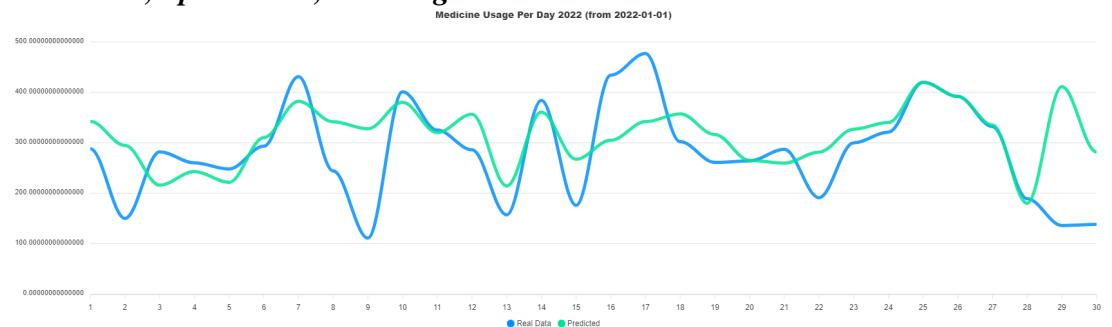
## BAB D Hasil Pengujian Model LSTM

---



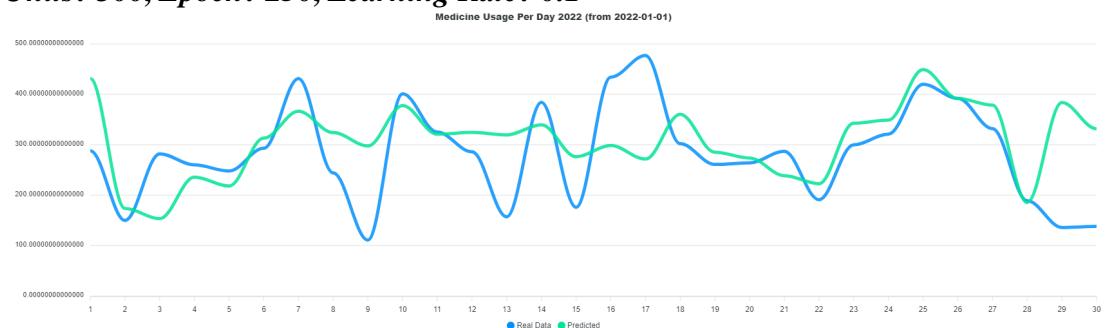
**Gambar 4.10** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1 untuk forecasting horizon 30 hari

### 11. *Units: 300, Epoch: 200, Learning Rate: 0.1*



**Gambar 4.11** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.1 untuk forecasting horizon 30 hari

### 12. *Units: 300, Epoch: 250, Learning Rate: 0.1*

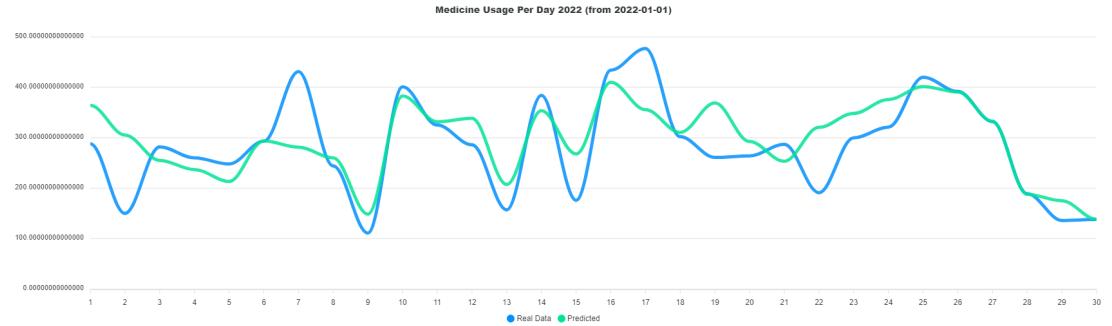


**Gambar 4.12** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.1 untuk forecasting horizon 30 hari

### 13. *Units: 100, Epoch: 100, Learning Rate: 0.01*

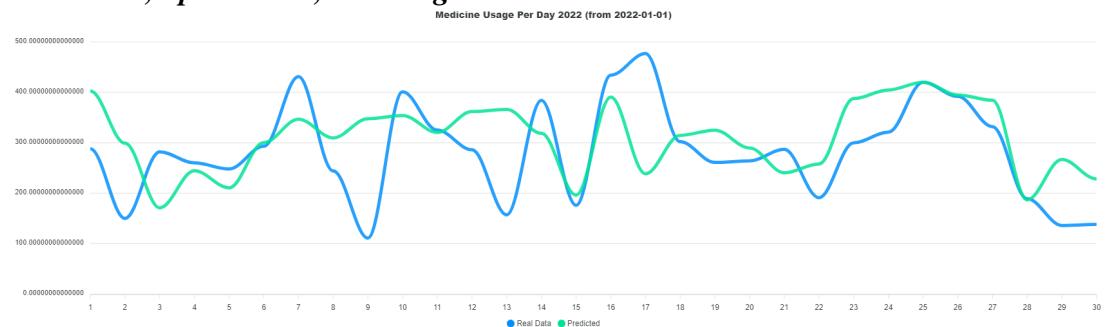
## BAB D Hasil Pengujian Model LSTM

---



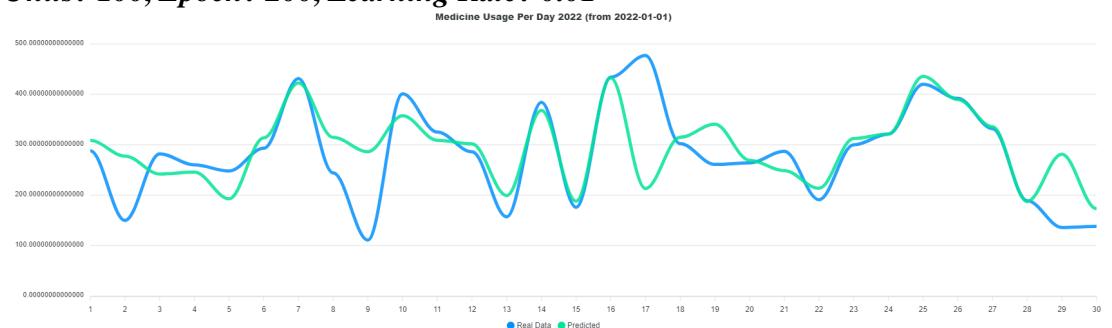
**Gambar 4.13** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.01 untuk forecasting horizon 30 hari

### 14. *Units: 100, Epoch: 150, Learning Rate: 0.01*



**Gambar 4.14** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01 untuk forecasting horizon 30 hari

### 15. *Units: 100, Epoch: 200, Learning Rate: 0.01*

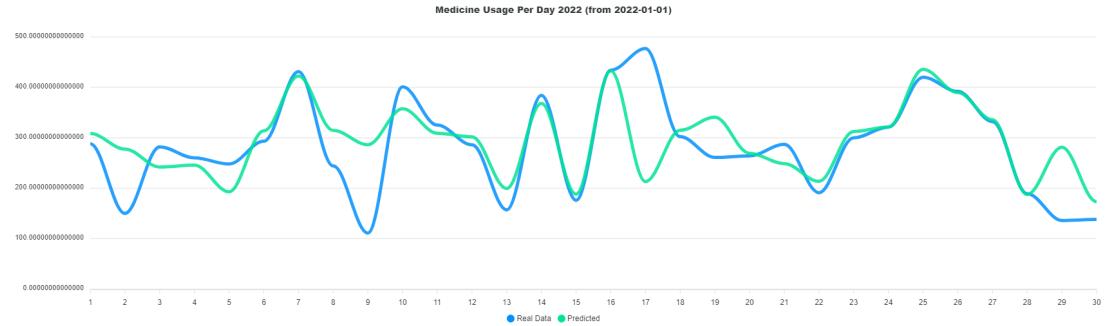


**Gambar 4.15** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01 untuk forecasting horizon 30 hari

### 16. *Units: 100, Epoch: 250, Learning Rate: 0.01*

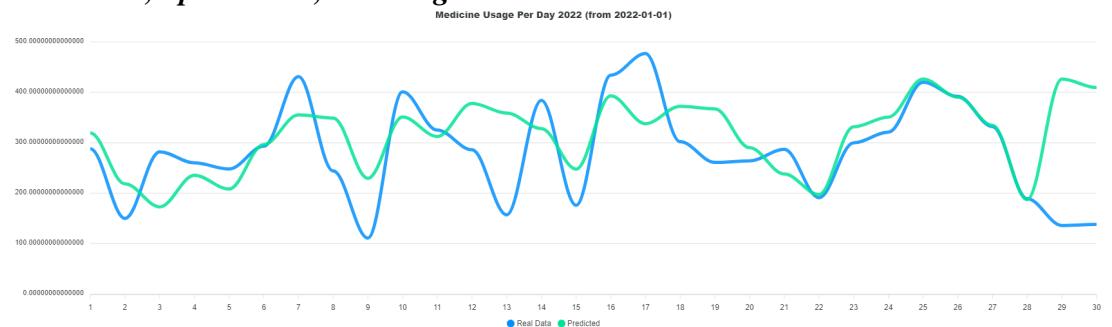
## BAB D Hasil Pengujian Model LSTM

---



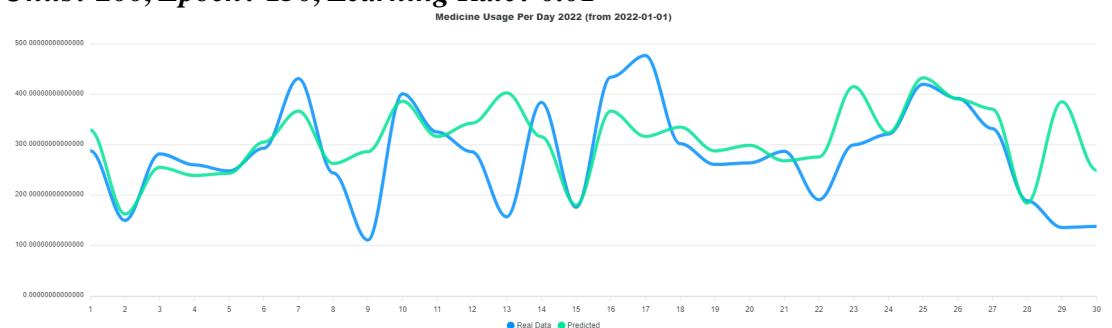
**Gambar 4.16** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01 untuk forecasting horizon 30 hari

### 17. *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.01



**Gambar 4.17** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.01 untuk forecasting horizon 30 hari

### 18. *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.01

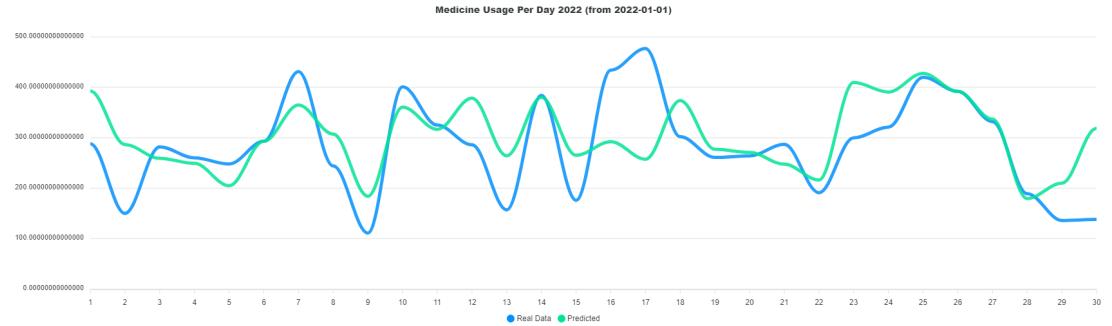


**Gambar 4.18** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.01 untuk forecasting horizon 30 hari

### 19. *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.01

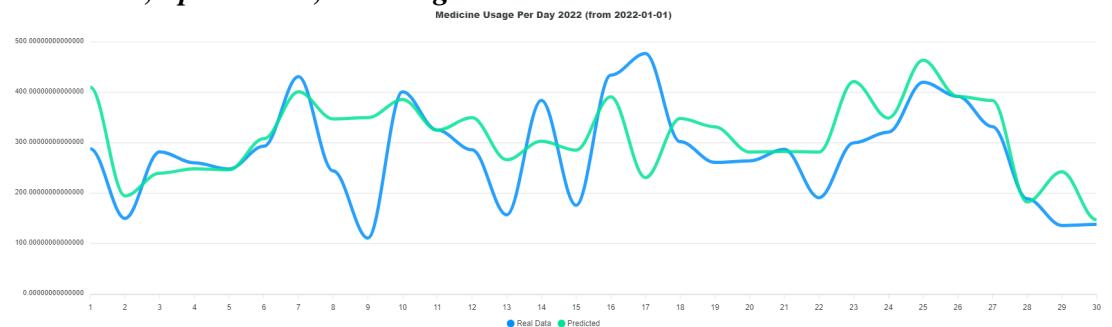
## BAB D Hasil Pengujian Model LSTM

---



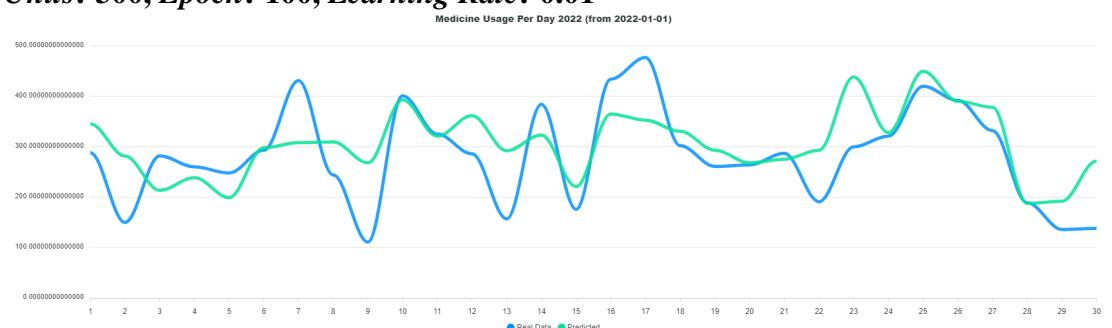
**Gambar 4.19** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.01 untuk forecasting horizon 30 hari

### 20. *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.01



**Gambar 4.20** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.01 untuk forecasting horizon 30 hari

### 21. *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.01

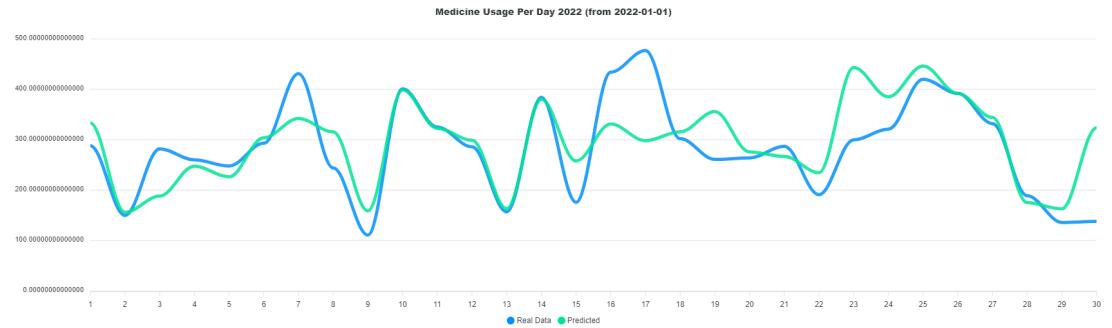


**Gambar 4.21** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.01 untuk forecasting horizon 30 hari

### 22. *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.01

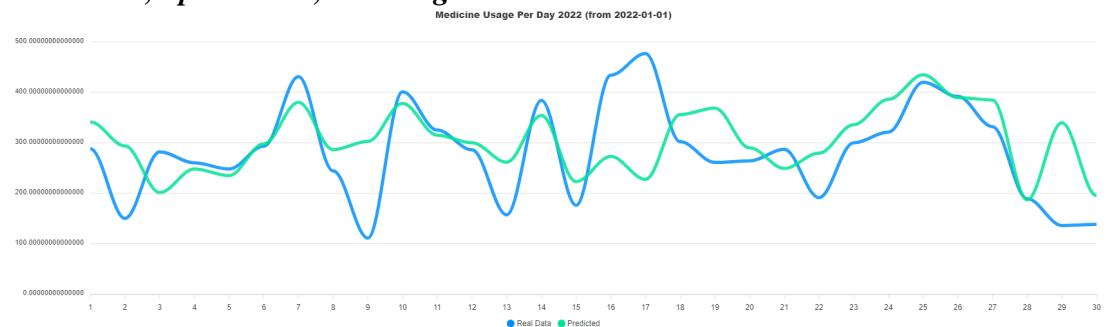
## BAB D Hasil Pengujian Model LSTM

---



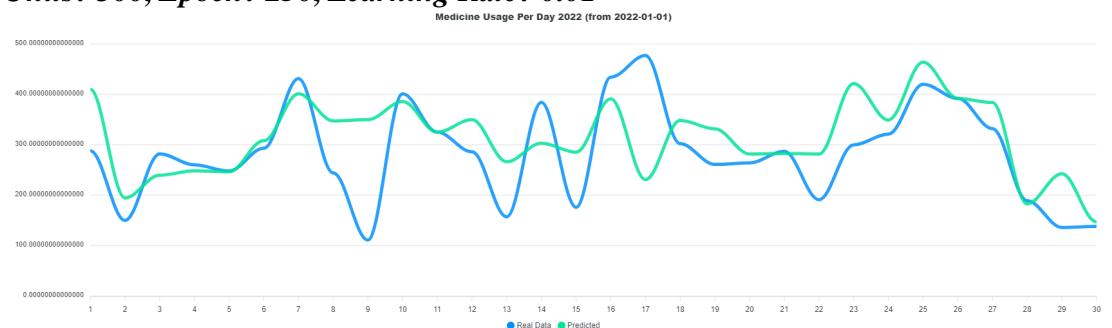
**Gambar 4.22** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.01 untuk forecasting horizon 30 hari

### 23. *Units: 300, Epoch: 200, Learning Rate: 0.01*



**Gambar 4.23** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.01 untuk forecasting horizon 30 hari

### 24. *Units: 300, Epoch: 250, Learning Rate: 0.01*

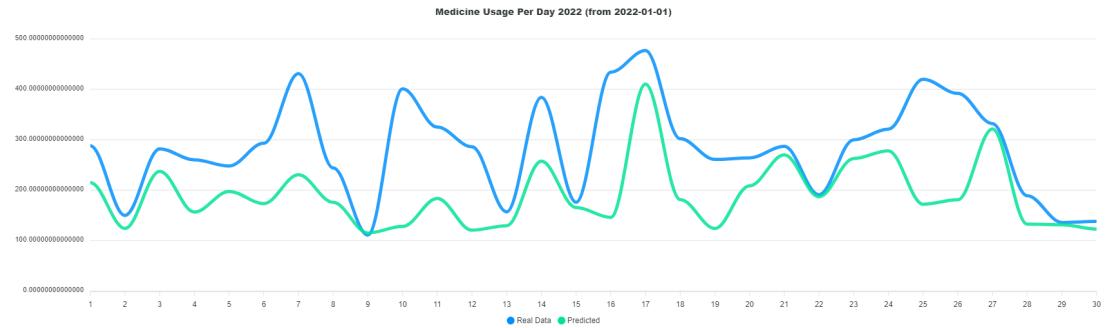


**Gambar 4.24** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.01 untuk forecasting horizon 30 hari

### 25. *Units: 100, Epoch: 100, Learning Rate: 0.001*

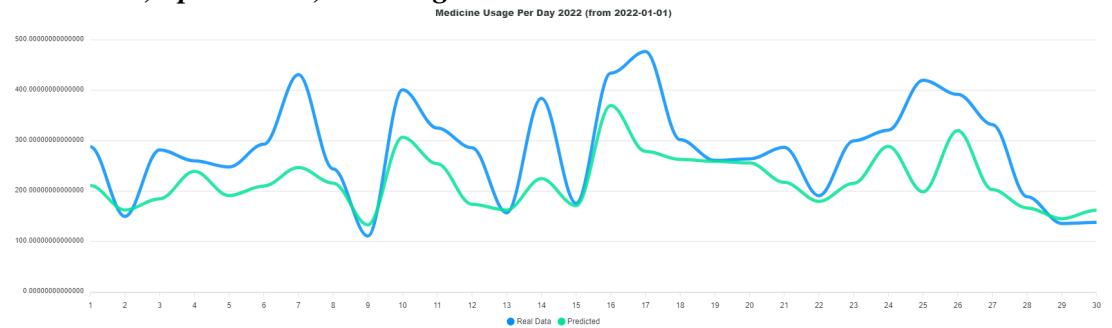
## BAB D Hasil Pengujian Model LSTM

---



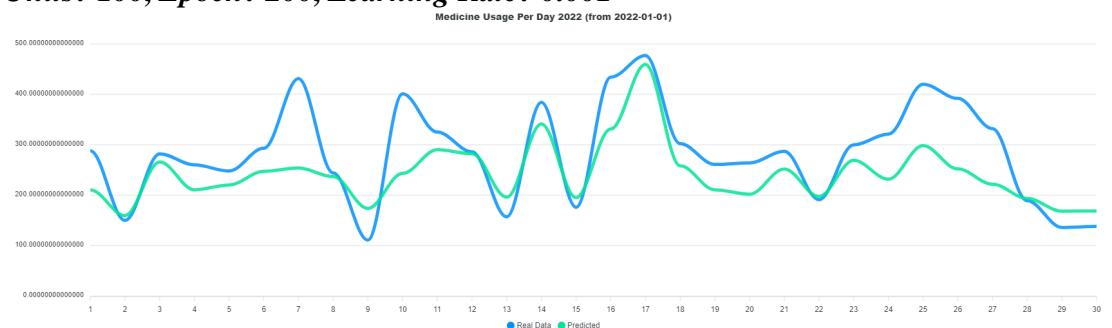
**Gambar 4.25** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.001 untuk forecasting horizon 30 hari

### 26. *Units: 100, Epoch: 150, Learning Rate: 0.001*



**Gambar 4.26** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.001 untuk forecasting horizon 30 hari

### 27. *Units: 100, Epoch: 200, Learning Rate: 0.001*

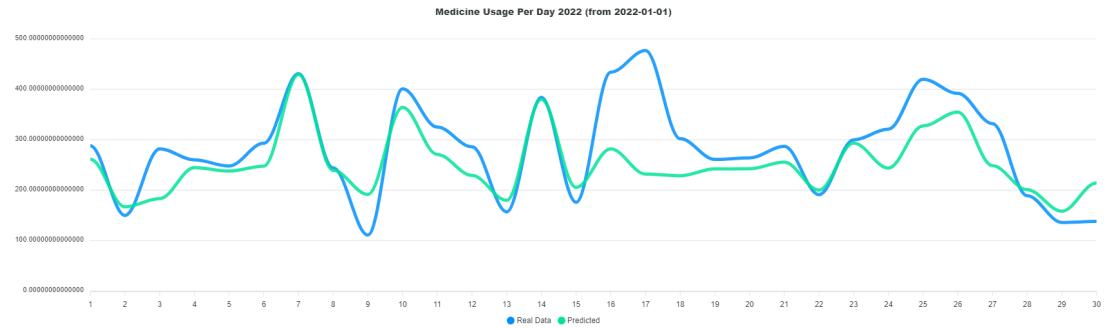


**Gambar 4.27** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001 untuk forecasting horizon 30 hari

### 28. *Units: 100, Epoch: 250, Learning Rate: 0.001*

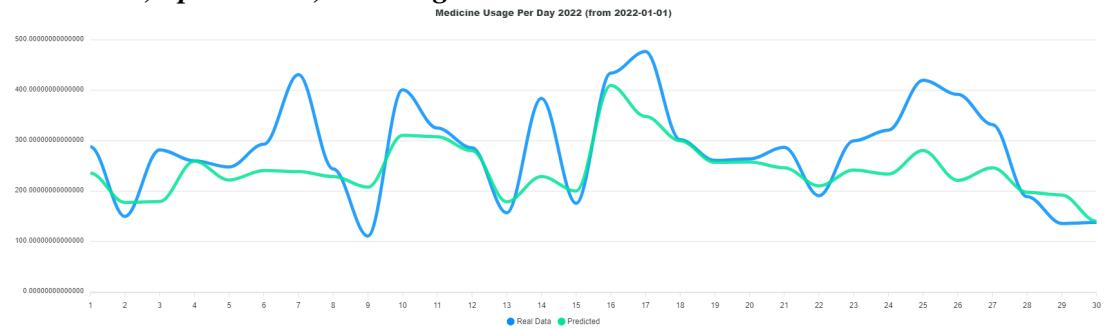
## BAB D Hasil Pengujian Model LSTM

---



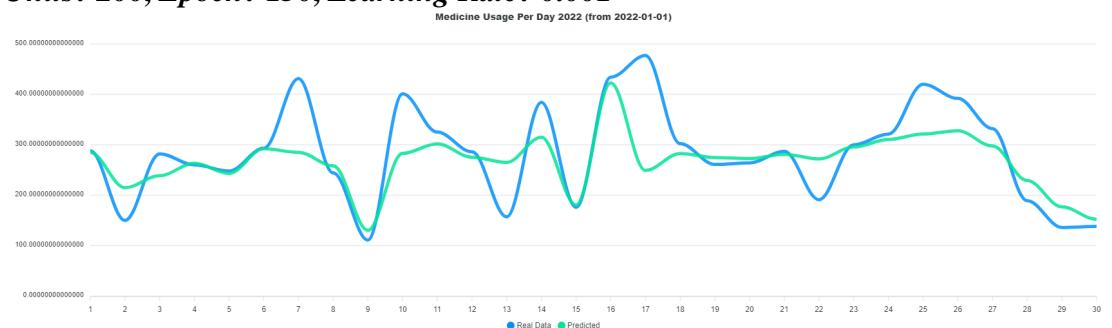
**Gambar 4.28** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.001 untuk forecasting horizon 30 hari

### 29. *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001



**Gambar 4.29** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001 untuk forecasting horizon 30 hari

### 30. *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001

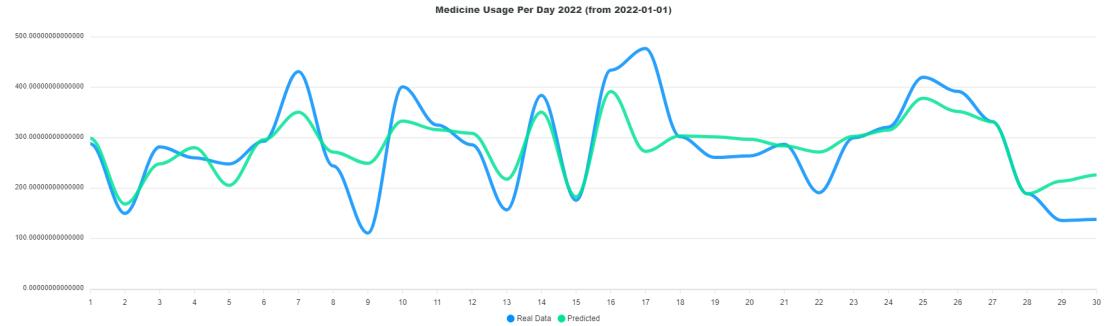


**Gambar 4.30** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001 untuk forecasting horizon 30 hari

### 31. *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001

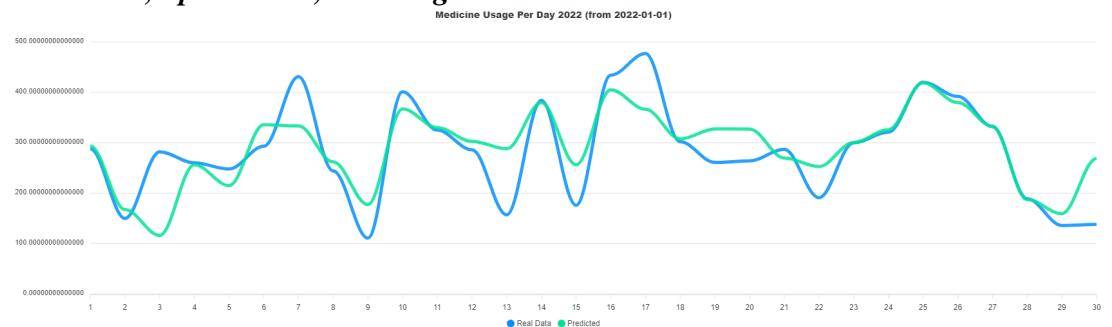
## BAB D Hasil Pengujian Model LSTM

---



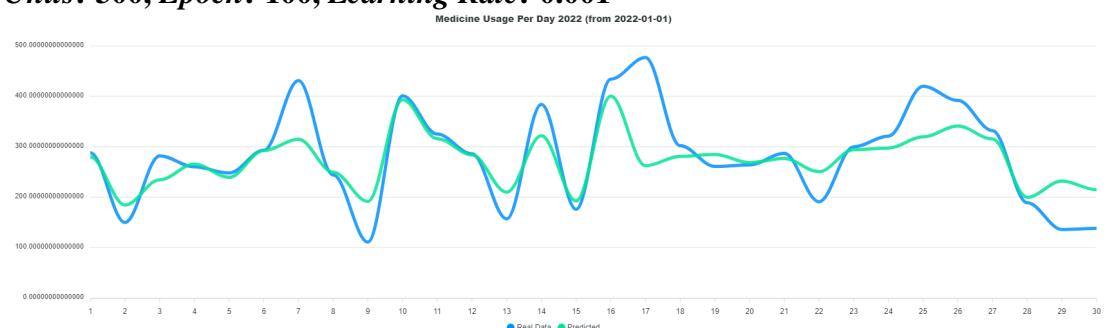
**Gambar 4.31** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001 untuk forecasting horizon 30 hari

### 32. *Units: 200, Epoch: 250, Learning Rate: 0.001*



**Gambar 4.32** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.001 untuk forecasting horizon 30 hari

### 33. *Units: 300, Epoch: 100, Learning Rate: 0.001*

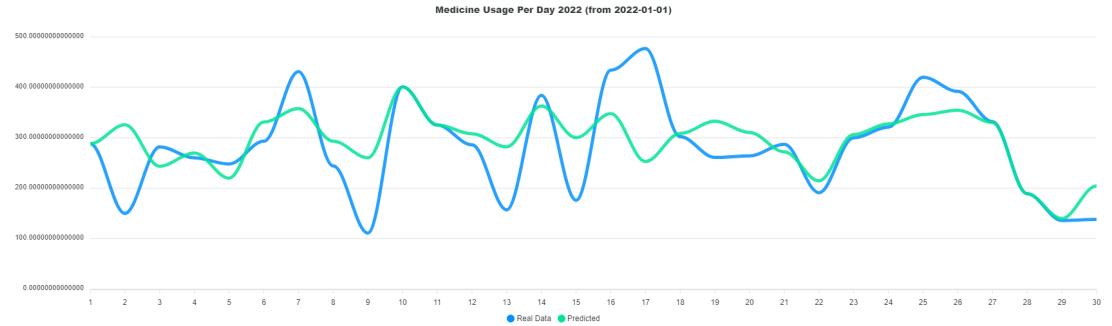


**Gambar 4.33** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.001 untuk forecasting horizon 30 hari

### 34. *Units: 300, Epoch: 150, Learning Rate: 0.001*

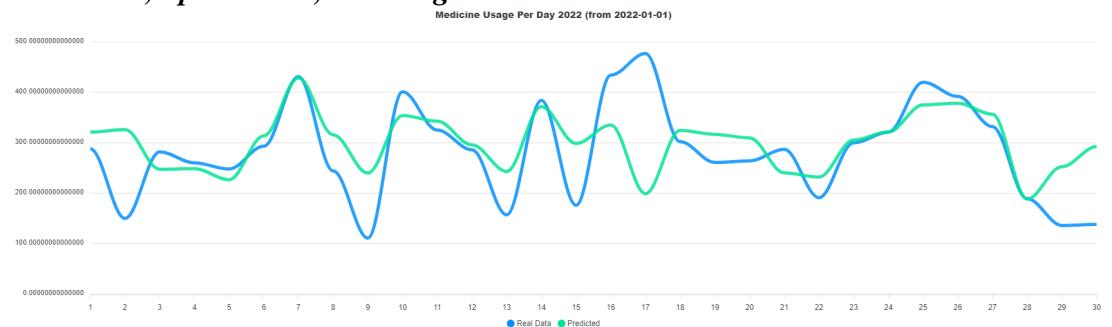
## BAB D Hasil Pengujian Model LSTM

---



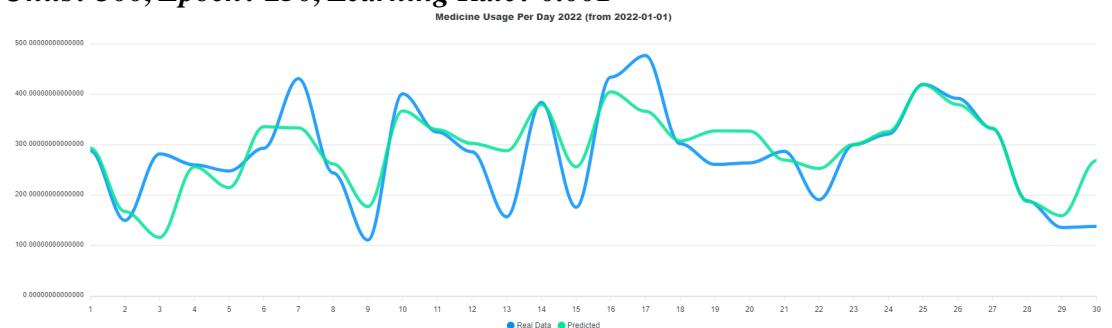
**Gambar 4.34** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.001 untuk forecasting horizon 30 hari

### 35. *Units: 300, Epoch: 200, Learning Rate: 0.001*



**Gambar 4.35** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.001 untuk forecasting horizon 30 hari

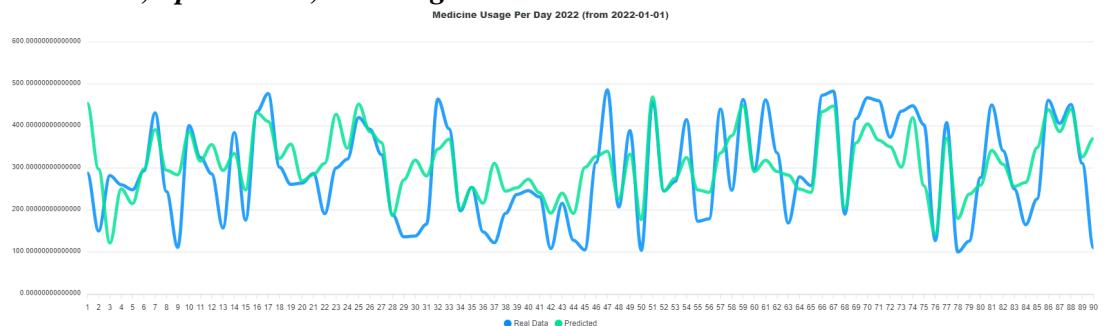
### 36. *Units: 300, Epoch: 250, Learning Rate: 0.001*



**Gambar 4.36** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.001 untuk forecasting horizon 30 hari

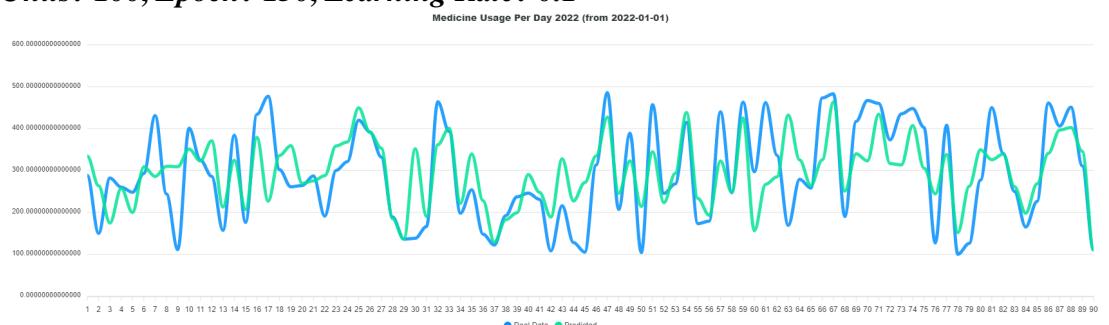
### 4.2 Forecasting Horizon 90 hari

#### 1. Units: 100, Epoch: 100, Learning Rate: 0.1



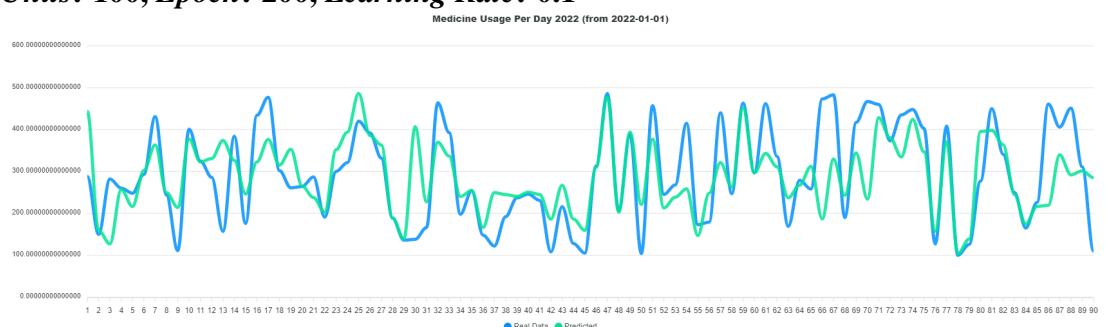
**Gambar 4.37** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units: 100, Epoch: 100, Learning Rate: 0.1* untuk forecasting horizon 90 hari

#### 2. Units: 100, Epoch: 150, Learning Rate: 0.1



**Gambar 4.38** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units: 100, Epoch: 150, Learning Rate: 0.1* untuk forecasting horizon 90 hari

#### 3. Units: 100, Epoch: 200, Learning Rate: 0.1

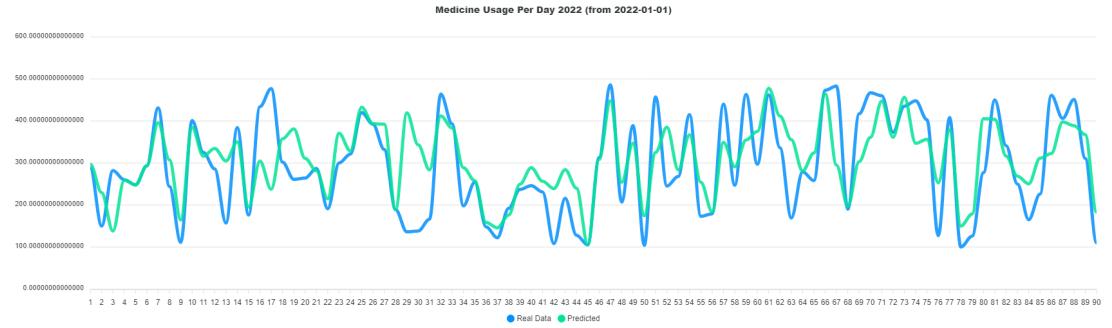


**Gambar 4.39** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units: 100, Epoch: 200, Learning Rate: 0.1* untuk forecasting horizon 90 hari

#### 4. Units: 100, Epoch: 250, Learning Rate: 0.1

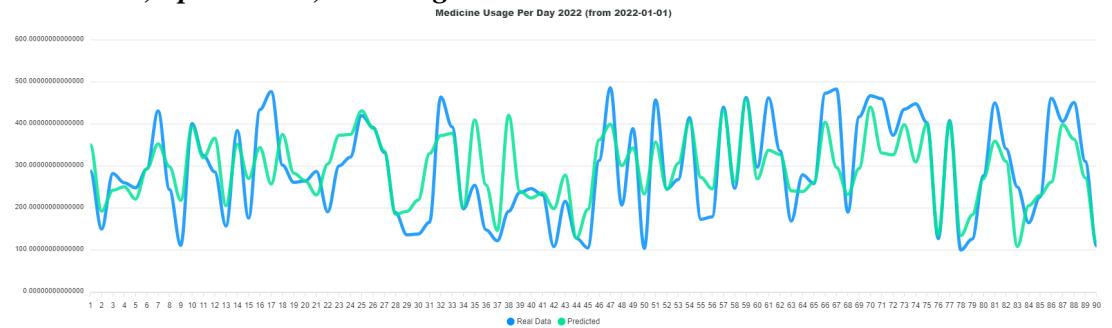
## BAB D Hasil Pengujian Model LSTM

---



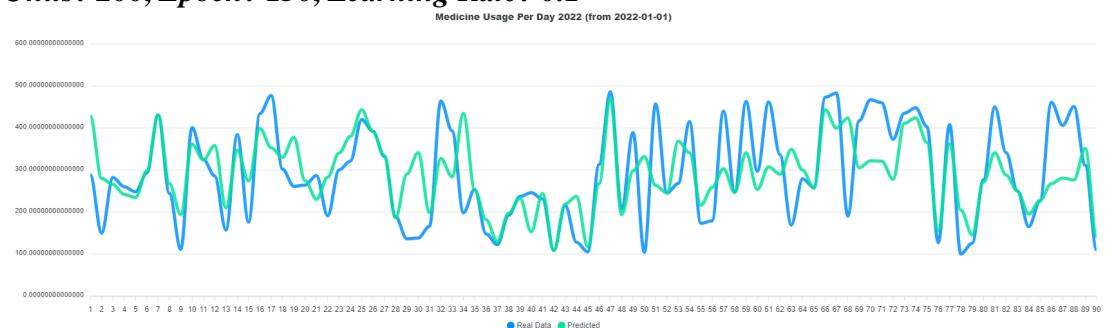
**Gambar 4.40** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.1 untuk forecasting horizon 90 hari

### 5. *Units: 200, Epoch: 100, Learning Rate: 0.1*



**Gambar 4.41** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.1 untuk forecasting horizon 90 hari

### 6. *Units: 200, Epoch: 150, Learning Rate: 0.1*

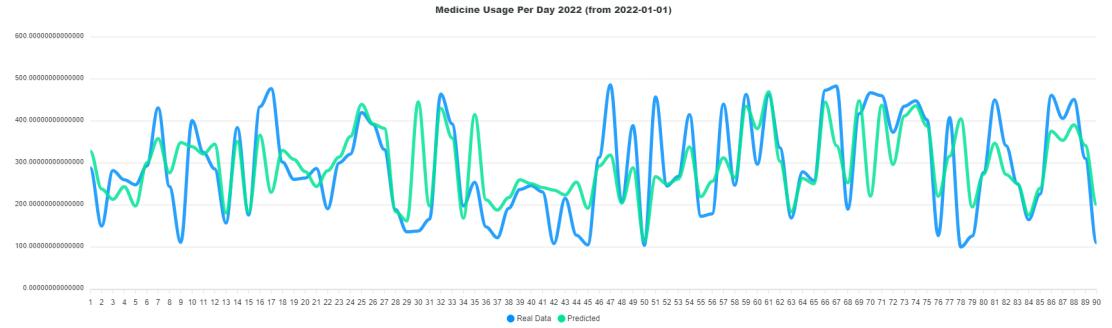


**Gambar 4.42** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.1 untuk forecasting horizon 90 hari

### 7. *Units: 200, Epoch: 200, Learning Rate: 0.1*

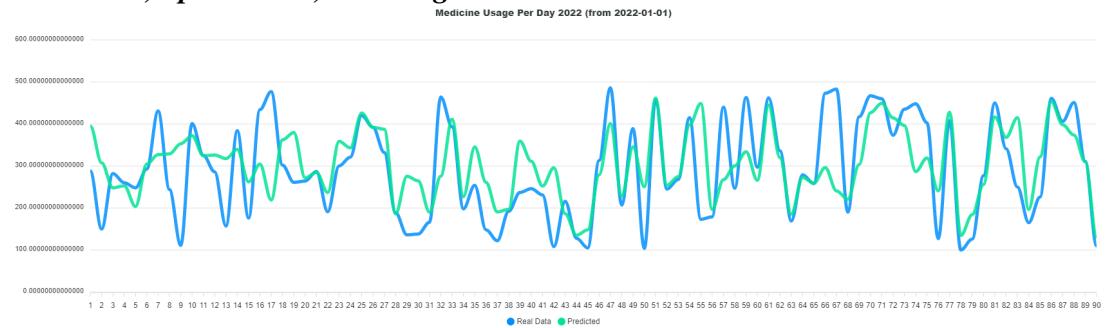
## BAB D Hasil Pengujian Model LSTM

---



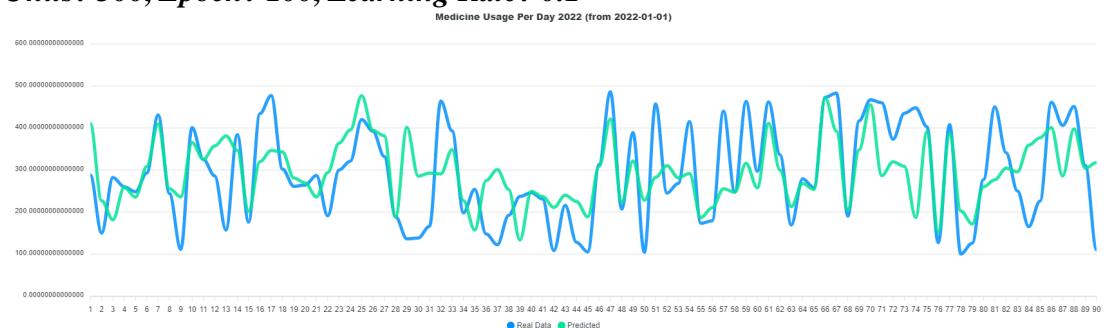
**Gambar 4.43** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.1 untuk forecasting horizon 90 hari

### 8. *Units: 200, Epoch: 250, Learning Rate: 0.1*



**Gambar 4.44** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.1 untuk forecasting horizon 90 hari

### 9. *Units: 300, Epoch: 100, Learning Rate: 0.1*

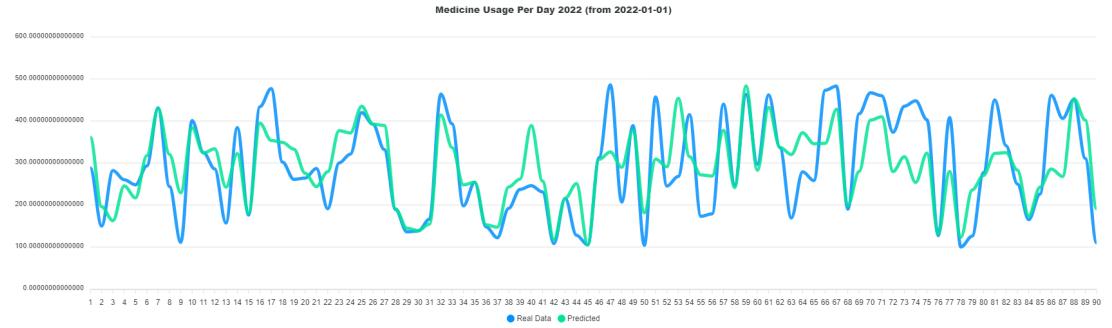


**Gambar 4.45** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.1 untuk forecasting horizon 90 hari

### 10. *Units: 300, Epoch: 150, Learning Rate: 0.1*

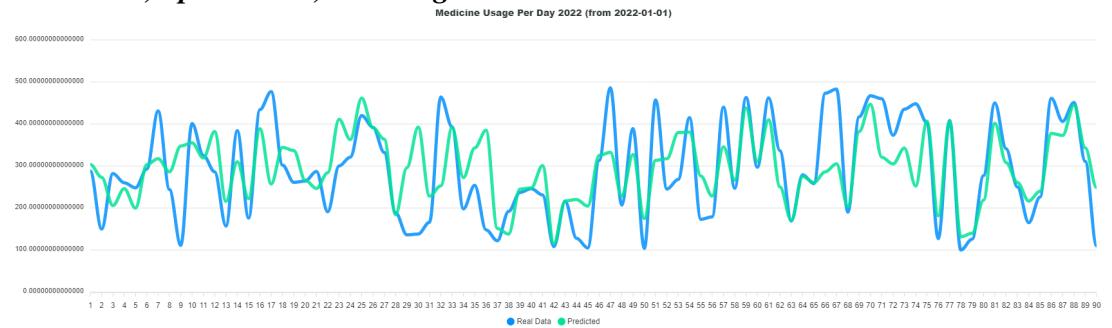
## BAB D Hasil Pengujian Model LSTM

---



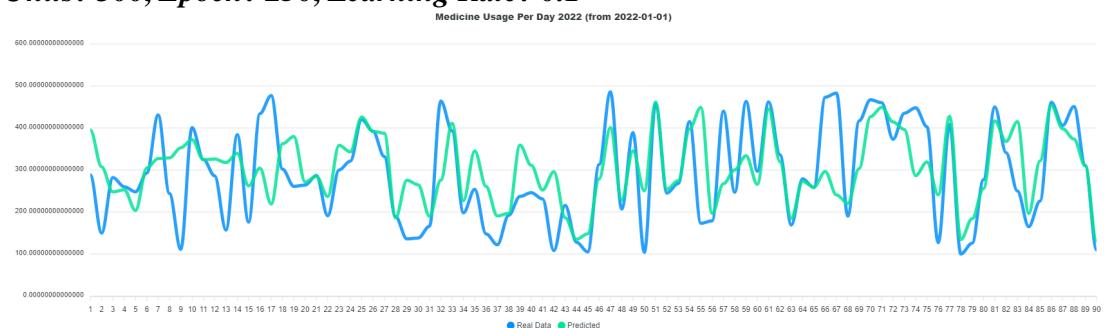
**Gambar 4.46** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.1 untuk forecasting horizon 90 hari

### 11. *Units: 300, Epoch: 200, Learning Rate: 0.1*



**Gambar 4.47** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.1 untuk forecasting horizon 90 hari

### 12. *Units: 300, Epoch: 250, Learning Rate: 0.1*

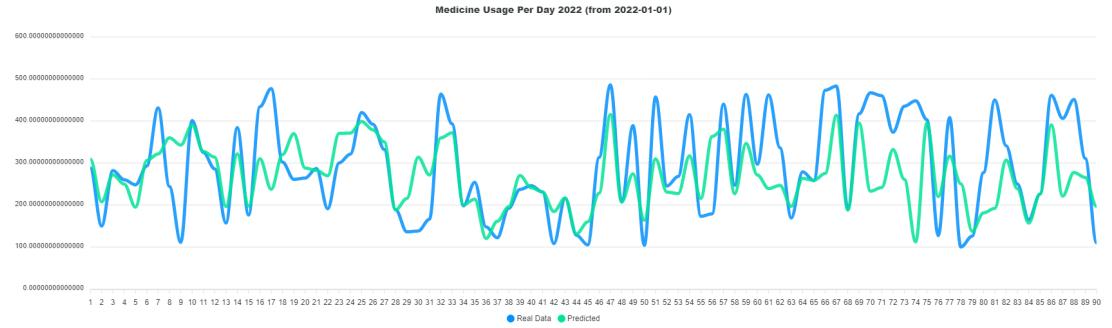


**Gambar 4.48** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.1 untuk forecasting horizon 90 hari

### 13. *Units: 100, Epoch: 100, Learning Rate: 0.01*

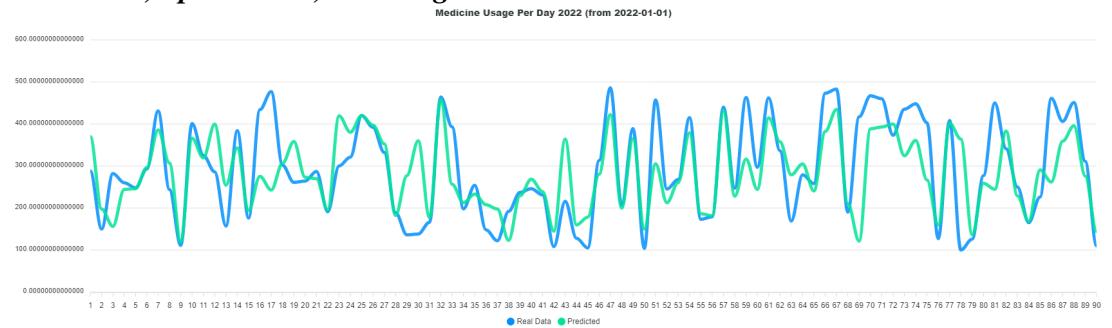
## BAB D Hasil Pengujian Model LSTM

---



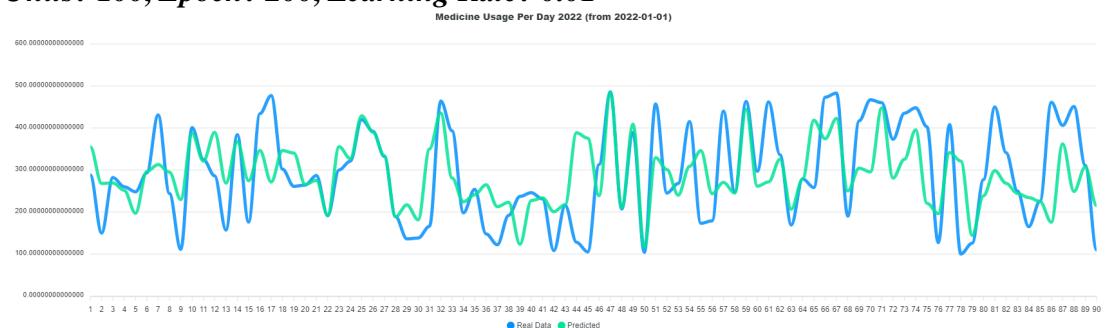
**Gambar 4.49** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.01 untuk forecasting horizon 90 hari

### 14. *Units: 100, Epoch: 150, Learning Rate: 0.01*



**Gambar 4.50** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.01 untuk forecasting horizon 90 hari

### 15. *Units: 100, Epoch: 200, Learning Rate: 0.01*

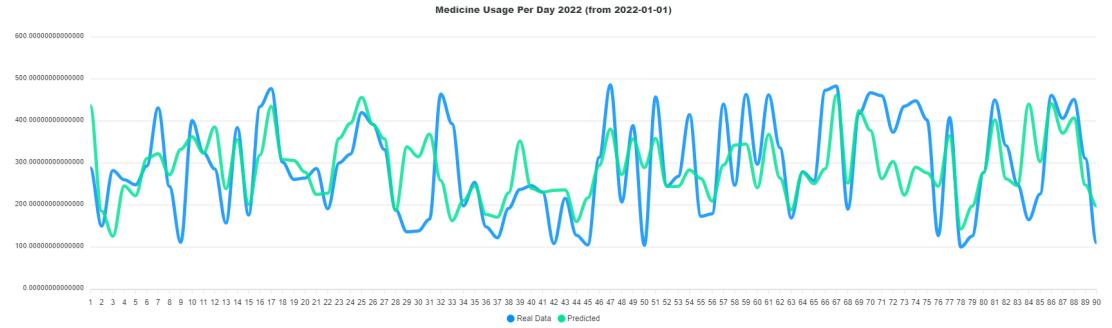


**Gambar 4.51** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.01 untuk forecasting horizon 90 hari

### 16. *Units: 100, Epoch: 250, Learning Rate: 0.01*

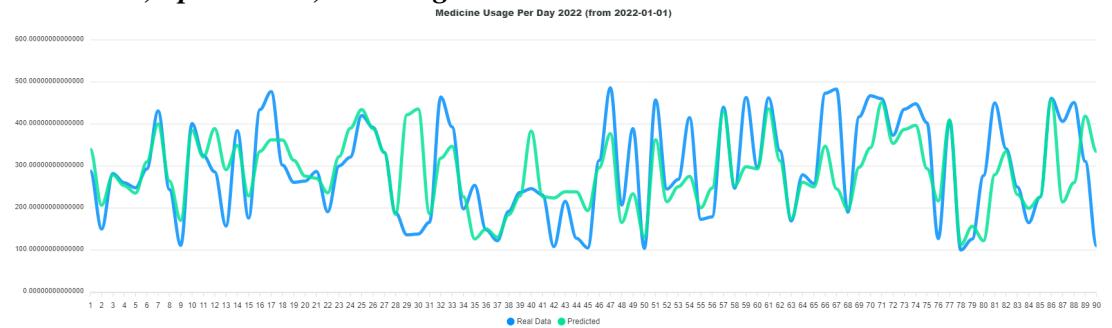
## BAB D Hasil Pengujian Model LSTM

---



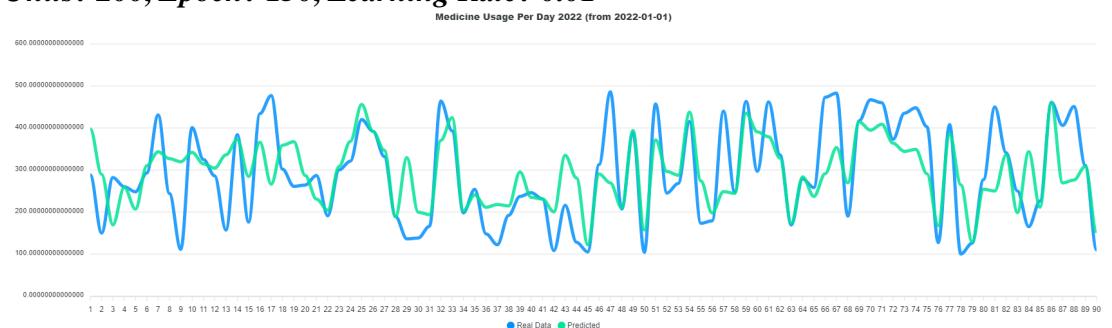
**Gambar 4.52** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.01 untuk forecasting horizon 90 hari

### 17. *Units: 200, Epoch: 100, Learning Rate: 0.01*



**Gambar 4.53** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.01 untuk forecasting horizon 90 hari

### 18. *Units: 200, Epoch: 150, Learning Rate: 0.01*

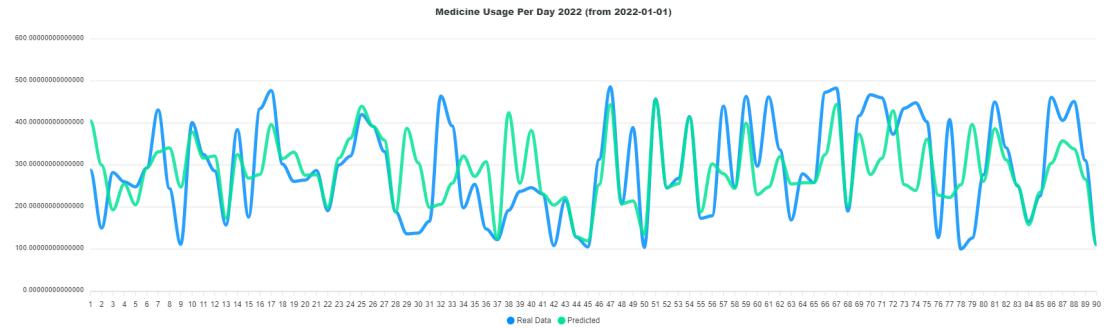


**Gambar 4.54** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.01 untuk forecasting horizon 90 hari

### 19. *Units: 200, Epoch: 200, Learning Rate: 0.01*

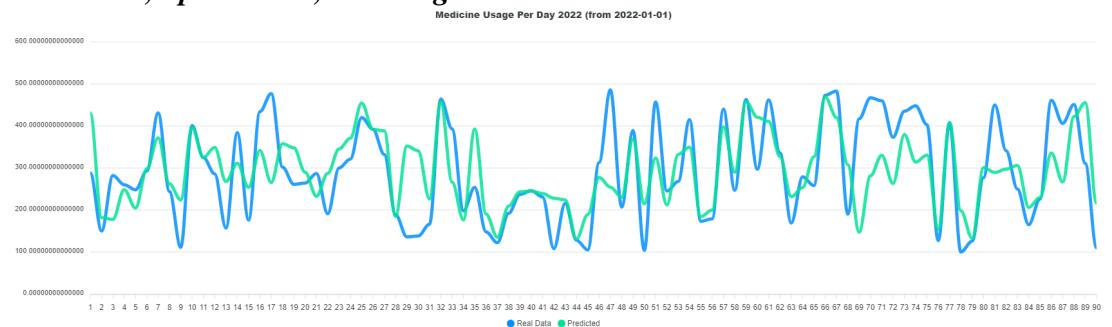
## BAB D Hasil Pengujian Model LSTM

---



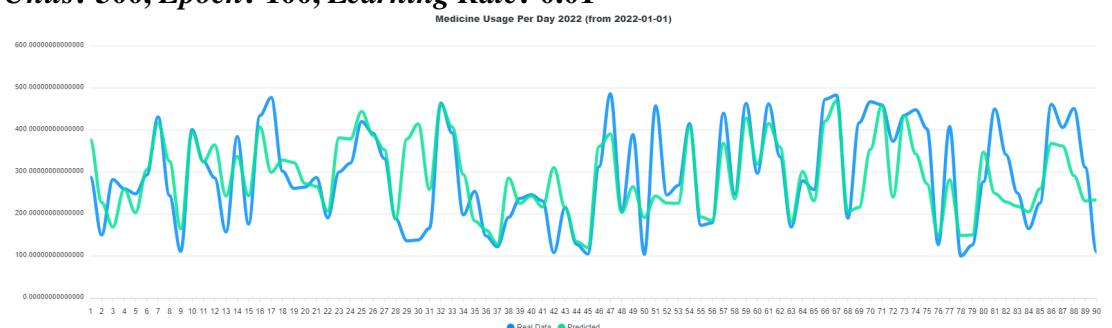
**Gambar 4.55** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.01 untuk forecasting horizon 90 hari

### 20. *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.01



**Gambar 4.56** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.01 untuk forecasting horizon 90 hari

### 21. *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.01

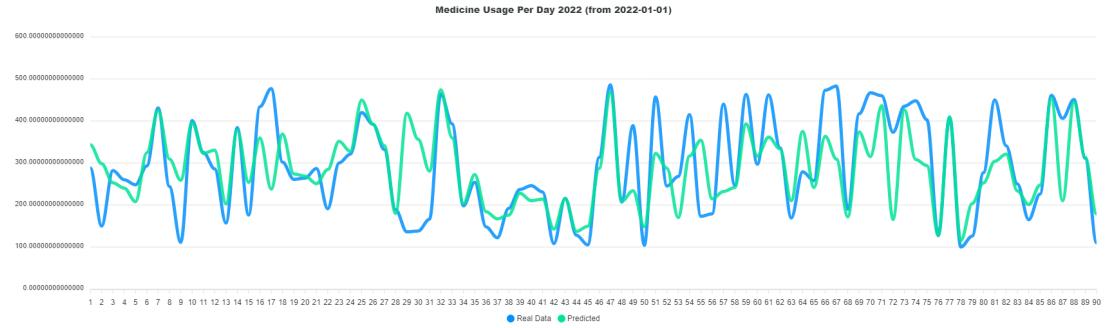


**Gambar 4.57** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.01 untuk forecasting horizon 90 hari

### 22. *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.01

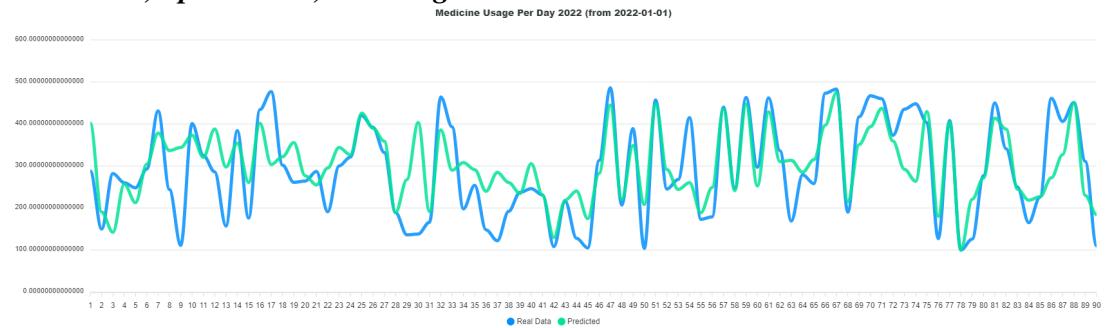
## BAB D Hasil Pengujian Model LSTM

---



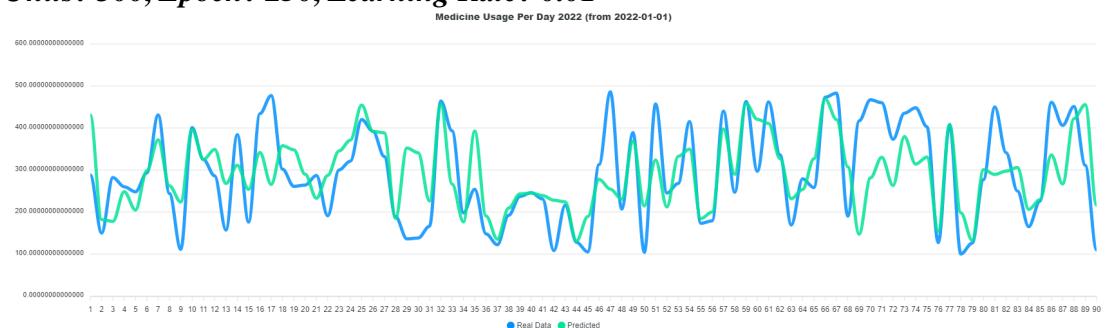
**Gambar 4.58** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.01 untuk forecasting horizon 90 hari

### 23. *Units: 300, Epoch: 200, Learning Rate: 0.01*



**Gambar 4.59** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.01 untuk forecasting horizon 90 hari

### 24. *Units: 300, Epoch: 250, Learning Rate: 0.01*

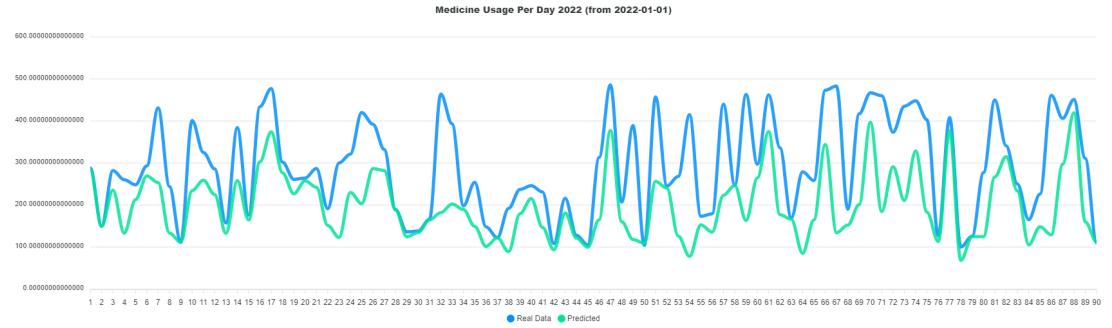


**Gambar 4.60** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.01 untuk forecasting horizon 90 hari

### 25. *Units: 100, Epoch: 100, Learning Rate: 0.001*

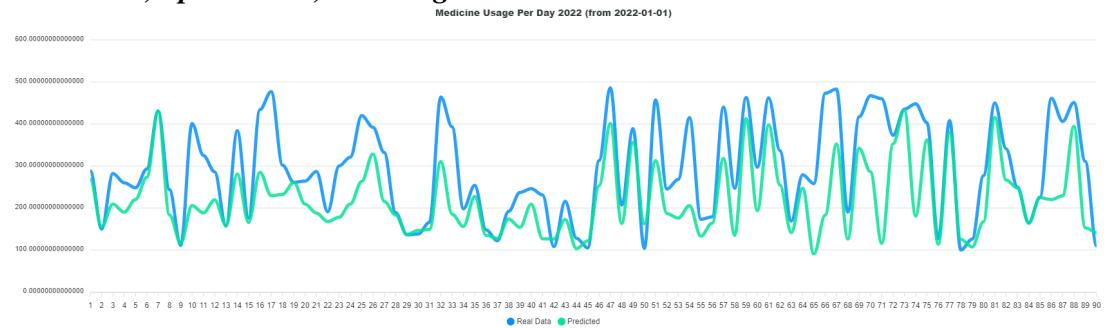
## BAB D Hasil Pengujian Model LSTM

---



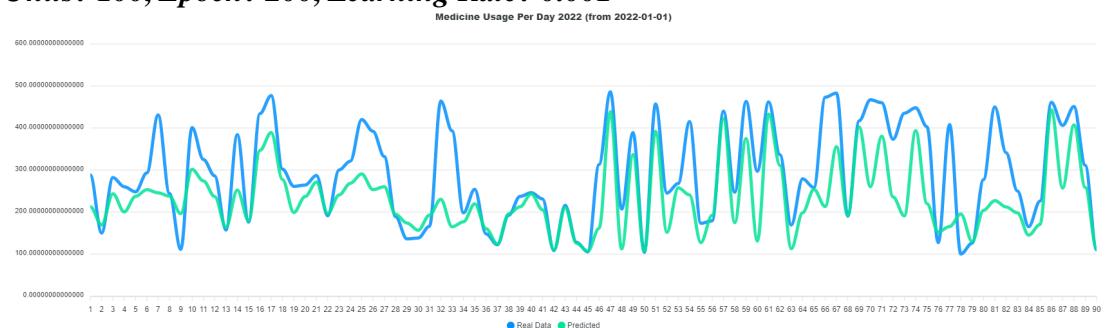
**Gambar 4.61** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 100, *Epoch*: 100, *Learning Rate*: 0.001 untuk forecasting horizon 90 hari

### 26. *Units: 100, Epoch: 150, Learning Rate: 0.001*



**Gambar 4.62** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 100, *Epoch*: 150, *Learning Rate*: 0.001 untuk forecasting horizon 90 hari

### 27. *Units: 100, Epoch: 200, Learning Rate: 0.001*

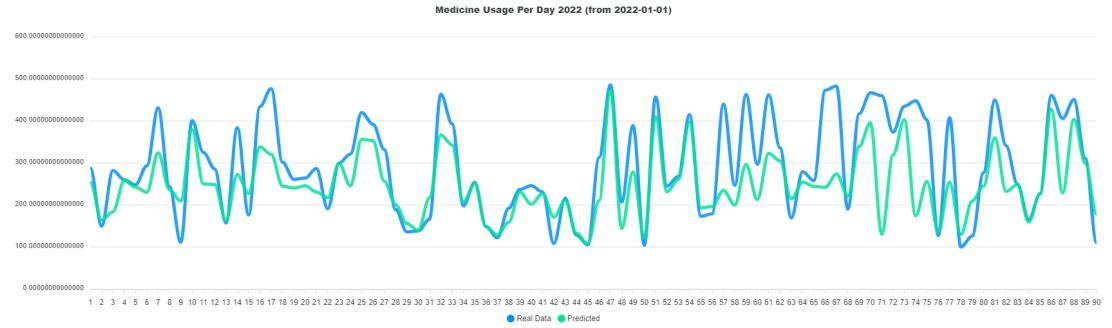


**Gambar 4.63** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 100, *Epoch*: 200, *Learning Rate*: 0.001 untuk forecasting horizon 90 hari

### 28. *Units: 100, Epoch: 250, Learning Rate: 0.001*

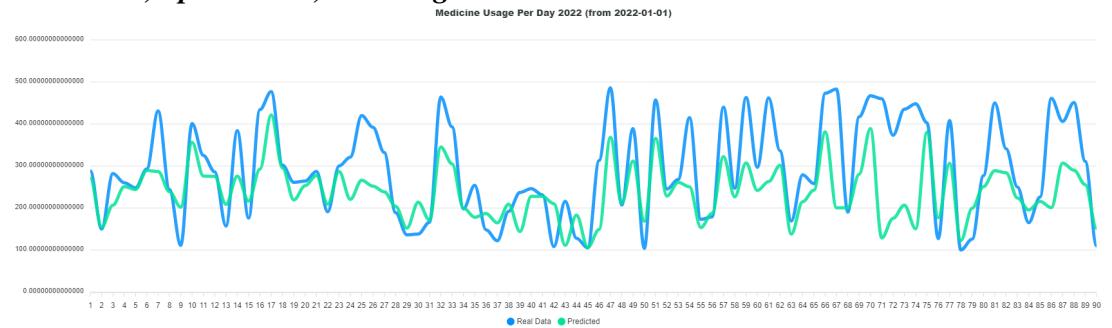
## BAB D Hasil Pengujian Model LSTM

---



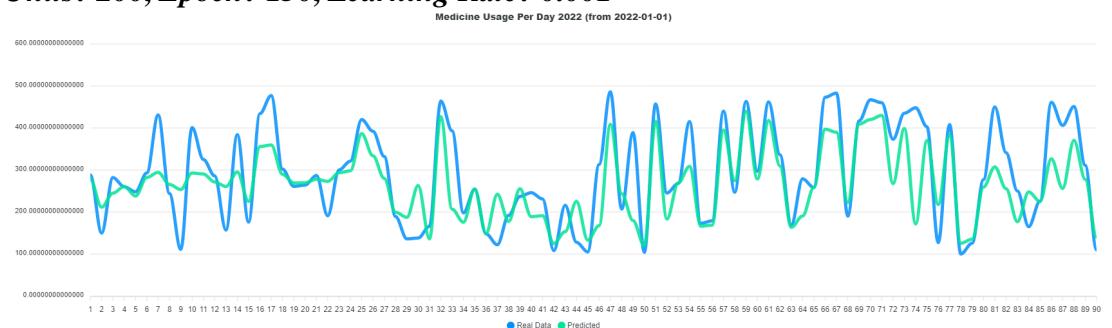
**Gambar 4.64** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 100, *Epoch*: 250, *Learning Rate*: 0.001 untuk forecasting horizon 90 hari

### 29. *Units: 200, Epoch: 100, Learning Rate: 0.001*



**Gambar 4.65** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 100, *Learning Rate*: 0.001 untuk forecasting horizon 90 hari

### 30. *Units: 200, Epoch: 150, Learning Rate: 0.001*

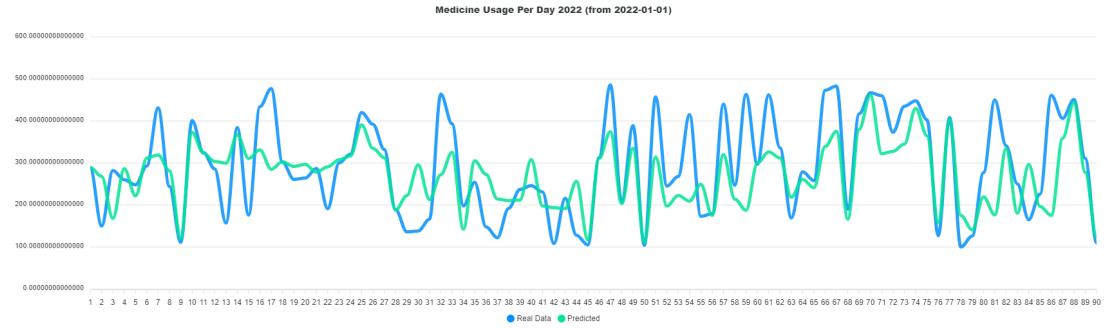


**Gambar 4.66** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 150, *Learning Rate*: 0.001 untuk forecasting horizon 90 hari

### 31. *Units: 200, Epoch: 200, Learning Rate: 0.001*

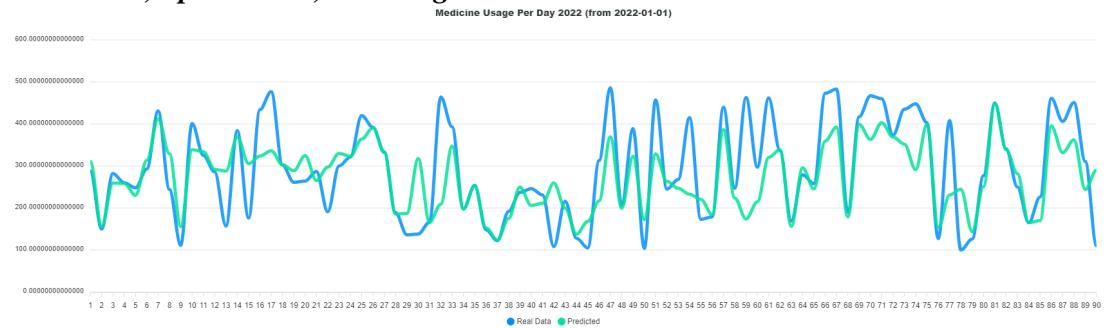
## BAB D Hasil Pengujian Model LSTM

---



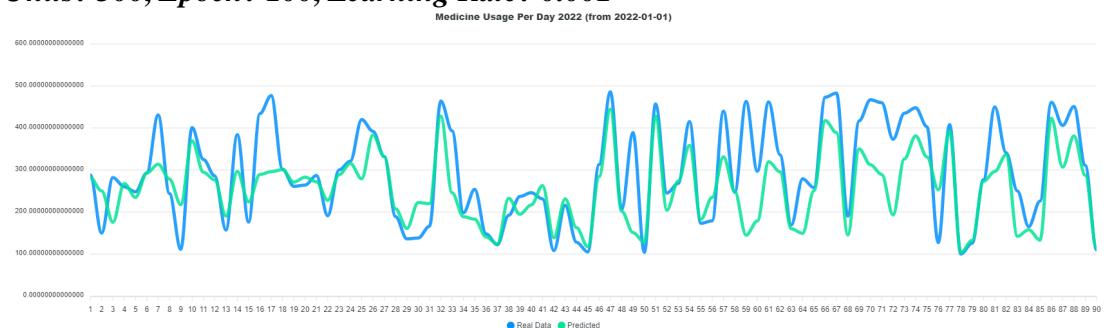
**Gambar 4.67** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 200, *Learning Rate*: 0.001 untuk forecasting horizon 90 hari

### 32. *Units: 200, Epoch: 250, Learning Rate: 0.001*



**Gambar 4.68** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 200, *Epoch*: 250, *Learning Rate*: 0.001 untuk forecasting horizon 90 hari

### 33. *Units: 300, Epoch: 100, Learning Rate: 0.001*

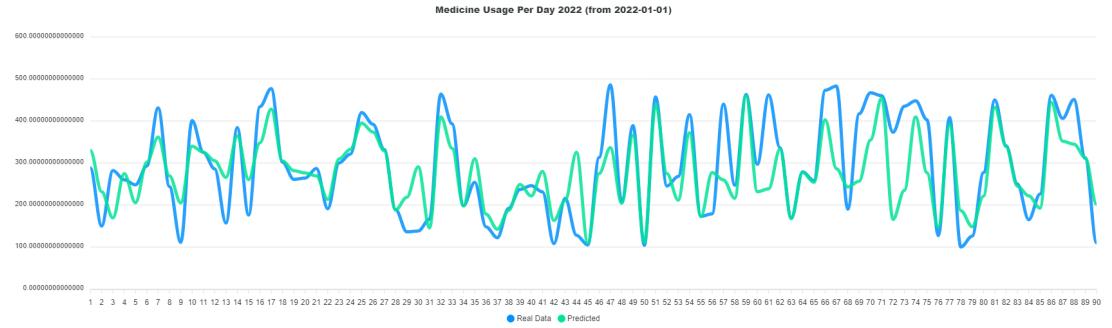


**Gambar 4.69** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 100, *Learning Rate*: 0.001 untuk forecasting horizon 90 hari

### 34. *Units: 300, Epoch: 150, Learning Rate: 0.001*

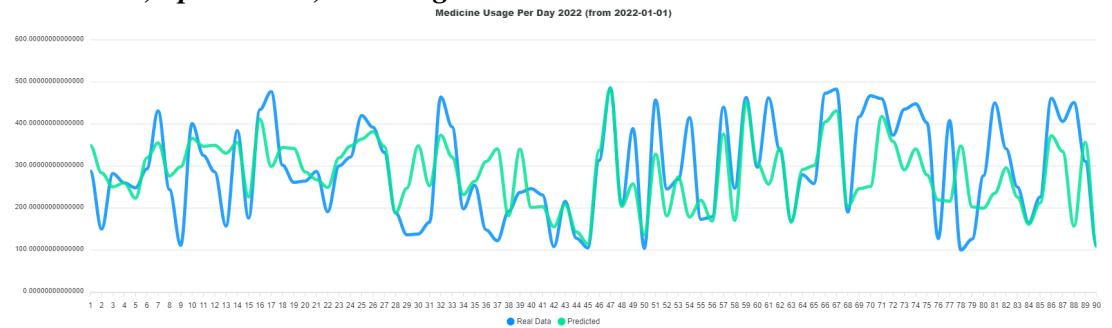
## BAB D Hasil Pengujian Model LSTM

---



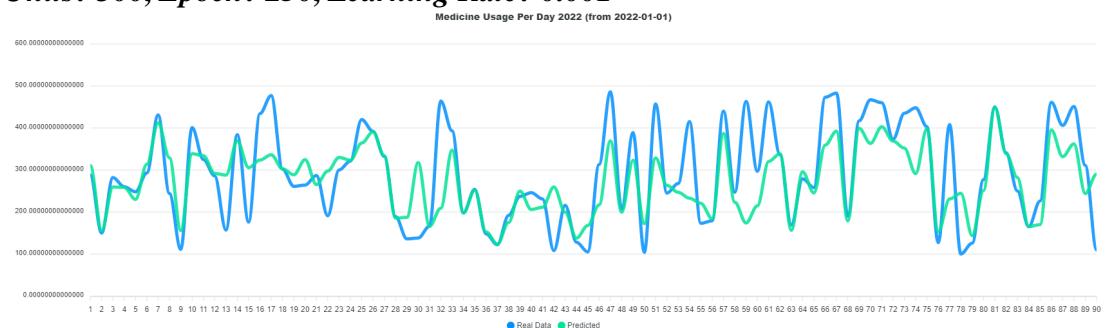
**Gambar 4.70** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 150, *Learning Rate*: 0.001 untuk forecasting horizon 90 hari

### 35. *Units: 300, Epoch: 200, Learning Rate: 0.001*



**Gambar 4.71** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 200, *Learning Rate*: 0.001 untuk forecasting horizon 90 hari

### 36. *Units: 300, Epoch: 250, Learning Rate: 0.001*



**Gambar 4.72** Perbandingan hasil prediksi dengan data asli model LSTM dengan konfigurasi *Units*: 300, *Epoch*: 250, *Learning Rate*: 0.001 untuk forecasting horizon 90 hari